

東北大學



NORTHEASTERN
UNIVERSITY

硕士学位论文

THESIS FOR MASTER'S DEGREE

论文题目 城市环境下无人驾驶汽车环境感知
技术研究

作者 毛立巍

学号 1800782

学院(部) 信息科学与工程学院

专业 控制理论与控制工程

指导教师 杨光红 教授

二〇二〇年六月

分类号_____ 密级 _____

UDC _____

学 位 论 文

城市环境下无人驾驶汽车环境感知技术研究

作 者 姓 名：毛立巍

作 者 学 号：1800782

指 导 教 师：杨光红 教授

东北大学信息科学与工程学院

申请学位级别：硕士 学 科 类 别：工学

学科专业名称：控制理论与控制工程

论文提交日期：2020 年 6 月 论文答辩日期：2020 年 6 月

学位授予日期：2020 年 7 月 答辩委员会主席：贾明兴

评 阅 人：李霄剑 范泉涌

东 北 大 学

2020 年 6 月

A Thesis in Control Theory and Control Engineering

**Research on Environment Perception
Technology of Self-Driving Vehicle in Urban
Environment**

By Mao Liwei

Supervisor: Professor Yang Guanghong

Northeastern University

June 2020

摘 要

近年来,随着计算机技术的发展以及传感器成本的降低,自动驾驶系统的研究取得了显著进展,无人驾驶汽车的技术日趋成熟。无人驾驶汽车具有提高生产率、行驶安全性以及道路使用率的作用,其可对环境产生积极的影响。未来,无人驾驶汽车会在成为城市交通系统中的主要交通工具。

自动驾驶系统一般由环境感知、定位、路径规划和车辆控制等若干个环节组成,其中环境感知是指自动驾驶汽车理解所处环境的能力,例如获取环境中障碍物的位置信息等。环境感知是路径规划和车辆控制的基础,也是整个自动驾驶系统中最重要的一环。

城市环境下的道路情况相较于其他驾驶环境更为复杂多样,需要对更多的环境信息进行感知,如路缘石与交通标志的检测等。本文主要研究城市环境下自动驾驶汽车的环境感知技术,并对城市环境下自动驾驶汽车的多个感知任务进行设计实现,具体内容如下:

首先,本文结合城市环境下道路的结构特征设计了一种基于激光雷达的路缘石检测算法。该算法简化了对激光雷达数据的预处理过程,并通过一种滑动窗口算法提取出粗糙路缘石点,最后使用所设计的路缘石位置预测方法对这些粗糙点进行处理,最终预测出路缘石的准确位置。该算法在保证运行效率的同时有效的提升了检测的精度。

其次,本文利用深度学习技术设计了一种基于摄像头的交通标志检测方法,使用该方法可以有效检测出日常行驶过程中常见的交通标志。此外,本文将该方法与光学字符识别技术进行结合还实现了对限速标志中限速信息的识别。

最后,本文给出了一种基于多传感器的前方车辆距离检测方法。该方法首先利用本文设计的深度神经网络对激光雷达数据进行处理,从中提取出前方车辆深度信息,其次将提取出的深度信息与二维目标检测器从摄像头数据中检测出的前方车辆二维信息进行匹配,最终得到前方车辆的距离信息。

关键词: 无人驾驶; 环境感知; 目标检测; 深度学习; 多传感器

Abstract

In recent years, with the development of computer technology and the reduction of sensor cost, significant progress has been made in the research of autonomous driving system, and the technology of self-driving car is becoming increasingly mature. Self-driving car have the potential to improve safety, productivity, and the usage rate of road, as well as good for the environment. Self-driving cars will become the main transportation in urban transportation systems in the future.

The autonomous driving system is generally composed of several parts, such as environment perception, path planning and vehicle control. environment perception refers to the ability of the self-driving car to understand the environment, such as obtaining the location information of the obstacles in the environment and detecting the traffic signs in the environment. Environmental perception is the basis of route planning and vehicle control and is also the most important part of the whole autopilot system.

Compared with other road conditions, the road condition in urban environment is more complex and diverse, requiring more environmental information perception, such as kerb and traffic sign detection. Therefore, this paper mainly studies the environmental perception technology of self-driving cars in urban environment, designs and realizes multiple perception tasks of self-driving cars in urban environment. The specific contents are as follows:

Firstly, a Lidar based kerb detection algorithm is designed based on the structural characteristics of urban roads. In the first place, this algorithm simplifies the preprocessing process of lidar data and use a sliding window algorithm to extract rough kerb points. Then , use the kerb position predicting method to process these rough points to get the exact position of the kerb. This algorithm not only guarantees the operation efficiency, but also effectively improves the detection accuracy.

Secondly, this paper uses deep learning technology to design a camera-based traffic sign detection method, which can effectively detect common traffic signs in daily driving. The method is combined with optical character recognition technology to recognize the speed limit information in the speed limit sign.

Finally, this paper presents a vehicle distance detection method based on multi -

sensor. Firstly, the depth information is extracted from the LiDAR data by using the deep neural network designed in this paper. Secondly, the extracted depth information is matched with the two-dimensional vehicle information extracted from the camera data by the two-dimensional target detector, and finally the distance information of the vehicle is obtained.

Key words: self-driving; environmental perception; object detection; Deep learning; multiple sensor

目 录

第 1 章 绪论.....	1
1.1 课题背景及意义.....	1
1.2 无人驾驶汽车研究现状.....	2
1.2.1 国外研究现状.....	2
1.2.2 国内研究现状.....	5
1.3 自动驾驶系统构成.....	8
1.4 环境感知技术.....	10
1.4.1 基于激光雷达的环境感知技术.....	10
1.4.2 基于摄像头的环境感知技术.....	11
1.4.3 基于多传感器的环境感知技术.....	12
1.5 本文研究内容及结构.....	13
第 2 章 实验平台	15
2.1 硬件概述.....	15
2.1.1 激光雷达.....	15
2.1.2 摄像头.....	18
2.2 软件概述.....	19
2.2.1 ROS	20
2.2.2 Pytorch	21
2.3 本章小结.....	21
第 3 章 基于激光雷达的路缘石检测	23
3.1 数据预处理.....	23
3.2 粗糙路缘石点提取.....	25
3.2.1 点集分割及排序.....	25
3.2.2 基于结构化道路特征的滑动窗口算法	27
3.3 路缘石位置预测方法.....	30
3.4 实验结果与分析.....	31
3.5 本章小结.....	32
第 4 章 基于摄像头的交通标志检测	33
4.1 数据集.....	33
4.1.1 CCTSDB 数据集	33
4.1.2 数据集预处理.....	34
4.2 交通标志检测网络.....	35
4.2.1 网络结构.....	35
4.2.2 网络输出与检测机制.....	39

4.3 损失函数.....	40
4.4 网络训练及检测效果.....	41
4.5 限速信息识别.....	42
4.5.1 限速信息识别方法.....	42
4.5.2 识别效果.....	45
4.6 本章小结.....	46
第5章 基于多传感器的车辆距离检测方法	47
5.1 数据集.....	47
5.1.1 KITTI 数据集	47
5.1.2 点云数据转化.....	48
5.2 距离信息提取网络.....	50
5.2.1 网络结构.....	50
5.2.2 网络输出与距离信息提取机制.....	51
5.3 损失计算.....	52
5.3.1 损失函数.....	52
5.3.2 损失计算策略.....	52
5.4 网络训练.....	53
5.5 车辆距离检测方法.....	54
5.6 检测效果.....	55
5.7 本章小结.....	55
第6章 总结与展望	56
6.1 总结.....	56
6.2 展望.....	56
参考文献.....	58

第1章 绪 论

1.1 课题背景及意义

无人驾驶汽车被认为是人类下一阶段的主要交通工具。由于其工作方式与由人类驱动的车辆有本质上的不同，具反应速度快、严格遵守逻辑规则等特点，因此其可以有效的减少交通安全事故的发生，并提升道路的使用效率^[1]。此外，无人驾驶汽车还能有效的缓解能源消耗，交通拥堵以及环境污染等问题。从广泛意义上来说，无人驾驶汽车将在安全，环境以及经济等多个方面对人们生活产生巨大的影响，并从根本上改变人们的生活^[2]。

首先，无人驾驶汽车可以有效的减少车祸的发生，极大的提升乘客和行人的的人身安全。据国家统计局统计，我国每年发生车祸约 15 万起，约占每年所发生交通事故的 7 成。每年因车祸造成的死亡人数约为 5 万，造成的受伤人数约为 15 万。除此之外，我国每年因车祸造成的直接财产损失约为 10 亿元人民币。车祸通常是由反应时间慢、注意力不集中、心理素质差等人类驾驶员的缺点所导致的。此外，酒精、疲劳、突发性疾病等因素也是导致车祸发生的重要诱因。无人驾驶汽车不同于人类驱动的汽车，其不存在人类驾驶员的缺陷，并且在反应速度、路径选择与执行速度等方面具有极大优势，因此无人驾驶汽车可以有效降低机动车交通事故死亡率。

其次，无人驾驶汽车在减少环境污染以及资源消耗方面也具有十分积极的作用。有关研究表明，使用自动驾驶汽车取代现有的普通汽车，将有望减少约九成碳排放量。此外，在过去 20 年里，为了使汽车能够满足严格的碰撞测试标准，提高车祸发生时的生还率。汽车制造厂商设计出来的汽车往往十分笨重。这种设计不仅会影响汽车的整体性能，还会消耗大量如钢铁，石油之类的资源，而无人驾驶汽车由于可以极大的减少车祸发生率，因此可以减少一些冗余的安全装备，使得车体重量大幅减轻，从而减少资源消耗^[3]。

再次，无人驾驶汽车还是解放生产力，推动经济发展的一大助力。无人驾驶汽车将人们从方向盘中解放了出来，并且有效解决交通拥堵以及停车难等问题^[4]。为人们节省出了大量的宝贵时间，极大地解放了人们的生产力，进而推动了经济的发展。另外，无人驾驶汽车还为老年人、残疾人等行动不便人士以及无车无照人士提供了出行便利，丰富了人们的出行方式，这将极大的促进旅游业发展，进而扩大人

们的消费需求。由此可见,无人驾驶汽车的兴起将从多方面推动我国经济的发展。

由上述分析可知,无人驾驶汽车将在多方面改变人们的生活方式。因此,对于无人驾驶汽车的研究是十分重要且有意义的。无人驾驶汽车是一个复杂的系统,对于研究人员来说,更为实际的做法是将自动驾驶系统按结构划分为感知、规划、控制三个子系统进行研究^[5]。同时,感知、规划与控制这一结构也是许多机器人系统的基础结构。

在自动驾驶系统中,汽车通过安装在其车身上的诸多传感器进行感知。这些传感器对原始环境信息及车辆自身信息进行采集,通过感知子系统内的软件算法将这些信息转换成诸如车道标记、障碍物位置、车身姿态等有意义的信息^[6]。规划子系统利用这些有意义的信息来制定车辆的短期(加速、转向等即时策略)和长期行为计划(车辆整体轨迹)。这些行为计划最终作为控制指令送入控制子系统^[7]。

从自动驾驶汽车的系统架构可以看出,感知是自动驾驶系统的基础功能,其为自动驾驶汽车提供行驶过程中所需的关键信息^[8]。凭借优秀的感知能力,自动驾驶汽车可以挑选出最优的行驶路线,平稳安全的行驶在道路上。过去十年中,许多环境感知相关技术取得了重大进展,在一些感知任务中,自动驾驶汽车的表现甚至优于人类,但想要自动驾驶汽车的感知能力全面超越人类,还有很长的路要走。

本文针对城市环境下无人驾驶汽车的环境感知技术进行研究,并对城市环境下无人驾驶汽车的多个感知任务进行设计实现。经过对无人驾驶汽车及其环境感知技术的多方面分析认为,该课题背景与实际应用紧密结合,具有极高的研究价值以及广阔的应用前景。

1.2 无人驾驶汽车研究现状

1.2.1 国外研究现状

无人驾驶汽车的概念可以追溯到 20 世纪 30 年代。1939 年纽约世界博览会上通用汽车公司的“Futurama”展厅展示了一种基于自动公路系统的无人驾驶汽车,该车利用自动公路系统产生的电磁场来实现自动驾驶功能^[9]。

1969 年,人工智能之父 John McCarthy 在其文章中提出利用计算机视觉对车辆进行导航的想法。1977 年,日本学者设计了一种基于摄像系统的无人驾驶汽车,该车利用计算机处理摄像系统采集到的道路图像以实现 20 英里每小时的低速自动驾驶。

20 世纪 80 年代早期,德国慕尼黑联邦国防军大学 Ernst Dickmanns 团队开发

了一种视觉导航车辆，该车可以在没有其他车辆的情况下以 100 公里/小时的速度行驶^[10]。20 世纪 80 年代中期到 21 世纪初，卡内基梅隆大学 NavLab 实验室开发了 NavLab 系列智能汽车^[11]，其中 NavLab 5 智能汽车于 1995 年 7 月进行了一次 3000 英里的横穿美国之旅，在这段旅程之中 NavLab 5 的操作人员只负责控制车辆的油门和刹车。除此以外，NavLab 5 在 98%的时间里都处于自动驾驶状态。

1989 年，卡内基梅隆大学 Dean Pomerleau 教授开发了一种基于深度学习技术的无人驾驶汽车 ALVINN^[12]，该车可以在公路上以 112 公里每小时的速度正常行驶一小时以上。ALVINN 是首辆使用深度学习技术直接进行控制的无人驾驶汽车，其将车身传感器数据送入神经网络来直接得到控制信号。ALVINN 的成功证明了是一种端到端自动驾驶的可行性，也为自动驾驶技术的研究开辟了新的方向。

2004 年至 2007 年期间，为促进无人驾驶汽车的发展，美国国防高级研究计划局 DARPA 组织了三次无人驾驶挑战赛。第一届比赛被命名为“Grand Challenge”，于 2004 年在美国莫哈维沙漠举办，比赛要求所有参赛车辆在十小时内穿越一百多英里长的沙漠路段。第一届挑战赛中所有参赛车辆均未能完成挑战，参赛车辆中的最优者仅行驶了不到 8 英里的路程。第二届“Grand Challenge”挑战赛于 2005 年举办，此次比赛中的驾驶场景较之第一届挑战赛更为复杂，然而此次比赛中有五个团队完成比赛，其中图 1.1 所示的斯坦福团队的参赛车辆“Stanley”以小于 7 小时的最好成绩夺得冠军^[13]。2007 年，DARPA 举办了最后一届自动驾驶挑战赛，此次比赛被命名为“Urban Challenge”^[14]。顾名思义，这一届比赛再次提升了路况的复杂程度，要求参赛车辆在一个模拟的城市环境下行驶 60 英里。最终六支比赛队伍完成了此次比赛，其中三支队伍在 4.5 小时内完成了比赛。三届 DAPRA 挑战赛加深了企业和科研机构之间的合作，极大的推动了无人驾驶汽车及其相关领域的发展，促进了无人驾驶相关领域的多学科融合，并且在全球引起了无人驾驶技术的研究热潮。



图 1.1 “Stanley” 智能车
Fig. 1.1 "Stanley" smart car

随着越来越多的公司与科研机构加入进无人驾驶技术的研究队伍，车辆的自动化等级日益提高。2009 年 1 月，Google X 实验室启动了一项名为“Waymo”的无人驾驶研究计划^[15]。项目初期，Waymo 团队共改造出了 7 辆无人驾驶汽车，这些车使用摄像头、激光测距仪等传感器进行环境感知，并使用高精地图进行导航。2012 年 5 月 Waymo 获得美国首个自动驾驶牌照。2017 年，Waymo 在进行载客测试，并于第二年推出 Waymo 出租车服务。截至目前，Waymo 无人车总载客量已超 10 万人次，其总行驶里程也已突破 3000 万公里大关，而其脱离接触率仅为 0.09，即平均每行驶约 1.8 万公里需要人工干预一次。图 1.2 为谷歌 Waymo 无人驾驶汽车。



图 1.2Waymo 无人驾驶汽车
Fig. 1.2 Waymo self-driving car

此外，一些老牌汽车公司如奔驰，奥迪，通用等也都在进行无人驾驶技术的研究，并取得了不错的成绩。值得一提的是，2017 年奥迪汽车公司宣称其推出的全新一代奥迪 A8 已经可以实现在一定条件下的无人驾驶，这也是世界首款具备这一功能的量产车型^[16]，该车如图 1.3（a）所示。

除老牌车企外，一些新兴车企以及其他领域企业如特斯拉，Uber，苹果等也在开发各自的自动驾驶系统。其中值得注意的是于 2014 年推出的特斯拉“Autopilot”自动驾驶系统^[17]，该系统是全球首个商用自动驾驶系统，与大多数自动驾驶系统不同的是，“Autopilot”并未配备激光雷达传感器，其另辟蹊径，将摄像头作为主要传感器再辅以毫米波雷达和超声波雷达来进行环境感知。图 1.3（b）为配备了“Autopilot”自动驾驶系统的特斯拉 Model 3。




图 1.3 奥迪 A8 与特斯拉 Model 3
Fig. 1.3 Audi A8 and Tesla Model 3

1.2.2 国内研究现状

中国对无人驾驶的研究始于上世纪 80 年代。1980 年由国家立项，多家国内科研机构参与研发的遥控驾驶防核化侦察车项目，拉开了我国研究无人驾驶技术的大幕。我国对于无人驾驶技术的研究虽然晚于欧美国家，但发展势头却十分迅猛。

上世纪 90 年代初，由清华大学、国防科技大学等 5 家科研机构共同参与研发的 ATB-1 无人驾驶汽车研制成功，该车是我国第一辆真正意义上的无人驾驶汽车，其时速可达 21 公里每小时。“九五”期间，ATB-1 的继任者 ATB-2 研制成功，ATB-2 较之于 ATB-1 在行驶速度上有了很大的提升，其最大行驶速度可达约 75 公里每小时^[18]。2005 年，ATB 系列无人车第三代产品 ATB-3 问世，其相较于前两代做了感知，规划等多方位的提升。ATB 系列自动驾驶汽车是我国自动驾驶领域的一座里程碑，其代表了当时我国在无人驾驶研究方面的最高水平，为我国培养了许多无人驾驶领域的人才。

2004 年至 2007 年期间，美国国防高级研究计划局成功举办了三届无人驾驶汽车挑战赛引起了全球的关注，在世界范围内掀起了研究无人驾驶技术的热潮，极大的推动了无人驾驶技术的发展与进步。2009 年 6 月国家自然科学基金委员会主办了第一届“智能车未来挑战赛”^[19]。首届比赛于古都西安举行，参赛队伍来自包括清华大学、国防科技大学等在内的数十家国内外科研机构，比赛要求参赛车辆在没有碰撞的情况下行驶完指定的路段，并且路段中还铺设了多个障碍物与交通信号灯，重点考察车辆的环境感知能力，首届比赛中湖南大学、北京理工大学与上海交通大学分别获得冠亚季军。

自 2009 年至今，“智能车未来挑战赛”已经举办了十一届。在此期间，该项赛事的比赛要求越来越复杂，越来越细致，该项赛事的参赛队伍也由最初的 7 支队伍增长至目前的 20 多支队伍。除此之外，在这十一届比赛中还涌现出了许多优秀

的参赛队伍，来自军事交通学院与西安交通大学的参赛队伍均在此项赛事上实现过三连冠。其中值得注意的是，军事交通学院的参赛车辆曾于 2012 年在真实高速公路上进行测试并以平均约 80 公里每小时的速度安全行驶了一百多公里。图 1.4 (a) 与图 1.4 (b) 分别为军事交通学院参赛车辆“军交猛狮号”^[20]与西安交通大学参赛车辆“先锋号”。与 DAPRA 自动驾驶挑战赛相同，“智能车未来挑战赛”的出现极大的促进了我国无人驾驶相关领域的发展，不断的缩小我国在无人驾驶领域上与欧美国家的差距。




图 1.4 “军交猛狮号”与“先锋号”

Fig. 1.4 AMT Lion and Pioneer

受“智能车未来挑战赛”影响，在无人驾驶领域，学术界与产业界的合作日益加深。2011 年，国内老牌车企一汽与国防科技大学共同开发的无人驾驶汽车研制成功，如图 1.5 (a) 所示。该车以约 90 公里每小时的平均速度行驶完了从长沙至武汉间近 300 公里的路程^[21]。2015 年，长安汽车与多家企业和科研机构研制的无人驾驶汽车于重庆亮相，如图 1.5 (b) 所示。2016 年，长安汽车成功对该车进行了一次无人驾驶测试。值得注意的是这次测试的起点为重庆，终点为北京，整个路程约 2000 公里^[22]。

在一汽、长安等车企之后，宇通、福田等以大型车辆为主业的车企也开始了对无人驾驶技术的研究。2015 年下半年，宇通客车对其研发的自动驾驶客车进行测试，该车最终在一段开放的高速公路上成功行驶了 30 多公里，图 1.6 (a) 为宇通自动驾驶客车。此次测试是全球首个在开放公路上进行的自动驾驶客车测试^[23]。2018 年初，福田汽车在位于北京海淀的国家智能汽车与智慧交通示范区对图 1.6 (b) 所示的自动驾驶卡车进行测试，测试结果表明该车在自动制动，行人及交通信号检测等方面有着亮眼的表现^[24]。



图 1.5 红旗 HQ3 与长安睿聘无人驾驶汽车
Fig. 1.5 Hong Qi HQ3 and CHANGAN RAETON self-driving car



图 1.6 宇通自动驾驶客车与福田自动驾驶卡车
Fig. 1.6 Yutong autonomous bus and FOTON autonomous truck

除传统车企外，百度^[25]、滴滴^[26]等互联网公司也加入进了无人驾驶技术研究的队伍中。2013 年，百度开始进行无人驾驶技术的研发。次年 9 月，百度与宝马汽车达成合作正式进入无人驾驶领域。2015 年百度对其无人驾驶汽车进行自主测试，整个测试路段涵盖了高速、环岛等多种驾驶场景。测试车辆不仅成功的跑完了全程，还多次完成了跟随、变道，超车等驾驶操作，图 1.7 为百度与宝马合作研制的无人驾驶汽车。



图 1.7 百度与宝马联合开发的无人驾驶汽车
Fig. 1.7 The self-driving car jointly developed by Baidu and BMW

国内研究无人驾驶技术的热情日益高涨，一些新成立的无人驾驶公司如雨后春笋般冒了出来，如寒武纪，驭势科技，图森未来等。这些科技公司大多着力于无人驾驶细分产品研发，它们的出现使我国自动驾驶技术研究领域出现了百家争鸣

的局面，促进了我国无人驾驶技术的发展。

1.3 自动驾驶系统构成

自动驾驶系统通常由三类子系统构成^[27]，即感知、规划和控制，跟据具体任务的不同三类子系统又被细分为许多小类，具体划分情况如图 1.8 所示。




图 1.8 自动驾驶系统结构图

Fig. 1.8 The structure of self-driving system

感知系统用于无人驾驶汽车对车身周围环境的感知以及对自身位姿状态的感知^[28]。因此，其由环境感知系统与定位系统两个子系统共同组成。

环境感知是无人驾驶汽车的基础功能，它是指自动驾驶汽车理解周围环境的能力，它通过对摄像头、激光雷达等车体外部传感器所采集数据进行提取，进而获取车身周围环境信息。

环境感知系统为无人驾驶汽车的安全行驶提供了重要保障。其为无人驾驶汽车提供了极为重要的驾驶环境信息，这些信息包括汽车前方障碍物信息，交通标志及交通信号灯信息，车道线及可行使区域信息，甚至前方车辆及行人的轨迹预测信息等等。

从实现环境感知任务的方法来说，环境感知系统所用到的感知技术包括目标检测、目标识别与追踪、三维环境重构以及空间布局的语义分割等方法。目前，基于深度学习等人工智能方法的环境感知系统是国内外的研究热点，该系统一般通过部署多个训练好的深度神经网络模型来进行不同的感知任务。对无人驾驶汽车而言，这些模型可以准确提取出道路形状、车道线位置、交通信号灯状态、限速标识以及障碍物位置等驾驶环境信息。

从实现环境感知任务的传感器来说，目前环境感知系统中常见的传感器包括

摄像头、红外热像仪、激光雷达、超声波雷达以及毫米波雷达等。通常,由于每种传感器都有其自身的优点与缺点,单一传感器无法完美的感知各种环境信息^{[29][30]}。为解决这一难题,自动驾驶汽车往往配有多种传感器。根据各自特性,这些传感器被用来进行不同的环境感知任务,例如使用摄像头获取交通标志及交通信号灯状态等信息,利用激光雷达获取障碍物位置信息。此外,为使环境感知系统具有更高的感知精度以及更好的鲁棒性,还可以利用优势互补的方法,通过将多个传感器数据融合进行环境感知。多传感器数据融合的方法麻烦之处在于,需要根据具体问题对所使用的多个传感器进行标定校准^[31]。虽然标定过程较为麻烦,但基于多传感器的环境感知方法可以有效地提升自动驾驶汽车的安全性,因此基于多传感器的环境感知技术也是当前研究的一大热门。

定位系统用于为无人驾驶车辆提供自身位姿状态信息。想要准确获取车辆的位置和方向等姿态信息往往是十分困难的,因此定位问题常常被表述为一个姿态估计问题。

由卫星导航系统和惯性导航系统的融合而成的组合定位方法是目前流行的车辆定位方法之一。卫星导航系统可以定位车辆所在位置,根据信号强度以及所用设备质量,其定位精度从几十米到几毫米不等。与卫星导航系统不同,惯导系统无需外部设施,其使用加速计、陀螺仪和信号处理技术来估计车辆的姿态,但其缺点是,随着工作时间的增加,其导航精度会随之下降。而将两者结合的组合定位方法,以合理的方式融合两者优势,提高了导航的精度。然而由于可能存在的卫星信号长时间缺失等情况,仅仅依靠该方法仍不能实现车辆对其自身位姿的准确估计,进而达到无人驾驶所需的水平。

为满足无人驾驶汽车的定位需要,同时定位与测绘(SLAM)技术近年来得到广泛关注。SLAM的目标是在无人驾驶汽车行驶范围内利用车身激光雷达或摄像头等传感器构建一个高精度地图,利用该地图计算出车体与所处环境的相对位置。SLAM技术自诞生以来一直是无人驾驶领域一个十分热门的研究方向,该技术的发展将使得无人驾驶汽车真正具备自主定位能力^[32]。

规划系统由任务规划、全局路径规划和局部路径规划三个子系统共同组成。这三个子系统用于制定由高至低三种不同层次的决策从而使无人驾驶汽车高效率地完成目标任务。

任务规划属于高层规划^[33],其将复杂的无人驾驶任务拆解为若干个相对简单的子任务,并给出执行各个子任务的先后顺序。全局路径规划属于中层规划,在不

考虑交通规则等约束条件下为各个子任务的达成提供尽量短的路径。局部路径规划属于底层规划，其结合全局路径规划结果以及感知系统提供的环境与车身位姿信息，在时间、交通规则等约束下对无人驾驶汽车的速度和方向等控制量进行规划，保证无人驾驶汽车的正常行驶。全局与局部路径规划在本质上没有太大的区别，因此实现它们的方法较为类似。

路径规划过程会用到环境模型和搜索算法。常用的环境模型包括 Voronoi 图、切线图以及可视图。传统搜索算法按搜索方式分为确定与不确定两种。其中经典的确定搜索算法包括 Dijkstra 算法、最佳优先搜索算法、A*算法和人工势场法等。经典的随机搜索算法有随机搜索树算法、随机路径规划算法和概率路标算法等。除传统搜索算法外，近年来，一些基于人工智能技术的智能搜索算法也取得了不错的效果。这也是今后一个重要的研究方向。

控制系统的主要作用是将规划系统给出的规划结果转化为车上各个执行器的控制指令，这些指令对自动驾驶汽车的速度以及方向进行控制，进而使无人驾驶汽车按照规划系统的规划行驶。除此之外，对车灯、喇叭等部件的控制也由控制系统负责。

控制系统通常由多个闭环控制器组成，如速度、角度和位置闭环控制单元。各控制单元常以串联的方式协同工作。控制器设计方法种类繁多，其中有 PID、模型预测控制等经典的传统控制方法，也有基于神经网络或模糊逻辑的智能控制方法。

1.4 环境感知技术

环境感知是实现汽车自动驾驶的关键环节，对该技术的研究是整个自动驾驶系统的重中之重，因此环境感知技术也是当下无人驾驶领域被研究最多的一个部分。目前，基于激光雷达的环境感知技术、基于摄像头的环境感知技术与基于多传感器的环境感知技术是无人驾驶环境感知领域最热门的三个方向，下面将对这三种环境感知技术进行介绍。

1.4.1 基于激光雷达的环境感知技术

激光雷达是现有绝大多数无人驾驶汽车所不可或缺的重要传感器。激光雷达是一种光探测与测距设备。其通过向外界发送激光脉冲并接收这些激光脉冲在接触物体表面后反射回来的激光点（这些点包含了其相对于激光雷达的三维位置信息）从而获得一个动态三维地图，这些激光点的集合被称为点云。

传统的基于激光雷达的环境感知方法大致分为 3 类^[34]。第一种是直接基于点云的方法,这种方法通常可以提供精确的环境表示,但运行效率较低,一般在对点云数据进行处理前需要对点云进行过滤处理以减少点的数量^{[35][36]}。其次是基于特征的方法,这种方法首先从点云中提取一些如曲线、平面^[37]之类的特征,接着再用这些提取出的特征进行环境表示,这种方法具有较高的运行效率,但无法完美适应所有环境。最后是基于网格的检测方法,这种方法将空间离散成小网格,对点云进行下采样^[38],这种方法虽然具有较高运行效率且不依赖于设定好的曲线、平面等特征,但确定离散化网格的尺寸却较为麻烦。

由于激光雷达所提供的点云数据给出了雷达周围环境的三维信息,因此激光雷达经常被用来进行 3D 目标检测。基于激光雷达的传统 3D 目标检测算法一般分为分割与分类两步。分割是指对点云中的点进行聚类,将其分成若干组点。分类是指对分割后得到的若干组点进行分类,判断这些点分别属于什么类的物体,如人、狗、车等。

根据实现原理的不同,点云的分割算法共分为 5 类,即基于边缘的分割算法、基于区域的分割算法、基于属性的分割算法、基于模型的分割算法和基于图的分割算法^[39]。这五种算法根据其原理的不同具有各自的优缺点,适用于不同的感知任务。例如基于边缘的分割方法,其要求被检测物体具有较强的边缘特征,因此适合用于路缘石检测一类的任务当中^[40]。

将点云分割后,需要使用分类算法对这分割之后的点进行分类。传统方法中常使用 SVM 分类器^[41]来对分割后的点云进行分类,但这种分类器较为粗糙,无法满足自动驾驶的需求。

随着深度学习技术的蓬勃发展。近几年利用深度神经网络处理点云进而实现环境感知的算法层出不穷。例如用于点云语义分割的 SqueezeSeg^[42]、RangeNet++^[43]等,用于 3D 目标检测的 VoxelNet^[44]、YOLO3D^[45]、Complex-YOLO^[46]等。这些算法不仅感知精度远好于传统算法,并且在实时性上也优于传统算法,基于深度学习的点云目标检测方法也是目前最有效的检测方法,其极大的推动了无人驾驶环境感知技术领域的发展。

1.4.2 基于摄像头的环境感知技术

摄像头是日常生活中常见的一种传感器,其也是无人驾驶汽车环境感知系统中不可或缺的一部分。由于摄像头与激光雷达在构造上有所不同,利用单一摄像头

很难获取物体的三维信息,但这并不影响其重要性,其所采集到的环境信息相较于激光雷达更为稠密,可以实现更高精度的环境感知。

传统的基于摄像头的环境感知方法,如 HOG^[47]、SIFT^[48]等,依赖于一些先验知识可以实现如车道线、行人、车辆检测之类的任务。但这些传统方法检测效果往往差强人意,并且在光照等因素的影响下,检测效果还会进一步下降。此外,传统算法的运行效率往往也无法令人满意。因此,目前传统的检测算法已很少出现在无人驾驶系统当中。

近几年随着深度学习的迅速发展,基于深度学习的图像处理方案被广泛应用并取得了良好的效果。基于深度学习的检测算法可以达到传统方法无法企及的精度。不同于传统检测算法里面人工设置的浅层简单映射,深度学习方法使用的是多层的复合映射,其具有更高的自由度,该方法在图像检测和分割等多项任务上都已经接近甚至超过了人类的平均水平。

目前,基于深度学习的感知算法已取代传统算法成为研究的主流,各种基于深度学习的感知算法不断被提出并验证。如目标检测算法中经典的 RCNN 系列(两步法)^{[49][50][51]},YOLO 系列^{[52][53][54]}以及 SSD 系列^{[55][56][57]}等,语义分割算法中极具代表性的 DeepLab^[58]、RefineNet^[59]等。

1.4.3 基于多传感器的环境感知技术

基于多传感器的环境感知技术是近些年来极为热门的环境感知技术之一,其可以充分的利用各传感器的特点进行优势互补,从而实现一加一大于二的感知效果。

以激光雷达与摄像头为例,这两种传感器各自的优缺点都十分的明显。摄像头虽然可以提供丰富的环境信息但极容易受到环境光的干扰且无法提供物体的三维信息。激光雷达与摄像头恰恰相反,其不受环境光的干扰而且可以提供物体的三维信息,但其所提供的环境信息极为稀疏。若单独利用这两种传感器中的一种进行环境感知任务会出现如各种各样的问题,比如在夜晚难以使用摄像头进行目标检测、利用激光雷达难以准确检测远处物体等。基于多传感器的环境感知技术将这两种传感器结合起来,用这两种传感器各自的长处弥补对方的短处最终以一种更为理想的方式进行环境感知,极大的提高了环境感知系统的鲁棒性以及整个无人驾驶系统的安全性。

总之,基于多传感器的环境感知技术对于构建一个稳定的环境感知系统是十分

必要的。目前,已有一些使用深度学习技术实现的基于多传感器的环境感知算法,如 MVOD^[60]、AVOD^[61]等。

1.5 本文研究内容及结构

本文主要研究城市环境下无人驾驶汽车的环境感知技术,对城市环境下无人驾驶汽车的多个环境感知任务进行了设计实现,实现内容具体如下:首先,结合城市环境下道路的结构特征设计了一种基于激光雷达的路缘石检测算法。该算法在保证运行效率的同时有效的提升了检测的精度。其次,本文利用深度学习技术设计了一种基于摄像头的交通标志检测器。将该检测器与光学字符识别技术结合,还实现了对限速标志中的限速信息的识别。最后,本文提出了一种基于多传感器的车辆距离检测方法。该方法使用摄像头与激光雷达两种传感器,可以有效检测出道路上的车辆并给出车辆的距离信息。

本文主要内容及结构安排如下:

第1章首先介绍了本课题的研究背景及意义;其次介绍了无人驾驶汽车的国内外发展及研究现状;接下来介绍了无人驾驶汽车的三大组成部分,即感知、规划与控制;然后又根据使用传感器策略的不同,大致介绍了三类环境感知技术,即基于激光雷达的环境感知技术、基于摄像头的环境感知技术、基于多传感器的环境感知技术;最后本章给出了本文的主要内容及结构安排。

第2章从硬件和软件两个层面对本文所使用的实验平台进行介绍。首先在硬件方面,介绍了本文主要用到的两个传感器——激光雷达与摄像头;接着在软件方面介绍了本文实验中主要使用到的机器人操作系统ROS以及深度学习框架Pytorch。

第3章设计了一种基于激光雷达的路缘石检测算法。该算法极大程度上简化了对激光雷达数据的预处理过程,并在此基础上通过一种滑动窗口方法提取出粗糙路缘石点,最后使用所设计的路缘石位置预测方法对这些粗糙点进行处理,最终预测出路缘石的准确位置。该算法在保证运行效率的同时有效的提升了检测的精度。

第4章设计了一种基于摄像头的交通标志检测方法。本章利用深度学习技术设计了一个交通标志检测网络,并对该网络的检测机制、训练方法进行详细介绍。该网络可以在保证实时性的基础上有效的检测出日常行驶过程中常见的交通标志。此外,本章还将该网络检测结果与光学字符识别技术进行结合设计了一种限速信息提取方法,在完成交通标志检测的同时还实现了对道路限速信息的获取。

第 5 章给出了一种基于多传感器的车辆距离检测方法。该方法首先利用本文设计的深度神经网络对激光雷达数据进行处理，从中提取出深度信息，其次将提取出的深度信息与二维目标检测器从摄像头数据中提取出的车辆二维信息进行匹配，最终得到车辆的距离信息。

第 6 章对本文全部研究内容进行了分析总结，并对未来的研究内容及工作进行展望。

第 2 章 实验平台

本章对所使用到的实验平台进行介绍。图 2.1 为本文中所用到的实验平台，该实验平台是由激光雷达、摄像头、IMU 元件、UPS 电源、线控底盘等元件组成的一个小车，利用该平台可对本文中所设计的算法等进行实验验证。本文中主要使用到的传感器元件为激光雷达与摄像头。




图 2.1 本文所使用的实验平台

Fig. 2.1 The experimental platform used in this paper

2.1 硬件概述

2.1.1 激光雷达

激光雷达是自动驾驶汽车环境感知系统最重要的组成部分，激光雷达每转动一周，产生一帧激光点云，每帧激光点云包含大量三维激光点，这些三维点描述了雷达可探测范围内的环境。激光雷达具有测距精度高、实时性好和不易受外界干扰等优点，其可以此外，本文将该方法与光学字符识别技术进行结合还实现了对限速标志中限速信息的识别。激光束的有效距离）探测障碍物的位置与形状。

按成像维度的不同，激光雷达可分为二维激光雷达与三维激光雷达。三维激光雷达又被称为多层激光雷达，相比于二维激光雷达，其可以扫描出物体的空间特征。三维激光雷达也可称为多线激光雷达，根据线数的不同，这种激光雷达进一步可细分为 16 线激光雷达、32 线激光雷达、64 线激光雷达和 128 线激光雷达等多种类

型, 线数越多的激光雷达, 扫描点越密集, 得到物体的空间特征越明显。

目前, Velodyne 公司生产的 HDL_64E 三维激光雷达在自动驾驶领域中应用最为广泛。如图 2.2 所示, 本文实验中所使用的激光雷达是 Velodyne 公司的 HDL_64E S3 型三维激光雷达, 其可发射 64 条激光射线。该激光雷达的水平视野范围为 360° , 根据雷达旋转频率的不同, 其角分辨率从 0.08° 至 0.35° 不等, 该激光雷达垂直视野范围为其中心位置正前方为水平线 (水平线位置为 0°) 向上 2° , 向下 24.8° 。在 HDL_64E S3 激光雷达垂直视野范围内, 其可发射 64 条激光射线, 这 64 条射线按其水平夹角进行排序 (射线 1 与水平线夹角为 -24.8° , 射线 64 与水平线夹角为 $+2^\circ$), 这 64 条射线按其所属激光发射器不同分为上下两层。上层 32 条激光射线分布在 $+2^\circ$ 到 -8.33° 的垂直视野范围内, 每两条激光间隔大约为 $1/3^\circ$; 下层 32 条激光射线分布在 -8.93° 到 -24.8° 的垂直视野范围内, 每两条激光间隔大约为 $1/2^\circ$ 。HDL_64E S3 型激光雷达有着 120m 的扫描范围, 约 2cm 的误差, 其转动频率可调范围为 5Hz-20Hz, 本文中将该激光雷达的转动频率设定为 10Hz。



图 2.2 本文所使用的激光雷达
Fig. 2.2 The LiDAR used in this paper

HDL_64E S3 激光雷达通过以太网与上位机建立连接。其以 UDP 数据包的形式与电脑进行通信。在每次探测的过程中 (发射与接收激光束), 激光雷达都会旋转一定的角度。待到每次探测完成后, 激光雷达将每束激光探测到的距离与激光雷达转角信息以 UDP 数据包的形式发送到上位机, 由于 HDL_64E S3 激光雷达的激光发射器与激光接收器分为上下两层各 32 对, 因此每次探测的数据分两次发送, 每次发送 100 字节。雷达旋转一周, 得到的所有数据为一帧点云数据, 图 2.3 为一帧点云的可视化效果图。




图 2.3 点云可视化效果
Fig. 2.3 Point cloud visualization

由上述可知，激光雷达直接采集到的数据是每个激光点与激光雷达的距离信息以及激光雷达的旋转角度信息，而非每个激光点相对于激光雷达坐标系的三维坐标。要获取激光点在激光雷达坐标系下的坐标信息，需要将激光雷达直接采集到的信息与每条激光束的俯仰角结合进行计算，式(2.1)为具体计算公式。

$$\begin{cases} x_l = L \sin \delta \cos \theta \\ y_l = L \sin \delta \sin \theta \\ z_l = L \cos \delta \end{cases} \quad (2.1)$$

式(2.1)中， L 为激光点距激光雷达距离， δ 为激光束与激光雷达坐标系 z 轴夹角， θ 为激光雷达的旋转角度。为便于理解，图 2.4 给出将采集到的激光点 P 信息转化为激光点 P 在激光雷达坐标系下三维坐标的过程示意图，图中坐标系即为激光雷达坐标系。

表 2.1 为 HDL_64E S3 激光雷达参数表。




图 2.4 获取激光点三维坐标示意图
Fig. 2.4 Schematic of obtain the 3d coordinate of laser point

表 2.1 Velodyne HDL_64E S3 激光雷达参数表
Table 2.1 Parameter table of Velodyne HDL_64E S3 LiDAR

参数	值
尺寸	203*284(cm)
重量	15kg
探测范围	120m
探测精度	< 2cm
数据大小	220 万点/秒
垂直视野	26.8°
垂直角分辨率	0.4°
水平视野	360°
水平角分辨率	0.08°-0.35°
电压	10-32VDC
功耗	60W
工作温度	-10℃- 50℃

2.1.2 摄像头

摄像头是自动驾驶汽车用来实现环境感知的重要传感器之一，相较于激光雷达，其具有价格低廉、分辨率高的优点，因此被大量应用于无人驾驶领域。

摄像头主要用于感知无人驾驶汽车周围的多种环境信息，包括车道线的识别、车辆的检测和障碍物定位等等。为实现这些感知任务，一般先采用摄像机获取原始图像，再通过一些传统或基于深度学习的计算机视觉技术对图像进行处理分析，最终将分析得到的模型应用于无人车的实时环境感知。

根据感光元件数量的不同，摄像头主要分为单目、双目、三目和全景几种类型。目前，市场上最为常见的摄像机是单目摄像头，它可以满足视觉感知任务的基本要求，且价格低廉，很大程度上降低了无人驾驶汽车的成本。本文在实验中使用如图 2.5 所示的一个单目摄像头，该摄像头是德国 Basler 公司生产的 ace 系列工业摄像头，其具体型号为 acA1920-40gc。



图 2.5 Basler acA1920-40gc 摄像头
Fig. 2.5 Basler aca 1920-40gc camera

本文中所使用摄像头的具体规格信息如表 2.2 所示。

表 2.2 Basler acA1920-40gc 摄像头参数表
Table 2.2 Parameter table of Basler acA1920-40gc camera

参数	值
感光元件类型	CMOS
感光芯片	Sony IMX249
靶面尺寸	1"
分辨率	1920*1200
像素	2.3MP
帧速率	40fps
黑白/彩色	Color
镜头接口	C-mount
工作温度	0-50℃
数据接口	GigE
电压	12VDC
功耗	<3W

实验中摄像头所配镜头为日本 Kowa 公司所生产的 Kowa Lens LM6HC F1.8 f6mm 1"镜头，该镜头如图 2.6 所示。



图 2.6 Kowa Lens LM6HC F1.8 f6mm 1"镜头
Fig. 2.6 Kowa Lens LM6HC F1.8 f6mm 1"

该镜头的具体规格信息如表 2.3 所示。

表 2.3 Kowa Lens LM6HC F1.8 f6mm 1"镜头头参数表
Table 2.3 Parameter table of Kowa Lens LM6HC F1.8 f6mm 1"

参数	值
焦距	6mm
靶面尺寸	1"
光圈	F1.8 - 16
聚焦范围	0.1m
镜头接口	C-mount
工作温度	-10-50℃
重量	215g

2.2 软件概述

2.2.1 ROS

ROS 的中文全称是机器人操作系统，其是由 Willow Garage 公司和斯坦福大学人工智能实验室研发提出的一种分布式框架。开发者能够在此框架下编程实现自动驾驶系统中各软件的功能。此框架利用通讯机制，将系统中的各功能组合到一起。

ROS 具有分布式点对点的特点，其可以降低系统的运算压力，提高系统的容错能力。此外，开发者还可以使用多种语言在 ROS 平台进行编程。ROS 中所包含的功能十分繁多。由于篇幅所限，本小节仅对本文中涉及到的 ROS 相关内容进行介绍。

本文实现的环境感知任务中主要用到了 ROS 的节点通讯机制。大概流程为：首先，利用节点通讯机制中的订阅方式获取传感器数据进行环境感知；其次，通过节点通讯机制中的发布方式将感知结果传递给实验平台的规划模块。ROS 的节点通讯机制是指节点之间进行通讯的方式。节点是 ROS 的一个基本概念，也称 ROS 进程。通俗来讲，节点就是一个用来实现某种任务的程序段，这些程序段一般是由 C++语言或 Python 语言编写而成。以本文为例，本文中用来实现环境感知任务的一个个程序就是一个个节点。节点之间通过传递消息进行互相通信，消息是一个数据结构，其由类型字段组成，ROS 平台下定义了许多消息类型，如 `sensor_msgs` 等。此外，ROS 还支持开发者自定义数据结构的消息类型。发出消息的节点称为消息发布者，接收消息的节点称为消息订阅者，两者建立通信后，发布者与订阅者通过话题进行消息的传输。话题是消息的载体，一个节点可以发布与订阅多个话题，一个话题也可以被多个节点发布或订阅。话题的发布与订阅是多对多模式，但消息的传输是单向的。图 2.7 为 ROS 的节点通讯机制示意图。




图 2.7 ROS 节点通讯机制

Fig. 2.7 Node communication mechanism of ROS

此外，在本文中还使用到了 ROS 的 3D 可视化工具 `rviz` 和录包功能。`rviz` 主要被用来对路缘石检测结果进行 3D 可视化。录包功能主要用来对实验平台行驶过程中的传感器采集到的数据进行记录，记录下的数据可重现实验平台之前的运动

数据，极大的方便了程序的调试工作。

调用 ROS 的 3D 可视化工具与录包功能可通过输入简单的指令实现，因此这里不进行赘述。

2.2.2 Pytorch

Pytorch 是目前在深度学习领域使用最为广泛的深度学习框架。它是一个由多个组件组成的 python 库。Pytorch 的这些组件简化了研究人员的编程操作，极大的加快了研究人员的研究速度，下面对本文中一些常用到的 Pytorch 组件进行介绍。

本文中用到最多的 Pytorch 组件包括 `torch.autograd`、`torch.nn`、`torch multiprocessing` 和 `torch.utils`。`torch.autograd` 是一个自动微分库，Pytorch 中的自动求导机制依赖于该库得以实现，而深度学习技术的核心是依赖于链式求导的反向传播算法，因此该库也是 Pytorch 最重要的组成部分。`torch.nn` 是一个集成了自动求导机制的神经网络库，该库预置了一些常用的神经网络模块，也支持用户根据自身需要自行构建一些模块，此外该库内还包含有一些常用的损失函数等，该库的存在极大的提高了神经网络的搭建速度。`torch multiprocessing` 是一个多进程模块，其主要用于数据的加载，通过该模块可以极大的提高数据的加载速度，提升程序的运行效率。`torch.utils` 库中主要提供一些方便研究人员的功能函数，其中较为常用的有 `DataLoader` 等。本文中通过 `DataLoader` 将数据加载进神经网络。

除上述所介绍函数库为搭建神经网络带来的便利之外，Pytorch 深度学习框架搭建神经网络的方式也是本文使用该框架的一大重要原因。不同于 TensorFlow 与 Caffe 这类使用静态图方式搭建神经网络的深度信息框架，Pytorch 使用动态图的方式搭建神经网络。这种方式方便研究人员随时对网络结构进行修改，且更为符合人们的编程逻辑，大大的提高了神经网络搭建的灵活性。

2.3 本章小结

本章开头对本文中所使用到的实验平台进行介绍，接着共用两节对本文中所使用到的相关硬件与软件进行介绍。在首节中，首先对激光雷达进行介绍，介绍内容包括激光雷达的基本原理，Velodyne HDL_64E S3 激光雷达的参数及其数据传输方式以及点云的三维坐标获取方式。其次，在首节中还对本文中所用到的 Basler acA1920-40gc 摄像头以及 Kowa Lens LM6HC F1.8 f6mm 1"镜头进行介绍。在次节中，首先对机器人操作系统 ROS 进行介绍，并着重介绍了 ROS 的消息传递机制。

其次对本文中所使用的深度学习框架 Pytorch 进行介绍。

第 3 章 基于激光雷达的路缘石检测

为确保无人驾驶汽车的行驶安全，需对城市道路上的路缘石进行检测。近些年来，研究人员尝试利用多种不同类型的传感器检测路缘石，如立体视觉摄像头、毫米波雷达、二维激光扫描仪等，但这些传感器具有一个共同的缺点——所提供的环境信息较为有限。因此，基于上述传感器的路缘石检测算法，时常会出现对路缘石位置误判的情况。

与上述传感器不同，3D 激光雷达能够获取大量环境信息，其可以给出被测物体的 3D 信息，因此激光雷达被广泛应用于无人驾驶的环境感知中。

本文设计了一种基于激光雷达的路缘石检测算法，在校园环境下的测试中，该算法在配备了 Velodyne HDL-64E S3 激光雷达的实验平台上成功实现了对路缘石位置的快速精确预测。

如图 3.1 所示，基于 3D 激光雷达的路缘石检测算法分为三大步。




图 3.1 本文中路缘石检测过程

Fig. 3.1 The process of Kerb detection in this paper

3.1 数据预处理

本章中设计的路缘石检测算法通过激光雷达采集的点云数据对路缘石进行检测。为提升算法的检测效率，在得到激光雷达采集到的原始点云后，首先需对原始点云数据进行预处理，去除掉原始点云中冗余的点。

本章所设计的路缘石检测算法中对于原始点云的预处理较为直接，其大致过程为：首先，在激光雷达感知范围选定一处感兴趣区域并对处于该区域内的激光点进行提取；其次，判断这些点是否为感兴趣射线（感兴趣射线为事先选好的若干条激光射线）投射所得到，若是则保留，若不是则丢弃；最后，将这些保留下的点按其所属激光射线（若一个激光射线投射到物体表面得到一个激光点，则称此激光点属于该激光射线）分成若干个点集即完成了对原始点云的预处理，图 3.2 为对原始点云进行预处理的基本流程。





图 3.2 点云数据预处理流程

Fig. 3.2 The process of point cloud data preprocessing

为便于直观理解，图 3.3 给出了原始点云预处理的示意图，图中阴影部分即为感兴趣区域，该区域内包含路面和部分路缘石平面，处于激光雷达前方且贴近地面，其具体位置信息在图 3.3 中给出。图 3.3（a）中所圈出射线与图 3.3（b）中加粗弧线为感兴趣射线及其在感兴趣区域内的投射点。图中 x 、 y 、 z 轴所构成坐标系即为雷达坐标系，坐标原点为雷达所在位置。






图 3.3 点云数据预处理示意图

Fig. 3.3 Schematic diagram of point cloud data preprocessing

本算法中感兴趣激光射线与感兴趣区域是相互匹配的，或者说对感兴趣激光射线的选择决定了感兴趣区域位置参数的设置，这一点由图 3.3 (b) 中感兴趣区域里只含有感兴趣激光射线的投射点可以看出。本算法中选择的感兴趣激光射线为 Velodyne HDL-64E S3 激光雷达所射出的第 21 至第 40 条射线（激光射线排序方式见第二章），这么选择是由于索引值过小的射线，其投射到地面的点距离雷达过近，无法投射到路缘石上，这会导致后面的检测过程中无法提取到有效的路缘石点；而索引值过大的射线，其投射到地面的点过于稀疏，会影响检测效果。因此，本算法中选择第 21 至第 40 条射线为感兴趣激光射线。

图 3.3 为对原始点云进行预处理后的可视化效果图。由于本算法在预处理过程中选择了 20 条感兴趣射线，因此对原始点云进行预处理后得到 20 个点集，这 20 个点集中的点构成了图 3.4 中所示的 20 条弧线。




图 3.4 点云数据预处理结果

Fig. 3.4 The result of point cloud data preprocessing

3.2 粗糙路缘石点提取

3.2.1 点集分割及排序

对原始点云数据进行预处理后，得到 20 个点集。本节利用所设计的一种基于

结构化道路特征的滑动窗口算法对这 20 个点集进行处理可以初步提取出粗糙的路缘石点。但在提取粗糙路缘石点之前，首先需对这些点集进行左右分割以及排序的操作。

由于路缘石存在于道路左右两侧。在提取粗糙路缘石点时，应判断路缘石点处于道路左侧还是右侧，对点集进行左右分割，方便了后续对粗糙路缘石点进行左右归类。最简单的点集左右分割方法是直接通过激光雷达的 x 轴进行左右分割，即判定处于雷达 x 轴左侧的点为左，反之为右。这种方法虽然简单直观，但在实验过程中发现，激光雷达随车体发生偏转时，很容易产生如图 3.5 (a) 中阴影部分所示的错误分割区域，这种错误分割区域会导致许多左侧或右侧路缘石上的点被误判为相反一侧。为避免这种情况发生，本文设计了图 3.5(b)所示的分割方法。该方法使用一条参考线代替 x 轴完成点集的左右分割，将处于参考线左侧的点划分为左子点集，反之划分为右子点集。

参考线由激光雷达中心点（图 3.5 所示的激光雷达坐标系原点）与参考点连接得到。获取参考点位置的过程为：首先，将 20 个点集中与最大感兴趣射线（最大感兴趣射线指所有感兴趣射线中索引值最大的射线）对应的点集单独提取出来（图 3.5 (b) 中加粗虚线）；其次，按水平高度从小到大选择该点集内的若干个；最后，将这若干个点的坐标的平均值作为参考点坐标（激光雷达坐标系下），即获取到了参考点的位置。

通过上述步骤得到的参考点几乎总是处于路面上，这使得其与激光雷达中心连接而成的参考线也总是处于路面之上。因此这种按参考线对点集进行左右分割的方法在很大程度上减少了左右子点集分割错误的情况。




图 3.5 两种点集分割方法

Fig. 3.5 Two kinds of point set segmentation methods

对点集进行左右分割后，每个点集被分成左、右两个子点集。20 个点集一共被分为 40 个子点集，本节设计的滑动窗口算法就是在这 40 个子点集的基础上进行粗糙路缘石点提取。但由于激光雷达所提供的点云是无序点云，即点云中的点是

无序排列的，因此在进行粗糙路缘石点提取前还需对这 40 个子点集进行排序，图 3.6 为本算法所采取的排序策略。

图 3.6 中每个点上的数字代表排完序后子点集内所包含点的顺序。由该图可以看出，左子点集中的点采用逆时针的排序方式，右子点集中的点采用顺时针的排序方式。




图 3.6 左右子点集排序示意图
Fig. 3.6 Sorting strategy of left and right subsets

3.2.2 基于结构化道路特征的滑动窗口算法

对点集进行左右分割并对排序后，即可使用本章中所设计的滑动窗口算法对左右子点集进行粗糙路缘石点的提取。该算法利用结构化道路的几何特征来提取粗糙路缘石点。

介绍该算法前，首先对结构化道路的几何特征进行介绍。图 3.7 (a) 为结构化道路示意图。图 3.7 (b) 为道路点云图，该图显示了激光雷达投射点在结构化道路上的分布状态。由图 3.7(a)可以看出，由于路缘石与路面存在一定高度差，因此雷达投射在路缘石垂面（路缘石垂面如图 3.7 (a) 所示）上相邻两点高度之差，远大于投射在路面或路缘石平面上相邻两点的高度差。本章中所设计的滑动窗口算法主要就是利用路缘石的这一几何特性再辅以一些限制条件来实现对粗糙路缘石点的提取。




图 3.7 结构化道路示意图与道路点云图
Fig. 3.7 Diagram of structural road and point cloud of road

本章介绍的滑动窗口算法中所指的窗口是一个抽象的概念。如图 3.8 所示，其是指子点集中一组连续点的集合。窗口所包含点的数量称之为窗口的尺寸。以示意图 3.8 为例，窗口的尺寸为 3。

窗口的滑动方法如图 3.8 中的窗口序号所示，即窗口 2 由窗口 1 滑动得到，窗口 3 由窗口 2 滑动得到，以此类推。窗口每次滑动的距离（点数）称为窗口之间的偏移量。以示意图 3.8 为例，窗口之间的偏移量为 1。窗口的尺寸和窗口之间的偏移量可以根据实际情况进行调整，但为使在窗口滑动过程中遍历子点集中的每一个点，应保证窗口尺寸始终大于窗口之间的偏移量，在实际实验中，本文将窗口尺寸设置为 15，窗口间偏移量设置为 5。




图 3.8 窗口及滑动方法示意图
Fig. 3.8 Schematic diagram of window and sliding method

使用滑动窗口法提取粗糙路缘石点的大致流程为，生成一个窗口，判断窗口是否为存在路缘石点的有效窗口，若该窗口有效，则开始提取路缘石点，若该窗口无效，则滑动生成下一个窗口并继续进行判断，直至找到有效窗口后开始提取路缘石点，若遍历完一个子点集上的所有点后仍未找到一个有效窗口，则认为该子点集上无可提取的路缘石点。

通过上述方法对所有子点集进行处理，并在处理的过程中将从所有左子点集中提取出的路缘石点放入一个新的点集，该点集称为左路缘石点集。将从所有右子点集中提取出的路缘石点放入另一个新的点集，该点集称为右路缘石点集。左右路缘石点集内包含的所有点即称为粗糙路缘石点。图 3.9 为该滑动窗口算法处理子点

集获取路缘石点的基本流程。




图 3.9 粗糙路缘石点提取流程

Fig. 3.9 Rough kerb point extraction process

图 3.9 中，确定窗口是否包含路缘石点通过三个条件来进行判断。第一个条件是判断窗口内包含的最高点与最低点高度差是否超过 0.06m，具体而言，由于路缘石与路面高度差通常大于 0.06m，因此若窗口内包含的最高点与最低点高度差超过这一高度，则有可能为有效窗口。第二个条件是判断窗口中与最高点高度差小于某一阈值的点（本文中该阈值设置为 0.3cm）是否足够多。由于有效窗口通常包含一部分投射在路缘石平面上的点。该条件的设立，用于判断窗口内是否包含投射在路缘石平面上的点。第三个条件是判断窗口中首尾点距离是否过大，用于筛除掉因障碍物遮挡而造成的一些的异常窗口。同时满足这三个条件的窗口，即判断为包含路缘石点的有效窗口。这三个限制条件是根据在实验过程中所遇到的问题总结而得，其在很大程度上减少了将无效窗口误判为有效窗口的情况。

通过上述三个条件确定有效窗口后，提取有效窗口内路缘石点的过程较为简单。通过前面介绍的结构化道路的几何特征可知，投射在路缘石垂面上相邻两点高度之差，远大于投射在路面或路缘石平面上相邻两点的高度差。因此找出有效窗口内与相邻点高度差最大的一点，认定该点为路缘石点，图 3.10 为粗糙路缘石点提取效果图。




图 3.10 粗糙路缘石点提取效果图
Fig. 3.10 The result of rough kerb point extraction

3.3 路缘石位置预测方法

得到了粗糙路缘石点后，便获取了大致的路缘石位置信息，但由图 3.10 可以看出，提取出的路缘石点仍有少部分错误。因此，这种感知精度仍无法满足自动驾驶的需求。为获取路缘石位置，或者说获取路缘石线的精确信息，本文基于随机采样一致性的原理设计了一种简单而又精确的路缘石位置预测方法。

该预测方法预测路缘石位置的过程大致如下：首先，对提取出的粗糙路缘石点进行两两相连，获取这些相连直线在激光雷达坐标系下的直线方程；其次，在获取到这些直线方程后，将这些直线按斜率进行聚类（聚类方式如图 3.11 所示，为便于观察，图中只设出 4 个路缘石点，由这 4 个路缘石点两两相连共得到 6 条直线。可以看出图 3.11 中 6 条直线按斜率共聚为 4 类，其中最大的一类包含 3 条线，即类 1）；最后，取出包含直线最多的一个类，对该类内所有直线的斜率和截距取平均值，将求得的斜率平均值和截距平均值视为路缘石线在激光雷达坐标系下的斜率与截距，即得到了路缘石的精确位置。




图 3.11 聚类示意图
Fig. 3.11 Clustering diagram

由于通过上述滑动窗口算法所提取出的粗糙路缘石点大部分处于路缘石之上，按斜率对这些粗糙路缘石点的连线进行聚类后，其中最大类内所包含的直线均十分贴近真实的路缘石线，因此对该类内的线取平均后即可视为路缘石线，图 3.12 为路缘石线的预测流程。




图 3.12 路缘石线预测流程
Fig. 3.12 The process of kerb line prediction

3.4 实验结果与分析

经在校园环境下实验验证，本章所设计的路缘石检测算法具有极高的精度，其在 80 米的范围内最大预测误差不超过 10 厘米。此外，该算法还具有极高的实时性，即使是在将激光雷达扫描频率提高 1 倍的情况下，该算法也可以实时的完成检测任务，图 3.13 为路缘石检测效果图（图中点并非提取出的路缘石点，而是利用预测出的路缘石线方程给出的若干个点）。




图 3.13 路缘石检测效果图

Fig. 3.13 Result of curb detection

3.5 本章小结

本章给出了一种基于激光雷达的路缘石检测算法，经验证，该算法在保证运行速度的同时，还有着优秀的检测精度。本章第一节介绍了从原始点云提取若干个点集的数据预处理过程；第二节介绍了粗糙路缘石点的提取过程，首先介绍了对点集的分割与排序方法，其次介绍了基于结构化道路几何特征设计的滑动窗口算法，利用该算法可以提取出粗糙路缘石点；第三节介绍了一种基于随机采样一致性原理的路缘石位置预测方法，该方法可以对路缘石位置进行准确预测；第四节给出了本章的实验结果与分析；末节对本章进行总结。

第 4 章 基于摄像头的交通标志检测

交通标志是城市交通系统的重要组成部分，其规范了车辆的行驶方式，使得车辆得以安全有序的行驶在城市道路之上。因此对交通标志的检测也是无人驾驶环境感知技术中极为重要的一部分。

本章利用深度学习技术设计了一种交通标志检测网络，使用该网络可以有效的检测出道路中出现的交通标志。此外，本章还将该网络与光学字符识别技术进行结合，实现了对道路限速信息的获取。

4.1 数据集

4.1.1 CCTSDB 数据集

由于我国路况较之其他国家更为复杂且交通标志牌样式也与其他国家差别较大，为获得更好的识别效果，文中选择 CCTSDB（CSUST Chinese Traffic Sign Detection Benchmark）数据集作为训练交通标志检测网络的数据集。该数据集共包含 15734 张包含交通标志的图片，这些图片涵盖了城市、郊区以及高度等多种驾驶环境下的图片，该数据集将交通标志粗略分为指示（mandatory）、警告（warning）和禁止（prohibitory）三类。

从大体上来说，CCTSDB 数据集是一种用来训练二维目标检测网络的数据集，因此该数据集中的标注信息为二维边界框在图像坐标系中的坐标信息以及框内物体（交通标志牌）所属类别信息。为便于理解标注信息内容，以数据集中第 26 张图片为例，图 4.1 中给出第 26 张图对应标注信息在该图中的可视化效果。本章中用 CCTSDB 数据集训练出的交通标志检测网络可以很好地实现三类交通标志的检测任务。




图 4.1 标注信息示意图
Fig. 4.1 Annotated information schematic diagram

4.1.2 数据集预处理

4.1.2.1 标注信息的转化与归一化

由图 4.1 可以看出, CCTSDB 数据集中的边界框位置尺寸标注信息由边界框左上角和右下角坐标值(图像坐标系下)组成。这种位置标注方式虽然较为简单, 但不适合用来对本章所介绍的交通标志检测网络进行训练。本章中训练交通标志检测网络所需要的边界框位置尺寸标注信息, 应由边界框中心坐标值(图像坐标系下)以及边界框的宽高来组成。因此需将数据集中的边界框位置尺寸标注信息进行转化。

将边界框位置尺寸标注信息转化后, 若直接使用原始的标注信息值对神经网络进行训练, 往往会导致网络收敛速度过慢等问题。为解决这些问题, 还应对转化后得到的边界框中心坐标和宽高进行归一化处理(图片宽高视为 1, 将其中的边界框中心点坐标和宽高等比例缩小到 $(0,1)$ 范围之内)。

4.1.2.2 标签文件转化

深度学习是一种有监督的学习方式, 为使神经网络实现某一任务, 通常需要将数据与对应的人工标注信息一起送入神经网络进行训练。因此一般的数据集中每个数据都有一个对应的标签文件, 该标签文件中存放着数据所对应的人工标注信息。

如图 4.2 中所示, CCTSDB 数据集将所有数据的人工标注信息都存放于一个名为 GroundTruth 的标签文件内。因此在对神经网络进行训练前, 还需将该数据集改为数据与标签文件一一对应的形式, 即就是将 CCTSDB 数据集中的单一标签文件拆分转化为多个标签文件, 转化结果如图 4.2 所示。

4.1.2.3 数据增强

由于 CCTSDB 数据集中所包含的数据量较小, 为使得训练后的交通标志检测网络具有更好的泛化能力, 本文还对 CCTSDB 数据集中的图片数据随机进行了旋转, 加入噪声, 翻转, 改变色调, 缩放, 裁剪等操作, 实现了对该数据集的数据增强。




图 4.2 标签转化示意图
Fig. 4.2 Label transformation diagram

4.2 交通标志检测网络

4.2.1 网络结构

4.2.1.1 前端网络

本小节对交通标志检测网络结构进行介绍。交通标志检测网络大体上分为两部分——特征提取部分（前端网络）以及检测部分（后端网络）。这里首先对特征提取部分进行介绍。

无论是利用传统计算机视觉方法还是利用深度学习的方法，要实现一个视觉任务，通常都要先对图像中的特征进行提取。在传统计算机视觉方法中，人们通过一定的先验知识对特征进行提取，而在深度学习方法中，一般是通过一个特征提取网络来对图像进行特征提取，这种网络提取出的特征往往可以用于不同的视觉任务，具有较高的移植性，因此这种网络也被称为骨干网络。

目前，常用的特征提取网络有 Googlenet、SPPNet、Resnet 等等。本章使用的 Darknet53 特征提取网络是一种使用了 53 个卷积层的全卷积神经网络。该网络吸收了 Resnet 等一些网络的思想，结构较为新颖，在保证检测精度的同时，缩减了网络中参数的规模。表 4.1 为该网络的结构信息

表 4.1 特征提取网络结构信息				
Table 2.1 Structure information of feature extraction network				
	Type	Filters	Size	Output
1×	Convolutional	32	3×3	416×416
	Convolutional	64	3×3 / 2	208×208
	Convolutional	32	1×1	208×208
	Convolutional	64	3×3	
	Residual			
2×	Convolutional	128	3×3 / 2	104×104
	Convolutional	64	1×1	104×104
	Convolutional	128	3×3	
	Residual			
	8×	Convolutional	256	3×3 / 2
Convolutional		128	1×1	52×52
Convolutional		256	3×3	
Residual				
8×		Convolutional	512g	3×3 / 2
	Convolutional	256	1×1	26×26
	Convolutional	512	3×3	
	Residual			
	4×	Convolutional	1024	3×3 / 2
Convolutional		512	1×1	13×13
Convolutional		1024	3×3	
Residual				

表 4.1 中 Type 指是网络每一层的类型，Filters 是对应层的卷积核数量，Size 是指每个卷积核的尺寸，Output 表示该层输出特征图的大小。下面详细介绍 Type 中 Convolutional 和 Residual 的具体组成以及各组成部分的作用。

（1）卷积块（Convolutional）组成

表 4.1 中每一个 Convolutional，称为卷积块，它由一个卷积层、一个批量归一化层和一个非线性激活函数顺序连接构成，如图 4.3 所示




图 4.3 卷积块组成

Fig. 4.3 Structure of convolutional block

神经网络的本质是为了学习训练数据的特征分布。如果送入网络的每批量数据分布各不相同，那么网络在每次迭代中要学习不同的分布，会大大降低网络的训练速度，因此需对原始训练数据做归一化预处理，即转换输入训练数据的分布到标

准正态分布。而批量归一化是处理训练期间，网络隐含层（hidden layer）数据分布发生改变的情况，能够提高网络的泛化能力。此外，它还可以将卷积得到的特征图（feature map）分布从饱和区（梯度为零的区域）拉到非饱和区，使得到的分布位于激活函数的敏感区域，从而解决梯度消失问题。批量归一化层一般放在卷积层或全连接层后、非线性激活函数前。

非线性激活函数的引入是为了增加神经网络的非线性，改善网络的训练效果。该特征提取网络中用到的激活函数是 Leaky ReLU 函数，数学表达式为：

$$f(x)=\max(ax,x)$$

(4.1)

式（4.1）中，a 是负斜率角度，一般默认为 0.01。在本章训练过程中取值为 0.1，Leaky ReLU 的函数图像如图 4.4 所示。




图 4.4 Leaky ReLU 函数图像

Fig. 4.4 Functional image of Leaky ReLU

(2) 残差块（Convolutional）组成

该特征提取网络结构中加入的残差块，起源于 2015 年 ImageNet 视觉识别挑战赛上夺冠的深度残差网络。残差块结构如图 4.5 所示。




图 4.5 残差块结构

Fig. 4.5 Structure of residual block

图 4.4 中残差块将输入直接加在卷积层的输出上，这种结构可以使网络设计的更深，以提取出更棒的特征。

(3) 卷积池化

前面介绍过 Darknet53 是一个全卷积网络，原因就在于该网络中未出现全连接层以及池化层。该网络使用增大卷积步长的方法实现对图像的降采样取代了池化层。

表 4.1 中 Size 为 $3\times3/2$ 的卷积层代表一次降采样，由该表可以看出一共进行了 5 次下采样。每次降采样后得到的特征图在原来的尺寸上缩减 2 倍，共缩减 32 倍。

4.2.1.2 后端网络

利用特征提取网络提取出图像中的特征后，还需利用卷积等方法对这些特征进行融合，进而实现对交通标志的检测。本文通过如图 4.6 所示的后端网络对这些特征进行融合，该网络借鉴了空间金字塔模型的思想，通过上采样的方法将特征提取网络输出的小尺寸深层特征与特征提取过程中的大尺寸浅层特征进行融合。




图 4.6 后端网络结构
Fig. 4.6 Back-end network architecture

由图 4.6 可以看出，经后端网络的一系列特征融合后，最终得到如图 4.7 所示三个不同尺度的特征图（ $13\times13\times24$ ， $26\times26\times24$ ， $52\times52\times24$ ），这些特征图即为整个交通标志检测网络的输出结果。




图 4.7 网络输出
Fig. 4.7 Outputs of network

4.2.2 网络输出与检测机制

上面介绍了网络的结构，但未对网络输出的特征图以及网络的检测机制进行详细解释。下面对交通标志检测网络的检测机制和输出特征图进行交叉解释。

本文所介绍的交通标志检测网络大体上属于一种端到端的目标检测网络，借鉴于其他端到端目标检测网络分而治之的思想（如 YOLO 系列与 SSD 系列），该交通标志检测网络将图像分割为若干个网格小图，并对每个网格小图进行特征提取与融合，进而判断出网格小图内是否存在交通标志并给出交通标志在图像中的位置尺寸信息。为了尽可能地检测出图像中尺度大小不同的交通标志，减少漏检率，本网络对图像进行了三种不同尺度地分割，即 13×13 ， 26×26 ， 52×52 。网络输出的三种不同尺度的特征图分别对应这三种不同的分割情况，特征图中每个像素对应一个网格小图，每个像素所包含的 24 个信息即为交通标志检测网络从对应网格小图所预测出的交通标志边界框信息，其具体构成如图 4.8 所示。




图 4.8 特征图像素点信息构成
Fig. 4.8 Composition of feature map pixel information

由上图可以看出，本章设计的交通标志检测网络从每个网格小图中预测出 box1、box2、box3 三个边界框，每个边界框包含 coord、conf、cls 三类信息。图 4.8 中 coord 为边界框的位置与尺寸相关信息，其给出了交通标志边界框的位置与尺寸相关信息；conf 为边界框的置信度信息，该信息表示边界框内包含交通标志的概率，网络所预测出的 conf 值越大表示该框内包含交通标志的可能性越大，换句话说，conf 值的大小决定了一个边界框是否有效；cls 为边界框的类别信息，由于本章所设计的交通标志检测网络对警告、指示、禁止这 3 类交通标志进行检

测，因此该信息中的 3 个数值分别代表边界框中所包含交通标志属于这三类交通标志的概率。在交通标志检测时，根据这三个概率值对交通标志牌进行类别划分。

4.3 损失函数

对网络结构以及检测机制介绍完后，要使网络实现既定的交通标志检测任务，还需对其进行训练。神经网络的训练过程如图 4.9 所示大致为，首先将网络输出的预测值（即上述所说的输出特征图）与利用人工标注信息生成的真值代入损失函数计算预测张量与真值张量之间的误差。其次，通过反向传播、计算参数梯度、利用优化器对参数更新，来持续减小误差，循环往复，直至误差降低到可以接受的程度。训练完成，即可以使用该网络进行交通标志检测的任务。




图 4.9 神经网络训练流程

Fig. 4.9 Neural network training process

由图 4.9 可以看出，损失函数是训练网络过程中的极为重要的一环，下面对本章所使用的损失函数进行介绍。由于本章所设计的交通标志检测网络是以边界框的形式对交通标志进行检测，因此本章所使用的损失函数需要对边界框的各个信息进行误差计算。由前面的介绍可知，网络预测出的边界框包含三类信息，因此损失函数也由三部分组成，分别为边界框位置尺寸损失、边界框置信度损失和边界框分类损失。

上述三类损失中，边界框位置尺寸损失用于计算网络预测边界框与真实边界框的中心点位置误差与宽高误差，其形式如式（4.2）所示采用平方损失函数，式中 x 、 y 为网络所预测的边界框中心点位置信息， w 、 h 为网络所预测的边界框宽高信息， x' 、 y' 、 w' 、 h' 为对应的真实值。当网络所预测出交通标志边界框与真实交通标志边界框所对应时，式中 1^{obj} 值为 1，否则为 0。这表示在计算边界框位置误差损失时，只对负责预测交通标志的边界框进行误差计算。

$$1^{obj} \left[(x - x')^2 + (y - y')^2 + (w - w')^2 + (h - h')^2 \right] \quad (4.2)$$

边界框置信度误差用于计算网络预测边界框与真实边界框的置信度误差，其形式如式（4.3）所示采用交叉熵损失函数，该损失函数目前被广泛的用在二分类以及多分类问题上，式中 $conf$ 为网络所预测的边界框置信度， $conf'$ 为对应的真实边界框置信度。式中 1^{noobj} 与 1^{obj} 正好相反，当网络所预测出交通标志边界框与真实交通标志边界框不对应时， 1^{noobj} 值为 1，负责为 0。式（4.3）中 1^{obj} 与 1^{noobj} 的设立表示在计算边界框置信度误差损失时，是对网络所预测的所有边界框进行误差计算。

$$1^{obj}[-conf'*\log(conf)-(1-conf')\log(1-conf)]$$
$$+1^{noobj}[-conf'*\log(conf)-(1-conf')\log(1-conf)]$$

(4.3)

边界框分类误差用于计算网络预测边界框与真实边界框在分类上的误差，其形式如式（4.4）所示，同样采用交叉熵损失函数，式中 cls_1 、 cls_1 、 cls_1 为网络所预测出的边界框属于各个类别的概率， cls_1' 、 cls_2' 、 cls_3' 为对应的真实边界框类别概率。与式（4.2）一样，式（4.4）中符号 1^{obj} 同样表示在计算边界框分类误差损失时，只对负责预测交通标志的边界框进行误差计算。

$$1^{obj}\begin{bmatrix}-cls_1'*\log(cls_1)-(1-cls_1')*\log(1-cls_1)\\-cls_2'*\log(cls_2)-(1-cls_2')*\log(1-cls_2)\\-cls_3'*\log(cls_3)-(1-cls_3')*\log(1-cls_3)\end{bmatrix}$$

(4.4)

上述三类损失函数共同组成了本章中所使用的损失函数。

4.4 网络训练及检测效果

在介绍完上述内容后，本节对交通标志检测网络的训练细节以及最终的检测效果进行介绍。本实验中使用 Pytorch 框架对网络进行训练，训练所使用的数据集为 CCTSDB 数据集，训练中设置的一些超参数如表 4.2 所示。

表 4.2 超参数设置表

Table 4.2 Hyper parameter setting table

参数	值
批尺寸	4
训练周期	100
图像宽度	416
图像高度	416
图像通道数	3
学习率	0.001

如上表所示，本实验中使用 CCTSDB 数据集对该交通标志检测网络训练了 100

个周期，全程共训练 10 小时，整个训练过程中网络收敛较好（训练结束时最终损失值大约为 0.8）。

在训练完成后，使用该交通标志检测网络对多组城市道路图像进行交通标志检测，经检验发现该网络可以很好的检测这些图片中的交通标志，其漏检率约为 10%。

除此之外，由于这些用于检验网络效果的城市道路图像拍摄于陌生环境，因此，这还说明，本章所设计的交通标志检测网络具有很好的泛化能力。图 4.10 和图 4.11 为利用 matplotlib 等工具对网络检测结果进行可视化后的效果图。



图 4.10 城市道路环境下交通标志检测效果

Fig. 4.10 Detection results of traffic signs in urban road environment



图 4.11 城市社区环境下交通标志检测效果

Fig. 4.11 Detection results of traffic signs in urban community environment

4.5 限速信息识别

4.5.1 限速信息识别方法

识别道路中的限速信息对于车辆的安全行驶十分重要，由于限速信息存在于限速标志牌中，而限速标志属于禁止类交通标志，因此本节结合上述交通标志检测

网络设计了一种限速信息识别方法。

如图 4.12 所示，限速信息相较于其他禁止类标志所包含信息具有极为明显的特点，其他禁止类标志所包含信息一般为图形或字母，而限速信息为纯数字，因此可以利用限速信息的这一特点对其进行识别。



图 4.12 三类交通标志
Fig. 4.12 Three kinds of traffic sign

利用限速标志特点识别限速信息的流程大致如图 4.13 所示，首先，利用交通标志检测网络检测图像中的交通标志。其次，将禁止类的交通标志从图像中切割出来。接着，提取出禁止类交通标志的语义信息。最后，判断提取出的语义信息是否为限速信息，若是，则对限速信息进行显示。




图 4.13 限速信息识别流程
Fig. 4.13 Process of speed limit information identification

如图 4.13 中所示，获得从图像中分割出的禁止类交通标志后，需要对其进行

语义提取。在本章所设计的限速信息识别方法中，采用 Python-tesseract 对禁止类交通标志进行语义提取。

Python-tesseract 是 Google Tesseract-OCR 引擎的封装，是用于 python 的光学字符识别（Optical Character Recognition）工具，其可以识别并“读取”图像中的文本信息。在读取图像类型方面，Python-tesseract 可以读取 Pillow 和 Leptonica 图像库支持的所有 jpeg、png、gif、bmp、tiff 等图像类型。

经实验验证，Python-tesseract 可以有效提取出限速标志中的数字信息。图 4.14 为 Python-tesseract 对限速标志的语义提取效果。




图 4.14 限速标志语义提取效果图

Fig. 4.14 Speed limit sign semantic extraction renderings

提取完禁止类交通标志的语义信息后，还需判断所提取信息是否为限速信息。具体判断方法为：首先，设置一个限速信息列表，将日常生活中所有可能出现的限速信息存放于该列表内；其次，将从禁止类交通标志中提取出的语义信息与限速信息列表中的限速信息进行匹配，若有匹配对象，则认为所提取出的语义信息为限速信息。

由于限速牌限速信息是固定的，因此上述将提取到的语义信息与限速信息列表匹配的过程可以减少限速信息识别错误的情况。图 4.15 为限速信息判断过程示意图，该图展示了禁止行人通行标志与限速 30km/h 标志的语义信息判断过程。




图 4.15 限速信息判断过程示意图

Fig. 4.15 Speed limit information judgment process diagram

4.5.2 识别效果

使用上述限速信息识别方法对多组包含限速标志的城市道路图像进行限速信息识别，经检验发现该方法可以很好的识别出这些图片中的限速信息。其具体识别效果如图 4.16 于图 4.17 所示。




图 4.16 城市道路环境下限速信息识别效果图

Fig. 4.16 Identification renderings of speed limit information in urban road environment




图 4.17 城市社区环境下限速信息识别效果图

Fig. 4.17 Identification renderings of speed limit information in urban community environment

对多组图片的识别结果进行统计发现，本章所设计的限速信息识别方法成功

率为 70%。

4.6 本章小结

本章使用深度学习技术设计了一种交通标志检测网络，该网络具有较好的泛化能力，对图像中的交通标志具有良好的检测效果。此外，本章结合该交通标志检测网络还设计了一种限速信息识别方法，该方法可以有效的识别出限速标志牌中的限速信息。

本章首先介绍了用于对交通标志检测网络进行训练的 CCTSDB 数据集以及对该数据集的处理方法。其次从网络结构，网络输出，网络检测机制等多个方面对所设计的交通标志检测网络进行介绍。接着又对本章所使用的损失函数进行介绍。在介绍完上述内容后，本章又对交通标志检测网络的训练过程以及检测效果进行介绍，并通过效果图的形式展示了该交通标志检测网络的检测效果，实验证明，本章所设计的交通标志检测网络可以很好的检测出图像中的交通标志，最后，本章还介绍了一种限速信息识别的方法。经验证，该方法可以成功识别出限速标志牌中的限速信息。

第5章 基于多传感器的车辆距离检测方法

除了对路缘石和交通标志的检测外,对道路上前方车辆的检测也很重要,尤其是对前方车辆距离的检测,更是无人驾驶汽车得以安全行驶的关键。目前一些基于深度学习的二维图像目标检测算法已经可以极为精准的检测出图像中的车辆,但由于二维图像数据的先天性缺陷,从图像中直接提取目标的位置信息很难实现。

受限于二维目标检测无法提供距离信息的限制,许多基于三维激光雷达的目标检测网络随之被提出。基于三维激光雷达的目标检测网络虽然可以预测车辆的位置信息,但由于三维激光雷达所提供的点云信息较为稀疏,这种检测方法往往在精度上差强人意。此外,基于三维点云的目标检测网络通常需要对数据进行三维卷积操作,三维卷积相比于二维卷积而言需要更大的运算量,这会大大降低程序的运行效率。因此基于激光雷达的三维目标检测也不是一个好的检测方法。

目前,将图像与激光雷达点云结合起来进行目标检测的策略是一种较好的检测方法,这种方法可以将两种传感器的优势结合起来,在获取目标三维信息的同时,还拥有着较为理想的检测精度。

本章设计了一种基于多传感器的车辆距离检测方法。该方法首先将激光雷达采集到的点云数据与摄像头采集到的图像数据进行匹配,其次使用二维目标检测器对图像进行处理获取图像中车辆的边界框信息,使用距离信息提取网络对点云数据进行处理得到一个包含车辆距离信息的深度图,最后将车辆边界框信息与深度图结合,即得到了前方车辆的距离信息。

由于本章所设计的车辆距离检测方法中使用现有目标检测器对图像进行处理,因此本章主要对所设计的距离信息提取网络进行介绍,该网络可以从点云数据中有效提取出车辆的距离信息。下面对训练该网络所使用的数据集以及对数据集的相关处理,还有整个网络的结构以及检测原理等信息进行介绍。

5.1 数据集

5.1.1 KITTI 数据集

本章所设计的距离信息提取网络,虽然用于对激光雷达数据进行处理,但由于其处理的激光雷达数据需要与同步采集的图像数据进行匹配。因此在数据集的选择上需要一个包含激光雷达与摄像头两种传感器数据的数据集,且该数据集中

的图像数据与点云数据应是同步采集的。经对目前公开的数据集进行遴选后发现, KITTI 数据集符合本章对距离信息提取网络训练的要求。

KITTI 数据集是目前自动驾驶研究环境感知领域最常用的数据集。其可用于视觉测距, 3D 物体检测和 3D 跟踪等多种自动驾驶任务。按功能的不同 KITTI 数据集被分为许多子数据集, 本章中使用的是 KITTI 的目标检测数据集。该数据集内包含在城市、郊区和校园等环境下采集的摄像头数据以及激光点云数据。

5.1.2 点云数据转化

本章中所设计的距离信息提取网络并不是直接对激光雷达采集到的原始点云数据进行处理。而是对一种本文中称之为点云矩阵的数据进行处理, 点云矩阵是由原始点云数据转化而得到。

点云矩阵中包含部分原始点云中的信息, 它是通过将原始点云数据与对应图像(这里的图像指数据集中与点云数据同步采集到的图像数据)进行匹配后所得。点云矩阵的具体生成方法如下:

首先, 将原始点云数据内所有的三维激光点投影至其所对应图像平面的图像面上。为实现这一目标, 要对三维激光点进行一系列的坐标变换, 其大致过程为先通过激光点在雷达坐标系下的三维坐标推算出其在相机坐标系下的三维坐标, 其次再将激光点在相机坐标系下的三维坐标通过相机的内参矩阵转化为图像平面的二维坐标。要完成上述第一步的转化, 通过激光点在雷达坐标系下的坐标推算出其在相机坐标系下的坐标, 需要了解激光雷达坐标系与相机坐标系以及这两种坐标系的相对位置, 进而获取一个坐标转换矩阵。如图 5.1 (a) 中所标示与相机和激光雷达所对应的坐标系即为激光雷达坐标系与相机坐标系, 由该图可以看出激光雷达坐标系与相机坐标系的相对位置即就是这两种传感器的相对位置。因此, 图 5.1 (b) 中给出了 KITTI 数据集采集平台上两种传感器的摆放位置。图 5.1 (b) 中所示 Velodyne 激光雷达为数据集中点云数据的采集器, Cam2 为数据集中图像数据的采集器。完成上述的所有坐标变换后, 即得到了所有三维激光点在图像平面上的二维坐标, 将激光点根据其二维图像坐标投影在图像平面上即得到如图 5.2 所示的投影效果图, 图中橙色的点为投影在图像内的点, 这部分点即为激光雷达所投射出的处于摄像头视野内的点。




图 5.1 KITTI 数据集采集平台结构图
Fig. 5.1 Structure diagram of KITTI data set acquisition platform




图 5.2 点云投影至二维图像平面效果图
Fig. 5.2 Point cloud projection to 2d image plane renderings

其次，在获取所有三维激光点在图像平面上的二维坐标后，只将图 5.2 中投影在图像上的点（即图 5.2 中橙色点）进行保留，将这些保留下的点称为感兴趣点，这些感兴趣点的集合称之为感兴趣点云。将感兴趣点云在图像平面上的坐标进行可视化，结果如图 5.3 所示。




图 5.3 感兴趣点云在图像平面上的可视化
Fig. 5.3 Point clouds of interest project on the image plane

接着，生成 3 个与图 5.2 中图像尺寸相同的空矩阵，由于图 5.2 中图像尺寸为 192×640 （本章中将 KITTI 数据集中所有图像处理为 192×640 ），因此生成 3 个尺寸为 192×640 的空矩阵。跟据感兴趣点的二维图像坐标将感兴趣点的三类信息分别填入这三个矩阵，这三类信息分别为感兴趣点在激光雷达坐标系下的坐标 x, y, z 。

最后，将上述三个矩阵在第三维度上进行拼接，即得到了本章中所用到的点云矩阵，该矩阵尺寸为 $192 \times 640 \times 3$ 。可以看出点云矩阵与 RGB 图像十分相似，其同样具有三个通道，但与 RGB 图像中三个通道用来存放色彩信息不同的是，点云矩阵中三个通道用来存放激光点的三维信息，即每个点在雷达坐标系下的 x, y, z 坐标。点云矩阵的这种类似图像的形式将无序的点云数据进行了有序化，其将三维点云投影在了二维平面，并且保留了每个点的三维信息。这种点云数据形式极大程度上提升了程序的运行效率。

如图 5.4 所示为点云矩阵三个通道的可视化效果图。




图 5.4 点云矩阵 3 通道可视化

Fig. 5.4 Point cloud matrix 3 channel visualization

5.2 距离信息提取网络

5.2.1 网络结构

本小节对本章中设计的距离信息提取网络的结构进行介绍，该网络同样需要

使用一个前端网络对点云矩阵进行特征提取，且由于点云矩阵与图像较为相似，因此可以使用一些提取图像特征的网络作为其前端网络。本章使用一个修改后的 Darknet53 网络作为前端网络（去掉了网络中的两次下采样过程，对点云矩阵进行八倍下采样）。本章中距离信息提取网络端网络的后端部分较为简单，因此结合前端网络在表 5.1 中一并给出，其通过一系列卷积操作对前端网络所提取特征进行融合最终输出所预测的车距离信息。

表 5.1 距离信息提取网络结构
Table 5.1 Distance information extraction network structure

		Type	Filters	Size	Output
前端	1×	Convolutional	32	3×3	192×640
		Convolutional	64	3×3 / 2	96×320
		Convolutional	32	1×1	
		Convolutional	64	3×3	
		Residual			96×320
	2×	Convolutional	128	3×3 / 2	48×160
		Convolutional	64	1×1	
		Convolutional	128	3×3	
		Residual			48×160
	8×	Convolutional	256	3×3 / 2	24×80
		Convolutional	128	1×1	
		Convolutional	256	3×3	
		Residual			24×80
		Convolutional	512g	3×3	24×80
	8×	Convolutional	256	1×1	
		Convolutional	512	3×3	
		Residual			24×80
		Convolutional	1024	3×3	24×80
	4×	Convolutional	512	1×1	
		Convolutional	1024	3×3	
		Residual			24×80
后端		Convolutional	512	1×1	24×80
		Convolutional	1024	3×3	24×80
		Convolutional	512	1×1	24×80
		Convolutional	1024	3×3	24×80
		Convolutional	512	1×1	24×80
		Convolutional	1024	3×3	24×80
		Convolutional	1	1×1	24×80

5.2.2 网络输出与距离信息提取机制

本小节对距离信息提取网络的输出特征图和其提取距离信息的机制进行交叉解释，由表 5.1 可知距离信息提取网络输出一个尺寸为 24×80 的特征图，如图 5.5 所示为距离信息提取网络的输出特征图，该特征图是对点云矩阵的八倍下采样，特征图中每个元素对应点云矩阵中一个 8×8 的区域。特征图中每个元素的值为距离信息提取网络从该元素所对应区域内所提取出的距离信息。




图 5.5 网络输出
Fig. 5.5 Outputs of network

5.3 损失计算

5.3.1 损失函数

本章使用如式 (5.1) 所示的均方误差函数来作为损失函数，式中 z 为距离信息提取网络预测的车辆距离， z' 为车辆距离信息的真实值。

$$loss = \sum (z - z')^2 \tag{5.1}$$

由于本章中利用距离信息提取网络车辆的距离信息进行预测，因此在使用损失函数计算网络输出的损失时，只对图 5.5 中负责进行预测车辆距离信息的元素进行损失计算。

5.3.2 损失计算策略

由于本章中利用距离信息提取网络对车辆的距离信息进行预测，因此在使用损失函数计算损失时，并不对图 5.5 中所有元素（距离信息）进行损失计算，而是只对图 5.5 中负责预测车辆距离信息的元素进行损失计算

确定特征图中某一元素是否负责预测车辆距离信息的方式如图 5.6 所示，图 5.6 中为一组匹配好的图像与点云矩阵，这两种数据具有相同的视野。由图 5.6 可以看出，判断特征图中一个元素是否负责车辆距离信息预测的方式为，首先，由车辆边界框（图中加粗虚线框）中心点在图像中位置得到该中心点在点云矩阵中的位置。其次，判断这一位置对应特征图中哪一元素，称该元素（图 5.6 中加粗实线框）负责预测对应车辆的距离信息。本文中将输出特征图中负责预测车辆距离信息的元素称为输出特征图中的有效元素。




图 5.6 输出特征图中有效元素判断示意图

Fig. 5.6 Schematic of determining the effective elements in the output feature map

5.4 网络训练

本小节对距离信息提取网络训练细节进行介绍。本章中同样使用 Pytorch 框架对神经网络进行训练，训练所使用的数据为由 KITTI 数据集中点云数据转化而成的点云矩阵，训练中设置的一些超参数如表 5.2 所示。

表 5.2 超参数设置表	
Table 4.2 Hyper parameter setting table	
参数	值
批尺寸	4
训练周期	8
点云矩阵宽度	640
点云矩阵高度	192
点云矩阵通道数	3
学习率	0.0001
参数优化器	Adam

实验中一共对网络进行了 7000 多次的批训练，训练过程中网络收敛较好，图 5.7 为训练过程中损失函数输出值的变化曲线。




图 5.7 损失变化曲线

Fig. 5.7 Loss curve

利用训练好的模型对一个点云矩阵进行处理，并对网络输出特征图进行可视

化处理得到如图 5.8（a）所示的结果，5.8（b）为点云矩阵对应的图像。图 5.8（a 中）一个元素越亮代表值越大。比较图 5.8（a）与图 5.8（b）可以看出，距离信息提取网络所输出的特征图可以粗略表示出物体的深度信息。




图 5.8 网络输出结果与图像对比图
Fig. 5.8 Compare network output with image

5.5 车辆距离检测方法

输出特征图中每个元素值都代表一个距离，由于在对网络进行训练时只对网络输出特征图中有效元素计算损失，因此有效元素的元素值才是可信度最高的车辆距离信息。所以，在实际检测车辆距离的过程中，需要如图 5.9 所示，利用二维目标检测器检测出的车辆边界框来获取网络输出特征图中的有效元素（有效元素获取方式与 5.3.2 节相同），进而获取每个车辆的距离信息。




图 5.9 车辆距离检测方法示意图
Fig. 5.9 Schematic of vehicle distance detection method

由于本节所介绍的检测车辆距离的方法，同时使用到了图像与点云矩阵两种

形式的数据，因此该方法是一种基于多传感器的方法。

5.6 检测效果

在实验验证阶段，本章利用上述车辆距离检测方法，结合 YOLOv3 二维目标检测器与本章中所设计的距离信息提取网络，对 100 多组数据进行车辆距离检测。图 5.10 为部分检测结果，图中 predict_dis 为从每组数据检测到的车辆距离信息，true_dis 为对应的真实距离。

```
predict_dis = tensor([27.9679])
avg_dis = tensor(0.4821)
true_dis = tensor([23.4900, 9.1600, 18.4100])
predict_dis = tensor([23.8330, 10.1763, 19.6598])
avg_dis = tensor(0.8697)
true_dis = tensor([14.5100])
predict_dis = tensor([13.4296])
avg_dis = tensor(1.0804)
true_dis = tensor([12.3000, 11.4700])
predict_dis = tensor([13.3856, 12.2447])
avg_dis = tensor(0.9302)
true_dis = tensor([ 7.5900, 13.8900, 17.9600])
predict_dis = tensor([ 7.7549, 13.5624, 18.5916])
avg_dis = tensor(0.3747)
true_dis = tensor([8.2900])
predict_dis = tensor([8.6218])
avg_dis = tensor(0.3318)
true_dis = tensor([31.6500])
predict_dis = tensor([30.7414])
avg_dis = tensor(0.9086)
true_dis = tensor([ 8.4900, 23.3000])
predict_dis = tensor([ 9.3317, 24.8353])
avg_dis = tensor(1.1885)
true_dis = tensor([20.8600, 13.1400])
predict_dis = tensor([22.2086, 11.2219])
avg_dis = tensor(1.6333)
true_dis = tensor([12.2900])
predict_dis = tensor([12.4428])
avg_dis = tensor(0.1528)
```

图 5.10 部分距离检测结果

Fig. 5.10 Partial distance detection results

实验完成后，将 100 组数据的检测距离与真实距离进行比对发现，检测距离的平均误差为 1.2 米，以车长 4 米来看，该方法的距离检测结果具有一定的实用性。

5.7 本章小结

本章设计了一种对激光雷达数据进行距离信息提取的深度学习神经网络，并结合该网络与二维目标检测器给出了一种检测车辆距离的方法。本章首先对自动驾驶数据集 KITTI 进行介绍，并对其中的激光点云数据进行处理以生成距离信息提取网络所需要的激光雷达数据——点云矩阵。其次本章从网络结构等方面对所设计的距离信息提取网络进行介绍。接着，本章对训练网络所使用的损失函数以及网络训练细节进行介绍。随后，本章对所设计的车辆距离检测方法进行具体介绍，阐述了距离信息提取网络与二维目标检测器如何协同工作获取车辆的距离信息。最后，本章对所给出的车辆距离检测方法进行测验，经验证，该方法具有一定的实用价值。

第6章 总结与展望

6.1 总结

本文主要研究城市环境下无人驾驶汽车的环境感知技术,并对城市环境下无人驾驶汽车的多个感知任务进行设计与实现。本文首先说明了无人驾驶环境感知技术研究背景及研究意义进行分析,介绍了无人驾驶汽车的国内外研究现状以及自动驾驶系统的构成,并重点介绍了环境感知技术的研究现状。其次,本文从硬件和软件两个方面对所使用的实验平台进行介绍。最后,本文对所设计实现的三种自动驾驶环境感知任务进行了详细介绍。以下为本文所作的主要工作:

(1) 利用结构化道路的空间特征设计了一种基于激光雷达的路缘石检测算法。该算法简化了对激光雷达数据的预处理过程,使用本文中所设计的一种滑动窗口算法对预处理后的数据中进行粗糙路缘石点的提取,提取出粗糙路缘石点后,该算法利用本文所设计的路缘石位置预测方法对这些粗糙点进行处理,最终预测出路缘石的准确位置。该算法在保证运行效率的同时,还拥有着极高的检测精度。

(2) 利用深度学习技术设计了一种基于摄像头的交通标志检测网络,该网络在保证实时性的情况下可以有效检测出道路图像中的交通标志。此外,将该网络与光学字符识别技术进行结合还实现了对限速标志中限速信息的识别。

(3) 给出了一种基于多传感器的车辆距离检测方法。该方法利用本文设计的距离信息提取网络对激光雷达数据进行处理,从中提取出深度信息,并将提取出的深度信息与二维目标检测器从摄像头数据中提取出的车辆二维信息进行匹配,最终得到车辆的距离信息。

6.2 展望

本文所实现的这些自动驾驶环境感知任务,经实验验证都具有较好的表现,具有一定的实用价值,但其各自还都有值得改进的地方。

(1) 目前利用道路几何特征实现的激光雷达检测算法虽然在直道情况下可以精确预测出路缘石位置,但在弯道及十字路口的情况下无法给出路缘石的精确位置,未来还需针对这两种情况对算法进行改进。

(2) 受限制于数据集的形式与规模,目前所实现的交通标志检测器只能将交通标志大致分为三类,而无法做到细致的分类,因此,未来还应对此问题给出相应的解决办法。

(3) 由于受计算资源的限制, 本文中所设计的车辆距离检测方法目前所检测出的车辆距离在精度上还略有不足, 未来还应进一步提升该方法的检测精度。

参考文献

- [1] 陈天殷, 耿殿丽. 5G 推进 ADAS 和自动驾驶发展进程[J]. 客车技术与研究, 2020, 42(02): 1-4.
- [2] 张思齐, 沈钧戈, 郭行, 闫杰, 徐德民. 智能无人系统改变未来[J]. 无人系统技术, 2018, (3): 1-7.
- [3] 王芳, 陈超, 黄见曦. 无人驾驶汽车研究综述[J]. 中国水运(下半月), 2016, 16(12): 126-128.
- [4] 陈安. 网联车自动驾驶系统研究及停车场场景下的应用[D]. 浙江大学, 2017.
- [5] Scott Drew Pendleton, Hans Andersen, et al. Perception, Planning, Control, and Coordination for Autonomous Vehicles[J]. Machines, 2017, 5(6): 1-54.
- [6] Shitao CHEN, Zhiqiang JIAN, Yuhao HUANG, Yu CHEN, Zhuoli ZHOU, Nanning ZHENG. Autonomous driving: cognitive construction and situation understanding[J]. Science China(Information Sciences), 2019, 62(08): 75-101.
- [7] Kichun Jo, Minchae Lee, Dongchul Kim, Junsoo Kim, Chulhoon Jang, Euiyun Kim, Sangkwon Kim, Donghwi Lee, Changsup Kim, Seungki Kim, Kunsoo Huh, Myoung-ho Sunwoo. Overall Reviews of Autonomous Vehicle AI - System Architecture and Algorithms[J]. IFAC Proceedings Volumes, 2013, 46(10).
- [8] Junsoo Kim, Kichun Jo, Dongchul Kim, Keonyup Chu, Myoung-ho Sunwoo. Behavior and Path Planning Algorithm of Autonomous Vehicle AI in Structured Environments[J]. IFAC Proceedings Volumes, 2013, 46(10).
- [9] Diego Galar, Uday Kumar, Dammika Seneviratne. Robots, Drones, Uavs and Ugvs for Operation and Maintenance[M]. Boca Raton: CRC Press, 2020, 10-11.
- [10] Bao Guiqiu, Xiong Shenshu, et al. Vision-based Extraction of Flight Parameters for Micro Air Vehicles[C]. Proceedings of the Second International Symposium on Instrumentation Science and Technology, Jinan, 2002.
- [11] Romuald Aufrère, Jay Gowdy, Christoph Mertz, Chuck Thorpe, Chieh-Chih Wang, Teruko Yata. Perception for collision avoidance and autonomous driving[J]. Mechatronics, 2003, 13(10).
- [12] Pomerleau D A. Alvin: an autonomous land vehicle in a neural network[R]. Pittsburgh: Carnegie-Mellon University, 1989.

- [13] Thrun S, Montemerlo M, Dahlkamp H, Stavens D, Aron A, Diebel J, Fong P, Gale J, Halpenny M, Hoffmann G, et al. Stanley: The robot that won the DARPA Grand Challenge[J]. Field Robot. 2006, 23, 661–692.
- [14] Urmson C, Anhalt J, Bagnell D, Baker C, Bittner R, Clark M.N, Dolan J, Duggins D, Galatali T, Geyer C, et al. Autonomous driving in urban environments: Boss and the Urban Challenge[J].Field Robot. 2008, 25, 425–466.
- [15] Tim Maughan. No One's Driving: Autonomous Vehicles Will Reshape Cities, but is Anyone Taking Control of How?[J]. Architectural Design, 2019, 89(1).
- [16] YANG DianGe, JIANG Kun, ZHAO Ding, YU ChunLei, CAO Zhong, XIE ShiChao, XIAO ZhongYang, JIAO XinYu, WANG SiJia, ZHANG Kai. Intelligent and connected vehicles: Current status and future perspectives[J]. Science China (Technological Sciences), 2018, 61(10): 1446-1471.
- [17] Ryan Bradley. Tesla Autopilot[J]. Technology Review, 2016, 119(2).
- [18] 夏天. 智能车速度规划及路径跟踪控制方法研究[D]. 北京工业大学, 2017.
- [19] 郑南宁. 中国智能车未来挑战赛, 稳步迈向第十年[N]. 科技日报, 2018-06-12(004).
- [20] 谢德胜, 徐友春, 万剑, 韩栋斌, 陆峰. 基于 RTK-GPS 的轮式移动机器人轨迹跟随控制[J]. 机器人, 2017, 39(02): 221-229.
- [21] 杨帆. 无人驾驶汽车的发展现状和展望[J]. 上海汽车, 2014(3): 35 - 40.
- [22] 姜红德. IT 助跑长安智能汽车[J]. 中国信息化, 2016(5): 49–51.
- [23] 李晓菲. 客车无人驾驶:宇通做到了[J]. 商用汽车新闻, 2015(Z5): 2.
- [24] 周静. 福田汽车实力挑战自动驾驶高难度“路考”[J]. 商用汽车新闻, 2018(35):6.
- [25] 穆康乐. 无人驾驶汽车发展现状及未来展望[J]. 电子技术与软件工程, 2017(21): 112-114.
- [26] NAMIK H, INAMURA T, STOL K. Development of a robotic driver for vehicle dynamometer testing[C]. Proceedings of 2006 Australasian Conference on Robotics and Automation. Auckland, New Zealand, 2006: 1–9.
- [27] Yifang Ma, Zhenyu Wang, Hong Yang, Lin Yang. Artificial Intelligence Applications in the Development of Autonomous Vehicles:A Survey[J]. IEEE/CAA Journal of Automatica Sinica, 2020, 7(02): 315-329.
- [28] Siegwart R, Nourbakhsh I R, Scaramuzza D. Introduction to Autonomous Mobile

- Robots (second edition)[M]. London: The MIT Press, 2011.
- [29]王东署, 王佳. 未知环境中移动机器人环境感知技术研究综述[J]. 机床与液压, 2013, 41(15): 187-191.
- [30]冯刘中. 基于多传感器信息融合的移动机器人导航定位技术研究[D]. 成都: 西南交通大学, 2008.
- [31]Premebida C, Ambrus R, Marton Z-C. Intelligent Robotic Perception Systems[M]. IntechOpen, 2018.
- [32]Siegwart R, Nourbakhsh I R, Scaramuzza D. Introduction to Autonomous Mobile Robots[M]. London: The MIT Press, 2011.
- [33]蔡自兴, 徐光祐. 人工智能及其应用[M]. 北京: 清华大学出版社, 1988.
- [34]Alireza Asvadi, Cristiano Premebida, Paulo Peixoto, Urbano Nunes. 3D Lidar-based static and moving obstacle detection in driving environments: An approach based on voxels and multi-region ground planes[J]. Robotics and Autonomous Systems, 2016, 83
- [35]Gangqiang Zhao, Xuhong Xiao, Junsong Yuan, Gee Wah Ng. Fusion of 3D-LIDAR and camera data for scene parsing[J]. Journal of Visual Communication and Image Representation, 2014, 25(1).
- [36]Moosmann F, Pink O, Stiller C. Segmentation of 3D lidar data in non-flat urban environments using a local convexity criterion[C]. Proceedings of the 2009 IEEE Intelligent Vehicles Symposium, Xi'an, 2009.
- [37]Oliveira M., Santos V., Sappa A.D, Dias P. Scene Representations for Autonomous Driving: An Approach Based on Polygonal Primitives[C]. Proceedings of the Robot 2015: Second Iberian Robotics Conference, Lisbon, 2015.
- [38]Wang, M.; Tseng, Y.H. Incremental segmentation of lidar point clouds with an octree-structured voxel space[J]. Photogramm Rec. 2011, 26, 32–57.
- [39]Nguyen A., Le B. 3D point cloud segmentation: A survey[C]. IEEE Conference on Robotics, Manila, 2013.
- [40]Yao W., Deng Z., Zhou L. Road curb detection using 3D lidar and integral laser points for intelligent vehicles[C]. International Conference on Soft Computing and Intelligent Systems, Kobe, 2012.
- [41]Zhang J., Lin X., Ning X. SVM-based classification of segmented airborne LiDAR

- point clouds in urban areas[J]. Remote Sens. 2013, 5, 3749–3775.
- [42] B. Wu, A. Wan, X. Yue and K. Keutzer. SqueezeSeg: Convolutional Neural Nets with Recurrent CRF for Real-Time Road-Object Segmentation from 3D LiDAR Point Cloud[C]. IEEE International Conference on Robotics and Automation, Brisbane, 2018.
- [43] A. Milioto, I. Vizzo, J. Behley, C. Stachniss. RangeNet ++: Fast and Accurate LiDAR Semantic Segmentation[C]. International Conference on Intelligent Robots and Systems, Macau, 2019.
- [44] Y. Zhou, O. Tuzel. VoxelNet: End-to-End Learning for Point Cloud Based 3D Object Detection. Conference on Computer Vision and Pattern Recognition[C], Salt Lake City, 2018.
- [45] Ali W., Abdelkarim S., Zidan M., Zahran M., Sallab A.E. YOLO3D: End-to-End Real-Time 3D Oriented Object Bounding Box Detection from LiDAR Point Cloud[C]. ECCV, 2018.
- [46] Simon M., Milz S., Amende K., Gross HM. Complex-YOLO: An Euler-Region-Proposal for Real-Time 3D Object Detection on Point Clouds[C]. ECCV, 2018.
- [47] Fan X, Tjahjadi T. A spatial-temporal framework based on histogram of gradients and optical flow for facial expression recognition in video sequences [J]. Pattern Recognition, 2015, 48(11): 3407-3416.
- [48] Lindeberg T. Scale invariant feature transform [M]. Scholarpedia, 2012.
- [49] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation [C]. IEEE Conference on Computer Vision and Pattern Recognition, Columbus, 2014, 580-587.
- [50] Girshick R. Fast R-CNN [C]. IEEE Conference on Computer Vision and Pattern Recognition, Boston, 2015.
- [51] Ren S, Girshick R, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks [J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39(6): 1137-1149.
- [52] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection [C]. IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, 2016.

- [53]Redmon J, Farhadi A. Yolo9000: Better, faster, stronger [C]. Computer Vision and Pattern Recognition, 2017, 6517-6525.
- [54]Redmon J, Farhadi A. Yolo3: An incremental improvement [OL]. arXiv: 1804.02767, 2018.
- [55]Liu W, Anguelov D, Erhan D, et al. SSD: Single shot multibox detector [C]. European Conference on Computer Vision, 2015, 21-37.
- [56]Fu C Y, Liu W, Ranga A, et al. DSSD: Deconvolutional single shot detector [C]. IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, 2017.
- [57]Li Z, Zhou F. FSSD: Feature fusion single shot multibox detector [OL]. arXiv: 1712: 00960, 2017.
- [58]Liang-Chieh Chen, George Papandreou, et al. DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs[OL]. arXiv: 1606.009615, 2016.
- [59]Guosheng Lin, Anton Milan, Chunhua Shen, Ian Reid. RefineNet: Multi-Path Refinement Networks for High-Resolution Semantic Segmentation[OL]. arXiv: 1611: 06612, 2016.
- [60]Chen X, Ma H, Wan J, et al. Multi-view 3D object detection network for autonomous driving [C]. IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, 2017.
- [61]Ku J, Mozifian M, Lee J, et al. Joint 3D proposal generation and object detection from view aggregation [C]. IEEE/RSJ International Conference on Intelligent Robots and Systems, Madrid, 2018.
- [62]M. Quigley, K. Conley, B. Gerkey, J. Faust, T. Foote, J. Leibs, et al. ROS: An open-source robot operating system[C], ICRA, kobe, 2009.