

基于 YOLOv4 网络模型的临时道路识别算法

王浩东^{1,2}, 王立勇^{1,2*}, 苏清华^{1,2}, 谢敏^{1,2}, 王超^{1,2}, 丁炳超^{1,2}

(1. 北京信息科技大学, 北京 100192;
2. 现代测控技术教育部重点实验室, 北京 100192)

摘要:针对自动驾驶车辆不能准确识别由交通锥桶标识的临时道路问题,提出一种融合彩色相机和深度相机数据的临时道路检测算法;使用一台四目相机实时采集环境的色彩和深度信息,通过 YOLOv4 模型实时检测彩色和深度图像中的交通锥桶,根据边界框的欧氏距离对二者结果进行融合,最终规划出车辆在临时道路中的运动轨迹。实验结果表明,该算法能够快速、准确地识别各色交通锥桶及其位置信息,检测交通锥桶的平均精度分别为 94.25%、95.16% 和 91.03%,平均单帧彩色图像处理时间为 36.34 ms。车辆在临时道路中的运动轨迹规划也符合预期,能够辅助车辆顺利驶出。

关键词:目标检测;YOLOv4 算法;立体视觉;交通锥桶;自动驾驶

中图分类号:TP391 **文献标识码:**A **文章编号:**1001-7445(2022)03-0712-11

Real-time traffic cone detection for autonomous driving based on YOLOv4

WANG Hao-dong^{1,2}, WANG Li-yong^{1,2*}, SU Qing-hua^{1,2},
XIE Min^{1,2}, WANG Chao^{1,2}, DING Bing-chao^{1,2}

(1. Beijing Information Science and Technology University, Beijing 100192, China;
2. Key Laboratory of Modern Measurement and Control Technology of
Ministry of Education, Beijing 100192, China)

Abstract: Aiming at the problem that autonomous vehicles couldn't accurately perceive the temporary road composed of traffic cones, a temporary road detection algorithm fusing color camera and depth camera data was proposed. The algorithm used a four-eye camera to collect the color and depth information of the environment in real-time, then detected the traffic cones in the color and depth images in real-time through the YOLOv4, fused the two results according to the Euclidean distance of the bounding boxes, and finally planned the motion trajectory of the vehicle in the temporary road. The experimental results show that the

收稿日期:2021-12-17;修订日期:2022-01-18

基金资助:国家 173 基础加强基金项目(2021-JCJQ-JJ-0022)

通讯作者:王立勇(1977—),男,河南许昌人,北京信息科技大学教授,博士生导师,博士;E-mail: wangliyong@bistu.edu.cn。

引文格式:王浩东,王立勇,苏清华,等.基于 YOLOv4 网络模型的临时道路识别算法[J].广西大学学报(自然科学版),2022,47(3):712-722.

system can quickly and accurately identify all kinds of traffic cones and their location information, the AP of all kinds of cones is 94.25%, 95.16%, and 91.03% respectively, and the average single frame processing time is 36.34 ms. In addition, the trajectory planning of the vehicle on the temporary road also meets the expectation and can assist the vehicle to drive out smoothly.

Key words: object detection; YOLOv4 algorithm; stereo vision; traffic cone; autopilot

0 引言

随着传感器技术和人工智能的发展,无人驾驶技术已经成为国内外企业和科研机构的重点研究方向。为了解决道路的安全和效率问题,研究人员赋予车辆环境感知和自主决策控制能力,实现辅助驾驶甚至自动驾驶。在无人驾驶系统中,感知道路、障碍物和交通标识是进行决策和控制的基础^[1]。

机器视觉能够提供丰富的颜色和纹理信息,尽管受光照、天气的影响可能会降低检测精度,但由于其成本远低于激光雷达(LiDAR),因此被广泛应用在自动驾驶领域中^[2],如检测车辆、行人、道路和交通标志等。尉天成等^[3]提出交通标志检测网络的锚盒框改进和优化方法,设计多分支卷积并联结构,使目标特征更加显著,提高FasterRCNN网络在不同环境和尺度下的识别效果。龙建武等^[4]将车道线检测定义为像素分类问题,通过增加解码器分支和知识蒸馏思想,提升主流算法检测车道线的能力。

随着机器学习算法的不断发展,将机器学习与机器视觉技术相结合的研究也不断深入。基于神经网络的算法将目标检测问题转化为图像分类问题^[5],由于其具有检测速度快、精度高、健壮性好等优点,因此近年来得到很大的发展。基于神经网络的目标检测算法可分为一阶段检测算法和两阶段检测算法^[6]。两阶段检测算法分阶段进行目标定位和分类,主要包括FasterRCNN^[7]、CPNDet^[8]等算法,这些方法检测精度较高,但计算量较大。一阶段检测算法可直接识别图像中的目标类别及其位置,计算量较小,随着一阶段检测算法精度的提高,这种算法能够同时满足无人驾驶系统对精度和实时性的要求^[9],主要包括You Only Look Once(YOLO)^[10]系列、EfficientDet^[11]等算法。2018年,Redmon等^[12]提出目标检测算法YOLOv3,使用了特征金字塔和多尺度检测等方法,但是它的小尺寸目标检测性能较差。为解决这个问题,Wang等^[13]于2020年提出YOLO系列算法Scaled-YOLOv4,改进了正、负样本的判定策略,提高小目标的检测性能,较好地平衡了检测速度和精度。

目前,对于具有车道标线和明显边缘特征的结构化道路,如高速公路和大多数城市道路,车道线检测算法已经取得良好的检测效果,但是针对在临时交通管制或突发路况下由交通锥桶构建的临时道路的检测研究则不多。交通锥桶体积小,位置不固定,所以检测难度较大。Zhou等^[14]提出一种使用立体视觉系统获取交通锥桶位置的方法,通过对像素的RGB值进行归一化处理,以减少亮度不均匀对图像的影响,根据颜色特征确定候选交通锥桶位置,使用经过训练的AdaBoost分类器最终确定锥桶的位置,但是该方法受环境的影响较大,早晨、傍晚等光照条件下将无法工作。Kalms等^[15]通过提取Haar特征和训练级联分类器,将Viola-Jones算法应用于交通锥桶检测,但这种基于特征的方法泛化性较差,动态环境、变化的光照条件都将导致检测失败。Huang等^[16]通过融合激光雷达和视觉传感器的信息来检测交通锥桶。该算法首先通过单应变换算法将激光雷达数据中的障碍物映射到图像中作为候选区域,然后使用形状匹配方法确定候选区域是否为交通锥桶;但由于交通锥桶的尺寸小,激光雷达获取的交通锥桶点云较稀疏,因此可能无法识别到25 m以外的交通锥桶。Wang等^[17]使用同时基于颜色和形状特征的方法检测交通锥桶,并将结果映射到深度图像以同时获得三维位置,但它需要手工设定颜色阈值以适应不同环境。Dhall等^[18]提出一种基于深度学习的交通锥桶检测方法,训练一个YOLOv2网络检测交通锥桶,并训练一个卷积神经网络提取交通锥桶的关键点进行Perspective-N-Points(PNP)计算,获得其空间位置,但计算得到的空间位置误差较大,且同时运行2个神经网络算法对系统性能要求较高。

本文中提出一种临时道路检测算法,该算法使用 YOLOv4 模型检测彩色图像和深度图像中的交通锥桶,通过基于欧氏距离的边界框匹配方法,计算 2 种检测结果的匹配关系,同时获取交通锥桶的颜色和位置信息,最终完成临时道路的路径规划。建立一个交通锥桶数据集,包含彩色图像和深度图像,并人工对其中的交通锥桶进行标注。

1 材料和方法

1.1 实验车辆和交通锥桶

本文使用的实验车辆为一台长 2.6 m、宽 1.5 m、高 1.65 m 的方程式赛车,它由一台功率 80 kW 的直流电机和一块容量为 14 A·h 的直流电池驱动,车辆控制系统包括一台工控机(Intel i7-7700 CPU、NVIDIA GTX2060 GPU、16G RAM),一个车辆控制单元(vehicle control unit, VCU)和一套机器视觉系统,实验车辆和交通锥桶如图 1 所示。



图 1 实验车辆和交通锥桶

Fig. 1 Experimental vehicle and traffic cone

交通锥桶包括红、蓝、黄 3 种颜色,锥体长度为 200 mm,宽度为 200 mm,高度为 300 mm,中间有一条反射带。在本文中,红色和蓝色交通锥桶分别标记临时道路的左边缘和右边缘,黄色交通锥桶用于标记道路的起点和终点。

1.2 机器视觉系统

本文使用中科慧眼的 Smart Eye B1 机器视觉系统,如图 2 所示,该系统由 4 个 6 mm 焦距摄像头(2 个彩色摄像头和 2 个单色摄像头)组成,水平视野为 50° ,机器视觉系统以 12 FPS 的速度输出分辨率为 1280×720 像素的图像。2 台彩色摄像机用于检测交通锥桶颜色,单色摄像机构成立体视觉系统,生成深度图像,用于获取锥桶位置信息。为了模拟驾驶员的视角,机器视觉系统被放置在头枕上方,距地面 1.5 m。



图 2 Smart B1 机器视觉系统

Fig. 2 Smart B1 machine vision system

2 个单色摄像机构成的立体视觉模型如图 3 所示,建立世界坐标系 $O-XYZ$ 和 2 个像素坐标系 $o_1-x_1y_1$ 和 $o_2-x_2y_2$ 。空间点 $P(X, Y, Z)$ 在相机坐标系的投影为点 $M(x_1, y_1)$ 和点 $N(x_2, y_2)$,其中 $y_1 = y_2$ 。 f 是相机的焦距, b 是左右摄像机之间的基线。




图 3 立体视觉模型

Fig. 3 Stereo Vision Model

根据三角形相似定律, X 、 Y 、 Z 的值可通过式(1)、(2)计算。

$$\frac{Z}{f} = \frac{Y}{y_l} = \frac{Y}{y_r} = \frac{X}{x_l} = \frac{X-b}{x_r}, \quad (1)$$

$$\begin{cases} X = \frac{x_l b}{x_l - x_r}, \\ Y = \frac{y_l b}{x_l - x_r}, \\ Z = \frac{fb}{x_l - x_r}. \end{cases} \quad (2)$$

深度图中每个像素点的值表示空间点与摄影机之间的距离。机器视觉系统生成的彩色和深度图像如图4所示。



(a) 彩色图像



(b) 深度图像

图4 机器视觉系统生成的彩色图像和深度图像

Fig. 4 Color image and depth image from machine vision system

1.3 临时道路检测算法

本文提出基于Darknet深度学习模型框架的YOLOv4临时道路检测算法,该算法首先在彩色图像和深度图像中分别检测交通锥桶,并进行检测结果融合,实现交通锥桶颜色和位置的感知,随后进一步实现路径规划,临时道路检测算法流程如图5所示。




图5 临时道路检测算法流程

Fig. 5 Flow chart of temporary road detection algorithm

1.3.1 基于 YOLOv4 模型的目标检测算法

将机器视觉系统提供的彩色图像输入深度学习网络模型,获得交通锥桶的图像坐标、类别和置信度信息。YOLOv4 网络的结构包括 3 个主要部分:骨干网络、颈部网络和头部网络,YOLOv4 网络结构如图 6 所示。




图 6 YOLOv4 网络结构

Fig 6 YOLOv4 structure overview

CSPDarknet53 是 YOLOv4 算法的主干网络,使用跨阶段部分连接(cross stage partial connection, CSP)网络结构,该结构在保持准确性的同时减少模型计算量。CSPDarknet53 中的激活函数是 Mish 激活函数,如式(3)所示。

$$f_{\text{Mish}} = x \tanh[\ln(1 + e^x)]。 \quad (3)$$

颈部网络包括空间金字塔池网络(spatial pyramid pooling, SPP)和路径聚合网络(path aggregation network, PANet)。SPP 网络在 CSPdarknet53 的输出特征层上执行 3 次卷积运算,然后分别实现 4 种不同规模的最大池处理,其结构如图 7 所示。PANet 网络接收 3 个特征图输入,包括一系列上采样和下采样,目的是特征的重复提取。




图 7 SPP 网络结构

Fig 7 SPP network structure

头部网络生成预测结果。它输出3种尺寸的特征图,每个特征图被划分为尺寸为 $S \times S$ 的网格,每个网格预测3个边界框,以及边界框的4个调整参数、置信度和分类概率。

在训练过程中使用带有动量优化的随机梯度下降(stochastic gradient descent, SGD)算法。随机梯度下降的每次迭代使用一个或一批样本来更新参数,用于减少训练时间。梯度下降方向主要是之前累积的下降方向,但是略微偏向当前时刻下降方向。

1.3.2 检测结果融合算法

为了同时获取用于路径规划的交通锥桶颜色和位置信息,需要将2种图像的检测结果进行融合,本文提出一种根据边界框的欧氏距离关系的匹配算法。

彩色图像检测结果 C 包含检测到的每个交通锥桶的边界框 $C_i(x_i, y_i, w_i, h_i)$, x_i, y_i 是边界框的左上角的坐标, w_i, h_i 是边界框的宽度、高度, $P_{ci}(m_{ci}, n_{ci})$ 是边界框 C_i 的中心点。深度图像检测结果 D 包含每个检测到的交通锥桶的边界框 $D_j(x_j, y_j, w_j, h_j)$, $P_{dj}(m_{dj}, n_{dj})$ 是边界框 D_j 的中心点,中心点的计算方法如式(4)所示。

$$P(m, n) = P\left[\left(x + \frac{w}{2}\right), \left(y + \frac{h}{2}\right)\right], \quad (4)$$

式中: m, n 分别为边界框的中心点; x, y 分别为边界框左上角点坐标; w, h 分别为边界框的宽度、高度。

在深度图像检测结果 D 中搜索具有最小欧氏距离 $\text{dis}(P_{ci}, P_{dj})$ 并满足 $P_{dj} \in C_i$ 的边界框 D_j ,将边界框 D_j 与边界框 C_i 匹配,视为同一个交通锥桶。如果未获得搜索结果,则匹配失败。欧氏距离计算方法如式(5)所示。

$$\text{dis}(P_{ci}, P_{dj}) = \sqrt{(m_{dj} - m_{ci})^2 + (n_{dj} - n_{ci})^2}. \quad (5)$$

1.3.3 路径规划算法

彩色、深度图像中的交通锥桶完成检测后,将用于路径规划。在路径规划过程中,按照交通锥桶到车辆的距离对交通锥桶进行排序,并按颜色分类得到点集 M_{red} 、 M_{blue} 和 M_{yellow} 。红色与蓝色交通锥桶之间的中点被计算为航路点 L_i ,然后这些航路点连接起来,形成车辆的预期路径。设第 i 个交通锥桶的坐标为 $(x_{\text{color}_i}, y_{\text{color}_i})$,航路点 L_i 计算方法如式(6)所示。

$$\begin{cases} L_i = \left(\frac{x_{\text{red}_i} + x_{\text{blue}_i}}{2}, \frac{y_{\text{red}_i} + y_{\text{blue}_i}}{2}\right), & M_{\text{red}} \neq \Phi \& M_{\text{blue}} \neq \Phi, \\ L_i = \left(\frac{x_{\text{red}_{i+1}} + x_{\text{red}_i}}{2}, \frac{y_{\text{red}_{i+1}} + y_{\text{red}_i}}{2} + \alpha\right), & M_{\text{blue}} = \Phi, \\ L_i = \left(\frac{x_{\text{blue}_{i+1}} + x_{\text{blue}_i}}{2}, \frac{y_{\text{blue}_{i+1}} + y_{\text{blue}_i}}{2} - \alpha\right), & M_{\text{red}} = \Phi, \\ L_i = \Phi, & M_{\text{red}} = \Phi \& M_{\text{blue}} = \Phi, \end{cases} \quad (6)$$

式中 α 为经验常数。由于相机的视场角限制,因此在车辆转弯的过程中,可能仅有一侧交通锥桶出现在图像中,求解车辆与最近2个锥桶的中心点,根据图像中出现的交通锥桶的颜色将其平移距离为 α ,得到航路点。

2 数据集准备与网络训练

2.1 数据集准备

本文使用交通锥桶模拟常见的临时道路,在早晨、正午和傍晚多种光照情况下,共采集2358张彩色图像,并在其中人工标记红色、蓝色和黄色交通锥桶,然后将该数据集随机分为训练集、验证集和测试

集,分别包含 1 697、425、236 张图像(比例约为 7 : 2 : 1)。同时,实验中采集的深度图像 1 304 张,由人工标记其中的交通锥桶,然后随机分为训练集、验证集和测试集,分别包含 938、235、131 张图像(比例约为 7 : 2 : 1)。

2.2 彩色图像检测网络训练

在训练过程中,对图像数据进行随机的数据增强,包括角度旋转和 HSV 值变化,图像在 $[-5, 5]$ 被随机旋转,并且 HSV 通道中的值被随机噪声化,用于色调、饱和度和亮度调整,H 通道的值被随机施加 $[-0.05, 0.05]$ 的倍数,S 通道和 V 通道中的数据随机乘以或除以 1.5。

训练过程中,使用不同的网络训练参数对比训练效果,包括批处理数量、图像分辨率和最大迭代次数等。彩色图像检测网络训练参数见表 1。设置 4 组参数进行网络训练,第 1 组批处理数量为其他组的一半,第 2 组具有比其他组更高的图像分辨率,第 4 组的最大迭代次数为其他组的 2 倍。

表 1 彩色图像检测网络训练参数

Tah 1 Training parameters of color image detection network

序号	图像分辨率/像素	批处理数量	最大迭代次数
1	416×416	32	6 000
2	576×576	64	6 000
3	416×416	64	6 000
4	416×416	64	12 000

2.3 深度图像检测网络训练

深度图像检测网络训练与彩色图像检测网络训练类似,区别在于数据增强和一些网络参数设置。由于深度图像只有一个通道用于存储深度数据,因此没有 HSV 变换操作,原始图像在 $[-5, 5]$ 度内随机旋转仅用于增强数据。深度图像检测网络训练参数见表 2。

表 2 深度图像检测网络训练参数

Tah 2 Training parameters of depth image detection network

序号	图像分辨率/像素	批处理数量	最大迭代次数
1	416×416	32	2 000
2	576×576	64	2 000
3	416×416	64	2 000
4	416×416	64	4 000

3 实验结果与分析

3.1 基于彩色图像的交通锥桶检测实验

为了验证该交通锥桶检测算法的效果,在自行构建的交通锥桶数据集中进行测试。使用平均精度(average precision, AP)^[19]、平均精度均值(mean average precision, mAP)^[19]和平均耗时对目标检测网络进行性能评估,并分析训练参数对交通锥桶检测结果的影响。

彩色图像检测网络训练结果见表 3,彩色图像检测结果如图 8 所示。从表 3 可见,第 3 组训练参数获得最均衡的效果,第 3 组在训练集和验证集中的 mAP 略小于第 4 组的,但第 3 组在测试集中获得最大的 mAP 值,达到 93.48%,并且对红色和黄色交通锥桶取得最大的 AP 值,说明更大的迭代次数没能增加网络的泛化能力。除黄色交通锥桶的 AP 值外,第 3 组的各项指标均大于第 1 组的,说明更大的批处理数量可提高网络的预测精度。虽然第 2 组的 mAP 值最大,但第 3 组推理耗时相比第 2 组减少

39.31%,平均为 36.34 ms,更小的图像分辨率适合应用于车载部署,因此最终选用第 3 组参数。

表 3 彩色图像检测网络训练结果
Tab 3 Training results of the color image detection network

序号	训练集	验证集	测试集				平均
	mAP /%	mAP /%	AP _{red} /%	AP _{blue} /%	AP _{yellow} /%	mAP /%	耗时 /ms
1	94.71	93.93	93.59	94.80	91.91	93.43	34.21
2	96.99	96.64	96.08	96.49	95.35	95.97	59.88
3	94.86	94.12	94.25	95.16	91.03	93.48	36.34
4	94.91	94.17	94.05	95.31	89.66	93.01	35.74



图 8 彩色图像检测结果
Fig. 8 Color image detection results

由于当前缺少可进行性能对比的开源交通锥桶数据集,因此在自建的交通锥桶数据集上比较了不同模型的性能,使用第 3 组网络训练参数,对 YOLOv4、YOLOv3、YOLOv4-tiny、YOLOX-L 网络进行训练,训练结果见表 4。

表 4 不同网络模型训练结果
Tab 4 Training results of different network models

模型	平均精度均值/%			平均耗时
	训练集 mAP/%	验证集 mAP/%	测试集 mAP/%	/ms
YOLOv4	94.86	94.12	93.48	36.34
YOLOv4-tiny	71.25	71.36	71.54	4.97
YOLOv3	91.08	91.24	90.56	42.34
YOLOX-L	90.59	90.73	90.66	37.92

YOLOv4 取得 mAP 最高的彩色图像交通锥桶检测结果,达到 93.48%,且推理耗时少于 YOLOv3,平均单帧检测时间为 36.34 ms,说明 CSP 结构有利于进行更好的特征提取,提高了小目标的检测效果。YOLOv4-tiny 推理时间仅为 4.97 ms,但在测试集中的 mAP 仅为 78.54%,说明 YOLOv4-tiny 不能充分地提取和融合交通锥桶的特征,不能满足车辆行驶过程中环境感知的精度要求。YOLOX-L 取得的 mAP 为 90.66%,说明 anchor-based 类型的 YOLOv4 对于小目标的检测性能更好。而 YOLOX 使用的 anchor-free 机制使特征图中的每个网格仅预测一组边界框的位置及宽高,造成了 YOLOX 在密集场景下的性能下降,因此选用 YOLOv4 检测彩色图片中的交通锥桶。

3.2 基于深度图像的锥桶检测实验

由于深度图中只有“cone”标签,因此统计 4 组参数在训练集、验证集和测试集的 AP 值,统计结果见表 5。

表 5 深度图像检测网络训练结果


Tab 5 Training results of depth image detection network

序号	平均精度/%			均耗时/ms
	训练集 AP/%	验证集 AP/%	测试集 AP/%	
1	96.88	94.94	97.02	22.95
2	97.95	97.52	98.19	39.32
3	97.39	97.08	97.89	22.67
4	97.66	96.94	97.92	21.68

检测结果如图 9 所示,第 3 组训练参数获得最均衡的效果。第 3 组在测试集中的 AP 值达到 97.89%,高于第 1 组但略低于第 4 组,但第 3 组的训练时间仅为第 4 组的一半。第 2 组的 AP 值最高,但第 3 组推理耗时相比第 2 组减少 42.34%,仅为 22.67 ms,因此最终选用第 3 组参数。



(a) 场景 1 检测结果



(b) 场景 2 检测结果

图 9 深度图像检测结果

Fig. 9 Depth image detection results

使用第 3 组网络训练参数,基于本研究建立的数据集分别训练 YOLOv4、YOLOv3、YOLOv4-tiny、YOLOX-L,训练结果见表 6。

表 6 不同网络模型训练结果

Tab 6 Training results of different network models

模型	平均精度/%			均耗时/ms
	训练集 AP/%	验证集 AP/%	测试集 AP/%	
YOLOv4	97.39	97.08	97.89	22.67
YOLOv4-tiny	76.62	76.40	76.84	3.29
YOLOv3	94.91	94.63	94.75	26.61
YOLOX-L	90.65	90.74	90.63	24.20

YOLOv4 取得最好的深度图像交通锥桶检测结果,AP 值达到 97.89%,平均推理时间为 22.67 ms。YOLOv4 在各数据集中的 AP 值均大于 YOLOv3 的,且平均推理时间减少 19.11%;在测试集中,YOLOv4 的 AP 值比 YOLOv4-tiny 的大 21.05%,因此 YOLOv4-tiny 可能会出现漏检和错检问题,不适用于实时的临时道路识别算法。YOLOX 在测试集中的 AP 为 90.63%,低于 YOLOv4 和 YOLOv3 结果,由于数据集中仅包含“cone”标签,因此 anchor-free 机制造成的漏检问题是影响 AP 值的主要原因,因此选用 YOLOv4 检测深度图片中的交通锥桶。

3.3 结果融合算法和实车实验

得到彩色图像和深度图像的检测结果后,在测试集中进行匹配实验测试,统计得到的匹配成功的交通锥桶占总锥桶数的85.04%。匹配失败的主要原因为数据传输延迟不稳定,导致周期性的匹配失败。

使用交通锥桶构建临时道路,红色交通锥标记道路的左边缘,蓝色交通锥标记道路的右边缘,黄色交通锥用于标记起点和终点。临时道路宽约3 m,相邻2个同色交通锥之间的距离约4 m,包含20 m直道和一段转弯半径为8 m的直角弯道。根据彩色图像得到的颜色信息和深度图像得到的三维位置信息,进行路径规划,结果如图10(b)所示。



(a)彩色图像检测结果



(b)位置信息感知及路径规划结果

图10 路径规划结果

Fig. 10 Path planning results

在该临时道路上,实验车辆以10 km/h的速度匀速行驶,机器视觉系统每秒捕获12帧彩色和深度图像,通过对彩色图像和深度图像的检测结果进行匹配,成功地得到交通锥的颜色信息和三维位置信息,如图10(b)所示。彩色图像和深度图像中交通锥桶的均检测时间分别为36.34、22.67 ms,结果匹配和路径规划的平均时间为2.69 ms,所以处理一帧相机数据的总时间成本约为61.70 ms,小于图像捕获间隔83 ms,满足实时处理的要求。约30 m的检测距离可以满足测试车辆在当前速度下的行驶安全性。

4 结论

本文中提出一种融合彩色相机和深度相机信息的临时道路识别算法,用于识别由交通锥桶标识的临时道路,在实车实验中规划出车辆的运动路径,论文得出的主要结论如下:

① 使用YOLOv4机器学习模型构建的交通锥桶识别算法,识别交通锥桶的mAP和AP分别可达93.48%、97.89%,单帧平均检测时间分别约为36.34、22.67 ms,在识别彩色图像和深度图像中实时获得的结果比YOLOv3、YOLOv4-tiny模型结果更为精确、稳定。

② 提出的基于边界框欧氏距离的匹配算法,可将彩色和深度信息进行融合,匹配成功率可以达到85.04%,提升了交通锥桶感知的精度、速度和鲁棒性。

③ 建立的交通锥桶数据集,包含多种环境、光照条件下的彩色图像和深度图像和人工标注,可有效用于深度学习模型进行交通锥桶检测的训练和验证。

参考文献:

- [1] 冯黎. 无人驾驶汽车自主导航策略与控制算法研究[D]. 成都:电子科技大学, 2019.
- [2] 冯明驰,高小倩,汪静姝,等. 基于立体视觉与激光雷达的车辆目标外形位置融合算法研究[J]. 仪器仪表学报, 2021,42(10):210-220.
- [3] 尉天成,陈小锋,殷元亮. 基于多尺度卷积神经网络的道路交通标志识别方法研究[J]. 西北工业大学学报,

- 2021,39(4):891-900.
- [4] 龙建武,彭浪,安勇. 基于目标特征蒸馏的车道线检测[J]. 重庆理工大学学报(自然科学版), 2020,34(9): 198-208.
- [5] 唐小煜,黄进波,冯洁文,等. 基于 U-Net 和 YOLOv4 的绝缘子图像分割与缺陷检测[J]. 华南师范大学学报(自然科学版), 2020,52(6):15-21.
- [6] 李砚峰,刘翠荣,吴志生,等. 基于深度学习 One-Stage 方法的焊缝缺陷智能识别研究[J]. 广西大学学报(自然科学版), 2021,46(2):362-372.
- [7] GIRSHICK R. Fast R-CNN[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). San Diego, Chile: IEEE, 2015:1440-1448.
- [8] DUAN K, XIE L, QI H. Corner proposal network for anchor-free, two-stage object detection[C]//Computer Vision-ECCV 2020: 16th European Conference, Springer International Publishing, Glasgow, UK: Springer, 2020: 399-416.
- [9] 顾恭,徐旭东. 改进 YOLOv3 的车辆实时检测与信息识别技术[J]. 计算机工程与应用, 2020,56(22):173-184.
- [10] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, USA: IEEE, 2016: 779-788.
- [11] TAN M, RUOMING P, QUOC L. Efficientdet: scalable and efficient object detection[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, USA: IEEE, 2020:10778-10787.
- [12] REDMON J, FARHADI A. Yolov3: an incremental improvement [C]//Proceeding of the IEEE Conference on Computer Vision and Pattern Recognition, Salt Lake City, USA: IEEE, 2018:89-95.
- [13] WANG C, BOCHKOVSKIY A, LIAO H. Scaled-YOLOv4: scaling cross stage partial network[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, USA: IEEE, 2021:13029-13038.
- [14] ZHOU L, HAN W, WANG D, et al. Traffic cone detection and localization in techx challenge 2013[J]. Physical Review Letters, 2015,234(2):287-97.
- [15] KALMS L, RETTKOWSKI J, HAMME M, et al. Robust lane recognition for autonomous driving[C]//Design & Architectures for Signal and Image Processing, Dresden, Germany: IEEE, 2017:1-6.
- [16] HUANG Y, XUE J. Real-time traffic cone detection for autonomous vehicle[C]//2015 34th Chinese Control Conference (CCC). Hangzhou, China: IEEE, 2015:3718-3722.
- [17] WANG L, SUN P, XIE M, et al. Advanced driver-assistance system (ADAS) for intelligent transportation based on the recognition of traffic cones[J]. Advances in Civil Engineering, 2020,2020(4):1-8.
- [18] DHALL A, DAI D, GOOL V. Real-time 3D traffic cone detection for autonomous driving[C]//2019 IEEE Intelligent Vehicles Symposium (IV). Paris, France: IEEE, 2019:494-501.

(责任编辑 梁碧芬)