

北方工业大学

硕士学位论文



基于双目立体视觉的自动驾驶赛车控制
研究

学 生 姓 名 _____ 关帅

学 号 _____ 2019312110114

学科(专业学位) _____ 控制科学与工程

研 究 方 向 _____ 智能交通控制与管理

导 师 _____ 范晶晶

2022 年 5 月 20 日

Research on Automatic Driving Car Control Based on Binocular Stereo Vision

By

Guan Shuai

A Dissertation Submitted to

North China University of Technology

In partial fulfillment of the requirement

For the degree of

Master of Engineering

North China University of Technology

May, 2022

基于双目立体视觉的自动驾驶赛车控制研究

摘 要

中国大学生方程式赛事是各大高校在汽车领域研究成果展示的重要平台，其中无人驾驶方程式赛事已经连续开展 5 年，技术水平很高。本文针对中国大学生无人驾驶方程式赛车比赛，对无人驾驶赛车的感知、规划与控制进行开发，综合分析赛道情况，采用双目立体视觉作为唯一感知元件，提出基于双目立体视觉的自动驾驶赛车控制系统。

首先，搭建方程式赛车自动驾驶系统的硬件架构。设计以双目相机为主要环境感知传感器的自动驾驶控制软件架构方案。建立方程式赛车轮胎模型，并进行仿真验证。并在适当的简化条件下，搭建三自由度动力学模型，在保证车辆横向运动精度的同时，降低模型复杂度。同时进行车辆运动学分析，建立赛车运动学模型。

其次，采用双目立体视觉系统对比赛赛道进行识别和测距。依据双目相机成像的原理，分析从空间中的三维目标点到相机成像平面的变换关系，为提高对方程式比赛中小目标锥桶的识别效果，提出一种改进 YOLOv4-tiny 的网络模型，将原 YOLOv4-tiny 的主干网络高卷积特征层与颈部网络特征层进行融合，增加预测尺度的输出。同时，使用 K-means++ 聚类方法，针对长方形锥桶数据集，确定出更适合锥桶识别的锚框尺寸，改进后的 YOLOv4-tiny 网络能够保持较快的检测速度，同时提高识别精度 2.83%。

最后，在决策控制方面建立 MPC 动力学控制器。在赛车三自由度车辆动力学模型的基础上建立了 MPC 控制器预测模型，根据赛车实际情况设定动力学约束，并利用 CarSim 与 Simulink 进行联合仿真，将本文提出的 MPC 跟踪算法与 Pure Pursuit、Stanley 跟踪算法进行仿真对比，仿真结果表明本文提出的跟踪算法跟踪效果更好。基于我校无人驾驶方程式赛车平台，通过实车试验验证自动驾驶控制算法的跟踪效果，试验结果显示，所设计的跟踪控制器在工况下跟踪精度良好，稳定性和可靠性较高，满足方程式比赛需求。

关键词：自动驾驶，双目立体视觉，模型预测控制

Research on Automatic Driving Car Control Based on Binocular Stereo Vision

Abstract

Formula SAE of china is an important platform for universities to display their research results in the automotive field. Among them, the driverless formula competition has been carried out for five consecutive years, with a high level of technology. This paper develops the perception, planning and control of the Formular Student Autonomous China. By comprehensively analyzing the track conditions and using binocular stereo vision as the only perception element, an autonomous driving racing car control system based on binocular stereo vision is proposed.

First, build the hardware architecture of the formula racing autopilot system. Design an autonomous driving control software architecture scheme with binocular camera as the main environment perception sensor. Build a formula car tire model and conduct simulation verification. And under the appropriate simplified conditions, a three-degree-of-freedom dynamic model is built to reduce the complexity of the model while ensuring the accuracy of the lateral motion of the vehicle. At the same time, the vehicle kinematics analysis is carried out, and the racing kinematics model is established.

Secondly, the binocular stereo vision system is used to identify and measure the distance of the race track. According to the principle of binocular camera imaging, the transformation relationship from the three-dimensional target point in space to the camera imaging plane is analyzed. In order to improve the recognition effect of small target cones in the equation competition, an improved YOLOv4-tiny network model is proposed. The high-convolution feature layer of the backbone network of YOLOv4-tiny is fused with the feature layer of the neck network to increase the output of the prediction scale. At the same time, the K-means++ clustering method is used to determine the anchor frame size that is more suitable for cone-bucket recognition for the rectangular cone-barrel dataset. The improved YOLOv4-tiny

network can maintain a faster detection speed and improve the recognition accuracy by 2.83%.

Finally, the MPC dynamics controller is established in terms of decision control. Based on the three-degree-of-freedom vehicle dynamics model of the racing car, the prediction model of the MPC controller is established, the dynamic constraints are set according to the actual situation of the racing car, and the joint simulation is carried out with CarSim and Simulink. The MPC tracking algorithm proposed in this paper is compared with the Pure Pursuit and Stanley tracking algorithms. The simulation results show that the tracking algorithm proposed in this paper has better tracking effect. Based on the unmanned formula racing platform of our school, the tracking effect of the automatic driving control algorithm is verified through the real vehicle test. The test results show that the designed tracking controller has good tracking accuracy, high stability and reliability under the test conditions. Meet the needs of formula competition.

Key words: autonomous driving, binocular stereo vision, MPC

目 录

摘 要.....	I
ABSTRACT.....	II
第一章 绪论.....	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 自动驾驶汽车研究状况.....	2
1.2.2 基于视觉的自动驾驶研究状况.....	4
1.2.3 自动驾驶轨迹跟踪控制研究状况.....	5
1.3 本文主要研究内容	7
第二章 无人驾驶方程式赛车架构与建模	9
2.1 无人驾驶方程式赛车硬件架构	9
2.2 无人驾驶方程式赛车建模	10
2.2.1 方程式赛车轮胎模型.....	10
2.2.2 方程式赛车动力学建模.....	12
2.2.3 方程式赛车运动学建模.....	16
2.3 无人驾驶方程式赛车控制软件架构	17
2.4 本章总结	18
第三章 基于双目立体视觉的锥桶识别	19
3.1 双目立体视觉测距原理	19
3.1.1 单目视觉与双目视觉对比.....	19
3.1.2 相机成像坐标变换原理.....	19
3.1.3 双目视觉测距原理.....	21
3.2 双目立体视觉平台搭建	23
3.2.1 软件开发平台.....	23
3.2.2 硬件平台.....	23
3.3 基于深度学习的锥桶识别	24

3.3.1 YOLOv4-tiny 算法原理	24
3.3.2 YOLOv4-tiny 网络结构改进	25
3.3.3 锥桶识别结果与分析	27
3.4 本章总结	30
第四章 路径规划与轨迹跟踪控制	31
4.1 赛车行驶路径规划	31
4.1.1 锥桶边界车道拟合	31
4.1.2 期望路径规划	33
4.1.3 路径平滑处理	34
4.2 基于 MPC 横向控制器设计	35
4.2.1 MPC 算法原理	35
4.2.2 非线性系统线性化	36
4.2.3 线性时变预测模型设计	37
4.2.4 目标函数设计	38
4.2.5 车辆动力学约束	39
4.3 路径跟踪控制仿真结果	41
4.3.1 联合仿真平台介绍	41
4.3.2 仿真参数设置	42
4.3.3 仿真验证	43
4.4 本章总结	45
第五章 实车试验结果与分析	47
5.1 操场情景下的实车试验	47
5.2 八字环绕情景下的实车试验	50
5.3 本章总结	51
第六章 结论与展望	52
6.1 主要结论	52
6.2 研究展望	53
参考文献	54

在学期间的研究成果	58
致 谢.....	59

第一章 绪论

1.1 研究背景及意义

近年来,我国科技水平大幅提升,逐步掌握新能源汽车领域核心技术,突破瓶颈。我国从“十五”开始经历了三个五年计划后,新能源汽车产业进入了高速发展的新时期^[1]。国务院办公厅最新发布的《新能源汽车产业发展规划(2021—2035年)》^[2]中表明新能源汽车要朝向智能化发展,到2025年在规定区域和场景下,自动驾驶车辆将实现商业化应用。在国家的大力支持下,各地高校和研究所、传统车企和新兴新能源企业、互联网企业等投入了大量资源,推动我国自动驾驶技术更上一层楼,加速成果转化和实车落地^{[3]-[4]}。我国工业和信息化部基于自动驾驶系统实现动态驾驶任务的复杂程度,将驾驶自动化分成0-5级^[5],目前具备自动驾驶功能的车辆多数处于2级,正在向着3级以上的目标发展,因此自动驾驶技术还有很大的提升空间,对此方向的研究是非常有意义的。

自动驾驶主要由感知、决策、控制三大模块组成^[6]。环境感知是自动驾驶的首要条件,准确的环境感知数据为决策和控制模块提供可靠的保障,环境感知不仅需要识别到各种工况下的不同的障碍物,还需要进行行为预测与高精度定位。决策与规划在自动驾驶中起到决定性作用,是确保自动驾驶安全的重要环节。决策与规划模块主要包括路径规划和行为决策,路径规划是在复杂的道路环境下,按照驾驶目标和规则,生成一条安全无碰撞路径,而行为决策是根据当前车辆状态合理地选择驾驶行为,配合路径规划实现最终自动驾驶目标^[7]。车辆运动控制模块主要是通过控制车辆底盘的线控机构,如油门、刹车、转向等,使车辆的实际路径收敛于自动驾驶决策规划的期望路径,控制模块是自动驾驶性能的直接体现。

要想实现自动驾驶,车辆需要配置多种传感器,例如激光雷达、毫米波雷达、超声波雷达、摄像头、组合导航等,各个传感器由于特性不同,在不同工况下有着差异的表现。激光雷达主要用于识别检测障碍物,且不受光线影响,但缺点在于价格昂贵;毫米波雷达主要用于检测周围车辆,同样不易受到光线的影响,但是对于交通灯及车道线无法实现识别;而摄像头通过处理包含大量信息的图像,实现了交通标识、行人、车道线等信息的获取,虽然易受天气影响,但是其高性价比更利于将自动驾驶大规模落地,像特斯拉更是主导以摄像头为主研发自动驾驶,在降低成本的同时挖掘摄像头更大的效能,因此基于视觉的自动驾驶有很大

的研究意义^[8]。

中国汽车工程学会为了培养新时代汽车人才，推动我国自动驾驶技术发展，于 2017 年 11 月，举办了第一届中国大学生无人驾驶方程式大赛(Formula Student autonomous china, FSAC)，第一届 FSAC 由北京理工大学的“灰鲨”号车夺得冠军，我校车队于 2020 年开始参加 FSAC，获得了全国三等奖。FSAC 赛事规则要求各大高校在一年时间内自主研发、制作一台方程式赛车，在经过严苛的车检后，保证有人驾驶的基础上实现对自动驾驶的赛况需求。比赛的静态项目主要是自动驾驶系统和设计答辩，动态项目则包括直线加速、八字环绕和高速循迹三个赛况^[9]。本文以 FSAC 赛车作为研究对象，以双目相机为主要的环境感知传感器，对赛车在实际 FSAC 比赛场景中跟随期望路径做研究，为后续自动驾驶汽车领域感知和运动控制方面研究与 FSAC 赛车感知和控制提供研究数据。

1.2 国内外研究现状

1.2.1 自动驾驶汽车研究状况

自上世纪 80 年代以来，国外许多大学、研究中心、汽车公司等都在研究和开发自动驾驶汽车。其中，Carnegie Mellon University 研制的智能无人平台 Navlab-V^[10]、Universität der Bundeswehr München 与 Mercedes Benz 联合研制的 VaMoRs 和 VaMP^[11]、Università degli Studi di Pavia 研发的 ARGO 智能车^[12]、Kumamoto University 的智能车辆等较为著名。



图 1-1 Navlab-V



图 1-2 VaMoRs

21 世纪初，美国国防高级研究计划局（DARPA）以促进自动驾驶技术发展为目标，组织了三次 DARPA 挑战赛。2004 年举办了第一届挑战赛，要求自动车辆在限定时间内通过 142 英里长的莫哈维沙漠，但没有团队能够完成比赛。2005 年的 DARPA 挑战赛要求自动驾驶汽车在 132 英里长的路线上穿越平原、干涸的湖泊等，4 辆自动驾驶汽车完成了路线，其中斯坦福大学研发的无人车获

得第一名^[13]。2007 年举办的 DARPA 挑战赛则聚焦到了城市环境下的自动驾驶工况，要求自动驾驶汽车在 60 英里长的城市环境路线上，与其他自动驾驶和有人驾驶汽车一起，在不违反道路法规的情况下通过^[14]。最终卡内基梅隆大学研发的 Boss 号获得第一名^[15]，斯坦福大学和弗吉尼亚理工大学分获二三名^{[16]-[17]}。相比日常驾驶环境，挑战赛中的工况设计较为简单，但这些挑战赛仍为自动驾驶汽车发展贡献了一份力量。



图 1-3 卡内基梅隆大学 Boss



图 1-4 斯坦福大学 Junior

近些年来，国外传统车企自动驾驶更是有了新的进展，2016 年日本的日产公司着手研发自动驾驶车辆，丰田汽车公司也与 Google 展开自动驾驶项目合作。戴姆勒集团和宝马集团为了专注于在高速场景下的无人驾驶，共同联合开展研发。而势头更猛的则是互联网企业，2017 年开始，Google 公司研制的自动驾驶车辆在不配路测实验员的情况下进行自动驾驶测试。此外还有 Waymo 公司、Uber、特斯拉等企业都已经拿到当地路测牌照^[18]。2017 年，德国大学生方程式比赛引入了新的无人驾驶赛事，首届比赛就有来自世界各地 22 个高校车队报名参加，吸引了包括 Technische Universität München、Eidgenössische Technische Hochschule Zürich、Karlsruher Institut für Technologie、Massachusetts Institute of Technology 等世界名校^[19]。

我国于上世纪 80 年代陆续开展对自动驾驶汽车的研发工作。1992 年，包括清华大学和国防科技大学在内的五所大学联合开发了中国第一辆无人驾驶汽车 ATB-1^[20]，这意味着我国自动驾驶技术研发工作正式启动。后续的 ATB-2 和 ATB-3 相继推出，提升了自动驾驶车辆的行驶速度和感知功能。2003 年国防科技大学在红旗轿车上部署了无人驾驶系统，可在高速公路上以最高 110km/h 的速度进行避障自动换道^[21]。后来，2011 年 7 月，国防科技大学以红旗 HQ3 轿车为基础平台，完成了 286 公里高速公路的无人驾驶。此次测试表示我国在无人驾驶汽车感知、决策和控制方面取得了新的技术突破^[22]。2015 年 12 月，百度研发的自动驾驶汽车在复杂的高速公路上完成了最高时速 100km/h 的测试，测试内容包括了日常复杂行驶任务，这意味着一项技术从科研到产品落地。2016 年 4 月，长安汽车与清华大学、华为公司合作，实现了 2000 公里自动驾驶车辆测试项目，

计划 2025 年实现量产^[23]。2019 年 8 月，滴滴研发的自动驾驶汽车在世界人工智能大会上表现良好。2020 年 4 月 27 日，国产智能电动轿车小鹏 P7 上市，该车针对国内复杂的交通场景，研发了一套基于多传感器融合的自动驾驶解决方案，对自动驾驶落地商业化应用具有重要影响。与此同时，高德公司联合安途公司在上海推出无人出租车服务，市民可以打到配有安全员的无人出租车，安全员只在紧急情况下接管车辆。



图 1-5 百度自动驾驶



图 1-6 中国大学生方程式系列比赛

中国汽车工程学会借鉴德国大学生方程式比赛并针对我国自动驾驶情况，从 2017 年开始，举办中国大学生无人驾驶方程式大赛。其中北京理工大学、辽宁工业大学、哈尔滨工业大学等高校研制的无人方程式赛车较为出色。随着自动驾驶技术的发展，越来越多的高校参与到中国大学生无人驾驶方程式大赛中来，为我国自动驾驶的发展贡献力量。虽然现阶段无人驾驶的发展非常迅速，但无人驾驶涉及技术复杂，不论国内外，现阶段仍有自动驾驶事故发生，并且各国还没有对应的自动驾驶法律法规相支撑，所以针对自动驾驶的研究具有意义。

1.2.2 基于视觉的自动驾驶研究状况

自动驾驶的关键技术主要有环境感知、路径规划、决策控制。其中环境感知是自动驾驶的前提，是保障后续自动驾驶功能安全性的基础。目前，自动驾驶环境感知方案可分为两大类：一类是以激光雷达为主要传感器，毫米波雷达、超声波雷达等为辅助传感器的方案；另一类是以摄像头为主，毫米波雷达为辅的解决方案。相比较激光雷达的感知方案，摄像头为主的感知方案可以从图像信息中直接获得更加丰富环境信息，并且成本低廉，针对以视觉为主导的自动驾驶研究也在不断地发展进步^[24]。

全球新能源汽车销量第一的特斯拉所坚持的技术路线是以视觉为主的自动驾驶方案，特斯拉车辆配有 8 个摄像头，1 个 77GHz 的毫米波雷达和 12 个超声波雷达作为辅助传感器。其中，为了针对不同交通场景下的目标识别，前视摄像

头为以鱼眼、主视和长焦镜头组合的三目总成件；后视摄像头主要功能为倒车、泊车；侧方向各有一对前视、后视摄像头，用来观察侧方向的道路情况^[25]。特斯拉采取的这套摄像头方案可以 360° 全方位感知车辆周围环境，中控大屏显示由汽车传感器检测到的道路可视化结果，为驾驶员提供用于车道偏离、障碍物信息、自适应巡航和碰撞预警等功能的信息。特斯拉的驾驶辅助系统也在不断地完善，除了自动驾驶功能外，每辆特斯拉汽车在不同路况下的驾驶行为都会共享到其中央服务器。在强大的数据库支撑下，利用机器学习开发出新的功能，更新并发布新版本自动驾驶解决方案。

除了特斯拉，日本富士重工旗下的斯巴鲁汽车早在 2008 年就量产了以双目立体摄像头为主的驾驶辅助系统 EyeSight。EyeSight 系统可以检测和区分车辆、摩托车、自行车、行人和车道标记等。具备自动转向、自适应巡航、车道保持、车道偏离修正等功能，并且这两个立体摄像头还具有识别交通信号灯颜色的功能，辅助系统的准确性进一步得到提升。例如，当检测到前车正在减速或停车，如果检测到驾驶员没有采取规避动作，则系统会自动施加刹车。如果检测到驾驶员的制动输入不足，则自动增加制动力。当车速在 60km/h 以上时，实时检测车辆是否在车道上，当出现偏离时自动修正方向。但是，在恶劣天气下，可能会出现干扰^[26]。

英特尔旗下公司 Mobileye 也是一家以视觉为主导的自动驾驶公司。2018 年，在耶路撒冷道路标识不全、行车艰难、行人不遵守交通规则的情况下，Mobileye 的百辆自动驾驶汽车顺利完成了街头测试，其自动驾驶车辆只配备了 12 颗摄像头，并没有其他任何辅助传感器。在 Mobileye 的自动驾驶解决方案中，360° 全景摄像头系统能够全方位识别周围车辆、行人、障碍物和交通指示灯等信息，实现实时创建全景地图，进而进行路径规划和决策控制^[27]。

1.2.3 自动驾驶轨迹跟踪控制研究状况

轨迹跟踪控制是通过整车控制器对车辆转向机构、踏板开度、制动机构等子系统进行控制，使得自动驾驶车辆按照预先规划出的轨迹精准、稳定的行驶，轨迹跟踪控制是自动驾驶算法性能的基本体现。轨迹跟踪控制分为横向控制和纵向控制。横向控制关注的是车辆在转向方面对于预定轨迹的跟踪性能，被控对象为车辆的转向机构；纵向控制关注的是对设定车速的跟踪性能，被控对象是油门踏板开度、制动机构。车辆是一个具有强耦合非线性变参数的系统，车辆的运动控制问题需要考虑车辆轮胎、转向等子系统，车辆与外界道路间的相互影响，具有很高的复杂程度。

为了解决自动驾驶的轨迹跟踪控制问题，国内外的学者提出了许多控制算

法,其中主要包括比例-积分-微分(PID)控制、纯跟踪控制(Pure Pursuit)、斯坦利控制(Stanley)、模型预测控制(MPC)等方法^{[28]-[30]}。

(1) PID 控制

PID 控制的模型简单、调节参数少、适应性好,在实际工程中应用较为广泛。1991 年, Hessburg 和 Peng 使用具有前馈控制作用的 PID 控制算法在实车上实现了良好的跟踪性能,但是当实验条件与预定值产生偏差后,跟踪效果就会下降^[31]。2011 年北京理工大学的赵熙俊在车辆动力学模型基础上,依据航向偏差设计了基于 PID 反馈的横向运动控制系统,低速下具有较好的跟踪效果^[32]。虽然 PID 控制算法相对简单,但是 PID 参数需要依靠大量试验来调整。此外, PID 控制的鲁棒性较差,道路结构的变化会导致控制精度变差,难以实现无人车辆运动的最优控制^[33]。

(2) Pure Pursuit 控制

Pure Pursuit 控制算法又叫做纯跟踪控制算法,该方法的实质是根据几何原理来控制车辆行驶轨迹,根据车辆的行驶速度在预定轨迹上设置路径点,计算车辆从当前位置转向预设目标点所需的角度,控制车辆行驶到路径点。纯跟踪控制算法最早由 Amidi 提出,并且在 NavLab 上测试了该算法^[34]。Urmson 等人研发的无人车在越野环境下累计行驶了 3500 多公里,验证了纯跟踪算法的可靠性^[35]。Leonard 等人在 2007 年举行的 DARPA 城市挑战赛中利用纯跟踪算法对城市环境中自动驾驶车辆的转向进行控制,并成功完成了所有比赛^[36]。长安大学的许耀华将基于航向角偏差的路径跟踪算法与纯跟踪算法进行比较,实车验证了改进的纯跟踪算法的控制效果^[37]。在纯跟踪算法中,前视距离的选取将会影响到车辆轨迹跟踪的精度。当前视距离较大时,车辆的转弯半径变大,转向调节频率降低,影响控制精度;当前视距离较小时,车辆的转弯半径小,转向调节频率高,可能会产生较大的振荡,车辆的稳定性差。此外,纯跟踪控制算法只考虑车辆运动学模型,不考虑车辆动力学,在中高速时会导致运动学模型失配,跟踪效果变差。该算法只适合低速工况下的路径跟踪控制。

(3) Stanley 控制

在 2005 年的 DARPA 智能汽车挑战赛中,斯坦福大学在 Stanley 智能车上针对挑战赛的的非结构化道路,提出了 Stanley 控制算法,该控制算法基于二自由度车辆运动学模型,设计了以路径曲率的前馈控制和 PID 反馈控制结合的横向控制系统,该控制器可使跟踪误差迅速收敛^[38]。湖南大学的王亚平针对 Stanley 算法受前方轨迹的曲率和自身车速的影响导致跟踪精度差的问题,采用模拟退火粒子群优化算法对 Stanley 算法进行改进,实车试验结果表明低速工况下改进后的算法具有较好的鲁棒性^[39]。Stanley 算法相较于 Pure Pursuit 算法考虑了横向误差带

来的轨迹跟踪控制的影响,对期望路线的贴合度更好。但 Stanley 算法与 Pure Pursuit 算法都属于基于车辆运动学的模型,不适合用于高速工况。

(4) 模型预测控制

模型预测控制是一种基于动力学模型的反馈控制算法,又被成为滚动时域优化器。Abbas 等人设计了一种轨迹跟踪控制的非线性模型预测系统,并使用非线性 CarSim 车辆模型进行仿真,实验表明在满足实时约束的同时提供了较好的跟踪性能,但是发现算法运算量较大,对控制器硬件要求较高^[40]。Falcone 等人提出了两种计算复杂度不同的方法,一种是使用非线性车辆模型来设计 MPC 控制器,另一种方法是基于车辆模型的线性时变的 MPC 控制器,并对两种控制算法进行了实车验证,轨迹跟踪效果较好^[41]。Kim 等人使用简化的车辆动力学模型来设计预测模型,优化了目标函数设计,经仿真验证了轨迹跟踪性能良好^[42]。Kong 等人对比了基于车辆运动学模型和动力学模型下的预测误差,并对 MPC 控制器进行了简化设计,经实验结果表明,该方法在不同速度下的跟踪效果较好^[43]。

国内也有众多学者对模型预测控制进行了研究。王银等人针对低附着系数下的轨迹跟踪控制,提出了一种自适应模型预测控制器,该控制器对车辆动力学模型添加侧偏角约束,并对算法进行仿真验证,但未通过实车来验证算法的实时性^[44]。陈舒平等人以 8 自由度车辆模型作为预测模型,来生成最优的前轮转角,通过仿真表明车辆在高速工况下的轨迹跟踪性能良好,但其运算量相当巨大,实时性较差,对硬件运算能力要求较高^[45]。

综上,国内外学者对自动驾驶轨迹跟踪进行了大量的研究,但对车辆自身因素以及道路条件的复杂程度考虑较少,如方向盘角度限制、加速度限制、地面附着条件、道路曲率等。而方程式赛车比赛要求轨迹跟踪精度要高,实时性和稳定性都要提高,因此,本文将重点研究考虑车辆动力学约束和行驶道路条件影响,以提高跟踪性能。

1.3 本文主要研究内容

本文以北方工业大学无人驾驶方程式赛车为研究平台,针对大学生无人驾驶方程式比赛,对无人驾驶赛车的感知、规划与控制进行开发。感知方面,采用双目相机在改进的深度学习模型上对锥桶进行识别、测距,并根据锥桶数据信息输出车道中心线;跟踪控制方面,在赛车三自由度车辆动力学模型的基础上建立了 MPC 控制器预测模型,并通过 CarSim、Simulink 联合仿真和实车试验对跟踪控制效果进行了对比验证。本文的章节安排如下:

第一章,绪论。首先介绍了自动驾驶的研究背景和研究意义,随后介绍了国

内外自动驾驶技术的研究现状,并重点关注了机器视觉技术下的自动驾驶研究发展状况,最后对轨迹跟踪控制研究状况做了阐述,明确了本文的研究方向。

第二章,无人驾驶方程式赛车架构与建模。阐述了本文研究的方程式赛车自动驾驶系统的软件和硬件架构,从轮胎模型出发搭建了方程式赛车模型,并以轮胎模型为基础搭建了三自由度车辆动力学模型,最后还进行了运动学模型的搭建。赛车模型的搭建为后续轨迹跟踪控制器的设计作了铺垫。

第三章,基于双目立体视觉的锥桶识别。本章首先依据双目摄像头成像的原理,分析了从现实物体变换到平面图像过程中四大坐标系间的转换关系,推导了双目立体视觉测距公式。随后根据赛事需求,选择、搭建了双目立体视觉平台。最后对基于深度学习的 YOLOv4-tiny 图像识别算法进行了改进,并将改进前后的深度学习网络进行实验对比,保证了感知系统的精度和效率。

第四章,路径规划与轨迹跟踪控制。本章提出了以双目立体视觉为主要传感器的路径规划方案,依据双目相机识别到的锥桶信息,拟合出锥桶边界线,求解得到期望路径。随后结合前文的车辆动力学模型设计了基于 MPC 的轨迹跟踪控制器,同时制定了控制器的目标函数,依据赛车实际情况添加了动力学约束。最后利用 CarSim 与 Simulink 对控制模型进行了联合仿真,验证所设计的轨迹跟踪控制器的可行性。

第五章,实车试验结果与分析。本章基于学校无人驾驶方程式赛车平台,在学校操场环境下设计了两种工况来对轨迹跟踪算法进行实车验证,通过实车试验进一步的对比、验证本文设计的轨迹跟踪算法。

第六章,结论与展望。总结本文研究内容,针对本文研究的不足提出未来研究的方向和思路,对下一步的研究进行展望。

第二章 无人驾驶方程式赛车架构与建模

无人驾驶车辆是一个涉及多学科、多技术的复杂系统，本文所研究的自动驾驶功能主要在我校 FSAC 赛车上实现。无人驾驶方程式赛车是由各大高校学生依据大赛相关的规则，历时一年自主设计、研发完成的具有自动驾驶功能的电动车。本章对我校无人驾驶方程式赛车整车架构进行介绍，并对车辆进行数学建模，为后续的路径规划及跟踪控制研究作铺垫。

2.1 无人驾驶方程式赛车硬件架构

无人驾驶方程式赛车需要具备无人和有人两种驾驶功能，本文的研究对象是在我校上一届有人驾驶赛车系统的基础上加入线控系统和自动驾驶系统组成的。线控系统主要由线控转向电机、线控驱动电机和线控制动电机组成，线控系统由整车控制器来控制，整车控制器对自动驾驶系统发出的指令进行处理，进而控制线控系统各部分响应相应指令，从而实现车辆的轨迹跟踪控制。自动驾驶系统主要由双目相机、组合导航、工控机等一系列环境感知传感器和运算平台组成。环境感知传感器负责感知赛道锥桶信息，运算平台负责处理传感器数据，规划相应的参考路径，发出控制指令等。无人系统硬件架构如图 2-1。



图 2-1 无人系统硬件架构

赛车除了增加的线控系统和自动驾驶系统以外，车辆本身还包括高压动力系统、低压系统。高压系统包括 400V 高压电池箱、电机控制器、驱动电机；低压

系统包括 24V 低压电池、整车控制器、各类低压用电设备（制动电机、转向电机、自动驾驶系统供电）等。方程式赛车硬件结构情况如图 2-2。




图 2-2 赛车硬件结构图

2.2 无人驾驶方程式赛车建模

2.2.1 方程式赛车轮胎模型

本文的研究对象是在高速工况行驶下的 FSAC 方程式赛车，轮胎的复杂结构影响着车辆的行驶稳定性。轮胎模型对于车辆动力学模型的构建具有重要影响，而车辆动力学模型又是轨迹跟踪控制的基础，因此在建立车辆动力学模型之前，需要依据轮胎的受力特性建立轮胎模型。

目前，轮胎模型主要分为物理模型和经验模型^[46]。物理模型是根据轮胎与地面间的力学关系建立的简化模型，经验模型是通过拟合实验数据得出的经验公式来建立的模型。物理模型相比经验模型更为复杂、精度更高，但是用这种方法表示的轮胎模型求解复杂，计算量大，不满足方程式赛车实时性的要求。而经验模型的模型较为简单、计算量较小、拟合精度较高，更适合快速运算的要求，所以本文的轮胎模型采用经验模型的代表“魔术公式”进行分析。

“魔术公式”轮胎模型的表达式为：

$$Y(x) = D \sin\{C \arctan[Bx - E(Bx - \arctan(Bx))]\} \quad (2-1)$$

其中， B 为刚度因子； C 为形状因子； D 为峰值因子； E 为曲率因子； x 为输入量； Y 为输出量，其输入与输出之间的关系如图 2-3 所示。所以“魔术公式”

轮胎模型描述了轮胎的纵向力 F_l 、侧向力 F_c 、回正力 M_z 与轮胎侧倾角 γ 、侧偏角 α 、滑移率 s 等输入量之间的关系。




图 2-3 魔术公式模型

根据上述“魔术公式”，可以得到轮胎纵向力计算公式：

$$\begin{cases}
 F_l = D \sin\{C \arctan[Bx - E(Bx - \arctan(Bx))]\} + S_v \\
 x = s + S_h \\
 C = B_0 \\
 D = B_1 F_z^2 + B_2 F_z \\
 E = B_6 F_z^2 + B_7 F_z + B_8 \\
 B = \frac{(B_3 F_z^2 + B_4 F_z) \times e^{-B_5 F_z}}{C \times D} \\
 S_v = 0 \\
 S_h = B_9 F_z + B_{10}
 \end{cases} \quad (2-2)$$

其中， S_v 表示垂直方向漂移， S_h 表示水平方向漂移，在纯纵滑工况下，对不同垂直载荷下的纵向力与纵向滑移率进行仿真，如图 2-4 所示。




图 2-4 纵向力和纵向滑移率关系图

由上图可以看出，当纵向滑移率不变时，纵向力随垂直荷载的增加而增大；在垂直荷载不变的情况下，当纵向滑移率在 $\pm 5\%$ 的范围内变化时，纵向力与纵

向滑移率近似线性关系；但当纵向滑移率在 $\pm 5\%$ 范围外变化时，纵向力趋于稳定，整体呈非线性关系。

根据“魔术公式”，可以得到轮胎侧偏力计算公式：

$$\begin{cases} F_c = D \sin\{C \arctan[Bx_1 - E(Bx_1 - \arctan(Bx_1))]\} + S_v \\ x = \alpha + S_h \\ C = A_0 \\ D = A_1 F_z^2 + A_2 F_z \\ E = A_6 F_z^2 + A_7 \\ B = \frac{A_3 \sin(2 \arctan F_z / A_4) \times (1 - A_5 |\gamma|)}{C \times D} \\ S_v = A_{11} F_z \gamma + A_{12} F_z + A_{13} \\ S_h = A_9 F_z + A_{10} + A_8 \gamma \end{cases} \quad (2-3)$$

在纯侧偏工况下，对侧偏力与侧偏角关系进行仿真，如图 2-5 所示：




图 2-5 侧偏力和侧偏角关系图

由上图可知，侧偏角固定时，垂直荷载越大，侧偏力越大；当侧偏角在 $\pm 3^\circ$ 以内变化时，侧偏角与侧偏力近似线性关系。但超过这一范围，侧偏力变化趋于稳定，整体呈非线性关系。

由上述分析可以得知，在侧偏角和滑移率变化范围较小情况下，可以对结构复杂的非线性特性轮胎模型进行线性拟合，从而降低后续模型的复杂程度。

2.2.2 方程式赛车动力学建模

无人驾驶赛车是一个高速行驶状态下的复杂变参数非线性系统，为了提高自动驾驶轨迹跟踪控制精度，必须要建立适合的车辆动力学模型。一般来说，车辆

动力学模型中的相关参数越多，描述车辆行驶状态的精度就越高，但随着精度的上升带来的运算量也是逐渐增大的，从而导致模型求解困难、实时性差，反而会影响自动驾驶轨迹跟踪控制效果。所以为了使赛车能够快速、准确地跟踪路径，需要根据实际情况对动力学模型进行简化。

无人驾驶方程式赛道是一条平坦干燥的路面，悬架特性对赛车的影响较小，在此不做分析，本文对赛车进行动力学建模，只考虑平面运动，即横向、纵向和横摆运动，并针对实际道路情况做出以下假设：

- (1) 车轮受力均匀，无载荷偏移；
- (2) 忽略车辆空气动力学的影响；
- (3) 忽略悬架与车身之间的耦合；
- (4) 忽略轮胎回正力矩的影响。

在上述假设下，建立了车辆 3 自由度车辆动力学模型，如图 2-6 所示。




图 2-6 3 自由度车辆动力学模型

其中， $O-XY$ 为惯性坐标系， $o-xyz$ 是以车辆质心为坐标原点建立的车辆坐标系， x 轴正方向沿车辆前进方向， y 轴正方向为车辆前进方向的左侧， z 轴正方向垂直地面向上。 F_{xf} 、 F_{xr} 分别表示车辆前后轮所受的 x 轴方向的力； F_{yf} 、 F_{yr} 分别表示车辆前后轮所受的 y 轴方向的力； F_{lf} 、 F_{lr} 分别表示车辆前后轮所受的纵向力； F_{cf} 、 F_{cr} 分别表示车辆前后轮所受的侧向力； a 为车辆质心到前轴的距离， b 为车辆质心到后轴的距离； φ 表示车辆航向角； δ_f 表示前轮转角； α_f 表示前轮侧偏角； $\dot{x}$ 为赛车沿 x 轴方向的速度； $\dot{y}$ 为赛车沿 y 轴方向的速度； $\dot{\varphi}$ 为航向角速度。

所以根据牛顿力学可以得到 x 、 y 、 z 轴的平衡方程：

$$\begin{cases} m\ddot{x} = 2F_{xf} + 2F_{xr} + m\dot{y}\dot{\phi} \\ m\ddot{y} = 2F_{yf} + 2F_{yr} - m\dot{x}\dot{\phi} \\ I_z\ddot{\phi} = 2aF_{yf} - 2bF_{yr} \end{cases} \quad (2-4)$$

其中： $\ddot{x}$ 、 $\ddot{y}$ 为赛车沿 x 、 y 轴方向的加速度； m 表示赛车的整备质量； I_z 表示赛车绕 z 轴的转动惯量。

对轮胎在 x 方向和 y 方向上受力分析可得：

$$\begin{cases} F_{xf} = F_{lf} \cos \delta_f - F_{cf} \sin \delta_f \\ F_{yf} = F_{lf} \sin \delta_f + F_{cf} \cos \delta_f \\ F_{xr} = F_{lr} \\ F_{yr} = F_{cr} \end{cases} \quad (2-5)$$

将式 (2-5) 带入式 (2-4) 得：

$$\begin{cases} m\ddot{x} = 2(F_{lf} \cos \delta_f - F_{cf} \sin \delta_f) + 2F_{lr} + m\dot{y}\dot{\phi} \\ m\ddot{y} = 2(F_{lf} \sin \delta_f + F_{cf} \cos \delta_f) + 2F_{cr} - m\dot{x}\dot{\phi} \\ I_z\ddot{\phi} = 2a(F_{lf} \sin \delta_f + F_{cf} \cos \delta_f) - 2bF_{cr} \end{cases} \quad (2-6)$$

车辆轮胎的纵向力及侧向力与侧偏角 α 、滑移率 s 、路面摩擦因数 μ 、垂向载荷 F_z 有关，具体关系用以下函数来表示：

$$\begin{cases} F_l = f_l(\alpha, s, \mu, F_z) \\ F_c = f_c(\alpha, s, \mu, F_z) \end{cases} \quad (2-7)$$

其中，由几何关系可得轮胎的侧偏角 α 为：

$$\alpha = \tan^{-1} \frac{v_c}{v_l} \quad (2-8)$$

式 (2-8) 中，轮胎侧向、纵向的速度 v_c 和 v_l 可以通过车辆质心坐标系下的 v_x 和 v_y 表示：

$$\begin{cases} v_l = v_y \sin \delta_f + v_x \cos \delta_f \\ v_c = v_y \cos \delta_f - v_x \sin \delta_f \end{cases} \quad (2-9)$$

轮胎的滑移率 s 可以由公式 (2-10) 计算，式中 ω_l 表示车轮的转速， r 表示车轮半径。

$$s = \begin{cases} \frac{r\omega_l}{v} - 1 (v > r\omega_l, \omega_l \neq 0) \\ 1 - \frac{r\omega_l}{v} (v < r\omega_l, \omega_l \neq 0) \end{cases} \quad (2-10)$$

前后轮的侧向速度与纵向速度由如下公式计算：

$$\begin{cases} v_{yf} = \dot{y} + a\dot{\varphi} \\ v_{yr} = \dot{y} - b\dot{\varphi} \\ v_{xf} = \dot{x} \\ v_{xr} = \dot{x} \end{cases} \quad (2-11)$$

在预设条件下，车辆前轴和后轴上的负载可以通过以下公式表示：

$$\begin{cases} F_{zf} = \frac{bmg}{2(a+b)} \\ F_{zr} = \frac{amg}{2(a+b)} \end{cases} \quad (2-12)$$

通过上一节的建立轮胎模型仿真分析可知，轮胎的侧偏力及纵向力在一定范围内变化时为线性关系，所以侧偏力及纵向力可以用以下公式进行计算：

$$\begin{cases} F_l = C_l s \\ F_c = C_c s \end{cases} \quad (2-13)$$

式中， C_l 为轮胎纵向刚度， C_c 为轮胎侧向刚度。

综上，在小角度变化范围且轮胎模型线性化的条件下，车辆动力学模型如下：

$$\begin{cases} \dot{X} = \dot{x} \cos \varphi - \dot{y} \sin \varphi \\ \dot{Y} = \dot{x} \sin \varphi + \dot{y} \cos \varphi \\ m\ddot{x} = 2 \left[C_{lf} S_f - C_{cf} \left(\delta_f - \frac{\dot{y} + a\dot{\varphi}}{\dot{x}} \right) \delta_f + C_{lr} S_f \right] + m\dot{y}\dot{\varphi} \\ m\ddot{y} = 2 \left[C_{lf} S_f \delta_f - C_{cf} \left(\delta_f - \frac{\dot{y} + a\dot{\varphi}}{\dot{x}} \right) + C_{cr} \frac{b\dot{\varphi} - \dot{y}}{\dot{x}} \right] - m\dot{y}\dot{\varphi} \\ I_z \ddot{\varphi} = 2a \left[C_{lf} S_f \delta_f + C_{cf} \left(\delta_f - \frac{\dot{y} + a\dot{\varphi}}{\dot{x}} \right) \right] - 2bC_{cr} \frac{b\dot{\varphi} - \dot{y}}{\dot{x}} \end{cases} \quad (2-14)$$

式中，除了路面摩擦系数 μ 外，其他参数可以通过上述计算公式得到。当路面类型给定后，摩擦系数 μ 即可视为固定值，可以将系统描述为如下状态空间表达式：

$$\begin{cases} \dot{\xi}_{dyn} = f_{dyn}(\xi_{dyn}, u_{dyn}) \\ \eta_{dyn} = h_{dyn}(\xi_{dyn}) \end{cases} \quad (2-15)$$

该模型是针对无人方程式赛车所建立的，赛车采用前轮转向的方式，所以控制量选取为前轮转角 δ_f ，即 $u_{dyn} = \delta_f$ ，状态量选取为 $\xi_{dyn} = [\dot{x}, \dot{y}, \varphi, \dot{\varphi}, X, Y]^T$ ，输出为 $\eta_{dyn} = [\varphi, Y]^T$ 。此模型是 MPC 中预测模型的基础，后文将使用该模型建立系统状态空间方程并设计 MPC 控制器。

2.2.3 方程式赛车运动学建模

在上一节，本文针对方程式赛车实际情况搭建了三自由度车辆动力学模型，车辆动力学模型是依据经典力学建立的微分方程，在赛车高速运动时控制效果好。在路面情况良好的低速工况下，可以不考虑车辆控制的动力学问题，从数学几何的角度来研究车辆运动，这就是车辆运动学模型的原理，车辆运动学适合中低速的运动控制。

方程式赛车采用阿克曼转向机构，并且比赛的路况良好，可以适当简化运动控制模型，将赛车运动学模型简化为自行车模型，如图 2-7。




图 2-7 车辆运动学模型

其中， $O-XY$ 为惯性坐标系； L 为车辆轴距， R 为转向半径； φ 为航向角； δ_f 为前轮转向角； v_f 为前轮轴中心速度， v_r 为后轮轴中心速度； (x_r, y_r) 为后轴中心的坐标， (x_f, y_f) 为前轴中心的坐标。

根据运动学原理可以得知如下关系：

$$\begin{cases} v_r = \dot{x}_r \cos \varphi + \dot{y}_r \sin \varphi \\ \dot{x}_f \sin(\varphi + \delta_f) = \dot{y}_f \cos(\varphi + \delta_f) \\ \dot{x}_r \sin \varphi = \dot{y}_r \cos \varphi \end{cases} \quad (2-16)$$

整理得到纵向和侧向速度的公式如下：

$$\begin{cases} \dot{x}_r = v_r \cos \varphi \\ \dot{y}_r = v_r \sin \varphi \end{cases} \quad (2-17)$$

由图中几何关系可知：

$$\begin{cases} x_f = x_r + L \cos \varphi \\ y_f = y_r + L \sin \varphi \end{cases} \quad (2-18)$$

根据阿克曼转向原理，横摆角速度为：

$$\omega = \frac{v_r}{L} \tan \delta_f \quad (2-19)$$

所以综合上述公式，可以得到车辆运动学模型为：

$$\begin{bmatrix} \dot{x}_r \\ \dot{y}_r \\ \dot{\varphi} \end{bmatrix} = \begin{bmatrix} \cos \varphi \\ \sin \varphi \\ \tan \delta_f / L \end{bmatrix} v_r \quad (2-20)$$

2.3 无人驾驶方程式赛车控制软件架构

本文开发的无人驾驶系统主要包括环境感知、路径规划和轨迹跟踪控制三大部分，系统软件架构如图 2-8。




图 2-8 无人系统软件架构

（一）环境感知

环境感知部分主要由双目相机为主要传感器，双目相机将锥桶图像信息输入到改进 YOLOv4-tiny 深度学习网络，对目标锥桶的颜色进行精确识别的同时，

利用双目立体视觉测距功能输出锥桶距离位置信息。

（二）路径规划

在确定了图像中锥桶的位置信息以后，在路径规划模块按照任务类型拟合出车道中心线，结合组合导航的位姿信息，输出参考路径。

（三）跟踪控制

跟踪控制部分接收了规划出的参考轨迹，结合组合导航输出的定位、车身姿态信息来判断实际车辆位置与参考轨迹的偏差，通过跟踪算法控制车辆准确稳定地跟踪参考轨迹，最终实现精确的路径跟踪效果。同时，监控整车各部件的状态，并根据故障等级要求或接受到急停信号后启动紧急制动，使车辆进入绝对安全状态。

2.4 本章总结

本章首先阐述了所研究的无人驾驶方程式赛车硬件、软件架构，提出了以双目相机为主要环境感知传感器的自动驾驶方案。其次，建立了以“魔术公式”为基础的轮胎模型，并进行了仿真验证，仿真结果表明在小范围变化下，轮胎的力学特性满足线性关系。再次，在适当的简化条件下，搭建了三自由度动力学模型，在保证模型精度的同时，降低了复杂度。最后，进行车辆运动学分析，建立了赛车运动学模型，本章为后续章节轨迹跟踪控制奠定了基础。

第三章 基于双目立体视觉的锥桶识别

基于视觉的目标识别已经被应用到各种领域,本文采用双目相机对方程式赛车比赛的两侧锥桶进行识别。双目立体视觉与我们双眼成像原理相似,当我们看到目标物体时,我们不但可以分别目标的类别,还可以估计目标距离。双目相机正是基于仿生学原理设计的一种环境感知传感器,双目相机不仅可以采集前方环境图像,还能够根据双目立体视觉测距原理,利用两台摄像机视差图像来精确计算目标距离。

3.1 双目立体视觉测距原理

3.1.1 单目视觉与双目视觉对比

自动驾驶环境感知最为基本的任务就是要实现目标识别和测距两项任务,而以视觉为主传感器的感知方案分为单目视觉和双目视觉两种方案。

单目摄像头测距的技术路线是先通过图像识别对目标物进行准确的标注,再通过识别结果在图像中的尺寸去估算目标距离,对目标识别的精确度要求极高^[47]。并且需要建立一个目标样本特征的数据库,这个数据库需要足够庞大来包含大量的目标特征数据。如果没有待识别目标的特征数据,系统识别将不精确,导致无法准确估计这些目标的距离。而双目摄像头测距的方法是通过计算两幅图像的视差直接测量前方目标的距离,双目测距的精度会更高,并且不需要准备庞大的样本特征数据库。

本文采用双目相机作为自动驾驶主传感器,技术路线是首先通过特征提取和深度学习算法对锥桶进行识别,随后待确定了锥桶识别区域以后,利用双目图像中的视差直接计算距离。

3.1.2 相机成像坐标变换原理

当相机拍摄图像时,由小孔成像可知,物体反射的光线透过镜头聚焦在相机的感光元件上,从而将三维空间中的投影转换为二维图像。要实现从三维空间位置点转换为二维图像需要经历四个坐标系:世界坐标系、相机坐标系、图像坐标系、像素坐标系,如图 3-1 所示。




图 3-1 四大坐标系

其中， $O_w - X_w Y_w Z_w$ 坐标轴是世界坐标系； $O_c - X_c Y_c Z_c$ 坐标轴是相机坐标系，原点是相机光心； $O - xy$ 坐标轴是图像坐标系，图像中点为光心； uv 坐标轴是像素坐标系，图像左上角为原点； P 为世界坐标系中的一点，即真实世界中的一个点，坐标为 (X_w, Y_w, Z_w) ； p 为点 P 在图像中的成像点，在图像坐标系中的坐标为 (x, y) ，像素坐标系中为 (u, v) ； f 为相机焦距，等于 O_c 与 O 之间的距离。

四大坐标系的建立可以更加清晰的描述相机的二维图像和三维世界的位置关系，本文双目立体相机的世界坐标系原点在左相机中心位置。为了将世界坐标系下的真实物体在平面图像中表述出来通常需要进行如下的坐标变换：




图 3-2 坐标变换

(1) 世界坐标系—相机坐标系

从世界坐标系到相机坐标系只需要对两个坐标系进行旋转和平移。假如，坐标轴 $O - XYZ$ 绕 Z 轴旋转 θ 可得 $O - X'Y'Z'$ ，则坐标变换关系如下：

$$\begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta & 0 \\ \sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X' \\ Y' \\ Z' \end{bmatrix} = R_1 \begin{bmatrix} X' \\ Y' \\ Z' \end{bmatrix} \quad (3-1)$$

同理绕 Y 旋转 φ ，绕 X 轴旋转 ω 可得：

$$R_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \varphi & \sin \varphi \\ 0 & -\sin \varphi & \cos \varphi \end{bmatrix}, R_3 = \begin{bmatrix} \cos \omega & 0 & -\sin \omega \\ 0 & 1 & 0 \\ \sin \omega & 0 & \cos \omega \end{bmatrix} \quad (3-2)$$

所以可以得出, P 点在相机坐标系下的坐标:

$$\begin{bmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{bmatrix} = \begin{bmatrix} R & T \\ 0^T & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} \quad (3-3)$$

其中, $R=R_1R_2R_3$ 称为旋转矩阵, T 为平移向量。

(2) 相机坐标系—图像物理坐标系

从相机坐标系的三维图像到图像坐标系的二维图像, 可以由透视投影得到, 通过相似三角形可以得知:

$$\frac{X_c}{x} = \frac{Z_c}{f} = \frac{Y_c}{y} \quad (3-4)$$

所以可得:

$$Z_c \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} = \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{bmatrix} \quad (3-5)$$

(3) 图像物理坐标系—像素坐标系

图像坐标系和像素坐标系都在成像平面上, 像素坐标系原点在成像平面的左上角, 单位为 pixel; 图像坐标系原点在成像平面的中点, 单位为物理值毫米^[48]。转换关系如式 3-6, 其中坐标 (u_0, v_0) 为图像坐标系原点的像素坐标,

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} \frac{1}{dx} & 0 & u_0 \\ 0 & \frac{1}{dy} & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (3-6)$$

通过上述, 则可推导出从世界坐标系转换到像素坐标系下的公式:

$$Z_c \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} \frac{1}{dx} & 0 & u_0 \\ 0 & \frac{1}{dy} & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} R & T \\ 0^T & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} = \begin{bmatrix} f_x & 0 & 0 & 0 \\ 0 & f_y & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} R & T \\ 0^T & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} = M_1 M_2 \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} \quad (3-7)$$

其中, $M_1 M_2$ 是相机的内参和外参, 由相机生产厂商决定。通过以上坐标变换过程以后, 就可以将真实三维世界的物体转为像素坐标。

3.1.3 双目视觉测距原理

双目立体视觉主要利用两个处于同一水平方向的相机, 获取不同视角下的图像信息, 通过立体匹配算法来获得视差图, 从而得到图像的深度信息。




图 3-3 双目视觉测距原理

图 3-3 中为双目立体视觉测距原理图，图中左右相机光心处于同一水平线上。其中， P 为目标所在位置； Z 为相机到目标的距离； O_L 和 O_R 分别为左右相机的光心； B 为两个相机的光心距离； f 为相机焦距； P_L 和 P_R 为目标经光心投影到相机感光元件上的点； P_L' 和 P_R' 为空间障碍物到左右像平面的投影； P_L' 和 P_R' 的横坐标为 X_L 和 X_R 。

由图中相似关系可以得知：

$$\frac{B'}{Z'} = \frac{B}{Z} \quad (3-8)$$

因为 B' 和 Z' 可由 B 和 Z 换算得来，所以上式可改为：

$$\frac{B - P_L' - P_R'}{Z - f} = \frac{B}{Z} \quad (3-9)$$

$$\frac{B - (X_L - \frac{L}{2}) - (\frac{L}{2} - X_R)}{Z - f} = \frac{B}{Z} \quad (3-10)$$

所以：

$$Z = \frac{Bf}{X_L - X_R} = \frac{Bf}{disparity} \quad (3-11)$$

其中 $disparity = X_L - X_R$ ，称为视差，它描述了投影到双目相机左右图像平面上的空间点的位置差，在双目立体视觉中，视差可以通过立体匹配获得。 B 和 f 为双目相机的自身参数，可通过双目摄像头标定获得，所以目标点的深度距离也就可以得到了。

3.2 双目立体视觉平台搭建

3.2.1 软件开发平台

本文的双目立体视觉锥桶识别和测距的开发工作主要是在 Ubuntu 18.04 系统中进行，Ubuntu 系统是一款基于 Linux 内核的开源操作系统。

在 Ubuntu 操作系统下，本文选用了 ROS Melodic 作为中间件搭建整个自动驾驶环境。ROS 高度灵活的架构经常被用来编写机器人软件程序，它不仅包括常用功能包或库，还提供了常用函数的实现、进程间消息传递等功能，它是工具、库和约定的集合。ROS 为全球广大机器人研究者们提供了极大的帮助，降低了学习门槛，现如今对于自动驾驶的初期开发大都基于 ROS 架构。

开源的计算机视觉库 OpenCV 是在 IPL (image processing library) 基础上发展而来的，由数百个 C 函数和 C++类所组成图像处理算法库。在双目立体视觉识别测距系统的运行过程中，借助 OpenCV 中轻量高效的图像处理和机器视觉算法，对双目视觉生成的数据量大的图像数据进行处理。本文使用 C++编程语言对双目立体视觉进行开发。

3.2.2 硬件平台

双目立体视觉系统的图像数据信息丰富，要想实现对目标的识别测距功能需要一个强大的计算平台来处理大量数据。这就要求硬件计算平台不仅需要一个好的 CPU 来运算大量数据，还需要配备性能强大的 GPU 来进行加速处理双目图像数据。

本文选用的车载计算平台为米文动力的 Apex，APEX 是基于英伟达 Jetson AGX Xavier 开发的一款 ARM 架构的工控机。Apex 在满足抗震防水等工业级标准的同时，采用了英伟达自研的 Carmel 架构 8 核 64 位 CPU 和 Volta 架构 512 个 CUDA 核心数的 GPU，提供了高达 32Tops 计算能力。在具备强大性能的同时，其最大功耗仅有 30W，内置 Ubuntu 18.04 系统和深度学习环境，更利于方程式赛事自动驾驶算法开发。



图 3-4 米文 APEX

基于双目立体视觉的方程式赛车感知系统是通过双目摄像头采集双目图像传输到工控机中，由工控机完成识别和测距工作。方程式赛事比赛中要识别的锥桶体积较小，且赛道距离较近，因此要针对比赛工况选择合适的双目相机。本文选用的是图 3-4 的中科慧眼长江 3 号双目相机，具体参数如表 3-1。



图 3-4 长江 3 号双目相机

表 3-1 双目相机详细参数

详细参数	参数值
镜头焦距	4mm
测距范围	1.5m-40m
基线	12cm
分辨率	1280×720
俯仰角度	70°-90°
动态范围	120dB
整机功率	6W
图像帧率	12.5fps

3.3 基于深度学习的锥桶识别

3.3.1 YOLOv4-tiny 算法原理

基于深度学习的目标识别方法主要分为两类：第一类是基于候选区域的目标检测方法，如 R-CNN^[49]、Fast R-CNN^[50]、Faster R-CNN^[51]；第二类是基于回归的目标检测方法，如 YOLO^{[52]-[55]}、SSD^[56]、RetinaNet^[57]、EfficientDet^[58]。基于候选区域的目标检测算法精度高，但是计算量大，运算处理耗时高，导致识别速度较慢，目标识别的实时性难以保证。而方程式赛车比赛车速较高，对锥桶识别的实时性要求较高，基于回归的目标检测算法可以直接对图像中的目标进行识别，输出位置信息，识别精度较高，速度快，更适用于方程式赛车比赛要求。

YOLOv4-tiny 是在 YOLOv4 的基础上进行精简的，属于轻量化模型，网络

结构占用内存不到 YOLOv4 的 10%，具有更快的目标识别速度^[59]。YOLOv4-tiny 相比于 YOLOv4 省略了路径增强网络（PAN）和空间金字塔池化（SPP）；采用 CSPDarknet53-tiny 代替 CSPDarknet53 主干网络；使用 LeakyRelu 激活函数代替 Mish 激活函数，大大降低了网络结构的复杂度；并且使用特征金字塔（FPN）提取了相邻尺度的特征图并进行融合，提升了运行速度。YOLOv4-tiny 网络结构图如图 3-5。




图 3-5 YOLOv4-tiny 网络结构

由上图可以看出，Yolov4-tiny 主要由 CBL（Conv&BN&LeakyRelu）和 CSP（Cross-Stage-Partial）两个小组件组成。CBL 结构由卷积层（Conv）、批量标准化层（BN）和 LeakyRelu 激活函数组成，通过最大池化完成下采样。CSP 结构在残差块的叠加通道旁边为输入特征添加另一个残差边缘通道，输出两个通道的特征拼接后的结果。为了提高特征提取能力，FPN 部分将 13×13 的特征层进行上采样后与 26×26 的特征层进行融合，最后网络会生成 $13 \times 13 \times n \times (5 + N)$ 与 $26 \times 26 \times n \times (5 + N)$ 两个预测尺度来预测不同大小的目标。其中 n 代表锚框数量，Yolov4-tiny 中锚框数量为 3， N 为识别的种类数。YOLOv4-tiny 的实时识别速度非常优秀，但简化后的网络特征融合不足，只包含 13×13 和 26×26 个预测尺度，对于方程式比赛中小目标锥桶的位置信息提取具有一定的局限性。

3.3.2 YOLOV4-tiny 网络结构改进

为了使 YOLOV4-tiny 网络更精准的识别锥桶，本文基于 YOLOv4-tiny 原有框架增加了 52×52 的预测尺度，使得图像被分割的更小，有利于提高小尺寸目

标识别的精度。具体来讲，从原 YOLOV4-tiny 的主干网络 CSPDarknet53-tiny 中引出包含丰富语义信息的第二次 CSP 的输出层，将其与 FPN 颈部网络中经过 CBL 和上采样的输出层进行特征融合，再经 CBL 模块，最终得到相对输入图像 8 倍下采样的特征图。在改进的 YOLOV4-tiny 网络结构中，增加了 52×52 比例的预测尺度，有助于提高小尺寸目标识别的精度。改进后的网络结构如图 3-6。




图 3-6 改进 YOLOv4-tiny 网络结构

除了对原有 YOLOv4-tiny 网络进行改进，本文还针对锥桶数据集改进目标识别网络中锚框的尺寸。原始 YOLOV4-tiny 算法中，锚框尺寸是由包含 80 种目标识别种类的 COCO 数据集训练聚类得到的，识别种类多、物体形状大小各异，从而聚类出来的锚框形状不一。而本文研究目标识别网络主要是用来识别红、黄、蓝三类锥桶的，锥桶数据集锚框多数形状是长方形的，为了使改进的 YOLOV4-tiny 算法能够更加快速精确地识别出锥桶目标位置，本文利用 K-means++ 聚类算法对锥桶数据集重新聚类，从而确定出更适合锥桶识别的锚框尺寸。K-means++ 聚类算法是一种改进 K-means 的聚类算法，K-means++ 聚类算法首先会从数据集中随机选择一个样本作为初始聚类中心，通过计算每个样本到聚类中心的欧式距离来计算被选为下一个聚类中心的概率，距离当前聚类中心越远的点成为下一个聚类中心的可能性就越大，重复计算并更新聚类中心，直到聚类中心不变，得到最终的聚类结果。对锥桶数据集重新进行聚类，生成 9 个先验框为 (3, 35)、(5, 36)、(7, 40)、(5, 63)、(10, 44)、(9, 65)、(9, 114)、(14, 74)、(20, 113)。

3.3.3 锥桶识别结果与分析

为了验证改进后的 YOLOv4-tiny 算法识别性能, 本文的训练和测试在一台配置为 i9-9900K、Tesla T4 显卡、64G 运行内存的工控机上进行, 操作系统为 Ubuntu 18.04, 安装有 CUDA 10.2 版本的并行计算机框架和 cuDNN 8.0.4 版本的深度学习加速库。

在模型训练时, 输入图像尺寸设置为 416×416 , 批量大小 (batch) 设置为 64, 小批量 (subdivisions) 设置为 8, 选择自适应矩阵估计算法 (Adam) 作为模型的优化器, 初始学习率为 0.0001, 权重衰减值为 0.0005, 训练最大迭代数设置为 4000, 权重模型每 1000 次迭代保存一次。本文用于训练和测试的锥桶数据集来自于双目相机拍摄的图片, 并使用图 3-7 的图片标注工具 (LabelImg) 对锥桶数据集进行标注, 共使用了 2043 张锥桶图片进行训练, 其中 1843 张作为训练集, 200 张作为测试集。




图 3-7 标注界面

图 3-8 是 YOLOv4-tiny 改进前后模型的训练损失曲线对比图, 从图中可以看出在训练的前 600 次迭代过程中, loss 曲线收敛速度快, 改进后的 YOLOv4-tiny 模型较原版模型收敛速度更快。随着迭代次数的不断增加, loss 曲线的变化逐渐平缓, 当迭代次数达到 1000 次左右时, 损失曲线达到稳定状态, 原版模型收敛时损失在 1.6 左右, 改进后的 YOLOv4-tiny 模型收敛时误差值在 0.006 左右, 低于未改进的, 证明改进后 YOLOv4-tiny 具有更好的学习能力。




图 3-8 损失曲线对比

本文采用每帧图片的检测时间作为模型识别速度的评判指标；用模型的权重文件大小来评判模型的参数量；以平均精准率（Average Precision, AP）、召回率（Recall, R）和正确率（Precision, P）来作为评判模型识别精度的指标，计算公式如下。

$$P = \frac{TP}{TP + FP} \times 100\% \quad (3-12)$$


$$R = \frac{TP}{TP + FN} \times 100\% \quad (3-13)$$

$$AP = \int_0^1 P(R) dR \times 100\% \quad (3-14)$$


式中，使用 TP 表示正确识别锥桶个数， FP 表示误识别为锥桶的个数， FN 表示漏识别锥桶个数。YOLOv4-tiny 模型和本文改进的 YOLOv4-tiny 模型对锥桶测试集的试验结果如表 3-2 所示。

表 3-2 模型对比结果

目标检测网络	正确率	召回率	平均精度	检测时间	模型大小
YOLOv4-tiny	92.56%	87.68%	92.85%	6.82ms/帧	23.50M
改进 YOLOv4-tiny	96.12%	94.76%	95.68%	7.53ms/帧	24.80M



(a) YOLOv4-tiny 识别效果图



(b) 改进 YOLOv4-tiny 识别效果图

图 3-9 实际效果图

从表 3-2 中可以看出,对于目标锥桶的识别,相较于原版 YOLOv4-tiny,改进后的 YOLOv4-tiny 网络对锥桶的识别正确率由 92.56%提升到了 96.12%,增长了 3.56%,说明改进后的网络改善了锥桶错误识别的概率;召回率由 87.68%提升到了 94.76%,提升了 7.08%,说明改进后的网络减少了锥桶漏检的概率;平均精度由 92.85%增加到 95.68%,提升了 2.83%,说明网络的整体识别精度更加优异。改进后的 YOLOv4-tiny 模型大小增加了 1.3MB,每一帧图像的检测时间增加了 0.71ms,所以改进后的 YOLOv4-tiny 模型在保持着较快的检测速度的同时提高了识别精度。从图 3-9 实际识别效果来看,改进后的 YOLOv4-tiny 模型可以检测出图像中原版 YOLOv4-tiny 未识别出的小目标,并且锚框的位置更加精准,表明改进后的 YOLOv4-tiny 模型识别锥桶的精度更高。

3.4 本章总结

本章为了提高对方程式比赛中小目标锥桶的识别效果，提出了一种改进 YOLOv4-tiny 网络模型，将原版 YOLOV4-tiny 的主干网络高卷积特征层与颈部网络特征层进行融合，从而增加了 52×52 预测尺度的输出，有助于提高小尺寸目标识别的精度。并且，使用 K-means++ 聚类方法确定出更适合长方形锥桶识别的锚框尺寸，让网络能够更加快速精确地识别出锥桶目标位置。通过将测试集在改进前后的网络上训练并进行识别测试，试验结果表明，改进后的 YOLOV4-tiny 模型正确率增长了 3.56%，召回率提升了 7.08%，平均精度提升了 2.83%，改进后的 YOLOv4-tiny 模型在保持着较快的检测速度的同时提高了识别精度。

第四章 路径规划与轨迹跟踪控制

无人车辆的路径规划与轨迹跟踪是自动驾驶的核心环节。路径规划问题就是通过感知周围环境信息，预先规划出一条安全可靠的行驶路径，无人驾驶车辆的路径规划需要具备快速性、合理性的要求。车辆在高速行驶状态下，周围环境条件在时刻变化，这就要求无人系统的规划控制速度要快，能够根据环境的变化实时做出相应的规划。并且在进行路径规划时需要考虑到车辆模型约束，保证规划的合理性。路径规划完成后，车辆需要精准的跟踪期望轨迹才能躲避周围障碍物完成自动驾驶任务，这就要求轨迹跟踪算法具备准确稳定的跟踪效果，尽可能的减小车辆实际行驶路径与目标路径之间的误差，并且保证行驶过程转向的平滑性，避免方向盘的突变。本章将对方程式赛车的路径规划与轨迹跟踪问题进行研究，路径规划与轨迹跟踪控制的技术路线如图 4-1。




图 4-1 技术路线图

4.1 赛车行驶路径规划

4.1.1 锥桶边界车道拟合

本文在第三章通过双目相机获取了锥桶识别结果和锥桶距离信息，从感知部分获得的锥桶信息实际上是多个离散空间坐标点，路径规划需要对感知结果进行分析，拟合出锥桶边界方程，进而得到车道中心线。那么车道线拟合就相当于对空间坐标点的拟合，常用的拟合方法有折线法和最小二乘法。

(1) 折线法

折线法是曲线拟合中最简单的方法，通过将相邻的离散点联立求解出多条线段的直线方程，将多条线段组合成曲线。折线法计算简单，但拟合出的曲线曲率变化较大，曲线不连续，不能用于车道线的拟合。

(2) 最小二乘法

最小二乘法最早由科学家勒让德提出,通过最小化离散点到曲线的误差平方和来求解离散点的最佳匹配函数。具体来讲,当我们在求解离散点的函数关系时,将这些离散点 $\{(x_i, y_i)\} (i=0,1,2,\dots,m)$ 绘制在平面直角坐标系下,如果点集分布近似直线,就可设函数为 $y=kx+b$, 其中 k 和 b 为待求系数。最小二乘法示意图如图 4-2 所示。




图 4-2 最小二乘法

最小二乘法求解 k 和 b 的方法是将实测值 Y_i 与计算值 Y_j 之差的平方和 $\sum (Y_i - Y_j)^2$ 作为优化数据,其值越小,直线拟合效果越好。

$$\varphi = \sum (Y_i - Y_j)^2 \quad (4-1)$$

$$\varphi = \sum (Y_i - kX_i - b)^2 \quad (4-2)$$

为了让 φ 最小,对 k 和 b 求偏导:

$$\sum X_i (kX_i + b - Y_i) = 0 \quad (4-3)$$

$$\sum (kX_i + b - Y_i) = 0 \quad (4-4)$$

所以联立可得 k 和 b 为:

$$\begin{cases} k = \frac{n \sum X_i Y_i - \sum X_i \sum Y_i}{n \sum X_i^2 - \sum X_i \sum X_i} \\ b = \frac{\sum Y_i}{n} - k \frac{\sum X_i}{n} \end{cases} \quad (4-5)$$

方程式赛事分为直线加速、八字环绕、高速循迹三个赛道,且锥桶间隔距离较远。在弯道时,最小二乘法拟合出的边界线可能会出现在锥桶范围外的情况,导致规划的路径不合理,所以本文选择在直线加速比赛采用最小二乘法拟合曲线,八字环绕和高速循迹比赛中选择折线法处理离散的锥桶,在计算出车道中心线后,再进行平滑处理。

4.1.2 期望路径规划





图 4-3 期望路径流程图

赛车行驶过程中，不能撞到赛道两侧锥桶，这就要求期望路径不应该出现与锥桶边界线相切的情况，期望路径输出流程图如图 4-3 所示。本文以赛道中心线为目标路径，按照边界线检测情况分为三种类型：识别到左右两条边界线，识别到一条边界线，没有识别到边界线，根据不同的情况，相应的处理方法也不同。通常在直线和弯曲程度小的弯道下，可以识别到左右两条边界线，此时可以通过对两侧的锥桶位置信息求平均值来计算赛道中心线，如图 4-4 所示。当车辆处于弯曲程度大的弯道时，可能无法同时识别到左右两条边界线，这时候需要根据识别的类型，在考虑车辆、赛道信息的前提下，向车辆左侧或者右侧计算赛道中心线。当识别不到边界线时，采取停车等待以确保行驶安全。



4.1.3 路径平滑处理

由于在弯道时，期望路径由折线法给出，斜率变化幅度较大，导致行驶轨迹不平滑，甚至有可能行驶偏离赛道。本文采用贝塞尔曲线的方法对路径进行平滑处理。贝塞尔曲线源于伯恩斯坦多项式，具有原理简单、连接点平滑、描述曲线特性能力强等优点，在工程中得到了广泛的应用^[60]。贝塞尔曲线是通过联立各控制点利用数学计算公式来生成一条平滑的曲线表达式。一条 n 次贝塞尔曲线表达式为：

$$P(u) = \sum_{i=0}^n P(i)B_{i,n}(u), u \in [0,1] \quad (4-6)$$

式中， $P(u)$ 为运动控制点； u 为独立变量； $P(i)$ 代表位置点； $P(0)$ 、 $P(1)$ 为起点和终点； $B_{i,n}(u)$ 代表 n 次伯恩斯坦多项式。当 $n=1$ 时，需选取两个位置点来确定一阶贝塞尔曲线；当 $n=2$ 时，需选取三个位置点来确定二阶贝塞尔曲线；当 $n \geq 3$ 时，需选取 $n+1$ 个位置点来确定高阶贝塞尔曲线。




图 4-5 二阶贝塞尔曲线

如图 4-5 所示，本文采用二阶贝塞尔曲线对路径进行平滑处理，依次选取三个离散点 P_0 、 P_1 、 P_2 ，在线段 P_0P_1 、 P_1P_2 上求点 M_1 、 M_2 ，使得 $P_0M_1/P_0P_1 = P_1M_2/P_1P_2$ ，并在线段 M_1M_2 上求点 N ，使得 $M_1N/M_1M_2 = P_0M_1/P_0P_1 = P_1M_2/P_1P_2$ ，那么 N 为所求贝塞尔曲线上的一个点，最后调整比例系数，求得到贝塞尔曲线上所有的点。期望路径经平滑处理之后的效果如图 4-6。



图 4-6 平滑处理后的期望路径

4.2 基于 MPC 横向控制器设计

4.2.1 MPC 算法原理

与基于运动学的 Pure pursuit、Stanley 轨迹跟踪算法不同，MPC 算法是基于车辆动力学模型的轨迹跟踪算法。对于在复杂的赛道中高速行驶的方程式赛车来说，要想实现安全可靠的轨迹跟踪控制，需要考虑各种动态约束，模型预测控制具有很强的预测系统和处理多目标约束的能力^[61]，模型预测控制原理如图 4-7 所示。




图 4-7 模型预测控制原理图

从图中可以看出，在构建好状态空间模型的情况下，以时刻 k 作为当前时刻，MPC 控制器会依据预测模型和当前值来预测未来一段时域内的输出，同时可以用来对系统的未来状态控制量进行预测。系统未来一段时域内的输出可通过式 (4-7) 计算：

$$\begin{cases} x(k+1) = f(x(k), u(k), x(0)) = x_0 \\ y(k) = h(x(k), u(k)) \end{cases} \quad (4-7)$$

其中 $x(k)$ 表示 k 时刻的系统状态； $u(k)$ 表示 k 时刻系统的控制输入； $y(k)$ 表示 k 时刻的系统输出。预测值可表示为：

$$\{y_{N_p}(k+1|k), y_{N_p}(k+2|k), \dots, y_{N_p}(k+N_p|k)\} \quad (4-8)$$

其中 N_p 称为预测时域；当前时刻 k 系统对 $k+i$ 时刻输出的预测为

$y_{N_p}(k+i|k)$ 。以 $x(k)$ 作为预测状态的起点， $y(k)$ 作为预测输出的起点，当得到输出 $y(k)$ 的预测值时，我们可以构造一个状态观测器来估计系统的状态 $x(k)$ 。模型预测的目的是使预测输出和期望输出之间的误差最小化，但要满足约束条件：

$$\begin{cases} u_{\min} \leq u(k+i) \leq u_{\max}, 0 \leq i \leq N_p \\ y_{\min} \leq y(k+i) \leq y_{\max}, 0 \leq i \leq N_p \end{cases} \quad (4-9)$$

在约束条件下，优化目标函数可以由下式定义：

$$G(y(k), u(k)) = \sum_{i=k+1}^{k+N_p} (r(i) - y_{N_p}(i/k))^2 \quad (4-10)$$

式中， $r(t)$ 表示 i 时刻对应的期望输出。MPC 控制器循环往复的对目标函数进行最优求解，将得到的 k 时刻最优控制输入 $u(k)$ 输入到控制模型，以此循环得到 k 时刻的输出。MPC 算法控制效果好、鲁棒性强，它能解决控制过程中时变性、耦合性和非线性等问题，能处理被控变量和控制变量的各种约束，更适用于高速无人方程式赛车比赛。

4.2.2 非线性系统线性化

在第二章中，建立了简化后的方程式赛车的三自由度模型，但该模型仍然是一个非线性模型，为了便于设计控制器，需要对非线性系统进行线性化处理，精确线性化和近似线性化是非线性系统的线性化的两种常用方法。精确线性化的精度较高，但对系统模型精确，计算量大，使用条件苛刻。而近似线性化是利用近似解的方式来实现非线性系统线性化，虽然精度相对不高，但是运算量小，本文选择近似线性化。

非线性系统状态和控制量满足以下公式：

$$\dot{\xi}_r = f(\xi_r, u_r) \quad (4-11)$$

将上式在点 (ξ_r, μ_r) 处进行泰勒展开，保留一阶项得：

$$\dot{\xi} = f(\xi_r, u_r) + \left. \frac{\partial f}{\partial \xi} \right|_{\substack{\xi=\xi_r \\ u=u_r}} (\xi - \xi_r) + \left. \frac{\partial f}{\partial u} \right|_{\substack{\xi=\xi_r \\ u=u_r}} (u - u_r) \quad (4-12)$$

也可写为：

$$\dot{\xi} = f(\xi_r, u_r) + J_f(\xi)(\xi - \xi_r) + J_f(u)(u - u_r) \quad (4-13)$$

式中， $J_f(\xi)$ 表示 f 对 ξ 的雅克比矩阵； $J_f(u)$ 表示 f 对 u 的雅克比矩阵。

式 (4-13) 与式 (4-11) 相减可得：

$$\dot{\xi} = \dot{\xi}_r + J_f(\xi)(\xi - \xi_r) + J_f(u)(u - u_r) \quad (4-14)$$

令 $\tilde{\xi} = \xi - \xi_r$, $\tilde{u} = u - u_r$, $A(t) = J_f(\xi)$, $B(t) = J_f(u)$, 上式可写为:

$$\dot{\tilde{\xi}} = A(t)\tilde{\xi} + B(t)\tilde{u} \quad (4-15)$$

这样就得到新的线性化状态方程, 由于 MPC 是基于离散模型设计, 需要对式 (4-15) 做离散化处理:

$$\begin{cases} A_{k,t} = I + TA(t) \\ B_{k,t} = TB(t) \end{cases} \quad (4-16)$$

结合式 (4-15) 与 (4-16) 可得:

$$\tilde{\xi}(k+1) = A_{k,t}\tilde{\xi}(k) + B_{k,t}\tilde{u}(k) \quad (4-17)$$

至此, 非线性系统的近似线性化完成, 式中 I 为单位矩阵, T 为采样周期。

4.2.3 线性时变预测模型设计

线性时变预测控制算法是应用最为广泛的一种 MPC 控制方法, 其计算较为简单, 实时性好, 所以本文采用线性时变预测模型。线性时变预测模型基于线性化模型, 主要经过预测模型、滚动优化以及反馈校正三个步骤。根据上一节推导的离散线性模型有:

$$x(k+1) = A_{k,t}x(k) + B_{k,t}\tilde{u}(k) \quad (4-18)$$

设定:

$$\xi(k|t) = \begin{bmatrix} x(k|t) \\ u(k-1|t) \end{bmatrix} \quad (4-19)$$

可得:

$$\begin{cases} \xi(k+1|t) = \tilde{A}_{k,t}\xi(k|t) + \tilde{B}_{k,t}\Delta u(k|t) \\ \eta(k|t) = \tilde{C}_{k,t}\xi(k|t) \end{cases} \quad (4-20)$$

其中 $\tilde{A}_{k,t} = \begin{bmatrix} A_{k,t} & B_{k,t} \\ 0_{m \times n} & I_m \end{bmatrix}$, $\tilde{B}_{k,t} = \begin{bmatrix} B_{k,t} \\ I_m \end{bmatrix}$, $\tilde{C}_{k,t} = [C_{k,t} \ 0]$, 为了便于计算, 进一

步简化, 做以下假设:

$$\begin{aligned} \tilde{A}_{k,t} &= \tilde{A}_t, k=1, \dots, t+N-1 \\ \tilde{B}_{k,t} &= \tilde{B}_t, k=1, \dots, t+N-1 \end{aligned} \quad (4-21)$$

若 N_p 表示系统的预测时域, N_c 表示控制时域, 那么预测时域内系统的状态量和系统的输出量如下:

$$\begin{cases} \xi(t+N_p|t) = \tilde{A}_t^{N_p} \xi(t|t) + \tilde{A}_t^{N_p-1} \tilde{B}_t \Delta u(t|t) + \dots + \tilde{A}_t^{N_p-N_c+1} \tilde{B}_t \Delta u(t+N_c|t) \\ \eta(t+N_p|t) = \tilde{C}_t \tilde{A}_t^{N_p} \xi(t|t) + \tilde{C}_t \tilde{A}_t^{N_p-1} \tilde{B}_t \Delta u(t|t) + \dots + \tilde{C}_t \tilde{A}_t^{N_p-N_c+1} \tilde{B}_t \Delta u(t+N_c|t) \end{cases} \quad (4-22)$$

系统未来时刻的输出矩阵形式为:

$$Y(t) = \Psi_t \xi(t|t) + \Theta_t \Delta U(t) \quad (4-23)$$

式中:

$$Y(t) = \begin{bmatrix} \eta(t+1|t) \\ \eta(t+2|t) \\ \dots \\ \eta(t+N_c|t) \\ \dots \\ \eta(t+N_p|t) \end{bmatrix} \quad \Psi_t = \begin{bmatrix} \tilde{C}_t \tilde{A}_t \\ \tilde{C}_t \tilde{A}_t^2 \\ \dots \\ \tilde{C}_t \tilde{A}_t^{N_c} \\ \dots \\ \tilde{C}_t \tilde{A}_t^{N_p} \end{bmatrix} \quad \Delta U(t) = \begin{bmatrix} \Delta u(t|t) \\ \Delta u(t+2|t) \\ \Delta u(t+3|t) \\ \dots \\ \Delta u(t+N_c-1|t) \\ \Delta u(t+N_c|t) \end{bmatrix}$$

$$\Theta_t = \begin{bmatrix} \tilde{C}_t \tilde{B}_t & 0 & 0 & 0 \\ \tilde{C}_t \tilde{A}_t \tilde{B}_t & \tilde{C}_t \tilde{B}_t & 0 & 0 \\ \dots & \dots & \ddots & \dots \\ \tilde{C}_t \tilde{A}_t^{N_c-1} \tilde{B}_t & \tilde{C}_t \tilde{A}_t^{N_c-2} \tilde{B}_t & \dots & \tilde{C}_t \tilde{B}_t \\ \tilde{C}_t \tilde{A}_t^{N_c} \tilde{B}_t & \tilde{C}_t \tilde{A}_t^{N_c-1} \tilde{B}_t & \dots & \tilde{C}_t \tilde{A}_t \tilde{B}_t \\ \vdots & \vdots & \ddots & \vdots \\ \tilde{C}_t \tilde{A}_t^{N_p-1} \tilde{B}_t & \tilde{C}_t \tilde{A}_t^{N_p-2} \tilde{B}_t & \dots & \tilde{C}_t \tilde{A}_t^{N_p-N_c+1} \tilde{B}_t \end{bmatrix}$$

从以上算式可以看出,在预测时域内,通过当前状态量与控制时域内输入增量可以预测出下一时刻状态量和输出量。

4.2.4 目标函数设计

通过上一节可知,当我们知道了预测时域内的控制增量和当前状态量,就可以求解出下一时刻的输出量,但预测方程中的控制增量是未知的,并且无法从传感器等设备中获取,这就需要设计合理的目标函数,来获得预测时域内的最优控制增量,从而实现快速又准确的轨迹跟踪。如下形式的目标函数:

$$J(\xi(t), u(t-1), \Delta U(t)) = \sum_{i=1}^{N_p} \|\eta(t+i|t) - \eta_{ref}(t+i|t)\|_Q^2 + \sum_{i=1}^{N_c-1} \|\Delta U(t+i|t)\|_R^2 \quad (4-24)$$

其中, Q 为轨迹跟踪精度权重矩阵, R 为轨迹跟踪稳定性权重矩阵; $\eta(t+i|t)$ 为系统实际输出量, $\eta_{ref}(t+i|t)$ 为系统参考输出量; N_p 为系统预测时域, N_c 为系统控制时域。基于目标函数的参数优化是为了让赛车能够更加稳定且快速的跟踪期望轨迹,但是在求解过程中也需要考虑像控制增量、控制量、输出量的约束。

$$\begin{cases} u_{\min}(t+k) \leq u(t+k) \leq u_{\max}(t+k) \\ \Delta u_{\min}(t+k) \leq \Delta u(t+k) \leq \Delta u_{\max}(t+k) \\ y_{\min}(t+k) \leq y(t+k) \leq y_{\max}(t+k) \end{cases} \quad k=0,1,\dots,N_e-1 \quad (4-25)$$

为了保证不断变化的模型优化求解过程中的连续性,使系统控制序列不断运行更新,可对目标函数增加松弛因子,以确保系统在控制时域中具有局部最优解,如下式:

$$J(\xi(t), u(t-1), \Delta U(t)) = \sum_{i=1}^{N_p} \|\eta(t+i|t) - \eta_{ref}(t+i|t)\|_Q^2 + \sum_{i=1}^{N_e-1} \|\Delta U(t+i|t)\|_R^2 + \rho \varepsilon^2 \quad (4-26)$$

式中, ρ 为权重因子, ε 为松弛因子。采用二次规划问题求解方式对目标函数进行求解,进一步通过矩阵运算可得:

$$J(\xi(t), u(t-1), \Delta U(t)) = [\Delta U(t)^T, \varepsilon]^T H_t [\Delta U(t)^T, \varepsilon] + G_t [\Delta U(t)^T, \varepsilon] + P_t \quad (4-27)$$

$$\text{其中, } H_t = \begin{bmatrix} \Theta_t^T Q \Theta_t + R & 0 \\ 0 & \rho \end{bmatrix}, \quad G_t = [2E(t)^T Q_e \Theta_t \quad 0], \quad P_t = E(t)^T Q_e E(t) \text{ 为常}$$

量。上述系统求解可以转化为求解下式的二次规划问题:

$$\begin{aligned} & \min_{\Delta U_t, \varepsilon} [\Delta U(t)^T, \varepsilon]^T H_t [\Delta U(t)^T, \varepsilon] + G_t [\Delta U(t)^T, \varepsilon] + P_t \\ & \text{s.t.} \begin{cases} \Delta U_{\min} \leq \Delta U(k) \leq \Delta U_{\max} \\ U_{\min} \leq u(t-1) + \sum_{i=1}^k \Delta U(i) \leq U_{\max} \\ Y_{\min} - \varepsilon \leq \Psi_t \xi(t|t) + \Theta_t \Delta U(t) \leq Y_{\max} + \varepsilon \\ \varepsilon > 0 \end{cases} \end{aligned} \quad (4-28)$$

通过对每个控制周期完成式(4-28)优化求解后,得到控制时域的控制输入增量序列:

$$\Delta U_t^* = [\Delta u_t^*, \Delta u_{t+1}^*, \dots, \Delta u_{t+N_e-1}^*]^T \quad (4-29)$$

此增量序列的第一位将作用于系统,用来下次预测输出:

$$u(t) = u(t-1) + \Delta u_t^* \quad (4-30)$$

系统按照上述执行到下一周期,在新的周期里,系统会根据当前状态信息重新预测下一周期的输出,并重新对目标函数进行优化求解。模型预测控制就是按照上述过程不断循环,最终实现对整个系统的控制。

4.2.5 车辆动力学约束

与车辆运动学模型相比,车辆动力学模型的优点之一是可以根据实际工作条

件为系统添加约束。如前一节所述，对于优化目标的求解过程是基于约束条件下的，在本研究中，控制量是前轮偏角，需要对前轮偏角进行约束。除此之外，由于方程式赛事对速度要求较高，要想在急加减速、大幅度转弯等特殊工况下维持良好的稳定性，还必须对赛车添加必要的动力学约束。本文针对方程式赛车比赛添加以下动力学约束：

(1) 轮胎侧偏角约束

根据第二章对轮胎特性的分析，当轮胎的侧偏角在一定范围内变化时，侧偏力与侧偏角可以线性化处理。但是当侧偏角超过这个范围后，侧偏力的变化放缓，那么轮胎所需的附着力将无法fe足，导致车辆侧滑。因此，需要约束轮胎的侧偏角 α 。由第二章轮胎特性仿真数据可以得知，轮胎侧偏角在 $\pm 3^\circ$ 范围之内变化时，侧偏力与侧偏角为线性关系，故而对轮胎侧偏角 α 做出如下约束：

$$-3^\circ \leq \alpha \leq 3^\circ$$

(2) 质心侧偏角约束

在高速行驶的方程式赛车比赛中，稳定性也是赛车控制中需要考虑的关键问题。影响赛车行驶稳定性一个重要因素便是质心侧偏角，当质心侧偏角超过一定变化范围时，轮胎模型将表现出非线性特性，对于高速行驶的赛车来说十分危险，因此有必要对质心侧偏角做一定约束。由于赛车是在附着系数良好的沥青路面上行驶，所以只要保持在合理范围即可。对质心侧偏角 β 的约束为：

$$-12^\circ < \beta < 12^\circ$$

(3) 车辆附着条件约束

方程式赛车的驱动力来自于地面对轮胎的反作用力。电机转动产生的扭矩通过齿轮结构作用到驱动轮，轮胎与地面摩擦力相互作用，由路面的摩擦力引起的驱动力反作用于赛车。所以，赛车驱动力与地面附着系数有着密不可分的关系，地面附着系数对于横纵向加速的约束为：

$$\sqrt{a_x^2 + a_y^2} \leq ug \quad (4-31)$$

当赛车沿纵向方向匀速行驶时，上式可以简化为：

$$|a_y| \leq ug \quad (4-32)$$

为了确保目标函数优化求解的成功，并且考虑赛车稳定性，将该约束条件设置为：

$$a_{y,\min} - \varepsilon \leq a_y \leq a_{y,\max} + \varepsilon \quad (4-33)$$

式中 $a_{y,\max}$ 、 $a_{y,\min}$ 为横向加速度的最小、最大约束。

(4) 转向控制量与控制增量约束

无人驾驶方程式比赛中转向大多由线控转向电机机构驱动，来实现前轮转向。所以需要考虑转向的极限位置和转向电机的响应效果。通过测量得知，我校方程式赛车左右旋转前轮的最大角度为 28° ，转向电机额定转速为 300r/min，所以将转向控制量与控制增量约束设为：

$$\begin{aligned} -30^\circ < \delta < 30^\circ \\ -5^\circ < \Delta\delta < 5^\circ \end{aligned}$$

至此，完成了 MPC 横向控制器的设计。

4.3 路径跟踪控制仿真结果

本文上一节完成了对 MPC 控制器设计，本节主要对 MPC 控制器下的横向控制效果进行仿真验证，并与 Pure Pursuit 算法与 Stanley 算法进行对比。

4.3.1 联合仿真平台介绍

本文基于 CarSim 与 Simulink 对轨迹跟踪横向控制进行仿真验证，CarSim 用来建立车辆模型，Simulink 用来生成期望路径及横向控制器的设计。CarSim 是一款专业的车辆系统仿真软件，尤其是在车辆动力学仿真方面。它可以对车辆系统进行动力学建模，对整车的尺寸参数、各子系统参数、性能参数等进行设置，并且可以对外部环境、行驶工况等进行模拟，从而输出车辆各种评价性能参数，绘制出各参数之间更为直观的关系图，对于控制系统的研究具有极大的帮助。CarSim 操作界面如图 4-8 所示。




图 4-8 CarSim 操作界面

4.3.2 仿真参数设置

方程式赛车与传统汽车不同，其质量轻、速度快，各性能参数不尽相同，所以本文并未选用 CarSim 中自带的车辆模型，而是依据我校无人驾驶方程式赛车 A15 赛车数据搭建的，整车基本参数如表 4-1 所示：

表 4-1 无人方程式赛车整车参数

参数名	参数值
外形尺寸	2240mm×1390mm×930mm
质量	265kg
车轮半径	0.22m
迎风面积	1.2m ²
升阻比	2.25494
风阻系数	0.75
传动效率	0.925
减速比	4.12
前后轮转向刚度	10000、16000N/rad
前后轮轴距	1.65m
质心到前轴距离	1.355m

仿真工况设置具体如下：车速设置为固定车速，根据仿真需要进行调节；制动方式设置为无制动，认为车辆行驶过程中不发生刹车；档位设置为闭环模式；路面选择摩擦系数为 1 的 1km² 的方形路面；仿真时间设置为 30s；仿真步长设置为 0.001。以上参数可随仿真情况、行驶条件的不同进行修改。

在确定了车辆模型和仿真工况后，就可以将 CarSim 与 Simulink 进行联合仿真。首先需要在 CarSim 和 Simulink 中设置好关联路径，其次要确定 CarSim 中车辆模型的输入与输出，本文输入为车轮角度，输出为横纵向速度、横纵向位置、偏航角和偏航率等，依据分析需求添加更改 CarSim 的输入和输出。最后通过 CarSim 将模型信息传入到 Simulink 仿真模型进行仿真验证。至此，仿真平台搭建完毕，具体模型如图 4-9。




图 4-9 仿真模型

4.3.3 仿真验证

为了验证 MPC 控制器轨迹跟踪效果，将本文提出的基于 MPC 控制器的跟踪算法与 Pure Pursuit、Stanley 跟踪算法分别进行 10km/h、40km/h、80km/h 的低速、中速、高速工况仿真对比，用于对比的跟踪算法通过经验调试参数以达到当前路径下最好跟踪效果，控制器调参过程在本文中不进行赘述。




图 4-10 10km/h 下仿真结果

从图 4-10 可以看出，在 10km/h 的低速工况下，三种轨迹跟踪算法都可以较好地跟踪期望路径，但 Pure Pursuit、Stanley 两种基于几何的控制算法，在横向、航向偏差明显大于基于动力学模型的 MPC 算法。




图 4-11 40km/h 下仿真结果

从图 4-11 可以看出，在 40km/h 的中速工况下，Pure Pursuit、Stanley 算法因运动模型失配开始出现无法较好地跟踪期望路径的现象，尤其是在拐弯处，最大横向误差超过 0.7m，最大航向偏差超过 1rad，而基于动力学的 MPC 控制器可以较好地跟随期望路径，并且误差变化相对平稳。




图 4-12 80km/h 下仿真结果

从图 4-12 可以看出，在 80km/h 的高速工况下，Pure Pursuit、Stanley 算法跟踪误差进一步加大，在拐弯处，最大横向误差甚至超过了 2m，最大航向偏差超过 1.5rad，并且变化相对剧烈，车辆稳定性差。而本文设计的 MPC 控制器还可以较好地跟随期望路径，并且横向误差变化稳定，波动较小，在高速工况下 MPC 控制算法依然适用。

4.4 本章总结

本章针对赛事工况进行了赛车路径规划与轨迹跟踪控制器设计。针对方程式赛事的锥桶道路，提出了以双目立体视觉为主要传感器的路径规划方案，利用双目相机识别到的锥桶信息，拟合出锥桶边界线，求解得到期望的车道中心线数据，对车道中心线进行二次贝塞尔曲线平滑处理。并且结合上文提到的车辆动力学模型设计了基于 MPC 的轨迹跟踪控制器，同时为了简化运算，制定了控制器的目

标函数，依据赛车实际状态添加了动力学约束，利用 CarSim 与 Simulink 进行了联合仿真，对比了三种控制器在不同速度下的跟踪效果，验证了本文设计的基于 MPC 控制器的轨迹跟踪算法的可行性。

第五章 实车试验结果与分析

实车试验的地点选择在北方工业大学内的封闭场地，考虑到无人驾驶方程式赛车行驶安全和场地限制问题，设计了操场赛道情景和八字环绕情景来验证轨迹跟踪控制算法，并设置实际车速低于仿真车速，实车试验如图所示。




图 5-1 试验场景图



图 5-2 主环视角

5.1 操场情景下的实车试验

为了验证本文轨迹跟踪算法的有效性，在学校操场搭建了一个室外试验环境。为了确保测试的安全，对操场进行了封闭，并配备了随车安全员以应对紧急情况，实际路段如图 5-3 所示。



图 5-3 操场情景实际路段

在操场赛道下，进行了 10km/h 与 30km/h 的试验，实车试验结果如图 5-4 和图 5-5 所示。




图 5-4 10km/h 实车试验结果

在 10km/h 的车速下分别对 Pure Pursuit、MPC 控制器进行实车对比试验。从图中可以看出, 10km/h 车速下, Pure Pursuit 算法的最大横向误差达到了 0.33m, MPC 控制算法的最大横向误差为 0.2m; 在航向偏差上, Pure Pursuit 算法的最大航向偏差达到 0.35rad, MPC 控制算法的最大航向偏差仅为 0.1rad。所以 10km/h 工况下本文设计的基于 MPC 控制器较 Pure Pursuit 算法轨迹跟踪精度更佳, 控制效果更稳定。




图 5-5 30km/h 实车试验结果

在 30km/h 的车速下分别对 Pure Pursuit、MPC 控制器进行实车对比试验。从图中可以看出，30km/h 车速下，Pure Pursuit 算法的最大横向误差达到了 0.9m，MPC 控制算法的最大横向误差仅为 0.3m；在航向偏差上，Pure Pursuit 算法的最大航向偏差达到 0.71rad，MPC 控制算法的最大航向偏差仅为 0.28rad。所以 30km/h 工况下 Pure Pursuit 算法轨迹跟踪精度已经不再适合于方程式赛车比赛的控制精度要求，控制效果差，而本文设计的 MPC 控制算法精度仍然良好，满足方程式赛车控制精度需求。

5.2 八字环绕情景下的实车试验

八字环绕是大学生无人驾驶方程式比赛中的一项赛事，八字环绕赛道的地图是确定的，本节试验所搭建的八字环绕情景与方程式赛事八字环绕标准赛道一致。八字环绕赛道由锥桶围成的两个同心圆组成，两个圆心之间距离为 18.25m。内圆直径为 15.25m，外圆直径为 21.25m，赛道内外圈之间是一个 3 米的赛道。赛车出入于两圆相切的 3m 宽赛道，八字环绕赛道示意图如图 5-6 所示。






图 5-6 八字环绕赛道

在八字环绕赛道，设置赛车运行最大车速为 15km/h，在进口和出口时设定速度较慢，试验结果如下图所示。



(a) 轨迹跟踪



(b) 局部放大图




图 5-7 八字环绕实车试验

图 5-7 为八字环绕实车试验结果，其中图 (a) 为轨迹跟踪对比图，可以看出基于 MPC 的跟踪算法可以更好的跟随八字环绕工况下的期望路径，没有出现偏离期望路径的情况。图 (b) 是赛车从入口进入环绕弯道时的轨迹放大图，从图中可以 MPC 的跟踪算法比 Pure Pursuit 算法的跟踪误差小。较小的横向误差可以控制赛车准确的行驶在锥桶车道内，赛车轨迹跟踪的最大横向误差可以由图 (c) 得知，基于 MPC 的跟踪算法最大横向偏差为 0.3m，而 Pure Pursuit 算法的最大横向偏差则达到了 0.57m，跟踪精度较差。由图 (d) 可以得知 MPC 的跟踪算法的航向误差较小，赛车行驶平稳。

综上，通过操场情景低速、中速实车试验和八字环绕实车试验，可证明本文设计的基于 MPC 的横向控制器轨迹跟踪效果出色且鲁棒性较好，能够按照给定期望路径行驶，满足方程式赛车比赛需求。

5.3 本章总结

本章通过试验验证了所设计的 MPC 横向控制器的有效性。以方程式赛车为基础试验平台，设计试验方案选择试验场地，通过操场情景下的低速、中速实车试验和八字环绕实车试验验证了横向控制算法的轨迹跟踪效果。试验结果表明，所设计的轨迹跟踪横向控制器能稳定地跟踪期望轨迹，且精确度较好，证明了控制器的可行性。

第六章 结论与展望

本文以北方工业大学无人驾驶方程式赛车为研究平台,对无人驾驶方程式赛车自动驾驶系统进行了研究。研究重点为基于双目立体视觉的目标识别、路径规划及对跟踪算法的研究,并进行了仿真和实车试验。本章对论文研究内容做主要工作总结及展望。

6.1 主要结论

本文的主要结论有:

(1) 针对大学生方程式赛事设计了以双目立体视觉为主传感器的自动驾驶赛车硬件架构和软件架构。建立了以“魔术公式”为基础的轮胎模型,并进行了仿真验证,仿真结果表明轮胎侧偏角在 $\pm 3^\circ$ 范围之内变化时,侧偏力与侧偏角呈线性关系,为接下来分析赛车动力学特性做铺垫。随后,搭建了三自由度车辆动力学模型,并且基于阿克曼转向建立了两自由度车辆运动学模型,为后续轨迹跟踪控制器设计奠定了基础。

(2) 为了提高锥桶的识别精度,本文提出了一种改进 YOLOv4-tiny 网络模型,此模型增加了 52×52 预测尺度的输出,并且使用 K-means++ 聚类方法确定出更适合锥桶数据集的锚框尺寸。通过将测试集在改进前后的网络上训练并进行识别测试,结果表明,改进后的 YOLOv4-tiny 模型正确率、召回率、平均精度均有提升,改进后的 YOLOv4-tiny 模型在保持着较快的检测速度的同时提高了识别精度。

(3) 针对方程式赛事的锥桶道路,利用双目相机识别到的锥桶信息,使用折线法拟合出锥桶边界线,根据边界情况确定车道中心线,计算出平滑处理后的期望路径。并且结合车辆动力学模型设计了基于 MPC 的轨迹跟踪控制器,对非线性车辆动力学模型线性化处理,利用离散线性化车辆模型得到预测模型,并依据赛车实际状态添加了轮胎侧偏角、质心侧偏角、车辆附着条件等动力学约束。最后利用 CarSim 与 Simulink 进行了联合仿真,验证了基于 MPC 控制器的轨迹跟踪算法的可行性。

(4) 通过实车试验验证了所设计的 MPC 横向控制器的有效性。以学校操场为试验场地,设计了操场和八字环绕两种工况,试验结果表明,方程式赛车能准确的完成轨迹跟踪, MPC 横向控制器满足方程式赛事需求。

6.2 研究展望

自动驾驶复杂程度极高，本文研究的自动驾驶赛车仅针对无人驾驶方程式比赛，虽然能在赛道中平稳运行，但仍然存在不足，未来可以对以下方面继续研究：

（1）本文在路径规划方面采用的是折线法输出车道中心线的方式，仅涉及到局部路径规划，没有考虑到全局路径规划问题，后续考虑利用视觉 SLAM 对全局路径进行规划，以获得更加精确的轨迹。

（2）本文在轨迹跟踪控制方面主要针对赛车横向控制进行研究，纵向控制采用 PID 控制器，横、纵向控制单独作用于赛车，但车辆的横向和纵向运动会相互影响，后续考虑将横向控制和纵向控制结合分析车辆运动控制。

（3）受限于试验场地，本文设计工况较为简单，无法达到自动驾驶车辆的行驶工况，后续考虑在复杂环境工况下进行试验验证。

（4）受限于激光雷达硬件设备的性能，本文并没有将双目视觉与激光雷达进行融合检测，后续将使用这两种传感器进行融合处理来实现更为准确的锥桶目标识别。

参考文献

- [1] 张庆彬. 我国新能源汽车技术与产业探究[J]. 决策探索(中), 2018(06): 94.
- [2] 国务院办公厅印发《新能源汽车产业发展规划(2021—2035 年)》[J]. 汽车零部件, 2020(12): 33.
- [3] 《中国公路学报》编辑部. 中国汽车工程学术研究综述·2017[J]. 中国公路学报, 2017, 30(06): 1-197.
- [4] 张宁. 造车新时代——我国 8 家企业抢占自动驾驶载货汽车高地[J]. 汽车工艺师, 2018(10): 32-37.
- [5] 叶纯青. 工信部公示中国自动驾驶分级标准[J]. 金融科技时代, 2020, 28(04): 95.
- [6] 彭育辉, 江铭, 马中原, 钟聪. 汽车自动驾驶关键技术研究进展[J]. 福州大学学报(自然科学版), 2021, 49(05): 691-703.
- [7] 王潞宇, 张平. 汽车自动驾驶关键技术分析[J]. 汽车实用技术, 2021, 46(23): 20-22+29.
- [8] 穆康乐. 无人驾驶汽车发展现状及未来展望[J]. 电子技术与软件工程, 2017(21): 112-114.
- [9] 张旭斌. 双电机独立驱动无人驾驶赛车轨迹跟踪控制研究[D]. 辽宁工业大学, 2020.
- [10] Thorpe C, Herbert M, Kanade T, et al. Toward autonomous driving: The CMU Navlab. II. Architecture and systems[J]. IEEE expert, 1991, 6(4): 44-52.
- [11] Gregor R, Lutzeler M, Pellkofer M, et al. EMS-Vision: A perceptual system for autonomous vehicles[J]. IEEE Transactions on Intelligent Transportation Systems, 2002, 3(1): 48-59.
- [12] Broggi A, Bertozzi M, Fascioli A. ARGO and the MilleMiglia in Automatico Tour[J]. IEEE Intelligent Systems and their Applications, 1999, 14(1): 55-64.
- [13] The 2005 DARPA grand challenge: the great robot race[M]. Springer, 2007.
- [14] The DARPA urban challenge: autonomous vehicles in city traffic[M]. springer, 2009.
- [15] Urmson C, Anhalt J, Bagnell D, et al. Autonomous driving in urban environments: Boss and the urban challenge[J]. Journal of Field Robotics, 2008, 25(8): 425-466.
- [16] Montemerlo M, Becker J, Bhat S, et al. Junior: The stanford entry in the urban

- challenge[J]. Journal of field Robotics, 2008, 25(9): 569-597.
- [17]Bacha A, Bauman C, Faruque R, et al. Odin: Team victortango's entry in the darpa urban challenge[J]. Journal of field Robotics, 2008, 25(8): 467-492.
- [18]陈慧岩, 熊光明, 龚建伟主编. 无人驾驶车辆理论与设计[M]. 北京: 北京理工大学出版社. 2018.
- [19]Kabzan J, Valls M I, Reijgwart V J F, et al. Amz driverless: The full autonomous racing system[J]. Journal of Field Robotics, 2020, 37(7): 1267-1294.
- [20]王金强, 黄航, 鄧朋, 申泽邦, 周庆国. 自动驾驶发展与关键技术综述[J]. 电子技术应用, 2019, 45(06): 28-36.
- [21]孙振平, 安向京, 贺汉根. CITAVT-IV——视觉导航的自主车[J]. 机器人, 2002(02): 115-121.
- [22]Yang F. Research on the course, form and strategy of autonomous driving competition[C]. Journal of Physics: Conference Series, 2021, 1948(1): 012093.
- [23]田晓生. 智能车局部路径规划及路径跟踪方法研究[D]. 北京工业大学, 2018.
- [24]史林波. 自动驾驶中路锥车道的识别方法及其路径规划研究[D]. 电子科技大学, 2020.
- [25]陈宇鹏. 基于深度学习的自动驾驶单目视觉目标识别技术研究[D]. 吉林大学, 2019.
- [26]Balcerek J, Luczak M, Pawlowski P, et al. Automatic recognition of image details using stereovision and 2D algorithms[C]. Signal Processing: Algorithms, Architectures, Arrangements, and Applications (SPA), IEEE, 2018: 268-273.
- [27]Ferencz A, Learned-Miller E G, Malik J. Learning to locate informative features for visual identification[J]. International Journal of Computer Vision, 2008, 77(1-3): 3-24.
- [28]Falcone P, Eric Tseng H, Borrelli F, et al. MPC-based yaw and lateral stabilisation via active front steering and braking[J]. Vehicle System Dynamics, 2008, 46(S1): 611-628.
- [29]周俊, 姬长英. 智能车辆横向控制研究[J]. 机器人, 2003(01): 26-30.
- [30]郭景华, 李克强, 罗禹贡. 智能车辆运动控制研究综述[J]. 汽车安全与节能学报, 2016, 7(02): 151-159.
- [31]Hessburg T, Peng H, Tomizuka M, et al. An experimental study on lateral control of a vehicle[C]. American Control Conference, IEEE, 1991: 3084-3089.
- [32]赵熙俊, 陈慧岩. 智能车辆路径跟踪横向控制方法的研究[J]. 汽车工程, 2011, 33(05): 382-387.

- [33]胡旋. 无人方程式赛车自动驾驶系统研究[D]. 北方工业大学, 2021.
- [34]Amidi O, Thorpe C E. Integrated mobile robot control[C]. Mobile Robots V. International Society for Optics and Photonics, 1991, 1388: 504-523.
- [35]Urmson C, Ragusa C, Ray D, et al. A robust approach to high - speed navigation for unrehearsed desert terrain[J]. Journal of Field Robotics, 2006, 23(8): 467-508.
- [36]Leonard J, How J, Teller S, et al. A perception - driven autonomous urban vehicle[J]. Journal of Field Robotics, 2008, 25(10): 727-774.
- [37]许耀华. 无人驾驶车辆的底层改造和车身控制算法研究[D]. 长安大学, 2018.
- [38]Thrun S, Montemerlo M, Dahlkamp H, et al. Stanley: The robot that won the DARPA Grand Challenge[J]. Journal of field Robotics, 2006, 23(9): 661-692.
- [39]王亚平. 无人驾驶汽车轨迹跟随控制研究[D]. 湖南大学, 2019.
- [40]Abbas M A, Eklund J M, Milman R. Real-time analysis for nonlinear model predictive control of autonomous vehicles[C]. IEEE Canadian Conference on Electrical and Computer Engineering (CCECE), IEEE, 2012: 1-4.
- [41]Falcone P, Borrelli F, Asgari J, et al. Predictive active steering control for autonomous vehicle systems[J]. IEEE Transactions on control systems technology, 2007, 15(3): 566-580.
- [42]Kim D, Kang J, Yi K. Control strategy for high-speed autonomous driving in structured road[C]. International IEEE Conference on Intelligent Transportation Systems (ITSC), IEEE, 2011: 186-191.
- [43]Kong J, Pfeiffer M, Schildbach G, et al. Kinematic and dynamic vehicle models for autonomous driving control design[C]. IEEE intelligent vehicles symposium (IV), IEEE, 2015: 1094-1099.
- [44]王银, 张灏琦, 孙前来, 李小松, 孙志毅. 基于自适应 MPC 算法的轨迹跟踪控制研究[J]. 计算机工程与应用, 2021, 57(14): 251-258.
- [45]Chen S, Xiong G, Chen H, et al. MPC-based path tracking with PID speed control for high-speed autonomous vehicles considering time-optimal travel[J]. Journal of Central South University, 2020, 27(12): 3702-3720.
- [46]李金畅. FSAC 赛车横向控制系统设计与研究[D]. 广东工业大学, 2019.
- [47]宋子豪. 基于双目立体视觉的汽车测距避障和目标识别研究[D]. 华中科技大学, 2019.
- [48]李雄飞. 动态环境下基于视觉的语义 SLAM 算法研究[D]. 燕山大学, 2021.
- [49]He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C]. Proceedings of the IEEE international conference on computer vision, 2017: 2961-2969.

- [50] Girshick R. Fast r-cnn[C]. Proceedings of the IEEE international conference on computer vision, 2015: 1440-1448.
- [51] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28.
- [52] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 779-788.
- [53] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 7263-7271.
- [54] Redmon J, Farhadi A. YOLOv3: An incremental improvement[J]. arXiv preprint arXiv:1804.02767, 2018.
- [55] Bochkovskiy A, Wang C Y, Liao H Y M. YOLOv4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.
- [56] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]. European conference on computer vision, Springer, Cham, 2016: 21-37.
- [57] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]. Proceedings of the IEEE international conference on computer vision, 2017: 2980-2988.
- [58] Tan M, Pang R, Le Q V. Efficientdet: Scalable and efficient object detection[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 10781-10790.
- [59] 王立舒, 秦铭霞, 雷洁雅, 王小飞, 谭克竹. 基于改进 YOLOv4-Tiny 的蓝莓成熟度识别方法[J]. 农业工程学报, 2021, 37(18): 170-178.
- [60] 徐梁, 高宏力, 宋兴国. 贝塞尔曲线融合 ACO 的移动机器人路径规划[J]. 机械设计与制造, 2020(01): 263-266.
- [61] 廖兴华. 基于 MPC 的 FSAC 赛车横向控制策略研究[D]. 西华大学, 2020.

在学期间的研究成果

一、发表论文

1.范晶晶, 关帅, 郭建英, 赵鹏媛. 地面无人平台系统方案之关键技术的应用探讨[J]. 车辆与动力技术, 2020(03): 58-64.

2.Shuai G, Wenlun M, Jingjing F, et al. Target Recognition and Range-measuring Method based on Binocular Stereo Vision[C]. International Conference on Vehicular Control and Intelligence (CVCI), IEEE, 2020: 623-626.

二、研究成果转化或应用情况

1.2020 年北方工业大学 NRT 车队无人驾驶方程式赛车 A05

2.2021 年北方工业大学 NRT 车队无人驾驶方程式赛车 A15

致 谢

时光如梭，研究生三年的学习生活就要结束了，回想起入学时候的场景仿佛就在昨日，当初那颗犹豫的心，现在已经有了肯定的答案。庆幸自己选择了北方工业大学，在北方工业大学求学的三年时光里收获颇多，感谢北方工业大学给我提供了一个教育资源优秀的学习平台。在研究生生涯即将结束之时，在本文的最后向三年来帮助我、指引我前进的人们表示最诚挚的谢意。

首先最要感谢我的研究生导师范晶晶老师，身为车辆行业的专家，范老师知识渊博，眼界宽广，工程实践能力强。在科研工作上，范老师认真负责，积极的帮助我参与科研项目，培养我的科研能力，多次带我参与实际工程项目，大大提高了我的工程能力水平。在开展课题研究期间，范老师给予我悉心的指导，为我指明研究方向，并且大力支持学校方程式赛车的发展，本文也是在范老师的指导下顺利完成。范老师一位和蔼可亲的人，不论在学习还是生活中遇到的困难都能帮我解决。在此，再次感谢范老师对我的培养，衷心地祝您身体健康，万事如意。

同时要感谢北京捷升通达信息技术有限公司和江苏英拓动力科技有限公司的领导和同事们，感谢公司给我提供了一个宝贵的实践平台。在实习过程中，与车辆行业各位同事们互相交流和学习，让我从对车辆知识一知半解的小白，快速成长到可以掌握工程应用实例，从整车控制到自动驾驶，让我对行业的认知从点到面逐步拓宽，感谢你们。

其次感谢师兄、师弟们三年来在科研和生活上对我的帮助。感谢一起生活三年的舍友们，是你们让我的研究生生涯更加精彩。感谢北方工业大学 NRT 车队的小伙伴们，虽然我们的资源有限，但是我从你们身上感受到了对赛车的热爱，感谢各位小伙伴帮我完成了本文的实车试验部分，愿 NRT 车队越来越好。

最后感谢父母对我的养育之恩，为我提供了一个优良的学习环境，在人生的选择路口，他们总能给予我足够的支持和理解，让我一步步的踏实前进。感谢我的女朋友，八年的陪伴是最长情的告白，愿有岁月可回首，且以深情共白头。