



机械硕士专业学位论文

施工道路路径智能采集规划系统的研究
Research on Intelligent Collection and
Planning System for Construction Road Paths

作 者：王临轩
导 师：李艾民 教授

中国矿业大学
二〇二四年五月

中图分类号 621

学校代码 10290

UDC TP24

密 级 公开

中国矿业大学

机械硕士专业学位论文

施工道路路径智能采集规划系统的研究
Research on Intelligent Collection and Planning
System for Construction Road Paths

作 者 王临轩

导 师 李艾民

申请学位 机械硕士专业学位

培养单位 机电工程学院

学科专业 机械工程

研究方向 工程机械智能化

答辩委员会主席 谢方伟

评 阅 人 盲评

二〇二四年五月

摘要

随着国家交通基础设施的快速发展,目前高速公路面临养护的工作量逐渐增大。为保证施工的高效性和安全性,沥青路面施工车辆智能驾驶是当下也是未来发展的方向。在施工车辆智能驾驶作业之前,需要对路面车道线信息进行坐标提取,并规划出路径,为车辆提供准确的路径信息。为此本文针对企业委托科研课题“施工道路车道线坐标信息的智能采集和轨迹规划”进行了深入研究,主要研究内容如下:

(1) 对采集规划系统的需求进行分析,根据需求,首先设计系统的整体框架;然后对传感器设备进行选型,并选择合适的软件平台;最后根据传感器的接线和布局要求,设计采集规划系统的实验平台。

(2) 针对施工道路车道线磨损、模糊和不连续等问题,采用一种基于锚点的深度学习车道线检测方式,并在自主建立的数据集上进行训练,检测效果上并未完全满足需求。为此,设计一种基于行分类与混合注意力机制的车道线检测算法,通过预定义行上的位置分类来判断正确的车道线位置,利用损失函数提高模型预测的准确性。最后对该算法进行训练实验,训练结果表明:精度 Accuracy 达到 96.79%,FPS 达到 310。

(3) 设计了基于 GNSS/视觉/惯性/轮式里程计的多传感器融合定位系统,提出一种基于视觉/惯性/轮式里程计(VIWO)紧耦合优化算法;采用静态初始化和动态初始化相结合的方法,建立准确的初始状态;为实现局部帧与 ENU 帧之间的转换,将局部状态信息与全球导航卫星系统(GNSS)测量信息进行融合;采用噪声重估计的方式保证惯性测量单元与轮速计的同步性。最后在公开数据集 Kaist 上,与典型 VIO 系统 VINS-Fusion 进行对比,结果表明:本文 VIWO 系统绝对轨迹和相对轨迹的误差均方根(RMSE)值分别为 0.503m 和 0.436m,均优于 VINS-Fusion。在自主采集的两段数据集上评估了 VIWO 与 GNSS 信息融合后定位效果,结果表明:实验路段 1 和 2 在融合 GNSS 信息后均方根误差为 0.113m 和 0.156m,误差显著降低。

(4) 综合车道线检测技术与多传感器融合定位技术,首先设计路径采集的总体方案,利用轨迹拟合和拟合轨迹重采样,规划出路径;然后分别在校园路段和施工路段进行实验,与人工采集真值对比;最后验证采集规划系统的性能。

综合来说,本文设计的路径智能采集规划系统,能提供精度较高的定位信息,对施工车辆智能驾驶的研究和发展有一定的实际意义。

该论文有图 77 幅,表 15 个,参考文献 92 篇。

关键词: 路径信息采集; 车道线检测; 多传感器定位; 轨迹规划; 施工道路

Abstract

With the rapid development of the national transportation infrastructure, the workload of highway maintenance is gradually increasing. In order to ensure the efficiency and safety of construction, intelligent driving of asphalt pavement construction vehicles is the direction of current and future development. Before the intelligent driving operation of construction vehicles, it is necessary to extract the coordinates of the road lane line information and plan the path to provide accurate path information for the vehicle. Therefore, this thesis conducts in-depth research on the scientific research project "intelligent collection and trajectory planning of construction road lane line coordinate information" commissioned by enterprises, and the main research contents are as follows:

(1) Analyze the requirements of the collection planning system. According to the requirements, the overall framework of the system is designed, and then the sensor devices are selected and the appropriate software platform is selected. Finally, according to the wiring and layout requirements of the sensor, an experimental platform for the acquisition planning system was designed.

(2) In order to solve the problems of wear, ambiguity and discontinuity of lane lines in construction roads, a deep learning lane line detection method based on anchor points was adopted. The training was carried out on the self-established dataset, and the detection effect did not fully meet the requirements. To solve this problem, a lane line detection algorithm based on row classification and mixed attention mechanism was designed. The correct lane line position is judged by the position classification on the predefined rows, and the loss function is used to improve the accuracy of the model prediction. Finally, the algorithm is trained in experiments, and the training results show that the accuracy reaches 96.79% and the FPS reaches 310.

(3) A multi-sensor fusion positioning system based on GNSS/vision/inertial/wheel odometer was designed, and a close coupling optimization algorithm based on vision/inertial/wheel odometer (VIWO) was proposed. A combination of static and dynamic initialization methods is used to establish an accurate initial state. In order to realize the conversion between local frames and ENU frames, the local state information is fused with the Global Navigation Satellite System (GNSS) measurement information. The noise re-estimation method is used to ensure the synchronization between the inertial measurement unit and the wheel speedometer. Finally, on the public

dataset Kaist, compared with the typical VIO system VINS-Fusion, the results show that the root mean square error (RMSE) values of the absolute and relative trajectories of the VIWO system in this thesis are 0.503m and 0.436m, respectively, which are better than VINS-Fusion. The results show that the root mean square errors of experimental sections 1 and 2 are 0.113m and 0.156m after fusing GNSS information, and the errors are significantly reduced.

(4) Based on the lane detection technology and multi-sensor fusion positioning technology, firstly, the overall scheme of path acquisition was designed, and the path was planned by using trajectory fitting and fitting trajectory resampling. Then, experiments were carried out on the campus section and the construction section respectively, and the true values were compared with the manual collection. Finally, the performance of the acquisition planning system is verified.

In general, the path intelligent acquisition and planning system designed in this thesis can provide positioning information with high accuracy. To a certain extent, it has promoted the development process of intelligent driving of construction vehicles.

There are 77 figures, 15 tables, and 92 references in this thesis.

Keywords: path information collection; lane detection; multi-sensor positioning; trajectory planning; construction road

目 录

1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	3
1.3 存在问题.....	9
1.4 论文主要研究内容.....	10
1.5 本章小节.....	11
2 路径采集规划系统的需求与相关软硬件	13
2.1 系统概述.....	13
2.2 硬件选型与结构设计.....	14
2.3 软件平台.....	18
2.4 路径采集设备设计.....	20
2.5 本章小节.....	20
3 基于深度学习车道线检测的研究	21
3.1 引言.....	21
3.2 基于锚点的车道线检测算法的研究	22
3.3 数据集建立.....	27
3.4 基于行分类与混合注意力机制的车道线检测算法的研究	30
3.5 实验结果与分析.....	36
3.6 本章小节.....	38
4 多传感器融合定位技术的研究	39
4.1 坐标系.....	39
4.2 姿态参数化.....	40
4.3 定位坐标转换.....	44
4.4 相机模型.....	46
4.5 IMU 模型.....	49
4.6 基于视觉/惯性/轮式里程计与 GNSS 融合定位系统.....	51
4.7 实验结果与分析.....	57
4.8 本章小结.....	64
5 路径智能采集规划及道路实验	65
5.1 路径智能采集.....	65
5.2 道路路径规划.....	67
5.3 智能采集规划系统道路实验	69
5.4 本章小结.....	74
6 结论与展望.....	75

6.1 主要结论.....	75
6.2 工作展望.....	76
参考文献.....	77

图清单

图序号	图名称	页码
图 1-1	近 6 年全国公路总里程数及公路密度	1
Figure 1-1	The total mileage and density of highways in China in the past six years	1
图 1-2	道路路径智能化施工	2
Figure 1-2	Intelligent construction of road paths	2
图 1-3	露天煤矿卡车智能驾驶施工流程	3
Figure 1-3	Construction process of intelligent driving of trucks in open-pit coal mines	3
图 1-4	推土机智能驾驶施工系统	4
Figure 1-4	Intelligent driving construction system of bulldozer	4
图 1-5	徐工挖掘机无人化施工现场	4
Figure 1-5	XCMG excavator intelligent construction site	4
图 1-6	无人驾驶农机	5
Figure 1-6	Unmanned agricultural machinery	5
图 1-7	无人震源车结构	5
Figure 1-7	Structure of an unmanned vibrator vehicle	5
图 1-8	多源信息融合框图	6
Figure 1-8	Block diagram of multi-source information fusion	6
图 1-9	传感器信息采集设备	7
Figure 1-9	Sensor information acquisition equipment	7
图 1-10	视觉惯性融合定位框架	7
Figure 1-10	Visual inertial fusion positioning framework	7
图 2-1	施工道路路径智能采集规划系统的总体结构	14
Figure 2-1	The overall structure of the intelligent collection and planning system for construction road paths	14
图 2-2	具体结构框架	14
Figure 2-2	Concrete structural framework	14
图 2-3	RTK 定位设备	16
Figure 2-3	RTK positioning device	16
图 2-4	IMU 模块	16
Figure 2-4	IMU module	16
图 2-5	工控机与显示屏组合连接方式	17
Figure 2-5	The combination of industrial computer and display screen connection mode	17
图 2-6	深度相机	17
Figure 2-6	Depth camera	17
图 2-7	轮速计	18
Figure 2-7	Wheel speedometer	18
图 2-8	软件平台结构框架	19

Figure 2-8	Architecture of the software platform	19
图 2-9	ROS 系统通信机制	19
Figure 2-9	Communication mechanism of the ROS system	19
图 2-10	ROS 开发平台	20
Figure 2-10	ROS development platform	20
图 2-11	路径智能采集规划系统实验平台三维图	20
Figure 2-11	Three-dimensional diagram of the experimental platform of the path intelligent acquisition and planning system	20
图 3-1	基于锚点的算法框架	23
Figure 3-1	Anchor-based algorithm framework	23
图 3-2	ResNet 的残差结构模型	23
Figure 3-2	Residual structure model of ResNet	23
图 3-3	残差学习模块	24
Figure 3-3	Residual learning module	24
图 3-4	Resnet-18 模型结构	25
Figure 3-4	Structure of the Resnet-18 model	25
图 3-5	锚线检测示意图	25
Figure 3-5	Schematic diagram of anchor line detection	25
图 3-6	厂区附近车道线图像	28
Figure 3-6	Image of lane markings near the plant	28
图 3-7	校园路段车道线图像	28
Figure 3-7	Image of lane markings for campus road sections	28
图 3-8	施工路段车道线图像	28
Figure 3-8	Image of lane markings for campus road sections	28
图 3-9	图像标注界面	29
Figure 3-9	Image annotation page	29
图 3-10	Label 文件	29
Figure 3-10	Label file	29
图 3-11	基于锚点的算法训练可视化结果	30
Figure 3-11	Anchor-based algorithm training visualization results	30
图 3-12	基于行分类方式示意图	31
Figure 3-12	Schematic diagram based on the row classification method	31
图 3-13	算法网络结构	32
Figure 3-13	Algorithm network structure	32
图 3-14	混合注意力模块	32
Figure 3-14	Convolutional block attention module	32
图 3-15	通道注意力模块	33
Figure 3-15	Channel attention module	33
图 3-16	Sigmoid 函数	34
Figure 3-16	Sigmoid function	34
图 3-17	空间注意力机制模块	34

Figure 3-17	Spatial attention mechanism module	34
图 3-18	厂区路段检测效果	37
Figure 3-18	Detection effect of the factory section	37
图 3-19	学校路段检测效果	38
Figure 3-19	Detection effect of school road sections	38
图 3-20	施工路段检测效果	38
Figure 3-20	Detection effect of construction section	38
图 4-1	传感器坐标系示意图	40
Figure 4-1	Schematic diagram of the sensor coordinate system	40
图 4-2	坐标变换	41
Figure 4-2	Coordinate transformation	41
图 4-3	ECEF 坐标系与 ENU 坐标系示意图	45
Figure 4-3	ECEF coordinate system and ENU coordinate system	45
图 4-4	像平面与地平面之间的变换示意图	47
Figure 4-4	Schematic diagram of the transformation between the image plane and the ground plane	47
图 4-5	正常图像与两种畸变图像	48
Figure 4-5	Normal image and two distorted images	48
图 4-6	标定板	49
Figure 4-6	Calibration plate	49
图 4-7	相机与 IMU 采样频率示意图	50
Figure 4-7	Sampling frequency of the camera and IMU	50
图 4-8	多传感器融合定位系统整体框架	52
Figure 4-8	The overall framework of the multi-sensor fusion positioning system	52
图 4-9	初始化流程图	53
Figure 4-9	Initialization flowchart	53
图 4-10	IMU 跳跃过程	54
Figure 4-10	IMU hopping process	54
图 4-11	全局因子图	56
Figure 4-11	Global factor chart	56
图 4-12	Kaist 数据集采集平台及序列可视化界面	58
Figure 4-12	Kaist dataset acquisition platform and sequence visualization interface	58
图 4-13	实验路段 1 示例图像及地图轨迹	58
Figure 4-13	Example image and map trajectory of experimental section 1	58
图 4-14	实验路段 2 示例图像及地图轨迹	59
Figure 4-14	Example image and map trajectory of experimental section 2	59
图 4-15	Kaist 数据集 22 序列上的轨迹对比结果	60
Figure 4-15	Processing results on 22 sequences of the Kaist dataset	60
图 4-16	Kaist 数据集 22 序列上 VIWO 系统预估轨迹误差结果	60
Figure 4-16	The error result of the estimated trajectory of the VIWO system on the sequence 22 of the Kaist dataset	60

图 4-17	实验路段 1 的直道与弯道轨迹	61
Figure 4-17	Straight and curve tracks in experimental section 1	61
图 4-18	直线路段和弯道路段下相机与 IMU 之间角度误差	62
Figure 4-18	Angle error between the camera and the IMU in straight and curved road sections	62
图 4-19	实验路段 1 和 2 的平面轨迹对比结果	62
Figure 4-19	Comparison results of planar trajectories of experimental sections 1 and 2	62
图 4-20	实验路段 1 和 2 的实验结果	63
Figure 4-20	Experimental results of sections 1 and 2	63
图 5-1	路径采集流程	65
Figure 5-1	Path collection process	65
图 5-2	RTK 软件界面	66
Figure 5-2	RTK software interface	66
图 5-3	系统工作界面	66
Figure 5-3	The working interface of the system	66
图 5-4	Rosbag 中车道线检测效果可视化界面	66
Figure 5-4	Visualization of lane line detection effect in Rosbag	66
图 5-5	采集数据文件的存储	67
Figure 5-5	Storage of acquisition data files	67
图 5-6	初采样点与重采样点示意图	69
Figure 5-6	Initial sampling point and resampling point	69
图 5-7	路径信息采集平台	69
Figure 5-7	Path information collection platform	69
图 5-8	往返直线路段示例图像及地图轨迹	70
Figure 5-8	Example image and map trail of a round-trip straight section	70
图 5-9	施工路段示例图像及地图轨迹	70
Figure 5-9	Example image and map trajectory of the construction section	70
图 5-10	往返直线路段车道线检测效果	71
Figure 5-10	Detection effect of lane lines in round-trip straight sections	71
图 5-11	往返直线路段规划轨迹与参考轨迹	71
Figure 5-11	Round-trip straight road section planning trajectory and reference trajectory	71
图 5-12	往返直线路段数据序列上定位误差	72
Figure 5-12	Positioning error on the data series of round-trip straight segments	72
图 5-13	施工道路场景	72
Figure 5-13	Construction road scene	72
图 5-14	施工路段路径信息采集可视化界面	73
Figure 5-14	Visualization interface for road information collection in construction sections	73
图 5-15	施工路段规划轨迹与参考轨迹	73
Figure 5-15	Planning trajectory and reference trajectory of construction section	73

图 5-16	施工路段数据序列上定位误差	74
Figure 5-16	Positioning error on the data series of the construction road section	74

表清单

表序号	表名称	页码
表 2-1	相关硬件型号	15
Table 2-1	Relevant hardware model	15
表 2-2	IMU 数据性能	16
Table 2-2	IMU data performance	16
表 2-3	工控机与显示屏组合设备参数	17
Table 2-3	Parameters of the combination of industrial computer and display screen	17
表 2-4	深度相机具体参数	18
Table 2-4	Parameters of the depth camera	18
表 2-5	轮速计具体参数	18
Table 2-5	Wheel speedometer specific parameters	18
表 3-1	训练实验的机器配置	37
Table 3-1	Machine configuration for the training experiment	37
表 3-2	训练结果各项参数	37
Table 3-2	Parameters of the training results	37
表 4-1	IMU 标定结果	50
Table 4-1	IMU calibration results	50
表 4-2	实验路段 1 和 2 采集时长与总里程数	59
Table 4-2	Duration and total mileage of experimental sections 1 and 2	59
表 4-3	两种算法绝对轨迹误差与相对轨迹误差的评价指标	60
Table 4-3	The evaluation indexes of absolute trajectory error and relative trajectory error of the two algorithms (m)	60
表 4-4	直道与弯道情况下相机与 IMU 相对旋转角度误差	61
Table 4-4	Relative rotation angle error between the camera and the IMU in straight and curved tracks	61
表 4-5	VIWO 系统与融合 GNSS 后的绝对轨迹均方根误差	63
Table 4-5	Root mean square error of absolute trajectories after VIWO system and fused GNSS	63
表 5-1	往返直线路段和施工路段的采集时长与总里程数	70
Table 5-1	The collection time and total mileage of the round-trip straight section and the construction section	70
表 5-2	往返直线路段定位位置误差 (m)	72
Table 5-2	Error in the positioning position of the round-trip straight segment	72
表 5-3	施工路段定位位置误差 (m)	74
Table 5-3	Positioning position error of construction road section	74

变量注释表

I	图像尺寸
F_{out}	主干网络输出的特征映射
x_j	锚线与车道线特征的交点 x 轴的坐标
y_j	锚线与车道线特征的交点 y 轴的坐标
θ	锚线与原点所在边界在右侧的夹角
$a_{loc,i}$	每条锚线产生的局部特征向量
$w_{i,j}$	权重矩阵
$a_{glob,i}$	全局特征向量
$X_{i,j}$	特征图 X 第 i 行、 j 列像素值
$w_{1,i}$	全局平局池化卷积结果
$w_{2,i}$	全局最大池化卷积结果
$\omega_{avg,i}$	第 i 个通道权重
P_m	第 m 行车道线网格选取的预测值
L_{cls}	基于分类的损失
L_{CE}	交叉熵损失
$T_{cls,m}$	第 m 行定位分支学习目标
$Prob_m$	每个位置存在车道线的概率
$T_{ext,m}$	第 m 行存在分支的学习目标
L_{exp}	期望损失
L_{ext}	存在分支损失
γ_i^w	WGS84 坐标系经度
ϕ_i^w	WGS84 坐标系纬度
h_i^w	WGS84 坐标系高度
x_i^w	地心地固坐标系 X 轴坐标
y_i^w	地心地固坐标系 Y 轴坐标
z_i^w	地心地固坐标系 Z 轴坐标
x_k^E	东北天坐标系 X 轴坐标
y_k^E	东北天坐标系 Y 轴坐标
z_k^E	东北天坐标系 Z 轴坐标
x_c	相机坐标系 X 轴坐标
y_c	相机坐标系 Y 轴坐标
z_c	相机坐标系 Z 轴坐标
u_i	图像坐标系 u 轴坐标
v_i	图像坐标系 v 轴坐标
x'	径向畸变后图像坐标系 x 轴坐标点
y'	径向畸变后图像坐标系 y 轴坐标点
p_n	径向畸变参数
k_n	径向畸变系数
ω_t	世界坐标系下 IMU 的角加速度

$\mathbf{b}_{a_t}^w$	加速度计随机漂移
$\mathbf{b}_{\omega_t}^w$	陀螺仪随机漂移
$\mathbf{n}_g$	陀螺仪白噪声
$\mathbf{n}_a$	加速度计白噪声
$\mathbf{g}_w$	世界坐标系下 IMU 重力加速度
$\mathbf{R}_{I_t}^w$	世界坐标系到 IMU 坐标系的转换矩阵
$\mathbf{a}_t$	世界坐标系下加速计真值
I_k	k 时刻图像帧
I_{k+1}	$k+1$ 时刻图像帧
$\alpha_{I_{k+1}}^{I_k}$	图像帧 I_k 到 I_{k+1} 的载体在 IMU 坐标系下平移变化量
$\beta_{I_{k+1}}^{I_k}$	图像帧 I_k 到 I_{k+1} 的载体在 IMU 坐标系下速度变化量
$\gamma_{I_{k+1}}^{I_k}$	图像帧 I_k 到 I_{k+1} 的载体在 IMU 坐标系下旋转变化量
$\mathbf{p}_{O_k}^w$	第 k 帧图像时载体在世界坐标系下的平移
$\mathbf{v}_{O_k}^w$	第 k 帧图像时载体在世界坐标系下的速度
$\mathbf{q}_{O_k}^w$	第 k 帧图像时载体在世界坐标系下的旋转
$\mathbf{v}_t^O$	t 时刻车轮坐标系下的车轮线速度
$\mathbf{w}_t^O$	t 时刻车轮坐标系下的车轮角速度
$\alpha_{O_{k+1}}^{O_k}$	t_k 和 t_{k+1} 时刻的平移预积分真实值
$\gamma_{O_{k+1}}^{O_k}$	t_k 和 t_{k+1} 时刻的旋转预积分真实值
$\mathcal{X}$	状态变量
w^O	附加轮速
v^O	线性轮速

1 绪论

1 Introduction

1.1 研究背景及意义（Background and Significance）

我国作为基建大国，公路建设水平一直处于世界领先地位。图 1-1 为全国 2016-2022 年公路总里程数，2022 年公路总里程数已经达到 535.48 万公里，公路养护里程 535.03 万公里，其中高速公路里程达到 17.73 万公里，占公路总里程数的 3.3%^[1]。由此可以看出，如今公路建设发展迅速，同时需要养护的公路里程量也在持续增多^[2]。




图 1-1 近 6 年全国公路总里程数及公路密度

Figure 1-1 The total mileage and density of highways in China in the past six years

随着每年高速公路养护里程量的增加，高速公路热再生养护施工工程日益增多^[3]。传统施工方式一般为人工驾驶车辆进行施工作业，一方面由于施工车辆的机械振动或驾驶人员判断失误，使施工车辆产生偏移，导致道路施工效率降低；另一方面，施工时间大多在夏秋季节，环境温度较高，劳动强度大，影响工人身体健康^[4-5]。因此，在实际施工工程的需求下，工程车辆智能驾驶是保障施工安全性和高效性的重要研究方向^[6-7]。

图 1-2 为高速公路智能化施工场景。智能化施工主要通过施工车辆上安装卫星信号接收器、5G 通讯芯片、微波通讯主机和信号接收天线等一系列通讯控制设备，在无人驾驶的情况下完成施工作业。施工前，工程人员会采用路径信息采集设备，获取施工区域的坐标信息^[8]；然后利用微波通讯传递给基站系统，将数据传给电脑上的软件程序并规划出施工路径；最后下发给机组中每台机械设备的微波通讯系统，引导压路机、摊铺机等多台道路施工设备按照施工要求的路径跟踪行驶，以此实现道路智能化施工^[9-11]。



图 1-2 道路路径智能化施工

Figure 1-2 Intelligent construction of road paths

目前,我国智能驾驶发展迅速,但仍有许多关键技术处于探索和试验阶段,在定位、感知和控制等方面有许多问题亟待解决^[12-14]。实现道路智能化施工的关键一环是施工路径信息采集。根据道路施工的效率、精度和跟踪目标的要求,路径目标检测和多源信息融合导航定位作为其不可或缺的部分,承担着路径坐标信息精准定位和路径目标检测的任务;另外,采集过后需要生成对应的路径轨迹,并对预施工路段进行路径规划,最终为施工车辆提供路径坐标信息^[15-17]。

多源信息融合定位系统通常由全球导航卫星系统(Global Navigation Satellite System, GNSS)、惯性导航系统(Inertial Navigation System, INS)和相机组成。GNSS 系统目前是导航定位中应用最广泛的,工程项目中常用的有北斗、GPS、GLONASS 和 GALILEO^[18-19]。无源式导航技术中,惯性导航系统(Inertial Navigation System, INS)应用比较广泛,通过使用惯导系统,获得载体的位置、角速度和加速度等姿态信息;而且它不受天气、电磁环境等影响,适用于大部分工程项目的环境,但系统存在随机性误差,会产生累积误差并发生漂移^[20-21]。而视觉相机可以提取丰富的道路信息,完成道路上关键目标检测任务,例如路面车道线和路牙石,但容易受到天气和光照等环境因素影响,导致成像质量下降。

综上所述,实现施工车辆智能驾驶,首先需要为其下发准确的路径坐标信息,但道路工程项目中涉及的环境因素比较复杂,且每次施工的地点和时间不同,单一的导航定位系统无法满足精度要求^[22]。因此,需要采用多个传感器设备,减少累积误差和漂移的现象,提高定位信息的精度^[23]。为此,本文针对企业委托科研课题“施工道路车道线坐标信息的智能采集和轨迹规划”,从车道线目标检测和多传感器融合定位两个方面出发,开展施工道路路径智能采集规划系统的研究,该系统利用深度学习车道线检测技术对施工路段的车道线目标进行检测,获得视觉定位关键信息;并采用多传感器融合定位,将视觉信息与其它传感器的定位信息进行融合得到车道线的定位坐标信息;最后完成采集任务并规划出相应的路径轨迹。该系统的研究意义在于为施工车辆智能驾驶提供精确的坐标信息和规划轨

迹，促进了施工道路路径智能驾驶和智能化施工的发展。

1.2 国内外研究现状（Research Status at Home and Abroad）

1.2.1 国内外工程车辆智能化施工发展现状

早在 20 世纪 70 年代，西欧国家便对车辆的无人驾驶进行了深入的研究，并取得一定的成果，但关于工程机械的智能化技术发展较晚。国外的卡特彼勒以及国内的柳工、徐工和山推等公司都对此展开了不同程度的研究^[24-26]。工程机械智能化施工主要由三个阶段组成^[27]。第一阶段：辅助驾驶，防止智能化施工过程中，发生车辆之间或人员的碰撞；第二阶段：远程通讯，通过建立工程机械与后台之间的联系，实现指令的传递和工程机械的接收。第三阶段：智能化的实现，在施工过程中，无操作人员在施工车辆内，无需人员干预。当前国内工程机械智能化施工还处于起步阶段，仍有许多控制和传感等方面技术不够完善^[28]。

矿用卡车是工程机械行业中较早应用于智能化施工领域的，20 世纪 80 年代末，卡特彼勒就开始研究并在 1996 年推出自主研发的无人驾驶矿用卡车^[29]，并用于矿石运输任务。2006 年，小松研制出载重 300 吨的智能驾驶矿用卡车。如图 1-3 展示了露天煤矿卡车无人驾驶流程，采用了 GPS 控制系统，并融合多种传感器实现自动作业^[30]。




图 1-3 露天煤矿卡车智能驾驶施工流程

Figure 1-3 Construction process of intelligent driving of trucks in open-pit coal mines

2019 年，Trimble 公司推进了基于传感器的推土机智能化技术，如图 1-4 所示，通过安装 GNSS 系统和压力传感器来测量推土机的铲刀和俯仰运动时的位置和姿势，以此完成推土机智能化施工工程^[31]。




图 1-4 推土机智能驾驶施工系统

Figure 1-4 Intelligent driving construction system of bulldozer

徐工集团的无人驾驶挖掘机采用无线遥控操作系统，通过远程无线操作实现了挖掘机的所有功能动作。图 1-5 展示了徐工挖掘机无人化施工场景。



图 1-5 徐工挖掘机无人化施工现场

Figure 1-5 XCMG excavator intelligent construction site

2015 年，厦工在北京机械展会上展示了无人驾驶装载机和挖掘机，设备搭载厦工与中航联合研发的智能控制系统，实现无人驾驶和动作操控。在展会上，展示了无线遥控的智能驾驶推土机，通信稳定且通信距离可达 1 千米。

2016 年，一辆搭载北斗定位系统的无人驾驶拖拉机由我国第一拖拉机股份有限公司研制成功，并应用于农田的智能化耕种撒播。

2019 年，sun 等人^[32]研发了基于视觉特征提取的无人压路机定位方法，该方法能准确定位压路机的横向坐标，并且相对误差控制在 0.04m，该系统受电磁干扰较小且硬件成本低。

2020 年，徐工集团设计出全国首台大吨位矿用无人驾驶液压挖掘机^[33]并交付矿区使用，该挖掘机采用 5G+MEC 商用组网方案和远程在线施工技术，实现了设备在 4G/5G 环境中进行不限距远程驾驶操作，极大降低生产成本。

2021 年，中国农业大学的翟卫欣等人^[34]针对无人驾驶农机自主作业的应用需求，设计了一种基于区块套行作业模式的路径规划方法，以生成含有速度指令

和机具状态指令的可执行路径，解决田内作业的四边形地块适应性、无人驾驶农机适应性和农田作业路径完整规划等问题，无人驾驶的农机如图 1-6 所示。



图 1-6 无人驾驶农机

Figure 1-6 Unmanned agricultural machinery

2022 年，北京理工大学刘鹏涛等人设计出如图 1-7 所示震源车无人驾驶系统^[35]，提出基于转向几何约束的局部纠偏路径规划算法，解决了工作点偏离路径问题；设计出基于运动学模型的模型预测控制算法用于车辆路径跟踪，提高了震源车路径跟踪精度，野外作业效率提高了 15%，精度提高了 57%。




图 1-7 无人震源车结构

Figure 1-7 Structure of an unmanned vibrator vehicle

国内外工程智能化施工以工程车无人驾驶为主，融合了多项技术，通常采用视觉特征提取定位、北斗导航定位、GNSS 系统定位和多传感器信息融合定位技术来实现工程机械智能驾驶的精准导航定位。设计相应的路径规划算法，对传感器采集到的道路路面信息进行处理和优化，规划出工程车预行驶的轨迹。

1.2.2 多传感器融合定位的研究现状

常用的导航定位与检测技术众多，不同的定位方法应用于多种场合，但同样存在差异^[36]。由于使用单一定位方法难以满足特殊场合下对定位精度和准确性的要求，尤其在工程机械方向，施工环境下，定位设备容易受到环境影响从而降

低稳定性和精确性^[37]。如图 1-8 所示为多传感器融合定位框架图。目前多传感器定位方向，GNSS、视觉相机、激光雷达以及惯导系统被广泛应用^[38-40]。




图 1-8 多源信息融合框图

Figure 1-8 Block diagram of multi-source information fusion

多源信息融合最早应用于军事领域。如今多源信息融合定位在工业^[41]、农业^[42-43]和矿业^[44]领域中也有一席之地。对此国内外学者也展开了相关研究：

李昂等人^[45]提出了基于惯性导航与轴编码器组合的采煤机三维绝对定位技术方案，并且基于光纤惯导、ARM 微处理器和轴编码器研发了 SAPAS，实现了采煤机采区绝对定位定姿。Boche 等人^[46]将立体视觉-惯性同步定位和映射 (SLAM) 与基于紧密耦合和优化的框架中的全局传感器模式融合在一起，提出了一个类似闭环的优化方案来补偿在接收 GPS 信号中断期间累积的漂移。Cao 等人^[47]将全球导航卫星系统 (GNSS) 的原始测量数据与视觉和惯性信息紧密融合，用于实时和无漂移状态估计。

多源传感器融合的方法不尽相同，各有优缺点，总的来说多源融合定位算法包括图优化、卡尔曼滤波、粒子滤波、加权融合等。Chen 等人^[48]研究了基于 INS/GPS 的组合导航系统，提出并测试了一种结合强跟踪卡尔曼滤波 (STKF) 和小波神经网络 (WNN) 算法的 INS 误差补偿模型。Lin 等人^[49]研究了在误差状态迭代卡尔曼滤波中测量激光雷达、惯性传感器和相机传感器，并使用因子图优化来细化图像关键帧和视觉地标滑动窗口中的局部地图，克服了传感器剧烈运动中产生的故障，在定位和映射方面达到了较高的准确性和鲁棒性，如图 1-9 为所采用的传感器信息采集设备。




图 1-9 传感器信息采集设备

Figure 1-9 Sensor information acquisition equipment

Ruben 等人^[50]提出了一种解耦的基于图形优化的多传感器融合方法 (GOMSF), 该方法将通用的 6 自由度视觉惯性测姿和 3 自由度全局参考位置结合起来, 实时推断机器人的全局 6 自由度姿态, 定位框架如图 1-10 所示。




图 1-10 视觉惯性融合定位框架

Figure 1-10 Visual inertial fusion positioning framework

多传感器信息融合定位, 通过融合局部信息, 对全局信息进行状态估计, 使定位精度更高。常用的融合定位算法有卡尔曼滤波、加权融合、目标跟踪算法等。通过使用多传感器融合定位技术, 不仅能够确保系统定位的精度, 而且还能保证路径信息采集的准确性和无人驾驶的稳定性。

1.2.3 车道线目标检测的研究现状

路径信息采集使用单个或多个传感器设备对道路路面的信息和周围的环境信息进行数据的收集^[51]。路径信息采集这项工作多应用于车辆、机器人和无人机等领域^[52-54]。工程机械中, 常常通过对行驶路径的信息收集, 并采用一定的算法对采集到的数据和图像进行处理, 是工程车辆的无人驾驶和完成无人化施工的关键步骤^[55]。路径信息采集中关键的一步就是对路径上的特征进行提取, 本文路径智能采集规划系统主要检测的就是车道线, 主要对路径上的车道线进行检测和提取。随着信息化的快速发展, 国内外学者对车道线检测技术展开了深入的研究, 并取得了一定的成果。车道线检测主要分为传统图像处理和深度学习神经网络两种方式。

（1）传统基于图像处理的车道线检测算法：

传统的车道线检测可分为基于特征的识别方式和基于模型的识别方式。基于特征的车道线检测方式通常利用车道线本身特征和路面的情况不同来检测，根据车道线不同的颜色、形状、边缘、纹理等特征进行识别，例如 Sun 等人^[56]提出了一种基于 HSI 颜色模型的车道线检测算法（HIS Lane Detection Model），将 RGB 图像转换为 HSI 颜色空间中，并裁剪出 ROI；东北大学的李晗^[57]根据车道线的轮廓特征，将车道线和背景进行分割，并进行图像恢复处理。但基于特征的方式通常对图像处理的要求比较高，需要进行图像灰度化处理、图像去噪和边缘提取等图像处理操作，且图像的质量不能过差，否则会导致检测的效果不佳，导致模型精度过低。比如 Yoo 等人^[58]利用连续帧之间的相似性，构建了动态转换向量将 RGB 图像转成灰度图。转换后的图像重点突出了车道线的强度信息，便于后续特征的提取。该方法利用连续帧之间特征的差异较小的特点，降低了阴影和光线发生重大变化时的不稳定；Suddamalla^[59]不仅提取出车道线的强度信息，同时提取出车道线的边缘信息，从而提高了车道线的检测准确率。总的来说，该方式存在鲁棒性差、抗干扰能力弱的缺点，也有算法比较简单、结构简单特点。基于模型的车道线检测方式考虑了车道线的几何特性和路面的具体情况，通过创建车道线的几何模型，并对模型中的各项参数进行计算。常用的方式有最小二乘法、霍夫变换、ROI 区域选择和逆透视变换等。比如王其东等人^[60]通过将感兴趣区域分为初帧检测 ROI 和车道线跟踪成功时的 ROI，来实现降低非车道区域的噪声对车道线检测的影响和提高车道线检测的实时性，但是该方式如果需要获得高精度训练模型，则要求复杂的模型，这样计算量也随之增加，同时，该方法也存在弯道检测差的缺点，所以基于模型的检测方式也存在一定的局限性。

（2）基于深度学习的车道线检测算法

近年来，随着自动驾驶和人工智能的不断发展，一些基于深度学习神经网络的方法在车道线检测领域显示出优越性，该方式不仅相较于传统的车道线检测方式提高了模型精度和鲁棒性，同样能够完成复杂场景下的检测任务。基于深度学习的车道线检测方式主要分为基于分割的和基于行分类的两种方式。基于分割的方法针对图像中的像素点，将图像中的像素点分类成车道线和非车道线的部分。比如杨淑琴等人^[61]采用实例分割的算法，提出了基于改进混合任务级联（HTC）网络的车道线检测方法，有效提高了车道线检测精度；Neven 等人^[62]提出了将检测问题转换为分割问题的新方法 LaneNet，该网络由一个用于提取特征的编码器和一个用于还原车道线的解码器组成，解码器由将每个像素标记成车道线或者背景的二值分割分支和将特征嵌入到空间结构的可嵌入分支组成，双分支输出的特征图送入后处理中进行融合和聚类，获取更加准确的车道线。基于行分类的方式，

是一种基于栅格分割的识别算法。车道线会被栅格划分成多行，算法模型会在每一行选择包含车道线的部分，且每行只会选择一个最具可能性的栅格，最终经过后处理所有的栅格会形成车道线集合。

总结来说，不管采用传统的图像处理方式，还是深度学习的方式，最终都会根据实际的需求，作为路径信息采集工作中目标检测的重要一步。

1.2.4 道路路径轨迹规划的研究现状

通过对行驶路径路面信息进行了采集之后，数据经过处理，需要进行道路路径规划，为智能化施工车辆提供准确的领航路径^[63-64]。道路路径规划技术是完成工程机械智能化施工的重要环节，为了能够给工程车辆快速规划出有起始点和终点的路径，选择合适的优化算法十分重要^[65]。工程机械智能化施工的路径规划主要有两种思路：一是施工情况下不考虑障碍物，只需保证规划的路径轨迹和施工时路径跟踪偏差保持在合适的范围之内，二是考虑障碍物的情况下，保证车辆行驶过程中按最优或最短路径行驶^[66-67]。

许保光等人^[68]通过人车混采的方式对道路路径信息进行采集，并建立了满足人车混采的整数规划模型，提出了 GPASP-PA 寻优算法，实现了对路面信息的高效精确采集并且能够规划出最优路径。鲍久圣等人^[72]采用最优性 A*算法和人工势场算法对无人驾驶无轨胶轮车进行全局和局部路径规划，并采用指数函数加权和三次样条插值的方法对全局路径规划传统 A*算法搜索节点多和路径不平滑的现象进行改进。

Analooee 等人^[69]采用五次多项式拟合车辆轨迹，在曲率约束和任意边界条件下生成长度最优轨迹，并使轨迹平滑。Provine 等人^[70]演示了使用本体来支持障碍物推理，来提高自动驾驶路径规划的能力和性能，自动推理用于估计碰撞损坏，将信息提供给路径规划设备，帮助车辆计划是否避开障碍。Shi 等人^[71]提出了一种改进的遗传与蚁群杂交算法，建立了智能车辆的物理模型，旨在解决四轮智能车辆路径规划算法路径规划不平滑的问题。

总的来说目前路径规划主要采用 GPASP-PA 寻优算法、蚁群优化算法、B 样条曲线和最小二乘法等算法对路径路线进行拟合处理，生成一条平滑连续的路径轨迹，用于后续下发路径给无人驾驶系统。

1.3 存在问题（Existing Problems）

从近年的发展情况以及相关研究成果来看，智能化施工以及路径信息采集的关键一步在于定位系统的搭建与路径车道线信息的目标检测。以下几点为拟解决的问题：

（1）目前，在对智能化施工道路路面信息的采集过程中，在复杂环境下，

会受到外界因素的影响。多传感器信息融合定位在工程机械领域有很大的应用价值,但由于应用场景是在高速施工公路上,针对这一特殊情况,对于多传感器融合定位系统的性能要求更高。

(2) 多传感器信息融合定位包含的传感器较多,考虑到的因素也要多于常规的单一传感器定位。而且将该技术应用于工程施工领域,需要在兼顾精度要求、方案可行性、数值稳定性和算法适配性等方面的前提下,研究合理的融合定位结构模型。根据各传感器之间的配合和数据的融合,设计合理的算法。

(3) 施工道路智能采集规划系统服务于路面热再生养护车辆的智能驾驶,主要应用场景为施工路段,但一般施工路面的车道线存在磨损和断裂等车道线不可视的情况,需要设计有针对性的算法进行车道线检测。

1.4 论文主要研究内容 (Main Research Content of the Thesis)

1.4.1 研究目标

本文针对道路养护热再生机组路面施工过程中的智能驾驶需求,完成路面热再生施工前的路径信息采集。为此,展开对视觉、惯性导航、轮式里程计和北斗卫星定位组合的多传感器融合定位系统与路径车道线目标检测的研究,设计了一套施工道路路径智能采集规划系统,完成软硬件系统的搭建,实现施工道路路径车道线坐标信息采集和路径轨迹拟合规划,为路面养护车辆智能化施工提供技术支持和理论依据。

1.4.2 研究内容

(1) 路径智能采集规划系统总体结构和实验平台搭建

首先,考虑实际工程施工场景、采集系统的需求和成本精度要求,对传感器进行选型;其次,选择合适的主操作系统和软件平台,进行数据的接收、传输和处理;最后,根据相机的视角高度要求和其它传感器接线位置,设计路径智能采集规划系统的实验平台(路径采集小车)。

(2) 施工道路路径车道线检测算法的研究

设计和选择合适的算法网络,解决车道线不可视情况难以检测的问题,并通过自主采集数据集进行训练,得到可视化结果和评价指标数据,证明算法的可行性和检测的准确性。

(3) 多传感器融合定位技术的研究

设计多传感器融合定位算法,首先,定义各传感器的坐标系,将车辆的运动姿态参数化,然后进行传感器建模;设计定位优化算法,通过完成传感器的初始化和优化,得到实时位姿和位置信息;最后,进行定位精度评估,验证定位算法的鲁棒性和准确性。

（4）道路路径信息采集及路径轨迹规划

综合车道线检测与多传感器融合定位，首先设计路径信息采集和轨迹规划的方案；其次，利用路径信息采集平台（路径采集小车）进行道路实验，得到采集后的路径轨迹信息；最后，进行相关的轨迹对比，验证路径采集规划系统的性能。

1.4.3 章节安排

本文主要分为以下六个部分，具体如下：

第一章 阐述本文的研究背景和意义，调研国内外相关技术的研究现状，确定本文的研究目标，介绍本文的研究内容。

第二章 介绍施工道路路径智能采集规划系统的用到的传感器及类型、主操作系统的功能和应用到的软件平台，根据传感器安装和接线的要求，设计并绘制了实验平台的三维轴测图。

第三章 针对施工路径车道线的特点，初步研究了基于锚点的车道线检测算法，并自建数据集进行算法训练，检测效果未能满足当前需求。针对该问题，设计了一种基于行分类和注意力机制的车道线检测算法，引入混合注意力机制更好的提取特征图像中的感兴趣特征，计算结构损失完成预测车道线，最后在自主采集的数据集上训练，并进行实验分析。

第四章 研究多传感器定位系统，首先定义各传感器坐标系和世界坐标系，介绍姿态参数化和定位坐标转换方式，建立相机和 IMU 模型；其次，设计基于 VIWO 紧耦合优化算法，采用视觉/惯性/轮式里程计动态和静态初始化方式获取载体初始状态；然后，基于 VIWO 系统与 GNSS 信息松耦合方式，完成多传感器融合定位系统的设计；最后，通过测算直道和弯道下惯导和相机之间相对角度误差来验证初始化效果，在公开数据集上验证 VIWO 系统的定位定姿性能，在自主采集的数据集上验证 VIWO 系统融合 GNSS 信息后的定位性能。

第五章 设计路径智能采集和路径轨迹规划的具体方案，通过在校园路段和施工路段进行实际道路实验，对比规划轨迹与参考轨迹，得到东-北-天三向的定位位置误差，并对路径智能采集规划系统的定位性能进行分析。

第六章 总结本文主要工作内容，展望后续的研究工作。

1.5 本章小节（Brief Summary of the Chapter）

施工道路智能化是未来公路养护机械发展的重要方向，通过研究施工路径采集和规划方式，为热再生机组提供准确的定位坐标信息和规划轨迹，对发展热再生机组智能驾驶有重要的研究意义。本章首先对课题的研究背景和意义进行详细的介绍，调研了施工道路养护车辆智能驾驶的相关技术和需求；其次，介绍了本文涉及的相关技术和目前国内外的研究现状，了解目前主流技术的研究方向；然

后，结合施工道路的实际情况，分析目前施工道路路径智能采集规划系统需要解决的问题；最后针对这些存在的问题，明确本文的研究目标，详细说明本文的研究内容，并对各章节的具体内容安排进行简述。

2 路径采集规划系统的需求与相关软硬件

2 Path Acquisition Planning System Requirements and Related Software and Hardware

针对施工道路的场景，本章阐述了路径智能采集规划系统的需求，设计道路路径智能采集规划系统的结构，该结构包括硬件组成部分、软件环境以及实验平台。本章节主要进行传感器的选型、软件平台的选取以及实验平台的设计，并对相关的传感器参数和软件系统的功能进行介绍。

2.1 系统概述（System Overview）

2.1.1 系统需求

（1）当前大多数的车道线检测主要是面向车道线完好、结构规范的城市路段和高速公路，但本文介绍的系统是面向高速施工道路，存在路面环境和车道线类型的差异，要求系统能在高速施工路径完成路径信息采集任务。

（2）要求系统定位精度较高，满足施工道路路径信息采集的实际需求。

（3）采集完成后，能够及时输出经纬度坐标，用于后续下发给施工车辆无人驾驶。

2.1.2 系统结构

本文介绍的施工道路智能采集规划系统主要由深度学习车道线检测、多传感器融合定位和路径轨迹规划组成，视觉定位信息主要依据路径上的车道线，检测识别并提取像素坐标，经过多传感器融合定位和定位坐标转换，生成相应的经纬高三维坐标点，三维坐标点信息再经过平面坐标转换为平面坐标点，通过定位信息滤波、路径轨迹拟合和路径重采样，最终完成路径轨迹的规划。系统的具体结构如图 2-1 所示。




图 2-1 施工道路路径智能采集规划系统的总体结构

Figure 2-1 The overall structure of the intelligent path collection and planning system for construction road paths

2.2 硬件选型与结构设计（Hardware Selection and Structural Design）

2.2.1 结构框架

路径智能采集规划系统的硬件部分由惯性测量单元、深度相机、GNSS-RTK 以及轮速计组成，具体结构如图 2-2 所示。




图 2-2 具体结构框架

Figure 2-2 Concrete structural framework

根据工程实际应用的需求，路径智能采集规划系统中包含的各类传感器设备拥有不同的性能，以确保采集到的数据精度高、系统的鲁棒性高。各传感器具体内容如下：

(1) 惯性测量单元 (Inertial Measurement Unit)

惯性测量单元主要用于获取运动设备角速度和加速度数据。广泛应用于自动驾驶路径规划和机器人等领域。惯性测量单元能够准确感知车辆的运动状态，方便及时校正和对比路径信息的变化。但 IMU 的测量数据往往存在较大噪声的现象，需要通过预积分处理的方式来减小噪声带来的误差。

(2) 深度相机

深度相机作为整个路径采集系统的核心设备，为整个系统提供了视觉功能，能够获取施工道路路径上的车道线特征信息。

(3) GNSS-RTK (Global Navigation Satellite System, GNSS)

全球定位系统主要用于提供物体在地球表面的三维坐标位置信息和姿态信息。本文采用北斗 RTK 差分定位系统，其作为我国自主研发的导航定位系统，拥有更高的定位精度，同时具备定位和通讯的功能，覆盖的范围广，更加安全、可靠、稳定且保密性强。

(4) 轮速计

轮速计通常用于测量前后轮的速度，能够提供车辆的运行状态。通常应用于路径规划、路径采集车和自动驾驶等领域。本文设计的系统采用外接轮速计的方式，该方式获取的数据精度较高，结构复杂，可靠性较差，但适用于路径信息采集车。

2.2.2 传感器选型

根据上文所涉及的硬件设备，综合考虑实际精度需求和成本，选择合适的硬件设备型号。各硬件名称以及型号如下表 2-1 所示。

表 2-1 相关硬件型号

Table 2-1 Relevant hardware model	
硬件名称	型号
GNSS 定位	RTK (北斗)
IMU 惯导模块	N100
工控机	英伟达 Jetson Xavier nx 16G
深度相机	英特尔 Intel RealSense D435i
硬件安装支架	0.6m 高
显示屏	CLB 256 13.3 英寸触摸屏
轮速计	OidEncoder

2.2.3 GNSS-RTK

RTK 的工作原理是通过架设基站和移动站，实时处理基准站与移动站观测测量之间的空间相关程度，这样的方式能够削弱电离层、对流层的干扰，减少卫星轨迹造成的误差，经过载波相位定位解算，最后输出定位坐标信息。RTK 定位模

块由定位天线、定向天线、基站和 GNSS 接收机组成，如图 2-3 所示。



图 2-3 RTK 定位设备
Figure 2-3 RTK positioning device

2.2.4 IMU

IMU 作为检测和测量系统加速度和角速度的主要原件，用于位置姿态和轨迹运动的测量控制，考虑性能和成本，选用 9 轴 IMU。IMU 模块具体实物如图 2-4 所示，IMU 数据性能参数如表 2-2 所示。



图 2-4 IMU 模块
Figure 2-4 IMU module
表 2-2 IMU 数据性能
Table 2-2 IMU data performance

项目	加速度计	陀螺仪
量程	$\pm 16g$	$\pm 2000^{\circ}/s$
线性度	$<0.1\% FS$	$<0.1\% FS$
零偏稳定性	$<0.4mg$	三轴陀螺: $5^{\circ}/hr$
带宽	260 Hz	256 Hz
正交性误差	$\pm 0.05^{\circ}$	$\pm 0.05^{\circ}$
分辨率	$<0.5mg$	$<0.02^{\circ}/s$

2.2.5 工控机

工控机作为整个系统的主控设备，使传感器设备与计算机实现通信，完成数据可视化、指令下达等操作，实现接收传递信息以及控制设备运行的功能。本文所选用的工控机与显示屏组合设备的具体参数如下表 2-3 所示，工控机与显示屏的连接方式如图 2-5 所示。



图 2-5 工控机与显示屏组合连接方式

Figure 2-5 The combination of industrial computer and display screen connection mode

表 2-3 工控机与显示屏组合设备参数

Table 2-3 Parameters of the combination of industrial computer and display screen	
项目	参数
GPU	32 个 Tensor Core 1024 核 NVIDIA Ampere 架构 GPU
CPU	6 核 ArmCortexA78AE v8.2 64 位 CPU1.5MB L2 + 4MB L3
显存	16GB 128 位 LPDDR5102.4GB/s
规格尺寸/mm	103×90×34

2.2.6 相机

相机作为采集图像，是完成目标检测的重要设备。根据本文介绍的系统对相机的分辨率以及帧率的要求，选用合适的深度相机，实物如图 2-6 所示。该型号相机能够采集彩色的车道线图像数据，也可以采集图像像素的空间深度信息，具体参数如图 2-6。



图 2-6 深度相机

Figure 2-6 Depth camera

表 2-4 深度相机具体参数
Table 2-4 Parameters of the depth camera

项目	参数
物理尺寸	90mm*25mm*25mm
深度分辨率	1280×720
帧率	90FPS
RGB 分辨率	1920×1080
视场角	69° ×42°
接口	USB-C*3.1 Gen1*

2.2.7 轮速计

轮式里程计是一种安装在车轮上的传感器，通过测量车轮的旋转情况来确定载体的位置和姿态。实物如图 2-7 所示，它主要通过计数脉冲来得到车轮旋转角度和方向，从而计算出载体在水平面上的位移和方向信息。具体参数如表 2-5 所示。



图 2-7 轮速计

Figure 2-7 Wheel speedometer

表 2-5 轮速计具体参数

Table 2-5 Wheel speedometer specific parameters

项目	参数
型号	8mm 盲孔
通讯协议	RS485
分辨率	12 位

2.3 软件平台（Software Platform）

施工道路路径智能采集规划系统应用的软件为 Linux 系统、ROS 系统和图像标注软件 Anaconda（Labelme）。智能采集系统的主操作软件采用 Linux 系统。Linux 系统广泛应用于智能驾驶和路径规划领域，且 Linux 模块化程度高、硬件支持更广泛、安全稳定、良好的可移植性和免费开源等特点。另外利用 ROS 进行通信和数据可视化，其能将传感器与计算机之间建立通讯，使系统中每个软硬件模块都能有效的进行互动，且 ROS 具有安全、稳定、高效以及实时监测的特

点。图像标注软件采用 Anaconda 中的 Labelme 软件，通过该软件标注图像，能够确定图像特征提取的区域，为后续深度学习训练模型提供数据样本。具体软件平台结构框架如图 2-8 所示。




图 2-8 软件平台结构框架

Figure 2-8 Architecture of the software platform

ROS 系统，即机器人操作系统，它是一个开源的元操作系统，不仅提供了底层设备控制的功能，同时还能实现信息之间的通信以及程序管理等功能，另外它还能提供大量的操作工具和数据库。ROS 系统也广泛应用于路径规划领域。本文介绍的路径智能采集规划系统在 ROS 系统上进行路径轨迹规划和可视化分析。

ROS 起源于斯坦福大学人工智能实验室与机器人技术公司 Willow Garage 合作的个人机器人项目。它采用基于节点 (Node) 的架构，其中每个节点可独立执行特定的任务，并通过消息传递机制进行通信。节点可以在单个或多个计算机上运行，形成分布式系统。不仅如此，ROS 系统还包含 Master、消息、话题、和服务等组件，具体的通信机制如下图 2-9 所示。




图 2-9 ROS 系统通信机制

Figure 2-9 Communication mechanism of the ROS system

基于 ROS 构建路径智能采集规划系统开发平台。开发平台包括服务器模块、上位机模块和下位机模块，如图 2-10 所示。





图 2-10 ROS 开发平台

Figure 2-10 ROS development platform

2.4 路径采集设备设计 (Design of Path Acquisition Equipment)

考虑相机的拍摄角度和高度以及传感器的安放位置, 在采集车辆底盘前端安装一个高 0.6m 的架子用于摆放传感器, 同时也便于拆卸。利用 solidworks 软件对路径智能采集规划系统的实验平台进行了设计, 该平台的三维设计图如图 2-11 所示。



1-定向天线; 2-电动车底座; 3-定位天线; 4-GNSS接收器;

5-工控机; 6-IMU; 7-轮速计; 8-相机

图 2-11 路径智能采集规划系统实验平台三维图

Figure 2-11 Three-dimensional diagram of the experimental platform of the path intelligent acquisition and planning system

2.5 本章小节 (Brief Summary of the Chapter)

本章首先施工道路路径智能采集规划系统的系统需求和系统结构进行概述, 其次根据系统的需求, 选择合适的传感器设备; 其次, 将 Linux 系统作为主操作系统, 采用 ROS 系统作为数据获取和可视化的平台; 最后根据传感器的接线要求和布局要求, 设计了路径采集系统的实验平台 (路径采集小车)。

3 基于深度学习车道线检测的研究

3 Research Based on Deep Learning Lane Line Detection

本章利用深度学习的车道线检测的方式来对高速公路施工路段的车道线信息进行识别和提取。车道线检测和图像处理技术是当今人工智能时代广泛应用的视觉技术。近年来,在工程应用领域中也大放异彩,通常出现在工程车无人驾驶、智能驾驶场景,能够实现路径车道线的提取和识别。本文中的定位系统中视觉部分也需要依据车道线,以此来完成对路径车道线的坐标信息提取。针对施工道路的实际情况,首先采用了基于锚点的车道线检测算法,然后通过自建数据集,进行模型训练,检测车道线特征不明显时效果未能满足需求;针对该问题,设计了一种基于行分类和混合注意力机制的车道线检测算法;最后对自建数据集进行模型训练,并对实验结果进行分析。

3.1 引言 (Introduction)

绪论中简单介绍了车道线检测算法的研究现状,目前自动驾驶与路径规划是热门的研究方向,针对车道线检测的任务,许多学者给出了很多种算法,例如过去常用的基于图像预处理的方式和近年兴起的基于深度学习神经网络的方式。

3.1.1 车道线检测算法类型及特点

传统的车道线检测方式,依赖车道线颜色、纹理和边缘信息,需要对图像进行预处理、特征提取、逆透视变换和车道线拟合,需要手动设计,检测方式整体复杂度不高,但精度很低,很难应对许多路面复杂的场景。

随着人工智能的不断发展,神经网络也被应用于车道线检测的研究中,基于卷积神经网络的车道线检测算法具有很强的特征提取能力,通过深度学习的方式学习车道线的具体特征,面对复杂的车道线场景具有较强的鲁棒性。另外,当今的深度学习车道线检测算法主要为基于语义分割、基于检测、基于参数曲线和基于关键点这四类。基于语义分割的方式主要是将图像中的每个像素沿通道进行分割,并判断其是否存在车道线,从而提取图像上的关键信息,最后利用后处理的方式将分割的结果进行聚类 and 拟合,得到车道线检测结果,代表算法有 SCNN、SAD 和 RESA 算法;基于检测的方式通常采用自上而下的方法来检测车道线,利用车道线图像的视觉特征由近向远延伸的特点,构建车道线实例,常用于车道线不可视情况,代表算法有 LaneATT、UFSA 和 CondLaneNet^[73];基于参数曲线的方式不同于上述的像素点聚类回归的方法,通常采用曲线参数对车道线进行建

模来检测车道线，比如 PolyLaneNet^[74]将输入图像中车道线用多项式标记，通过计算每个车道的置信度得分来检测车道线；基于关键点的方式通过对局部的特征建模，采用自上而下的方式实现全局的预测，代表算法有 FOLOLane^[75]。

3.1.2 施工道路车道线检测待解决的问题

(1) 面向复杂的道路情况时，如光照与车道线模糊、磨损和不连续等情况，会对车道线检测工作有一定的考验，需要设计相关的车道线检测算法来完成车道线目标检测任务。

(2) 本文介绍的系统对于精度的要求比较高，要求训练模型的精度高、响应速度快。

(3) 当前公开的数据集很少有施工道路场景下的车道线图像，所以需要采集高速施工道路的车道线图像，提高训练模型的泛化性。

3.2 基于锚点的车道线检测算法的研究 (Research on Lane Line Detection Algorithm Based on Anchor)

针对上述施工道路车道线检测的具体问题，受车道线检测经典算法 LaneATT^[76]的启发，采用一种基于锚点的深度学习车道线检测算法。该方法使用锚点进行特征池化步骤，将车道线用多个像素点表示，能够精确检测车道线的特征，另外该方法可以聚合局部信息和全局信息，进行车道线预测。

3.2.1 基于锚点的车道线检测算法原理

算法模型主要包括主干网络、注意力机制、基于锚点的特征池以及预测模块组成。为了产生这些输出，一个残差神经网络 (ResNet)，被称为主干，生成一个特征图。主干网络从输入图像生成特征映射，随后，将每个像素点投影到特征映射上，然后汇集以提取每个像素点的特征，这些特征与注意力模块产生的一组全局特征相结合。通过结合局部与全局信息，模型可以通过采用其他部分的信息来解决没有车道标记的情况。最后，使用输出的特征集结果，分别用于回归和分类，将组合的特征传递给全连接层进行结果预测和输出。算法具体框架如图 3-1 所示：




图 3-1 基于锚点的算法框架

Figure 3-1 Anchor-based algorithm framework

3.2.2 主干网络

算法第一步，往往是通过原始车道线图像进行特征提取，一般会采用到主干网络，下文将对算法的主干网络的组成和来源进行介绍。

传统的神经网络主要通过卷积层和池化层叠加组成的，过去人们认为卷积层和池化层的层数越多，获取特征的能力就更强，经过神经网络训练后的效果就更佳。但实际却恰恰相反，随着卷积层与池化层的不断叠加，非但没有出现训练效果更佳的情况，反而出现了梯度消失和梯度爆炸的现象。同样，网络叠加到一定层数会达到饱和，此时网络模型已经达到最优状态，如果过度的叠加网络，会导致训练变得繁重，模型性能降低。为了解决上述的问题，微软实验室的何凯明等人于 2015 年提出了残差神经网络(Residual neural network, ResNet)^[77]，该神经网络由 4 块卷积网络构成，分别为 18 层卷积层堆积网络及 18 层残差网络、34 层卷积层堆积网络及 34 层的残差网络。在 ResNet 模块中引入残差结构可以有效解决网络退化的问题，但在网络训练过程中，相同类型的网络模型中前 34 个卷积层会比前 18 个卷积层更加容易出现模型退化的情况。针对这种情况，引入 34 层残差网络可以避免该情况的出现，提高模型的准确性，ResNet 的残差结构模型如图 3-2 所示。




图 3-2 ResNet 的残差结构模型

Figure 3-2 Residual structure model of ResNet

假设输入为 x ，网络学习到的特征为 $H(x)$ ，网络设计为 $F(x) + x$ ，网络最优的拟合输出如式 (3-1) 所示，将恒等映射作为网络训练一部分，残差为 0 时，构成一个恒等映射，式 (3-2) 为和之间的残差，通过拟合该残差，能够对网络进行优化，提高网络的整体性能。

$$H(x) = F(x) + x \quad (3-1)$$

$$F(x) = H(x) - x \quad (3-2)$$

式中： $F(x) + x$ 通过具有“短路连接” (shortcut connections) 的前馈神经网络来实现。它将输入与输出相连，具体模块结构如图 3-3 所示。




图 3-3 残差学习模块

Figure 3-3 Residual learning module

深度残差神经网络中的基本单元残差包括线性映射与恒等映射，这样能够减少网络模型训练的时间。

ResNet 中 block 的连接方式通常采用线性映射与恒等映射混合使用的方式，这样既能保证精度，又可以使模型的复杂程度保持平衡。

另外，ResNet 网络结构的函数具有以下特点：

- (1) 网络中的总梯度保持在 1 附近，能够解决卷积层过度堆叠引起的梯度消失。
- (2) 理论上来说，网络能够无限堆叠，进行非常深度的网络模型训练。
- (3) 残差学习可以简化模型训练的难度，网络的泛化性能好，能够作为绝大多数算法的主干网络。

ResNet-18 作为本文采用的深度学习车道线图像识别算法的主干网络，图 3-4 展示了模型的结构，该模型主要采用步长为 2 的卷积进行下采样，如图中实线所示，每两个卷积层之间加入了短路机制，从而形成残差学习，图中虚线表示将特征升维并下采样，保证网络层的复杂度。在此过程中，由相机拍摄的图像的尺寸为 $I \in \mathbb{R}^{3 \times H_I \times W_I}$ ，经过主干网络，主要输出一个特征映射 $F_{out} \in \mathbb{R}^{C_F \times H_F \times W_F}$ ，通过池化层提取每个锚点的特征，如下一节所述的锚点系统的锚点，通过对 F_{out} 进行

1x1 的卷积进行降维处理, 生成一个通道简化映射 $F \in R^{C_F \times H_F \times W_F}$, 从而达到简化计算的目的。




图 3-4 Resnet-18 模型结构

Figure 3-4 Structure of the Resnet-18 model

3.2.3 方法概述

(1) 基于锚线的表示方式

首先, 为了对图像中的车道线像素点精确提取, 将图像放置于坐标轴中, 图像中的车道线沿 y 轴方向等分为若干点, 等分点 y 轴坐标表示为 $Y = \{y_i\}_{i=0}^{N_{\text{img}}-1}$, 其中 $y_i = i \cdot H_I / (N_{\text{img}} - 1)$, Y 固定不变, x 轴的坐标表示为 $X = \{x_i\}_{i=0}^{N_{\text{img}}-1}$ 表示, 其中由于车道线不会贯穿整张图像, 所以会设置起始索引和结束索引来定义车道线特征的有效连续性。如图 3-5 所示, 图像上预设一条“虚拟锚线”, 其坐标原点 $O = (x_{\text{org}}, y_{\text{org}})$, $y_{\text{org}} \in Y$, 原点可出现在图像的左右下边界, 由此引出锚线, 角度 θ 表示方向, 在实际检测过程中, 图像会被多个原点生成的不同角度的锚线覆盖, 这些锚线与车道线特征相交的像素点作为锚线的感兴趣点。




图 3-5 锚线检测示意图

Figure 3-5 Schematic diagram of anchor line detection

每条锚线都需要从特征映射 $\mathbf{F}$ 提取特征，坐标索引提取感兴趣点，也就是锚线与车道线相交的点，定义这些坐标点（锚点） y 轴方向坐标为 $y_j=0, 1, 2, \dots, H_F-1$ ，锚线对应的 x 轴坐标表示为：

$$x_j = \frac{1}{\tan \theta} (y_j - \frac{y_{org}}{\delta_{back}}) + \frac{x_{org}}{\delta_{back}} \quad (3-3)$$

式中： (x_{org}, y_{org}) 和 $\tan \theta$ 分别为锚线的原点和斜率， δ_{back} 为主干的整体步幅。因此，每个锚线 i 都有其对应的特征向量 $\mathbf{a}_{loc,i} \in \mathbf{R}^{C_F \cdot H_F}$ ，该特征向量从 $\mathbf{F}$ 中池化，其中包含了局部特征信息。另外如果锚线在特征 $\mathbf{F}$ 范围之外，则该位置会被置零。

（2）注意力机制

注意力机制的概念源于 20 世纪 90 年代，当时学者在处理信息的过程中会过滤掉无关的信息，着重于感兴趣的信息，于是将这种现象称作注意力机制。传统的机器学习中，通过建立特征方程，将输入数据向量化，能有效提取兴趣特征，使模型更关注需要检测的目标。

2014 年，Volodymyr 等人^[78]将注意力机制引入视觉领域，后来伴随着 2017 年 Ashish Vaswani^[79]中 Transformer 结构的提出，注意力机制广泛应用在自然语言处理（Natural Language Processing, NLP）和计算机视觉（Computer Vision, CV）等相关领域中。

计算视觉领域中，注意力机制按照其关注的区域可以被划分为通道注意力机制、空间注意力机制以及时间注意力机制。

通道注意力机制：在计算机视觉中，输入的二维图像的长宽为一个维度，加入神经网络之中后，会产生一个维度，称为通道，用于表示图像的深度信息。通道注意力机制更加关注特征图像通道之间的关系，然而一般的卷积只会对通道进行融合。

空间注意力机制：更加关注输入特征的空间信息，处理网络模型中最关键的部分进行处理。

根据模型体系结构的不同，汇集的特征向量所携带的信息大多是局部的。对于网络模型较浅、速度更快的来说，这种情况更明显，这些模型倾向于利用具有较小接受域的主干。然而，在处理一些车道线特征不明显的情况，局部信息难以精确预测出车道线位置，导致模型的整体性能下降。为此，通过采用注意力机制，使局部特征 $\mathbf{a}_{loc}$ 产生额外的特征 $\mathbf{a}_{oth}$ ，将局部信息与全局信息联系。

主干网络特征提取中卷积层、池化层和激活函数，都是将原始输入映射到特征空间，注意力机制通过引入全连接层对特征映射进行学习，并将其映射到样本空间。特别的是全连接层将前一层所有节点与后一层的每个节点相连接，这样可

以起到综合前一层特征的作用，经过全连接层将卷积向量转化为一个 1×1 的向量。

本节介绍的注意力机制结构由全连接层 L_{atn} 组成， L_{atn} 用于处理每个锚线生成的局部特征向量 $\mathbf{a}_{loc,i}$ ，并根据锚线上锚点 j 的存在情况，输出一个概率(权重) $w_{i,j}$ ，表达如式 (3-4) 所示：

$$\mathbf{w}_{i,j} = \begin{cases} \text{softmax}[L_{atn}(\mathbf{a}_{loc,i})]_j, & j < i \\ 0, & j = i \\ \text{softmax}[L_{atn}(\mathbf{a}_{loc,i})]_{j-1}, & j > i \end{cases} \quad (3-4)$$

通过集合所有局部向量权重与局部特征的乘积，得到相同维度的全局特征向量：

$$\mathbf{a}_{glob,i} = \sum_j \mathbf{w}_{i,j} \mathbf{a}_{loc,j} \quad (3-5)$$

这个过程就是通过矩阵乘法来实现的，所有局部特征向量都会经历该过程。

设 N_{anc} 为锚线的个数。 $\mathbf{A}_{loc} = [\mathbf{a}_{loc,0}, \mathbf{a}_{loc,1}, \dots, \mathbf{a}_{loc,N_{anc}}]^T$ 为包含局部特征向量的矩阵， $\mathbf{W} = [\mathbf{w}_{i,j}]_{N \times N}$ 为公式 (3-4) 中定义的权重矩阵。因此，全局特征可以计算为：

$$\mathbf{A}_{glob} = \mathbf{W} \mathbf{A}_{loc} \quad (3-6)$$

式中： $\mathbf{A}_{glob}$ 和 $\mathbf{A}_{loc}$ 具有相同的维度，即 $\mathbf{A}_{glob} \in \mathbf{R}^{N_{anc} \times C_F \cdot H_F}$ 。

为生成最后的结果，通过连接 $\mathbf{a}_{loc,i}$ 和 $\mathbf{a}_{glob,i}$ 来聚合局部和全局信息，产生增强特征向量 $\mathbf{a}_{str,i} \in \mathbf{R}^{2 \cdot C_F \cdot H_F}$ 。然后将该向量传递到两个并行的全连接层，用于分类和回归。

3.3 数据集建立 (Dataset Creation)

3.3.1 数据集来源

本节数据集中图像主要来源于学校路段、厂区路段和施工路段。初期先通过采集校园内的车道线图像进行训练，中期在厂区附近采集了图像进一步扩大数据集，最后通过实地采集施工路段的车道线图像，匹配本文所研究的应用场景。

通过前往施工现场，实地考察施工道路下的环境。高速公路施工在半封闭的环境下进行，施工车道有工程车进行施工，隔壁车道正常通行，由交通锥隔开。而且施工路段往往是单车道，因此在获取路径经纬度坐标信息和路径规划的过程中只考虑单车道线，所以在后续的图像处理中，只对单条车道线进行图像标注，并且建立的数据集也是只考虑单车道线。本文获取道线图像采用上文介绍的路径采集小车搭载深度相机进行采集，并生成视频，通过代码截取为多帧包含车道线的图像，以供图像标注。其中，采集的数据集类型包括施工路段 500 张、校园路段 3000 张以及工厂附近路段 3000 张。总计 6500 张，并且包含了晴天、阴天的

早上、正午和傍晚等情况，图 3-6 展示了部分厂区附近车道线图像；图 3-7 展示了部分校园路段的车道线图像；图 3-8 展示了部分施工路段车道线图像。由于雨天不施工，故没有考虑雨天情景。



图 3-6 厂区附近车道线图像

Figure 3-6 Image of lane markings near the plant



图 3-7 校园路段车道线图像

Figure 3-7 Image of lane markings for campus road sections



图 3-8 施工路段车道线图像

Figure 3-8 Image of lane markings for campus road sections

3.3.2 图像标注

模型训练时，网络中采用损失函数来计算车道线真值与预测值之间的偏差，再通过权重得出最优解，实现这一过程需要对车道线图像进行标注并生成数据集，为深度学习训练提供数据支持。该数据集采用的标注软件为 Anaconda 中的 Labelme，该软件操作简单，且标注精确，图像标注界面如图 3-9 所示。标注的

目标主要是偏向视角右侧的单条车道线。




图 3-9 图像标注界面

Figure 3-9 Image annotation page

对每个图像标注完成后，会生成相应的 **Json** 文件，通过代码将所有 **Json** 文件转成一个 **Label** 文件，该文件包含数据集集中的像素点信息和图像文件夹所在位置，并用于模型训练。**Label** 文件如下图 3-10 所示。

```

"lanes": [[-2, -2, -2, -2, -2, -2, -2, -2, -2, -2, -2, -2, 2, 318, 326, 333, 341, 348, 356, 363, 370,
378, 385, 393, 400, 407, 415, 422, 430, 437, 445, 452, -2]], "h_samples": [140, 150, 160, 170, 180,
190, 200, 210, 220, 230, 240, 250, 260, 270, 280, 290, 300, 310, 320, 330, 340, 350, 360, 370, 380,
390, 400, 410, 420, 430, 440, 450, 460, 470, 480], "raw_file": "gt_image/0.jpg"]
"lanes": [[-2, -2, -2, -2, -2, -2, -2, -2, -2, -2, -2, -2, 318, 325, 333, 340, 347, 355, 362, 370,
377, 385, 392, 399, 407, 414, 422, 429, 436, 444, 451, -2]], "h_samples": [140, 150, 160, 170, 180,
190, 200, 210, 220, 230, 240, 250, 260, 270, 280, 290, 300, 310, 320, 330, 340, 350, 360, 370, 380,
390, 400, 410, 420, 430, 440, 450, 460, 470, 480], "raw_file": "gt_image/1.jpg"]
"lanes": [[-2, -2, -2, -2, -2, -2, -2, -2, -2, -2, -2, -2, 307, 313, 319, 325, 331, 336, 342, 348,
354, 360, 366, 372, 378, 383, 389, 395, 401, 407, 413, -2]], "h_samples": [140, 150, 160, 170, 180,
190, 200, 210, 220, 230, 240, 250, 260, 270, 280, 290, 300, 310, 320, 330, 340, 350, 360, 370, 380,
390, 400, 410, 420, 430, 440, 450, 460, 470, 480], "raw_file": "gt_image/100.jpg"]
"lanes": [[-2, -2, -2, -2, -2, -2, -2, -2, -2, -2, -2, -2, 328, 333, 337, 342, 347, 352, 357, 362,
367, 371, 376, 381, 386, 391, 396, 401, 405, 410, 415, -2]], "h_samples": [140, 150, 160, 170, 180,
190, 200, 210, 220, 230, 240, 250, 260, 270, 280, 290, 300, 310, 320, 330, 340, 350, 360, 370, 380,
390, 400, 410, 420, 430, 440, 450, 460, 470, 480], "raw_file": "gt_image/101.jpg"]
"lanes": [[-2, -2, -2, -2, -2, -2, -2, -2, -2, -2, -2, -2, 333, 338, 343, 347, 352, 357, 362,
367, 372, 377, 382, 387, 392, 397, 402, 407, 412, 416, -2]], "h_samples": [140, 150, 160, 170, 180,
190, 200, 210, 220, 230, 240, 250, 260, 270, 280, 290, 300, 310, 320, 330, 340, 350, 360, 370, 380,
390, 400, 410, 420, 430, 440, 450, 460, 470, 480], "raw_file": "gt_image/101.jpg"]

```

图 3-10 Label 文件

Figure 3-10 Label file

3.3.3 可视化结果

根据上述算法,在采集的数据集上进行模型训练,得到了相应的可视化结果,如图 3-11 所示。从图中,蓝线代表图像标注时的真值,红线为检测结果,可以看出,在检测车道线特征完整的情况下,例如实线或连续的虚线,检测的效果较好,一旦遇到如施工路径的磨损车道线,检测的结果与真值有较大偏差。

算法在模型建立时，设置的锚线数量过多，训练中需要的计算量增大了，导致算法的处理速度变慢，但强行减少锚线的生成来加速算法，也会导致精度的下降。所以既要保证算法的速度，也要保证精度，同时，还需提高算法在检测车道线特征不明显时的性能。




图 3-11 基于锚点的算法训练可视化结果

Figure 3-11 Anchor-based algorithm training visualization results

3.4 基于行分类与混合注意力机制的车道线检测算法的研究 (Research on Lane Detection Algorithm Based on Row Classification and Mixed Attention Mechanism)

针对车道线检测的速度和检测性能两个方面,完成道路车道线特征不明显情况下的车道线检测任务,在上文介绍算法的思路,受 UFLD 算法^[80]启发,设计了一种基于行分类和混合注意力机制的车道线检测算法。通过增加空间注意力机制和通道注意力机制,使模型更加关注车道线特征,获取特征图的空间信息,提取有用信息和特征;引入损失函数进行车道线预测,并未添加多余的计算量,但能提高模型预测的能力。

3.4.1 基于行分类的方式

(1) 方法概述

基于行分类的方式主要针对车道线特征不明显的情况,该方法主要在每个预定义行上位置进行分类来判断正确的车道线位置。如图 3-12 的示意图,车道线检测区域被划分为若干个网格,每个行上都存在落在车道线上的网格,那么车道线检测的任务就可以看作在行上将车道线的部分和无车道线的部分进行分类。与基于分割的方式不同的是,分割采用的是通道维度上逐个像素的选取,而行分类是在一系列的行上进行网格的选取。

另外,行分类通过预定义稀疏行位置,通道可以表示为每行的坐标。车道线图像被分为无车道线区域和车道线检测区域,车道线则被表示为行上的网格。




图 3-12 基于行分类方式示意图

Figure 3-12 Schematic diagram based on the row classification method

(2) 计算方式

通常检测的车道线图像大小用 $H \times W$ 表示,原始的图像分割方法,需要对 $(C+1)$ 维的 $H \times W$ 的特征进行分割,第 $(C+1)$ 维为无车道线的情况,而通过采用行分类的方式,只需处理 $(w+1)$ 维的 $C \times h$ 个特征分类,另外检测车道线数目为 1,所以 $C=1$ 。原本计算量为 $H \times W \times (C+1)$ 转化成 $C \times h \times (w+1)$ 。模型训练时,行上的网格数量可以人为进行设定, h 的大小可以进行调整,一般情况下, h 远小于图像像素高 H ,同样情况下, w 也远小于图像像素宽度 W ,因此利用行分类的方式,简化了计算的参量,降低计算的复杂度,提高算法处理速度。

3.4.2 算法网络结构

该车道线检测算法依然采用 ResNet-18 残差网络作为主干网络,加入特征映射,将图像特征传输到下一层网络,如图 3-13 所示为车道线检测算法网络结构,为了能够进一步提高特征提取的有效性和针对性,在主干网络 ResNet 基础上,添加空间注意力机制和通道注意力机制,称为混合注意力机制;然后将图像深度

特征送入两个分支，其中定位分支通过数学期望函数来定位车道线位置，存在分支通过存在损失函数预测每个行上车道线的存在性；最后输出模型训练结果。




图 3-13 算法网络结构

Figure 3-13 Algorithm network structure

引入混合注意力机制使模型更加关注车道线特征，使车道线检测更加纯粹的提取车道线的特征，而非过多关注车道信息。取消了辅助分割，该方式对算法性能提升较小，但会增加训练成本。混合注意机制提取最重要的特征，具体来说，将原始输入图像上采样四次，提取相对较浅的特征，再经过全局特征和更大的感知场，增加模型预测能力，提高网络在无视觉特征情况下的推理能力。

3.4.3 混合注意力机制

本节基于典型的 CBAM 模型^[81]进行改进，对于输入的特征图，图 3-14 为混合注意力模块，首先，通过通道注意力模块提取图像中重要的特征；其次，经过空间注意力模块处理后提取重要的空间信息；最后，得到特征结果，该方式提高了模型的表达能力和泛化性。




图 3-14 混合注意力模块

Figure 3-14 Convolutional block attention module

图 3-15 为通道注意力机制模块的具体信息，其主要原理是将注意力模块加入主干网络中的不同卷积层位置，根据每个通道特征向量与检测任务目标的相关程度，为每个局部特征向量赋予相应的权重。以此来提取重要特征，并忽略不重要的信息。




图 3-15 通道注意力模块

Figure 3-15 Channel attention module

通道注意力模块主要计算流程如下：

输入的特征图尺寸为高 H 、宽 W 和通道 C ，将其在特征域进行全局最大值池化和全局平均值池化，并获得全局描述的特征，表示为：

$$G(X) = \frac{1}{WH} \sum_{i=1}^H \sum_{j=1}^W X_{i,j} \quad (3-7)$$

$$M(X) = \max X_{i,j} \quad (3-8)$$

式中： $G(X)$ 为全局平均池化表达式， $M(X)$ 为全局最大池化表达式。 $X_{i,j}$ 表示输入特征图 X 第 i 行、 j 列的像素值。

其中，全局最大池化只会保留最大值特征的信息，而舍弃区域内最大值之外的特征信息。全局平均池化会对区域内的特征元素进行平均值的计算，并保留空间背景特征信息。

输入特征图通道数量为 C ，可以计算出一维的卷积核 k 。通过一维卷积核进行通道之间的信息传递，再利用自适应函数求解卷积核大小，确定增加或减少通道之间的交互，卷积核表达式为：

$$k = \psi(C) = \left\lfloor \frac{\log_2(C)}{\gamma} + \frac{b}{\gamma} \right\rfloor \quad (3-9)$$

式中：设置 $\gamma = 2$ ， $b = 1$ 。

分别对 $G(X)$ 和 $M(X)$ 进行通道卷积，得到卷积结果表达式为：

$$w_{1,i} = \sum_{j=1}^k \alpha^j G_i^j, G_i^j \in \Omega_{1,i}, i \in C \quad (3-10)$$

$$w_{2,i} = \sum_{j=1}^k \alpha^j M_i^j, M_i^j \in \Omega_{2,i}, i \in C \quad (3-11)$$

式中： α^j 为一维卷积核第 j 个元素， $\Omega_{1,i}$ 和 $\Omega_{2,i}$ 为 $G(X)$ 和 $M(X)$ 相邻 k 个通道的元素集合， G_i^j 、 M_i^j 分别为第 i 个通道中的第 j 个通道中的元素。

得到卷积的结果后，采用 Sigmoid 函数激活函数进行归一化，再求平均值得

到 $1 \times 1 \times C$ 的张量，它的权重表达为：

$$\omega_{1,i} = \sigma w_{1,i} \quad (3-12)$$

$$\omega_{2,i} = \sigma w_{2,i} \quad (3-13)$$

$$\omega_{avg,i} = \frac{\omega_{1,i} + \omega_{2,i}}{2} \quad (3-14)$$

式中， σ 为 Sigmoid 函数， $\omega_{avg,i}$ 为通道 i 的权重。其中 Sigmoid 的函数曲线如图 3-16 所示。




图 3-16 Sigmoid 函数

Figure 3-16 Sigmoid function

最后，将所有的通道权重与其对应的特征通道相乘，输出最后的结果。

在计算得到经过通道注意力得到的图像特征信息，紧接着串联空间注意力，这样能使特征提取过程中更加关注图像中物体的空间位置。图 3-17 为空间注意力机制模块，通过在空间域上进行最大池化和平均池化，将获取两个二维向量拼接，与通道注意力机制类似的是，也是将得到的权重矩阵与对应输入的特征向量相乘，最后得到特征信息结果。

经过混合注意力模块处理后，模型得到了更丰富的全局信息，使得后续的分类检测任务更关注检测目标的特征，并且可以利用全局特征信息进行预测，进一步提升网络的整体性能。




图 3-17 空间注意力机制模块

Figure 3-17 Spatial attention mechanism module

通过混合注意力机制，使模型能够提取更加丰富的全局信息，有利于后续分类，利用全局信息对车道线的位置进行预测。

3.4.4 损失函数

损失函数是车道线检测的关键部分之一，主要作用是将真值数据与预测数据量化，得到偏差用于评估模型整体性能。通过最小化损失函数，使检测模型预测更加精确。

经过主干和注意力机制模块后的特征，经过深度特征平坦化，送入两个分支中，两个分支表达式为：

$$P, E_m = f_m(X) \quad (3-15)$$

式中： X 为图像的深度特征，预测网络分为定位分支 P 和存在分支 E 。深度特征经过平坦化，可以提高深度特征质量。

定位分支输出 P_m ，表示第 m 行车道线网格选取的预测值，维度为 $w+1$ ，用于学习分类表示的网格位置，可以得到基于分类损失为：

$$L_{cls} = \sum_{m=1}^h L_{CE}(P_m, T_{cls,m}) \quad (3-16)$$

式中： L_{CE} 为交叉熵损失， h 为行框数量， $T_{cls,m}$ 表示第 m 行定位分支的学习目标。

通过有序的分类，能够解决车道线位置概率的问题，数学期望表示为：

$$\text{Exp}_m = \sum_{k=1}^w \text{Prob}_m[k] \cdot k \quad (3-17)$$

式中： w 为行上网格数量， $[\cdot]$ 为索引操作符， Prob_m 为每个位置存在车道线的概率，采用 softmax 函数定义为：

$$\text{Prob}_m = \text{softmax}(P_m) \quad (3-18)$$

在期望的约束下，使预测尽量接近真实情况，通常有以下期望损失：

$$L_{exp} = \sum_{m=1}^h L_1(\text{Exp}_m, T_{cls,m}) \quad (3-19)$$

式中： $L_1(\cdot)$ 为平滑损耗。期望损失能够预测分布的数学期望趋向于地面真实位置，从而能够准确的定位车道位置。

另外存在分支的损失定义为：

$$L_{ext} = \sum_{m=1}^h L_{CE}(E_m, T_{ext,m}) \quad (3-20)$$

式中：存在分支输出 E_m ，表示存在分支的预测值， $T_{ext,m}$ 表示第 m 行存在分支的学习目标，根据式 (3-17)，(3-18)，过滤无车道线的情况的表达式为：

$$Loc_m = \begin{cases} \sum_{k=1}^w \text{Prob}_m[k] \cdot k, E_m[2] > E_m[1] \\ -1, \text{otherwise} \end{cases} \quad (3-21)$$

根据式 (3-16)、(3-19)、(3-20) 可以得到损失总和 L :

$$L = L_{cls} + \alpha L_{exp} + \beta L_{ext} \quad (3-22)$$

式中: α , β 为损耗系数。

3.5 实验结果与分析 (Experimental Results and Analysis)

本节主要对上述的制作的数据集进行训练, 根据相关的评价指标检验模型的精度, 证明算法的有效性; 对可视化结果进行分析, 得出相关结论。

3.5.1 实验评价指标

模型训练的评价指标通常可以用精度 (*Accuracy*)、召回率 (*Recall*)、交并比 (*IOU*) 和 *F1-measure* 等指标用来评价, 检测速度用每秒帧数 (*FPS*) 表述。其中 *F1-measure* 其实是 *F-measure* 的一个特殊形式, 而 *F-measure* 最初是用来综合精度 (*Accuracy*) 与召回率 (*Recall*) 的。一般情况下, 训练模型的 *F1* 值越高代表目标检测的效果越好, 也代表检测结果更接近理想的状态。*FPS* 值越大, 模型检测速度越快, 其在一秒内处理的图像数量也就越多。

本文采用 Tusimple 数据集评价指标, 其中包含三个标准指标, 分别为精度 (*Accuracy*)、错误发现率 (*FDR*), 错误阴性率 (*FNR*)^[82]。精度 (*Accuracy*) 定义为:

$$Accuracy = \frac{\sum_{clip} C_{clip}}{\sum_{clip} S_{clip}} \quad (3-23)$$

式中: C_{clip} 为在片段中车道线点预测正确的数量, S_{clip} 为图像片段中的总点数。其中预测值与地面真值在 20 像素以内会被认定为正确预测。

另外, *F1* 指数为精度 (*Accuracy*) 和召回率 (*Recall*) 的均值。

3.5.2 实验参数设置

本章实验的数据集是自主采集的车道线数据集, 其中训练集 6500 张, 测试集 2000 张。图像分辨率为 1280×720 。深度学习框架为 PyTorch, 深度学习训练在多卡服务器上进行, 主要语言为 Python3.6, 具体配置信息如表 3-1 所示。

对于数据设置, 将图像像素尺寸缩放到 640×360 , 同时采用数据增强手段。采用 Adam 优化器, 训练 Epoch 为 100 代, 初始学习率 0.0001, 批处理大小为 8, 行数量 h 设置为 22, 单元格 w 数量设置为 150, 车道线数目为 1。

表 3-1 训练实验的机器配置

Table 3-1 Machine configuration for the training experiment

名称	具体信息
处理器	Intel(R) Xeon(R) W-2265 CPU @ 3.50GHz
内存	32G
显卡	NVIDIA GeForce RTX 3090
操作系统	Ubuntu 18.04
编译软件	PyCharm
CUDA	CUDA11.4

3.5.3 实验可视化结果与分析

为了验证车道线检测算法的可行性,将自主制作的数据集在本文设计的基于行分类与混合注意力机制算法上进行训练,并与经典算法 SCNN^[91]与 SAD^[92]算法进行对比,得到如表 3-2 所示的参数结果。本文算法在精度 (*Accuracy*) 指标上略低于另外两种算法,但处理速度较快,并且 F1 值达到 96.79%,证明目标检测效果较好。

表 3-2 训练结果各项参数

Table 3-2 Parameters of the training results

	<i>F1</i>	<i>Accuracy</i>	<i>FDR</i>	<i>FNR</i>	<i>FPS</i>
SCNN	95.97%	96.53%	0.06	0.02	8
SAD	95.92%	96.64%	0.06	0.02	75
本文算法	96.79%	95.59%	3.66	3.21	310

经过模型训练后,得到车道线检测的可视化结果,图 3-18、图 3-19、图 3-20 分别展示了厂区路段、校园路段和施工公路的车道线检测效果。



图 3-18 厂区路段检测效果

Figure 3-18 Detection effect of the factory section



图 3-19 学校路段检测效果

Figure 3-19 Detection effect of school road sections



图 3-20 施工路段检测效果

Figure 3-20 Detection effect of construction section

从图可以看出，对于车道线是虚线、有人员遮挡住车道线的情况，依然能够准确地检测出车道线。另外在高速公路场景下，部分车道线特征不明显的情况，检测识别效果较好。

3.6 本章小节（Brief Summary of the Chapter）

本章针对施工道路车道线检测待解决的问题，首先采用一种基于锚点的车道线检测算法，该算法通过聚合局部信息和全局信息完成车道线检测，经过自主采集车道线图像数据集训练验证后，发现该算法在检测车道线特征明显的情况下表现良好，但遇到车道线特征不明显情况检测效果不佳；为此，设计一种基于行分类与混合注意力机制的车道线检测算法，该算法通过预定义行上位置进行分类来判断正确的车道线位置，并引入混合注意力机制，加强模型的表达能力和泛化性，利用损失函数提高模型预测的准确性；最后，对该算法进行训练实验，训练结果表明：精度 *Accuracy* 达到 96.79%，*FPS* 达到 310，检测的可视化结果较好。

4 多传感器融合定位技术的研究

4 Research on Multi-sensor Fusion Localization Technology

本文介绍的系统采用了视觉/惯性/轮式里程计技术，在未知先验信息的环境下，采用多种传感器得到不同的数据信息，估计当前状态下的位置与姿态，完成对系统实时定位。首先，介绍了视觉惯性轮式里程计的基本理论，包括坐标系的定义、定位坐标转换以及姿态的表达方式；其次，对传感器进行特性分析，主要为相机、IMU 模型，车道线图像成像原理，相机、IMU 的标定参数以及 IMU、车轮的预积分；然后，提出了一种基于优化的视觉惯性里程计紧耦合系统，为有效地估计系统的所有初始状态变量，提出一种静态初始化和动态初始化相结合的方法，为实现局部帧与局部直角坐标系（ENU）坐标之间的转换，将局部状态信息与全球导航卫星系统（GNSS）测量信息进行融合，为保证惯性测量单元与车轮速度计的同时性，采用噪声重估计方法；最后，在公开数据集和自主采集数据集上验证定位系统的性能。

4.1 坐标系（Coordinate System）

本节主要对定位系统中各坐标系的建立和坐标系之间的转换进行阐述。视觉/惯性/轮式里程计系统中主要的坐标系有相机坐标系、世界坐标系、IMU 坐标系、车轮坐标系、图像坐标系和 ENU 坐标系，具体坐标系示意图如图 4-1 所示。为了能够获取车辆在运动过程中的各种定位参数，下文对上述坐标系进行定义，保证后续坐标系转换后的参数一致。

（1）相机坐标系

相机坐标系主要用于描述相机的具体位置，其将图像坐标系与世界坐标系建立起关系。其原点以相机的光心为基准，以相机的正右方、正下方和正前方为其 X^c , Y^c , Z^c 三个坐标轴。

（2）世界坐标系

世界坐标 WGS84，即经纬度坐标，作为表达地面真实位置和姿态的世界坐标系，实际应用过程中，需要将 WGS84 坐标进行转换，转换成适合计算的坐标系。世界坐标系三坐标轴分别表示为 X^w , Y^w , Z^w 。

（3）IMU 坐标系

IMU 坐标系主要用于描述惯性测量单元的三维空间信息。理想条件下，IMU 坐标系的原点与载体的质心重合。由于 IMU 质心和载体质心产生的杆臂效应在视觉惯导定位系统中（VIO）可以忽略，所以一般将 IMU 坐标系与载体重合。其

坐标轴分别表示为 X^I , Y^I , Z^I 。

(4) 车轮坐标系

车轮坐标系用于表示车轮运动状态。坐标轴的原点为两侧车轮的轴心。用 X^O , Y^O , Z^O 来表示车轮的坐标信息。

(5) ENU 坐标系

ENU 坐标系为东北天坐标, 是一种地理坐标系, 以观测者所在位置为原点建立的坐标系, 用于描述地球上定位物体的位置和方向。ENU 代表东 (East)、北 (North) 和上 (Up), 分别表示坐标系的三个轴 X^E , Y^E , Z^E 。 X^E 指向东方向, Y^E 指向北方向, Z^E 指向天空。本文视觉-惯性-车轮里程计融合定位方案选择指定位置的 ENU 坐标系作为定位位置和位姿的参考系。

(6) 图像坐标系

图像坐标系用于描述视觉特征在图像中的像素位置, 其坐标轴定义采用 u 轴和 v 轴表示, 以图像左上顶点为原点, 沿上边界为 u 轴, 左边界为 v 轴。




图 4-1 传感器坐标系示意图

Figure 4-1 Schematic diagram of the sensor coordinate system

4.2 姿态参数化 (Attitude Parameterization)

姿态指两坐标系之间的相对旋转关系, 因为存在旋转的不可交互性, 姿态参数化计算会变得复杂。本节主要对姿态参数化方式进行介绍, 内容主要包含旋转矩阵、旋转矢量和四元数的姿态参数化方式, 以及参数之间的转换关系。

4.2.1 旋转矩阵

对于车辆的位姿定义时, 需要对刚体在三维空间的运动进行描述, 这些运动可以拆解为旋转或平移。定位系统中包含了多个传感器坐标系, 在融合定位时, 需要考虑三维空间下的刚体模型在不同坐标系下的转换关系, 同时在三维空间运

动中, 保证同一向量在不同坐标系变换, 夹角和长度不变, 这种变换被称为欧式变换, 示意图如图 4-2 所示。




图 4-2 坐标变换

Figure 4-2 Coordinate transformation

对于三维空间中的向量 $\mathbf{a}$, 变换前后两坐标系下的坐标分别为 $(\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3)^T$ 和 $(\mathbf{a}'_1, \mathbf{a}'_2, \mathbf{a}'_3)^T$ 。一组正交基 $(\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3)$ 经过旋转转换为另一组正交基 $(\mathbf{e}'_1, \mathbf{e}'_2, \mathbf{e}'_3)$ 。坐标系旋转后, 向量 $\mathbf{a}$ 的空间位置不会发生改变, 有如下式 (4-1):

$$(\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3) \begin{pmatrix} \mathbf{a}_1 \\ \mathbf{a}_2 \\ \mathbf{a}_3 \end{pmatrix} = (\mathbf{e}'_1, \mathbf{e}'_2, \mathbf{e}'_3) \begin{pmatrix} \mathbf{a}'_1 \\ \mathbf{a}'_2 \\ \mathbf{a}'_3 \end{pmatrix} \quad (4-1)$$

上式左右两边同时左乘 $(\mathbf{e}_1^T, \mathbf{e}_2^T, \mathbf{e}_3^T)^T$, 得:

$$\begin{pmatrix} \mathbf{a}_1 \\ \mathbf{a}_2 \\ \mathbf{a}_3 \end{pmatrix} = \begin{pmatrix} \mathbf{e}_1^T \mathbf{e}'_1 & \mathbf{e}_1^T \mathbf{e}'_2 & \mathbf{e}_1^T \mathbf{e}'_3 \\ \mathbf{e}_2^T \mathbf{e}'_1 & \mathbf{e}_2^T \mathbf{e}'_2 & \mathbf{e}_2^T \mathbf{e}'_3 \\ \mathbf{e}_3^T \mathbf{e}'_1 & \mathbf{e}_3^T \mathbf{e}'_2 & \mathbf{e}_3^T \mathbf{e}'_3 \end{pmatrix} \begin{pmatrix} \mathbf{a}'_1 \\ \mathbf{a}'_2 \\ \mathbf{a}'_3 \end{pmatrix} \triangleq \mathbf{R} \begin{pmatrix} \mathbf{a}'_1 \\ \mathbf{a}'_2 \\ \mathbf{a}'_3 \end{pmatrix} \quad (4-2)$$

式中: $\mathbf{R}$ 为旋转矩阵, 描述同一向量经过坐标系旋转后的变化过程。通常情况下, 位置表示为三维向量 $\mathbf{t} \in \mathbb{R}^3$, 旋转矩阵 $\mathbf{R} \in \mathbb{R}^{3 \times 3}$, 向量 $\mathbf{a}$ 经过旋转矩阵变换和平移 $\mathbf{t}$ 后, 得到向量 $\mathbf{a}'$, 表示为:

$$\mathbf{a}' = \mathbf{R}\mathbf{a} + \mathbf{t} = \mathbf{R} \begin{pmatrix} \mathbf{a}_1 \\ \mathbf{a}_2 \\ \mathbf{a}_3 \end{pmatrix} + \mathbf{t} \quad (4-3)$$

式中: 行列式为 1 的正交矩阵也为旋转矩阵, 旋转矩阵的集合为特殊正交群 $\text{SO}(n)$, 如下式所示。

$$\text{SO}(n) = \{\mathbf{R} \in \mathbb{R}^{n \times n} \mid \mathbf{R}\mathbf{R}^T = \mathbf{I}, \det(\mathbf{R}) = 1\} \quad (4-4)$$

n 表示集合由 n 维的旋转矩阵组成, 则 $\text{SO}(3)$ 代表三维空间下旋转矩阵的集合。通过引入齐次矩阵和变换矩阵, 能够简单描述多次变换, 如式 (4-5) 所示:

$$\begin{bmatrix} \mathbf{a}' \\ 1 \end{bmatrix} = \begin{bmatrix} \mathbf{R} & \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix} \begin{bmatrix} \mathbf{a} \\ 1 \end{bmatrix} \stackrel{\text{def}}{=} \mathbf{T} \begin{bmatrix} \mathbf{a} \\ 1 \end{bmatrix} \quad (4-5)$$

式中：在同一向量后末尾添加 1，使其变为一个四维向量，称为齐次坐标。 $\mathbf{T}$ 为变换矩阵，它的左上角为旋转矩阵，右上角为平移向量，左下角为 $\mathbf{0}$ 向量，右下角为 1，它的集合称为特殊欧式群 $\text{SE}(n)$ ，由式（4-6）表示：

$$\text{SE}(3) = \left\{ \mathbf{T} = \begin{bmatrix} \mathbf{R} & \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix} \in \mathbb{R}^{4 \times 4} \mid \mathbf{R} \in \text{SO}(3), \mathbf{t} \in \mathbb{R}^3 \right\} \quad (4-6)$$

式中： $\text{SO}(3)$ 中含有 9 个元素，但是三维空间中的旋转自由度为 3，远达不到 9，这会导致出现多余的计算。

4.2.2 旋转向量

当需要一个旋转向量来表示旋转运动时，通常采用轴-角表示的方法。与旋转矩阵相比，旋转向量的三个元素表示三维空间三自由度的旋转，同时，加上三维空间的平移向量，实现六自由度的运动。通过采用罗德里格斯公式将旋转向量转换为旋转矩阵的表达式为：

$$\mathbf{V} = \cos \theta \mathbf{I} + (1 - \cos \theta) \mathbf{n} \mathbf{n}^T + \sin \theta \mathbf{n}^\wedge \quad (4-7)$$

式中：旋转向量为 $\mathbf{V}$ ， θ 为旋转角度， $\mathbf{I}$ 为单位矩阵， $\mathbf{n}$ 为轴方向的单位向量， $\mathbf{n}^\wedge$ 为向量 $\mathbf{n}$ 的反对称矩阵。

4.2.3 欧拉角

上述的旋转矩阵和旋转向量描述旋转运动的方式通常不直观，可以采用欧拉角表示三维空间的旋转运动。欧拉角由三个角度组成，分别为俯仰角（pitch）、偏航角（yaw）和翻滚角（roll），表示绕 Z ， Y ， X 轴旋转的角度。那么三维空间中的旋转运动就可以通过采用三维向量 $[r, p, y]^T$ 来表示，且旋转后对应轴的逆时针方向为正向。欧拉角与旋转向量类似，同样采用三个元素表示三自由度的旋转。

翻滚角（roll）表示刚体绕坐标系 X 轴旋转的角度，三维空间中，刚体围绕坐标系 X 轴旋转 α 度，姿态变换矩阵可以表示为：

$$\mathbf{R}_x(\alpha) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \alpha & \sin \alpha \\ 0 & -\sin \alpha & \cos \alpha \end{bmatrix} \quad (4-8)$$

俯仰角（pitch）表示刚体绕坐标系 Y 轴旋转的角度，三维空间中，刚体围绕坐标系 Y 轴旋转 β 度，姿态变换矩阵可以表示为：

$$\mathbf{R}_Y(\beta) = \begin{bmatrix} \cos \beta & 0 & -\sin \beta \\ 0 & 1 & 0 \\ \sin \beta & 0 & \cos \beta \end{bmatrix} \quad (4-9)$$

偏航角 (yaw) 表示刚体绕坐标系 Z 轴旋转的角度, 三维空间中, 刚体围绕坐标系 Z 轴旋转 γ 度, 姿态变换矩阵可以表示为:

$$\mathbf{R}_Z(\gamma) = \begin{bmatrix} \cos \gamma & \sin \gamma & 0 \\ -\sin \gamma & \cos \gamma & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad (4-10)$$

4.2.4 四元数

除了利用矩阵来表述旋转的方式, 还可以采用四元数来表述。四元数通过复数平面上两个复数的乘积来表示二维平面的旋转, 将空间中的旋转描述为定轴运动, 另外它还是一种既紧凑又没有奇异性的方式。

四元数由一个实部和三个虚部组成, 具体表示方式为:

$$\mathbf{q} = q_0 + q_1 i + q_2 j + q_3 k = \begin{bmatrix} q_w \\ \mathbf{q}_v \end{bmatrix} \quad (4-11)$$

式中: q_0, q_1, q_2, q_3 为实数, i, j, k 为虚数单位, 它们之间的关系如下:

$$i^2 = j^2 = k^2 = ijk = -1 \quad (4-12)$$

$$\begin{cases} ij = -ji = k \\ jk = -kj = i \\ ki = -ik = j \end{cases} \quad (4-13)$$

任意两个四元数 $\mathbf{p}$ 和 $\mathbf{q}$, 相乘得到运算结果为:

$$\mathbf{p} \otimes \mathbf{q} = \begin{bmatrix} p_w q_w - \mathbf{p}_v^T \mathbf{q}_v \\ p_w \mathbf{q}_v + q_w \mathbf{p}_v + \mathbf{p}_v \times \mathbf{q}_v \end{bmatrix} \quad (4-14)$$

当需要计算两坐标系的变换可以定义四元数的左右算子来求解, 如下所示:

$$\mathbf{q}_L = \begin{bmatrix} q_0 & -q_1 & -q_2 & -q_3 \\ q_1 & q_0 & -q_3 & q_2 \\ q_2 & q_3 & q_0 & -q_1 \\ q_3 & -q_2 & q_1 & q_0 \end{bmatrix} \quad (4-15)$$

$$\mathbf{q}_R = \begin{bmatrix} q_0 & -q_1 & -q_2 & -q_3 \\ q_1 & q_0 & q_3 & -q_2 \\ q_2 & -q_3 & q_0 & q_1 \\ q_3 & q_2 & -q_1 & q_0 \end{bmatrix} \quad (4-16)$$

假设相机坐标系绕轴 $\mathbf{q} = (0, q_1, q_2, q_3)$ 旋转 θ 角后得到 IMU 坐标系。向量之间关系如下：

$$\begin{cases} \mathbf{R}^i = \mathbf{q} \otimes \mathbf{R}^c \otimes \mathbf{q}^* \\ \mathbf{R}^i = \mathbf{0} + \mathbf{r}^i \\ \mathbf{R}^c = \mathbf{0} + \mathbf{r}^c \\ \mathbf{q} = \cos \frac{\theta}{2} + \mathbf{q} \sin \frac{\theta}{2} \end{cases} \quad (4-17)$$

式中： $\mathbf{R}^c$ 为相机坐标系下的向量， $\mathbf{r}^i$ 为测量向量。 $\mathbf{R}^c$ 和 $\mathbf{R}^i$ 是对应向量 $\mathbf{r}^i$ 和 $\mathbf{r}^c$ 的四元数。

根据四元数的左右算子计算出相机坐标系到 IMU 坐标系的变换矩阵，相应的四元数矩阵关系为：

$$\begin{aligned} \mathbf{q} \otimes \mathbf{R} \otimes \mathbf{q}^* &= \mathbf{q}_L \cdot \mathbf{q}_R \cdot \mathbf{R} \\ &= \begin{bmatrix} q_0 & -q_1 & -q_2 & -q_3 \\ q_1 & q_0 & -q_3 & q_2 \\ q_2 & q_3 & q_0 & -q_1 \\ q_3 & -q_2 & q_1 & q_0 \end{bmatrix} \cdot \begin{bmatrix} q_0 & -q_1 & -q_2 & -q_3 \\ q_1 & q_0 & q_3 & -q_2 \\ q_2 & -q_3 & q_0 & q_1 \\ q_3 & q_2 & -q_1 & q_0 \end{bmatrix} \cdot \begin{bmatrix} 0 \\ r_1 \\ r_2 \\ r_3 \end{bmatrix} \\ &= \begin{bmatrix} * & 0 & 0 & 0 \\ * & q_0^2 + q_1^2 - q_2^2 - q_3^2 & 2(q_1 q_2 - q_0 q_3) & 2(q_1 q_3 + q_0 q_2) \\ * & 2(q_1 q_2 + q_0 q_3) & q_0^2 - q_1^2 + q_2^2 - q_3^2 & 2(q_2 q_3 - q_0 q_1) \\ * & 2(q_1 q_3 - q_0 q_2) & 2(q_2 q_3 + q_0 q_1) & q_0^2 - q_1^2 - q_2^2 + q_3^2 \end{bmatrix} \cdot \begin{bmatrix} 0 \\ r_1 \\ r_2 \\ r_3 \end{bmatrix} \end{aligned} \quad (4-18)$$

由式 (4-17)，(4-18) 确定两坐标系转换矩阵为：

$$\mathbf{R}_c^i = \begin{bmatrix} 1 - 2(q_2^2 + q_3^2) & 2(q_1 q_2 - q_0 q_3) & 2(q_1 q_3 + q_0 q_2) \\ 2(q_1 q_2 + q_0 q_3) & 1 - 2(q_1^2 + q_3^2) & 2(q_2 q_3 - q_0 q_1) \\ 2(q_1 q_3 - q_0 q_2) & 2(q_2 q_3 + q_0 q_1) & 1 - 2(q_1^2 + q_2^2) \end{bmatrix} \quad (4-19)$$

4.3 定位坐标转换 (Positioning Coordinate Conversion)

为了对路面实际位置与预估位置进行对比，得到定位误差，评估系统的性能，需要将坐标信息统一归算到同一坐标系下，而路径采集小车获取的经纬度坐标信息是基于 WGS84 大地坐标系的，所以将 WGS84 坐标转换为东-北-天坐标，方便进行对比和分析。

4.3.1 WGS84 大地坐标系转为地心地固坐标系

设 WGS84 大地坐标系下坐标点表示为 $P_i(\gamma_i^w, \phi_i^w, h_i^w)$ ， $i \in [1, n]$ ， n 为采集坐标点的个数。经过 WGS84 直角坐标转换，转变为 WGS84 直角坐标系下的坐标点 (x_i^w, y_i^w, z_i^w) ，变换形式如下：

$$\begin{aligned}
x_i^w &= (N + h_i^w) \times \cos \varphi_i^w \times \cos \gamma_i^w \\
y_i^w &= (N + h_i^w) \times \cos \varphi_i^w \times \sin \gamma_i^w \\
z_i^w &= [N(1 - e^2) + h_i^w] \times \sin \varphi_i^w
\end{aligned} \quad (4-20)$$

式中: WGS84 大地坐标系其实为一个椭球坐标系, 相应的椭球参数分别有: 长半径为 6378137m, 短半径为 6356752.3142m, 椭球扁率为 $\alpha=1/298.2572236$, 椭球的第一偏心率 $e = \sqrt{2f - 1} / f$, 第一辅助系数为 $W = \sqrt{1 - e^2 \times \sin^2 \varphi_i^w}$, 椭球面卯酉圈的曲率半径 $N = a / W$ 。

4.3.2 地心地固坐标系转为东北天坐标系

WGS84 大地坐标系转换到地心地固坐标系后, 再将地心地固坐标系 (ECEF) 转换到东-北-天坐标系 (ENU)。图 4-3 展示了 ECEF 坐标系与 ENU 坐标系。




图 4-3 ECEF 坐标系与 ENU 坐标系示意图

Figure 4-3 ECEF coordinate system and ENU coordinate system

设载体坐标系原点经纬高坐标为 $P_0(\gamma_0^w, \varphi_0^w, h_0^w)$, 其中 ECEF 坐标为 (x_0^w, y_0^w, z_0^w) , 某坐标点在 ECEF 坐标系下为 (x_k^w, y_k^w, z_k^w) , 对应东-北-天坐标系下坐标点为 (x_k^e, y_k^e, z_k^e) , 表达式为:

$$\begin{bmatrix} x_k^e \\ y_k^e \\ z_k^e \end{bmatrix} = \begin{bmatrix} -\sin \gamma_0^w & \cos \gamma_0^w & 0 \\ -\sin \varphi_0^w \cos \gamma_0^w & -\sin \varphi_0^w \sin \gamma_0^w & \cos \varphi_0^w \\ \cos \varphi_0^w \cos \gamma_0^w & \cos \varphi_0^w \sin \gamma_0^w & \sin \varphi_0^w \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta y \\ \Delta z \end{bmatrix} \quad (4-21)$$

$$\begin{bmatrix} \Delta x \\ \Delta y \\ \Delta z \end{bmatrix} = \begin{bmatrix} x_k^w \\ y_k^w \\ z_k^w \end{bmatrix} - \begin{bmatrix} x_0^w \\ y_0^w \\ z_0^w \end{bmatrix} \quad (4-22)$$

多传感器定位系统输出世界坐标系下的定位位置信息, 将其转换为 ECEF 坐标系下的坐标信息, 对应的大地坐标为 $(\gamma_c^w, \varphi_c^w, h_c^w)$, 参考大地坐标为

$(\gamma_t^w, \phi_t^w, h_t^w)$ ，东-北-天方向位置误差为：

$$\begin{cases} \delta p_e = (M + h_t^w) \delta \lambda \cos \phi_t^w \\ \delta p_n = (N + h_t^w) \delta \phi_i^w \\ \delta h = h_c^w - h_t^w \end{cases} \quad (4-23)$$

式中： $\delta \gamma_i^w = \gamma_c^w - \gamma_t^w$ 为经度误差， $\delta \phi_i^w = \phi_c^w - \phi_t^w$ 为纬度误差， r_n 表示卯酉面曲率半径， r_m 表示子午面曲率半径，表达式为：

$$r_m = \frac{r_n (1 - e^2)}{1 - e^2 \sin^2 \phi_i^w} \quad (4-24)$$

定位位置的均方根误差为：

$$RMSE = \sqrt{\sum_i^N \|\delta p^E(t_i^w)\|^2 / r_n} \quad (4-25)$$

式中： $\delta p^E = [\delta p_e, \delta p_n, \delta h]^T$ 。

4.4 相机模型（Camera Model）

本节主要介绍了相机坐标系下的车道线提取过程和畸变模型。进行相机标定，获取相机的内参，并矫正偏差。另外，相机拍摄的图像，是由众多像素点集合组成，每个像素反映色彩、亮度等信息。反射光强调决定像素点的亮度，三维空间中物体与相机的位置关系和相机的内部结构决定了像素点在成像平面的位置。

4.4.1 相机坐标系下的车道线提取过程

深度相机采用针孔成像原理，利用中心投影变换，将三维的物体转变为二维的图像。定义空间中的世界坐标系下的坐标为 $(x_w, y_w, z_w)^T$ ，在相机坐标系下的坐标为 $(x_c, y_c, z_c)^T$ 。通过旋转和平移矩阵表达点在相机坐标系下的坐标点：

$$\begin{bmatrix} x_c \\ y_c \\ z_c \end{bmatrix} = \mathbf{R} \begin{bmatrix} x_w \\ y_w \\ z_w \end{bmatrix} + \mathbf{t} \quad (4-26)$$

相机采集到包含车道线的图像后，采用图像坐标系中的像素坐标点来确定车道线位置，此时需要将图像坐标系下的车道线像素坐标点转换到相机坐标系下，以此获得车道线在三维世界下的坐标位置信息，通常采用单应性变换实现。

如图 4-4 所示，当采用车道线检测技术，对路径车道线的像素坐标进行提取后，此时车道线位于像平面坐标系，相机以光心位置为其坐标系的原点。




图 4-4 像平面与地平面之间的变换示意图

Figure 4-4 Schematic diagram of the transformation between the image plane and the ground plane

设特征点坐标为 $(u_i, v_i)^T$, 在相机坐标系下坐标点为 $(x_c, z_c)^T$, 通过最小二乘的方式可以得到相应的表达式:

$$s \begin{bmatrix} x_c \\ z_c \\ 1 \end{bmatrix} = \underbrace{\begin{bmatrix} h_1 & h_2 & h_3 \\ h_4 & h_5 & h_6 \\ h_7 & h_8 & 1 \end{bmatrix}}_H \begin{bmatrix} u_i \\ v_i \\ 1 \end{bmatrix} \Rightarrow \begin{cases} X = \frac{h_1 \cdot u_i + h_2 \cdot v_i + h_3}{h_7 \cdot u_i + h_8 \cdot v_i + 1} \\ Z = \frac{h_4 \cdot u_i + h_5 \cdot v_i + h_6}{h_7 \cdot u_i + h_8 \cdot v_i + 1} \end{cases} \quad (4-27)$$

式中: H 为单应性矩阵, 其中含有 8 个参数, 需要利用图像中车道线 4 个特征点来求解。双目相机通过标定的方式得到左右相机之间的相对关系, 然后采用双目交会的方式, 获取地面坐标点在单目坐标系下的坐标位置。

理论上, 相机、车辆和路面的相对关系不发生改变, 采用上述方式, 可以实现每一帧图像中车道线的定位信息变换, 但应用过程中, 可能出现相对关系发生改变的情况, 仍然需要通过重新计算单应性矩阵来保证定位信息变换的准确性。另外, 将相机固定在载体上, 相机的视场角和高度不发生变化, 与地面夹角恒定, 所以, 每帧图像像素坐标系中 Y 轴是不变的。

局部定位系统通过组合解算, 惯导输出位置和姿态信息, 通过惯导与相机之间的三维变换关系, 获取当前图像帧下相机的 ECEF 坐标系定位信息, 另外, 每帧图像得到一个 ECEF 坐标点, 连续的图像数据序列可以获取完整连续的车道线坐标信息。

总的来说, 通过相机作为媒介, 实现车道线坐标信息从地面到世界坐标系的转换。

4.4.2 相机畸变模型

另外, 相机在安装过程中, 相机的感光片和镜头没有保持平行, 会导致相机

出现径向和切向的畸变现象，影响相机的成像功能。如图 4-5 展示了径向畸变中的枕型畸变和桶型畸变：




图 4-5 正常图像与两种畸变图像

Figure 4-5 Normal image and two distorted images

相机在成像之前，需要将相机坐标系下的坐标点归一化到 $Z=1$ 的平面上，表达式为：

$$X_{nc} = \begin{bmatrix} x_c / z_c \\ y_c / z_c \\ 1 \end{bmatrix} \quad (4-28)$$

归一化后相机平面为 (x, y) ， (x', y') 为径向畸变后的坐标，矫正模型可以表示为：

$$\begin{cases} x' = x(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) \\ y' = y(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) \end{cases} \quad (4-29)$$

其中 k_n 为径向畸变系数， $r^2 = x^2 + y^2$ 。另一种畸变是切向畸变，是相机组装问题导致的畸变，矫正模型为：

$$\begin{cases} x' = x + 2p_1 xy + p_2(r^2 + 2x^2) \\ y' = y + 2p_2 xy + p_1(r^2 + 2y^2) \end{cases} \quad (4-30)$$

式中： p_n 为切向畸变系数。

4.4.3 相机标定

相机标定主要是为了排除畸变产生的影响，使图像信息位置准确。目前比较成熟的相机标定工具有基于张正友标定法的 OpenCV 标定工具、CamOdoCal、Kalibr 等。本文选择 Kalibr 工具对相机标定，采用其中的布朗畸变模型 (radial-tangential)，使用 k_1 、 k_2 、 p_1 、 p_2 四个畸变参数。使用图 4-6 所示的标定板，开启相机拍摄标定板在俯仰、移动和倾斜状态下的图像，获得全面观测，以此提高标定的准确性。




图 4-6 标定板

Figure 4-6 Calibration plate

得到内参矩阵:

$$K = \begin{bmatrix} 387.554056 & 0 & 321.234705 \\ 0 & 387.765555 & 241.748267 \\ 0 & 0 & 1 \end{bmatrix}$$

四个畸变参数分别为:

$$\begin{cases} k_1 = -0.0446969 \\ k_2 = 0.0397764 \\ p_1 = -0.0003087 \\ p_2 = 0.0005062 \end{cases}$$

4.5 IMU 模型 (IMU Model)

4.5.1 IMU 测量

IMU 由三轴加速度计和三轴陀螺仪组成, 可以测量载体所在坐标系下的三轴方向的加速度和角加速度。其系统存在随机噪声和漂移误差, IMU 的测量值和误差模型为:

$$\hat{\omega}_t = \omega_t + b_{\omega_t}^w + n_g \quad (4-31)$$

$$\hat{a}_t = R_{I_t}^w (a_t + g_w) + b_{a_t}^w + n_a \quad (4-32)$$

式中: ω_t 为世界坐标系下 IMU 的角加速度真值, $b_{a_t}^w$ 和 $b_{\omega_t}^w$ 为加速度计和陀螺仪的偏置, n_a 和 n_g 为加速度计和陀螺仪的白噪声, g_w 为世界坐标系下的 IMU 重力加速度。 $R_{I_t}^w$ 为世界坐标系到 IMU 坐标系的转换矩阵, a_t 为世界坐标系下加速度计真值。

4.5.2 IMU 标定

进行误差分析后，IMU 在使用过程中会受到噪声误差的影响，因此对 IMU 进行标定，首先启动 IMU，将相机水平放置保持静止，IMU 输出频率稳定后，开始录制 rosbag，获取加速度和角加速度数据；然后对 IMU 的数据进行分析处理，对 Allan 方差曲线进行计算；最后，得到 IMU 的标定结果，如下表 4-1 所示。

表 4-1 IMU 标定结果
Table 4-1 IMU calibration results

类型	加速度计	陀螺仪
噪声标准偏差	0.01	0.04
随机游走偏差	0.00004	0.000006

4.5.3 IMU 预积分

为了将视觉信息与 IMU 信息进行融合，可采用 IMU 预积分的方式。通常情况下，IMU 的采集频率高于相机采集频率，图像的采集频率大约为 10Hz，IMU 采样频率可以达到 100Hz 以上。如图 4-7，简单表达了相机和 IMU 采样频率之间的时序关系。




图 4-7 相机与 IMU 采样频率示意图

Figure 4-7 Sampling frequency of the camera and IMU

由于 IMU 的采样频率明显高于相机，如果每一时刻 IMU 状态变量加入后端滑窗进行非线性优化，会导致优化器计算过于庞大，影响系统性能。为此，在保证系统实时性的前提下，优化关键帧的状态变量。相邻两图像关键帧 k 到 $k+1$ 之间的 IMU 测量值，通过积分处理作为约束条件，IMU 的预积分公式如下^[85]：

$$\mathbf{p}_{l_{k+1}}^w = \mathbf{p}_{l_k}^w + \mathbf{v}_{l_k}^w \Delta t_k + \iint_{t \in [t_k, t_{k+1}]} \left(\mathbf{R}(\mathbf{q}_t^w) (\hat{\mathbf{a}}_t - \mathbf{b}_{a_t}^w - \mathbf{n}_a) + \mathbf{g}_w \right) dt^2 \quad (4-33)$$

$$\mathbf{v}_{l_{k+1}}^w = \mathbf{v}_{l_k}^w + \int_{t \in [t_k, t_{k+1}]} \left\{ \mathbf{R}(\mathbf{q}_t^w) (\hat{\mathbf{a}}_t - \mathbf{b}_{a_t}^w - \mathbf{n}_a) + \mathbf{g}_w \right\} dt \quad (4-34)$$

$$\mathbf{q}_{l_{k+1}}^w = \int_{t \in [t_k, t_{k+1}]} \left\{ \mathbf{q}_{l_k}^w \otimes \mathbf{q} \left(\frac{1}{2} (\hat{\boldsymbol{\omega}}_t - \mathbf{b}_{\omega_t}^w - \mathbf{n}_g) \right) \right\} dt \quad (4-35)$$

式中： Δt_k 为相邻图像帧的时间差。当要求 t_{k+1} 时刻系统的平移和速度，需

要考虑 t_k 时刻的系统状态, 如果 t_k 状态发生变化, 上述的积分运算需要重新进行。

采用预积分的主要目的是将相邻两个关键帧的测量值转为不受初始状态影响的约束。再经过世界坐标系到 IMU 坐标系的变换, 则有姿态变换式 $\mathbf{q}_t^W = \mathbf{q}_{I_k}^W \otimes \mathbf{q}_t^{I_k}$, 得到 t_k 到 t_{k+1} 时刻的平移变化量 $\alpha_{I_{k+1}}^{I_k}$ 、速度变化量 $\beta_{I_{k+1}}^{I_k}$ 和旋转变换量 $\gamma_{I_{k+1}}^{I_k}$ 表达式为:

$$\alpha_{I_{k+1}}^{I_k} = \iint_{t \in [t_k, t_{k+1}]} \mathbf{R}(\mathbf{q}_{I_t}^{I_k})(\hat{\mathbf{a}}_t - \mathbf{b}_{a_t}^W - \mathbf{n}_a) dt^2 \quad (4-36)$$

$$\beta_{I_{k+1}}^{I_k} = \int_{t \in [t_k, t_{k+1}]} \mathbf{R}(\mathbf{q}_{I_t}^{I_k})(\hat{\mathbf{a}}_t - \mathbf{b}_{a_t}^W - \mathbf{n}_a) dt \quad (4-37)$$

$$\gamma_{I_{k+1}}^{I_k} = \int_{t \in [t_k, t_{k+1}]} \left\{ \mathbf{q}_{I_t}^{I_k} \otimes \mathbf{q} \left(\frac{1}{2} (\hat{\boldsymbol{\omega}}_t - \mathbf{b}_{\omega_t}^W - \mathbf{n}_g) \right) \right\} dt \quad (4-38)$$

通过上式 (4-36)、(4-37) 和 (4-38), 将积分预先计算出, 当初始状态变化时, 三个变化量能够通过 k 和 $k+1$ 时刻 IMU 测量值表示出来。

4.6 基于视觉/惯性/轮式里程计与 GNSS 融合定位系统 (Based on Vision/Inertial/Wheel Odometer and GNSS Fusion Positioning System)

定位系统进行状态估计时, 会出现漂移现象, 为减少这种情况发生, 实现高精度的定位, 设计一种多传感器融合定位系统, 该系统基于视觉-惯性-轮式里程计 (Visual-Inertial-Wheel Odometer, VIWO) 的紧耦合优化, 获得局部状态估计, 并与 GNSS 松耦合融合, 得到全局状态估计。

分别在局部坐标系和 ENU 坐标系中保留关键帧位姿。为了估计相应的外部参数, 需要将局部帧转换为 ENU 坐标。

整个系统使用四个传感器作为环境信息感知的来源: 相机、IMU、车轮轮速计和 GNSS。系统整体框架如图 4-8 所示, 首先, 将相机、IMU 和轮速计的测量数据集成到系统初始化中; 其次, 系统初始化完成后, 通过紧耦合优化算法将多个测量数据耦合在一起, 得到局部估计位置和位姿信息; 最后, 采用松耦合优化方法与 GNSS 测量数据进行融合, 得到全局估计信息。语义映射模块结合当前车辆的实时姿态和 GNSS 测量结果, 构建全局一致的语义地图。另外分别在局部坐标系和 ENU 坐标系中保留关键帧位姿。为了估计相应的外部参数, 需要将局部帧转换为 ENU 坐标。




图 4-8 多传感器融合定位系统整体框架

Figure 4-8 The overall framework of the multi-sensor fusion positioning system

4.6.1 滑动窗口及边缘化

当对多个关键帧进行基于非线性优化的紧耦合方式来优化系统时,随着关键帧的增多和地标值的增加,优化的效果会变差,为了避免这种情况的发生,采用滑动窗口来控制关键帧的数量,同时也能保证优化效果。滑动窗口的中变量表示如下:

$$\begin{aligned} \mathcal{X}_d &= [x_0, x_1, \dots, x_{N-1}, \lambda_0, \lambda_1, \dots, \lambda_{M-1}, m_0, m_1, \dots, m_{K-1}]^T \\ \mathbf{x}_k &= \left[\left(\mathbf{p}_{O_k}^w \right)^T, \left(\mathbf{v}_{O_k}^w \right)^T, \left(\mathbf{q}_{O_k}^w \right)^T, \mathbf{b}_{w_t}^w, \mathbf{b}_{a_t}^w \right]^T \end{aligned} \quad (4-39)$$

式中: $\mathcal{X}_d$ 为滑动窗口关键帧的状态变量、特征第一次被视觉观测的逆深度值和正交表示。 $\mathbf{x}_k$ 为载体在第 k 帧图像时的状态, $\mathbf{p}_{O_k}^w$, $\mathbf{v}_{O_k}^w$, $\mathbf{q}_{O_k}^w$ 分别为第 k 帧图像时世界坐标系下的车辆平移、速度和旋转。 $\mathbf{b}_{a_t}^w$, $\mathbf{b}_{w_t}^w$ 为加速度计和陀螺仪的偏置。

若采用前后两帧图像来计算相机位姿,算法迅速但精度很低;若采用全局优化方式,精度提高了但速度变低了。为了能够既保证精度和效率,采用滑窗的方式,每次对固定数量的关键帧优化,同时滑窗会不断有新的帧进入,旧帧也会离开,边缘化使这些旧帧充分利用,去除系统不需要的状态变量。次新关键帧删除时,最新关键帧移到次新关键帧帧的位置;旧帧删除后,对应的预积分分量也需要删除,特征观测保存到下一帧。利用边缘化算法将丢弃的特征观测作为先验约束,以此来达到充分利用旧帧的目的。

4.6.2 视觉/惯性/轮式里程计初始化

采用 VIWO 系统定位时,需要进行系统初始化,以获取初始位置和姿态,建立一个准确的初始状态,对于系统运行时能够准确地估计自身的位置和姿态有重要意义。初始化主要包括特征提取与匹配、视觉惯性对齐、初始位置估计、尺度

恢复和初始地图构建。

视觉惯性导航（Visual-Inertial Navigation System, VINS）初始化过程中，单目视觉运动恢复结构（Structure From Motion, SFM）估计的姿态会受到单目模式下的尺度不确定性的影响，因此，滑动窗口估计的姿态与实际运动状态之间存在比例关系，称为比例因子。另外，路径采集设备在运动过程中也不是绝对平稳的，IMU 可能会得不到充分的激励，将可视化 SFM 结果与 IMU 的预积分结果进行单一的积分会导致系统初始化缓慢，因此，在初始化时对车轮速度计进行预积分，提供绝对里程观测，可以有效地估计单一用途的尺度因子。通过求解最小二乘问题，可以得到比例因子 μ [83]，表达式为：

$$\min_{\mu} \left\| \sum_{k \in U} \|z_{O_{k+1}}^{O_k} - F_{O_{k+1}}^{O_k} \mu^2\| \right\| \quad (4-40)$$

式中： U 为索引窗口中的所有帧， $F_{O_{k+1}}^{O_k}$ 为基础矩阵， $z_{O_{k+1}}^{O_k}$ 为深度恢复矩阵。

动态初始化方法将视觉 SFM 结果与 IMU 预积分结果对齐时，需要考虑加速度计零偏的优化问题，且加速度计的零偏只能在系统初始化完成后估计。

因此，本节主要采用静态初始化和动态初始化相结合的方法，算法结构如图 4-9 所示。IMU 静态初始化过程主要估计加速度计与陀螺仪的静态偏差。动态初始化以静态偏差为初始值，对加速度计和陀螺仪的零偏进行优化。这样能够得到系统任意状态下的初始位置、速度、重力方向、加速计偏置和陀螺仪偏置。




图 4-9 初始化流程图

Figure 4-9 Initialization flowchart

静态初始化是指在视频序列开始时需要一个静止状态。系统使用静止的 IMU 数据来估计重力方向、加速度计偏置和陀螺仪偏置。如图 4-10 静态初始化需要

检测 IMU 的弹跳过程，该过程包括静止和跳跃两种状态。

设置阈值(IMU 激励阈值)来确定 IMU 是否足够激励，并从获得运动激励之前静止测量的 IMU 结果估计 IMU 初始化参数。然后计算初始旋转矩阵，滑动窗口 $w2$ 加速度计平均值为 $\bar{a}$ ，陀螺仪平均值为 $\bar{\omega}$ 。




图 4-10 IMU 跳跃过程

Figure 4-10 IMU hopping process

因为在世界系统下，静止时测量的加速度为 $(0,0,g)$ 。将窗口加速计平均值 $\bar{a}$ 除以其模长，得到平均加速度的方向（单位矢量），确定世界系 Z^w 方向在 IMU 坐标系上的投影为：

$$z = \frac{z}{Z.norm(\cdot)} \quad (4-41)$$

采用施密特正交法构造单位向量：

$$e_0 = (1, 0, 0)^T \quad (4-42)$$

将 X^I 轴投影在 $Z^w - X^w$ 平面，IMU 坐标系下 X^w 的方向矢量为：

$$e_1 = e_0 - (z^T e_0) z$$

$$x = \frac{e_1}{e_1.norm(\cdot)} \quad (4-43)$$

X 轴和 Z 轴叉乘表示 Y 轴方向：

$$y = [z]_x x \quad (4-44)$$

上述计算可以得出世界坐标系 $\{W\}$ 转到 IMU 坐标系 $\{I\}$ 的初始旋转矩阵为 $R_I^w = [X_I^w, Y_I^w, Z_I^w]$ 。陀螺仪在静态时刻的理想测量值（角速度）应为零，因此可以计算出陀螺仪的偏置，即滑动窗口中陀螺仪数据的平均值 avg_{wn} 。

$$avg_{wn} = \frac{1}{n} \sum_{n=1}^n w_n \quad (4-45)$$

最后, 加速度计静止时的偏置是由于重力引起的平均加速度和实际加速度之间的差值, 假设 M 为加速度计偏置。

$$M = avg_{wm} - R_g \quad (4-46)$$

式中: g 为世界体系中的重力加速度, R_g 为第一步得到的旋转矩阵, 将世界体系中的重力矢量投影到 IMU 坐标系中。

如果平台不是静态的, 那么使用动态初始化来尝试恢复初始状态。它通过首先创建一个用于恢复速度、重力和特征位置的线性系统来解决初始化问题。在初始恢复之后, 执行全面优化以允许协方差恢复。

4.6.3 基于 VIWO 的紧耦合优化算法

系统初始化后, 通过优化算法将多个测量数据耦合在一起, 得到当前车辆的实时位置和姿态。为了提供更稳健和准确的状态估计, 采用一种基于视觉-惯性-车轮里程计的紧耦合优化方法, 并且利用了线速度的可靠观测特性, 在构建预积分时考虑了沿 X 轴的速度。

在给定两关键帧 k 到 $k+1$ 之间的若干个纵向车轮速度与前轮转角的载体运动测量数据 $[v_{m,t_k}^O, \delta_{mf,t_k}^O, \dots, v_{m,t_{k+1}}^O, \delta_{mf,t_{k+1}}^O]$, t_k 与 t_{k+1} 时刻车辆预积分表达式为^[90]:

$$\begin{aligned} p_{O_{k+1}}^W &= p_{O_k}^W + \int_{t \in [t_k, t_{k+1}]} R(q_{O_t}^W) v_t^O dt \\ q_{O_{k+1}}^W &= \int_{t \in [t_k, t_{k+1}]} \left\{ q_{O_t}^W \otimes \begin{bmatrix} \frac{1}{2} w_t^O \\ 0 \end{bmatrix} \right\} dt \end{aligned} \quad (4-47)$$

式中: v_t^O 、 w_t^O 分别表示在 t 时刻车轮坐标系下的车轮线速度和车轮角速度, 通过车轮坐标系转换到世界坐标系, 则有变换矩阵 $R(q_{O_t}^W)$, 此时车轮姿态 $q_{O_t}^W = q_{O_k}^W \otimes q_{O_t}^{O_k}$, 代入 (4-47), 得到:

$$\begin{aligned} p_{O_{k+1}}^W &= p_{O_k}^W + R(q_{O_k}^W) \int_{t \in [t_k, t_{k+1}]} R(q_{O_t}^{O_k}) v_t^O dt \\ q_{O_{k+1}}^W &= q_{O_k}^W \otimes \int_{t \in [t_k, t_{k+1}]} \left\{ q_{O_t}^{O_k} \otimes \begin{bmatrix} \frac{1}{2} w_t^O \\ 0 \end{bmatrix} \right\} dt \end{aligned} \quad (4-48)$$

通过离散中值积分得到连续时间序列的车轮预积分为:

$$\begin{aligned} \alpha_{O_{k+1}}^{O_k} &= \int_{t \in [t_k, t_{k+1}]} R(q_{O_t}^{O_k}) v_t^O dt \\ \gamma_{O_{k+1}}^{O_k} &= \int_{t \in [t_k, t_{k+1}]} q_{O_t}^{O_k} \otimes \begin{bmatrix} \frac{1}{2} w_t^O \\ 0 \end{bmatrix} dt \end{aligned} \quad (4-49)$$

得到 t_k 和 t_{k+1} 时刻的平移预积分真实值 $\alpha_{O_{k+1}}^{O_k}$ 和旋转预积分真实值 $\gamma_{O_{k+1}}^{O_k}$ 。

在获得 IMU 和车轮预积分后, 提出噪声重估计方法。通过调整各预测位置方差的一致性来调整可比的噪声^[86], 在惯性测量期间, 额外的频率会产生更大的

噪声，需要放大 50~100 倍。IMU 与车轮预积分的最优比值为 1。如果该比值小于 1，则表明车轮测量异常，然后将设定的车轮噪声乘以该比值与测量参数的倒数。如果该值大于 1，则认为 IMU 测量值有问题。在这种情况下，IMU 参数集将乘以比率和噪声参数。如图 4-11 所示的全局因子图，每个节点为一个姿态，包含位置 and 方向，相邻两个节点之间由局部估计的 VIWO 紧耦合系统的局部约束，其它来自传感器的全局约束。采用非线性最小二乘使各测量值约束因子之间的残差和边缘化最小值来优化各节点的状态变量。非线性优化表示为：

$$f = \min_{\mathcal{X}} \{ \|\gamma_p - H_p \mathcal{X}\|^2 + \sum_{k \in I} \|\gamma_I(z_{I_{k+1}}^I, \mathcal{X})\|^2 + \sum_{k \in O} \|\gamma_O(z_{O_{k+1}}^O, \mathcal{X})\|^2 + \sum_{(i,j) \in C} \|\gamma_C(z_i^C, \mathcal{X})\|^2 \} \quad (4-50)$$

式中： $\mathcal{X}$ 为状态变量， $\|\gamma\|^2$ 表示残差 γ 协方差距离，即马氏距离。四个残差分别对应边缘化、IMU 预积分约束、车轮预积分约束和相邻帧间重投影残差的先验信息。 $\{\gamma_p, H_p\}$ 为滑动窗口被边缘化的先验信息约束， $\gamma_I(z_{I_{k+1}}^I, \mathcal{X})$ 为系统状态 x_k 和 x_{k+1} 之间的 IMU 残差约束，即两时刻间 IMU 测量值预积分。 I 为滑动窗口中 IMU 预积分所有测量值的集合。 $\gamma_O(z_{O_{k+1}}^O, \mathcal{X})$ 为系统状态 x_k 和 x_{k+1} 之间的车轮预积分约束，由两时刻车辆角、加速度状态量的预计分组成。 $\gamma_C(z_i^C, \mathcal{X})$ 为特征投影残差。




图 4-11 全局因子图

Figure 4-11 Global factor chart

另外，为了计算和发布 IMU 和轮式里程计的原始数据，设计惯性-轮式里程计（Inertial-Wheel Odometer, IWO）模块，减轻陀螺仪在姿态估计中引起的误差，加速度计用于逼近陀螺仪误差。另外，由于数据由不同位置获取，刚性连接位置会受到切向加速度作用。扩展卡尔曼滤波（Extended Kalman Filter, EKF）通过在当前估计点将系统非线性近似转为线性问题来求解，然后再对线性系统进行滤波，实现旋转矩阵和偏差的实时更新^[84]。通过陀螺仪获得姿态角，计算相对于平移分解的左雅可比矩阵为：

$$J = \frac{\sin \theta}{\theta} I_{3 \times 3} + \left(1 - \frac{\sin \theta}{\theta} \right) n n^T + \frac{1 - \sin \theta}{\theta} \hat{n} \quad (4-51)$$

式中： θ 为姿态旋转角度， n 为单位向量表示的旋转轴， $\hat{n}$ 为偏对称矩阵。将线性轮速和附加轮速转换为 IMU 框架：

$$\mathbf{v}^I = \mathbf{R}_o^I \cdot \mathbf{w}^o \times \mathbf{t}_o^I + \mathbf{R}_o^I \cdot \mathbf{v}^o \quad (4-52)$$

式中： $\mathbf{w}^o$ 为附加轮速， $\mathbf{v}^o$ 为线性轮速， $\mathbf{R}_o^I$ 为车轮坐标系到 IMU 坐标系的变换矩阵。

4.6.4 多传感器融合方式

两个关键帧姿态分别来自局部坐标系和绝对坐标系，通过将局部帧转换为 ENU 帧来实现对 VIWO 和 IWO 的相对姿态约束，估计相应的外部参数。

将图形优化细分为三个阶段：初始化、外部校准和定位。初始化阶段主要用于外部参数估计。算法设置是，当车辆在前一个节点中完成足够的移动时，选择一个新的关键帧。通过姿态插值的方式将关键帧插入到因子图中，并以此方式进行时间对准。确定初始化是否成功的方法是在收集了 15 个关键帧节点之后。

为了准确地求解坐标系变换关系，构造三元边。具体来说，关键帧的状态被约束在两帧图像和外部参数中。得到的 ENU 坐标用于角度约束。每个全局节点都有一个绝对的转换约束。三元边约束的数量限制为 52。如果 VIWO 中的优化姿势没有出现在相邻的关键帧中，则它与 IWO 中的姿态互补。如果 VIWO 中的优化姿势没有出现在相邻的关键帧中，则它与 IWO 中的姿态互补。

将特殊欧式群 SE(3)表示的优化方差定义为：

$$\mathcal{X} = \{\mathcal{X}^E, \mathcal{X}_I^E, \mathcal{X}^I\} \quad (4-53)$$

对应的问题可表示为：

$$\arg \min_{\mathcal{X}} r(\mathcal{X}) = \text{Log}((\mathcal{X}^E \cdot \mathcal{X}^I)^{-1} \mathcal{X}^E) \quad (4-54)$$

式中： $r(\mathcal{X})$ 定义为从 SE(3)到 se(3)阻力的映射，其初始猜测由 $\mathcal{X}_I^E$ 根据前 15 个节点的轨迹给出。

引入三元组边缘，精确标定两帧之间的外部参数，优化不同帧下的姿态，为了简化多传感器融合过程，将标定后的外部参数从待调整变量中去除。在高频定位中，基于前一节点的优化姿态，系统将累积 IWO 提供的相对于当前姿态的姿态信息。此外，采用线性 EKF 方法减轻 GNSS 抑制区域对开放区域的突然影响，并将漂移引起的误差均匀分布到不同时刻的位置和姿态上，使轨迹平滑。

4.7 实验结果与分析 (Experimental Results and Analysis)

4.7.1 实验描述

本节对上述提出算法的有效性进行验证，实验在 Ubuntu 版本为 18.04 的 ROS 软件平台上完成，编程语言为 C++，运行的 CPU 为 NVIDIA Carmel ARM®v8.2 64-bit。

首先，与常见方法进行对比，对本文介绍的 VIWO 紧耦合定位算法进行初步验证，决定采用开源的 Kaist 数据集对 VIWO 系统进行定位性能评估。Kaist 数据集由韩国科学院提供，采集了城市公路和高速公路场景下的图像、IMU 和轮速计等数据信息，并提供了参考真值^[87]。本次采用其数据集中的序列 22，该序列为高速公路场景，总里程 3.4km。图 4-12 展示了 Kaist 数据集的采集平台和数据序列可视化界面。



(a) Kaist 数据集采集平台

(b) 数据集序列可视化界面

图 4-12 Kaist 数据集采集平台及序列可视化界面

Figure 4-12 Kaist dataset acquisition platform and sequence visualization interface

然后，由于目前同时包含 GNSS、相机、IMU 与轮速计信息的公开数据集较少，为了能够对视觉/惯性/轮式里程计与 GNSS 融合定位系统的定位性能和初始化效果进行评估，通过采集车自主采集了两段数据集，实验场景与 google map 上标注的实验轨迹如图 4-13 和图 4-14 所示。其中实验路段 1 为厂区附近路段，该路段比较空旷，利于检测实验；实验路段 2 为校园路段，与普通公路相似，实验过程中，道路两旁的行人或树叶会产生大量的纹理和交叉特征点，特征匹配困难。




图 4-13 实验路段 1 示例图像及地图轨迹

Figure 4-13 Example image and map trajectory of experimental section 1




图 4-14 实验路段 2 示例图像及地图轨迹

Figure 4-14 Example image and map trajectory of experimental section 2

其中，采集数据集过程中，直道近似为匀速行驶，弯道会有加速或减速的状态，实验路段 1 和实验路段 2 采集时长和总里程数如下表 4-2 所示。

表 4-2 实验路段 1 和 2 采集时长与总里程数

Table 4-2 Duration and total mileage of experimental sections 1 and 2

实验路段	1	2
采集时长 (s)	480	340
总里程数 (m)	926	889

最后，通过 evo 软件绘制预估轨迹与参考轨迹并进行对比，然后将数据量化，采用均方根误差（Root Mean Square Error, RMSE）作为评价指标，以评估定位系统的性能。

4.7.2 视觉/惯性/轮式里程计定位性能评估

本节在开源数据集上进行仿真，验证本文 VIWO 系统的定位性能，主要内容是：1) 在没有 GNSS 信息修正和车道线关键信息的情况下，评估 VIWO 的定位性能；2) 与典型 VIO 算法 VINS-Fusion^[88]对比，验证算法的优越性。图 4-15 展示了数据集 22 序列的处理结果，图中 (a) 为 Kaist 数据集序列 22 上 X, Y 平面下真值轨迹（黑色虚线）、VIWO 预估轨迹（蓝色实线）和 VINS-Fusion 预估轨迹（绿色实线）；图中 (b) 为三向轨迹对比图，从图中可以看出，VINS-Fusion 的视觉惯性里程计系统状态估计受到长期漂移影响，导致轨迹误差很大，而通过引入轮式里程计的 VIWO 系统，很好的解决了由噪声因素引起的状态估计轨迹漂移问题。图 4-16 为 VIWO 系统预估轨迹与真值对比的误差结果，包含绝对轨迹和相对轨迹的相关评价参数指标。由于该数据集为直线路程，所以预估轨迹误差总体较小。




图 4-15 Kaist 数据集 22 序列上的轨迹对比结果

Figure 4-15 Processing results on 22 sequences of the Kaist dataset




图 4-16 Kaist 数据集 22 序列上 VIWO 系统预估轨迹误差结果

Figure 4-16 The error result of the estimated trajectory of the VIWO system on the sequence 22 of the Kaist dataset

两种算法的轨迹误差的均值、中值和均方根如表 4-3 所示，其中绝对轨迹误差能够反映估计位置与真实位置状态之间的差异，而相对轨迹误差能够判断在连续图像帧序列下估计自身位置的准确性。从表中结果可以看出，本文的 VIWO 系统相较于 VIO 系统，误差更小，得益于轮式里程计提供更可靠的观测结果，使系统的整体定位性能提高。

表 4-3 两种算法绝对轨迹误差与相对轨迹误差的评价指标 (m)

Table 4-3 The evaluation indexes of absolute trajectory error and relative trajectory error of the two algorithms (m)

算法	绝对轨迹			相对轨迹		
	均值	中值	均方根	均值	中值	均方根
VINS-Fusion	10.853	9.793	11.039	8.899	8.635	9.977
本文 VIWO	0.461	0.434	0.503	0.34	0.269	0.436

4.7.3 视觉/惯性/轮式里程计系统初始化效果分析

初始化效果影响着整个系统定位的准确性,为了验证 4.6.2 节介绍的视觉惯性轮式里程计的初始化方式的有效性,在实验路段 1 展开初始化效果的验证实验,四个直道和四个弯道实验轨迹在图 4-17 上标出。另外,本文提出的初始化方法,采用视觉里程计相对于世界参考系的位姿估计结果,并结合 IMU 预积分结果、车轮预积分结果与 GNSS-RTK 定位数据,最后计算出相机与 IMU 之间的相对旋转。



图 4-17 实验路段 1 的直道与弯道轨迹

Figure 4-17 Straight and curve tracks in experimental section 1


通过标定库离线标定能够获取相机与 IMU 之间的旋转和平移参考值,设定 IMU 激励阈值为 1° 。进行直线路段和弯道路段的测试,能够体现动态情况下算法的效果。表 4-4 为直道与弯道情况下相机与 IMU 相对旋转角度误差均值。

表 4-4 直道与弯道情况下相机与 IMU 相对旋转角度误差


Table 4-4 Relative rotation angle error between the camera and the IMU in straight and curved tracks

	直道 1	直道 2	直道 3	直道 4	平均值
误差($^\circ$)	2.88	2.54	1.31	1.51	2.06
	弯道 1	弯道 2	弯道 3	弯道 4	平均值
误差($^\circ$)	0.63	0.81	0.83	1.47	0.93

直线路段实验过程中,采集小车近似匀速运动,图 4-18 (a) 直观表示了 4 种车道下,相机与 IMU 的旋转角度估计误差在 0~7s 内波动较大,7s 之后趋于平稳,没有较大的波动;弯道路段实验过程中,采集小车有加速或减速的运动,相应的相机与 IMU 的相对旋转角度误差曲线如图 4-18 (b) 所示,角度误差在 0~8s 呈现下降趋势,8~12s 趋于平稳。



(a) 直道路段




(b) 弯道路段

图 4-18 直线路段和弯道路段下相机与 IMU 之间角度误差


Figure 4-18 Angle error between the camera and the IMU in straight and curved road sections

4.7.4 视觉/惯性/轮式里程计与 GNSS 融合定位系统性能评估

本节实验在实验路段 1 和实验路段 2 展开, 其中实验路段 1 和实验路段 2 数据集处理结果如图 4-19, 图中 (a) 和 (b) 分别为实验路段 1 和 2 数据集序列上 X, Y 平面下参考轨迹轨迹、VIWO 系统定位轨迹和融合 GNSS 后的预估轨迹, 实验轨迹起点为原点 (0, 0), 从图中可以看出, VIWO 系统由于引入了轮速计, 在弯道变速的情况, 也有较好表现, 经过 GNSS 的偏差修正后, 使轨迹更加平滑。



(a) 实验路段 1




(b) 实验路段 2


图 4-19 实验路段 1 和 2 的平面轨迹对比结果

Figure 4-19 Comparison results of planar trajectories of experimental sections 1 and 2

为了对 VIWO 系统与融合 GNSS 后的结果进行定量的评价, 将数据融合前后两段数据序列对齐, 图 4-20 中 (a) 和 (b) 分别为实验路段 1 和 2 的 VIWO 系统绝对轨迹误差与融合 GNSS 信息后的预估轨迹误差。从图中曲线可以看出, 融合 GNSS 后, 误差明显呈下降趋势。



(a) 实验路段 1



(b) 实验路段 2

图 4-20 实验路段 1 和 2 的实验结果

Figure 4-20 Experimental results of sections 1 and 2

最后, 对应的两实验路段的 VIWO 系统与融合 GNSS 预估结果的绝对轨迹位置的均方根误差数据如表 4-5 所示, 从表中数据可知, VIWO 系统在回环路段下轨迹预估能力较差, 定位误差明显增大, 但通过系统的回环修正, 在经过弯道时, 不会出现过度漂移的情况。另外, 融合 GNSS 信息后, 消除了部分 VIWO 系统的漂移偏差, 使全局轨迹误差降低。

表 4-5 VIWO 系统与融合 GNSS 后的绝对轨迹均方根误差

Table 4-5 Root mean square error of absolute trajectories after VIWO system and fused GNSS

实验路段	长度	RMSE (m)	
		VIWO	Proposed
1	925.56	0.601	0.113
2	888.63	0.753	0.156

4.8 本章小结 (Brief Summary of the Chapter)

本章设计了基于视觉/惯性/车轮里程计与 GNSS 融合的定位算法，首先为有效估计系统的所有初始状态变量，提出静态初始化和动态初始化相结合的方法；其次为实现局部帧与 ENU 帧之间的转换，将局部状态信息与 GNSS 测量信息进行融合；然后采用噪声重估计的方式保证惯性测量单元与车轮里程计的同步性；最后在 Kaist 数据集上对 VIWO 系统定位性能进行评估，并与典型算法 VINS-Fusion 进行对比，实验表明，基于 VIWO 算法更优，各项误差指标更小。在实际道路上四条弯道与四条直道上对系统初始化性能进行验证，实验表明，直道与弯道情况下，相机与 IMU 相对旋转角度平均误差分别为 2.06° 和 0.93° 。为评估 VIWO 系统与 GNSS 信息融合后的轨迹预估效果，分别在厂区和校园路段采集了两段数据集，经过实验验证，将 VIWO 系统预估轨迹、融合 GNSS 后的轨迹与真值轨迹对比，得到量化的数据，结果表明：实验路段 1 和 2 在 VIWO 系统下绝对轨迹均方根误差分别为 0.601m 和 0.753m，融合 GNSS 信息后均方根误差为 0.113m 和 0.156m，VIWO 系统与 GNSS 信息融合后，误差显著降低。

5 路径智能采集规划及道路实验

5 Intelligent Path Collection Planning and Road Experiments

路径智能采集规划系统综合了车道线检测部分与多传感器融合定位部分,通过车道线检测提取车道线的图像像素坐标点,将其作为定位系统中视觉部分的关键信息,经过多源信息融合得到车道线的定位坐标信息。前文已对这两部分性能进行了验证,本章对系统中路径智能采集的主要流程和路径轨迹规划工作进行详细的说明。最后在实际道路上进行实验,实验场景包括校园路段和施工路段,通过将采集的路径信息和参考信息进行对比,综合评估采集规划系统的性能。

5.1 路径智能采集 (Intelligent Path Collection)

路径信息采集工作由路径采集小车完成,各传感器设备型号和整体系统结构已在第二章详细描述。采集前,需要将训练好的车道线数据模型集成到定位系统中;采集过程中,对靠采集设备右侧的车道线进行实时的检测;采集完成后,得到各传感器数据,融合多源信息并输出车道线的定位坐标信息。

路径信息采集的具体流程方案如图 5-1 所示,具体步骤如下:




图 5-1 路径采集流程

Figure 5-1 Path collection process

(1) 首先在实验路径选取空旷且没有遮挡物的地方安放 RTK 基站,保证信号覆盖需要采集信息的路段,并且 GNSS 接收器能够接收到信号。

(2) 将基站与移动站建立通讯,实时接收 GNSS 数据。通过图 5-2 所示的软件将移动站和基准站通过蓝牙与终端连接,设置电文格式,确定需要输出的坐标格式,便于后续的轨迹对比、误差分析和实际应用。

截止高度角(^)	10
PDOP限制值	3
PPK模式	☐ OFF
数据链方式:	内置电台
频道	自定义频率
频率	458.521
协议	TRANSEOT

设置

(a) 移动站参数设置

地面点坐标	
☒ BLH ☐ NEH	
纬度B	00:00:00.00000N
经度L	000:00:00.00000E
椭球高H	0.0000
天线高 0.000	杆高
电文格式	RTCM3.2
截止高度角(^)	10
PDOP限制值	3
PPK模式	☐ OFF

设置

(b) 基准站参数设置

图 5-2 RTK 软件界面

Figure 5-2 RTK software interface

(3) 启动路径采集车系统控制界面。打开小车工控机，检查传感器连接正常。如图 5-3 为路径信息采集系统的工作界面。




图 5-3 系统工作界面

Figure 5-3 The working interface of the system

(4) 路径信息采集。确认工控机、传感器连接无误，可以正常工作后，输入代码，开启 rosbag 录制，待初始化完成后开始采集工作，可从采集小车屏幕上实时观测到车道线检测效果，如图 5-4 为采集过程中车道线检测效果示意图，图中蓝色的点为提取到的车道线像素点信息。




图 5-4 Rosbag 中车道线检测效果可视化界面

Figure 5-4 Visualization of lane line detection effect in Rosbag

(5) 完成路径信息采集, 获取 IMU、轮速计和 GNSS 数据。

另外，完成采集工作后，由于采集的 `rosvbag` 数据包文件较大，需要将文件保存至固态硬盘 `File_SSD` 中，如图 5-5，系统支持离线运行 `rosvbag`，便于随时使用和处理数据。

图 5-5 采集数据文件的存储
Figure 5-5 Storage of acquisition data files

路径规划主要是智能体车辆沿某特定路段完成相关行进任务的工作,对于智能体车辆来说,关键在于确定起点与终点,以及确定行进路径轨迹中的定位坐标信息。

5.2.1 路径轨迹拟合

为了将采集的坐标点规划成光滑的路径曲线,需要对采集到的坐标点进行曲线拟合。常见的路径拟合方式有多项式拟合、B 样条拟合和最小二乘法拟合。施工路段的路段有表面变化平缓、曲率较小的特点。所以适合采用多项式拟合进行路径轨迹拟合,多项式拟合的表达式如(5-1)所示。

多项式的误差评价通常采用最小二乘法，取观测值 p_f 与多项式拟合出的 $y(x_f)$ 之差的平方和来作为误差的评价标准，为保证拟合的误差最小，要求出多项式的系数，误差评价表达式为：

$$E^2 = \sum_{f=0}^n (p_f - y(x_f))^2 \quad (4-56)$$

式中： p_f 为观测值， $y(x_f)$ 为拟合值，求取两者之差，并开方求和，最后得到评价指标。

5.2.2 拟合路径重采样

将拟合好的路径轨迹下发给施工车辆用于智能驾驶时，车辆无法做到完全跟踪路径轨迹，跟踪轨迹通常是采用微分的直线近似成曲线轨迹，并且需要保证每一微分直线段在误差允许范围之内。为此将拟合的多项式曲线离散化，生成多个路径数据点。相邻点之间距离称为路径步长，根据曲率变化来决定步长的大小，曲率小时，采样的步长应当增加，反之，则应当减小。离散的主要方法有等距离步长法，等参数步长法，等弧长步长法和等弦高步长法，跟根据路面的实际情况来选择不同的方式来确定步长。

为了保证曲率变化大或小的情况下，都能采用合适的步长来进行离散采样，所以采用一种适应曲面的步长计算方法^[89]，首先需要考虑曲线的曲率，计算曲率的表达式如下：

$$K(x) = \frac{|y''(x)|}{[1 + y'^2(x)]^{\frac{3}{2}}} \quad (4-57)$$

曲率和步长之间的关系为：

$$S(k) = S_m \cdot e^{-\mu k} \quad (4-58)$$

式中： μ 为常数且 $\mu > 0$ ， $k \geq 0$ ， S_m 代表最大步长。

$$S(x) = S_{\max} \cdot e^{-\mu \frac{|y''(x)|}{[1 + y'^2(x)]^{\frac{3}{2}}}} \quad (4-59)$$

经过拟合和重采样后的路径轨迹示意图，如图 5-6 为一组数据拟合曲线的重采样示意图，经过拟合和重采样，生成了平滑的路径轨迹，并获得了间隔均匀的坐标点。




图 5-6 初采样点与重采样点示意图

Figure 5-6 Initial sampling point and resampling point

5.3 智能采集规划系统道路实验 (Road Experiments of Intelligent Collection and Planning System)

5.3.1 实验描述

为了验证智能采集规划系统采集和规划的性能,采用了两组数据:第一组为经过采集小车采集的室外数据,并依据第三章介绍的部分,将实验路段的车道线图像采集并标注后制作成数据集,训练完成后生成的数据模型集成到了小车控制端上,路径信息采集平台如图 5-7 所示搭载的传感器主要有相机 (10Hz)、IMU (100Hz)、轮速计 (100Hz) 和 GNSS 接收器 (5Hz),小车行驶速度约 2~3m/s,采用 rosbag 录制传感器信息;第二组为人工采集真值数据,采用高精度组合导航定位系统,沿着路径上车道线中间位置,人工设置控制点方式,获取实验路径的参考轨迹。




图 5-7 路径信息采集平台

Figure 5-7 Path information collection platform

实验的场景为校园和高速公路施工路段,且路段都含有车道线。实验共 2 组,首先,在校园环境下路段进行初步验证;然后,前往高速施工路段进行工程实际验证,如图 5-8 和图 5-9 为实验路段示例图像和标注在 google map 上的路径轨迹(黄色线标注)。实验中,校园场景下实验路线为往返直线路段,场地空旷,道路两侧树木较多,车道线为白色实线;施工路段为河北元氏高速公路,道路车道线存在磨损情况,车道线右侧有交通锥。由于采集过程中,行驶速度比较缓慢,帧间的图像重复比较多,利于视觉特征匹配。



图 5-8 往返直线路段示例图像及地图轨迹

Figure 5-8 Example image and map trail of a round-trip straight section



图 5-9 施工路段示例图像及地图轨迹

Figure 5-9 Example image and map trajectory of the construction section

实验过程中,采集小车的运动状态包括加速、减速、匀速、转弯和静止。采集的位置 GNSS 信号良好,且覆盖采集路段,校园往返直线路段与施工路段采集时长与总里程数如表 5-1 所示。

表 5-1 往返直线路段和施工路段的采集时长与总里程数

Table 5-1 The collection time and total mileage of the round-trip straight section and the construction section

实验路段	往返直线路段	施工路段
采集时长 (s)	150	350
总里程数 (m)	491	710

5.3.2 实验结果与分析

为方便对比,实验中规划轨迹与参考轨迹的经纬度坐标通过 4.3 节的坐标转换,转换到 ENU 坐标下,并且起始点都归算到了 $(0, 0)$ 。评价指标依然采用均方根误差 (RMSE) 来评价定位的精度。校园路段和施工路段的实验结果分别如下:

(1) 往返直线路段实验结果分析


按照 5.1 节的采集方式进行实验,从系统工作界面可以实时看到实验路段的车道线检测效果,如图 5-10 为检测效果的示意图像,检测点线位于车道线中央位置,由于校园实验路段是直道且路面车道线类型单一,所以车道线检测效果较好。



图 5-10 往返直线路段车道线检测效果

Figure 5-10 Detection effect of lane lines in round-trip straight sections

图 5-11 展示了路径采集规划轨迹与人工采集的参考轨迹,其中包含了路径三个方向的轨迹变化,轨迹起点为原点 $(0, 0)$,从图中可以看出,参考轨迹与规划轨迹几乎贴合。



(a) 三向轨迹

(b) 平面轨迹

图 5-11 往返直线路段规划轨迹与参考轨迹

Figure 5-11 Round-trip straight road section planning trajectory and reference trajectory

同时将两段路径轨迹对齐并重采样,对比得到三向定位误差结果,其中部分序列 120s 内的误差结果如图 5-12 所示,定位位置误差主要在-0.15m~0.15m 范围内波动,实验路段中两侧的树木不仅会对检测效果造成偏差,GNSS 信号的接收也会受到小幅度影响,但得益于多传感器融合定位系统的良好性能,使得定位误差没有出现过大的漂移。




图 5-12 往返直线路段数据序列上定位误差

Figure 5-12 Positioning error on the data series of round-trip straight segments

通过计算得到全局定位位置误差的均方根值 RMSE,具体数据如下表 5-2 所示,可见综合车道线检测技术与多传感器融合定位技术的路径采集规划系统在良好的工作情况下能够达到厘米级精度。

表 5-2 往返直线路段定位位置误差 (m)

Table 5-2 Error in the positioning position of the round-trip straight segment

	E 向	N 向	U 向	定位位置
最大值	0.108	0.194	0.089	0.209
最小值	0.003	0.008	0.006	0.009
均方根	0.067	0.069	0.033	0.101

(2) 施工路段实验结果分析


通过在高速施工路段进行实验,验证路径采集规划系统在施工道路场景下的性能,实验场景如图 5-13,在施工高速公路路段大多为直道和曲率较小的弯道;路径上人员较少,利于车道线检测;另外,环境比较开阔,GNSS 信号较好。



图 5-13 施工道路场景

Figure 5-13 Construction road scene

实验过程中,得益于车道线检测算法中模型预测的能力,车道线检测情况较好,如图 5-14 左侧为采集系统的可视化界面,右侧为施工实验路段车道线检测效果示意图。




(a) 可视化界面

(b) 车道线检测效果

图 5-14 施工路段路径信息采集可视化界面

Figure 5-14 Visualization interface for road information collection in construction sections

图 5-15 展示了施工路段下规划轨迹与参考轨迹在 ENU 三向的全局轨迹变化曲线。



(a) 三向轨迹

(b) 平面轨迹

图 5-15 施工路段规划轨迹与参考轨迹

Figure 5-15 Planning trajectory and reference trajectory of construction section

图 5-16 为施工路段部分序列 300s 内的三向定位误差结果,从图中变化趋势来看,误差范围集中在-0.1~0.1m,整体定位效果较好;实验路段空旷,没有大面积的物体遮挡信号源,GNSS 信号接收情况良好,使系统在 GNSS 信息的修正下,误差在合理的范围内波动。




图 5-16 施工路段数据序列上定位误差

Figure 5-16 Positioning error on the data series of the construction road section

通过量化的数据来评估系统在施工路段的整体性能,如表 5-3 为全局定位误差的具体参数指标,从表中可视化数据看出系统的整体定位位置误差较小,这得益于实验路段曲率较小,车道线特征单一;但由于车道线模型中的数据样本有限,车道线预测本身也存在一定的偏差,导致在部分图像帧时刻采集的数据信息出现较大误差。

表 5-3 施工路段定位位置误差 (m)

Table 5-3 Positioning position error of construction road section

	E 向	N 向	U 向	定位位置
最大值	0.138	0.143	0.069	0.181
最小值	0.01	0.013	0.009	0.013
均方根	0.052	0.044	0.025	0.073

总的来说,路径智能采集规划系统在直道和曲率较小的弯道路段下表现较好,比较适用于高速施工路段。同时,系统对车道线的检测效果依赖性较高,遇到部分图像帧时刻检测效果不佳,导致定位误差增大,所以车道线信息的准确性对于整个采集规划系统来说至关重要。

5.4 本章小结 (Brief Summary of the Chapter)

本章首先对系统的采集方式、路径轨迹拟合方式和拟合轨迹的重采样进行了介绍;然后利用路径采集小车在校园场景下的往返直线路段上进行了初步的系统定位性能验证,将规划轨迹与人工采集的真值轨迹进行对比,得到全局定位位置误差,并计算出定位位置均方根误差为 0.101m,总体性能良好;最后在施工道路进行实际验证,实验结果表明:施工路段 ENU 三向定位和定位位置均方根误差分别为 0.052m、0.044m、0.025m 和 0.073m,定位误差较小。总的来说,路径智能采集规划系统在曲率较小的弯道和直道定位性能较好,比较适合施工高速路段,但遇到车道线检测效果不佳的情况,会影响系统的定位性能。

6 结论与展望

6 Conclusions and Prospects

6.1 主要结论 (Main Conclusion)

随着智能化施工和工程车辆智能驾驶的进一步发展,施工道路路径智能采集规划系统作为施工道路智能化施工的重要设备,为工程车辆智能驾驶提供了准确的路径信息,同时工程车辆智能驾驶也是未来智能化施工的重点发展方向。本文以满足高速公路养护热再生机组施工过程中的智能驾驶需求为目标,实现施工前的路径车道线坐标信息采集和轨迹规划,并从深度学习车道线检测和多传感器融合定位两个方面展开相关研究,主要结论如下:

1) 分析了施工道路路径智能采集规划系统的系统需求,根据系统的需求,设计了系统结构的整体方案,确保研究的可行性。其次根据系统的需求和方案要求,选择合适的传感器设备,并将 Linux 系统作为主操作系统,ROS 系统作为数据获取和可视化的平台,最后根据传感器的接线要求和布局要求,设计路径采集系统的实验平台(路径采集小车)。

2) 针对施工道路车道线的磨损、模糊和不连续等问题,首先选择了基于锚点表示的车道线检测算法,并通过自建数据集,经过算法训练后,发现该算法在车道线可视情况下表现良好,但是遇到车道线不可视情况效果一般,并且由于锚点设置过多导致算法变慢。于是针对该情况,设计了基于行分类与混合注意力机制的车道线检测算法,在自建数据集上训练,评价指标 Accuracy 达到 95.59%,FPS 达到 310,从检测效果来看,能够准确地识别施工路径的车道线。

3) 设计一种基于视觉/惯性/轮式里程计紧耦合定位算法,采用一种静态初始化和动态初始化相结合的方法。将局部状态信息与全球导航卫星系统(GNSS)测量信息进行融合实现局部帧与 ENU 帧之间的转换。采用噪声重估计的方式保证惯性测量单元与轮式里程计的同步性。最后通过在 Kaist 数据集上对 VIWO 系统定位性能进行评估,并与典型算法 VINS-Fusion 进行对比,实验表明,本文基于 VIWO 算法更优,各项指标误差更小。并在实际道路上四条弯道与四条直道上对系统初始化性能进行验证,实验表明直道与弯道情况下,相机与 IMU 相对旋转角度平均误差分别为 2.06° 和 0.93° 。分别在厂区和校园路段采集了两段数据集评估 VIWO 系统与 GNSS 信息融合后的轨迹预估效果,通过实验验证,将 VIWO 系统预估轨迹、融合 GNSS 后的轨迹与真值轨迹对比,并得到量化的数据,结果表明:实验路段 1 和 2 在 VIWO 系统下绝对轨迹均方根误差分别为 0.601m 和 0.753m,融合 GNSS 信息后均方根误差为 0.113m 和 0.156m,VIWO

系统与 GNSS 融合后，误差显著降低。

4) 设计了路径采集和轨迹规划方案，首先采用多项式拟合和拟合轨迹重采样的方式对采集信息进行处理；其次利用路径采集小车在校园中往返直线路段上进行系统定位性能初步验证，对比规划轨迹与人工采集的真值轨迹，得到全局定位位置误差，并计算出定位位置均方根误差为 0.101m；然后在施工道路进行实验验证，实验结果表明：施工路段定位位置均方根误差为 0.073m，定位误差波动在合理范围内；最后根据实验结果表明，本文设计的施工道路路径智能采集规划系统总体性能良好，适用于施工高速路段。

6.2 工作展望 (Prospects of Future Works)

本文以施工车辆为应用对象，施工道路智能化施工为研究背景，设计了基于深度学习的车道线检测算法，实现对施工道路车道线的检测，并以此为视觉定位的关键信息，设计视觉/惯性/轮式里程计与 GNSS 融合定位算法，以此对施工路径的车道线坐标进行定位和提取。但由于研究时间有限和实验场景较少等原因，因此未来可以从以下几方面继续展开研究：

1) 本文设计的深度学习车道线检测算法虽然能够准确检测出施工路径的车道线情况，但是由于国内施工道路单车道线的数据集较少，数据模型的泛化性一般，这就需要每次施工前都采集好车道线图像，不断扩充数据集，提高数据模型的泛化性，提供更精确的车道线预测信息和视觉定位信息。

2) 本文只对路径智能采集规划系统的定位性能进行了实验分析，但最终需要将系统规划的路径坐标信息应用到施工车辆上，但由于时间有限，应用到施工车辆上还需要考虑车辆轨迹跟踪和编队控制，因此需要进一步对控制方法展开研究，以实现施工道路热再生机组的智能驾驶。

3) 目前，本文研究的路径智能采集规划系统只在一段高速公路上完成过实验，未来可以应用于多个施工场景，针对不同的环境，进行相关的优化工作，使系统的应用面更广泛。

参考文献

- [1] 中华人民共和国交通运输部, 2022 年交通运输行业发展统计公报[EB/OL].
https://www.gov.cn/lianbo/bumen/202306/content_6887539.htm, 2023.
- [2] 贾元华, 戴东昌, 刘奕. 我国高速公路建设发展的绩效与评价[J]. 北京交通大学学报, 2005, (06): 1-5.
- [3] 林翔, 李强. 公路路面养护决策技术体系[J]. 公路, 2021, 66(10): 357-364.
- [4] 丁蓓妍, 王元庆, 苏新琦等. 公路养护与运行安全管理责任体系构建探讨[J]. 公路, 2017, 62(04): 293-297.
- [5] 李青洋, 刘天云, 王澄. 沥青路面智能化施工系统研究[J]. 公路, 2020, 65(11): 87-90.
- [6] 赵玮, 叶炜, 潘芳, 等. 智能化管控技术在沥青路面施工质量预警处置中的应用[J]. 筑路机械与施工机械化, 2017, 34(07): 111-114+118.
- [7] 刘朝晖, 柳力, 李文博, 等. 融合感知特性的道路铺装结构设计体系研究综述及应用展望[J]. 中国公路学报, 2022, 35(07): 18-35.
- [8] Van Huynh D, Do-Duy T, Nguyen L D, et al. Real-time optimized path planning and energy consumption for data collection in unmanned ariel vehicles-aided intelligent wireless sensing[J]. IEEE Transactions on Industrial Informatics, 2021, 18(4): 2753-2761.
- [9] 张相龙. 基于机器视觉的压路机作业路径识别与轨迹控制系统研究[D]. 西安: 长安大学, 2020.
- [10] 武博文, 薛力戈, 朱洪睿, 等. 路面无人化施工集群装备技术研究[J]. 建筑机械, 2022, (01): 18-20.
- [11] 郝心. 基于无人化技术的工程机械产品设计研究[D]. 济南: 山东大学, 2021.
- [12] 熊璐, 杨兴, 卓桂荣等. 无人驾驶车辆的运动控制发展现状综述[J]. 机械工程学报, 2020, 56(10): 127-143.
- [13] 代凯, 申棋仁, 吴官朴, 等. 基于激光雷达的 SLAM 和融合定位方法综述[J]. 汽车文摘, 2021, (02): 1-8.
- [14] 刘兴堂. 现代导航、制导与测控技术[M]. 北京: 科学出版社, 2010.
- [15] 冯黎, 郭承军. 基于 GNSS/SINS/双目视觉里程计的车载导航系统分析与设计[J]. 汽车技术, 2019, (10): 37-41.
- [16] 马建, 孙守增, 芮海田, 等. 中国筑路机械学术研究综述·2018[J]. 中国公路学报, 2018, 31(06): 1-164.
- [17] Zhang X H, Qing L, Li M. Aided Navigation System Research Based on Multi-Information Fusion[C]//Advanced Materials Research. Trans Tech Publications Ltd, 2012: 479-481.
- [18] Jin S, Cardellach E, Xie F. GNSS remote sensing[M]. Dordrecht: Springer, 2014.
- [19] Johnston G, Riddell A, Hausler G. The international GNSS service[M]// Springer handbook of

- global navigation satellite systems, 2017.
- [20] Esfahani M A, Wang H, Wu K, et al. AbolDeepIO: A Novel Deep Inertial Odometry Network for Autonomous Vehicles[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21(5): 1941-1950.
- [21] Yang H, Li W, Luo C, et al. Research on error compensation property of strapdown inertial navigation system using dynamic model of shearer[J]. IEEE Access, 2016(4): 2045-2055.
- [22] 许哲, 牟晓华, 魏鹏. 北斗卫星导航系统在工程机械中的应用[J]. 全球定位系统, 2016, 41(06): 122-125.
- [23] 沈贺兵. 无人车多源传感器信息融合导航技术研究[D]. 哈尔滨: 哈尔滨工业大学, 2021.
- [24] You K, Ding L, Zhou C, et al. 5G-based earthwork monitoring system for an unmanned bulldozer[J]. Automation in Construction, 2021, 131.
- [25] 赵宇. 柳工“无人驾驶”设备集群助力甘肃高速公路建设[J]. 今日工程机械, 2021(05): 61.
- [26] 吴俊杰, 刘雨辰, 夏永强. 徐工集团无人驾驶设备闪耀京雄京雄高速路面工程无人集群智能化施工观摩会[J]. 市政技术, 2020, 38(06): 4-6.
- [27] 许文杰. 基于深度学习的工程机械无人驾驶方法研究[D]. 泉州: 华侨大学, 2020.
- [28] 林泽昊. 浅析道路工程无人化智能化的发展现状与关键技术[J]. 中国设备工程, 2021, (24): 24-25.
- [29] Voronov Y, Voronov A, Makhambayev D. Current State and Development Prospects of Autonomous Haulage at Surface Mines[J]. E3S Web of Conferences, 2020, 174(11): 01028.
- [30] 丁震, 孟峰. 矿用无人卡车国内外研究现状及关键技术[J]. 中国煤炭, 2020, 46(02): 42-49.
- [31] Kim S H, Lee Y S, Sun D I, et al. Development of bulldozer sensor system for estimating the position of blade cutting edge[J]. Automation in construction, 2019, 106: 58-69.
- [32] Sun Y, Xie H. Lateral Positioning Method for Unmanned Roller Compactor Based on Visual Feature Extraction[C]//2019 3rd Conference on Vehicle Control and Intelligence (CVCI). IEEE, 2019.
- [33] 中国首台徐工无人驾驶液压挖掘机交付矿区[J]. 建筑机械, 2020, (11): 38.
- [34] 翟卫欣, 王东旭, 陈智博等. 无人驾驶农机自主作业路径规划方法[J]. 农业工程学报, 2021, 37(16): 1-7.
- [35] 刘鹏涛, 汪首坤, 王军政, 等. 震源车无人驾驶控制算法设计与应用[J]. 机械工程学报, 2022, 58(06): 211-220.
- [36] Zhang X, Zhang L, Jiao R, et al. Multi-information Fusion Technology for Positioning System[C]//2018 International Conference on Smart Grid and Electrical Automation (ICSGEA).

IEEE, 2018: 408-411.

- [37] Shladover S E, Tan S K. Analysis of vehicle positioning accuracy requirements for communication-based cooperative collision warning[J]. Journal of Intelligent Transportation Systems, 2006, 10(3): 131-140.
- [38] 李安然. 基于 GNSS/IMU/LIDAR 多源信息融合的定位方法研究[D]. 重庆: 重庆大学, 2021.
- [39] Zhu J, Li H, and Zhang T. Camera, LiDAR, and IMU Based Multi-Sensor Fusion SLAM: A Survey[J]. Tsinghua Science and Technology, 2024, 29(2): 415-429.
- [40] Aboutaleb A, El-Wakeel A S, Elghamrawy H, et al. LiDAR/RISS/GNSS Dynamic Integration for Land Vehicle Robust Positioning in Challenging GNSS Environments[J]. Remote Sensing, 2020, 12(14): 2323.
- [41] Dasarathy B V. Industrial applications of multi-sensor multi-source information fusion[C]//Proceedings of IEEE International Conference on Industrial Technology, 2000.
- [42] Li Y, Jia H, Qi J, et al. An acquisition method of agricultural equipment roll angle based on multi-source information fusion[J]. Sensors, 2020, 20(7): 2082.
- [43] 沈跃, 肖鑫桦, 刘慧, 等. 果园机器人 LiDAR/IMU 紧耦合实时定位与建图方法[J]. 农业机械学报, 2023, 54(11): 20-28+48.
- [44] 田伟琴, 田原, 贾曲, 等. 悬臂式掘进机导航技术研究现状及发展趋势[J]. 煤炭科学技术, 2022, 50(03): 267-274.
- [45] 李昂. 采煤机采区绝对定位定姿技术研究[D]. 徐州: 中国矿业大学, 2015.
- [46] Boche S, Zuo X, Schaefer S, et al. Visual-Inertial SLAM with Tightly-Coupled Dropout-Tolerant GPS Fusion[C]// 2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2022: 7020-7027.
- [47] Cao S, Lu X, Shen S. GVINS: Tightly Coupled GNSS-Visual-Inertial Fusion for Smooth and Consistent State Estimation[J]. IEEE Transactions on Robotics, 2022, 38(4): 2004-2021.
- [48] Chen X, Shen C, Zhang W, et al. Novel hybrid of strong tracking Kalman filter and wavelet neural network for GPS/INS during GPS outages[J]. Measurement, 2013, 46(10): 3847-3854.
- [49] Lin J, Zheng C, Xu W, et al. R2LIVE: A Robust, Real-time, LiDAR-Inertial-Visual tightly-coupled state Estimator and mapping[J]. IEEE Robotics and Automation Letters, 2021, 6(4): 7469-7476.
- [50] Mascaro R, Teixeira L, Hinzmann T, et al. GOMSF: Graph-Optimization Based Multi-Sensor Fusion for robust UAV Pose estimation[C]// IEEE International Conference on Robotics and Automation (ICRA), 2018: 1421-1428.
- [51] 王亚平, 张政, 蔺宏良, 等. 智能车辆路径信息采集控制系统的设计研究[J]. 自动化与

- 仪器仪表, 2017, (09): 55-56+59.
- [52] 汪小岳, 李泽晟, 陈彦宇, 等. 高地隙农田信息采集机器人设计与试验[J]. 农业机械学报, 2023, 54(06): 65-77.
- [53] 林相泽, 王祥, 林彩鑫, 等. 基于超宽带的温室农用车定位信息采集与优化[J]. 农业机械学报, 2018, 49(10): 23-29+45.
- [54] 韩向朝, 潘毅, 谢雨冬, 等. 无人机图像采集法对清水混凝土外观质量评价的研究[J]. 材料导报, 2021, 35(S2): 205-212.
- [55] 于向军, 槐元辉, 姚宗伟, 等. 工程车辆无人驾驶关键技术[J]. 吉林大学学报(工学版), 2021, 51(04): 1153-1168.
- [56] Sun T Y, Tsai S I, Chan V. Hsi color model based lane-marking detection[C]// 2006 IEEE Intelligent Transportation Systems Conference, 2006: 1168-1172.
- [57] 李晗. 基于机器视觉的高速车道标志线检测算法的研究[D]. 沈阳: 东北大学, 2006.
- [58] Yoo H, Yang U, Sohn K. Gradient-Enhancing Conversion for Illumination-Robust Lane Detection[J]. IEEE Transactions on Intelligent Transportation Systems, 2013, 14(3):1083-1094.
- [59] Suddamalla U, Kundu S, Farkade S, et al. A novel algorithm of lane detection addressing varied scenarios of curved and dashed lanemarks[J]. 2015 International Conference on Image Processing Theory, Tools and Applications (IPTA), Orleans, France, 2015: 87-92.
- [60] 王其东, 魏震亚, 王乃汉, 等. 基于投影统计与双曲线拟合的车道识别算法[J]. 中国机械工程, 2019, 30(4): 393-399.
- [61] 杨淑琴, 马玉浩, 方铭宇, 等. 基于实例分割的复杂环境车道线检测方法[J]. 浙江大学学报(工学版), 2022, 56(04): 809-815+832.
- [62] Neven D, De Brabandere B, Georgoulis S, et al. Towards end-to-end lane detection: an instance segmentation approach[C]//Proceedings of the IEEE International Conference on Intelligent Vehicles Symposium. 2018: 286-291.
- [63] 杜连旗. 基于多智能体编队的就地热再生机组智能驾驶系统设计[D]. 济南: 山东交通学院, 2021.
- [64] 王其伟, 周勇, 杜连旗. 就地热再生机组联动智能驾驶控制系统设计[J]. 交通世界, 2019, (33): 146-149.
- [65] 海振洋, 王健, 牟思凯, 等. 无人驾驶路径规划算法综述[J]. 农业装备与车辆工程, 2022, 60(11): 142-146.
- [66] Ali M A H, Mailah M. Path Planning and Control of Mobile Robot in Road Environments Using Sensor Fusion and Active Force Control[J]. IEEE Transactions on Vehicular Technology, 2019, (3): 1-1.
- [67] 朱冰, 贾士政, 赵健, 等. 自动驾驶车辆决策与规划研究综述[J]. 中国公路学报, 2024,

37(01): 215-240.

- [68] 许保光, 常嘉欣, 高敏刚. 考虑人车混采的道路信息采集的路径规划研究[J]. 中国管理科学, 2022, 30(04): 218-227.
- [69] Analooee A, Kazemi R, Azadi S. SCR-Normalize: A novel trajectory planning method based on explicit quintic polynomial curves[J]. Proceedings of the Institution of Mechanical Engineers, Part K: Journal of Multi-body Dynamics, 2020, 234(4): 650-674.
- [70] Provine R, Schlenoff C, Balakirsky S, et al. Ontology-based methods for enhancing autonomous vehicle path planning[J]. Robotics and Autonomous Systems, 2004, 49(1-2): 123-133.
- [71] Shi K, Huang L, Jiang D, et al. Path planning optimization of intelligent vehicle based on improved genetic and ant colony hybrid algorithm[J]. Frontiers in Bioengineering and Biotechnology, 2022(10).
- [72] 鲍久圣, 张牧野, 葛世荣, 等. 基于改进 A*和人工势场算法的无轨胶轮车井下无人驾驶路径规划[J]. 煤炭学报, 2022, 47(03): 1347-1360.
- [73] Liu L, Chen X, Zhu S, et al. CondLaneNet: a Top-to-down Lane Detection Framework Based on Conditional Convolution[C]// 2021 IEEE/CVF International Conference on Computer Vision (ICCV), 2021: 3753-3762.
- [74] Tabelini L, Berriel R, Paixao T M, et al. PolyLaneNet: Lane Estimation via Deep Polynomial Regression[C]// 25th International Conference on Pattern Recognition, 2021: 6150-6156.
- [75] Qu Z, Jin H, Zhou Y, et al. Focus on Local: Detecting Lane Marker from Bottom Up via Key Point[C]// 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 14117-14125.
- [76] Tabelini L, Berriel R, Paixao T M, et al. Keep your Eyes on the Lane: Real-time Attention-guided Lane Detection[C]// 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Nashville, TN, USA, 2021: 294-302.
- [77] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]// IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2016.
- [78] Mnih V, Heess N M O, Graves A, et al. Recurrent Models of Visual Attention[C]// International Conference on Neural Information Processing Systems. MIT Press, 2014.
- [79] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[J]. arXiv, 2017.
- [80] Qin Z, Wang H, Li X. Ultra-fast structure-aware deep lane detection[C]// European Conference on Computer Vision. Springer, Cham, 2020: 276-291.
- [81] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]// Proceedings of the European conference on computer vision (ECCV), 2018: 3-19.

- [82] TuSimple benchmark [EB/OL]. <https://github.com/TuSimple/tusimple-benchmark>, 2017.
- [83] Kang R, Xiong L, Xu M, et al. VINS-Vehicle: A Tightly-Coupled Vehicle Dynamics Extension to Visual-Inertial State Estimator[C]//2019 IEEE Intelligent Transportation Systems Conference, 2019: 3593-3600.
- [84] Angelino C V, Baraniello V R, Cicala L. UAV position and attitude estimation using IMU, GNSS and camera[C]//2012 15th International Conference on Information Fusion, 2012: 735-742.
- [85] Qin T, Li P, Shen S. VINS-Mono: A Robust and Versatile Monocular Visual Inertial State Estimator[J]. IEEE Transactions on Robotics, 2017, 34(4): 1004-1020.
- [86] Cioffi G, Scaramuzza D. Tightly-coupled Fusion of Global Positional Measurements in Optimization-based Visual-Inertial Odometry[C]// 2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2020: 5089-5095.
- [87] Jeong J, Cho Y, Shin Y S, et al. Complex Urban LiDAR Data Set[C]// 2018 IEEE International Conference on Robotics and Automation (ICRA), 2018: 6344-6351.
- [88] Qin T, Cao S, Pan J, et al. A General Optimization-based Framework for Global Pose Estimation with Multiple Sensors[J]. arXiv, 2019.
- [89] 蔡金亮. 基于点云数据的机器人自主打磨曲面路径规划方法研究[D]. 长沙: 中南大学, 2022.
- [90] 才子建. 基于多源信息融合的智能车辆同步定位与建图技术研究[D]. 长春: 吉林大学, 2024.
- [91] Pan X, Shi J, Luo P, et al. Spatial as deep: Spatial CNN for traffic scene understanding[J]. Association for the Advancement of Artificial Intelligence, 2018: 7276-7284.
- [92] Hou Y, Ma Z, Liu C, et al. Learning Lightweight Lane Detection CNNs by Self Attention Distillation[C]// 2019 IEEE/CVF International Conference on Computer Vision (ICCV), 2019: 1013-1021.

学位论文数据集

关键词*	密级*	中图分类号*	UDC	论文资助
路径信息采集；车道线检测；多传感器定位；轨迹规划；施工道路	公开	TP24	621	
学位授予单位名称*	学位授予单位代码*	学位类别*	学位级别*	
中国矿业大学	10290	工学	硕士	
论文题名*	并列题名*			论文语种*
施工道路路径智能采集规划系统的研究	Research on Intelligent Collection and Planning System for Construction Road Paths			中文
作者姓名*	王临轩	学号*	TS21050174P31	
培养单位名称*	培养单位代码*	培养单位地址	邮编	
中国矿业大学	10290	江苏省徐州市	221116	
学科专业*	研究方向*	学制*	学位授予年*	
机械工程	工程机械智能化	3 年	2024 年	
论文提交日期*		2024 年 4 月		
导师姓名*	李艾民	职称*	教授	
评阅人		答辩委员会主席*	答辩委员会成员	
盲评		谢方伟	江红祥、宋瑾、黄笛	
电子版论文提交格式：文本（√） 图像（ ） 视频（ ） 音频（ ） 多媒体（ ） 其他（ ）				
电子版论文出版（发布）者		电子版论文出版（发布）地	权限声明	
论文总页数*		85		
注：共 33 项，其中带*为必填数据，共 22 项。				