

分类号:TP39

10710-2021224006



长安大学

专业硕士学位论文

晴雨雾天气场景交通限速标志检测方法研究

任欣宇

导师姓名职称	袁绍欣 副教授		
申请学位级别	电子信息硕士	专业学位类别及领域名称	软件工程
论文提交日期	2024 年 4 月 15 日	论文答辩日期	2024 年 5 月 25 日
学位授予单位	长安大学		

Research on Traffic Speed Limit Sign Detection Method under Sunny, Rainy or Hazy Weather Conditions

A Thesis Submitted for the Degree of Master

Candidate: Ren Xinyu

Supervisor: Associate Prof. Yuan Shaoxin

Chang'an University, Xi'an, China

答辩委员会名单

答辩委员会	姓名	职称	工作单位
主席	李华明	高级工程师	西安拓维科技有限公司
委员	王夏黎	副教授	长安大学信息工程学院
委员	荆树旭	副教授	长安大学信息工程学院
委员	曲卫东	副教授	长安大学信息工程学院
委员	袁绍欣	副教授	长安大学信息工程学院
秘书	李鹏	讲师	长安大学信息工程学院

摘 要

交通标志检测可为智能车辆认知路段提示信息提供依据。雨天或雾天条件会干扰获取的交通图像质量,为交通标志检测造成困难。交通标志的样式会进行更新,导致难以针对新样式的交通标志收集大量的数据样本以训练目标检测模型。现实场景中有多样的天气和目标类别,设计的流程需具有灵活性以应对用户更复杂的需求。研究内容包括:

(1) 研究交通图像晴雨雾天气识别模型。交通图像的天气条件为多种特征的组合,需要综合多样性的特征以识别图像天气。针对该问题,构建基于通道注意力机制的 SE-ResNeXt101 模型,为特征图各通道赋予不同权重,重点关注反映天气特征的通道,同时抑制与天气无关的通道,综合提取天气的多样特征以提高天气识别准确率。模型准确区分晴雨雾天气,为图像增强提供有效的前置分类。

(2) 研究交通图像去雨雾增强模型。雨天图像包含雨线噪声,雾天图像包含雾噪声,在雨天或雾天下进行交通限速标志目标检测易发生漏检或误检。针对该问题,对于包含部分遮挡图像背景的条状雨线噪声的雨天图像,构建 Restormer 模型进行去雨操作;对于包含完全遮挡图像背景的雾噪声的雾天图像,构建 FFA-Net 模型进行去雾操作。研究 Restormer 模型去除不同长度和密度的雨线、FFA-Net 模型去除不同大气光强和散射系数的雾的性能边界。模型可增强受雨或雾影响的图像视觉效果,为目标检测改善条件。

(3) 研究基于深度强化学习的交通限速标志检测模型。现实场景中的交通标志外观样式会进行更新,导致难以针对新样式的交通标志收集足够的图像样本以训练基于深度学习的目标检测模型。针对该问题,以交通限速标志检测为例,模拟人眼视觉注意视野中目标的机制,将交通图像视为环境,设计智能体与环境交互的动作和状态空间,通过改进的 ϵ -greedy 策略训练智能体,使智能体能够更高效地在探索和利用的过程中积累经验而得到训练。构建基于长短时记忆 (LSTM) 模型的深度 Q 网络 (DQN),综合分析历史和实时的感知数据及行为来选择动作,指导智能体调整观察区域,最终定位目标。模型可在较小规模训练集的基础上实现较准确地检测图像中的交通限速标志。

(4) 研究晴雨雾天气场景交通限速标志检测流程模型。如果依靠简单的条件判断语句组合构建的各模型以实现整体逻辑,会导致模块之间出现紧耦合,不利于功能扩展与修改。针对该问题,将设计的各功能模块进行解耦,根据功能模块间的依赖关系设计

有向无环图，基于 Airflow 工作流调度工具构建流程模型，将解耦后的各模块通过功能协作实现晴雨雾天气场景交通限速标志检测的完整服务。低耦合的各功能模块使流程模型具有高可修改性和高可扩展性，当用户需要更新流程中的部分内容时，只需在对应接口进行部分修改即可满足新的需求。

实验结果表明，图像增强模型对雨天或雾天交通图像的恢复操作可为交通限速标志检测提供更加有利的前置条件，有效提升交通限速标志检测的准确率。流程模型中的各功能模块可通过组合协作以实现整体复杂服务，具有高灵活性以应对用户的需求变更。研究为复杂天气场景下的目标检测及功能组合协作方法提供参考。

关键词：通道注意力机制，图像天气识别，图像去雨雾，目标检测，工作流技术

Abstract

The detection of traffic signs provides the basis for intelligent vehicles to recognize road information. Rainy or hazy conditions interfere with the quality of traffic images, complicating the detection of traffic signs. Additionally, the styles of traffic signs are regularly updated, making it challenging to collect a large amount of data samples needed for training detection models. Under the diverse weather conditions and target types present in real-world scenarios, the designed process must be flexible to accommodate more complex user demands. The research includes the following components:

(1) Research on the traffic image weather recognition model. Traffic images exhibit diverse weather characteristics, necessitating the integration of various features to accurately identify the image weather. To address this issue, an SE-ResNeXt101 model based on the channel attention mechanism is constructed. Different weights are assigned to each channel of the feature map, focusing on channels that reflect weather characteristics while suppressing those unrelated to weather. This model accurately distinguishes between sunny, rainy and hazy conditions, providing effective pre-classification for image enhancement.

(2) Research on the traffic image deraining and dehazing enhancement models. Rainy images contain rain streak noise, while hazy images include haze noise, which complicates the detection of traffic speed limit signs under these conditions, leading to missed or false detections. To address this issue, a Restormer model is constructed for deraining images with rain streak noise that partially obscures the image background, and an FFA-Net model is constructed for dehazing images with haze noise that completely obscures the image background. The performance boundaries of the Restormer model in removing rain streaks of various lengths and densities, and the FFA-Net model in removing haze with different atmospheric light intensities and scattering coefficients, are studied. These models enhance the visual quality of images affected by rain or haze, improving conditions for target detection.

(3) Research on the traffic speed limit sign detection model based on deep reinforcement learning. In real-world scenarios, the styles of traffic signs can be updated, making it challenging to collect enough image samples of new sign styles to train deep learning-based object detection models. To address this issue, taking traffic speed limit sign detection as an example, a mechanism simulating the human eye's focus on targets within the visual field is adopted, taking traffic images as the environment. An interaction space of actions and states for the intelligent agent is designed. An improved ε -greedy strategy is used to train the agent, enabling it to accumulate experience more efficiently through exploration and exploitation. A Deep Q-Network (DQN) based on the Long Short-term Memory (LSTM) model is constructed to analyze historical and real-time perceptual data and actions to guide the agent in adjusting the observation area and ultimately locating the target. The model can accurately detect traffic speed limit signs in traffic images on a relatively small training dataset.

(4) Research on the traffic speed limit sign detection workflow model under sunny, rainy or hazy weather conditions. If the overall logic is implemented using simple conditional statement combinations of various models, tight coupling between modules may occur, which is not conducive to function expansion and modification. To address this issue, the designed functional modules are decoupled, and a directed acyclic graph based on the dependency relations between modules is designed. Using the Airflow workflow scheduling tool, a workflow model is built, integrating the decoupled modules through functional collaboration to achieve a complete service for detecting traffic speed limit signs under different weather conditions. The low coupling of the functional modules makes the process model highly modifiable and scalable, allowing for easy updates to specific parts of the process to meet new user demands.

Experimental results indicate that the image enhancement models, by restoring traffic images taken in rainy or hazy conditions, provides more favorable prerequisites for traffic speed limit sign detection, thereby effectively improving the accuracy of such detection. The functional modules within the workflow model can collaborate in a combinatory manner to realize the overall complex service, exhibiting high flexibility to accommodate changing user

requirements. This research offers a reference for target detection and functional module collaboration methods in complex weather scenarios.

Key words: Channel Attention Mechanism, Image Weather Recognition, Image Deraining or Dehazing, Target Detection, Workflow Technology

目 录

第一章 绪论.....	1
1.1 . 研究背景及意义.....	1
1.1.1 . 研究背景.....	1
1.1.2 . 研究意义.....	3
1.2 . 国内外研究现状.....	4
1.2.1 . 图像天气识别研究现状.....	4
1.2.2 . 图像去雨雾研究现状.....	5
1.2.3 . 交通标志检测研究现状.....	7
1.2.4 . 国内外研究现状总结.....	8
1.3 . 研究内容.....	9
1.4 . 论文结构.....	10
第二章 相关理论及技术基础	13
2.1 . 概述.....	13
2.2 . 深度神经网络.....	13
2.3 . 相关功能模型.....	15
2.3.1 . 通道注意力机制.....	15
2.3.2 . SE-ResNeXt101 模型	16
2.3.3 . Restormer 模型	18
2.3.4 . FFA-Net 模型.....	22
2.4 . 深度强化学习理论.....	25
2.5 . AIRFLOW workflow调度工具.....	30
2.6 . 小结.....	33
第三章 交通图像晴雨雾天气识别方法	35
3.1 . 概述.....	35
3.2 . 数据准备及预处理.....	35
3.3 . SE-RESNEXT101 晴雨雾天气识别模型构建	36
3.4 . 实验结果.....	40
3.5 . 小结.....	41
第四章 交通图像去雨雾增强方法	43
4.1 . 概述.....	43
4.2 . 雨雾图像数据集构建.....	43
4.2.1 . 雨雾图像特征分析.....	43
4.2.2 . 雨天图像构建.....	44
4.2.3 . 雾天图像构建.....	45

4.3 . 交通图像去雨雾增强模型构建	46
4.3.1 . Restormer 图像去雨模型	46
4.3.2 . FFA-Net 图像去雾模型	50
4.4 . 模型边界测试.....	51
4.4.1 . Restormer 模型边界	51
4.4.2 . FFA-Net 模型边界.....	52
4.5 . 实验结果.....	53
4.6 . 小结	55
第五章 基于深度强化学习的交通限速标志检测方法	57
5.1 . 概述.....	57
5.2 . 交通限速标志检测问题分析	57
5.3 . 模块结构设计.....	58
5.4 . 动态决策过程设计.....	60
5.4.1 . 交通图像环境设计.....	60
5.4.2 . 动作空间设计.....	61
5.4.3 . 状态空间设计.....	62
5.4.4 . 奖励函数设计.....	63
5.5 . DQN 网络构建	65
5.5.1 . DQN 网络结构设计	65
5.5.2 . DQN 网络训练	67
5.5.3 . DQN 网络预测	71
5.6 . DQN 网络测试	72
5.7 . 小结	73
第六章 晴雨雾天气场景交通限速标志检测流程模型	75
6.1 . 概述.....	75
6.2 . 问题分析与解决方案.....	75
6.3 . 模块依赖关系分析.....	76
6.4 . 流程模型建模.....	77
6.5 . 流程模型运行.....	80
6.5.1 . 运行状态	80
6.5.2 . 运行结果	82
6.5.3 . 失败重试机制.....	83
6.5.4 . 实验结果.....	84
6.6 . 流程模型对新需求适应性	84
6.7 . 小结	86
总结与展望.....	87
总结.....	87
展望.....	88

参考文献.....	89
-----------	----

第一章 绪论

1.1. 研究背景及意义

1.1.1. 研究背景

随着经济的飞速发展，机动车成为了人民群众生活的重要组成部分，保有量稳步提升。然而，由于机动车驾驶员的驾驶水平参差不齐，道路交通环境具有复杂多变的特点，交通事故也成为了当今社会的一个严重问题，对人身安全和财产安全产生了极大的威胁。在早期，为了减少交通事故的发生，交通管理部门采取了加强法规立法、提高驾驶员的培训和教育和交通管理等措施。然而，传统措施存在一些不足，包括过度依赖人为因素、法规执行的难度大、道路设施改善的空间有限等。

随着智能交通系统（Intelligent Transportation System, ITS）技术的快速发展，不少企业在近年开始着手研发基于人工智能技术的车载自动驾驶或辅助驾驶系统。据市场调研报告显示，2022 年中国自动驾驶平台市场销售额达到了 5.89 亿元人民币，其中百度 Apollo 自动驾驶云、华为和阿里巴巴的市场份额位居前列^[1]。这些系统通过集成各种传感器，利用先进算法帮助自动驾驶系统来监测车辆周围的环境，识别潜在的危险，并提供警告或自动采取行动以避免事故。智能车辆在各种外界条件下对其周围交通标志目标的感知方法是自动驾驶技术研究的关键，直接关系到车辆的决策制定的正确性。交通限速标志是交通场景中的一种典型的交通标志目标，通过检测智能车辆周边环境中的交通限速标志，智能车辆可以据此进一步认知路段的限速信息，并向其中央控制系统提供相关数据，有助于使其做出更合适的决策，提升行驶的安全性。如果无法准确地获取相关信息，自动驾驶系统可能会误判情况，导致错误的变速决策，对行驶过程中的人员安全和财产安全构成威胁。因此，如何使得智能车辆准确地感知周边的交通限速标志目标成为了研究无人驾驶技术的重中之重。

现实场景中的复杂天气条件对自动驾驶车辆的视觉系统构成挑战。对于视觉系统而言，晴天一般不影响其获取周边环境特征的能力，但在雨天或雾天条件下，摄像头收集到的图像信息往往会受到干扰。在雨天条件下，快速下落的雨滴在摄像设备捕获的交通图像上会呈现条状的雨线噪声；在雾天条件下，空气中的微小水滴会使得太阳光线发生散射，在交通图像上会呈现灰白色雾遮挡。雨天或雾天直接降低车辆感知信息的质量，

增加自动驾驶系统的风险。为了克服该问题，需要在图像采集阶段识别图像的天气，并针对雨和雾的特点对图像进行增强。近年来，随着计算机硬件性能的更新迭代和算力的增强，人工智能模型的性能得到了大幅提升，深度学习技术在计算机视觉领域的应用为解决该问题提供了新的思路和方法。晴雨雾天气在图像上分别展示出多种特征的组合，例如晴天图像通常包含蓝天白云，且阳光较强；雨天图像通常包含空气中的雨线、潮湿的地面、打伞的行人等；雾天图像的空气中通常包含白色的雾遮挡，且光线由于穿过雾气导致较暗，图像对比度较低等。构建基于深度学习的图像晴雨雾天气识别模型和图像去雨雾增强模型可以有效地识别智能车辆行驶环境的天气类别，并对雨天或雾天采集的图像进行针对性的增强，消除影响图像能见度的雨或雾，从而提高图像的视觉质量，不仅有助于推动自动驾驶技术的发展，而且对提高车辆在复杂环境下自动驾驶的可靠性和适应性具有重要的研究价值。

交通标志目标检测是自动驾驶技术研究的重要组成部分，目的是提升智能车辆在行驶过程中对周边环境交通标志目标的感知能力。交通限速标志检测是其中的一个代表，可以为智能车辆认知路段限速信息提供依据。基于深度学习的目标检测算法主要依赖于将图像划分为若干候选区域，并对其进行迭代搜索，通过比较概率大小以确定目标的边界框，在目标检测领域取得了一定成就。但是，深度学习目标检测模型主要依赖于将图像分割为若干候选区域，并通过对其逐一计算概率的方式查找目标位置，不可避免地出现大量的计算冗余。此外，随着神经网络算法的更新迭代，构建基于深度学习的目标检测模型所需的计算资源要求变得越来越高，训练数据集规模偏大，基于深度学习的目标检测算法已然遭遇了技术发展的瓶颈。深度强化学习是人工智能的一个分支，融合了深度学习在高效特征提取方面的优势以及强化学习在环境交互学习方面的独特性，通过奖励机制引导智能体做出最优选择。经过尝试和错误过程，智能体能够逐步调整其行为策略，从而实现累积奖励最大化的目标。该方法通过设计合理的状态空间、动作空间以及奖励函数，使得模型能够逐步学习如何解析环境的特征变化以及基于当前状态选择最优动作的方法，从全局的角度出发，模拟人眼搜索可视范围内目标位置的过程，自顶向下动态地调整观测区域并定位目标，为目标检测领域带来了一个创新的视角。

在不同天气场景下进行交通限速标志目标检测是一个复杂的流程，其中包含图像晴雨雾天气识别、图像去雨、图像去雾和交通目标检测模型，各模块的具体功能需要独立

执行，模块之间需要互相协作以执行整体逻辑，实现完整的服务流程。由于用户的需求可能发生变更，设计的流程需要满足高内聚、低耦合的特点以实现流程的可扩展与可维护。因此，对各模型之间的依赖关系进行分析，构建有向无环图（Directed Acyclic Graph, DAG），设计晴雨雾天气场景交通限速标志检测流程模型，不仅使得各模块可以自动化调用和执行，提高流程的执行效率，还使得在其中部分服务发生变更时，只需要对流程进行局部调整即可，提升了流程的灵活性。

1.1.2. 研究意义

在此背景下，研究基于深度学习技术构建了交通场景晴雨雾天气识别模型和针对雨天或雾天的图像视觉效果增强模型，基于深度强化学习技术实现了交通限速标志目标检测。此外，基于 workflow 技术构建了晴雨雾天气场景交通限速标志检测流程模型，对各功能模块进行组合与协作，使流程实现更高效的执行。本研究的意义如下：

（1）实现交通图像晴雨雾天气识别模型。为了识别交通图像场景的天气情况，建立基于通道注意力机制的 SE-ResNeXt101 深度残差网络模型，对晴雨雾天气状况图像的深层特征进行学习，从而将图像天气分为晴天、雨天和雾天三个类别，提高自动驾驶系统的环境适应性，为后续交通图像增强实验打下基础。

（2）实现交通图像去雨雾增强模型。分析雨和雾影响图像质量的不同特征，对于雨天或雾天的交通图像，分别建立 Restormer 模型和 FFA-Net 模型，有效消除图像上的雨或雾，提升车辆在复杂天气条件下行驶的可靠性，为后续目标检测实验改善前置视觉条件。此外，验证了两个模型去除不同强度的雨或雾的性能边界。

（3）实现基于深度强化学习的交通限速标志检测模型。为了模拟人眼视觉感知目标的机制，在现实交通场景图像环境下，利用深度强化学习算法，建立适当的状态和动作空间，并通过合适的奖励机制训练深度 Q 网络（Deep Q-Network, DQN），使智能体能够基于识别到的特征做出最优的决策，从而准确地检测交通限速标志目标，提升智能车辆感知系统的准确性和行驶的安全性。

（4）实现晴雨雾天气场景交通限速标志检测流程模型。根据晴雨雾天气场景下目标检测的需求构建 DAG，流程模型接收用户输入的交通图像后能够自动调用和执行各功能模块，功能模块按照流程模型预设的逻辑进行组合协作，为用户提供完整的服务流

程。流程模型具有可修改和可扩展的特征，如果用户需要调整部分功能，只需要变更局部内容，使服务更加灵活、高效。

1.2. 国内外研究现状

1.2.1. 图像天气识别研究现状

自然界中存在着多变的天气，常见的天气包括晴天、雨天、雾天等。使用计算机视觉算法识别图像中的天气，可以帮助智能车辆等系统感知所捕获的图像的天气条件，为进一步对图像中隐含的信息进行感知或认知提供条件。

在早期，研究人员使用机器学习模型实现图像天气分类。Zhang^[2]等人提出了一种基于多类别字典学习和多核学习的方法，通过提取多种天气特征并基于这些特征学习字典来提高图像天气多分类机器学习模型的性能。Lu^[3]等人提出了一种机器学习二分类模型，用于将单张户外图像标记为晴天或阴天。该方法将图像编码为特征向量，在统一的优化框架下协同工作，通过协作学习的方式使模型识别特定天气线索的存在或缺失以实现图像分类。Chen^[4]等人为了识别图像天气，应用图像分割技术以排除非天空区域的干扰，使用多核学习从特定特征池中收集和选择最优的特征子集，并采用多轮次主动学习来训练机器学习模型。但是，基于机器学习的图像天气识别模型要建立在复杂的特征工程上，对机器学习模型的优化需要研究人员建立大量的数学公式，操作过程繁琐，且泛化能力较弱。

随着深度学习的发展，研究人员设计了多种基于卷积神经网络(Convolutional Neural Network, CNN)的深度学习模型对图像中的天气信息进行识别。Kalkan^[5]等人选取了从地面拍摄的天空图像数据集，建立多种深度学习模型对图像中是否存在云层进行识别，得到 VGG-16 在准确性方面表现最佳的结论。Tan^[6]等人设计了三通道 CNN (Three-Channel Convolutional Neural Network, 3C-CNN) 将图像中的天气分为多个类别。Xiao^[7]等人设计了 MeteCNN 网络，用于天气现象的分类。然而，传统的 CNN 模型可能无法充分捕捉到图像中与天气识别最相关的部分，限制了其对图像天气条件中的复杂细微特征的捕捉能力。

自从注意力机制问世后，研究人员将其应用于不同的神经网络架构，通过对网络结构中的不同部分自适应地赋予不同的权重以提升天气识别准确率。Xie^[8]等人提出了基于

图卷积网络（Graph Convolutional Network, GCN）和注意力机制的 GCN-A 多标签天气识别模型。这是首次将 GCN 应用于图像天气识别，可以捕捉不同天气条件之间的复杂依赖关系。Zhao^[9]等人开发了一种基于 CNN 和递归神经网络（Recurrent Neural Network, RNN）的图像天气分类方法，将注意力机制融入 CNN 以提取视觉特征，并通过 RNN 挖掘天气类别之间的依赖性。

1.2.2. 图像去雨雾研究现状

雨、雾等低能见度条件会显著降低图像的质量，进而影响相关算法的性能。在智能交通系统中，图像去雨雾的主要目的是提高在不良的外界环境条件下获取的图像的质量，提高智能车辆搭载的各类模型在雨天或雾天条件下性能的可靠性。

在雨天条件下，大量的雨线会遮挡视野，导致视觉感知系统难以识别图像中的对象，且雨水会散射光线，造成图像的对比度下降，使其细节变得模糊不清，导致计算机视觉系统在雨天下的识别准确性大幅降低。因此，开发能够适应雨天条件的图像恢复技术是计算机视觉领域的一个重要研究方向，其目标在于去除图像上的雨线噪声，提高图像识别、检测和分析的鲁棒性和准确性。

在过去，研究人员基于传统的数字图像处理方法实现去雨效果。Kim^[10]等人分析了雨迹的典型特征，并设计了非局部均值（Non-Local-means, NL-means）算法以去除视频中的雨迹。刘亚楠^[11]等人基于阈值滤波理论提出了一种图像去雨算法，通过改进的引导滤波技术提取低频部分，并设置约束保持高频部分非负，利用方差值设定阈值以保留纹理细节。Chang^[12]等人引入了一种以低秩先验为基础的方法，结合局部和非局部稀疏性处理复杂噪声，优化了去雨的效果。然而，传统的图像去雨方法需要根据图像的具体特征信息来确定繁杂的参数，在不同场景以及不同强度雨的条件下的具体公式和参数各不相同，泛化能力较弱。

在当代的计算机视觉研究中，深度学习技术的兴起已成为推动创新的核心动力。深度学习方法在图像去雨任务中展现出的优越性不仅在于可以精确地去除图像中的雨线，还在于其对各种复杂场景的适应能力。通过深度神经网络的特征提取和学习，这些方法不仅提高了图像处理的效率，而且在实际应用中获得了广泛的应用和认可。Zamir^[13]等人提出的 Restormer 模型是其中的一个代表。该模型基于优化的 Transformer 块构建，其中的 Transformer 块由多深度卷积头转置注意力（Multi-Dconv head Transposed Attention,

MDTA) 机制和门控深度卷积前馈网络 (Gated-Dconv Feed-forward Network, GDFN) 组成。其中, MDTA 可以从全局的角度计算生成注意力图, 不受像素间物理距离限制, 捕获长距离依赖关系; GDFN 通过引入门控机制来控制特征传播, 能够根据图像内容自适应地调整信息流, 允许模型强调更有用的特征, 同时抑制不重要的特征。Restormer 模型主要由编码和解码两个部分组成, 在编码环节, 高分辨率的有雨图像会经过若干优化的 Transformer 块, 被映射到高维度空间, 在此空间中雨噪声和背景会得到分离, 易于被神经网络学习雨噪声的特征, 并进行去除。随后, 在解码环节, 特征被还原为高分辨率的图像。该模型可以有效地去除图像中的雨噪声, 提升图像的视觉效果。

在雾天条件下, 环境中悬浮的小水滴等物质导致光线散射和吸收现象加剧, 进而对成像设备捕获的视觉信息产生显著的遮蔽和干扰效果, 通常表现为图像的模糊化、对比度降低以及色彩饱和度的减弱, 从而对计算机视觉系统的图像处理能力构成挑战。为了对抗不利影响, 研究人员开始探索应用图像去雾技术, 其目标在于提升图像的局部细节, 通过抑制图像中的非主要信息, 使图像中的关键特征得以凸显, 减小雾天对图像质量的负面影响。

过去的研究人员依赖传统的数字图像处理方法为图像去雾。He^[14]等人提出了暗通道先验算法, 该算法基于室外无雾图像的统计特性实现, 即在至少一个颜色通道中, 大多数局部图像块有一些像素强度非常低, 可以据此估算雾霾厚度, 并恢复无雾图像。但是, 该算法在本身就较暗的环境下恢复图像时很可能发生失真, 在没有明亮背景的场景下效果不佳。Zhu^[15]等人提出了一种基于颜色衰减先验的单幅图像去雾方法。该方法通过建立线性模型学习模糊图像的深度信息, 并使用大气散射模型恢复图像亮度。Fan^[16]等人提出了一种用于尺度自适应和颜色校正的 Retinex 去雾算法, 能够解决 Retinex 去雾算法需手动设置高斯参数和去雾后图像色偏的问题。然而, 传统的去雾算法需要对每种场景的特定特征进行精细调整, 在处理多样的实际场景时不够灵活, 使得算法难以广泛应用于不同强度和不同场景的去雾任务。

近年来, 深度学习驱动的图像去雾算法日益成熟。深度学习算法通常建立在图像退化模型的基础上, 通过深度神经网络架构进行模型中关键参数的高效估计。近年来, 计算机视觉学界涌现了大量的神经网络去雾模型。Qin^[17]等人提出的 FFA-Net 模型是其中的一个代表。该模型基于若干包含特征注意力 (Feature Attention, FA) 机制的组结构与

块结构实现,特征注意力机制由两种不同的注意力机制组成,其中包括通道注意力机制和像素注意力机制。通道注意力机制可以将图像中的不同元素映射到不同通道上,增强模型学习图像中 useful 元素特征的能力;像素注意力机制可以捕获图像中不同区域中不同浓度的雾的特征,提升模型对于不同强度的雾天图像的增强效果。

1.2.3. 交通标志检测研究现状

交通标志检测是计算机视觉领域的一个关键研究方向,其主要任务是确定交通标志在图像中的位置,通常通过在对象周围画出一个矩形框来实现。

在早期,交通标志检测主要依赖于传统的方法。Benallal^[18]等人通过比较 RGB 颜色分量以检测交通标志的位置。García-Garrido^[19]等人使用改进的霍夫变换通过检测交通标志的轮廓来对其进行定位。Piccioli^[20]等人将交通标志的几何特征作为先验知识,通过与标准交通标志模板进行模板匹配及计算相似度的方法以实现限速标志检测。然而,传统目标检测算法在处理大规模数据集时面临计算效率低、对复杂变化敏感度高和适应性差等挑战。

随后,研究人员在传统方法的基础上结合机器学习算法以检测交通标志。常发亮^[21]等人提出了一种结合高斯颜色模型和机器学习的交通标志检测算法,通过高斯颜色模型对交通标志图像进行分割和形态学处理以提取候选标志,并使用 HOG 描述子和 SVM 分类器对其进行精确检测。Chen^[22]等人提出了一种基于 AdaBoost 和支持向量回归(Support Vector Regression, SVR)的交通标志检测技术,通过特定于交通标志的颜色、形状和空间信息,创建增强的特征金字塔,利用 AdaBoost 模型检测候选标志,并通过 SVR 模型识别真实的交通标志。曹继承^[23]提出了一种结合多尺度池化和聚合通道特征的方法,通过合并不同尺度的通道特征增强了特征描述子的目标抽象能力,利用 AdaBoost 级联分类器的高效分类性能,有效降低了限速标志的漏检率。

随着深度学习的发展,研究者开始将视线转向深度神经网络。Ghasemi^[24]等人认为基于深度学习的目标检测算法主要分为两大类:一类是基于区域候选的两阶段算法,如 Girshick^[25]等人提出的基于区域的卷积神经网络(Region-CNN, R-CNN)算法;另一类是基于回归的一阶段算法,以 Redmon^[26]等人提出的 YOLO(You Only Look Once)算法为代表。例如,Zhang^[27]等人使用级联 R-CNN 和金字塔多尺度特征提取方法检测交通

标志,通过层间融合和联合训练增强检测能力,并引入多尺度注意力机制以提高检测准确性。Yu^[28]等人结合 YOLOv3 和 VGG19 网络,用于视频序列中交通标志的准确检测。

近年来,基于深度强化学习的目标检测算法在计算机视觉领域得到了研究并取得了一定的成果,展现出很大的潜力。Caicedo^[29]等人首次将深度强化学习算法应用于目标检测,使用深度强化学习算法训练 DQN,使模型在图像中迭代地调整观察窗口以定位目标。吴志鹏^[30]等人将该算法运用于交通标志目标检测,并通过调整折扣因子和学习率以提高性能。虽然基于深度强化学习的目标检测算法在某些任务上已经取得了令人瞩目的成果,但是这些方法仍然面临许多挑战,包括如何对环境的特征进行高效提取,如何处理不稳定的奖励、复杂的状态和动作空间,以及如何建立符合目标检测场景需求的 DQN 网络结构以提高模型训练的稳定性和效率等。因此,基于深度强化学习的目标检测算法的研究仍然是一个活跃的研究领域。

1.2.4. 国内外研究现状总结

在现有的图像天气识别领域,研究人员从使用基于数学和统计学的机器学习算法逐渐过渡到构建基于神经网络的深度学习模型并引入了注意力机制,提高了模型的准确性。然而,现有的天气识别算法对现实场景下天气信息复杂特征的抓取和关注能力有限。因此,本研究构建了 SE-ResNeXt101 模型,将图像的各特征元素反映在特征图的不同通道内,基于通道注意力机制对与天气条件相关的特征通道赋予更高的权重,在现实场景的测试中展现出高精度和优异性能。

在现有的图像去雨雾研究领域,研究人员从依赖于传统数字图像处理技术的算法逐渐演进到采用深度学习方法,提升了算法的泛化能力,在多个标准数据集上展现了卓越的性能。本研究构建了 Restormer 去雨模型和 FFA-Net 去雾模型两种深度学习模型,对雨天或雾天条件下交通图像的视觉质量进行增强,并在实际场景测试中测试 Restormer 去雨模型去除不同长度和密度的雨、FFA-Net 模型去除不同大气光强和散射系数的雾的性能边界。

在现有的交通标志检测研究领域,研究人员从传统的数字图像处理技术过渡到基于深度学习的方法,进而探索融合强化学习的新思路。尽管深度学习算法在现实应用上取得了卓越的性能,然而,这些模型的训练过程通常需要较大的数据集,难以针对新出现的交通标志数据样本进行收集并训练目标检测模型。本研究以交通限速标志目标检测为

例，引入了深度强化学习算法，开发了一种新型的目标检测模型实现交通限速标志目标检测。该模型采用主动学习策略，模拟人眼的视觉机制自顶向下地调整观察区域，定位交通场景中的特定目标。

现有的图像天气识别、图像去雨雾增强与目标检测相关的研究局限于孤立的功能模块，对于复杂的业务逻辑则缺乏表达能力。因此，本研究设计了基于 Airflow 工作流调度工具的流程模型，构建流程模型对功能模块的拓扑关系进行表达，使功能模块之间通过组合协作完成整体的复杂功能。流程模型中具有低耦合性的各模块使其实现了高可修改性和高可扩展性，当用户需要修改流程中的部分模块或对功能进行扩展时，只需进行部分修改即可满足新的需求。

1.3. 研究内容

考虑到现实交通场景下复杂气候条件对图像质量产生的不利影响，建立深度学习模型以准确识别环境中的晴雨雾天气条件。针对该模型识别到的雨天或雾天条件，建立针对性的图像去雨雾增强模型来恢复图像质量。建立基于深度强化学习的 DQN 模型，对图像中的交通限速标志目标进行检测，设计晴雨雾天气场景交通限速标志检测流程模型，将整体流程解耦为具有单一职责的功能模块，基于工作流技术实现功能模块的组合和协作，实现模型的自动选用和执行。具体的研究内容如下：

（1）研究交通图像晴雨雾天气识别模型。分析晴雨雾天气在交通图像上展现的多种综合特征，建立 SE-ResNeXt101 模型，通过通道注意力机制将注意力集中在与天气条件有关的特征上，并抑制无关特征，实现了对天气状态细微深层特征的高效学习。模型能够精准地对交通图像晴雨雾天气状况进行分类，增强智能车辆在多变气候条件下的稳定性。

（2）研究交通图像去雨雾增强模型。针对雨天或雾天特征的本质不同，分别建立深度学习模型以实现图像视觉效果的增强。针对雨天图像构建 Restormer 模型；针对雾天图像构建 FFA-Net 模型，去除交通图像上的雨或雾，提升智能车辆获取的图像质量。此外，验证了 Restormer 去雨模型和 FFA-Net 去雾模型在不同强度的雨或雾下展现的性能边界。

(3) 研究基于深度强化学习的交通限速标志检测模型。应用深度强化学习算法,构建适当的状态和动作空间,利用合理的奖励机制和改进的 ϵ -greedy 算法使智能体在与环境的不断交互中利用经验回放原理、试错机制、建立策略网络和目标网络学习最优价值函数,进而获得最佳策略。引入 LSTM 模型对 DQN 进行改进,能够结合历史和当前的感知特征选择合适的动作,在交通场景图像中准确检测交通限速标志目标。

(4) 研究晴雨雾天气场景交通限速标志检测流程模型。将整体的功能逻辑解耦为多个具有单一职责的功能模块,利用 DAG 表示各功能模块之间的依赖关系,基于 Airflow 构建流程模型,可以自动调用对应的模型对图像天气进行分类,改善雨天或雾天下的图像视觉效果,并对其中的限速标志目标进行检测,向用户提供完整的服务流程,显著提升流程的执行效率。由于功能模块基于高内聚、低耦合原则设计,流程模型中的个别模块变化或需要扩展功能逻辑时,只需要找到相应的接口,对其中部分内容进行调整即可,使得流程具有较高的灵活性。

1.4. 论文结构

本论文分为六章,各章节的具体内容如下:

第一章,绪论。本章首先论述论文的研究背景,并结合研究背景提出论文的研究意义;其次介绍了图像去雨雾算法和目标检测算法的研究现状,并作出了研究评述;最后明确了论文的主要研究内容和结构。

第二章,相关理论及技术基础。本章讲述图像晴雨雾天气识别、交通图像去雨雾增强和利用深度强化学习进行目标检测的核心算法基础,介绍深度学习的基本理论,详细介绍了通道注意力机制、SE-ResNeXt101 残差网络模型、Restormer 去雨模型、FFA-Net 去雾模型、深度强化学习的相关原理以及 Airflow 工作流调度工具。

第三章,基于 SE-ResNeXt101 模型的图像晴雨雾天气识别方法。本章聚焦于综合分析晴雨雾天气图像的不同特征,构建并训练 SE-ResNeXt101 模型进行图像晴雨雾天气分类,以支持后续的雨天或雾天图像增强和目标检测实验。实验结果显示模型具有较高的准确性。

第四章,交通图像去雨雾增强方法。本章探讨雨或雾对图像视觉质量造成干扰的原因,针对两者的本质不同,构建用于训练监督学习模型的图像数据集,并针对性地选用

深度学习模型以实现图像视觉效果增强。针对雨天图像，建立 Restormer 模型实现图像去雨；针对雾天图像，建立 FFA-Net 模型实现图像去雾。最后，验证了模型在不同程度的雨或雾下展示的性能边界。

第五章，基于深度强化学习的交通限速标志目标检测方法。本章建立并训练基于深度强化学习的目标检测模型，用于检测图像中的交通限速标志。构建包含交通限速标志的图像数据集作为环境，设计状态空间、动作空间、奖励函数以及基于 LSTM 模型的 DQN，对现实交通场景下的交通限速标志目标进行检测。

第六章，晴雨雾天气场景交通限速标志检测流程模型。本章分析了构建的图像晴雨雾天气识别、去雨、去雾和交通限速标志检测模型之间的依赖关系，将整体服务解耦为 4 个具有单一职责的功能模块，基于 Airflow 工作流调度工具设计流程模型。流程模型具有高可修改性和高可扩展性以满足用户多变的需求。

本文的组织结构图如图 1.1 所示。




图 1.1 论文组织结构图

第二章 相关理论及技术基础

2.1. 概述

探讨实验中涉及的相关核心算法的理论及技术基础。首先，介绍深度学习的基本概念，其次深入解析通道注意力机制、SE-ResNeXt101 残差网络模型、Restormer 去雨模型以及 FFA-Net 去雾模型的结构和原理。接着，探讨强化学习与深度强化学习的相关理论。最后，介绍 Airflow 工作流调度工具。通过深入探讨以上算法和模型的原理，为后续的实验设计、实现和结果分析奠定了坚实的理论基础。

2.2. 深度神经网络

深度神经网络也称为人工神经网络，其设计灵感来源于人类的神经结构，是一种模拟人脑神经行为的计算模型，用于模拟、理解和应用人脑的机制进行模式识别和决策，通过复杂的连接来拟合数据的非线性特征，在分类^[31]、回归^[32]、聚类^[33]问题等领域已经证明了其优秀的性能。

（1）反向传播神经网络

反向传播神经网络（Back Propagation Neural Network，BPNN）是一种经典的神经网络，采用了基于梯度的优化策略，其目标是最小化网络的预测输出和目标输出之间的均方误差函数。BPNN 的训练过程首先通过正向传播阶段，网络的输入信息在各层之间前馈传递，直至输出层产生预测结果。随后，预测输出与目标输出之间的差异形成损失函数，该函数关于网络参数的梯度通过链式法则在网络结构中逆向传播。在逆传播阶段，损失函数的梯度被用于逐层计算误差信号，更新各层的权重和偏置参数，从而在迭代过程中逐步减少输出误差。由于 BPNN 对非线性关系较强的映射能力，在计算机视觉的诸多领域被研究者们广泛使用^[34]。

（2）卷积神经网络

卷积神经网络（Convolutional Neural Network，CNN）是一种前馈深度学习模型，在设计概念上受到动物视觉皮层的启发，在图像处理^[35]、语音识别^[36]和文本处理^[37]等领域具有广泛的应用。

一个典型的 CNN 模型由卷积层（Convolutional Layer）、池化层（Pooling Layer）、激活函数（Activation Function）以及全连接层（Fully Connected Layer）构成。其中，卷积层负责提取输入数据的局部特征；池化层用于降低数据的维度并保持数据的主要特征；激活函数为网络提供非线性处理能力，增强模型的表示能力；全连接层将前述各层提取的特征进行整合，并输出最终的结果。CNN 的结构示意图如图 2.1 所示。




图 2.1 卷积神经网络结构图

（3）LSTM 网络

长短期记忆（Long Short-Term Memory, LSTM）^[38]网络是一种循环神经网络（Recurrent Neural Network, RNN），可以从时间序列中学习长期依赖，在深度学习中得到了广泛应用^[39]。LSTM 为解决实际应用中输入数据为有序时间序列的问题而设计。原始的 RNN 无法处理长距离的依赖性，其隐藏层只有一个状态，对于短期输入非常敏感。LSTM 在 RNN 中增加了细胞状态（Cell State），使其能够保存长期状态。LSTM 的结构如图 2.2 所示。




图 2.2 LSTM 模型结构图

在 LSTM 中，节点使用内部状态作为数据记忆存储单元，可以在多个时间步骤上存储和检索信息。节点计算使用的输入值、先前的输出以及内部状态，计算结果不仅用于提供输出值，还用于更新状态。

与普通的神经网络类似，LSTM 节点具有决定计算中用到的输入数据权重的参数。但是，LSTM 还有一种称为门（Gate）的参数，包括训练获得的权重和偏置，控制了节

点内信息的流动。LSTM 门的值在 0~1 之间变化，表示允许通过多少信息。因此，使用 Sigmoid 函数作为激活函数。

2.3. 相关功能模型

2.3.1. 通道注意力机制

在卷积神经网络（Convolutional Neural Network, CNN）的训练过程中，输入的数据经过卷积层后会生成其特征图，特征图的不同维度中隐含了图像上不同元素的特征信息。通道注意力（Channel Attention）机制^[40]是一种通过压缩与激励（Squeeze and Excitation, SE）操作体现的注意力机制，通过对特征图内部每个通道维度的特征进行自适应权重标定，使网络将注意力集中于有用的特征，并抑制不重要的特征，结构如图 2.3 所示。




图 2.3 通道注意力机制模块图

首先，特征转换（Transformation）操作 F_t 将形状为 $H' * W' * C'$ 的输入特征图 X 通过标准的卷积操作转换为形状为 $H * W * C$ 的输出特征图 U 。该步骤为可选操作，如果输入特征维度为 $H * W * C$ ，则不需要此步骤。然后，压缩（Squeeze）操作 F_{sq} 利用通道的全局平均池化来提取全局信息，将维度为 $H * W * C$ 的特征图转换为 $1 * 1 * C$ 的特征向量 z ，即每个通道的特征被压缩成单一的数值。随后，激励（Excitation）操作 F_e 利用压缩阶段获得的信息全面捕获通道依赖性。采用由两层全卷积层组成的门控机制，第一层将通道数从 C 压缩至 $\frac{C}{r}$ 以降低参数量和计算复杂度，压缩比例 r 用于控制模型的参数量。经过 ReLU 激活函数后，第二层将通道数恢复至 C ，并通过 Sigmoid 激活函数产生权重 s ，用于表示 U 中各个特征图的重要性。最后，加权（Scale）操作 F_{sc} 将激励阶段计算得到的权重 s 应用于特征图 U 的每个通道。将 U 中的每个特征图乘以其对应的权重，得到加权调整后的特征图 $\tilde{X}$ ，以强调更重要的特征并抑制不重要的特征。

2.3.2. SE-ResNeXt101 模型

SE-ResNeXt101 模型是一种优化的残差网络^[41]模型，在 ResNeXt101^[42]的基础上融合通道注意力机制算法，可以提升模型对图像深层特征的挖掘能力以提高准确率。

(1) 残差网络

在使用深度神经网络拟合训练数据时，模型追求的是在其未见过的数据上的泛化能力，即对训练集以外的数据进行精确预测。对于较为细微和复杂的输入特征，神经网络需要较多的层数以增加特征图提取深度和神经元数量，对训练集的特征进行拟合。然而在实践中，模型在叠加较多的卷积层数后常遇到梯度消失的问题，即模型在训练的反向传播过程中梯度随着层级的增加而递减，导致浅层的权重更新非常缓慢，甚至停止更新。

残差网络（Residual Network, ResNet）通过引入残差学习来解决深度神经网络训练过程中的梯度消失问题。ResNet 的核心思想是引入了残差连接。残差连接又称为跳过连接（Skip Connection），允许输入跳过一些层并添加到更深层的输出上。因此，神经网络的层不再学习整个特征转换，而是学习输入特征与输出特征之间的差异。残差连接有助于缓解梯度消失问题，使得网络能够有效地进行更深层次的训练。

为解决不同的问题，残差网络可具有不同的深度。例如，ResNet101 残差网络包含 101 层深的卷积部分。ResNet101 模型中包含多个阶段，每个阶段都包含多个残差单元。该过程首先将数据输入 7*7 的卷积层、批归一化（Batch Normalization）^[43]层、ReLU 激活函数和最大池化层，然后将转换结果输入包含 4 个阶段的残差块的模型主干，每个阶段由多层卷积网络结构组成。最后，将数据输入全局平均池化（Global Average Pooling）层、全连接层和 Softmax 激活函数，输出结果。

(2) 组卷积运算

ResNeXt 模型是一种改进的 ResNet 模型，使用组卷积运算代替普通卷积运算以提升计算效率。普通的卷积运算中，假设输入特征矩阵具有 C_{in} 个通道，则每个卷积核也必须具有相应的 C_{in} 个通道以便执行卷积操作。如果需要输出具有 n 个通道的输出特征矩阵，则应具有 n 个卷积核。当卷积核尺寸为 $k*k$ 时，普通卷积操作的总参数量为 $k*k*C_{in}*n$ 。组卷积运算中，同样假设输入特征矩阵具有 C_{in} 个通道。但是，输入被分为 g 组，每组独立进行卷积操作。以图中 $g=2$ 为例，输入的特征矩阵被分为两组，每

组的卷积核通道数减半至 $\frac{C_{in}}{2}$ ，并假设每组使用 $\frac{n}{2}$ 个卷积核。因此，每组卷积操作后产生 $\frac{n}{2}$ 个通道的特征矩阵。最终，对两组的输出进行拼接，得到的输出特征矩阵恢复至 n 个通道。在组卷积中，每组的参数量为 $k * k * \frac{C_{in}}{2} * \frac{n}{2}$ ，因此，两组的总参数量为 $k * k * \frac{C_{in}}{2} * n$ 。

(3) SE-ResNeXt101 的残差块结构

将以压缩和激励（SE）操作体现的通道注意力机制应用于 ResNeXt 中。优化的残差块的设计采用了降维与升维的策略，以优化数据流经网络时的信息传递和梯度反向传播。该结构首先利用 $1*1$ 卷积核降低特征矩阵的通道数以减轻计算负担，并提高计算效率。随后，残差块引入组卷积作为中间处理层，采用的卷积核尺寸为 $3*3$ ，组数 $g = 32$ 。组卷积分割特征矩阵并在各个子集上独立操作，能够在保持通道数不变同时，促进不同通道组间的特征融合。然后，再次运用 $1*1$ 卷积核进行升维，将特征矩阵的通道数恢复至初始值。将输出的特征矩阵输入通道注意力模块，并将输出的注意力权重与该特征矩阵加权。最终，通过将特征矩阵与原始输入进行按元素相加，使用残差连接的思想，得到残差块的输出。优化后的残差块的结构如图 2.4 所示。




图 2.4 优化后的残差块结构图

将 ResNeXt101 模型中的残差块采用上述优化后的基于通道注意力机制的残差块替代,得到优化后的 SE-ResNeXt101 模型。该模型可解决在神经网络卷积层数较多的情况下可能产生梯度下降的问题,且相较于普通的残差网络,可在提升准确率的同时提升计算效率。

2.3.3. Restormer 模型

Restormer 模型是一种基于优化的 Transformer 块构建的图像去雨模型。其中的 Transformer 块由多深度卷积头转置注意力 (Multi-Dconv head Transposed Attention, MDTA) 机制和门控深度卷积前馈网络 (Gated-Dconv Feed-forward Network, GDFN) 组成。

(1) Transformer 模型

Transformer 模型^[44]是一种基于自注意力 (Self-Attention) 机制的模型。自注意力机制是一种捕捉长期依赖关系的有效方法,其优点在于能够显著地识别和运用数据序列中元素间的内在相关性。Transformer 架构由编码器和解码器两部分组成,编码器和解码器由多个功能块的重复堆叠构成。

Transformer 模型中的编码器每个模块内主要包括多头自注意力机制和位置感知的前馈神经网络 (Position-wise Feedforward Neural Network, PFNN),并辅以残差连接和层归一化组件。多头自注意力部分由若干自注意力单元并行组成,可以捕捉序列内各元素间的复杂关系。多头自注意力并行地计算多组查询、键和值向量,每一组都被称为一个“头”。这些头通过不同的线性变换矩阵来生成,每一个头捕获序列的不同方面的信息。残差连接用以缓解训练深层网络时可能出现的问题,允许模型专注于输入与输出之间的差异性,防止性能退化。Transformer 模型中的解码器在架构上类似于编码器,但引入了关键的差异以适应其在序列生成任务中的特定角色。解码器模块包含两个关键的多头自注意力子层。第一个多头自注意力层实施掩码操作,防止在预测当前时间步的输出时不合理地利用后续位置的信息。该层使用的查询、键和值矩阵均来源于上一解码器层的输出,但通过掩码确保了自注意力计算仅限于当前和之前的时间步。第二个多头自注意力层负责协调解码器与编码器之间的信息流。此处的查询矩阵仍然来源于解码器的上一层输出,而键和值矩阵则直接使用编码器的输出,从而允许解码器访问输入序列的上下文信息,使得解码器能够在生成每个新元素时考虑到整个输入序列的信息。除了多头注意

力子层之外，解码器还包含一个 PFNN，其结构与编码器中的 PFNN 相同。每个子层之后都跟随一个残差连接，然后进行层归一化操作。最终，解码器在生成每个时间步的输出之前经过了 Softmax 激活函数，负责输出序列中下一个观察点的概率分布。

(2) MDTA 机制

原始的 Transformer 架构中的自注意力机制计算开销较大。对于宽度为 W 、高度为 H 的图像，其时间复杂度约为 $O(W^2H^2)$ ，难以胜任高分辨率图像恢复等复杂任务。如果只在像素周围较小的空间窗口上计算注意力图，或将图像分割为若干部分并在每个部分上计算注意力图，会导致算法无法捕获长距离像素之间的依赖关系。为解决该问题，在 Transformer 块中引入了 MDTA，在增加计算效率的同时，拥有捕获长距离像素之间依赖关系的能力。传统的自注意力机制计算特征图需要考虑特征图空间中每个像素与其他所有像素的交互关系。由于每个像素都要与其他所有像素进行比较，当像素数量增加时，计算量会呈二次方增长。对于高分辨率的图像，会导致计算量非常大。MDTA 计算注意力图时不需要将每个像素与其他所有像素进行比较，而是计算通道维度上的交叉协方差，通过聚焦于特征通道的交叉关系而不是像素位置的直接关系生成注意力图，将自注意力机制的复杂度从 $O(n^2)$ 复杂度降低到基于特征通道数的 $O(n)$ 线性复杂度。这种计算从全局的角度生成注意力图，不受像素之间物理距离的限制，因此可以捕获长距离依赖关系。MDTA 的结构图如图 2.5 所示。




图 2.5 MDTA 结构图

(3) GDFN 网络

传统的前馈网络（Feed-forward Network, FN）对每个像素位置的处理是独立且一致的，对所有像素应用相同的变换，而不考虑其在图像中的上下文或位置，忽略了图像中不同区域的特异性。GDFN 对 FN 进行了改进，在其中引入门控机制，控制不同特征的流动，从而使网络能够根据当前的任务和图像内容自适应地调整信息流。同时，GDFN 采用深度卷积，增强其在特征转换过程中的表示能力。

通过引入门控机制，GDFN 可以控制不同特征的流动，从而使网络能够根据当前的任务和图像内容自适应地调整信息流，允许模型区分和强调更有用的特征，同时抑制不重要的特征。GDFN 的结构如图 2.6 所示。




图 2.6 GDFN 结构图

对于一个形状为 $\hat{H} * \hat{W} * \hat{C}$ 的输入特征张量 X ，GDFN 采用通过两个平行的线性变换层的逐元素乘积实现的门控机制。与 MDTA 相似，两个线性变换层中都会对输入特征计算 $1*1$ 点卷积和 $3*3$ 深度卷积操作，以便从空间上相邻的像素位置编码信息，进而学习局部图像结构以实现有效的图像恢复。

(4) 优化的 Transformer 块

优化的 Transformer 块包含 MDTA 和 GDFN 两个部分。输入特征首先通过 MDTA 机制，从全局的角度以线性时间复杂度生成特征的注意力图；GDFN 通过门控机制允许有用的信息进一步传播。

(5) Restormer 模型结构

Restormer 模型融入了多尺度（Multiscale）层次结构，包括 4 个由若干优化后的 Transformer 块组成的层，以及若干卷积操作、下采样操作、上采样操作和残差结构。Restormer 模型的结构如图 2.7 所示。




图 2.7 Restormer 模型结构图

模型首先对输入的长度为 H 、宽度为 W 并有 RGB 三个通道（形状为 $H*W*3$ ）的雨天图像执行初步的 $3*3$ 卷积操作以提取低级特征 F_d ，形状为 $H*W*C$ ，随后通过一个 4 层对称编码器-解码器结构进行加工，最终变换成更深层次的特征 $H*W*2C$ 。在这个 4 层编码器-解码器结构中，特征会先通过 3 个编码层将图像中的雨噪声与背景信息分离，这 3 层中分别包含 4、6、6 个优化的 Transformer 块。编码器部分在通过下采样操作逐步降低特征的长和宽的同时，通过 Transformer 块内部的 $1*1$ 点卷积操作增加通

道数，使用 3 个 Transformer 层将图像特征维度从 $H*W*C$ 转换为 $\frac{H}{4}*\frac{W}{4}*4C$ ，并再次通过下采样操作将其转换为 $\frac{H}{8}*\frac{W}{8}*8C$ 。该过程中的下采样操作将图像特征压缩到更紧凑的形式，虽然在降低特征图分辨率的过程中会造成部分信息损失，但有助于模型学习图像的细节特征。然后，特征通过一个含有 8 个 Transformer 块的层被进一步提取。解码器部分接收低分辨率的特征 $\frac{H}{8}*\frac{W}{8}*8C$ ，并通过 3 个解码层逐步重建高分辨率的图像 $H*W*C$ ，这 3 层中分别包含 6、6、4 个优化的 Transformer 块。编解码过程中，编码器的特征通过残差连接与解码器的特征拼接（Concatenate），有助于保留图像在恢复过程中的细节和纹理。解码器部分的每层会通过上采样操作增加特征的长和宽，且除最顶层以外，每一次特征拼接后，使用 $1*1$ 卷积来减半通道数。该过程中的上采样操作在尽可能保持图像内容的细节和质量的同时，将低分辨率的图像特征转换为高分辨率。解码器的第一层被用于整合第一个编码器的形状为 $H*W*C$ 的浅层特征和解码器的形状为 $H*W*C$ 的深层特征，以恢复编码-解码过程中损失的图像精细结构和纹理细节，使特征图反映图像更全面的特征。随后，经过细化的形状为 $H*W*2C$ 的深层特征 F_d 在一个由 4 个 Transformer 块组成的精炼（Refine）层被进一步提取。最终，在精炼特征 F_r 上进行 $3*3$ 卷积计算，得到了残差图像 R ，并将其与原始输入图像按像素相加，得到最终的去雨图像。

2.3.4. FFA-Net 模型

FFA-Net 模型是一种基于特征注意力（Feature Attention, FA）机制构建的图像去雾模型。FA 机制由通道注意力机制和像素注意力（Pixel Attention）机制组成。

（1）FA 机制

传统的图像去雾网络架构采用相同方法处理图像的通道和像素特征，忽视了雾可能呈现出的不同分布以及通道特征可能需要的差异化加权。为解决该问题，设计 FA 机制，其中包含通道和像素注意力两种不同的机制，为网络赋予更高的适应性，使其能够灵活地处理各种不同类型的信息。FA 的结构如图 2.8 所示。




图 2.8 特征注意力机制结构图

通道注意力机制与 SE-ResNeXt101 模型中的该机制相似，针对不同通道特征之间的差异进行加权处理，其起始步骤采用全局平均池化算法将每个通道的空间信息聚合成单一的通道描述符。为了估算出各通道的权重，特征数据先后通过两个卷积层，这两个卷积层分别采用 ReLU 和 Sigmoid 激活函数。最终，将通道权重和输入特征通过残差连接进行逐元素相乘，输出结果。

像素注意力机制针对雾分布在距离观察者不同距离展示出的不同强度进行加权处理。与通道注意力相似，将通道注意力模块的输出 F_c^* 直接输入到两个卷积层中，分别采用 ReLU 和 Sigmoid 激活函数。最后，将像素权重和输入特征通过残差连接进行逐元素相乘，输出结果。

（2）块结构

块结构包含局部残差学习和 FA 模块，使模型获得次要信息，例如较为轻微的雾等低频区域。同时，通过一系列局部残差连接忽略次要信息，使得主网络能够集中处理更为关键的信息。输入的特征张量在起始阶段通过一个卷积层和 ReLU 激活函数，提取其中的特征，并经过残差连接与原输入特征按元素相加。其次，将特征输入另一个卷积层、通道注意力模块以及像素注意力模块。最后，再次经过残差连接，将特征与原输入特征按元素相加，进一步提高训练的稳定性，改善模型的性能。块结构的内部示意图如图 2.9 所示。




图 2.9 块结构示意图

(3) 组结构

模型中的组结构由若干块结构通过残差连接进行级联，不仅可以加深模型的深度，也可以增强其表达能力。组结构与块结构的关系如图 2.10 所示，输入的图像特征经过组结构中包含的 17 个块结构以及 1 个卷积层后，通过残差连接将输入图像与组结构提取的特征进行逐元素相加，输出结果。




图 2.10 组结构示意图

(4) FFA-Net 模型结构

FFA-Net 模型由若干个组结构、若干卷积操作和残差结构组成。首先，网络引入一个卷积层用于对输入的雾天图像进行特征提取，用于捕捉图像中的浅层特征。随后，特征被送入由 3 个组结构组成的深层网络，每个组结构包含若干基础块。基础块相互残差连接，以加强信息流动并避免梯度消失问题。随后，将处理好的特征张量输入通道注意力和像素注意力模块。通道注意力模块负责对不同通道的特征赋予不同的权重，而像素注意力模块则关注于图像像素间的雾分布差异。双重注意力机制使网络能够不均等地处

理不同特征和像素，增强神经网络处理复杂信息的能力。最终，模型的输出特征通过 2 个卷积层，并与原始图像进行残差叠加，以生成去雾后的图像。FFA-Net 模型结构如图 2.11 所示。




图 2.11 FFA-Net 模型结构图

2.4. 深度强化学习理论

深度强化学习^[45]是一种融合了深度学习和强化学习的人工智能算法，结合了深度学习在模式识别和特征抽象方面的优秀能力以及强化学习在环境探索和决策优化方面的卓越性能。深度强化学习的优点是其能够根据外部环境的实时变化来动态调整其决策策略，使其非常适用于处理包含多重不确定性因素的问题，在智能交通系统中有广泛的应用^[46]。

(1) 强化学习

强化学习（Reinforcement Learning）是机器学习的一个分支，其主要目标是让一个智能体（Agent）学习如何在环境（Environment）中选择合适的动作（Action），以达到最大化累计奖励（Reward）的目标。

强化学习与监督学习和无监督学习等机器学习技术的主要区别在于训练过程。在强化学习中，智能体通过与环境的交互获得奖励反馈，并根据反馈来调整其行为。智能体不仅需要学习如何根据当前的环境情况作出最优的决策，还需要探索未知的环境以找到更优的策略。基于经验和试错的学习过程使得强化学习非常适合于处理需要长期规划和决策的问题。

强化学习中，智能体与环境的互动是一个马尔科夫决策过程（Markov Decision Process, MDP），其特点是具有马尔科夫性质，即下一状态的概率分布只取决于当前状态和动作，而与之前的状态和动作无关。通常情况下，MDP 由四个元素 (S, A, R, π) 组成，交互过程如图 2.12 所示。




图 2.12 强化学习交互过程

四元素中的 S 为状态集合，即智能体可能处于的各种状态 s 的总和。智能体在 t 时刻的状态记为 s_t 。 A 为动作集合，即智能体可能执行的各种动作 a 的总和。智能体在 t 时刻执行的动作记为 a_t 。 R 为奖励函数，即智能体在给定状态下执行特定动作所得到的即时奖励。智能体在 t 时刻下的状态 s_t 执行动作 a_t 获得的即时奖励为 $r_t = R(s_t, a_t)$ 。 π 为策略集合，即智能体的行为模式或决策规则，表示状态空间 S 到动作空间 A 的映射。

强化学习核心的训练过程为一个智能体与其环境进行交互的过程。此过程中，智能体根据已定义的策略来选择行动并从环境中得到相应的反馈，包含即时奖励和新的环境状态。强化学习的每轮训练称为回合（Episode）。每个回合中，智能体在每一个时间步骤 t 处，获取当前环境状态 s_t ，根据策略 π 选择行动 a_t 。随后，环境迁移至下一状态 s_{t+1} 并给予智能体即时奖励 r_t 。该过程产生了一条从初始状态至终止状态的交互路径 τ ，如式（2.1）所示：

$$\tau = s_0, a_0, r_1, s_1, a_1, r_1, \dots, s_t, a_t, r_t, s_{t+1}, \dots \quad (2.1)$$

该轨迹被视为智能体的经验，是智能体学习和调整其行动策略的基础。

Q 学习（Q-Learning）算法是一种强化学习的方法，其主要目标是发现一个最优策略，指导智能体在任何给定的状态下选择一个最佳的行动，以便最大化其在长期内的累

积奖励 R_t 。累积奖励是智能体在与环境交互过程中从当前时间步骤开始所有未来奖励的总和。在多时间步骤的情景中，时间步骤 t 的累积奖励如式（2.2）所示：

$$R_t = \sum_{i=0}^{\infty} \gamma^i r_{t+i} \quad (2.2)$$

其中， γ 为折扣因子，用于减小未来奖励的权重。

折扣因子 γ 是强化学习算法的一个超参数，选择适当的值可以有效加速算法的训练和收敛。 γ 的取值范围为 $[0,1]$ 。当 $\gamma = 0$ 时，智能体只考虑当前的即时奖励，忽略了未来可能获得的奖励；反之，当 $\gamma = 1$ 时，智能体将未来的每一个奖励都考虑在内。

累积奖励不仅取决于当前的状态，还与未来的状态和奖励有关。然而，未来的状态和奖励常常是不确定的。为了评估在任何给定状态下执行特定策略能够获得的预期回报，深度强化学习引入了状态值函数 $V_{\pi}(s_t)$ 和动作值函数 $Q_{\pi}(s_t, a_t)$ 。状态值函数 $V_{\pi}(s_t)$ 表示在状态 s_t 下，通过执行策略 π 所能获得的预期累积回报，如式（2.3）所示：

$$V_{\pi}(s_t) = E_{\pi}[R_t | s = s_t] \quad (2.3)$$

其中 E_{π} 为期望值。该函数提供了一个度量，用来评估在特定状态下应用特定策略的长期效益。

动作值函数 $Q_{\pi}(s_t, a_t)$ 表示智能体从状态 s_t 开始执行动作 a_t 并采用策略 π 的预期回报，如式（2.4）所示：

$$Q_{\pi}(s_t, a_t) = E_{\pi}[R_t | s = s_t, a = a_t] \quad (2.4)$$

贝尔曼方程（Bellman Equation）是强化学习中的一个重要概念，描述了强化学习中的优化问题。贝尔曼方程根据贝尔曼原理提出，表明了一个最优策略的子策略也必定是最优的。对于强化学习中的状态值函数 $V_{\pi}(s_t)$ 和动作值函数 $Q_{\pi}(s_t, a_t)$ ，贝尔曼方程可以描述两者的递归关系，如式（2.5）所示：

$$\begin{cases} V_{\pi}(s_t) = \sum_{a_t} \pi(a_t | s) \sum_{s_{t+1}, r} p(s_{t+1}, r | s_t, a_t) [r + \gamma V_{\pi}(s_{t+1})] \\ Q_{\pi}(s_t, a_t) = \sum_{s_{t+1}, r} p(s_{t+1}, r | s_t, a_t) [r + \gamma \sum_{a_{t+1}} \pi(a_{t+1} | s_{t+1}) Q_{\pi}(s_{t+1}, a_{t+1})] \end{cases} \quad (2.5)$$

其中, $Q_{\pi}(s_t, a_t)$ 表示智能体在状态 s_t 下选择动作 a_t 的概率; $p(s_{t+1}, r | s_t, a_t)$ 为环境的转换概率, 表示智能体在状态 s_t 下执行动作 a_t 后转移到状态 s_{t+1} 并获得奖励 r 的概率; γ 为折扣因子。

寻找最优的策略等价于寻找最优的值函数。最优状态值函数 V_{π^*} 和最优动作值函数 Q_{π^*} 为在所有可能策略中给定状态 s 或给定状态-动作对 (s, a) 能够获得的最大预期累积奖励。计算最优状态值的函数称为最优值函数, 如式 (2.6) 所示:

$$\begin{cases} V_{\pi^*} = \max(V_{\pi}(s)) \\ Q_{\pi^*} = \max(Q_{\pi}(s, a)) \end{cases} \quad (2.6)$$

由最优值函数得到最优策略 π^* , 可以在任何状态 s 或状态-动作对 (s, a) 下选择能够最大化状态值函数的动作。最优策略计算公式如式 (2.7) 所示:

$$\begin{cases} \pi^* = \arg \max(V_{\pi}(s)) \\ \pi^* = \arg \max(Q_{\pi}(s, a)) \end{cases} \quad (2.7)$$

因此, 寻找最优策略的问题可以转化为寻找最优值函数的问题。通过求解最优状态值函数或最优动作值函数可以找到对应的最优策略, 即强化学习问题的最优解。

(2) 深度强化学习

深度学习拥有出色的特征表达和数据非线性拟合能力, 能够有效地弥补强化学习在处理复杂场景和高维度数据方面的缺陷。将深度学习与强化学习算法结合, 构成深度强化学习 (Deep Reinforcement Learning) 算法。深度强化学习算法可以在复杂的高维度场景中寻找解决具有不确定性问题的方案, 利用深度 Q 网络 (Deep Q-Network, DQN) 来逼近强化学习中的价值函数和策略函数。该方法称为深度 Q 学习 (Deep Q-Learning, DQL)。相对于强化学习, DQL 节省了存储资源, 提升了算法的训练速度, 同时也扩大了算法的应用范围。深度强化学习的结构原理如图 2.13 所示。




图 2.13 深度强化学习交互过程

智能体在某一时刻 t 感知到环境的当前状态 s_t ，并根据现有的策略网络选择相应的动作 a_t 。此时，环境给予智能体奖励 r_t 并将其带入下一个状态 s_{t+1} 。智能体根据奖励大小来更新深度神经网络的参数，即调整动作策略。

深度强化学习引入神经网络来近似价值函数，从而有效地避免了维度爆炸问题。DQN 的目标是通过优化神经网络的参数，使得动作值函数尽可能地逼近最优动作值函数，如式 (2.8) 所示：

$$Q(s, a, \theta) \approx Q^*(s, a) \quad (2.8)$$

其中， $Q^*(s, a)$ 表示最优动作值函数的值， θ 表示神经网络的参数。

经验回放机制是 DQL 算法中的另一个关键组成部分。智能体在当前状态下 s_t 执行动作 a_t ，达到下一个状态 s_{t+1} 并获得环境反馈的奖励 r_t 。将经验数据以(状态，动作，奖励，下一个状态)四元组的形式存储在经验池中，如式 (2.9) 所示：

$$(s_t, a_t, r_t, s_{t+1}) \quad (2.9)$$

DQL 算法引入了经验回放机制，以解决连续的样本之间存在强相关性和依赖性导致神经网络损失函数的值波动和不稳定的问题。在训练神经网络时，DQN 从经验池中随机抽取一批样本进行训练以打破样本之间的相关性和依赖性，提高样本的利用率并缓解过拟合的问题。经验回放机制使训练过程更加稳定，提高了智能体的学习效率。

传统的强化学习在计算损失函数时使用相同的函数来估计当前值和目标值。然而，当该算法结合深度学习改进为深度强化学习时，采用相同的神经网络来计算估计值函数和目标值函数可能会产生问题。其原因在于，在神经网络的参数更新后，目标值函数也会相应地被更新，与深度学习中通常设定的固定目标值互相矛盾，可能导致训练过程中的损失函数波动，使得神经网络难以收敛。为了解决该问题，DQL 引入了两个具有相同网络结构和初始参数的深度神经网络，称为策略网络和目标网络，分别用于计算时间差分的估计值函数和目标值函数，以降低两个函数之间的相关性，从而减小了算法的波动程度，提高了训练过程的稳定性。

当前值函数使用策略网络进行计算，而目标值函数使用目标网络进行计算，如式 (2.10) 所示：

$$Q^{\text{target}} = r + \gamma \max_a (Q(s', a'; \theta')) \quad (2.10)$$

其中， Q^{target} 为目标值函数， θ' 为该函数的参数。

损失函数 $L(\theta)$ 表示当前值与目标值的差值，公式如式 (2.11) 所示：

$$L(\theta) = E[(Q^{\text{target}} - Q(s, a; \theta))^2] \quad (2.11)$$

其中， θ 为该函数的权重参数。

权重参数使用随机梯度下降法求出，公式如式 (2.12) 所示：

$$\frac{\partial L(\theta)}{\partial \theta} = E[(Q^{\text{target}} - Q(s, a; \theta)) \frac{\partial Q(s, a; \theta)}{\partial \theta}] \quad (2.12)$$

其中，动作值函数相对于网络参数的梯度值 $\frac{\partial Q(s, a; \theta)}{\partial \theta}$ 可以使用反向传播算法计算得出。

梯度值在每次更新神经网络模型参数时被用来优化目标函数。DQL 算法采用小批量随机梯度下降策略，从经验池中随机抽取一组样本来进行训练，通过不断迭代优化神经网络，使动作值函数朝向最优动作值函数接近，从而实现模型的优化。

2.5. Airflow workflow 调度工具

Airflow^[47]是一个开源的 workflow 调度工具，可以通过编程的方式创建一系列按模块依赖关系执行的任务，设计针对特定需求的 workflow 调度平台，以实现 workflow 调度。Airflow 的架构包含多个组件，每个组件具有不同的职责，以确保整个框架的协调与高效运作。

Airflow 采用有向无环图（Directed Acyclic Graph, DAG）表示流程的拓扑结构，即各模块间的依赖关系，决定了 workflow 执行各模块的顺序。DAG 是一种基于图的数据结构，其中的“有向”指图中的边均有方向，“无环”指图中不存在从一个顶点出发，经过一系列的边又回到该顶点的路径。DAG 支持拓扑排序，即将图中的所有顶点排成一个线性序列，该性质是实现依赖关系正确执行顺序的关键。

Airflow 主要包括 Queuing Service、Executor、Scheduler 以及 Web Server 共 4 个组件，组件图如图 2.14 所示。




图 2.14 Airflow 组件图

其中，Queuing Service 是用于任务消息传递的队列服务，基于 RabbitMQ 消息中间件实现，可确保任务能够被有效传递并分配给 Executor 进行处理，也可实现任务的异步处理与负载均衡。Executor 为任务执行引擎，负责任务的实际执行。Scheduler 是 Airflow 的核心组件，执行任务的调度工作，周期性地检查元数据库以确定任务的状态，并根据任务的依赖关系、可用的执行线程数以及优先级队列，制定任务的执行策略与顺序。Web Server 为用户提供基于 Web 的界面，使用户能够直观地与 Airflow 进行交互，在界面上监控、执行和管理 workflow。

在构建复杂系统 workflow 时，各模块触发执行的时序并非一致。因此，Airflow 实现了灵活且高效的调度策略以实现预定目标。该策略需要具备良好的扩展性和出色的性能指标，以适应系统需求的动态变化。调度机制受到多种因素的影响，如线程池大小、并发控制策略、执行器的当前状态及模块优先级。其中，模块优先级的确定最为关键，直接决定了任务调度的顺序。workflow 调度的流程如图 2.15 所示。




图 2.15 workflow调度流程图

调度流程的初始步骤包括对工作流中各模块的解析，从而明确模块之间的依赖关系。其次，检测各模块的状态，并将其记录在元数据库中。如果检测到依赖关系符合 DAG 的规则，开始调度过程。调度过程中通过优先级队列来实现工作流的核心调度逻辑，确保高优先级的模块得到优先执行。若某模块的调度执行遭遇失败，则提供相应的重试机制，以确保任务最终完成。

Airflow 使用元数据库查询和更新功能模块的状态，并构建反映模块优先级的队列。因此，首先对模块的优先级进行计算。工作流模块集 M 的定义如式 (2.13) 所示：

$$M = \{m_1, m_2, \dots, m_r\} \quad (2.13)$$

其中， m 为工作流中的模块。

工作流中的每个模块最初被赋予默认为 1 的优先级配置值。接着，根据元数据库中各模块的当前状态，对模块集 M 进行筛选，以获取处于待执行状态的模块，形成待执行任务集 EM ，如式 (2.14) 所示：

$$EM = \{em_1, em_2, \dots, em_n\} \quad (2.14)$$

其中， em 为工作流中的待执行模块。

其次，计算 EM 中各模块的优先级，如式 (2.15) 所示：

$$P = 1 + \sum_{i \in U(S, T)} P_i \quad (2.15)$$

其中, P 表示一个模块的优先级。 S 和 T 为 DAG 的起点和终点, P_i 为初始的优先级配置值。

结合以上两个公式, 可得出所有模块的优先级集合 EMP , 如式 (2.16) 所示:

$$EMP = \{P_1, P_2, \dots, P_n\} \quad (2.16)$$

该集合指导优先级队列对模块进行排序, 从而确定执行顺序。

2.6. 小结

详细阐述实验相关的理论基础和用到的关键技术。首先, 介绍深度学习的基础知识。其次, 详细分析通道注意力机制、SE-ResNeXt101 残差网络模型、Restormer 去雨模型以及 FFA-Net 去雾模型, 阐述各模型的工作原理与计算过程。接着, 探究深度强化学习的相关原理。最后, 介绍 Airflow 工作流调度工具相关技术。通过对上述技术的理解, 为后续章节中的实验设计和结果解析提供了必要的理论支撑。

第三章 交通图像晴雨雾天气识别方法

3.1. 概述

研究交通图像晴雨雾天气识别方法。首先，分别收集包含晴天、雨天和雾天天气状况的图像数据集并对其进行预处理工作，以确保数据质量符合模型输入的要求。随后，构建 SE-ResNeXt101 深度学习模型，并利用该模型对图像进行分类，将图像识别为晴天、雨天或雾天三个类别，并评估训练效果。如果用户需要增加识别天气的类别，只需要对训练该模型使用的天气图像类别进行扩展即可。该过程实现了对交通图像中晴雨雾天气的识别，从而为后续针对特定天气图像进行增强及目标检测的实验提供支持。

3.2. 数据准备及预处理

收集^{[48][49]}晴天、雨天和雾天条件下的交通图像数据集共 1800 张，示例如图 3.1 所示。可以看出，晴天图像具有蓝天白云、能见度高特征；雨天图像具有雨线、潮湿的地面和打伞的行人等特征；雾天图像具有远处能见度低、灰白色雾等特征。




图 3.1 晴雨雾交通图像

模型训练前，对交通图像数据集进行预处理。首先，读取所有图像，并对每一张图像设置标签，代表图像的晴雨雾天气种类。将图像的尺寸调整为 224*224。接着，将图像的像素值转换为浮点数，并对其进行归一化操作，将像素值调整至[0,1]区间。对图像天气条件种类进行独热（One-Hot）编码，以二进制数组形式保存天气条件种类，将晴

天编码为[1,0,0]，雨天编码为[0,1,0]，雾天编码为[0,0,1]，作为后续训练的目标值。最后，将数据集划分为 80% 的训练集和 20% 的测试集。

3.3. SE-ResNeXt101 晴雨雾天气识别模型构建

基于大气光学特性的天气识别方法^[50]在初始阶段利用与特定天气条件相关的先验知识进行特征提取，随后利用基于机器学习的分类器组合特征以进行分类任务，对于特定的天气图像有较好的识别效果与准确度。然而，此类方法依赖过多的手动特征工程，需要大量气象领域知识且泛化能力弱。因此，引入深度神经网络模型对图像的晴雨雾天气进行识别。

交通图像中不仅包括汽车、摩托车、行人等与图像天气条件无关的特征，还包括晴天图像中的蓝天白云、雨天图像中的潮湿地面、打伞的行人和雨线、雾天图像中的雾状遮挡等与天气条件密切相关的特征。不同天气条件具有多种特征的组合，具有多样性。例如，潮湿地面可能与洒水车有关，烟雾可能与露天烧火有关，行人也可能是由于强光照而打伞。图像天气条件的多样复杂特征会反映在特征图的不同通道中，设计的模型需要综合反映图像天气条件的多样性特征以对图像天气类别进行准确识别。为了捕捉不同天气条件各自的复杂特征，引入通道注意力机制。通道注意力机制能够捕获图像的不同天气反映在特征图不同通道的特征，自适应地为不同的通道赋予不同的权重。这样，模型就可综合对于天气分类任务重要的多样性特征，并抑制不那么重要的信息，从而提高整体的分类准确性。

SE-ResNeXt101 模型是基于通道注意力机制优化的 ResNeXt101 残差网络模型。构建并训练 SE-ResNeXt101 模型以识别交通图像晴雨雾天气。由于收集的交通图像规模不大且服务器训练资源有限，基于迁移学习的思想，主干 (Backbone) 部分使用在 ImageNet 数据集^[51]上预训练的模型以提高模型的特征提取能力。ImageNet 是一个包含 1000 个类别的超过 1400 万张图像的大型数据集，其中涵盖了现实场景中常见的多种物体。通过迁移学习技术，可以将这些在大规模样本中学习到特征的共性应用在新的场景中，使特征提取步骤具有更好的效果。

模型的主干部分将输入的交通图像转换为特征图。如果要对这些特征进行具体的分类，需要构建分类器，将输入的图像特征转换为各类别对应的概率。将模型主干部分提

取的特征向量输入自定义的分类器结构。特征图首先会被输入一个 **Flatten** 层，将特征图进行扁平化操作，即转换为一维向量，以适应全连接层的输入要求。接着，构建一个包含 256 个神经元的层和一个包含 128 个神经元的层，每层后面均会进行 **Dropout** 操作，并连接 **ReLU** 激活函数，以增加特征的非线性。其中，**Dropout** 是一种在神经网络训练过程中用于防止过拟合的技术。**Dropout** 在每次训练迭代中随机选择一部分神经元并将其“关闭”，意味着在前向传播和反向传播中都不参与计算，使网络将信息分散到更多的神经元上，从而产生更稳健的模型。**Dropout** 的比例 p 是一个可调参数，决定了在每次迭代中关闭神经元的比例。设置 $p = 0.1$ ，即通过在训练时随机将 10% 的输入单元设置为 0，以减少过拟合，同时增强模型学习特征的非线性组合的能力。最后一个全连接层具有 3 个神经元，代表输出的值将会对应晴雨雾 3 种天气类别。

由于这是一个多分类问题，通过 **Softmax** 激活函数将特征数据映射为概率值，即输入图像为晴天、雨天和雾天图像的概率。模型中自定义的全连接分类器部分的具体结构如图 3.2 所示。




图 3.2 晴雨雾天气分类器结构图

在收集的交通图像数据集上训练 SE-ResNeXt101 模型。训练的过程中采用交叉验证（Cross Validation）的方法。对于模型训练过程中的每一个周期（Epoch），将训练集划分 90% 用于模型拟合，将剩下的 10% 用于验证（Validate），计算并记录所构建模型该周期在训练时未曾接触过的验证集上的损失（Loss）值和准确率。

准确率（Accuracy）是最直观的性能指标，计算了分类正确的样本数占总样本数的比例。准确率的公式如式（3.1）所示：

$$\text{Accuracy} = \frac{\text{预测正确样本数量}}{\text{总样本数量}} \quad (3.1)$$

为了防止模型过拟合训练数据，即在训练集上性能良好，但在新数据上泛化能力差的情况，实施了早停（Early Stopping）策略。早停是一种预防深度学习模型过拟合的技术。该策略在模型训练过程中定期监控模型在验证集上的性能。当模型在验证集上的性能连续 *patience* 个周期出现下降或不再改善时，认为模型已经开始过拟合，并终止训练过程。早停策略有助于保留泛化能力强的模型，同时避免了无谓的计算资源浪费。设置 *patience* = 5，即模型在验证集上的性能连续 5 个训练周期不再改善时，停止训练。最后，保存具有最优权重的模型。

选择模型训练过程中的超参数时采用网格搜索（Grid Search）策略。网格搜索策略系统地遍历了基于经验预设的各种超参数组合，以确定能够使模型产生最佳性能的超参数。模型的主要超参数如表 3-1 所示。

表 3-1 晴雨雾天气分类模型超参数

编号	超参数	值
1	周期数	38
2	批大小	32
3	学习率	0.1
4	优化器	Adam
5	损失函数	交叉熵

Adam（Adaptive Moment Estimation）^[52]优化器是一种用于深度学习应用中的梯度下降算法。模型训练过程中，如果学习率过高，可能导致梯度爆炸；如果学习率过低，可能导致梯度消失。Adam 结合了 Momentum 和 RMSprop（Root Mean Square Propagation）两种优化算法的优点，可以自适应地调整每个参数的学习率。Adam 优化器在更新时计算偏差校正后的一阶和二阶矩估计来更新网络权重，是一种适用于处理较大规模神经网络的优化算法。

由于这是一个多分类问题，损失函数需要衡量模型输出的概率分布和真实标签的概率分布之间差异。因此，选用交叉熵（Cross-Entropy）损失函数。交叉熵损失函数对于

预测的概率分布和真实的概率分布之间的微小差异非常敏感,使其成为训练分类器的一个有效的损失函数。对于多分类问题,交叉熵损失函数的公式如式(3.2)所示:

$$CE(y, \hat{y}) = -\sum_{i=1}^N \sum_{j=1}^M y_{ij} \log(\hat{y}_{ij}) \quad (3.2)$$

其中, y_{ij} 表示第 i 个样本是否属于类别 j , 如果样本属于该类别, 则为 1, 否则为 0。 $\hat{y}_{ij}$ 表示模型预测第 i 个样本属于类别 j 的概率, M 是类别的数量。

加载训练好的模型并将测试集图像数据输入模型, 得出模型对测试集中 180 张图像的预测类别。考虑到这是一个多分类问题, 除准确率以外, 还采用精确率 (Precision)、召回率 (Recall)、F1 分数 (F1 Score) 和混淆矩阵 (Confusion Matrix) 对模型的性能进行评价。

精确率是对于给定类别的预测中, 正确预测该类别的比例。在多分类问题中, 目标值类别视为正例, 目标值类别以外的其他类别均视为反例。精确率的公式如式(3.3)所示:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (3.3)$$

召回率指在所有真正为正例的样本中被模型预测为正例的样本的占比。召回率的计算公式如式(3.4)所示:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3.4)$$

以上两个公式中, TP (True Positive) 为真正例的数量, 即模型正确预测为正类的实例数量; FP (False Positive) 为假正例的数量, 即模型错误预测为正类的实例数量; FN (False Negative) 为假负例的数量, 即模型错误预测为负类的实例数量。

F1 分数是精确度和召回率的调和平均数, 将两者同时纳入考虑。F1 分数的计算公式如式(3.5)所示:

$$\text{F1 Score} = 2 \frac{\text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3.5)$$

混淆矩阵是一个具体显示每个类别中正确和错误预测数量的矩阵, 对于多分类问题, 混淆矩阵包含所有类别之间的预测情况。对于具有 3 个目标类别的分类问题, 混淆矩阵为一个 3*3 的矩阵, 其中的每个数值代表模型将其所在的行对应类别预测为其所在列对应类别的次数。

使用热力图（Heatmap）可以通过颜色和数值的标注清晰直观地将混淆矩阵可视化，如图 3.3 所示。




图 3.3 晴雨雾天气分类混淆矩阵热力图

SE-ResNeXt101 模型、优化前的 ResNeXt101 残差网络模型以及 ConvNeXt 模型在测试集中各类别上的准确率、精确率、召回率和 F1 分数共 4 种评价指标如表 3-2 所示。结果显示，SE-ResNeXt101 模型在执行晴雨雾天气图像各类别的预测任务上，各评价指标均体现出优势。

表 3-2 各天气类别评价指标对比

编号	模型	类别	准确率	精确率	召回率	F1 分数
1	SE-ResNeXt101	晴天	96.67%	95.16%	98.33%	96.72%
		雨天		96.61%	95.00%	95.79%
		雾天		98.31%	96.67%	97.48%
		平均		96.69%	96.67%	96.67%
2	ResNeXt101 ^[42]	晴天	89.44%	87.93%	85.00%	86.44%
		雨天		87.10%	90.00%	88.52%
		雾天		93.33%	93.33%	93.33%
		平均		89.45%	89.44%	89.43%
3	ConvNeXt ^[53]	晴天	94.44%	91.94%	95.00%	93.44%
		雨天		98.21%	91.67%	94.83%
		雾天		93.55%	96.67%	95.08%
		平均		94.57%	94.44%	94.45%

3.4. 实验结果

加载训练好的 SE-ResNeXt101 模型，将若干晴雨雾天气场景下的交通图像输入模型。模型对图像晴雨雾天气状况的预测效果示例如图 3.4 所示。图中包含模型对于每张图像输出的各类别对应概率以及图像晴雨雾天气的最终预测结果。



图 3.4 图像晴雨雾天气预测效果示例图

由此可以得知，该分类模型可以充分提取交通图像晴雨雾天气的多样复杂特征，在测试集上的评价效果较好，可以用于预测交通图像的晴雨雾天气状况。

3.5. 小结

本章构建并训练基于通道注意力机制的 SE-ResNeXt101 架构的深度学习模型，以实现交通图像中晴雨雾天气状况的识别。该模型可以将图像中的天气状况识别为晴天、雨天和雾天共 3 个预定义的天气类别。模型的性能通过准确率、精确率、召回率、F1 分数、混淆矩阵共 5 种评价指标进行了测试。测试结果表明，构建的模型能够准确地执行天气分类任务，不仅为实现交通图像晴雨雾天气识别提供了强有力的方法，还为后续进行特定天气图像增强和目标检测的实验夯实了基础。

第四章 交通图像去雨雾增强方法

4.1. 概述

现实环境中的雨天和雾天条件对图像视觉效果造成不良影响，可能使目标检测模型出现漏检和误检等问题，从而不能达到预期的精度。研究在雨天和雾天下对交通图像视觉效果进行增强的方法。首先，利用计算机图形学算法构建用于监督学习的雨天和雾天图像数据集。针对雨天或雾天分别训练 Restormer 和 FFA-Net 深度学习模型对图像进行增强处理。然后，对 Restormer 模型去雨、FFA-Net 模型去雾的性能边界进行评价。测试结果表明，模型能够有效地改善图像的视觉质量，降低环境因素的干扰。

4.2. 雨雾图像数据集构建

4.2.1. 雨雾图像特征分析

自然环境中采集的图像可能包含种类、强度不一的干扰，对图像质量造成负面影响。其中，雨、雾天气对于图像中目标能见度的影响最为显著。车辆在雨间行驶时，快速下落的水滴在与摄影设备的成像系统交互时会向其获取的交通图像中引入线状干扰，降低图像质量，增加目标检测系统识别目标的难度。雾中的水滴大小与可见光波长相近，导致光线在穿过雾滴时被吸收或发生反射和散射，使得光线难以直线传播，降低光的直射程度，在图像上呈现出灰白色的雾遮挡，减少图像中重要元素的清晰度降低图像质量，增加目标检测系统识别目标的难度。

雨和雾是两种不同性质的天气，雨、雾天气对智能车辆获取的图像造成干扰的特征本质不同。雨天在图像上主要形成的是条状的雨线噪声，对雨线以外的像素影响轻微；而雾天在图像上主要形成的是灰白色的雾遮挡，几乎会影响图像上的所有像素信息。因此，分别构建用于监督学习模型训练的雨、雾天气图像数据集。为了使模型可以适应自然环境中不同级别的雨、雾天气，构建的图像数据集需要具有不同程度的雨噪声或雾遮挡。收集 900 张交通图像作为去雨和去雾实验的数据集^[54]，在此基础上添加雨噪声或雾遮挡。构建的交通图像数据集将用于基于预训练的模型构建，以及去雨模型和去雾模型的性能边界测试。

4.2.2. 雨天图像构建

基于监督学习的去雨模型需要将包含雨噪声的图像作为输入的特征值，将不包含雨噪声的图像作为输出的目标值。因此，对现有的不含雨噪声的交通场景图像数据集进行加雨噪声处理。采用计算机图形学方法生成带雨噪声的图像。为了训练可以适应不同降雨大小的深度学习模型，使用带有不同程度雨噪声的图像作为训练使用的图像数据集，构建雨天图像的流程如下。

(1) 首先，采用随机方法来生成代表降雨噪声的像素矩阵 R 。定义二维矩阵 R ，其形状与输入图像一致，并用 0~255 范围内的正态分布随机值填充。

(2) 定义代表雨滴密度的参数 ν ，作为阈值参数使得矩阵 R 变得稀疏。将阈值 $255-\nu$ 以下的数组的所有元素设置为 0，从而模拟了自然环境中雨滴的随机性和分布。随后，定义卷积核 k 作为滤波器，用以给噪声模式带来轻微的扩散，模拟由于运动和大气相互作用对雨滴产生的模糊效果。对矩阵 R 和卷积核 k 执行卷积操作，减弱噪声的锐度，并生成更加逼真的雨效果的表示。获取修改后的噪声数组 R' ，包含模糊地象征雨滴的值。构建旋转矩阵 T 进行仿射变换。该矩阵基于图像对角线的中心点旋转 θ° ，并将图像放大等同于雨滴长度的 l 倍。

(3) 生成主对角线元素为 1，其他位置为 0 的对角线矩阵 Λ ，其行、列数由雨滴长度 l 定义。对矩阵 Λ 应用旋转矩阵 T ，生成倾斜的模糊核 k' 反映雨滴下落的轨迹。为了使雨滴轮廓更自然，对模糊核 k' 实施高斯模糊处理，按照宽度 1 像素和自动计算的标准差平滑模糊核的边缘。施加模糊核 k' 至输入的噪声图像 R' 上，生成模糊后的图像 R'' ，模拟出雨滴的运动模糊效果。

(4) 最后，将二维雨噪声矩阵 R'' 扩展到与原图像相同的维度，并将其与原图像按像素进行合并，生成最终的带雨效果的图像 R_{result} 。

为了模拟不同大小的雨天图像，设置雨滴密度 ν 区间为 [40,200]，旋转矩阵 T 的旋转度数为 $[-30^\circ, 30^\circ]$ ，其中的负数代表顺时针旋转，正数代表逆时针旋转；雨线长度 l 区间为 [30,70]。加雨操作前后的图像对比如图 4.1 所示，其中左侧第一张图像为原图像，其他三张图像的加雨量向右依次增大。



图 4.1 加雨效果对比图例

可以看出，图像上添加了雨噪声，且雨线的长度、密度和角度等存在随机性。创建的数据集可以为监督学习去雨模型创造条件。

4.2.3. 雾天图像构建

与去雨模型相似，构建的监督学习去雾模型采用端到端的架构，需要将包含雾的图像作为输入的特征值，将不包含雾的图像作为输出的目标值。因此，对现有的不含雾的交通场景图像数据集进行加雾处理。采用计算机图形学方法生成带雾遮挡的图像。为了训练可以适应不同雾强度的深度学习模型，使用带有不同程度雾遮挡的图像作为训练使用的图像数据集，构建雾天图像的流程如下。

(1) 首先，定义光学散射参数。 A 代表全局大气光的强度，为一个介于 0 到 1 之间的常数，代表了无雾情况下的亮度。 β 代表散射系数，决定了雾的浓度。

(2) 随后，对于图像中的每一个像素点，计算透射率 t 。透射率 t 描述了光线从物体到观察者的路径上到达观察者时的减弱程度。雾的浓度 β 越大， t 越小，意味着雾越浓，透射率越低。

(3) 基于物理上的光学散射原理，计算得出每个像素的新值。该原理如式 (4.1) 所示：

$$\text{NewPixel} = \text{Pixel} * t + A * (1 - t) \quad (4.1)$$

其中，Pixel 是原始图像的归一化像素红绿蓝 (Red Green Blue, RGB) 值，NewPixel 是对 Pixel 加雾后的像素 RGB 值。等号右边的第一项是像素自身的值与透射率 t 的乘积，第二项是大气光强度 A 与 $1 - t$ 的乘积。

为了模拟不同浓度的雾天图像,设置全局大气光强度 A 区间为 $[0.8,1]$,散射系数 β 区间为 $[0.6,1.6]$ 。加雾操作前后的图像对比如图 4.2 所示,其中左侧第一张图像为原图像,其他三张图像的加雾量向右依次增大。



图 4.2 加雾效果对比图例

可以看出,图像上添加了雾遮挡,且大气光强度和雾的浓度存在随机性。创建的数据集可以为监督学习去雾模型创造条件。

4.3. 交通图像去雨雾增强模型构建

雨、雾两种天气降低交通图像视觉效果的特征本质不同。因此,需要针对雨、雾两种天气分别构建深度学习模型以实现图像去雨、去雾增强,提升智能车辆在不同天气条件环境下行驶的适应能力。

4.3.1. Restormer 图像去雨模型

在雨天条件下捕获的交通图像会受到表现为雨线的视觉噪声,对图像的视觉质量造成负面影响。图像去雨模型需要针对图像上存在的可视雨线进行去除,而需要尽可能地雨线以外的图像背景信息。然而,雨噪声与图像背景在空间层面上紧密相邻,导致传统的数字图像处理算法难以辨别两种不同的信息。此外,自然界中存在不同大小的降雨强度,不同速度和密度下落的雨滴在图像传感器上产生的噪声模式各不相同。在这种情况下,依赖于传统数学模型的处理方法需要为不同规模的降雨和多变的环境场景调整多个参数,严重限制了其泛化能力。因此,选择基于深度学习的图像恢复模型以去除图像上的雨噪声。

由于雨天图像中的雨噪声与背景信息相邻,导致难以区分,应用编码器将雨天图像的特征转换到另一个维度空间,在这一空间中,雨噪声与背景信息特征可以变得使神经网络更容易区分。同时,为解码器将这一特征空间恢复为无雨图像打下基础。因此,对于雨天图像,构建 Restormer 模型以增强图像的视觉效果。该模型应用优化的 Transformer 块,其中包含了多深度卷积头转置注意力(Multi-Dconv head Transposed Attention, MDTA)机制和门控深度卷积前馈网络(Gated-Dconv Feed-forward Network, GDFN)。MDTA 在模型的训练过程中学习雨噪声特征,通过计算特征图在通道维度上的交叉协方差,以线性的时间复杂度从全局的角度生成图像的注意力图,捕获像素之间的长距离关系,为图像中的雨噪声和背景信息自适应地赋予不同的权重;GDFN 网络可以控制信息流,自动选择并过滤与雨噪声无关的特征。通过监督学习过程中若干周期的迭代,不断将预测图像与原无雨图像进行对比,随着损失函数的下降,模型可以对雨的特征进行充分的学习,进而去除图像中的雨,达到图像增强的效果。

在加雨前后的交通图像数据集上训练 Restormer 去雨模型。由于构建的雨天交通图像规模不大且服务器训练资源有限,基于迁移学习的思想,使用基于 Rain14000 数据集^{[55][56]}上预训练的基础上进行训练,以提高模型的特征提取能力。Rain14000 是一个包含 14000 组无雨与人工加雨图像的数据集,其中涵盖了多种现实场景。通过迁移学习技术,可以应用这些在大规模样本中学习到特征的共性,使模型训练具有更好的效果。

Restormer 模型将图像去雨问题视为一个监督学习问题,将构建的加雨图像作为模型输入的特征值,模型预测得出去雨图像,并将加雨前的无雨图像作为目标值,与模型输出的预测值进行对比,计算损失值,并据此更新神经元权重,完成一个周期的训练。模型训练过程中,对于模型训练过程中的每一个周期,将训练集划分 90%用于模型拟合,将剩下的 10%用于验证。Restormer 模型的主要超参数如表 4-1 所示。

表 4-1 Restormer 模型超参数

编号	超参数	值
1	周期数	212
2	批大小	8
3	学习率	通过余弦退火策略从初始的 3×10^{-4} 逐渐降低到 1×10^{-6}
4	优化器	Adam
5	损失函数	L1

训练复杂的深度学习模型时通常需要较多的周期数进行迭代。在此过程中，如果学习率设置过大，可能导致梯度爆炸现象，导致损失函数无法收敛到一个稳定的最小值；如果学习率设置过小，可能导致模型在损失函数达到全局最小值之前就停止了学习，陷入局部最小值，导致性能不佳。余弦退火（Cosine Annealing）策略是一种基于余弦函数的学习率调整策略，用于在训练复杂深度学习模型时优化学习率。该策略借鉴了模拟退火（Simulated Annealing）算法的思想，通过模拟退火过程中温度逐渐降低的物理现象来逐渐减小学习率。余弦退火策略特别适用于在训练初期快速进展，而在训练后期需要更精细搜索的情况，可以帮助模型在训练早期快速下降，而在训练后期则能够细致地调整参数，从而避免过早地陷入局部最小值。余弦退火策略的数学公式如式（4.2）所示：

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos \left(\frac{T_{\text{cur}}}{T_{\max}} \pi \right) \right) \quad (4.2)$$

其中， η_t 为在周期 t 迭代的学习率， $\eta_{\min}$ 为学习率的最小值， $\eta_{\max}$ 为学习率的最大值。 T_{cur} 为当前迭代次数， $T_{\max}$ 为一个周期内的迭代总次数。

使用监督学习模型预测去雨图像的像素值本质上是一个回归问题。因此，选用 L1 损失作为 Restormer 模型的激活函数。L1 损失也称为最小绝对误差，是一种在回归问题中常用的损失函数，通过计算预测值和真实值之间的绝对差值的总和来度量模型的预测精度。L1 损失的公式如式（4.3）所示：

$$L1(y, \hat{y}) = \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4.3)$$

其中， y_i 为真实值， $\hat{y}_i$ 为预测值， n 为样本数目。

模型在训练过程中每个周期上的验证采用图像恢复研究领域常用的结构相似性指数（Structural Similarity Index Measure, SSIM）作为评价指标。SSIM 设计基于视觉感知的原理，不仅考虑像素值的误差，还考虑了图像的结构、对比度和亮度。SSIM 的取值范围为[-1,1]。其中 1 表示两个图像完全相同，较高的 SSIM 值表示图像质量较高。计算公式如式（4.4）所示：

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (4.4)$$

其中, x 和 y 是待比较的两个图像窗口, μ_x 和 μ_y 分别是 x 和 y 的像素平均值, σ_x^2 和 σ_y^2 是 x 和 y 的方差, σ_{xy} 是 x 和 y 的协方差, C_1 和 C_2 是用于稳定分母的小常数。

模型训练完成后, 将测试集中的加雨图像输入到模型中, 使模型预测得出去雨后的测试集图像。采用峰值信噪比 (Peak Signal-to-Noise Ratio, PSNR) 和 SSIM 两种指标用于评估模型的性能。PSNR 是常用的衡量图像重建质量的指标之一, 通过比较原始图像和恢复后的图像之间的均方误差 (Mean Squared Error, MSE) 来计算信号最大可能功率和误差噪声功率的比率。MSE 用于计算两个等长向量之间的平均平方差异, 通常用于评估预测值和实际值之间的差值, 常用于回归问题。在计算机视觉领域, 两个图像之间的 MSE 的公式如式 (4.5) 所示:

$$\text{MSE}(I, K) = \frac{\sum_{i=1}^m \sum_{j=1}^n (I(i, j) - K(i, j))^2}{mn} \quad (4.5)$$

其中, m 和 n 分别是图像的高度和宽度, $I(i, j)$ 是原始图像 I 在位置 (i, j) 的像素值, $K(i, j)$ 是增强后的图像在位置 (i, j) 的像素值。

PSNR 通常以对数尺度的分贝 (dB) 作为单位。PSNR 的公式如式 (4.6) 所示:

$$\text{PSNR} = 10 \log \left(\frac{\max^2(I)}{\text{MSE}} \right) \quad (4.6)$$

其中, $\max(I)$ 是图像 I 可能的最大像素值, 通常为 255。

MSE 的值越小, 表示两幅图像越接近。由于 MSE 在 PSNR 公式的分母上, 可以得知, PSNR 越高, 增强的质量越好。Restormer 模型以及传统的 NL-Means 去雨算法在测试集上的各评价指标如表 4-2 所示。其中, “无” 模型指原图像与加雨后的图像之间的 PSNR 和 SSIM 指标。

表 4-2 Restormer 去雨模型评价指标对比

编号	模型	PSNR	SSIM
1	无	33.26	80.10%
2	Restormer	39.82	88.39%
3	NL-Means ^[10]	37.48	83.95%

通过以上对比可以得知,相较于传统的 NL-Means 数字图像方法,Restormer 模型具有更好的去雨效果。

4.3.2. FFA-Net 图像去雾模型

在雾天条件下捕获的交通图像会受到表现为灰白色的视觉遮挡,覆盖图像中的交通元素,对图像的视觉质量造成负面影响。图像去雾模型需要针对图像上存在的雾进行去除,这需要考虑到雾与图像背景信息紧密相关,因为雾几乎会影响到整张图像上所有区域的视觉质量。自然界中存在不同强度的雾,雾本身的浓度以及观察者与目标的距离使得雾在图像传感器上产生的形式不同。在这种情况下,依赖于传统数学模型的处理方法需要为不同浓度的雾和多变的环境场景调整多个参数,严重限制了其泛化能力。因此,选择基于深度学习的图像恢复模型以去除图像上的雾遮挡。

交通图像中的各元素具有复杂的特征,在经过神经网络的特征提取后生成的特征图的各通道上可以具有更高的区分度,因此采用通道注意力机制,将特征图的各通道赋予不同的权重,以强化模型对图像中大量类别的交通元素各自的特征的认识。图像中各区域根据物体与观察者距离、像素颜色等要素不同导致雾的浓度也各不相同,因此采用像素注意力机制,将特征图通道中的各像素赋予不同的权重,以强化模型对图像中不同强度和分布区域的雾特征的认识。因此,对于雾天图像,构建基于特征注意力机制的 FFA-Net 模型,以消除图像中的雾。该模型应用的特征注意力机制由通道注意力机制和像素注意力机制组成。通过监督学习过程中若干周期的迭代,不断将预测图像与原无雾图像进行对比,随着损失函数的下降,模型可以对雾的特征进行充分的学习,进而去除图像中的雾,达到图像增强的效果。

在加雾前后的交通图像数据集上训练 FFA-Net 去雾模型。由于构建的雾天交通图像规模不大且服务器训练资源有限,基于迁移学习的思想,使用基于 RESIDE 数据集^[57]上预训练的基础上进行训练,以提高模型的特征提取能力。RESIDE 是一个包含 13990 组无雾与人工加雾图像的数据集,其中涵盖了多种现实场景。通过迁移学习技术,可以应用这些在大规模样本中学习到特征的共性,使模型训练具有更好的效果。

与 Restormer 去雨模型类似,FFA-Net 模型将图像去雾问题视为一个监督学习问题。模型训练过程中,对于模型训练过程中的每一个周期,将训练集划分 90%用于模型拟合,将剩下的 10%用于验证。FFA-Net 模型的主要超参数如表 4-3 所示。

表 4-3 FFA-Net 模型超参数

编号	超参数	值
1	周期数	275
2	批大小	16
3	学习率	通过余弦退火策略从初始的 1×10^{-4} 逐渐降低到 0
4	优化器	Adam
5	损失函数	L1

使用监督学习模型预测去雾图像的像素值本质上是一个回归问题。因此，选用 L1 损失作为 FFA-Net 模型的激活函数。模型在训练过程中每个周期上的验证采用 SSIM 作为评价指标。模型训练完成后，将测试集中的加雾图像输入到模型中，使模型预测得出去雾后的测试集图像。采用 PSNR 和 SSIM 两种指标用于评估模型的性能。FFA-Net 模型以及传统的暗通道先验去雾算法在测试集上的各评价指标如表 4-4 所示。其中，“无”模型指原图像与加雾后的图像之间的 PSNR 和 SSIM 指标。

表 4-4 FFA-Net 模型评价指标对比

编号	模型	PSNR	SSIM
1	无	27.38	81.26%
2	FFA-Net	27.99	90.07%
3	暗通道先验 ^[14]	27.60	87.57%

通过以上对比可以得知，相较于传统的暗通道先验数字图像方法，FFA-Net 模型具有更好的去雾效果。

4.4. 模型边界测试

4.4.1. Restormer 模型边界

为了验证构建的模型恢复受不同强度雨干扰的图像视觉效果的性能，探究模型的性能边界，在 50 张交通图像上添加长度在[30,90]区间、密度在[30,210]区间的雨，分别调用 Restormer 模型对图像进行去雨操作。计算原图像与加雨图像之间的相似度以及原图像与去雨图像的相似度，并计算模型提升的 SSIM 占雨噪声降低的 SSIM 的比例，如式 (4.7) 所示：

$$ratio_{derain} = \frac{SSIM(o, dr) - SSIM(o, r)}{1 - SSIM(o, r)} \quad (4.7)$$

其中， $SSIM(o,r)$ 代表原图像与加雨图像之间的相似度， $SSIM(o,dr)$ 代表原图像与去雨图像的相似度。

可以得知， $SSIM(o,dr)-SSIM(o,r)$ 代表图像去雨前后与原图像相似度的变化量， $1-SSIM(o,r)$ 代表图像加雨操作为图像带来的失真比例。因此， $ratio_{derain}$ 计算得出的数值越大，即越接近 1，说明去雨的效果越好。使用热力图对模型对于不同雨长度和密度的图像的去雨效果 $ratio_{derain}$ 进行可视化，如图 4.3 所示。可以看出，模型对于雨长度在 [30,60] 且密度在 [70,210] 的图像具有较好的去雨效果，对于雨噪声过于密集或稀疏的图像则性能较低。




图 4.3 Restormer 模型去雨能力对比图

4.4.2. FFA-Net 模型边界

为了验证构建的模型恢复受不同强度雾干扰的图像视觉效果的性能，探究模型的性能边界，在 50 张交通图像上添加大气光强度在 [0.6,1.0] 区间、散射系数在 [0.4,2.0] 区间的雾，分别调用 FFA-Net 模型对图像进行去雾操作。计算原图像与加雾图像之间的相似

度以及原图像与去雾图像的相似度，并计算模型提升的 SSIM 占雾遮挡降低的 SSIM 的比例，如式（4.8）所示：

$$ratio_{dehaze} = \frac{SSIM(o, dh) - SSIM(o, h)}{1 - SSIM(o, h)} \quad (4.8)$$

其中， $SSIM(o, h)$ 代表原图像与加雾图像之间的相似度， $SSIM(o, dh)$ 代表原图像与去雾图像的相似度。

可以得知， $SSIM(o, dh) - SSIM(o, h)$ 代表图像去雾前后与原图像相似度的变化量， $1 - SSIM(o, h)$ 代表图像加雾操作为图像带来的失真比例。因此， $ratio_{dehaze}$ 计算得出的数值越大，即越接近 1，说明去雾的效果越好。使用热力图对模型对于不同雾强度的图像的去雾效果 $ratio_{dehaze}$ 进行可视化，如图 4.4 所示。可以看出，模型对于雾的散射系数在 $[0.6, 1.2]$ 且大气光强度在 $[0.7, 1.0]$ 的图像具有较好的去雾效果，对于雾散射系数过大或过小、光强过低或过高的图像则性能较低。




图 4.4 FFA-Net 模型去雾能力对比图

4.5. 实验结果

加载训练好的 Restormer 模型，将测试集中的若干雨天交通图像输入模型，原图像与去雨图像的对比示例如图 4.5 所示。



图 4.5 测试集去雨结果对比图

将现实场景中的若干雨天交通图像输入 Restormer 模型，原图像与去雨图像的对比示例如图 4.6 所示。为了使对比效果更加清晰，图中红色方格部分经过放大处理后显示于对应图像下方。




图 4.6 现实场景去雨结果对比图

通过以上对比可以得知，Restormer 模型可以改善受雨干扰的图像视觉效果，该模型可以为雨天条件下的交通图像目标检测提供改善的环境条件。

加载训练好的 FFA-Net 模型，将测试集中的若干雾天交通图像输入模型，原图像与预测结果图像的对比如图 4.7 所示。




图 4.7 测试集去雾结果对比图

将现实场景中的若干雾天交通图像输入 FFA-Net 模型，原图像与去雾图像的对比示例如图 4.8 所示。为了使对比效果更加清晰，图中红色方格部分经过放大处理后显示于对应图像下方。




图 4.8 现实场景去雾结果对比图

通过以上对比可以得知，FFA-Net 模型可以改善受雾干扰的图像视觉效果，该模型可以为雾天条件下的交通图像目标检测提供改善的环境条件。

4.6. 小结

分析雨天和雾天的特点，构建雨天和雾天图像数据集，并针对雨天和雾天图像分别建立并训练监督学习模型以还原交通图像，改善其视觉效果。针对雨天图像，构建 Restormer 模型；针对雾天图像，构建 FFA-Net 模型。最后，验证了两个模型面对不同程度的雨或雾场景的性能边界。经过测试得知，两种深度学习模型可以增强受雨、雾影响的图像质量，且相较于传统方法具有更好的增强效果，为后续的交通限速标志目标检测实验奠定了基础。

第五章 基于深度强化学习的交通限速标志检测方法

5.1. 概述

基于深度强化学习算法实现针对交通限速标志的目标检测模型，能够模拟人眼从全局的角度出发，自上而下地帮助智能体将注意力集中在潜在的候选区域，以便准确地标注目标的位置。首先，收集并标注包含交通限速标志的图像数据集，构建强化学习的环境。然后，设计动作空间、状态空间以及奖励函数，使模型能够准确地理解环境在各步骤时的特征，选择并做出合适的动作，动态地调整观察区域框的形状和位置，通过自上而下的推理来完成决策。奖励函数的设计考虑了时间步长的影响，以使模型能够在更少的步骤内完成任务。训练并建立基于 LSTM 模型的 DQN，综合历史和当前的行动及观察结果进行全面分析，进而确定并选中目标的具体位置。实验结果表明，该模型具有较高的目标检测精度和较好的性能。

5.2. 交通限速标志检测问题分析

交通限速标志检测是自动驾驶技术研究中道路环境感知的关键环节，使智能车辆能够感知行驶路段的交通限速标志，为后续认知道路的限速信息创造条件，以应对可能遇到的风险和挑战。现有的深度学习目标检测模型训练所需的数据集较大，在小规模样本上训练易产生欠拟合。交通限速标志检测可以被看作是通过一系列步骤来改变观察区域框的形状或位置，并确定图像中交通限速标志目标的位置的过程，需要模型的主动参与以理解图像的上下文信息，进而达到准确的定位。因此，交通限速标志检测算法可以采用基于动态检测机制的策略，首先对整个交通图像场景进行全局分析，然后逐渐缩小搜索范围，通过自顶向下的搜索过程，不断地根据当前区域的内容调整观察区域框，逐步确定观察区域框目标的位置。模型在该过程中通过对初始全局覆盖图像的观察区域框执行一系列转换实现，经过反复的迭代，最终紧密拟合目标。

图 5.1 为模型迭代过程的示意图。左侧的图像周围的蓝色矩形框代表模型在初始状态下默认标注的观察区域框，覆盖了图像的全局区域；后续的两张图像上的蓝色矩形框分别代表模型在迭代过程中的某一步和最后选定的一步标注的观察区域框，两者分别覆盖了包含目标交通限速标志的部分图像区域，且模型随着迭代的进行会将观察区域框不

断地向目标贴合。在迭代的过程中，观察区域框在下一个步骤的位置取决于其在当前步骤的位置和当前步骤要做的动作，而观察区域框进入下一个步骤之后，重复上述过程，使其更加贴近目标。



图 5.1 模型迭代过程示意图

在该过程的上下文中，状态可以描述为当前观察区域框内的图像特征和历史动作；动作为模型可以执行的改变观察区域框位置或尺寸的操作；策略为状态到动作的映射；转移概率可以表示为一个给定当前状态和动作后将会到达下一个状态的函数；奖励函数可以根据动作是否导致观察区域框更接近目标位置来定义。可以看出，此过程可被形式化为一个马尔科夫决策过程（Markov Decision Process, MDP）。模型的目的是找到一个策略，通过执行一个序列的动作，使得从初始状态到目标状态的累积奖励最大。因此，引入了强化学习算法，使模型通过与环境的持续交互，逐步优化决策效果。强化学习算法在每个步骤中都会根据当前的状态和奖励来更新其策略，从而在迭代过程中逐步改善观察区域框的位置和尺寸，使得观察区域框更准确地定位目标对象。由于状态包含图像数据，状态空间较为复杂，为一个具有维度较大的连续数值的向量，建立了 DQN 作为算法主体，使用深度强化学习完成交通限速标志目标检测的任务。

智能体需要理解状态随时间变化的序列依赖，以便做出最优决策。长短期记忆（Long Short-Term Memory, LSTM）网络是一种特殊的循环神经网络，适合处理带有时间序列依赖性的数据，其一大优点是能够捕捉长期依赖信息，综合分析历史和实时的感知数据及行为来指导智能体选择动作。因此，选用 LSTM 作为 DQN 的模型结构，通过 LSTM 的时序信息处理能力有效地学习动态环境中的时序特征，为智能体提供执行决策的强大支持。

5.3. 模块结构设计

交通限速标志目标检测中的状态由当前观察区域框内的图像区域和一些历史动作定义，动作是从可选动作空间中选择的对观察区域框的一种操作，奖励函数由执行一个动作后对检测结果的影响而评定。对于每个步骤，模型会在给定状态的情况下选择一个动作，并执行该动作。根据执行的动作，模型会收到一个奖励，并转移到新的状态。该奖励用于评估选择动作的效果，并为后续的决策提供反馈。模型的目标是寻找一个策略，该策略可以最大化期望的累积奖励。图 5.2 显示了各模块的设计思路，展示了构建交通限速标志目标检测模型时各模块中包含的不同功能。




图 5.2 目标检测模块结构设计

（1）动态决策过程模块

首先，加载收集的交通图像数据集和图像上的交通限速标志目标位置，并对相关数据进行预处理操作，以构建用于深度强化学习的环境。其次，针对交通限速标志目标检测任务的特点，分别设计合适的动作空间、状态空间和奖励函数，为后续模型的训练和预测等步骤打下基础。

（2）DQN 网络构建模块

首先，根据深度强化学习任务中的状态、动作等要素的特点构建适合的网络结构，使得 DQN 网络可以更好地理解环境。其次，设计 DQN 网络的训练流程，包括在训练集上训练模型的具体步骤、DQN 网络参数的更新步骤和其中的参数选择等。最后，设计将图像数据输入训练好的 DQN 网络后，网络对交通限速标志目标进行检测的流程，使模型可以发挥其功能，并为后续的模式测试做准备。

（3）DQN 网络测试模块

首先，设计合适的测试流程，对模型在测试集上的性能进行测试。其次，选择合适的评价指标，对模型的性能进行评价，判断模型能否准确地标注测试集图像中的交通限速标志目标。

5.4. 动态决策过程设计

强化学习任务中，智能体通过感知环境 E 并通过与其进行交互以实现更加准确的决策。MDP 在形式上具有一组动作 A 、一组状态 S 和一个奖励函数 R 。本节介绍环境、动作、状态和奖励函数的详细设计。

5.4.1. 交通图像环境设计

在强化学习中，环境 E 是指智能体所处的上下文或背景，决定智能体可观察的状态以及可行的动作。环境的状态根据智能体的行为或者外部因素进行变化。根据上述需求分析，将输入模型的图像视为使用强化学习方法解决交通目标检测任务的环境。因此，本模块读取图像及其标注数据，并对其进行必要的预处理工作。

(1) 构建交通图像数据集

收集包含交通限速标志的图像数据集^[54]，如图 5.3 所示。构建包括图像中各像素的 RGB 值数据以及观察区域框的坐标数据的交通图像环境，作为后续模型训练的数据基础。为了使智能体可以在训练过程中有限的探索步骤内更高效地学习交通图像及其中限速标志的特征，通过裁剪方式调整图像，使图像中的限速标志大小平均占图像面积的 12% 左右。调整后的数据集共有 589 张交通图像。



图 5.3 交通图像环境

(2) 标注交通图像特征信息

需要的交通限速标志图像特征信息包括图像的名称、以像素 RGB 值的形式表示的图像数据和目标对象所在的坐标位置数据。对每一张图像上需要检测的交通限速标志目标的坐标进行标注。

（3）保存交通图像环境

保存所有图像对应的标注文件，文件中包含图像的路径、名称、尺寸等信息以及目标交通限速标志对象的坐标等结构化数据。

（4）加载交通图像环境

根据标注文件中图像的路径和名称读取图像数据后，将图像的像素 RGB 值数据归一化处理，将其值映射为 0~1 的区间，以便神经网络更好地提取其特征。然后，为了方便保存数据以及后续模型训练的输入，将图像的尺寸统一转换为 224*224。将图像依照其路径读取到以图像的名称为键（Key）、以包含一个张量对象表示的图像的像素 RGB 值数据、标注框坐标位置数据以及图像本身的宽、高和维度数据的对象为值（Value）的键值对中。

为了后续能够测试模型训练的效果，将数据集按照 80%：20%的比例随机划分为训练集和测试集。将图像数据保存到文件中，以供模型直接读取，避免频繁的 IO 操作，改善了读写性能。

5.4.2. 动作空间设计

强化学习中，动作空间 A 指的是在给定状态下智能体可以选择执行的所有可能动作 a 的集合。动作空间可以分为离散的和连续的两种类型。智能体在每个步骤移动或缩放观察区域框，使得观察区域框尽可能地接近交通限速标志目标的实际位置，构成了一个离散的动作空间。设置动作空间的大小 $|A|=9$ ，并将动作空间设置为 $A=\{0,1,2,3,4,5,6,7,8\}$ 。其中，0 代表选定观察区域框的位置，1、2、3、4 代表移动观察区域框，5、6、7、8 代表缩放观察区域框。

每次移动或缩放均会使观察区域框按图像长、宽一定比例的像素的距离变化，将该比例定义为缩放因子 α 。将缩放因子设置为 $\alpha = 0.03$ 。此外，如果坐标在变化后超出了 $[0,224]$ 区间，将其中的负值变换为 0，大于 224 的值变换为 224。

动作空间的详细说明如表 5-1 所示。

表 5-1 动作空间详细说明

编号	动作	说明
0	选中	选中观察区域框的位置
1	向右	将观察区域框向右移动, 即横坐标的最大值和最小值均增大 224*3%
2	向左	将观察区域框向左移动, 即横坐标的最大值和最小值均减小 224*3%
3	向上	将观察区域框向上移动, 即纵坐标的最大值和最小值均减小 224*3%
4	向下	将观察区域框向下移动, 即纵坐标的最大值和最小值均增大 224*3%
5	变大	将观察区域框变大, 即横坐标和纵坐标的最小值均减小 224*3%, 横坐标和纵坐标的最大值均增大 224*3%
6	变小	将观察区域框变小, 即横坐标和纵坐标的最小值均增大 224*3%, 横坐标和纵坐标的最大值均减小 224*3%
7	变宽	将观察区域框变宽, 即纵坐标的最小值增大 224*3%, 最大值减小 224*3%
8	变窄	将观察区域框变窄, 即横坐标的最小值增大 224*3%, 最大值减小 224*3%

5.4.3. 状态空间设计

强化学习中, 状态 s 指智能体关于其环境的信息的描述, 状态空间 S 指所有可能的状态的集合。状态空间分为离散和连续共两种类型。设计状态空间为连续和离散的两个部分。智能体在 t 时刻的状态定义如式 (5.1) 所示:

$$s_t = (f, h) \quad (5.1)$$

其中, 第一部分 f 为特征提取器从观察区域框中提取的特征向量, 第二部分 h 为基于滑动窗口理论设计的包含历史动作信息的向量。

(1) 向特征提取器输入观察区域框内的图像。基于迁移学习的思想, 使用在 ImageNet 数据集上预训练的 VGG16 网络^[58]中的主干部分以及不含原网络连接 Softmax 激活函数的最后一个全连接层的分类器部分作为特征提取器。此处不使用观察区域框内的图像数据对该网络进行训练, 因此, 关闭网络中的 Dropout 部分, 并在批归一化层使用运行平均值和运行方差, 从而得到更准确的模型输出。智能体在每个回合的每个步骤中, 将观察区域框定的图像数据输入网络, 构建连续的状态空间。设置状态向量 f 的维度为 4096。

(2) 每个回合的开始, 定义一个形状为(9,9)的二维向量, 将其初始值设置为全为 1。每次动作执行后, 将动作的编号转换为独热编码, 即一个长度为 9 的二进制向量, 其中除了选择的动作对应的位置为 1, 其余全为 0。定义步骤 t 的动作为 a_t , 则步骤 t 的历史

动作滑动窗口为 $h = \{a_{t-9}, a_{t-8}, a_{t-7}, a_{t-6}, a_{t-5}, a_{t-4}, a_{t-3}, a_{t-2}, a_{t-1}\}$ 。将向量放入滑动窗口队列的开头，并删除滑动窗口队列结尾的一个向量。将该状态向量展平，其维度为 81。

(3) 最后，将两个特征向量横向拼接为一个维度为 4177 的向量 s_t ，作为智能体在步骤 t 的状态。

状态空间的设计结构如图 5.4 所示。




图 5.4 状态空间设计结构

5.4.4. 奖励函数设计

强化学习中，奖励函数 R 是一个用来衡量智能体在环境中执行某个动作后获得的即时反馈的函数。奖励函数是强化学习算法的核心组成部分，为智能体在环境中的行为提供了优化的方向。智能体的动作包括选中观察区域框和对观察区域框进行移动或缩放。每个步骤中动作执行完成后，根据执行的动作类别为“选中”或变更观察区域框的位置，按两种不同的公式计算奖励函数。智能体选择了“选中”动作后，使用训练集中事先标注好的目标真实位置与观察区域框的位置进行对比。决策的好坏通过目标和预测的观察区域框面积的交并比（Intersection-over-Union, IoU）衡量。设 ob 为观察区域框， gr 为目标对象的真实区域框。那么， ob 和 gr 之间的 IoU 定义如式（5.2）所示：

$$IoU(ob, gr) = \text{area}(ob \cap gr) / \text{area}(ob \cup gr) \quad (5.2)$$

当智能体成功选中观察区域后,意味着智能体认为已经精确地定位到图像中的目标。因此,选定观察区域框是最重要的动作,应该获得较高的奖励。奖励函数基于预设的交并比阈值 τ 决定,如果交并比大于该阈值,则给予该动作较大的正奖励;反之,则给予其绝对值较大的负奖励。奖励函数的计算公式如式(5.3)所示:

$$R_a(s_t, s_{t+1}) = \begin{cases} \max(3, (IoU(ob, gr) - \tau) * \nu), & IoU(ob, gr) \geq \tau \\ \min(-3, (IoU(ob, gr) - \tau) * \nu), & IoU(ob, gr) < \tau \end{cases} \quad (5.3)$$

其中, a 表示该步骤选择的动作, s_t 表示 t 步骤的状态。 τ 为交并比阈值, ν 则为一个使实际交并比和阈值的差值放大的一个系数。

设置 $\tau = 0.66$, 即做出“选中”动作后交并比应大于 0.66 才给予正反馈; ν 则设置为 20, 经过计算可得知, 交并比在(0.66,0.81)区间内时, 奖励函数计算公式的第一项为 3, 大于 0.81 后该项与交并比差值的绝对值成系数为正值的正比例关系; 交并比在(0.51,0.66)区间内时, 奖励函数计算公式的第一项为-3, 小于 0.51 后该项与交并比差值的绝对值成系数为负值的正比例关系。

智能体选择“选中”以外的其他动作时, 奖励函数与智能体选择特定动作后观察区域框与目标位置的交并比的改进程度成正比。当智能体选择动作 a 从状态 s_t 移动到 s_{t+1} 时, 奖励如式(5.4)所示:

$$R_a(s_t, s_{t+1}) = \text{sign}(IoU(ob_{t+1}, gr) - IoU(ob_t, gr)) - t / 500 \quad (5.4)$$

可以得知, 如果从状态 s_t 到状态 s_{t+1} 后交并比有所增加, 那么奖励函数计算公式的第一项赋予 1; 否则, 将该项设置为-1。该设计可以明确地表示步骤 t 选择动作的好坏, 即当智能体导致观察区域框离开目标时会受到惩罚; 反之, 就会得到正奖励。此外, 该公式也考虑了步骤数 t 的大小对奖励的影响。在智能体做出非“选中”动作后, 给出的奖励中引入一个惩罚项, 该项的值与步骤数 t 成系数为负的正比, 意味着如果智能体在更多的步骤中还未完成任务, 那么将得到更低的奖励。加入该项的设计基于强化学习中优先选择短步骤序列达到目标的理念, 使智能体在执行过多步骤时得到一定的惩罚, 避免执行过多不必要的动作, 以减少智能体使观察区域框重复相同动作序列, 但无法选中区域的情况^[59]。

5.5. DQN 网络构建

智能体的目标是通过选择不同的动作来变换观察区域框，通过最大化与环境交互过程中获得的奖励之和，使得观察区域框更贴近目标的位置。该方法的核心问题是找到一个适用于不同状态 s 和动作 a 下的策略 $\pi(s)$ 指导智能体的决策过程。由于该问题中的状态空间包含连续的图像特征数据且维度较高，选用基于深度强化学习算法处理该问题。DQN 采用深度神经网络模型来近似 Q 函数，其输入是状态，输出是对应于每个可能动作的 Q 值。通过该方式，DQN 能够有效地处理高维度的复杂状态空间和动作空间。

5.5.1. DQN 网络结构设计

人眼在观察视野中的某种物体时，会有选择性地忽略看见的大多数信息，并关注其中感兴趣的部分。然后，将注意力逐渐向目标位置转移，以关注到物体的位置。该过程不仅会涉及到对人眼获取的历史信息的应用，也涉及到将获取的历史信息与当前信息结合，来确定目标的位置。

智能体在训练的每个回合会从步骤 $t=0$ 开始更新状态。智能体在 t 时刻的状态为 $s_t = (f, h)$ ，其中， f 为观察区域框内经过基于预训练 VGG16 模型的特征提取器提取的图像特征向量，以及 9 项以独热编码形式记录、保存在长度为 9 的滑动窗口中的历史动作 h 。由于观察区域框按步骤移动，该特征向量的历史记录为一个随着观察区域框移动而变化的序列。此外，如果定义步骤 t 的动作为 a_t ，则步骤 t 的历史动作滑动窗口为 $\{a_{t-9}, a_{t-8}, a_{t-7}, a_{t-6}, a_{t-5}, a_{t-4}, a_{t-3}, a_{t-2}, a_{t-1}\}$ 。由此可知，观察区域框自顶向下地按步骤逐渐确定目标位置的过程具有时间序列依赖。基于普通的全连接神经网络搭建的 DQN 在每次做出决策时只会依赖上一个时刻的观测状态，没有考虑到状态可能会是一个随时间变化的序列，无法捕捉历史状态对当前状态和策略的影响。如果 DQN 可以记忆这种时序依赖，便可以在预测的过程中更准确地指导智能体选择动作。

对于历史信息 and 当前信息的获取与应用，LSTM 模型具有明显的优势。LSTM 的输入不仅包括当前时刻的特征值，也包括模型在过去若干时刻输入的历史特征，使其既可以捕捉短期状态，又可以捕获状态和动作时间序列的长期信息。将 LSTM 应用于深度强化学习算法中，通过整合跨帧的图像序列信息，将智能体获取的历史经验运用到当前时

刻的观察，可以使智能体结合当前步骤和历史步骤的状态和动作序列来做出决策^[60]。因此，选用 LSTM 作为策略网络和目标网络的主要结构。基于 LSTM 模型的 DQN 的具体结构如图 5.5 所示。




图 5.5 基于 LSTM 模型的 DQN 结构图

模型当中选用的 LSTM 是一种 RNN，可以处理序列数据，记忆过去的时序信息，并在预测时将其作为参考。智能体通过使用 LSTM 可以更好地理解各步骤下状态之间的时间序列依赖关系。全连接层和 Softmax 激活函数将 LSTM 的输出映射到选择 9 项动作的概率上，使得 DQN 可以准确地选择合适的动作。

Dropout 的比例 p 决定了在每次迭代中关闭神经元的比例。设定 $p = 0.2$ ，即每次迭代中都会随机关闭 20% 的神经元。

基于 LSTM 模型的 DQN 网络的主要超参数如表 5-2 所示。

表 5-2 DQN 网络超参数

编号	超参数	值
1	回合数	60
2	批大小	100
3	学习率	1×10^{-6}
4	优化器	Adam
5	损失函数	交叉熵

将最大回合数 $e_{\max}$ 设置为 60，每次更新网络时从经验回放缓冲区中抽取的样本批大小为 100。DQN 的输入是包含观察区域框内图像特征和历史动作向量的状态信息，输出是选择的动作。因此，这是一个分类问题，选择交叉熵作为 DQN 的损失函数。

5.5.2. DQN 网络训练

在收集和标注的交通图像数据集上训练目标检测模型。主要目标是训练一个智能体，使其能够在图像中找到并准确地标注交通限速标志对象。图 5.6 为 DQN 模型的训练流程图。




图 5.6 DQN 训练流程图

(1) 首先，设置对训练集中每张图像训练的回合数 $e_{\max}$ 和每回合的最大步骤数

$t_{\max}$ 。

(2) 每张图像的每个回合开始时，将该图像及该图像上目标的真实位置提取为训练样本，并将观察区域框划定为整个图像。

(3) 开始步骤数 t 从 0 到 $t_{\max}$ 的循环。对于每个步骤，在每张图片上运行一系列的动作。如果 $t=t_{\max}$ ，结束流程。如果动作选择为“选中”且 $t \neq t_{\max}$ ，对于每个动作，智能体根据是否是“选中”动作处理不同的情况。如果选择的是“选中”动作，将其计入历史动作，计算当前的观察区域框坐标，计算记录的各历史动作对应的观察区域框坐标与真实值的交并比的最大值，计算奖励，并标记一回合结束。如果不是，则更新动作历史，计算新的观察区域框坐标，提取新的观察区域框内的图像，根据特征提取器提取的图像特征向量和动作历史滑动窗口计算新的状态，选择一个动作并将其记入历史动作。计算记录的各历史动作对应的观察区域框坐标与真实值的交并比的最大值，找到最佳的动作以更新观察区域框，计算奖励。

(4) 在每个动作执行后，将当前的状态、动作、下一个状态和奖励存储到经验回放缓冲区，并运行优化模型函数来更新策略网络。

(5) 在每张图像训练完成后，使用策略网络的参数来更新目标网络，并保存当前的网络模型。

将每个回合的最大步骤数 $t_{\max}$ 设置为 50，即动作选择为“选中”或 $t=50$ 时结束该回合的流程。

传统的 ε -greedy 策略中，智能体以探索率 ε 的概率随机选择一个动作，以 $1-\varepsilon$ 的概率使用贪心算法选择 DQN 网络当前估计的最优动作。这种策略虽然简单，但效率较低，因为很多随机选择的动作可能是无效的。针对该问题，训练过程中，使用基于改进的 ε -greedy 策略^[61]来选择动作。改进的 ε -greedy 策略中，智能体也会以 $1-\varepsilon$ 的概率贪心地选择 DQN 网络估计的最优动作，但会以 ε 的概率模拟执行动作空间 A 中的所有动作，并分别计算各种动作执行后的奖励函数集合 $\{R_{a_1}(s_t, s_{t+1}), R_{a_2}(s_t, s_{t+1}) \cdots R_{a_A}(s_t, s_{t+1})\}$ 。接着，将该集合中大于 0 的奖励函数对应的动作放入集合 $\{A_{\text{positive}}\}$ 中。如果集合 $\{A_{\text{positive}}\}$ 不为空，智能体从该集合中随机选择一个动作。否则，智能体从动作空间 A 随机选择一个动作。该策略通过更智能的探索机制和动态探索与利用的平衡，能够提高学习效率，同时减少对无效探索的浪费，从而优化整体的训练过程和模型性能。执行流程的伪代码如表 5-2 所示。

表 5-2 改进的 ϵ -greedy 策略伪代码

改进的 ϵ -greedy 策略
输入: DQN 网络 Q 、 t 步骤的状态 s_t 、动作空间 A 、探索率 ϵ
输出: 选择的动作
<pre> def improved_epsilon_greedy(Q, s_t, A, epsilon): if random(0, 1) < epsilon: # random(0, 1)生成一个(0,1)区间的数 R_values = {} # 各种动作执行后的奖励函数集合 for a in A: # 执行各种动作并分别计算奖励 R_values[a] = calculate_reward(s_t, a) A_positive = {a for a in A if R_values[a] > 0} # 找出奖励大于 0 的动作集合 if A_positive: # 如果存在奖励为正的动作为, 则从中随机选择 return random_choice(A_positive) else: # 否则从全部动作中随机选择 return random_choice(A) else: # 贪心地选择 DQN 当前估计的最优动作 return argmax_a(Q(s_t, a)) </pre>

训练开始时, 设置 $\epsilon = 1$, 即完全随机地选择动作。在训练的前 5 个周期内, 每个周期结束后 ϵ 的值减小 0.18, 使得智能体在初始阶段有足够的机会进行探索, 而随着训练的的进行, 逐渐减少探索, 在 5 个回合后随机选择动作的概率降低为 10%, 增加对探索结果的利用。因此, 虽然改进的 ϵ -greedy 策略在早期 ϵ 值较大时会使模型训练效率略有下降, 但后期随着 ϵ 值的减小, 模型训练效率会显著提升, 且会使模型收敛更快, 同时增加训练的速度和性能。

智能体在每次做出一个动作、计算奖励后, 基于 LSTM 模型的策略网络和目标网络均需要进行一次更新, 更新流程如下。

(1) 首先, 从经验回放缓冲区中随机抽取一批样本, 批大小设定为 100。缓冲区用于存储智能体与环境交互所获取的经验, 包括状态、动作、奖励以及下一个状态。随机抽样可以确保独立同分布的假设, 打破数据之间的时间关联, 从而提高数据的利用效率。

(2) 将随机抽取的样本构造为一批数据, 包括状态批数据、动作批数据和奖励批数据, 用于进行梯度下降和网络参数的更新。

(3) 将状态和动作的批数据输入到策略网络中, 用于计算每个状态-动作对的 Q 值。同时, 使用目标网络来计算每个非终止状态的最大 Q 值。策略网络主要用于选择动作, 而目标网络负责提供稳定的目标 Q 值, 避免训练过程中的不稳定性。

(4) 通过贝尔曼方程计算出目标 Q 值, 由即时奖励和折扣后的下一状态的最大 Q 值之和得到。折扣因子 γ 用于控制对未来奖励的考虑程度。将 γ 的值设置为 0.99。

(5) 计算损失函数, 并执行反向传播和参数更新。Adam 优化器首先清零梯度, 然后计算损失函数的梯度, 并根据梯度执行 DQN 的参数更新。

DQN 训练过程的目标是最大化累积奖励函数。交通限速标志目标检测模型训练过程中, 使用改进前后的 ε -greedy 策略的情况下各回合的累积奖励函数的变化趋势如图 5.7 所示。




图 5.7 累积奖励函数趋势图

从图上可以得知, DQN 在第 1 个回合有较高的累积奖励, 前 5 个回合的累积奖励依次递减。其原因在于, 在改进的 ε -greedy 策略中, 智能体以 ε 的概率模拟执行动作空间 A 中的所有动作, 并随机执行一个奖励函数为正的動作。由于第 1 个回合中 $\varepsilon = 1$, 智能体执行的所有动作获取的奖励函数均为正, 使得 DQN 获得了较高的奖励函数。随着 ε 的减小, 智能体不再总是能够通过该方式获取较高奖励, 只能通过利用从探索中获取的经验来做出正确的动作选择。第 5 个回合后, ε 衰减到 0.1, 智能体逐步依靠自身的经验选择动作, 获取逐渐升高的累积奖励, 并在若干回合后超过了初始状态下依靠随机选择正确动作获得的较高累积奖励值, 完成了训练。相比之下, 原始的 ε -greedy 策略起点较低, 且经过了 60 个回合的训练以后, 累积奖励仍未能超越基于改进的 ε -greedy 策略训练的 DQN 模型, 出现了欠拟合问题, 仍需要继续花费时间进行训练才可能达到较优的训练效果。

图 5.8 为使用改进前后的 ε -greedy 策略的情况下训练 DQN 模型的累积训练时长。从图上可以看出,改进的 ε -greedy 策略在训练的早期阶段较为缓慢,这是因为智能体需要模拟执行动作空间中的所有备选动作,找出奖励为正的的动作集合以供选择。但是,在经历了若干周期的训练后,在每个回合的探索过程中需要更少的步骤数,改进的 ε -greedy 策略下训练的 DQN 具有更高的性能。因此,在最后累积奖励更高的情况下,展示出了更快的训练效果。




图 5.8 累积训练时长趋势图

5.5.3. DQN 网络预测

将训练好的 DQN 保存在本地后,模型即可以加载网络,对训练集以外的图像中的交通限速标志目标位置进行检测,流程如下。

- (1) 首先,读取一张图像,并将其形状转换为 $224*224$,以适应模型的输入要求。
- (2) 将观察区域框初始化为框定整张图像。从步骤 $t = 0$ 开始循环,每一步均将图像输入特征提取器,并将图像特征向量与滑动窗口保存的历史动作作为状态,将状态输入训练好的 DQN 网络中。此时, DQN 网络能够为每个可能的动作进行“评分”,并选择得分最高的动作作为最佳动作。
- (3) 循环不断进行,直到 DQN 网络选择“选中”动作或 $t = t_{\max}$ 为止。

模型在交通图像上检测其中的交通限速标志目标位置时观察区域框的变化过程、IoU 值以及检测结果如图 5.9 所示,图中的蓝色矩形即为观察区域框。




图 5.9 目标检测过程与 IoU 值示意图

从图中可以得知，模型在检测目标的具体过程中，观察区域框在 $t = 0$ 时覆盖整张图像，并在后续步骤的迭代过程中不断趋近于目标位置。最终，模型较为准确地框定了图像中的交通限速标志目标。

5.6. DQN 网络测试

将测试集输入训练完成的 DQN 后，模型按上述预测流程对测试集中的每张图像当中交通限速标志目标的位置进行预测，并使用蓝色矩形框标注。对于每张图像，预测结束后，将预测结果与训练集中事先标注的目标位置真实值进行对比，计算预测结果与目标真实位置的交并比。定义如果两者的交并比大于等于 50%，则为一次正确的预测，即预测结果可以比较准确地确定图像中指定目标的位置。

按照上述分析可以得知，该问题是一个分类问题，引入准确率指标来评价模型框定交通限速标志的性能。此外，除了构建的 DQN 模型以外，在相同的 589 张图像组成的数据集上训练改进前的模型以及 YOLOv4 模型，将三者 in 测试集中上的准确率指标进行对比，实验结果如表 5-3 所示。

表 5-3 DQN 模型评价

编号	模型	准确率
1	本实验	93.16%
2	Caicedo ^[29] 等人实验	88.03%
3	YOLOv4 ^[62]	83.76%

实验结果表明，DQN 在较小训练样本的条件下展示出了较高的检测精度，优于改进前的模型。此外，虽然 YOLOv4 深度学习目标检测模型已经在现实生产生活中被广泛应用，有卓越的性能表现，但是在 589 张图像组成的小训练样本下，由于欠拟合问题，性能表现不佳，构建的 DQN 模型在此情况下有独特的优势。

加载本地保存的包含和去除了雨、雾的交通图像数据集，调用训练好的 DQN 模型，对图像中的交通限速标志执行目标检测操作。经过测试，模型对图像中交通限速标志进行目标检测的准确率如表 5-4 所示。

表 5-4 模型在不同图像状况上目标检测效果评价

编号	图像状况	准确率
1	雨天	76.92%
2	去雨	89.74%
3	雾天	69.23%
4	去雾	85.47%

结果表明，Restormer 与 FFA-Net 图像增强模型对交通图像视觉效果优化为目标检测提供了更加有利的基础，提升了目标检测模型的准确性。

5.7. 小结

构建基于深度强化学习的目标检测模型。首先，收集包含交通限速标志的图像数据集，并对其中的目标进行标注。其次，基于深度强化学习算法构建模型，详细定义其动作空间、状态空间以及奖励函数。基于 LSTM 模型建立 DQN，读取图像和历史动作相关特征数据后可以选择动作，使观察区域框不断靠近目标位置以实现目标检测。实验结果不仅验证了该模型具有准确的目标检测能力，而且证实了构建的 Restormer 与 FFA-Net 图像增强模型可以有效地改善雨雾天气下图像的质量，为目标检测创造良好的条件，增加目标检测的精度。

第六章 晴雨雾天气场景交通限速标志检测流程模型

6.1. 概述

设计晴雨雾天气场景交通限速标志检测流程模型。根据晴雨雾天气场景下目标检测的要求，将构建的各模块进行功能解耦，对各模块的依赖关系进行详细分析并构建有向无环图，确保其能够以正确的逻辑执行。将各模型和 Airflow 调度工具搭载于 Linux 服务器，构建晴雨雾天气场景交通限速标志检测流程模型。流程模型中的各模块具有高内聚、低耦合的特性，使得流程模型具备高度的可修改性和可扩展性。当用户需要修改流程中的某些模块或扩展功能时，只需对相应部分进行修改即可满足新的需求。构建的流程模型可以按照预设的功能模块之间的关系对其进行自动化调度和执行。

6.2. 问题分析与解决方案

晴雨雾天气场景交通限速标志检测是一个复杂的服务，其中包含多个模型，涉及对图像的天气识别、去雨、去雾和目标检测一系列操作。智能车辆在行驶时，驾驶人员无法以手动的方式分别调用模型。如果依靠简单的条件判断（if...else...）语句整合构建的各模型，会导致流程中的各功能模块出现紧耦合。如果用户的需求变更，则需要重新编写系统逻辑，不利于系统的修改与扩展。因此，设计的流程应具有以下特征：

（1）可扩展。如果用户需要增加可以识别的天气种类，或增加需要检测的交通标志类别，只需要对接相应的接口，而不需要修改现有的功能模块以及流程逻辑。

（2）可修改。如果用户需要变更其中的一个模块，例如用户将来需要将图像去雨模块更换为更先进的模型，只需要在流程中的对应位置来更新其中一个功能模块，流程逻辑以及流程中的其他模块不需要发生改变。

为了实现流程的灵活性，在流程设计过程中，需要对各功能模块进行解耦，满足高内聚、低耦合的设计原则，并按照软件工程的开闭原则，关闭对各模块的具体功能修改，开放对流程功能的扩展，使得流程便于修改、扩展和维护。此外，流程执行出现错误时需要异常处理与重试机制以降低人工干预的需求，用户需要对流程运行的过程、功能模块的运行状态和运行结果进行可视化。因此，对构建的各模块进行功能解耦，并对各模

块之间的依赖关系进行表达，基于 Airflow 工作流调度工具设计晴雨雾天气场景交通限速标志检测流程模型，流程模型具有可扩展性与可维护性以解决用户多变的需求。

6.3. 模块依赖关系分析

晴雨雾天气场景交通限速标志检测流程中各模块间存在特定的依赖关系，决定功能模块的执行顺序。由于用户的需求可能会发生变更，工作流应具有可扩展性和可修改性以适应变化。因此，遵循高内聚、低耦合的软件设计原则，将系统中不同的功能模块进行解耦，确保解耦后的各模块均可以独立实现各自的功能，其目的在于降低系统组件间的依赖性，允许独立地扩展或修改系统的不同部分，无需对整个系统进行全面的重构。为了描述各模块之间的组合关系，采用树形结构表示流程中的 4 个功能模块，如图 6.1 所示。




图 6.1 服务树形功能结构图

该流程包含 4 个功能模块：

（1）图像晴雨雾天气识别模块。调用 SE-ResNeXt101 模型对交通图像的天气进行分类，将图像分为晴天、雨天和雾天 3 种天气类别。

（2）图像去雨模块。若天气为雨天，调用 Restormer 去雨模型增强图像质量，并保存增强后的图像。

（3）图像去雾模块。若天气为雾天，调用 FFA-Net 去雾模型增强图像质量，并保存增强后的图像。

(4) 交通限速标志目标检测模块。加载晴天图像或去雨雾增强的图像，调用基于深度强化学习的目标检测模型，检测图像中的交通限速标志目标，并输出目标检测结果。

为了表示模块间的复杂依赖关系，采用有向无环图（Directed Acyclic Graph, DAG）表示算法中各模块之间的拓扑关系，以确保 workflow 按照依赖关系执行各模块。按照流程逻辑编排的 DAG 模型如图 6.2 所示。




图 6.2 流程逻辑有向无环图

6.4. 流程模型建模

将构建的晴雨雾天气识别模型、去雨模型、去雾模型和交通限速标志目标检测模型部署在 Linux 服务器上，并在服务器上安装 Airflow 工作流调度工具。服务器的程序运行环境如表 6-1 所示。

表 6-1 服务器运行环境

编号	名称	选用版本
1	操作系统	CentOS 7
2	Airflow	2.8.1
3	Python	3.10.12
4	PyTorch	2.1.0
5	OpenCV2	4.8.0

根据 DAG 依赖关系，基于 Airflow 设计晴雨雾天气场景交通限速标志检测流程模型。该模型是流程的一种抽象化表达方式，每次对该模型进行调用时，都会生成具体的流程实例来执行具体功能模块。流程模型如图 6.3 所示。




图 6.3 晴雨雾天气场景交通限速标志检测流程模型

Airflow 允许参数化流程模型，使得相同的工作流可以用不同的参数多次运行，增加了工作流的重用性。流程模型的参数如表 6-2 所示。该流程模型支持异步并行执行最多 10 个实例。可供功能模块调用的自定义变量 `img_path`（图像路径）和 `target`（目标）将会在启动流程的命令中赋值，功能模块可以从 `dag_run.conf` 对象中读取所需的变量。如果功能模块执行失败，Airflow 会在 10 秒后尝试重新执行该流程 1 次。

表 6-2 流程模型参数

编号	名称	值	说明
1	<code>dag_id</code>	<code>detection_workflow</code>	流程模型的 ID，唯一标识流程模型
2	<code>fileloc</code>	<code>/root/airflow/dags/detection_workflow.py</code>	流程模型定义 Python 文件的位置
3	<code>tags</code>	<code>["experiment"]</code>	流程模型的标签列表，便于分类管理
4	<code>conf</code>	<code>["img_path", "target"]</code>	可供功能模块调用的自定义变量列表
5	<code>concurrency</code>	1	单个流程模型实例可以同时运行的功能模块数
6	<code>depends_on_past</code>	False	是否需要等待上一个实例结束才能执行新的实例
7	<code>max_active_runs</code>	10	流程模型可以同时拥有的活跃实例数
8	<code>retries</code>	1	功能模块失败后最多重试的次数
9	<code>retry_delay</code>	<code>timedelta(seconds=10)</code>	功能模块失败后延迟多长时间后进行重试

流程模型中包含 4 个功能模块，包括图像晴雨雾天气识别（`predict_weather`）、图像去雨（`derain`）、图像去雾（`dehaze`）和目标检测（`detect_target`）。功能模块包含的参数如表 6-3 所示。

表 6-3 功能模块参数

编号	名称	说明
1	task_id	功能模块的 ID, 唯一标识功能模块
2	dag	功能模块所属的流程模型 ID
3	type	功能模块类型
4	python_callable	功能模块对应的可调用 Python 文件
5	op_kwargs	自定义参数字典

流程模型接收到用户输入的一张交通图像后, 将流程模型进行实例化, 赋予其 Run ID 用于唯一区别流程实例。平台首先调用天气识别模型, 执行天气识别功能模块, 将图像天气分为晴天、雨天和雾天共 3 种类别。为了控制该功能模块与后续模块的协作关系, 定义 `weather_result` 变量, 将晴天、雨天和雾天分别用 0、1、2 表示。该变量会通过 Airflow 后台的元数据库进行传递。当 `weather_result` 变量值为 0 时, 直接调用目标检测模型; 当 `weather_result` 变量值为 1 时, 调用图像去雨模型, 将增强后的图像保存为 `temp.png`, 调用目标检测模型; 当 `weather_result` 变量值为 2 时, 调用图像去雾模型, 将增强后的图像保存为 `temp.png`, 调用目标检测模型。最后, 目标检测模型对图中交通限速标志的位置进行检测, 并用蓝色矩形框标注, 输出检测结果到 `/root/target-detection-airflow/result/*.png`, 该流程结束。

图像晴雨雾天气识别功能模块的参数如表 6-4 所示。该功能模块是一个分支操作 (Branch Operator), 用于在工作流中根据条件执行不同的后续模块, 即根据识别得到的天气种类来选择不同的后续操作。该功能模块包含 1 个自定义参数 `img_path`, 表示输入的图像在服务器上存储的路径。该功能模块通过在服务器上执行 `python predict_weather.py {img_path}` 命令实现。该功能模块还包括一个返回值 `weather_result`, 将晴天、雨天和雾天分别用 0、1、2 表示, 以控制该功能模块与后续模块的协作关系。

表 6-4 图像晴雨雾天气识别功能模块参数

编号	名称	值
1	task_id	<code>predict_weather</code>
2	dag	<code>detection_workflow</code>
3	type	<code>BranchPythonOperator</code>
4	python_callable	<code>predict_weather.py</code>
5	op_kwargs	<code>{'img_path': '{{dag_run.conf["img_path"]}}'}</code>

图像去雨功能模块的参数如表 6-5 所示。该模块通过在服务器上执行 `python derain.py {img_path}` 命令实现。

表 6-5 图像去雨功能模块参数

编号	名称	值
1	task_id	derain
2	dag	detection_workflow
3	type	PythonOperator
4	python_callable	derain.py
5	op_kwargs	{'img_path': '{{dag_run.conf["img_path"]}}'}

图像去雾功能模块的参数如表 6-6 所示。该模块通过在服务器上执行 `python dehaze.py {img_path}` 命令实现。

表 6-6 图像去雾功能模块参数

编号	名称	值
1	task_id	dehaze
2	dag	detection_workflow
3	type	PythonOperator
4	python_callable	dehaze.py
5	op_kwargs	{'img_path': '{{dag_run.conf["img_path"]}}'}

交通限速标志目标检测功能模块的参数如表 6-7 所示。该模块通过在服务器上执行 `python dehaze.py {img_path} speed_limit_sign` 命令实现。

表 6-7 交通限速标志目标检测功能模块参数

编号	名称	值
1	task_id	detect_target
2	dag	detection_workflow
3	type	PythonOperator
4	python_callable	detect_target.py
5	op_kwargs	{'img_path': '{{dag_run.conf["img_path"]}}', 'target': '{{dag_run.conf["target"]}}'}

6.5. 流程模型运行

6.5.1. 运行状态

在 Airflow 的 Web Server 中查看工作流的实际运行状态。Web Server 主界面如图 6.4 所示，界面中的第一个 DAG 即为设计的晴雨雾天气场景交通限速标志流程模型。在左侧点击开关按钮，启动该流程模型，即可向平台输入命令以启动服务流程。




图 6.4 Airflow Web Server 主界面

流程模型通过在 Linux 终端输入命令进行实例化，命令为 `airflow dags trigger 'detection_workflow' --conf '{"img_path":"/root/target-detection-airflow/images/*.png", "target":"speed_limit_sign"}'`。流程模型设计完成后，分别对晴天、雨天和雾天 3 种天气的目标检测流程进行实验。将待检测的交通图像上传到 Linux 服务器，即可向平台输入交通图像，平台自动调用构建的图像晴雨雾天气识别模型、去雨或去雾图像增强模型以及交通限速标志目标检测 DQN 模型，对其执行对应操作。

模块被调用时，Airflow 首先将功能模块的状态变更为“scheduled”（计划），表示功能模块实例被创建并被计划执行。功能模块转为“queued”（入队）状态，意味着该功能模块已经被放入任务队列，等待有可用资源来执行。接着，功能模块在获取了必要的资源并开始执行时，状态变为“running”（运行）。如果功能模块执行完毕并且没有错误，它的状态会被更新为“success”（成功），开始根据设计的流程执行方案调用下一个模块。功能模块被调用和执行过程中的各状态如图 6.5 所示。




图 6.5 功能模块的各状态

6.5.2. 运行结果

向流程模型输入晴天图像，平台首先调用天气识别模型。由于识别结果为晴天，平台跳过去雨和去雾模型，将两者的状态变更为“skipped”（跳过），并直接调用目标检测模型，如图 6.6 所示。




图 6.6 晴天图像调度执行结果

向流程模型输入雨天图像，平台首先调用天气识别模型。由于识别结果为雨天，平台跳过去雾模型，依次调用去雨模型和目标检测模型，如图 6.7 所示。




图 6.7 雨天图像调度执行结果

向流程模型输入雾天图像，平台首先调用天气识别模型。由于识别结果为雾天，平台跳过去雨模型，依次调用去雾模型和目标检测模型，如图 6.8 所示。




图 6.8 雾天图像调度执行结果

6.5.3. 失败重试机制

如果流程模型没有失败重试机制，可能会导致每次有功能模块失败都需要人工介入进行重启，造成服务中断和延迟等问题，使用户体验变得低下。因此，设计的流程模型将功能模块执行失败后流程的重试机制纳入考虑。如图 6.9 所示，如果图像晴雨雾天气识别模块发生异常，此时该模块的状态会变为“up_for_retry”（待重试），流程模型会在 10 秒后重新执行模块。如果再次失败，状态会变为“failed”（失败），终止流程。




图 6.9 功能模块重试及失败状态

流程因执行失败而终止后，失败模块后续的各模块状态都会变更为“upstream_failed”（上游失败），如图 6.10 所示。




图 6.10 运行失败的流程

6.5.4. 实验结果

由上述分析可以得知,用户向设计的晴雨雾天气场景交通限速标志检测流程模型输入不同天气场景下的交通图像后,平台按照预设的流程模型定义,根据不同天气场景下图像增强和目标检测的流程逻辑,从起点到终点按照任务优先级顺序依次执行各功能模块。每个模块均通过平台调度并依次独立执行,实现各功能模块之间的解耦以及 workflow 调度平台与具体功能模块之间的解耦。

平台输出的晴雨雾天气条件下交通限速标志目标检测结果分别如图 6.11 所示。可以得知,目标检测模型较为准确地框定了不同天气条件下交通图像中交通限速标志目标的位置。



图 6.11 晴雨雾天气条件下的交通限速标志目标检测效果

6.6. 流程模型对新需求适应性

(1) 对增加天气种类的适应性

构建的流程模型中,图像晴雨雾天气识别功能模块是一个分支操作,用于在工作流中根据返回值来执行不同的功能模块,在该模块中即为根据天气识别模型得到的天气类别来选择不同的功能模块执行不同的后续操作。由于流程模型中的不同功能模块具有高内聚、低耦合性质,因此,如果用户需要增加天气种类,只需要收集若干对应天气种类的图像,训练 SE-ResNeXt101 模型,将服务器上的原有天气识别模型替换为新的模型,并对天气识别功能模块的返回值 `weather_result` 变量所对应的逻辑进行修改即可,现有

的其他代码以及 0、1、2 代表的晴雨雾天气对应的流程逻辑不需要发生改变，使得流程具有高可扩展性。例如，将雪天定义为 `weather_result=3`，执行图像去雪相关流程。变更后的流程模型在 Airflow 的 Web Server 中可视化如图 6.12 所示。




图 6.12 增加去雪模块的流程模型

（2）对增加交通标志目标类别的适应性

由于流程模型是基于参数构建的，相同的流程可以用不同的参数多次定义，使得构建的流程模型具有可扩展性。因此，如果用户需要增加流程模型可以检测的交通标志目标类别，只需要收集并标注若干对应类别的交通标志图像数据集，训练 DQN 模型，并将获得的 DQN 模型上传到服务器的指定路径即可。当需要调用该流程来检测新类别的交通标志时，执行命令 `airflow dags trigger 'detection_workflow' --conf '{"img_path":"/root/target-detection-airflow/images/*.png", "target":"目标类别"}'`，即可调用该流程模型来检测新类别的交通标志，流程模型和功能模块中的所有代码都不需要改变。

（3）对更新深度学习模型的适应性

由于构建的流程模型中的一个功能模块作用仅为定义一个接口，用于通过在服务器上执行 `python *.py {参数}` 命令来调用功能模块对应的 Python 文件，流程模型可以做到使具体功能模块与其他功能模块的逻辑解耦，实现了高内聚、低耦合的软件工程设计思想，具有高可扩展、可维护性。由于流程模型中的每个功能模块都与其他功能模块之间功能独立，与流程模型的逻辑独立，因此，当基于深度学习的图像天气识别、图像去雨、

图像去雾模块需要更新时,只需要对相应功能模块调用的*.py 文件进行变更即可,不需要修改流程模型以及其他功能模块的代码。例如,如果用户需要在未来将图像去雨模型更新为一个更为先进的模型,只需要训练该模型,将该模型上传到服务器的指定路径,并修改图像去雨功能模块(derain)的 python_callable 参数,改变该功能模块调用的 Python 文件名,而不需要修改流程模型和其他功能模块的代码逻辑,使得流程模型具有高可维护性。

6.7. 小结

构建晴雨雾天气场景交通限速标志检测流程模型。首先,将目标检测在晴雨雾天气条件下的特定需求解耦为 4 个具有单一职责的功能模块,并分析模块之间的依赖关系,构建 DAG 对其进行结构化表达。为了将各模块进行组合以实现复杂的整体服务,将图像晴雨雾天气分类模型、图像去雨雾增强模型、交通限速标志目标检测模型与 Airflow 调度工具部署在 Linux 服务器上,构建流程模型并对其进行测试。流程模型中的各模块具有高内聚、低耦合的特征,使流程模型具有高可修改性和高可扩展性,当用户需要修改流程中的部分模块或对功能进行扩展时,只需进行部分修改即可满足新的需求。构建的流程模型可以有效地实现预定的功能,根据功能模块之间的关系,自动化完成各功能模块的调度和执行。

总结与展望

总结

在雨天和雾天条件下，交通图像能见度较差，直接使用在晴天条件下训练的目标检测模型会导致精度大大降低。因此，研究晴雨雾天气下的交通限速标志检测方法，利用深度学习技术识别图像晴雨雾天气状况，针对雨天和雾天的特点构建交通图像去雨雾增强模型，并设计基于深度强化学习的交通限速标志目标检测模型，提高在不同天气场景下进行目标检测的适应性。设计晴雨雾天气交通限速标志检测流程模型，使服务具有高灵活性以满足用户在现实场景中多变天气条件下的实际需求。具体工作总结如下：

（1）提出了基于 SE-ResNeXt101 模型的交通图像晴雨雾天气识别方法。为解决交通图像天气条件具有多样性特征，需对多种天气条件特征的组合进行综合提取以识别图像天气的问题，构建基于通道注意力机制的 SE-ResNeXt101 模型，达到对交通图像晴雨雾天气状况进行分类的效果。经过评价，模型展现出较为准确的识别性能。

（2）提出了交通图像去雨雾增强方法。为解决雨天和雾天交通图像的能见度较低，造成交通限速标志检测易出现漏检或误检的问题，分析雨和雾对图像视觉效果造成负面影响的不同原因，针对雨天图像构建 Restormer 模型，针对雾天图像构建 FFA-Net 模型，并验证了 Restormer 模型在不同长度和密度的雨线、FFA-Net 模型在不同大气光强和散射系数的雾的场景下进行去雨或去雾的性能边界。测试结果显示模型可以有效地去除交通图像上的雨或雾，实现图像视觉质量的增强。

（3）提出了基于深度强化学习的交通限速标志检测方法。为解决现实场景中交通标志样式会进行更新，导致难以收集足够的新样式交通标志图像样本来训练深度学习目标检测模型的问题，以交通限速标志目标检测为例，构建基于 VGG16 模型的特征提取器，设计包括移动、缩放目标检测框和选中目标的动作空间，并通过改进的 ϵ -greedy 策略训练智能体，使其可以更准确地选择动作。构建了基于 LSTM 架构的 DQN，综合分析历史行为和实时感知数据，为模型提供全面的状态特征。测试不仅证实了在较小的图像数据集上训练的 DQN 模型可以在交通限速标志检测任务上展示出较高精度，而且证实了构建的图像增强模型能够有效提升雨天或雾天图像的质量，提高目标检测精度。

(4) 提出了晴雨雾天气场景交通限速标志检测流程模型。为实现流程的可修改与易扩展,分析交通目标检测在晴雨雾天气条件下的特定要求以及各功能模块之间的依赖,将构建的各模块进行功能解耦,设计有向无环图,将基于 Airflow 的工作流调度平台部署于 Linux 服务器,平台能够接收用户输入的交通图像,并据此对各模块进行调用和执行。晴雨雾天气场景交通限速标志检测服务的各功能模块之间具有低耦合特征,因此,当用户需要修改或扩展其中的部分功能时,只需要找到对应的接口进行部分调整,而不需要变更整个服务的代码逻辑,提升了服务的可维护性。实验结果验证了平台能够按预定的需求通过对各模块进行组合协作以自动执行晴雨雾天气场景下的交通限速标志目标检测服务流程。

展望

鉴于研究资源和能力的限制,研究工作存在一定的局限性,并留有进一步深化和扩展的余地。未来的研究可以在以下方向进行拓展:

(1) 对天气识别和图像增强的改进。由于篇幅有限,本实验仅限于对晴雨雾三种天气的交通图像进行天气识别,并增强雨天或雾天图像的视觉效果。未来可以增加天气的种类,也可以对雨和雾的级别进行细分,从而提升流程对复杂外界环境的适应性。

(2) 增加检测交通标志的类别。本实验仅限于对交通限速标志目标进行检测。未来可以增加现实场景中其他类别的交通标志,提升流程对现实场景的适应性。

(3) 对目标检测模型的进一步优化。本实验构建的基于深度强化学习的目标检测模型在小目标检测和多目标检测等问题上仍具有改进空间。在未来的研究中,可以对这种技术路线继续改进,改善目标检测效果。

参考文献

- [1] Hong C, Wang J. 自动驾驶开发平台市场份额, 2022[R]. IDC Corporate, 2023.
- [2] Zhang Z, Ma H, Fu H, et al. Scene-free Multi-class Weather Classification on Single Images[J]. Neurocomputing, 2016, 207: 365-373.
- [3] Lu C, Lin D, Jia J, et al. Two-class Weather Classification[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2014, 3718-3725.
- [4] Chen Z, Yang F, Lindner A, et al. How is the Weather: Automatic Inference from Images[C]. 2012 19th IEEE International Conference on Image Processing. IEEE, 2012, 1853-1856.
- [5] Kalkan M, Bostancı G, Güzelet M, et al. Cloudy/Clear Weather Classification Using Deep Learning Techniques with Cloud Images[J]. Computers and Electrical Engineering, 2022, 102: 108271.
- [6] Tan L, Xuan D, Xia J, et al. Weather Recognition based on 3C-CNN[J]. KSII Transactions on Internet and Information Systems, 2020, 14(8): 3567-3582.
- [7] Xiao H, Zhang F, Shen Z, et al. Classification of Weather Phenomenon from Images by Using Deep Convolutional Neural Network[J]. Earth and Space Science, 2021, 8(5): e2020EA001604.
- [8] Xie K, Wei Z, Huang L, et al. Graph Convolutional Networks with Attention for Multi-label Weather Recognition[J]. Neural Computing and Applications, 2021, 33: 11107-11123.
- [9] Zhao B, Li X, Lu X, et al. A CNN - RNN Architecture for Multi-label Weather Recognition[J]. Neurocomputing, 2018, 322: 47-57.
- [10] Kim J, Sim J, Kim C. Video Deraining and Desnowing using Temporal Correlation and Low-rank Matrix Completion[J]. IEEE Transactions on Image Processing, 2015, 24(9): 2658-2670.
- [11] 刘亚楠, 曹风云, 王璐. 基于双阈值引导滤波的单幅图像去雨算法[J]. 甘肃联合大学学报(自然科学版), 2022(003): 036.

- [12]Chang H, Yi P, Xu J, et al. One for All: Adapting One Efficient Model for the Rain Removal Task of Both Homogeneous and Heterogeneous Images[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2017, 875-883.
- [13]Zamir S, Arora A, Khan S, et al. Restormer: Efficient Transformer for High-resolution Image Restoration[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022, 5728-5739.
- [14]He K, Sun J, Tang X. Single Image Haze Removal Using Dark Channel Prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2010, 33(12): 2341-2353.
- [15]Zhu Q, Mai J, Shao L. A Fast Single Image Haze Removal Algorithm Using Color Attenuation Prior[J]. IEEE Transactions on Image Processing, 2015, 24(11): 3522-3533.
- [16]Fan D, Liu X, Gao Z, et al. Scale-adaptive and Color-corrected Retinex Defogging Algorithm[C]. International Conference on Electronic Information Technology and Computer Engineering. IEEE, 2019, 1080-1084.
- [17]Qin X, Wang Z, Bai Y, et al. FFA-Net: Feature Fusion Attention Network for Single Image Dehazing[C]. Proceedings of the AAAI Conference on Artificial Intelligence. 2020, 34(07): 11908-11915.
- [18]Benallal M, Meunier J. Real-time Color Segmentation of Road Signs[C]. CCECE 2003-Canadian Conference on Electrical and Computer Engineering. IEEE, 2003, 3: 1823-1826.
- [19]García-Garrido M, Sotelo M, Martín-Gorostiza E. Fast Road Sign Detection Using Hough Transform for Assisted Driving of Road Vehicles[C]. International Conference on Computer Aided Systems Theory. Springer Berlin Heidelberg, 2005: 543-548.
- [20]Piccioli G, De Micheli E, Parodi P, et al. Robust Method for Road Sign Detection and Recognition[J]. Image and Vision Computing, 1996, 14(3): 209-223.
- [21]常发亮, 黄翠, 刘成云等. 基于高斯颜色模型和 SVM 的交通标志检测[J]. 仪器仪表学报, 2014, 35(1):7.

- [22]Chen T, Lu S. Accurate and Efficient Traffic Sign Detection Using Discriminative AdaBoost and Support Vector Regression[J]. IEEE Transactions on Vehicular Technology, 2015, 65(6): 4006-4015.
- [23]曹继承. 基于机器学习的交通标志检测与分类方法研究[D]. 电子科技大学, 2018.
- [24]Ghasemi Y, Jeong H, Choi S, et al. Deep Learning-based Object Detection in Augmented Reality: A Systematic Review[J]. Computers in Industry, 2022, 139: 103661.
- [25]Girshick R, Donahue J, Darrell T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2014, 580-587.
- [26]Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2016, 779-788.
- [27]Zhang J, Xie Z, Sun J, et al. A Cascaded R-CNN With Multiscale Attention and Imbalanced Samples for Traffic Sign Detection[J]. IEEE Access, 2020, 8: 29742-29754.
- [28]Yu J, Ye X, Tu Q. Traffic Sign Detection and Recognition in Multiimages Using a Fusion Model With YOLO and VGG Network[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(9): 16632-16642.
- [29]Caicedo J, Lazebnik S. Active Object Localization with Deep Reinforcement Learning[C]. Proceedings of the IEEE International Conference on Computer Vision. IEEE, 2015, 2488-2496.
- [30]吴志鹏, 董超俊. 基于深度强化学习的道路目标检测[J]. 现代计算机, 2020, 2020(17): 25-28.
- [31]Minaee S, Kalchbrenner N, Cambria E, et al. Deep Learning-based Text Classification: a Comprehensive Review[J]. ACM Computing Surveys, 2021, 54(3): 1-40.
- [32]Lathuilière S, Mesejo P, Alameda-Pineda X, et al. A Comprehensive Analysis of Deep Regression[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 42(9): 2065-2081.

- [33]Karim M, Beyan O, Zappa A, et al. Deep Learning-based Clustering Approaches for Bioinformatics[J]. Briefings in Bioinformatics, 2021, 22(1): 393-415.
- [34]Sarraf A, Azhdari M, Sarraf S. A Comprehensive Review of Deep Learning Architectures for Computer Vision Applications[J]. American Scientific Research Journal for Engineering, Technology and Sciences, 2021, 77(1): 1-29.
- [35]姜羽菲, 石宇, 何若男, 等. 基于卷积神经网络特征提取的病理语音识别[J]. 电子设计工程, 2023, 1-5.
- [36]韩向阳. 基于卷积神经网络的中文语音识别人机交互系统设计[J]. 自动化与仪器仪表, 2023, (07): 201-204+209.
- [37]刘影, 余进, 陈莉. 基于改进卷积神经网络的多标签文本自动化分类研究[J]. 自动化与仪器仪表, 2023, (11): 62-66.
- [38]Hochreiter S, Schmidhuber J. Long Short-term Memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [39]Lindemann B, Müller T, Vietz H, et al. A Survey on Long Short-Term Memory Networks for Time Series Prediction[J]. Procedia CIRP, 2021, 99: 650-655.
- [40]Hu J, Shen L, Sun G. Squeeze-and-excitation Networks[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018, 7132-7141.
- [41]He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016, 770-778.
- [42]Xie S, Girshick R, Dollár P, et al. Aggregated Residual Transformations for Deep Neural Networks[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017, 1492-1500.
- [43]Ioffe S, Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[C]. Proceedings of the 32nd International Conference on Machine Learning, 2015, 37: 448-456.
- [44]Vaswani A, Shazeer N, Parmar N, et al. Attention is All You Need[C]. Advances in Neural Information Processing Systems, 2017, 5998-6008.

- [45] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level Control through Deep Reinforcement Learning[J]. Nature, 2015, 518(7540): 529-533.
- [46] Haydari A, Yılmaz Y. Deep reinforcement learning for intelligent transportation systems: A survey[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 23(1): 11-32.
- [47] Apache Software Foundation. Airflow[CP/OL]. <https://airflow.apache.org>, 2016.
- [48] Wjybuqi. Weather-Time Classification with Road Images[DB/OL]. Kaggle. <https://www.kaggle.com/datasets/wjybuqi/weathertime-classification-with-road-images>, 2022.
- [49] Pratik2901. Multi-class Weather Dataset[DB/OL]. Kaggle. <https://www.kaggle.com/datasets/pratik2901/multiclass-weather-dataset>, 2020.
- [50] 杨鹤, 马洪波, 孙韦男等. 基于 XGBoost 算法的吉林省强对流天气分类识别研究[J]. 气象灾害防御, 2023, 30(02): 28-33.
- [51] Russakovsky O, Deng J, Su H, et al. ImageNet Large Scale Visual Recognition Challenge[J]. International Journal of Computer Vision, 2015, 115(3): 211-252.
- [52] Kingma D, Ba J. Adam: A Method for Stochastic Optimization [EB/OL]. arXiv preprint, 2014, arXiv:1412.6980.
- [53] Liu Z, Mao H, Wu C, et al. A convnet for the 2020s[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022, 11976-11986.
- [54] Andrewmvd. Road Sign Detection[DB/OL]. Kaggle. <https://www.kaggle.com/datasets/andrewmvd/road-sign-detection>, 2020.
- [55] Zamir S, Arora A, Khan S, et al. Supplementary Material—Restormer: Efficient Transformer for High-Resolution Image Restoration[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022.
- [56] Fu X, Huang J, Zeng D, et al. Removing Rain from Single Images via a Deep Detail Network[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017, 3855-3863.
- [57] Li B, Ren W, Fu D, et al. Benchmarking Single-Image Dehazing and Beyond[J]. IEEE Transactions on Image Processing, 2018, 28.1: 492-505.

- [58]Simonyan K, Zisserman A. Very Deep Convolutional Networks for Large-Scale Image Recognition[EB/OL]. arXiv preprint, 2014, arXiv:1409.1556.
- [59]柳箐汶. 基于深度强化学习的目标检测技术研究是实现[D]. 电子科技大学, 2023.
- [60]Hausknecht M, Stone P. Deep Recurrent Q-Learning for Partially Observable MDPs[C]. 2015 AAAI Fall Symposium Series, 2015.
- [61]Fengyuan-coder. DRL_object_observation[CP/OL]. https://github.com/fengyuan-coder/DRL_object_observation/tree/master, GitHub, 2022.
- [62]Bochkovskiy A, Wang C, Liao H. YOLOv4: Optimal Speed and Accuracy of Object Detection[EB/OL]. arXiv preprint, 2020, arXiv:2004.10934.