

学校代码: 10286

分类号: U491

密 级: 公开

U D C: 656

学 号: 223160



东南大学

交通运输硕士学位

车联网条件下高速公路施工区换道行为 与决策方法研究

(学位论文形式: 应用研究)

研究生姓名: 马宇恒

导师姓名: 过秀成 教授

李科 正高级工程师

申请学位类别 交通运输 学位授予单位 东南大学

领域名称 交通运输 论文答辩日期 2025 年 5 月 12 日

研究方向 交通运输规划与管理 学位授予日期 2025 年 月 日

答辩委员会主席 任刚 教授 评 阅 人 盲审

2025 年 5 月 12 日

東南大學
交通运输硕士学位论文

车联网条件下高速公路施工区换道行为
与决策方法研究

专业名称: 交通运输

研究生姓名: 马宇恒

导师姓名: 过秀成 教授

李科 正高级工程师

RESEARCH ON LANE-CHANGING BEHAVIOR AND DECISION-MAKING METHODS IN HIGHWAY WORK ZONES WITH V2X

A Thesis Submitted to

Southeast University

For the Professional Degree of Master of

Transportation Engineering

BY

MA Yuheng

Supervised by

Prof. GUO Xiucheng

&

Senior Engineer LI Ke

School of Transportation

Southeast University

May 2025

摘要

随着我国智能交通与基础设施数字化建设的不断推进，车联网作为提升高速公路运行效率的关键支撑技术之一，正加速在实际道路环境中的部署与应用，道路交通流也开始向人工驾驶车辆与自动驾驶车辆混行的异质交通流转变。在此过程中，伴随着道路基础设施的改造和升级，高速公路施工区成为制约路段通行效率的主要瓶颈之一。施工区复杂的交通条件对自动驾驶车辆的智能决策与路径规划能力提出更高要求，开展车联网环境下面向自动驾驶的施工区换道行为建模与智能决策方法研究，有助于提升智能驾驶系统在复杂交通环境中的行为理解与决策能力，对于保障施工区通行安全、提高局部道路运行效率具有重要的理论价值与工程意义。

本文聚焦于高速公路施工区车辆换道行为建模与换道决策优化这一研究主题，提出了融合行为识别、意图预测与分层强化学习决策的车联网感知增强型换道建模框架。整体研究路径可分为三大阶段：基于无人机轨迹数据的驾驶行为建模、面向多施工场景的换道意图预测、以及融合行为先验的分层强化学习换道决策。

在数据构建与行为建模方面，依托无人机采集的高速公路施工区航拍视频，完成车辆检测、跟踪与坐标转换，构建高精度、连续性的多车轨迹数据集。结合施工区域空间特征与交通运行状态，对不同类型施工场景下的流量分布、平均速度、瓶颈特征与车头时距等关键指标进行系统分析。针对换道行为的时序演化特征，本文引入贝叶斯凝合分割算法，实现对换道轨迹的无监督分段。在此基础上，采用混合潜在狄利克雷分配模型进行行为基元提取，识别出五类典型换道阶段，提升了换道行为的结构化表达能力。进一步通过 K-Means 聚类方法，基于五阶段特征矩阵识别出三种驾驶风格：激进型、稳健型与保守型，为换道决策建模提供驾驶者个性标签与先验行为特征。

在换道意图预测阶段，针对施工区场景多变性与行为异质性问题，构建基于并联结构的 LSTM-Transformer 混合模型，分别提取短期时序动态与长期依赖模式，实现对换道意图的预测。模型通过针对不同场景的子模型的构建，针对不同场景进行场景特化建模，并设计动态权重融合机制，动态调节子模型贡献度，实现跨场景条件下的自适应预测输出。实验证明，该模型在换道行为预测任务中准确率达 90.1%，优于传统单模型在不同场景下的性能表现。

在换道策略生成阶段，本文构建融合先验信息的分层强化学习模型。模型架构包括行为选择层与动作执行层两级结构，上层使用 Dueling DQN 方法决策当前状态下的换道策略，下层使用 Policy Gradient 策略网络生成具体的加速度控制动作，实现速度连续控制与轨迹平稳调整。状态空间中不仅包含自车速度、加速度、前后邻车距离、车道编号、施工区域特征等物理量，还引入换道预测概率作为先验引导，增强智能体的决策敏感性。奖励函数设计围绕三大核心目标：安全性、效率性与舒适性，引导模型

在训练中学习更加合理、平稳、高效的换道策略。

为评估模型效果，本文在 SUMO 仿真平台搭建封闭左侧两车道的高速公路施工场景，设置不同的交通流量开展多组仿真实验，并与 DQN、DDQN、Dueling DQN 等传统强化学习算法进行对比。在训练阶段，本文对策略层与控制层分别进行网格搜索优化，最终确定学习率、折扣因子、探索因子等超参数组合。在实验结果方面，HRL 模型在训练收敛速度、损失下降幅度、最终累计奖励方面均优于其他方法，展现出更高的训练效率与学习稳定性。在仿真结果方面，HRL 在高流量场景下平均速度提升 13.3%、瓶颈通行能力提升 0.6%，显示出较优越的通行效率与拥堵缓解能力。

本文提出的高速公路换道决策方法实现了从换道意图识别到换道策略生成的闭环，具备良好的行为理解能力、跨场景适应能力与仿真可验证性。研究不仅在理论上丰富了复杂交通场景下驾驶行为建模与智能决策方法体系，也为车联网环境下自动驾驶系统在施工区的落地应用提供了可行路径。

关键词： 高速公路施工区；车联网；换道行为；换道决策；强化学习

ABSTRACT

With the continuous advancement of intelligent transportation and infrastructure digitalization in China, Telematics, as one of the key supporting technologies to enhance the operational efficiency of highways and the decision-making level of automated driving, is accelerating the deployment and application in the actual road environment, and the road traffic flow has begun to shift to the heterogeneous traffic flow where the manually-driven vehicles are mixed with the automated driving vehicles. In this process, along with the renovation and upgrading of road infrastructure, highway construction zones have become one of the main bottlenecks restricting the passage efficiency of road sections. The complex traffic conditions in the construction zone put forward higher requirements on the intelligent decision-making and path planning ability of self-driving vehicles, and the research on the construction zone lane-changing behavior modeling and intelligent decision-making method for self-driving vehicles oriented to automated driving in the vehicle networking environment helps to improve the behavioral understanding and decision-making ability of intelligent driving systems in complex traffic environments, which is of important theoretical value and engineering significance for guaranteeing the safety of passage in the construction zone and improving the operational efficiency of the local roads. It has important theoretical value and engineering significance for ensuring the traffic safety in the construction area and improving the operation efficiency of local roads.

This paper focuses on the research theme of vehicle lane changing behavior modeling and lane changing decision optimization in highway construction zones, and proposes an enhanced lane changing modeling framework for Telematics sensing that integrates behavior recognition, intention prediction, and hierarchical reinforcement learning decision making. The overall research path can be divided into three major phases: driving behavior modeling based on UAV trajectory data, lane-changing intention prediction for multi-construction scenarios, and hierarchical reinforcement learning lane-changing decision-making with fusion of behavioral a priori.

In terms of data construction and behavior modeling, relying on the aerial video of highway construction area collected by UAV, vehicle detection, tracking and coordinate conversion are completed to construct a high-precision and continuous multi-vehicle trajectory data set. Combined with the spatial characteristics of the construction area and the traffic operation state, key indicators such as flow distribution, average speed, bottleneck characteristics and headway are systematically analyzed under different types of construction scenarios. Aiming at the time-series evolution characteristics of lane-changing behavior, this paper introduces the Bayesian condensation segmentation algorithm to realize the unsupervised segmentation of lane-changing trajectories. On this basis, the behavioral primitives are extracted by adopting the hybrid potential Dirichlet allocation model, and five types of typical lane-changing phases are identified, which improves the structured representation of lane-changing behavior. Further, through the K-Means clustering method, three driving styles are identified based on the five-stage feature matrix: aggressive, robust and conservative, which provide driver personality labels and a priori behavioral characteristics for lane change decision modeling.

In the stage of lane change intention prediction, to address the problem of scene variability and behavioral heterogeneity in construction zones, a hybrid LSTM-Transformer model based on parallel structure is constructed to extract the short-term time-series dynamics and long-term dependency patterns respectively to realize the prediction of lane change intention. The model achieves adaptive prediction output under cross-scene conditions by constructing sub-models for different scenarios, modeling scene specialization for different scenarios, and designing a dynamic weight fusion mechanism to dynamically adjust the sub-model contribution. Experiments demonstrate that the model achieves an accuracy of 90.1% in the lane-changing behavior prediction task, which outperforms the performance of the traditional single model in different scenarios.

In the lane-changing strategy generation phase, this paper constructs a hierarchical reinforcement learning model that incorporates a priori information. The model architecture includes a two-level structure of behavior selection layer and action execution layer, the upper layer uses the Dueling DQN method to decide the lane changing strategy in the current state, and the lower layer uses the Policy Gradient strategy network to generate specific acceleration control actions, realizing continuous speed control and smooth trajectory adjustment. The state space not only contains physical quantities such as self-vehicle speed, acceleration, distance between front and rear neighboring vehicles, lane number, and construction area characteristics, but also introduces the lane change prediction probability as an a priori guide to enhance the decision-making sensitivity of the intelligent body. The reward function is designed around three core objectives: safety (collision penalties, distance constraints), efficiency (passage speed, time cost) and comfort (speed change smoothness, lane change frequency control), which are weighted and fused to form a total reward objective, guiding the model to learn a more reasonable, smooth, and efficient lane change strategy during training.

In order to evaluate the model effect, this paper builds a closed left two-lane highway construction scenario in SUMO simulation platform, sets different traffic flows to carry out multiple simulation experiments, and compares it with traditional reinforcement learning algorithms, such as DQN, DDQN, and Dueling DQN. In the training phase, this paper optimizes the grid search for the strategy layer and the control layer respectively, and finally determines the combination of hyperparameters such as learning rate, discount factor and exploration factor. In terms of experimental results, the HRL model outperforms other methods in terms of training convergence speed, loss decline, and final cumulative reward, showing higher training efficiency and learning stability. In terms of simulation results, HRL improves the average speed by 13.3% and bottleneck capacity by 0.6% in high traffic scenarios, showing superior access efficiency and congestion relief.

The highway lane changing decision-making method proposed in this paper realizes the closed loop from lane changing intention recognition to lane changing strategy generation, and has good behavioral understanding, cross-scene adaptability and simulation verifiability. The research not only theoretically enriches the system of driving behavior modeling and intelligent decision-making methods in complex traffic scenarios, but also provides a feasible path for the application of automatic driving systems in construction zones under the environment of Telematics.

Keywords: Highway work zone; V2X; lane-changing behavior; lane-changing decision-making; reinforcement learning

目 录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 高速公路施工区交通流特性.....	2
1.2.2 驾驶员换道行为特性.....	4
1.2.3 高速公路施工区驾驶行为与控制方法	5
1.2.4 车联网条件下的换道决策模型.....	7
1.2.5 研究现状总结.....	10
1.3 研究内容.....	10
1.4 技术路线.....	12
第二章 高速公路施工区交通流运行特征分析	15
2.1 研究范围.....	15
2.1.1 高速公路施工区范围界定.....	15
2.1.2 高速公路施工区布置形式.....	17
2.1.3 面向车辆换道决策的车联网环境界定	18
2.2 数据采集与提取.....	20
2.2.1 无人机视频采集与预处理.....	20
2.2.2 轨迹提取与坐标转化.....	22
2.2.3 换道轨迹提取.....	24
2.3 施工区交通运行特征分析	26
2.3.1 交通量特性.....	26
2.3.2 速度特性.....	28
2.3.3 车头时距特性.....	31
2.4 车联网条件下的施工区交通流运行特征分析	34
2.5 本章小节.....	36
第三章 高速公路施工区车辆换道行为特性分析	37
3.1 基于驾驶基元的施工区车辆换道行为特征分析方法	37
3.2 驾驶人换道行为基元提取模型	38
3.2.1 基于贝叶斯方法的换道行为轨迹序列分割	39
3.2.2 基于无监督学习的车辆换道行为基元提取	40
3.2.3 换道行为基元提取模型评价.....	44
3.2.4 换道行为基元物理意义分析.....	45
3.3 驾驶人换道风格聚类模型构建	47
3.4 本章小结.....	49

第四章 多场景识别与融合的高速公路施工区换道预测模型	51
4.1 模型总体架构.....	51
4.2 双层 LSTM-Transformer 换道预测模型	53
4.2.1 双层 LSTM-Transformer 模型.....	53
4.2.2 场景识别驱动的子模型加权融合策略	58
4.2.3 模型训练与优化.....	60
4.3 实验设计与实验结果分析	61
4.3.1 实验方案设计.....	61
4.3.2 数据预处理.....	62
4.3.3 模型性能指标评估.....	66
4.3.4 实验结果分析.....	68
4.4 本章小节.....	70
第五章 车联网环境下的高速公路施工区换道决策模型	73
5.1 基于分层强化学习的换道决策模型构建	73
5.1.1 模型架构.....	73
5.1.2 行为选择模块.....	74
5.1.3 动作执行模块.....	76
5.1.4 状态与动作空间定义.....	78
5.2 奖励函数与优化目标设计	83
5.2.1 安全性奖励.....	83
5.2.2 效率性奖励.....	85
5.2.3 舒适性奖励.....	86
5.3 模型训练与优化.....	87
5.3.1 训练环境搭建.....	87
5.3.2 训练过程.....	90
5.3.3 超参数设置与调整.....	93
5.4 仿真实验与结果分析.....	96
5.4.1 实验设计.....	96
5.4.2 实验结果及结果分析.....	97
5.5 本章小结.....	100
第六章 结果与展望	101
6.1 主要研究结论.....	101
6.2 论文创新点.....	102
6.3 研究展望.....	102
参考文献.....	104

第一章 绪论

1.1 研究背景与意义

随着车联网技术的不断发展，交通数字化与智能化成为发展的核心趋势。我国在《交通强国建设纲要》以及《国家综合立体交通网规划纲要》中，明确提出要推进交通基础设施数字化、网联化，加快提升交通运输智能化水平，以实现交通高质量发展^[1,2]。这一系列政策的出台，为车联网技术在交通领域的应用提供了坚实的政策支持与发展导向。

高速公路作为现代交通体系的主动脉，在国家经济发展与社会运行中占据着无可替代的重要地位。不仅为人员的跨区域流动提供了极大便利，促进了各地文化的交流与融合，更在推动物资流通、拉动产业协同发展方面发挥着关键作用^[3]。然而，随着高速公路长期高负荷运转，其设施老化、通行能力不足等问题逐渐凸显。为保障高速公路始终保持良好的运行状态，满足日益增长的交通需求，维护与升级工程的实施变得愈发频繁。在此过程中，高速公路施工区这一特殊路段应运而生，其独特的运行特性对整个交通网络的顺畅运行带来了全新挑战，亟待深入研究与有效应对。

高速公路施工区相较基本路段具有显著的特殊性，车道数量的减少和车流组织形式的变化对车辆行驶路径产生限制，进而影响交通流的运行。车辆频繁的换道、合流、交织造成了交通流速度不稳定的现象，进而在流量较大时出现严重的拥堵与安全隐患，导致通行能力的陡降与事故的发生^[4]。目前的施工区多采用静态标志与标线相结合的形式对车辆进行管控，来引导施工区车辆进行合流^[5]。当前研究表明，标志标线的布设位置可以一定程度上减少施工区的危险变道行为，但仅依赖驾驶员自身的感知与判断的管控方式对作业区的交通流稳定和通行效率的优化有限^[6]，需要更加精细的交通管理与控制来提高调控效果。

随着当前交通领域迈向智能化、高效化，《国家综合立体交通网规划纲要》将推进交通智慧发展作为交通高质量发展的重要部分，着重强调提升既有道路交通设施的数字化、网联化^[2]。当前通信、传感器、人工智能等前沿技术迅猛发展并与交通管控进行深度融合，车联网（V2X）逐渐从概念设想迈向广泛应用。车联网依托车与车、路、人及云等多端智能信息的交互共享，具备对复杂交通环境的精准感知、智能决策及协同控制能力，这对提升道路安全性与通行能力起到了关键作用^[7]。车联网技术与网联汽车的应用也在优化交通流、提升道路通行能力、降低交通事故发生率等方面具有显著优势，为解决高速公路施工区的交通难题提供了新的契机与技术手段。

相较于基本路段，施工区的换道行为更加频繁，合理的换道行为是优化交通流的

关键因素之一^[8]。车联网技术的普及为换道控制提供了更多的选择，基于深度学习、强化学习等的换道决策模型与换道控制方法为施工区车辆的换道行为优化与引导提供了新的方案^[9]。通过车辆与道路、车辆与车辆之间的信息交互，可以减少车辆在施工区的无序换道与频繁加减速，进而改善交通流的稳定性，提高道路的通行能力，减少车辆在施工区的延误时间。

本文在现有高速公路换道控制方法的基础上进行了系统拓展，充分考虑了驾驶风格差异与施工区组织形式对换道行为的影响特征。基于无人机采集的施工区实景轨迹数据，开展驾驶行为基元提取与风格识别，挖掘施工区环境下驾驶员的微观换道特征。在此基础上，构建融合 LSTM 与 Transformer 的多场景换道预测模型，提升换道意图识别的准确性与环境适应性。进一步将预测结果作为先验信息引入至强化学习状态空间，结合 Dueling DQN 与 Policy Gradient 算法，构建分层强化学习决策架构，优化自动驾驶车辆在施工区内的换道策略。通过 SUMO 平台构建典型施工场景，开展多流量仿真实验验证所提方法的有效性，结果表明本研究在提升行驶安全性与通行效率方面具有良好表现。研究成果为施工区交通行为建模与智能换道决策提供了可行的数据驱动路径，也为面向车联网环境的自动驾驶决策系统设计提供了有益参考。

1.2 国内外研究现状

1.2.1 高速公路施工区交通流特性

高速公路施工区受到道路封闭、车道缩减、限速等因素的影响，其交通流特性与正常路段存在显著差异。由于施工区域特殊的几何设计、驾驶员不同行为及交通管理措施的存在，施工区的交通运行具有较高的通行延误和事故风险。因此，对施工区交通流特性的研究有助于提高交通管理的科学性，并为施工区的优化设计提供数据支持。

根据目前国内外的现有研究，施工区交通流特性可从宏观交通流特性和微观交通流特征两个层面进行分析。前者关注整体交通流状态和通行能力，后者关注个体车辆的行驶行为、车头时距、速度分布等特征。

1. 宏观交通流特性研究

宏观交通流特性主要涉及交通流参数分析、通行能力评估以及施工区交通流模型的建立。王强和邓建华提出，不同驾驶风格的车辆在自由换道时呈现不同的博弈策略，对施工区内交通流组织和车道利用率产生直接影响^[10]。何小洲等（2005）研究了施工区不同控制段（警告区、过渡区、作业区）的交通流参数变化，发现过渡区通常是交通运行的瓶颈，其速度-流量关系与正常路段存在显著差异^[4]。在国外研究方面，Xu 等（2021）基于自然驾驶数据分析了施工区的车头时距和车速分布，发现施工区的车头时距较正常路段更短，表明驾驶员在施工区会采取更为谨慎的跟车策略^[11]。Racha 等

(2008) 则研究了施工区的交通行为特征, 并提出基于施工环境优化的交通组织方案^[12]。

施工区的通行能力评估方面, 相关研究多通过实地调查数据进行建模, 并利用仿真模拟或模拟驾驶来实现控制方法, 进而针对其对施工区交通流的影响来证明控制方法的效果。张韩(2024)等研究了车道缩减路段的自动车辆协同换道控制, 提出了一种基于优化控制的协同换道策略, 以提高施工区通行能力, 并使用 SUMO/Traci 与 Python 的联合仿真来进行交通流震荡波的特性分析^[13]。李耘(2014)使用实地调查法进行数据的收集, 并分析了不同施工场景下的通行能力, 发现车流密度超过 30 辆/公里时, 交通流状态发生突变, 施工区通行能力显著降低^[14]。Weng 等(2014)基于实际观测数据研究了施工区车辆的车头间距分布, 并提出施工区通行能力计算模型, 为施工区的交通管理提供了参考依据^[15]。

随着大数据技术的发展, 基于数据驱动的方法在施工区交通流建模中得到了广泛应用。朱慧芳(2011)提出了一种施工区交通组织优化仿真模型, 通过仿真实验验证了不同交通管理措施对施工区通行效率的影响^[16]。此外, Genders 和 Razavi(2016)利用网联车辆数据, 研究了动态路径引导对施工区交通流的影响, 并提出基于网联技术的施工区交通优化方案^[17]。

2. 微观交通流特征研究

微观交通流特征主要关注驾驶员的个体行为对施工区整体交通流的影响, 包括车头时距分布、车速变化规律以及换道行为分析等。李耘(2014)的研究发现, 高速公路施工区的车头时距与正常高速公路基本路段相比更短, 特别是在过渡区, 车辆间的最小车头间距大幅减少, 增加了追尾事故的风险^[14]。杨正艳(2024)进一步研究了高速公路多车场景下的智能车辆换道决策, 并结合轨迹规划技术优化了施工区车辆的行驶路径^[18]。Xu 等(2021)利用自然驾驶数据分析了施工区的车速分布, 发现施工区的平均行驶速度较正常路段降低了15%-30%, 而速度标准差则显著增加, 表明驾驶员在施工区的驾驶行为更加不稳定^[11]。

换道行为是施工区内影响交通流稳定性的重要因素。马瑞兰(2024)研究了多车协同换道决策控制策略, 提出了基于博弈论和强化学习的方法, 以优化施工区换道行为^[19]。方华珍等(2024)提出了一种基于换道意图和强化学习的车辆匝道汇入决策模型, 该方法通过深度强化学习算法提升了智能车辆的换道安全性^[20]。姜文鑫等(2023)研究了基于强化学习的自动驾驶换道决策方法, 通过强化学习框架训练智能体, 使其在施工区环境下能够优化换道策略, 减少不必要的换道冲突^[21]。

施工区的交通冲突状况直接影响了行车的安全性。冯超铭(2004)研究了施工区的安全管理, 提出了基于交通冲突的风险评估方法, 发现施工区的主要事故类型为追尾和侧向碰撞^[22]。吴彪等(2013)提出了一种考虑驾驶员认知过程的高速公路施工区

MVMS（可变信息标志）前置距离计算模型，以优化施工区的交通管理措施^[23]。

综上所述，施工区交通流特性研究涉及宏观交通流参数分析、通行能力评估、微观换道行为分析等多个方面。宏观层面主要关注施工区整体交通流状态，微观层面则聚焦个体车辆的行驶行为。随着人工智能、强化学习和车联网技术的发展，未来的研究将更加侧重于施工区的动态交通管理与智能优化控制，以提升施工区的通行效率和安全性。

1.2.2 驾驶员换道行为特性

换道行为是高速公路及城市快速路中最常见的驾驶行为之一，影响着交通流的稳定性和安全性。研究表明，换道行为受到驾驶员个体特性、交通流状态、周围车辆行为及道路环境等多种因素的影响^[24]。近年来，随着车联网技术和自动驾驶的发展，学者们对换道行为的研究从传统的规则建模逐步转向数据驱动的方法，如深度学习、强化学习及博弈论建模等^[25]。论文从换道行为的基本分类与触发因素、换道行为的微观特性、驾驶员个体差异的影响几个方面，对驾驶员换道行为的研究进展进行综述。

驾驶员的换道行为通常可分为以下三类：自由换道、强制换道与协同换道。自由换道指驾驶员为提高行驶速度或获得更优行驶位置而主动进行的换道。强制换道是因车道终止、障碍物、驶出匝道等因素而被迫进行的换道。协同换道则是在车联网环境下，驾驶员或自动驾驶车辆通过通信协作完成的换道。张磊等分析了不同类型换道的时空特性，发现强制换道在换道持续时间、加速度变化上明显不同于自由换道，而高速公路施工区过渡段的换道行为是典型的强制换道行为^[26]。

国内外现有研究中将换道行为的触发因素分为驾驶员因素、交通环境因素和道路几何因素三类。侯海晶（2018）在其研究中指出驾驶风格、驾驶经验、风险偏好等会直接影响换道决策^[27]。李阳钊（2024）在其研究中强调了车流密度、周围车辆速度差、可用车道数量等交通环境因素对换道行为的影响^[28]。王畅（2015）建立了基于速度估计的换道触发模型，优化了换道时机选择^[29]。Weng（2014）的研究表明了车道宽度、匝道设计、施工区布设方式等道路几何因素对换道行为有重要的影响^[15]。

针对换道行为的微观特性的相关研究多聚焦于车头时距与速度特性和换道轨迹特性。车头时距是衡量换道前后车辆间安全距离的关键指标，自由换道的车头时距较短，驾驶员主要依靠速度匹配进行换道，强制换道通常需要更大的间隙，受后方车辆反应影响更大。而换道过程中速度变化主要体现在换道的不同阶段的速度调整，换道前驾驶员会提前加速或减速以寻找合适的换道机会；换道过程中受周围车辆影响，驾驶员可能出现急加速或急减速^[30]。Weng（2014）研究了施工区换道的速度变化，发现限速控制可以显著改善换道安全性^[15]。换道轨迹特性包括换道持续时间、横向位移特性、

纵向加速度变化等。李阳钊（2024）基于自然驾驶轨迹数据分析了小型车辆换道轨迹，并对不同流量下的换道轨迹特性进行比对分析^[28]。

驾驶员的个体差异与驾驶风格同样会对换道行为产生影响，激进型驾驶员的换道频繁，换道间隙较短，加速度变化大，风险较高；而谨慎型驾驶员的换道间隔较长，换道动作较缓慢，安全性较高。侯海晶等（2018）研究了驾驶风格对换道行为的影响，发现激进型驾驶员的换道风险显著增加^[27]。此外，驾驶员的认知因素也会影响换道时机的选择，经验丰富的驾驶员往往能够更加精准地判断换道时机，不同风险偏好的驾驶员也会采用不同的换道策略。车松珊等（2023）基于有限理性博弈模型，研究了驾驶员认知偏差对换道行为的影响^[31]。

随着车联网技术的发展，车辆轨迹数据蕴含的驾驶行为重新受到关注，驾驶意图的识别与分类相关的研究逐渐增加。朱凯家（2021）使用改进的权熵 FCM 聚类算法对客车驾驶员的驾驶行为进行了分类分析，但应用场景主要集中与车速预测，复杂度与可推广性较低^[32]。侯海晶等人将车辆的换道行为划分为意图阶段和执行阶段，并基于混合高斯隐马尔可夫模型和支持向量机构建了驾驶人换道意图识别模型。郑奇（2022）在现有的驾驶意图识别模型的基础上从数据驱动层面进行模型的修正与标定，提高了意图研究场景的可行性和可复制性^[27]。王琦（2023）基于代价敏感半监督深度学习构建了自动驾驶汽车的行为解释，从数据层面对驾驶行为进行了解释^[33]。基于轨迹数据的驾驶行为分析蓬勃发展。

1.2.3 高速公路施工区驾驶行为与控制方法

高速公路施工区作为动态交通场景中风险高、扰动强的关键节点，其驾驶行为研究对提升通行效率与安全性具有重要意义。论文基于近年国内外研究成果，从驾驶行为特征、风险机理、控制策略及技术应用四个维度展开综述：

1. 施工区驾驶行为特征建模

高速公路施工区的驾驶行为在跟驰和换道两个驾驶模型的层面上均区别于基本路段，其换道行为包含因车道缩减呈现显著异质性的强制换道行为。张俊杰等（2024）提出基于车辆跟驰间距阈值的被动换道模型，发现施工区换道触发距离比常规路段缩短 23%-35%^[34]。Duan 等（2023）通过驾驶模拟实验揭示，施工区换道决策时间平均增加 1.8 秒，且纵向加速度标准差提高 42%，表明驾驶员心理负荷显著增大^[35]。朱伯青（2023）针对入口匝道场景构建汽车换道模型，验证了车间通信延迟低于 150ms 时可降低换道冲突率 19%^[36]。

而其跟驰行为也具有独特的特征，施工区限速控制对驾驶行为调节作用显著。肖哲（2022）建立车联网环境下可变限速（VSL）控制模型，实测数据表明动态限速可

使施工区速度标准差降低 31%，燃油效率提升 12%^[37]。Domenichini 等（2017）通过驾驶模拟器发现，施工区过渡段驾驶员速度适应呈现两阶段特征：前 300m 速度下降率达 0.8m/s^2 ，后 200m 趋于稳定^[38]。季文韬（2022）进一步将强化学习引入 VSL 控制，其 Q-learning 算法在高峰时段通行量提升 18%的同时，急减速事件减少 27%^[39]。

2. 施工区风险形成机理与评估

高速公路施工区对道路环境的影响包括由冲突风险引起的安全性问题和由交通扰动引起的通行效率问题。冲突风险量化方面，段克（2023）提出基于冲突时间（TTC）与换道偏移角度的复合风险指标，发现施工区汇合点风险概率比常规路段高 2.4 倍^[40]。Adeel 等（2024）采用 SMOTE 技术平衡事故数据，构建施工区事故严重性预测模型，其随机森林分类器对重伤事故的召回率达 87.5%^[41]。朱尧等（2024）引入大语言模型分析盲区影像对换道决策的影响，发现盲区面积每增加 10%，驾驶员换道犹豫时长延长 0.6 秒^[42]。

交通流扰动传播机制方面，张龙钊（2022）通过无人机轨迹数据建立施工区交通流波动模型，揭示车道封闭导致的速度扰动波以 3.5m/s 向后传播，持续影响范围达 1.2km ^[43]。Li 等（2024）构建混合交通流环境下的施工区计量模型，证明网联车辆渗透率超过 30%时可抑制扰动波幅达 58%^[44]。Jiao 等（2024）实证研究表明，施工区不同布局方案可使换道冲突率降低 12%-19%^[45]。

3. 施工区管控策略与技术应用

在车联网技术发展的背景下，针对施工区的管控策略与技术发展主要从三个方向进行，针对传统控制方法的优化，车联网条件下的控制方法和人因工程干预手段。

国内外学者对传统控制方法进行各种方面的优化以实现更好的控制效果。梁志康（2019）开发施工区智能网联车辆分层控制架构，通过模型预测控制（MPC）实现车道级协同，仿真显示平均行程时间缩短 14%^[46]。Duan 等（2024）提出考虑排队长度的动态信号控制策略，其滚动优化算法在饱和流条件下可使排队长度减少 26%^[35]。黄群龙（2021）通过 VISSIM 仿真标定施工区通行能力修正系数，发现三车道变两车道场景通行能力衰减率达 28%^[47]。

车联网的引入使得控制方法可以基于实时数据进行，显著提升控制的时效性。梁晨曦等（2024）设计基于 Stackelberg 博弈的网联车辆换道模型，在事故路段场景下实现系统效用提升 21%^[48]。Maddineni 等（2024）对比不同自动驾驶等级的影响，发现 L4 级车辆占比达 40%时施工区通行效率提升 35%，但通信故障率超过 5%会引发效率骤降^[49]。刘志强等（2014）早期研究已证明，BP 神经网络在入口合流区换道意图识别中的准确率比决策树高 11%^[50]。

由于车联网技术的普及仍不完全，网联车辆与人类驾驶员驾驶的车辆并存的交通环境仍会持续，驾驶员因素对施工区的管控策略的效果仍有重要影响。Duan 等（2023）

开发车载音频预警系统,实验表明提前 3 秒的语音提示可使换道横向速度降低 0.3m/s,轨迹平滑度提升 19%^[35]。陆键等(2020)提出基于轨迹数据的驾驶行为实时辨识算法,对施工区频繁变道行为的检测精度达 92%^[51]。

当前研究已初步揭示施工区驾驶行为的动态特征与风险形成机制,并在智能控制技术应用上取得突破。然而,面对新型基础设施与混合交通流的发展趋势,需进一步深化多学科交叉研究:在理论层面构建“人-车-路-环境”耦合作用模型,在技术层面推动车路云一体化决策系统落地。

1.2.4 车联网条件下的换道决策模型

在车联网技术(V2X)的快速发展背景下,换道控制开始与网联信息相结合。车联网条件下的换道决策模型成为提升交通安全性、通行效率的关键研究方向。换道决策模型在辅助驾驶系统(ADAS)、自动驾驶决策系统、智能交通管理等方面具有广泛应用。现有研究主要从基于规则的方法、机器学习方法及深度学习方法三大方向进行探索,国内外学者在不同技术路径上提出了多种创新性解决方案。论文将从基于微观交通理论的换道决策、基于博弈论的换道决策、基于深度学习的换道决策三个方面综述国内外研究现状,并探讨当前挑战和未来发展趋势。

现阶段国内外学者提出的基于微观交通理论的换道决策模型主要包括基于规则、基于间隙、基于加速度阈值的模型。基于规则的车道变换模型是车道变换行为建模的基础框架,其中解释变量和依赖变量之间存在明确的因果关系。Gipps 模型是这一领域的里程碑,由澳大利亚学者 Gipps 提出,它考虑了障碍物和交通控制对驾驶行为意图的影响,并将车道变换模型的框架设计为车道变换意图、车道变换条件和车道变换执行三个部分^[52]。随后,基于 Gipps 模型的研究如 MITSIM、MRS、CORSIM、SITRAS、AIMSUN2 和 HUTSIM 模型相继发展,各有其特点和应用范围^[53-55]。

基于间隙的模型考虑了车辆在变道决策中的安全间距或时间距离,驾驶员通过评估与周围车辆的间隙来判断是否可以进行车道变换。研究发现,车辆进行变道需要满足与前车或后车的一定相对距离,并服从于在二元 Logit 模型中估计的概率分布,进一步的研究引入了元自动机模型,如 NaSch 模型,以及对称和非对称的车道变换规则^[56]。基于加速度阈值的模型使用加速度作为判断是否进行车道变换的标准。例如,MOBIL 模型通过衡量潜在车道变换的利弊,基于单车道加速度进行决策^[57]。

博弈论因其在动态冲突场景中刻画多主体交互的天然优势,被广泛应用于自动驾驶及混合交通环境下的车辆换道决策建模。基于博弈论的模型考虑了车辆之间的交互作用和策略选择。经典博弈论模型通过构建收益矩阵与纳什均衡求解策略,在强制换道与协同交互场景中展现出较强解释力。Ali 等(2019)基于非合作博弈框架建立了网

联环境下的强制换道模型，通过量化安全性与效率指标设计效用函数，验证了博弈均衡解与真实驾驶数据的拟合度^[58]。陆春意等（2024）针对自动驾驶车辆驶离专用车道场景，引入模糊逻辑处理驾驶员行为不确定性，提出分层博弈决策机制，其仿真结果表明模型在通行效率提升 12.7%的同时将冲突率降低 19.3%^[59]。黄平（2024）进一步拓展至多车交互场景，提出融合 Stackelberg 博弈与风险场理论的冲突消解算法，解决了传统模型在复杂交通流中策略收敛性不足的问题^[60]。

针对传统静态博弈难以刻画策略动态演化的问题，学者们通过引入演化稳定策略（ESS）增强模型适应性。黄开启等（2024）构建了车辆换道演化博弈模型，利用复制动态方程描述驾驶员策略调整过程，发现群体策略收敛速度与收益差异系数呈指数关系^[61]。孟少寅等（2024）在高承载车道共享研究中提出动态惩罚因子调整机制，通过仿真揭示了政策干预对演化路径的调控效应^[62]。Chen 等（2023）在高速公路匝道场景中引入有限理性假设，建立基于前景理论的演化博弈模型，其参数标定结果显示驾驶员对时间收益的敏感度比安全风险高出 1.8 倍^[63]。

从当前研究趋势中可以发现，博弈的主体从单车博弈向群体博弈扩展；决策机制从完全理性假设向有限理性建模深化；技术路径从单一博弈理论向多学科融合转变。然而，现有模型在复杂动态场景的实时性、多主体协同机制的理论完备性以及人机交互中的认知差异量化等方面仍存在改进空间^[59,61,64]。

随着机器学习技术在智能交通领域的深入应用，车辆换道决策研究逐步从规则驱动转向数据驱动范式。基于动态场景特征提取与复杂交互关系建模的优势，机器学习方法在换道意图识别、轨迹预测及多目标优化等环节展现出显著潜力。

早期研究聚焦于通过监督学习算法挖掘换道行为与交通状态间的非线性映射关系。徐兵等（2019）提出基于梯度提升决策树（GBDT）的融合决策模型，通过融合车辆运动学特征与驾驶员注视特征，在 NGSIM 数据集上实现 91.2%的换道行为分类准确率，较传统逻辑回归模型提升 23.6%^[65]。Dogan 等（2011）系统比较了 SVM、随机森林等算法的性能，发现随机森林在短时预测（<2s）场景中 F1 值可达 0.87，但对长时预测的适应性较差^[66]。近年来，集成学习因能有效缓解数据稀疏性问题得到重视，Khelfa 等（2023）通过 Stacking 策略融合 XGBoost 与 LightGBM 模型，将高速公路换道预测的 AUC 值提升至 0.932，较单一模型提高 8.4%^[67]。

在监督学习与集成学习的基础上，深度学习方法通过端到端的特征学习显著提升了复杂场景的建模能力。房哲哲（2018）构建了基于卷积神经网络的换道行为识别框架，通过引入时空注意力机制，在交叉口场景下将误判率降低至 4.7%^[68]。罗归权等（2023）针对匝道合流场景，提出深度强化学习（DRL）与课程学习结合的自主换道方法，实验表明其奖励函数收敛速度比传统 DQN 算法快 1.8 倍，且冲突率下降 37%^[69]。Vallon 等（2017）开创性地将个性化驾驶风格嵌入 DRL 框架，通过聚类算法生成差异

化策略集，使换道决策的自然度评分提升 42%^[70]。王琦（2023）进一步引入可解释性约束，设计梯度加权类激活映射（Grad-CAM）与 LSTM 的混合架构，在保持 90.5%预测精度的同时提供决策依据可视化^[33]。

意图识别与轨迹预测的协同优化使得换道模型的精度与适用范围进一步提高。高精度意图识别是换道决策的前置条件，国内外学者利用时序建模技术实现了这一方面的突破。刘普俊（2024）开发时变协方差隐马尔可夫模型（TV-HMM），利用车辆横向加速度协方差矩阵动态调整状态转移概率，将周车换道意图识别准确率提高至 89.3%^[71]。鲁爽（2024）采用双向 LSTM 网络建模车辆交互依赖，在 0.5s 预测时域内轨迹误差小于 0.32m，较单向 LSTM 降低 19%^[72]。刘晗等（2024）结合 LSTM 与车辆相对运动特征，提出多模态意图识别框架，其查全率在紧急换道场景中达到 93.5%^[73]。国际研究方面，Benterki 等（2019）通过对比实验证明，LSTM 在换道意图预测中的 ROC 曲线下面积（AUC）比 SVM 高 0.15，但对计算资源的消耗增加 1.7 倍^[74]。

而为了兼顾模型性能与安全性约束，学者提出使用多种混合架构来进行换道决策模型的构建。贾寒冰等（2022）建立规则与机器学习的双层决策机制，上层采用模糊逻辑保证安全性下限，下层通过 XGBoost 优化效率目标，仿真结果显示混合模型在冲突避免成功率上比纯数据驱动模型提高 15.8%^[75]。李柏（2018）将机器学习嵌入模型预测控制（MPC）框架，设计基于高斯过程回归的约束处理算法，使复杂场景下的实时求解效率提升 2.3 倍^[76]。胡林等（2024）创新性地融合动态队列规划（DQP）与学习型 MPC，其超车换道路径的曲率连续性指标改善 26%^[77]。国际研究中，Dong 等（2021）提出级联式架构，先用随机森林筛选可行换道时机，再通过 DRL 优化轨迹参数，在出口匝道场景下通行效率提升 18.4%^[78]。

车路协同环境为机器学习提供了更丰富的感知信息输入。陆文琦（2023）提出路端智能体协同决策框架，通过联邦学习实现多边缘节点的模型共享，在 200m 通信范围内可将换道决策延迟降低至 120ms^[79]。胡锦涛（2023）在此基础上引入博弈理论，设计车路协同奖励函数分配机制，使合流区吞吐量提高 22%的同时降低能耗 14%^[80]。在个性化建模方面，Das 等（2020）利用自然驾驶数据构建驾驶员特征画像，通过迁移学习实现跨用户策略适配，其换道行为检测的跨数据集泛化能力提升 31%^[81]。机器学习在换道决策领域主要在发生两大转变：从单一算法竞争走向混合架构协同，从孤立车辆决策转向车路系统优化。文献对比表明，深度强化学习在动态场景适应性方面具有显著优势，但监督学习在资源受限场景仍不可替代^[65,70]。随着车路云一体化技术的发展，如何平衡集中式学习与分布式决策的关系，将成为下一阶段的研究重点。

1.2.5 研究现状总结

高速公路施工区的研究涉及交通流特性、驾驶员行为及管控策略等多个关键领域，对保障施工期间道路安全与通行效率至关重要。

在交通流特性研究中，宏观层面聚焦于交通流参数分析、通行能力评估及模型构建。国内外研究表明，施工区交通流状态受驾驶风格、路段控制等因素影响，如过渡区常为交通瓶颈，通行能力随车流密度变化而改变。大数据技术推动了基于数据驱动的交通流建模应用，提升了对施工区交通状态的模拟与分析能力。微观层面关注驾驶员个体行为，如车头时距缩短、车速不稳定及换道行为复杂，这些因素增加了施工区交通冲突与事故风险。

驾驶员换道行为特性研究指出，换道行为分为自由、强制与协同换道，受驾驶员个体、交通环境及道路几何等多因素触发。微观特性方面，车头时距、速度及换道轨迹在不同换道类型下表现各异，驾驶员个体差异也显著影响换道决策。随着智能网联技术发展，基于轨迹数据的驾驶意图识别研究逐步增多，为深入理解换道行为提供新视角。

施工区驾驶行为与控制方法研究揭示，施工区驾驶行为在跟驰和换道模型上与常规路段不同，限速对驾驶行为调节作用明显。风险评估通过量化冲突风险和分析交通流扰动传播机制，为制定管控策略提供依据。管控策略涵盖传统方法优化、智能网联技术应用及人因工程干预，虽已取得一定成效，但面对新型基础设施与混合交通流，仍需深化多学科交叉研究。

车联网条件下的换道决策模型研究呈现多元化发展。基于微观交通理论的模型包括基于规则、间隙、加速度阈值等类型；基于博弈论的模型在多主体交互场景中不断演进，但在实时性和理论完备性上有待完善；基于深度学习的模型通过特征学习和协同优化，显著提升了复杂场景下换道决策的精度与适应性，同时机器学习正从单一算法向混合架构、从孤立车辆向车路系统优化转变。

总体而言，现有研究在高速公路施工区的各方面取得了丰富成果，但仍面临诸多挑战，如复杂动态场景下模型的实时性、多主体协同机制的完善、人机交互中的认知差异量化以及车路云一体化技术下集中式学习与分布式决策的平衡等问题，这些将是未来研究的重点方向。

1.3 研究内容

本研究聚焦于车联网环境下的高速公路施工区场景，面向自动驾驶车辆在动态交通环境中的安全与效率挑战，围绕换道行为的深度剖析与智能决策系统构建展开。通

过融合真实轨迹数据分析、深度学习驱动的换道意图预测，以及强化学习导向的换道行为优化策略，提出一套可部署于自动驾驶系统中的智能换道决策方法体系。该系统不仅考虑了施工区域复杂交通条件下的行为不确定性，还充分结合车联网环境中可获得的多源动态感知信息，提升决策响应的实时性与可靠性。具体研究内容涵盖以下几个关键方面：

1. 高速公路施工区交通流运行特征分析：

通过无人机视频采集数据，利用轨迹提取处理技术，深入研究施工区交通流在交通流量、速度分布、车头时距等方面的关键特征，分析不同施工环境对换道行为的影响。为后续驾驶行为分析提供数据支撑和环境参数输入。

2. 高速公路施工区驾驶员换道行为特征分析：

基于轨迹数据，采用贝叶斯凝合分割算法对换道行为序列进行自动分段，并分别利用 GMM-LDA 和 MLDA 模型提取行为基元，划分出更具语义清晰度的五个换道阶段。通过比较发现，MLDA 模型在困惑度与信息熵方面表现更优，能更有效地建模施工区中驾驶行为的动态演化过程。随后，结合阶段运动学特征，使用 K-Means 聚类算法对驾驶风格进行分类，识别出激进型、稳健型、保守型三类换道风格，为个性化预测与决策建模提供依据。

3. 基于 LSTM-Transformer 架构的换道预测：

针对施工区域中驾驶行为高度异质、环境变化频繁的问题，提出一种面向多施工场景的换道预测方法，构建融合双层 LSTM 与 Transformer 架构的深度学习模型，以提升复杂条件下的预测精度与稳定性。模型设计方面，结合典型施工区域特征，分别构建三类专属子模型以刻画不同场景下的驾驶行为模式。引入动态权重融合机制，根据车道结构、交通状态与施工类型等信息，动态调整各子模型输出的权重，实现预测输出的自适应优化。该预测模块不仅能够精确输出目标车辆的换道意图，还可将预测结果作为先验信息嵌入后续强化学习框架中，为智能体提供更具语义意义的决策参考，降低决策探索的盲目性、加速策略收敛过程。

4. 基于强化学习的施工区换道决策：

在换道预测结果的辅助支持下，构建面向施工区场景的分层强化学习换道决策模型。融合提取的驾驶风格标签与预测模块输出的换道概率信息，作为智能体的先验认知输入，在提升学习效率的同时，增强策略的行为合理性与个性化适应能力。将换道决策任务分解为策略选择与动作控制两个模块。策略选择模块采用 Dueling DQN 算法进行换道意图规划，结合全局交通状态评估不同策略的长期价值；动作控制模块采用 Policy Gradient 方法，实现对加速度的连续控制，确保换道过程平稳自然。状态空间设计融合自车状态、周围车辆信息、施工标志与换道预测概率等特征，并通过多目标奖励函数从安全性、效率性与舒适性多维度对模型进行优化。在 SUMO 平台上开展仿真

实验，验证模型在多种交通密度条件下的决策稳定性与性能优越性。

1.4 技术路线

本研究面向高速公路施工区的复杂驾驶场景，构建一套融合行为建模、深度预测与强化学习的智能换道决策方法体系。首先，基于无人机采集的施工区车辆轨迹数据，开展交通流运行特征分析，识别不同施工区段下的流量、速度与时距特性，为后续建模提供数据支撑与场景参数。随后，围绕换道行为建模，利用贝叶斯凝合分割算法对驾驶行为序列进行动态分段，提取出具有物理语义的换道行为基元。进一步采用 MLDA 模型对行为基元进行建模，并结合 K-Means 聚类实现驾驶风格分类，为后续决策模型引入风格特征打下基础。

在此基础上，设计融合双层 LSTM 与 Transformer 架构的多场景换道预测模型，提升对施工区域内换道意图的判断精度。模型引入动态权重融合机制，适应不同施工工况下驾驶行为的差异性，同时输出的换道概率作为强化学习模块的重要先验输入。

最终，构建面向施工区的分层强化学习换道决策模型，将策略规划与动作控制任务进行任务分解：高层模块基于 Dueling DQN 完成换道意图选择，低层模块基于 Policy Gradient 实现纵向加速度控制。状态空间融合换道概率、驾驶风格、施工区域标签等多源感知信息，奖励函数则从安全性、效率性与舒适性三方面进行设计，引导智能体逐步学习最优换道策略。

整体技术路线如图 1-1 所示，形成了从行为理解、换道预测到智能决策的完整闭环，实现对施工区场景下复杂换道行为的建模与辅助决策。




图 1-1 研究技术路线图

本页空白

第二章 高速公路施工区交通流运行特征分析

2.1 研究范围

在实际交通管理中，施工区通常作为临时性交通干扰源，其设置形式直接影响车辆的运行行为与驾驶决策。在常规交通条件下，施工区主要依赖于静态的物理设施传递封闭车道、变道指引等信息，驾驶员获取环境信息的能力高度依赖于视距条件与个体经验，存在信息延迟、感知盲区等问题，尤其在车道突变或视距受限情境下，易导致换道判断滞后，增加交通风险。

而在车联网环境下，借助车-车（V2V）、车-路（V2I）通信机制，施工区相关信息可以通过无线通信方式提前传递至车辆系统，包括封闭车道的长度、位置、类型变更指令、前方车流状态等；同时，车辆还可获取邻近车辆的实时行为状态（如换道意图、速度变化等），从而在认知范围和响应时间上显著优于常规条件。

本文所研究的车联网条件下的施工区不仅具备传统物理边界标识的功能，同时强化了环境信息的实时共享，使得施工区中的车辆可以得到周围车辆的运动信息和道路的实时状态。

2.1.1 高速公路施工区范围界定

高速公路施工区的合理界定是确保施工安全与道路通行效率的核心问题。根据《公路养护安全作业规程》（JTG H30-2015，以下简称《规程》）的规定，标准化的高速公路养护作业控制区由六个关键区域构成，分别为警告区、上游过渡区、纵向缓冲区、工作区、下游过渡区及终止区^[82]（图 2-1）。区域的合理划分与科学设置，对于施工安全管理、交通流组织以及减少施工对高速公路运营的干扰均具有重要意义。




图 2-1 高速公路养护施工区布置形式图

此外，《规程》根据养护作业的持续时间，将养护作业划分为长期养护作业、短期养护作业、临时养护作业和移动养护作业四种类型，以适应不同施工需求及交通管理要求。具体划分如表 2-1 所示：

表 2-1 公路养护作业类型

作业类型	持续时长	适用条件	特点
长期养护作业	超过 24 小时	路面重铺、桥梁维护、大型基础设施改造	施工规模较大，对交通影响较为显著
短期养护作业	4 小时至 24 小时	局部路面修复、排水系统清理、标线重绘	布置与撤离速度相对较快
临时养护作业	30 分钟至 4 小时	快速维修、设备安装、路面监测	控制区布置更加简化，对交通流的干扰较小
移动养护作业	不超过 30 分钟	道路巡查、应急抢修	通常使用移动式标志车或自动化作业设备

在养护作业控制区的布局规划上，长期养护作业和短期养护作业均要求完整涵盖上述六个关键区域。如此设置的目的在于，确保养护作业人员、施工设备与过往行驶车辆之间相互独立、互不干扰，进而有效保障施工区域的安全性以及道路的正常通行秩序。临时养护作业在满足基本作业安全规范的基础上，可依据实际情况适当缩短控制区部分区段的长度，以此提高施工效率，缓解道路通行压力。当施工单位采用移动式标志车实施临时作业时，在满足特定条件的情况下，可省略上游过渡区，进一步简化控制区布置方案。此外，对于部分作业时间极短且影响范围较小的临时养护作业，可仅设置警告区和工作区，并根据实际需求灵活缩短警告区的长度，从而最大程度地降低对正常交通流的干扰。

虽然长期养护作业区和短期养护作业区在控制区结构和长度方面基本相似，均易形成类似的道路瓶颈效应，但二者在安全设施的选用上却存在明显区别。长期养护作业区由于施工周期较长，为提供更为可靠的安全防护，通常采用稳固式安全防护设施，如混凝土防撞护栏、固定式标志等。而短期养护作业区则更侧重于选用便于快速安装和拆卸的临时安全设施，例如可移动防撞墩、弹性标志牌等，以便在施工结束后能够迅速恢复道路正常通行状态。

另一方面，临时养护作业和移动养护作业因施工时间较短，其控制区布置在标准方案的基础上进行了适当简化。这样做的主要目的是减少对高速公路交通流的影响，提升施工效率，增强道路运行的灵活性。本文聚焦于标准化公路养护作业控制区的优化布置展开深入研究，旨在通过科学合理的布设策略，进一步提升施工安全性，优化交通流组织模式，降低施工对道路通行能力的负面影响。

为更具针对性地分析施工区交通运行特征，本文重点对施工路段中的四个关键区域进行研究：警告区、上游过渡区、纵向缓冲区、下游过渡区。在此基础上，选取不同作业类型的长期养护作业区作为研究对象，分别从交通量、速度、车头时距等维度进行特征分析，以揭示高速公路养护作业区的交通流变化规律，为后续的换道行为建模与决策优化奠定数据基础与场景认知依据。

2.1.2 高速公路施工区布置形式

高速公路施工区的布置受到施工内容、作业持续时间、交通流量、道路等级及封闭车道位置等因素的影响。合理的施工区布置不仅能够确保施工人员和设备的作业安全，还能最大程度地减少施工对交通流的干扰，提升道路通行效率。施工区的布设方式往往结合道路的车道资源与交通流特征进行调整，以确保施工期间交通运行的连续性与安全性。

根据封闭车道的位置，高速公路的施工区布置可归纳为三种主要模式，包括封闭外侧车道、封闭内侧车道及封闭中间车道。封闭外侧车道通常适用于硬路肩施工、边坡防护、排水设施维护等作业，其优势在于能够尽可能减少对正常车道的占用，但仍需在施工区前方合理设置警告区及限速标志，以提醒驾驶员提前调整行驶行为。封闭内侧车道的施工通常涉及中央分隔带维护、桥梁养护及隔离设施改造等作业，该模式可能会影响超车道的通行，增加车辆换道的难度，因此需在上游过渡区布置换道引导标志，并在封闭区域周边设置护栏或防撞设施，以提高安全性。封闭中间车道通常应用于路面修复、交通标线重划、大面积养护施工等场景，为减少对通行能力的影响，该模式多采用双车道封闭方案，并配置过渡区及导向标志，引导车辆提前完成换道，从而降低施工区入口处的交通流冲突风险。

依据《公路养护安全作业规程》(JTG H30-2015)的相关规定，在六车道及以上的高速公路上进行中间车道封闭施工时，宜同步封闭相邻一条车道，以减少换道过程中因车道宽度受限而引发的安全隐患^[82]。在此基础上，为保障车辆的平稳合流，应在施工区上游设置两个上游过渡区，并确保各区段之间的最小间距不小于 200m，以便驾驶员在合理距离内完成车道调整，避免因换道迟滞造成的局部交通拥堵。而在四车道高速公路上，由于可用车道资源有限，封闭其中一条车道将对道路通行能力产生较大影响。因此，在四车道公路的施工组织过程中，应优先考虑分时段施工或错峰封闭方案，在保证施工安全的前提下，尽量降低施工对交通流的影响。此外，施工区长度也是影响交通流运行的重要因素。研究表明，当施工区长度小于 500m 时，驾驶员通常能够提前完成换道，而当施工区长度超过 1km 时，部分驾驶员可能在接近施工区入口时才执行换道操作，从而导致施工区入口处交通密度增加^[83]。在不同场景下的高速公路布置施工区时，需结合施工区长度与车道封闭情况，合理设置信号标志与引导措施，提高换道效率，减少换道过程中对交通流稳定性的干扰。

施工区的布置方式直接关系到高速公路的通行能力，不同车道数的高速公路在施工期间的交通流特征存在一定差异。对于八车道高速公路，由于可用车道较多，通常可以在不影响正常通行的情况下封闭 1 至 2 条车道，但仍需合理优化换道区域，以避免因突发车道合流导致的局部瓶颈效应。近年来，伴随高速公路交通流量的持续攀升，施工区封闭车道对交通状况造成了较为显著的影响。在部分高速公路施工过程中，通

过启用应急车道来缓解交通流的做法已较为常见。当前，常见的施工区布置形式如图 2-2 所示。本研究中对各个车道的序号进行如下定义：由靠近中央分隔带的车道向靠近路肩外侧的车道依次编号为车道 1、车道 2、车道 3、车道 4 和应急车道。后文研究中采用同样的编号进行说明。




图 2-2 八车道高速公路养护作业区主要布置形式

施工区的安全设施配置需根据施工类型、作业时长及封闭车道位置进行合理选择。长期施工区通常采用稳固式安全防护设施，如混凝土护栏、固定式防撞墩、反光标志牌等，以提供更高的安全防护能力，防止外部车辆误入施工区域。短期施工区由于施工时长较短，通常使用便捷安装的临时安全设施，如可移动防撞墩、反光锥桶、临时警示灯等，在满足安全性能的前提下确保施工结束后可以迅速撤除，恢复道路通行能力。而对于临时及移动施工区，由于作业时间较短，通常采用轻量化安全布置方案，如移动式警示标志、警示灯及动态 LED 标志等，以提升警示效果，同时保证施工完成后能够快速撤离，避免施工区布设对正常交通流造成长期影响。

2.1.3 面向车辆换道决策的车联网环境界定

自动驾驶汽车是融合了现代汽车技术与人工智能、传感器技术、车载计算、通信技术等多种前沿信息技术的系统集成体^[84]。其核心能力在于能够自主感知环境、做出决策并执行驾驶操作，降低人为干预，提升交通系统的整体智能化水平。在此基础上，随着车联网（V2X）技术的发展，自动驾驶车辆不仅具备单车感知与控制能力，还可通过无线通信与周围交通参与体实现信息共享与协同，从而进一步提升其在复杂交通环境下的响应能力、安全性和运行效率^[85]。

近年来，在政策引导、产业布局和技术创新的共同推动下，基于车联网环境的自动驾驶已成为交通技术变革的重要方向。我国《交通强国建设纲要》明确提出推进车路协同、构建新型智慧交通基础设施，为车联网与自动驾驶的融合发展提供政策保障^[1]。国际上，自动驾驶车辆在车道变换、交叉口协同、协同换道与队列控制等典型应用场景中，依托 V2X 技术提升决策精度与交通协同水平的研究也持续深入^[86]。

在车联网环境中，自动驾驶车辆通过车载通信设备与外部环境进行信息交互，能够感知盲区、提前预知障碍、基于多源感知结果进行全局决策，是实现高等级自动驾驶的关键支撑手段之一^[85,87-89]。本研究基于上述技术背景，探索车联网环境下高速公路施工区的换道行为优化方法，以构建更加可靠、高效、可部署的换道决策系统。

截至 2025 年 4 月，自动驾驶汽车相关标准体系持续完善。我国已正式发布并实施《汽车驾驶自动化分级（GB/T 40429-2021）》（以下简称《分级》）^[90]，将驾驶自动化等级划分为 L0 至 L5 共六个等级，具体依据驾驶任务中驾驶员与系统的分工关系及运行设计域（ODD）进行定义。该分级标准为后续在不同等级自动驾驶场景中设计与部署车联网决策机制提供了统一的技术框架与实施基础（详见表 2-2）。

表 2-2 《汽车驾驶自动化分级》驾驶自动化等级与划分要素的关系表

分级	名称	持续的车辆横向和纵向运动控制	目标和时间探测与响应	动态驾驶任务后援	设计运行范围
0 级	应急辅助	驾驶员	驾驶员及系统	驾驶员	有限制
1 级	部分驾驶辅助	驾驶员和系统	驾驶员及系统	驾驶员	有限制
2 级	组合驾驶辅助	系统	驾驶员及系统	驾驶员	有限制
3 级	有条件自动驾驶	系统	系统	动态驾驶任务后援用户（执行接管后成为驾驶员）	有限制
4 级	高度自动驾驶	系统	系统	系统	有限制
5 级	完全自动驾驶	系统	系统	系统	无限制

在《分级》标准实施之前，国际上广泛采用的自动驾驶分级体系由美国汽车工程师学会（SAE）发布，定义了从 L0 到 L5 共六个等级。该分级依据车辆在动态驾驶任务中承担的自主功能与人类驾驶员的介入程度进行划分，基本理念与我国《分级》标准一致。其中，L1 和 L2 被归类为“驾驶员辅助”系统，系统仅在部分维度（如纵向或横向）提供有限控制支持；而从 L3 开始，自动驾驶系统具备了独立完成完整驾驶任务的能力，具备决策权并承担在指定运行条件内的主要控制责任，事故责任主体也由驾驶员逐步过渡至车企及自动驾驶系统提供方。

在当前技术发展背景下，L1/L2 级功能已在多数量产车型中普遍应用，尤其在新能源车领域得到快速普及；L3 及以上级别则处于准入试点阶段，尚需在测试验证、法律规范、道路基础设施等方面进一步完善支撑条件。本研究正是以 L3 及以上等级自动驾驶系统为研究对象，聚焦其在车联网协同环境下的换道感知-预测-决策流程，探讨其在面对施工区等复杂交通场景中的运行能力。

因此，本文所讨论的车联网环境主要指基于 V2X（Vehicle-to-Everything）通信技术构建的交通信息交互体系，包括车辆与车辆（V2V）、车辆与基础设施（V2I）、车辆与云平台（V2C）之间的高频率、低延迟的信息传输机制。该环境为自动驾驶汽车提供了远超传统传感器能力的信息维度，使其能够获取超视距的前方施工信息、邻车换道意图、临时交通管控状态等关键数据，从而显著增强其在复杂道路场景下的换道感

知与决策能力。在此基础上，自动驾驶车辆能够将本车实时状态与外部感知信息进行融合处理，实现更为安全、智能、高效的换道决策。

2.2 数据采集与提取

本研究利用无人机对不同布置形式下的高速公路施工路段的交通情况进行数据采集。数据采集涉及八车道高速公路施工区封闭一二车道、三四车道及六车道高速公路封闭第一车道、第三车道等。在视频采集时段内，道路交通流量较大，局部区域出现交通拥堵现象，部分情况下排队车辆的末端延伸至警告区中段。为了确保无人机拍摄视频中的车辆轨迹数据能够准确地反映道路交通流特征，本研究构建了一套系统化的轨迹提取与坐标转换流程。该流程主要包括视频预处理、目标检测、轨迹跟踪、坐标建系、轨迹标准化及数据优化等关键步骤。具体流程如图 2-3 所示。




图 2-3 施工区轨迹数据采集与提取流程

2.2.1 无人机视频采集与预处理

本研究采用无人机航拍方式获取施工区路段的交通流数据。分别于 2024 年 10 月 28 至 11 月 18 日于宁宣高速进行施工区各路段的视频数据采集。无人机拍摄的视频时长为 15 min/段，覆盖了警告区、上游过渡区、工作区，以获取施工区交通流的详细特征。本研究针对不同的施工区组织形式进行了数据收集，包括常见的几种道路封闭形式（见图 2-4）。无人机的航拍高度约 300m，可以确保较大范围内的车辆运动数据采集。然而，由于气流影响，视频存在一定程度的画面抖动，影响轨迹精度。因此，在进行目标检测与轨迹提取之前，需要对视频进行预处理。




图 2-4 无人机采集数据场景示意

无人机拍摄过程中可能受到风速、姿态调整等因素的影响，原始视频可能存在画面抖动和透视畸变，进而影响后续轨迹提取的准确性。因此，在数据处理前，采用视频稳定算法对视频进行增稳处理。本研究使用 OpenCV 的 Lucas-Kanade 光流法（LK 光流）对视频序列进行帧间运动估计，并采用仿射变换对视频进行平稳化处理，确保后续检测精度。

光流法是一种经典的计算机视觉技术，用于估算视频帧间的运动。其核心思想是：假设视频中的相邻帧之间，像素的运动是连续的，并且像素颜色变化较小，从而可以通过计算光流向量来估算帧间运动。本研究使用的 LK 光流适用于小范围的平移运动估计。具体过程如表 2-3 所示。

表 2-3 LK 光流平滑过程

步骤	操作
特征点检测	选取视频中具有高梯度变化的像素点（例如路标、护栏等固定参考物）作为特征点。
局部光流估计	在特征点的邻域内，计算光流向量，获取像素的运动轨迹。
全局运动拟合	采用最小二乘法（Least Squares），对所有光流向量进行全局运动拟合，估计整个视频帧的平移向量。

在获取帧间位移后，采用仿射变换对图像进行几何校正，以消除抖动影响。对原图像进行平移、旋转、缩放和错切变换以完成：

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} a & b & t_x \\ c & d & t_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (2.1)$$

其中:

(x, y) 和 (x', y') 分别为原始像素坐标和修正后的坐标;

t_x, t_y 为帧间平移量 (由光流法计算);

a, b, c, d 控制图像缩放、旋转和错切。

2.2.2 轨迹提取与坐标转化

1. 目标检测

在稳定的视频基础上, 进一步采用 YOLOv8 (You Only Look Once, Version 8) 进行车辆目标检测, 该算法是一种高效的单阶段目标检测模型, 能够实时识别不同类型的车辆, 包括小客车、大客车、小型货车、大型货车及超长货车, 并输出每辆车的像素级位置信息、车辆类别标签以及检测置信度分数。相比于传统的目标检测算法, YOLOv8 具备更高的检测精度、实时性强、计算开销较小等优点, 适用于复杂交通环境下的多目标检测。

2. 轨迹跟踪

在目标检测完成后, 需对检测到的车辆进行轨迹跟踪, 以确保在整个视频序列中保持目标身份的一致性, 并提取完整的时空轨迹信息。本研究采用 DeepSORT (Simple Online and Realtime Tracker) 进行多目标跟踪, 该方法结合卡尔曼滤波 (Kalman Filter) 进行轨迹状态预测, 并利用匈牙利匹配算法 (Hungarian Algorithm) 进行目标匹配, 同时融合深度特征 (ReID Embeddings) 以提升对重叠目标的区分能力。

轨迹跟踪过程主要包括以下步骤: 首先, 初始化目标轨迹, 为 YOLOv8 识别出的每一辆车分配唯一的 ID, 并记录其初始位置坐标。随后, 利用卡尔曼滤波预测目标在下一帧中的位置, 以减少因遮挡或短暂消失导致的 ID 误匹配问题。接着, 通过匈牙利匹配算法计算上一帧目标集合与当前帧目标集合之间的最优匹配关系, 并结合深度特征 (ReID) 进行目标身份关联。最终, 输出每辆车的轨迹数据, 包括车辆 ID、时间戳 t 、像素坐标 (x, y) 等信息, 从而形成完整的运动轨迹。通过 DeepSORT, 可以确保相同车辆在整个视频序列中的轨迹数据连续、匹配准确, 为后续运动特征分析提供可靠的基础数据支持。

3. 坐标系构建及比例尺设定

在无人机拍摄的视频数据中, 车辆的轨迹信息以像素坐标形式存储, 而非实际的物理空间坐标。由于视频本质上是二维投影影像, 且拍摄视角具有一定倾斜角度, 因此需要建立统一的坐标系, 并通过像素-实际距离映射关系, 将像素坐标转换为物理坐标, 以确保轨迹数据与真实道路环境保持一致。本文采用 Tracker 软件进行坐标系构建, 并设定比例尺, 以实现像素数据的标准化转换。

为了确保轨迹数据的空间一致性, 首先需要确定坐标系的参考原点。本研究选取整个画面的左上角作为坐标系原点, 记作 $(0, 0)$, 并以此作为所有轨迹数据的基准点。

该设定能够确保所有车辆轨迹在相同的空间参考系下进行对比分析。

在建立坐标系后，需要利用已知的道路标志信息计算像素到实际距离的映射关系。为减小坐标标定过程中的误差，本研究选取不同拍摄视频中可见的最远道路桩点间距作为参考以保证物理尺度的准确性，以实地测量的桩点间距作为标定坐标的依据。

为了建立像素坐标与真实世界坐标之间的映射关系，采用如下公式计算比例尺：

$$R = \frac{L_{\text{real}}}{P_{\text{px}}} \quad (2.2)$$

其中：

L_{real} 为基准线的真实物理长度（m），

P_{px} 为基准线在图像中的像素长度（px），

R 为像素与实际距离的转换比例（m/px）。

计算得到比例尺 R 后，可以将所有像素坐标转化为真实坐标：

$$x_{\text{real}} = x_{\text{px}} \times R, \quad y_{\text{real}} = y_{\text{px}} \times R \quad (2.3)$$

通过上述步骤，建立像素坐标与真实物理坐标之间的映射关系，确保轨迹数据的标准化，便于后续的交通流分析、轨迹优化及运动学计算。

4. 轨迹转化

由于施工区道路通常存在一定的弧度，直接提取的车辆轨迹往往呈弯曲分布，这可能会影响后续的轨迹分析和运动参数计算。因此，本文采用道路中心线坐标变换的方法，将车辆轨迹沿道路中心线的切线方向展开，以模拟标准的直线路段。该方法能够消除道路曲率对轨迹分析的影响，使车辆的运动特征更加直观地反映实际行驶状态。

首先进行提道路的中心线坐标，并对其进行平滑拟合，以建立标准化的空间参考基准。使用 Tracker 软件对道路中心线进行取点，选取多个中心线特征点，确保其均匀分布于施工区范围内，并能够准确反映道路的曲率变化。接着采用 B 样条（B-Spline）插值对中心线进行平滑拟合，构建连续的道路中心线方程：

$$f_c(s) = (x_c(s), y_c(s)) \quad (2.4)$$

其中， s 代表沿中心线的弧长坐标，即沿道路中心线方向的累积距离。

在得到平滑拟合的道路中心线后，需要对原始轨迹进行坐标旋转变换，使其沿着道路中心线的切线方向展开，以消除道路曲率对轨迹分析的影响。选取道路中心线上的参考点 $(x_c(s), y_c(s))$ ，并结合相邻点计算该点的切线方向：

$$\theta_c = \arctan\left(\frac{dy_c}{dx_c}\right) \quad (2.5)$$

其中， θ_c 为中心线在该点的局部切线角度，反映该点处道路的行驶方向。

对于每个车辆轨迹点 (x_i, y_i) ，按照参考点的切线角度 θ_c 进行旋转变换，以将轨迹展开至直线路段：

$$\begin{aligned} x'_i &= (x_i - x_c) \cos(-\theta_c) + (y_i - y_c) \sin(-\theta_c) \\ y'_i &= -(x_i - x_c) \sin(-\theta_c) + (y_i - y_c) \cos(-\theta_c) \end{aligned} \quad (2.6)$$

其中, (x'_i, y'_i) 为标准化道路坐标, 即旋转变换后得到的新轨迹点坐标。

经过旋转变换后, 所有车辆轨迹的纵向坐标沿中心线排列, 横向坐标表示其相对于道路中心线的偏移量。这一转换确保了轨迹数据能够在标准直线坐标系中进行分析, 便于后续进行换道检测、速度计算及车头时距分析。

5. 轨迹纠偏与滤波平移

为了进一步优化轨迹数据的精度与稳定性, 本研究采用 Savitzky-Golay 滤波 (Savitzky-Golay Filtering, SG 滤波) 与移动平均滤波 (Moving Average Filtering) 相结合的方法, 对采集到的车辆轨迹数据进行平滑处理, 以减少数据中的噪声和异常值, 提升轨迹数据的连续性和可用性。在无人机航拍过程中, 由于气流扰动、无人机姿态调整、相机光轴偏移等因素, 可能导致车辆轨迹数据在某些时间帧内出现细微抖动或漂移现象, 影响轨迹的精确性。因此, 为了有效补偿因拍摄过程中的无人机漂移所引入的坐标误差, 本文选取道路中央分隔带的护栏作为固定参考点, 利用其相对稳定的空间位置, 对轨迹数据进行漂移校正, 确保坐标系统的一致性。

Savitzky-Golay 滤波是一种基于局部多项式拟合的平滑方法, 通过在一定窗口范围内对数据进行最小二乘拟合, 保留轨迹曲线的整体趋势, 同时减少高频噪声影响。本研究采用二阶多项式拟合, 并结合滑动窗口方法, 优化轨迹数据的平滑程度, 使得轨迹在滤波后仍能较好地保留其原有的动态变化特性, 避免过度平滑导致的轨迹畸变。

移动平均滤波是一种常见的时序数据去噪方法, 通过计算相邻数据点的平均值, 以消除突发性偏差, 使轨迹数据更加平稳。本研究采用加权移动平均法, 在平滑轨迹数据的同时, 降低对轨迹局部特征的影响, 从而确保换道行为、速度变化等关键信息得以保留。

在进行坐标漂移补偿时, 首先选取施工区域内中央分隔带护栏的多个固定点作为参考基准, 并在不同时间帧中记录其像素坐标变化。然后, 采用仿射变换计算这些参考点的漂移向量, 并基于漂移量对所有车辆轨迹数据进行同步校正, 消除因无人机摄像头位置变化导致的系统性误差。最终, 经过滤波平滑和漂移补偿处理的轨迹数据更加稳定、精准, 为后续的换道行为分析、速度计算及车辆交互研究提供了高可靠性的数据支撑。

通过上述处理方法, 本文将弯曲道路上的轨迹数据转换为标准化的直线道路坐标, 确保数据分析的准确性, 并为后续施工区交通流特征研究提供了轨迹数据支撑。

2.2.3 换道轨迹提取

为获取后续驾驶行为分析与决策建模所需的数据基础, 本文在完成车辆轨迹坐标

标准化与滤波预处理之后,进一步开展了换道行为轨迹的提取工作。考虑到施工区环境中换道行为普遍具有突发性强、空间受限、时序连续等特征,传统基于车道变更标签或人工观察的换道识别方法难以满足高精度建模需求,因此本文基于轨迹几何特征与动力学变化构建自动提取流程。具体而言,换道轨迹提取主要依据以下两个核心指标:

(1) 横向位移特征:在标准化坐标系中分析车辆横向坐标随时间的变化趋势,筛选出横向偏移量超过 3.0m 的轨迹段(约为标准车道宽的 80%)。该阈值可有效排除短时扰动、弯道漂移等非换道行为。

(2) 横向速度动态变化:为进一步提升提取准确性,引入横向速度变化规则进行约束。要求换道过程中存在横向速度极值点,且速度在连续 10 帧(约 0.5 秒)内绝对值大于 0.2 m/s,以保证动作的明确性与持续性。

此外,为确保轨迹结构完整性,本文排除出现遮挡/中断的非连续轨迹、横向位移异常回弹的轨迹、以及同一车辆在短时间内多次变道或位置标注错误的轨迹段。

基于上述标准,本文对无人机拍摄所提取的 95760 条有效轨迹样本进行了逐一分析识别。经人工抽检验证,该换道轨迹集覆盖了施工区中不同封闭方式(如封闭右侧一车道、左侧两车道等)与不同流量状态下的典型换道场景。

在识别出换道轨迹后,需进一步完成换道车辆的标定。本文通过将每条换道轨迹所对应的 Vehicle ID 进行汇总,建立换道车辆集合。凡在观测时间段内完成至少一次换道操作的车辆,均标记为 lane_change=True,其余车辆则标记为 lane_change=False

为进一步支持后续对换道意图识别和行为预测建模,本文在完成换道轨迹提取的基础上,同步进行了强制换道决策点的自动标定。所谓换道决策点,指的是驾驶员开始产生换道意图、进入换道准备阶段的起始时间点。

由于无人机航拍轨迹数据中无法获取车辆转向灯等显式驾驶信号,本文参考已有研究采用速度变化滞后性分析法作为主要方法,结合经验时间窗法作为补充,构建决策点识别机制^[27]:

(1) 速度滞后性法

在封闭车道跟驰状态下,正常驾驶情况下,车辆与前车的速度变化具有同步性,存在一定滞后;而一旦驾驶员产生换道意图,其操作将不再完全受前车控制,速度变化曲线将与前车显著脱节。因此,本文基于前后车速度差值的滞后响应特征进行分析,定义判断逻辑:当换道车辆与前车在某一时刻出现持续的速度变化差异($\Delta v > 0.15m/s^2$),且换道车辆不再保持滞后响应特性时,该时刻即判定为换道决策点,标记为 t_1 。

(2) 经验时间窗法

对于无前车或距前车过远、缺乏跟驰特性的数据,采用经验策略法进行补充识别。

参考侯海晶等人对换道准备阶段的时间统计分析^[27]，其平均换道意图持续时间约为 2.81 秒。据此，本文对剩余无法由速度滞后性识别的换道轨迹，统一向换道执行点前移 3 秒，作为换道决策点标注。

最终，所有换道轨迹均被标注了唯一决策时间点 t_1 ，其在轨迹结构中明确分隔了前序跟驰阶段与换道准备阶段，构成后续驾驶行为时序分段与预测模型输入的关键起点。

基于上述换道轨迹与决策点的识别和提取结果，本文构建了涵盖换道全过程的轨迹数据集。该数据集不仅完整记录了换道前的跟驰状态、换道准备过程及换道执行行为，还明确标注了各类驾驶状态的分界时刻。为后续关于驾驶行为阶段划分、行为基元提取、驾驶风格识别、换道意图预测以及强化学习换道决策模型的训练与验证提供数据支撑。

2.3 施工区交通运行特征分析

2.3.1 交通量特性

交通运输部颁布的《公路工程技术标准（JTGB01-2014）》依据客车座位数和货车载质量，将我国公路运营车辆分为小客车、中型车、大型车和汽车列车四类。以小客车为标准车型，其他类型车辆的换算系数如表 2-3 所示。

表 2-3 《公路工程技术标准》中车型换算系数及分类标准表

汽车代表车型	车辆换算系数	分类标准
小客车	1.0	座位 ≤ 19 座的客车和载质量 ≤ 2 吨的货车
中型车	1.5	座位 > 19 座的客车和 $2 \text{ 吨} < \text{载质量} \leq 7$ 吨的货车
大型车	2.5	$7 \text{ 吨} < \text{载质量} \leq 20$ 吨的货车
汽车列车	4.0	载质量 > 20 吨的货车

我国运营的多数高速公路实行客货分离的车道管理措施，不同车型的交通量及分布情况对高速公路施工区的交通流运行状态，尤其是对车辆的车道选择和换道行为存在影响。依据具体的车道管理措施，结合对无人机拍摄视频中各车辆车身长度的观察统计，进一步细化车型分类为小汽车、中型车、大型车、超长车四种类型，分类标准及换算系数如表 2-4 所示。

表 2-4 研究路段车型换算系数及分类标准表

车型分类	车辆换算系数	分类标准
小汽车	1.0	车身长度 $\leq 6\text{m}$ 的车辆
中型车	2.5	$6\text{m} < \text{车身长度} \leq 10\text{m}$ 的车辆
大型车	2.0	$10\text{m} < \text{车身长度} \leq 12\text{m}$ 的车辆
超长车	3.0	车身长度 $> 12\text{m}$ 的车辆

将研究路段分为警告区，上游过渡区，纵向缓冲区，下游过渡区四个区段进行研究，选取典型施工区视频路段进行对应的特征分析，图 2-4 为封闭右侧两车道的高速公路施工区分车道路段流量分布。




图 2-4 高速公路右侧封闭两车道施工区流量分布图

在施工区的警告区段，车道 3 和车道 4 的交通流量相对较高。分析这两条车道的交通流构成可知，大型车和超长车在其中占比较大，大型车辆通常需要更大的行驶空间和更长的车头间距，相较于小型车辆，其单位长度的通行能力较低，这是导致交通流量增加的关键因素。车道 2 的交通流量相对较低，该情况可能与部分小型汽车驾驶员的驾驶习惯及心理因素紧密相关。基于过往对驾驶员行为的研究，当小型车驾驶员知晓前方右侧两车道正在施工，且察觉到各可用车道的驾驶环境差异不大时，他们往往倾向于选择受影响最小的车道 1 行驶。这种选择主要源于人类在驾驶过程中倾向于将潜在风险和干扰降至最低的本能^[91]。

在施工区的过渡区上游，交通流量出现了显著的重新分配情况。车道 3 的交通流量显著增加，并超过了车道 4。其可能的原因在于，随着车辆逐渐靠近施工区，大型车和超长车的驾驶员会逐步向左侧车道靠拢，以便顺利通过施工区。大型车辆的机动性通常较为有限，而左侧车道一般拥堵程度较低，且能为其提供更多调整行驶速度和位

置的空间。此外,封闭右侧车道的施工区布局对右侧车道影响更大,交通状况与行驶条件更为复杂,这使得大型车驾驶员更青睐左侧车道。车道4的交通流量未出现明显下降,这或许归因于部分小型车驾驶员打算借用应急车道通过施工区,因而向车道4靠近。小型车驾驶员凭借其相对灵活的驾驶特性,可能计划利用应急车道绕过因施工导致的拥堵区域。他们向车道4靠近,是因为车道4紧邻应急车道,便于在需要时进入应急车道。然而,这种行为也带来了潜在风险,因为不当使用应急车道可能导致交通违规,扰乱整体交通秩序。

在施工区的纵向缓冲区,车道4已完全封闭。此时,车道1的交通流量最高,这表明众多车辆已选择换道至车道1通行。车道3的交通量显著上升。车道3可能接纳了部分从车道4换道过来的车辆,且这些车辆主要为大型车和超长车。小型车本有更优选择,即换道至应急车道通行。部分驾驶员过度谨慎,害怕因违反交通规则被罚款,所以更倾向于选择相对熟悉但更为拥堵的车道3。这种行为进一步加剧了车道3的交通拥堵。此时,车道4的所有车辆均已完成换道,应急车道出现了较高的交通流量,这表明众多小型车驾驶员选择利用应急车道通过过渡区。应急车道较高的交通流量反映出该替代路线对小型车驾驶员绕过施工影响区域的有效性。但在当前工程环境中开放应急车道的条件较为模糊,仍需持续监测以确保应急车道的使用符合规定,不会引发新的交通问题。

在施工区过渡区下游,车道3和车道4均已封闭。此时,车道1和车道2的交通流量相近。所有大型车、超长车以及大部分中型车均分布在车道1和车道2,应急车道则主要由小型车占据,这表明车辆的重新分配已完成。车道1和车道2相近的交通流量表明,车辆在通过上游和中游过渡区后,已逐渐适应新的交通状况。大型车和中型车因其尺寸和驾驶特性,更集中于较宽且更稳定的车道1和车道2。小型车在纵向缓冲区使用应急车道后,在下游区域逐渐回到正常车道。这一整体的车辆重新分配过程体现了交通流系统在应对施工引发的干扰时的自我调节能力。然而,这也凸显了有效的交通管理和引导在施工期间优化交通流、确保交通安全的重要性。

从微观行为角度看,车道交通压力的差异直接影响驾驶员的换道动机与执行时机,尤其在上游过渡区和纵向缓冲区,车辆密度变化剧烈,换道行为更为频繁,后续建模中需要考虑交通量对个体决策的影响。

2.3.2 速度特性

交通流特性的研究对于深入理解道路运行状况,尤其是施工区这种复杂环境下的交通现象至关重要。速度特性是交通流研究的核心要素之一,车辆速度不仅直接影响道路的通行能力,还与车头时距相互作用、相互影响。深入分析施工区不同阶段的速

度特性，能够进一步完善对施工区交通状况的认知，有助于更精准地把握交通拥堵的演变过程，为制定科学有效的交通优化策略提供更为全面的理论依据。对施工区在警告区、施工区上游、纵向缓冲区、施工区下游各阶段的速度分布进行计算分析，并统计不同车型的平均速度，结果如图 2-5，2-6 所示。




图 2-5 施工区各区段平均速度分布热力图




图 2-6 施工区各区段不同车型速度分布热力图

在施工区警告区，小型车的速度最高，基本在 26-28 m/s 之间，表明该区域对小型车而言通行较顺畅，尚未收到比较大的影响。大型车和超长车的速度较低，尤其是超

长车仅出现在车道 4，速度为 22.38 m/s，略低于乘用车。车道 1、3 和 4 速度相差不大，但车道 2 的小汽车速度最高，可能因为该车道相对而言车流量较小，车辆能够保持较高速度。

在施工区过渡段上游，施工区对交通流的影响开始显露，所有车辆速度下降到 2 m/s 左右，表明该区域可能发生了车辆排队或者密集车流导致的拥堵。重型车速度最低（1.23-2.20 m/s），由于车辆尺寸较大，受施工影响更为显著。小汽车速度比其他车型略高（最高 2.89 m/s），但仍然远低于上游警告区（下降约 25 m/s）。车道 1、2、3 速度相近，整体拥堵严重，所有车道的车流都受到了影响。车道 4 中有大型车与超长车行驶以及前方车道减少带来的强制换道，有更严重的速度下降。

在纵向缓冲区，车辆速度略微回升，相比上游过渡区的 2 m/s，提高到 3.5-5 m/s，但仍然远低于上游警告区。此时应急车道的速度明显高于其他车道，小型车与中型车速度分别达到 12.11 m/s 和 12.54 m/s，说明开放应急车道对于缓解施工区的交通拥堵具有明显的效果，行驶在应急车道上的车辆受到施工区的影响较小。从整体上来看车道 1-3 的车辆速度基本均衡，表明车道减少后，交通压力仍然较大。大型车与超长车的速度（3.83-5.01 m/s）仍低于其他车型，受施工影响最严重。

在施工区过渡段下游，小型车与中型车速度最高（6.34-12.29 m/s），表明该区域的交通状况有所改善。大型车和超长车速度仍然偏低（5.79-5.87 m/s），但相比中游过渡区有所提升，说明在过渡区下游，车辆的行驶受施工区强制变道的影响较中游略有改善。车道 2 与应急车道的速度最高，车辆已经较好的完成合流，但仍然没有完全恢复到施工之前的状况。

通过对施工区各区段各车道的速度分布热力图的分析可以了解不同区域和车道的速度变化特征。分析结果表明，随着车辆进入施工区域，速度逐步下降，尤其是在上游过渡区和中游过渡区，速度大幅降低，部分车道甚至出现低速行驶或停滞现象。而在下游过渡区，尽管速度有所恢复，但整体通行效率仍未完全恢复至施工前水平。这一分析有效展现了施工区不同车道的速度分布规律，但仍然无法直观体现个体车辆的行驶动态及换道行为对速度变化的影响。

为了进一步深入研究施工区内车辆速度的演变趋势及其在不同区段的时空分布特性，对施工区各个区段的车辆进行速度轨迹图的绘制（图 2-7）。速度轨迹图不仅能反映车辆在时间和空间上的行驶状态，还能揭示施工区域内的速度波动、换道影响以及可能的拥堵模式。通过分析不同施工区段的速度轨迹图，我们可以更清晰地观察到个体车辆在进入、穿越和驶离施工区过程中的速度调整策略，以及由换道或车道减少引起的速度不稳定现象。




图 2-7 高速公路施工区各区段速度轨迹图

施工区警告区的速度轨迹呈现深红色，车辆的行驶速度较高，交通流整体顺畅，各个车道的速度曲线波动微小，分布较为均匀。表明在数据收集时段内施工区的拥堵尚未传播到上游的警告区，车辆遵循正常高速公路行驶模式，车距稳定，行驶过程中速度无明显变化，交通系统处于高效、稳定运行状态。

进入施工区上游后，部分车辆的速度出现明显的下降。速度轨迹出现倾斜，表明车辆受施工影响产生换道行为，不同车辆速度差异增大。靠近施工区域的车辆开始减速，换道行为导致车道内速度分布不均，交通流稳定性降低。

纵向缓冲区交通状况更为复杂，车辆速度进一步下降，速度轨迹倾斜角度增大，存在明显低速区，可能因车流密集或施工影响引发局部拥堵。此阶段施工对车辆行驶限制增强，速度降低、换道频繁，导致速度不均匀性加剧，部分车道缓行，交通拥堵严重影响通行效率。

施工区下游车辆速度回升，但未达警告区水平。轨迹趋于稳定，仍存在速度差异，低速轨迹减少但局部低速区域仍存，表明施工影响尚未完全消除。车辆逐渐恢复正常行驶，但因车道合并等因素，速度仍有波动，换道行为减少，但低速车辆仍影响交通流顺畅。

不同车道与区段间速度分布的异质性，揭示了换道行为背后的局部交通扰动机制。对于微观建模而言，这种速度不稳定性是换道触发机制的重要外在表现形式，也是后续强化学习模型中状态空间设计的关键考量因素。

2.3.3 车头时距特性

车头时距作为交通流特性的关键参数，指前后两辆车通过同一点的时间间隔，其变化直接反映车辆的跟驰状态以及道路的通行状况。在施工区这一复杂交通环境下，车头时距的动态变化能够有效揭示拥堵程度、车道合流影响以及车辆换道行为的特征。

本部分基于四张车头时距 - 距离分布图（图 2-8），对施工区不同路段（警告区、施工区上游、中游、下游）的车头时距进行分析。




图 2-8 高速公路施工区车头时距分布热力图

警告区的车头时距分布状况中，车头时距分布较为均匀，主要集中于 0-6 秒的时间区间内，部分区域时距相对较小（呈现为红色区域）。从车辆分布情况来看，车辆分布状态相对稳定，车头时距变化幅度较小，这充分表明车辆的行车状态较为均衡。图中颜色主要以蓝色和部分黄色为主，依据交通流可视化规则，这意味着大部分车辆保持着较短的车头时距，体现出高流量且车速相对稳定的交通运行状态。

深入分析警告区的交通状况可知，车辆在此区域仍处于正常的高速公路运行模式。较短的车头时距表明车流密度较高，但由于交通顺畅，车辆间能够保持较为稳定的跟驰状态。少量车头时距较大的区域，可能与特定车辆类型（如大型车辆）的行驶特性有关，也可能是部分车辆换道行为导致的短暂扰动。整体而言，施工影响在警告区尚未明显显现，车辆未出现明显的拥堵或急刹车现象，交通流处于高效、稳定的运行状态。

施工区上游相较于警告区，车头时距呈现出更大的离散性，部分区域的车头时距显著增加（以黄色、红色区域标识）。这一现象表明车辆的行驶状态已开始受到施工影响，出现了时距较长的情况，意味着部分车辆开始减速或进入排队等待状态。在某些特定的距离范围内，车头时距从 0-6 秒逐渐攀升至 10 秒以上，这一变化趋势强烈暗示部分车道可能存在堵塞状况。

随着施工影响在施工区上游逐渐显现，部分车辆出于对施工干扰的规避，可能开

始采取减速或换道措施，进而导致车头时距增大。不同车道由于施工相关因素（如车道宽度变化、交通引导设置等），其通行能力差异逐渐增大，这进一步致使车头时距分布不均匀。然而，部分区域仍然保持较短的车头时距，这可能是因为某些车道尚未受到严重影响，依旧保持畅通，但周边换道车辆的频繁穿梭开始对整体车流的稳定性产生扰动。

纵向缓冲区的车头时距状况显示该路段车头时距进一步显著扩大，众多区域的车头时距超过 10 秒，表明施工导致了严重的通行受阻。从车头时距的曲线形态可以明显观察到剧烈的波动，这反映出车流出现了停滞或时快时慢的不稳定行驶情况，极有可能是由车辆换道或车道合并等因素造成的。同时，车辆密度在此区域有所降低，推测是部分车辆提前预判施工区状况，选择提前换道，从而导致局部车道流量分布不均匀。

纵向缓冲区是整个施工区域内通行受阻最为严重的部分。车头时距的大幅增加明确表明车辆的行驶状态极不稳定，大概率出现了拥堵现象。车道数量减少的影响在此处表现得极为明显，部分车辆在此处需要进行合流或调整车道，这直接导致部分区域的车头时距异常增大。施工对车流的干扰在该区域达到最高峰，极有可能形成瓶颈效应，严重限制了整体道路的通行能力。

从施工区下游的车头时距变化趋势中可以看出，车头时距开始呈现恢复态势，低时距区域（以蓝色标识）有所增加，这一现象表明车辆开始逐渐恢复正常行驶。尽管仍然存在部分车头时距较大的区域，但整体分布趋势较为均匀，不再出现施工区中游那样的极端变化情况。车流在此区域逐渐恢复平稳，车辆开始主动调整车距，以适应施工区结束后的正常道路行驶环境。

随着车辆逐渐驶离工作区，施工影响逐步减弱，车辆通行状况逐渐恢复正常，车头时距也随之逐渐降低，这表明道路的通行条件正在不断改善。然而，仍然能够观察到一些残余的车头时距波动，这可能是由于施工区出口处的合流影响尚未完全消除。当车辆进入正常车道后，车头时距趋于均匀，换道和减速现象明显减少，这表明车辆已经基本适应了施工区后的行驶环境，交通流正在逐步恢复到稳定状态。

施工区下游的车头时距变化趋势中可以发现车头时距开始呈现恢复态势，低时距区域（以蓝色标识）有所增加，这一现象表明车辆开始逐渐恢复正常行驶。尽管仍然存在部分车头时距较大的区域，但整体分布趋势较为均匀，不再出现施工区中游那样的极端变化情况。车流在此区域逐渐恢复平稳，车辆开始主动调整车距，以适应施工区结束后的正常道路行驶环境。

随着车辆逐渐驶离施工核心区域，施工影响逐步减弱，车辆通行状况逐渐恢复正常，车头时距也随之逐渐降低，这充分表明道路的通行条件正在不断改善。然而，仍然能够观察到一些残余的车头时距波动，这可能是由于施工区出口处的合流影响尚未完全消除。当车辆进入正常车道后，车头时距趋于均匀，换道和减速现象明显减少，

这表明车辆已经基本适应了施工区后的行驶环境，交通流正在逐步恢复到稳定状态。

综合以上分析结果，在警告区，车头时距较小，车辆通行顺畅，施工影响尚未在车头时距特征上有所体现。进入施工区上游后，部分车头时距开始增加，表明车辆已开始因施工影响而减速或换道，施工影响初步显现。在施工区中游，车头时距大幅增加，拥堵情况加剧，施工影响在此区域表现得最为显著，部分车辆的行驶甚至出现停滞现象。进入施工区下游后，车头时距逐步恢复至相对正常水平，车辆重新调整车距，施工影响逐渐消退。施工过程中车道数量的减少促使车辆换道行为显著增加，这一因素直接造成车头时距波动加剧，尤其是在施工区上游和中游表现得更为突出。纵向缓冲区由于施工活动的集中开展以及车道变化等因素，形成了拥堵瓶颈，导致该区域车头时距达到最大值，部分车辆不得不经低效行驶过程。在施工区下游，随着车辆逐渐驶离施工影响区域，换道行为减少，交通通行逐渐恢复稳定，但由于施工区出口合流等因素的残余影响，仍然存在局部的车头时距波动情况。车头时距的变化反映了驾驶员对空间感知与风险控制的反应机制。在微观层面，这类变化可视为潜在意图萌发与换道行为准备阶段的重要判断依据。

2.4 车联网条件下的施工区交通流运行特征分析

为进一步响应车联网条件在施工区交通组织中的关键作用，并对比分析不同渗透率下交通运行的演化特征，通过构建典型施工区微观仿真场景，开展系列对比实验。仿真场景以无人机采集的典型施工区布设为基础，结合真实交通流量与车道封闭信息进行建模，并在仿真平台（如 SUMO）中对不同网联车辆渗透率（0%、25%、50%、75%、100%）下的运行特性进行分析。

仿真模型以实际采集的施工区布设方案为基础，设置双向八车道高速公路，封闭左侧两条车道作为施工作业区，并在封闭段前设置 1500m 的预告区域。仿真场景采用如下参数设定：

表 2-5 SUMO 仿真场景参数设置表

参数名称	数值或范围
仿真平台	SUMO 1.18
仿真时长	3600s（前 1200s 高流量）
步长	1s
路段设置	四车道直道，右侧一车道封闭
车辆类型	小客车（含网联）、大客车、货车、超长货车
渗透率设定（小客车）	0%、25%、50%、75%、100%
ACC 控制启用范围	渗透率 > 0% 的小客车
流量设置（veh/h）	高峰：3200，平峰：2400

其中，智能网联车辆采用 ACC 跟驰控制，无换道控制策略，换道行为基于 SUMO

默认的 LC2013 换道模型。分析结果基于高峰状态下的输入流量进行仿真，意在反映施工区拥堵压力较大时车联网条件对运行效率与安全性的影响。



图 2-9 SUMO 仿真示意图

1. 交通量特性

统计不同渗透率条件下高峰状态的施工区瓶颈段（施工区中段）通过断面的总交通量，结果如表 2-6 所示。

表 2-6 不同渗透率下施工区中段交通量统计（veh/h）

渗透率	交通量（veh/h）	增幅（相较于 0%）
0%	1865	—
25%	1975	+5.9%
50%	2110	+13.1%
75%	2168	+16.2%
100%	2195	+17.7%

随着智能网联车辆渗透率上升，瓶颈段的通过交通量显著提升。其中，0~50%渗透率提升最为明显，超过 50%后增长趋缓，表明 CAV 在缓解交通拥堵方面具有显著的边际效益提升能力。

2. 速度特性

各渗透率条件下，提取施工区上下游与作业区内各关键位置的平均行驶速度，结果如表 2-7 所示。

表 2-7 不同渗透率下平均车速统计（单位：km/h）

渗透率	上游过渡区	警告区中段	施工区下游
0%	78.6	46.2	58.9
25%	80.1	51.7	60.5
50%	81.2	55.9	64.1
75%	82.5	58.7	65.0
100%	83.4	60.4	65.5

随着渗透率提升，施工区关键路段平均速度明显提高，尤其在瓶颈段（警告区中段）表现最为突出，从 0% 时的 46.2 km/h 提升至 100% 时的 60.4 km/h，提升幅度达 30.7%。表明智能网联车辆通过精准的跟驰控制，在高密度条件下仍可维持较高运行效率。

通过仿真分析可知，在车联网条件下，智能网联车辆可有效提升瓶颈段通行能力，缓解流量下降问题；速度稳定性增强，空间波动减少，车道间协调性提升。

本节基于典型施工区布设场景，设计了包含不同智能网联车辆渗透率的微观交通仿真方案，初步分析了车联网条件对施工区交通运行效率与行为特征的影响。在高峰状态下的仿真结果表明，智能网联车辆的引入可有效缓解瓶颈段的通行压力，提高平

均速度，降低换道集中度与突发性行为的比例，展现出较强的运行稳定性与拥堵缓解潜力。

2.5 本章小节

本章围绕高速公路施工区交通流运行特征展开了分析，主要包括研究范围的界定、数据采集与处理方法，以及交通流特征的分析。明确了高速公路施工区的范围界定和典型布局形式，既定并探讨了本文研究的车联网环境下自动驾驶汽车的换道决策影响因素，为后续分析奠定基础。在数据采集与处理部分，采用无人机视频采集技术获取施工区交通数据，并结合轨迹提取与坐标转换方法，实现了施工区车辆轨迹数据获取，为后续特征分析提供基础的数据支持。在施工区交通运行特征分析部分，围绕交通量、速度特性、车头时距等关键指标展开研究，揭示了施工区交通流的运行规律及其变化趋势。为优化施工区交通组织管理、提升交通安全性提供了理论支撑。此外，结合智能网联车辆在实际道路中的逐步应用趋势，进一步引入车联网条件下的微观仿真设计方案，分析了不同智能车渗透率下施工区的交通量变化、速度稳定性以及换道行为分布等特征。仿真结果表明，智能网联车辆在高渗透率条件下可有效提升瓶颈段通行能力，缓解换道拥堵集中，增强整体运行稳定性，展现出良好的交通效率提升潜力。研究内容主要聚焦于施工区交通流的宏观运行特征，但其分析结果为后续微观行为建模与智能决策提供了现实基础与数据支撑。一方面，通过对施工区典型布置方式、交通流强度与时空分布的系统分析，揭示了不同区段内交通压力与行驶行为差异的演化特征，为微观层面行为建模场景的构建提供了背景依据。另一方面，车道流量、速度变化、车头时距等关键指标的统计结果，反映出驾驶员在应对车道封闭、交通密度上升等场景中所采取的操作趋势，可为换道意图识别、驾驶风格建模等微观分析提供参考边界与输入变量设计思路，为后续章节中从个体行为层面开展的换道行为建模、意图预测及强化学习决策优化奠定了数据基础与情境设定依据。

第三章 高速公路施工区车辆换道行为特性分析

3.1 基于驾驶基元的施工区车辆换道行为特征分析方法

高速公路施工区域由于其道路空间有限、交通流组织变化、驾驶环境复杂等特点,车辆的行驶行为与普通高速公路路段存在显著差异。施工区内驾驶员的驾驶行为相较于基本路段具有更多的影响因素,在速度变化、加速模式等方面的特征具有其独特性质。现阶段国内外学者主要依据驾驶员操作模式、换道行为、跟车行为、驾驶风格等维度对高速公路车辆驾驶行为进行了多个方面的分类分析^[9,92-94]。为开展换道行为的特性分析与微观建模工作,本章使用源自第二章基于无人机航拍的车辆轨迹采集与换道轨迹处理的数据进行换道行为特征分析。

驾驶员在高速公路的主要驾驶行为包括保持行驶、换道、加速、减速、制动等操作。在限速管控较严格的情况下,驾驶员会选择保持稳定的车道位置,并遵循限速要求以保证安全^[88]。由于施工区存在封闭车道与交通流合流区,驾驶员在施工区的驾驶行为存在较多的强制换道场景。驾驶员需要在车流密度高、可用车道减少的情况下做出快速决策,合理选择换道时机,以降低因突发情况带来的风险。此外,加速和减速行为在施工区的频率较高,驾驶员可能因前方施工车辆、交通信号变化或前车制动等情况需要调整速度。在部分突发状况下,如遇到施工设备移动、突然封闭的道路、行人穿越等情况,驾驶员可能采取紧急制动,以避免交通冲突和事故发生。

受限于施工区内的交通组织,换道行为在施工区驾驶行为中尤为突出。驾驶员的换道行为也因个体差异而表现出不同特征。现有研究中主要将驾驶人的驾驶风格归类为激进型、保守型和稳健型^[95]。激进型驾驶员在施工区内通常表现为频繁变换车道、较高的行驶速度、较短的跟车距离等行为。这类驾驶员往往倾向于快速通过施工区域,并减少行驶时间,但其行为可能带来较高的事故风险。保守型驾驶员则表现出较为谨慎的行驶方式,他们在施工区通常保持较低车速,避免频繁换道,并与前车保持较大的安全距离,以减少潜在的交通冲突风险。稳健型驾驶员在速度控制、跟车距离及换道频率方面保持适中,既兼顾行驶效率,又保持相对安全的操作模式。

为了对施工区段内的换道行为进行全面分析,本文将复杂驾驶行为中分解出的简单、原始的驾驶片段定义为驾驶行为基元,通过驾驶行为基元的划分可以实现对换道轨迹数据的精细表达,并进一步用于驾驶风格的定量分析与聚类建模^[95]。施工区复杂的交通条件导致不同驾驶员在面对施工区限速、车道变更、前方拥堵等情况时,采取的行驶策略存在明显差异^[43],使用驾驶行为基元可以实现对不同驾驶人的驾驶行为的精确分析,进而实现驾驶风格的区分。近年来,针对驾驶风格的分类研究已经取得了较多成果,主要围绕驾驶员的加速模式、制动习惯、换道频率、跟车距离等关键特征

展开,使用无监督学习方法进行分类^[6,32,96]。施工区场景中道路环境对车辆行驶的影响因素较复杂,驾驶行为存在显著的时空扰动特性,本研究采用基于驾驶行为基元换道行为分析方法,聚焦于微观行为片段的提取与分类建模。

为克服传统驾驶行为建模中存在的行为片段边界模糊和时间窗口不自适应等问题,本文采用贝叶斯凝合分割算法(BASS)对轨迹序列进行无监督分段,BMASS 基于贝叶斯最大似然准则与协方差结构分析,自底向上合并相邻轨迹片段,能够有效识别驾驶行为中的变化点,无需人工指定分段数,具有良好的行为语义保持性和时序稳定性^[98]。该方法在时间敏感类序列建模任务中已被广泛应用,并适用于结构连续但状态变化频繁的交通轨迹数据场景。考虑到换道行为的复杂性与阶段性特征,本文基于分段后的轨迹序列,提取了每段对应的运动学特征,以构建结构化的行为特征向量,便于后续聚类与模式识别。已有研究表明,驾驶行为在轨迹层面具有明显的物理特征模式,其多维特征空间可用于识别驾驶风格差异^[99]。

在分类方法选择上,本文采用 K-Means 聚类算法对换道行为样本进行风格识别。该算法作为一种经典的无监督聚类方法,适用于高维特征空间中类别数量已知或可控的场景。与层次聚类、DBSCAN 等方法相比,K-Means 具备计算效率高、收敛稳定、聚类边界清晰等优势,适合本研究中以物理特征为基础的行为样本划分任务^[100-102]。

最终聚类结果识别出三类典型风格:激进型、稳健型与保守型,分别对应驾驶员在换道过程中不同的速度控制、车距保持和换道策略特征。该分类结果不仅符合已有风格研究的认知框架,也为后续的预测建模与个性化决策优化提供了行为标签支持。

3.2 驾驶人换道行为基元提取模型

在进行驾驶行为的建模与分析过程中,明确核心术语的含义对于建立统一的研究框架至关重要。为避免歧义,本文对以下几个关键概念作出统一界定:

驾驶片段:指在时间上连续、在行为特征上相对一致的一段车辆轨迹,通常通过轨迹分段算法从完整轨迹中切分而得,反映出驾驶员在该时段内维持的一种操控模式,如匀速行驶、换道准备等。

行为基元:指在时序结构上不可再细分、具有稳定特征的驾驶行为模式,是构成换道行为等复杂动作的最小语义单位。例如,“加速进入换道”、“减速等待时机”等均可视作行为基元。

在本文中,“片段”强调轨迹分段的结果,而“基元”则侧重于从片段中提炼出的语义行为类别。即:驾驶片段是时间维度上的划分结果,行为基元是语义空间上的聚类标签。在建模流程上,通常先基于轨迹特征进行分段(得到驾驶片段),再使用无监督学习方法从这些片段中提取出可复用的行为基元,形成完整的驾驶行为建模体系。

3.2.1 基于贝叶斯方法的换道行为轨迹序列分割

为实现对施工区换道行为的精细分析，驾驶序列的时序分段是关键的一步。传统的固定窗口或基于阈值的分割方法，往往依赖人为设置窗口长度或规则阈值，难以适应不同行驶状态下行为变化节奏的差异，容易造成分割过粗或边界错位等问题。传统的固定窗口分割方法无法适应驾驶行为的动态变化，而贝叶斯方法则能够依据观测数据的统计特征自适应地进行分段，提升行为单元的表达能力。

为提升分段的行为语义一致性与时序连续性，本节使用从原始轨迹数据中提取出换道行为轨迹子集，作为后续分段的对象。依据前期构建的空间标准化坐标系，结合车辆横向位移阈值、速度变化率以及相邻车道空间判断条件，对整体轨迹数据进行换道事件识别。提取出的换道轨迹样本均涵盖换道的准备、执行与回稳阶段，具备明确的行为边界与动作特征。

本节采用贝叶斯凝合分割算法（BMASS）方法对车辆轨迹数据进行无监督分段。BMASS 基于最大似然准则与协方差相似性原则，自底向上地不断合并相邻片段，直到整体分割最优为止。其主要优势在于避免了人为指定分段数，且能够自适应调整分段粒度，提升分段结果的语义一致性和时间连贯性。

BMASS 算法以贝叶斯概率框架为基础，假设观测到的轨迹序列由若干个行为模式片段构成，每一片段在统计上服从不同的生成模型。算法初始将整个轨迹划分为多个最小粒度的子段，然后通过最大后验准则（MAP）指导的合并-分裂操作，逐步寻找全局最优的分段结构。在合并阶段，BMASS 通过比较相邻片段合并前后模型的边际似然变化，判断是否存在统计一致性以合并；而在必要时也可执行分裂操作，进一步优化行为边界的定位。该方法通过引入贝叶斯信息准则自动平衡模型复杂度与拟合精度，避免过拟合，并且在无需预设分段数量的情况下自动适应轨迹变化结构，实现高鲁棒性的行为识别与语义建模。

通过对轨迹数据的分析，本研究使用 BMASS 方法对完整驾驶序列进行了建模，统计结果如表 3-1 所示：

表 3-1 BMASS 算法分割基本信息

指标	BMASS
分割段总数	8927
分割段平均持续时长	1.07s
样本总数	95760
换道行为数量	278

BMASS 方法识别出了 8927 个行为片段，行为片段是指从完整轨迹提取的具有统一驾驶行为的子轨迹段，用于分析局部行为特征。平均每段持续时间约为 1.07 秒，表明该方法能够以较细粒度地刻画驾驶行为的变化。在整个数据集中，共采集到 95760

条有效轨迹数据，并识别出 278 次换道行为，展示了 BMASS 在大规模数据下的实用性。

为进一步验证分段效果，图 3-1 展示了分割点在轨迹中的归一化相对位置分布：




图 3-1 BMASS 分割点位置分布

BMASS 所识别的分割点在每辆车的行驶过程中分布较为均匀，分段点未呈现聚集在固定时间点的趋势，表明分段决策可能主要由轨迹特征驱动而非时间因素主导。

3.2.2 基于无监督学习的车辆换道行为基元提取

在高速公路施工区环境下，驾驶员的操作行为往往呈现出明显的阶段性与时序演化特征。换道行为作为其中最具代表性的驾驶行为之一，不仅涉及纵向与横向操作的协同，还与驾驶者的风险感知、意图表达和行为风格密切相关。为实现对换道行为结构的精准刻画，仅依赖整体轨迹特征或单点指标往往难以捕捉行为演化的动态过程，因此有必要对换道行为进行更细粒度的建模与拆解。

为此，本文基于数据驱动的视角，采用无监督学习方法对驾驶行为序列进行建模，通过提取具有代表性的驾驶行为基元来描述驾驶员在换道过程中的细节操作模式。所谓行为基元，指的是驾驶行为在时间尺度上的最小结构单元，它能够反映驾驶员在某一阶段下的稳定操作策略。相比于传统的人工标注或规则提取方法，基于无监督学习的建模方式更具通用性和适应性，能够从大规模数据中自动发现潜在行为结构，为后续的驾驶风格识别与智能决策提供理论基础。

考虑到驾驶行为数据通常具有高维、连续和多模态等特征，本文在方法上引入了高斯混合模型-隐狄利克雷分配（GMM-LDA）与多模态隐狄利克雷分配（MLDA）两种主题建模框架，对换道行为进行行为基元提取。该建模思路融合了轨迹分段与语义主题识别两大核心任务，能够在不依赖标签的前提下，从轨迹数据中自动学习出换道行为的阶段性结构及其在特征空间中的分布规律。

1. 高斯混合模型-隐狄利克雷分配模型

在施工区环境下，驾驶员的驾驶行为往往表现出复杂的时序特征。由于道路条件的变化、施工区域的干扰以及周围交通流的影响，驾驶员在施工区内的行驶状态并非静态的，而是经历了不同阶段的演化过程。传统的驾驶行为分析方法通常依赖于全局特征建模，而忽视了驾驶行为在时间维度上的动态变化，这在一定程度上限制了对施工区驾驶模式的精准刻画。因此，为了更全面地描述驾驶行为在施工区内的变化过程，本文采用高斯混合模型-隐狄利克雷分配模型（GMM-LDA）方法对驾驶行为基元进行提取。该方法首先利用高斯混合模型（GMM）对驾驶行为轨迹进行分段，并对驾驶行为片段进行聚类，以保证行为模式的相似性。随后，结合隐狄利克雷分配模型（LDA）建模驾驶风格的潜在主题分布，从而揭示施工区驾驶员的行为模式及其演化过程。流程如图 3-2 所示。




图 3-2 高斯混合模型-隐狄利克雷分配模型流程

GMM 作为一种典型的无监督学习方法，能够基于数据的统计特性识别不同的驾驶行为模式，从而实现轨迹分段的自动化。相比于传统的固定时间窗口切割方法，GMM 能够通过概率建模的方式自适应地确定最优的轨迹分段数量，避免人为设定分段数带来的主观偏差，使得轨迹分段的边界更加合理，从而提高后续驾驶风格分类的准确性。在保留驾驶行为丰富特征信息的同时，减少了数据的取值空间，使得 LDA 模型能够更有效地建模驾驶行为的主题分布，同时也解决了驾驶数据的连续性与 LDA 需要离散输

入之间的接口匹配问题。

在轨迹分段完成后，单纯依赖 GMM 仍然无法完整刻画驾驶行为的语义结构，因为驾驶员的行为模式不仅受瞬时状态（如速度、加速度等）影响，还受到长期驾驶习惯和道路环境因素的约束。因此，本文在 GMM 轨迹分段的基础上，进一步引入 LDA 进行驾驶行为基元提取，以挖掘驾驶行为的潜在主题模式。

LDA 是一种典型的主题建模方法，最初用于文本分析，其核心思想是认为一篇文档可以由多个主题混合组成，而每个主题由不同概率的词汇构成。在驾驶行为建模中，LDA 的这种思想同样适用，可以将驾驶行为数据视作一种“文档-主题-词汇”结构，即驾驶轨迹片段对应于“文档”，驾驶状态特征（如速度、加速度、换道角度等）对应于“词汇”，而驾驶行为基元则相当于“主题”。即一条驾驶轨迹并不单一地属于某一种驾驶行为，而是由多个驾驶行为基元的混合所构成，每种行为基元可以看作是在特定驾驶情境下的驾驶策略模式。这种方法的优势在于，它不仅可以识别出驾驶行为的主要类别，还能够量化不同类别之间的相互关系，从而更深入地分析驾驶员在不同道路场景中的驾驶风格和策略。例如，在施工区环境下，驾驶员的行驶方式可能是由稳定驾驶、换道调整和速度调整等行为模式的不同权重混合而成。LDA 通过狄利克雷过程建模，使得每条轨迹的行为基元分布可以通过概率建模的方式自动学习，而不需要人为设定驾驶行为类别，从而能够更灵活地适应不同驾驶环境和个体驾驶风格的变化。相比传统的聚类方法，LDA 不仅可以实现驾驶行为的无监督分类，还能够更细粒度地刻画驾驶员在整个行驶过程中不同行为模式的贡献比例，从而为智能驾驶决策提供更全面的行为建模基础。

对于任意一条轨迹 d ，首先从狄利克雷分布采样得到该轨迹的驾驶行为基元分布 θ_d ：

$$\theta \sim \text{Dirichlet}(\alpha) \quad (3.1)$$

接着，对于轨迹 d 中的每个时间片段 n ，首先基于该轨迹的行为基元分布，按照多项分布（Multinomial Distribution）选择该时间片段所属的驾驶行为基元 $z_{d,n}$ ：

$$z \sim \text{Multinomial}(\theta) \quad (3.2)$$

随后，根据已分配的驾驶行为基元，从另一个多项分布中采样生成该时间片段的驾驶特征 $w_{d,n}$

$$w \sim \text{Multinomial}(\beta) \quad (3.3)$$

在该建模框架下：

α 和 β 为超参数，分别控制驾驶行为基元的稀疏性以及驾驶特征在不同基元中的分布稀疏性。

θ_d 是轨迹 d 的驾驶基元分布，决定了该轨迹由哪些驾驶风格组合而成。

$z_{d,n}$ 表示轨迹 d 的第 n 个驾驶行为状态，即该时间片段属于哪种驾驶风格。

$w_{d,n}$ 代表观测到的驾驶特征，如速度、加速度等，它由对应的驾驶行为基元生成。

通过该概率生成过程，LDA 能够基于轨迹数据挖掘出驾驶员的行为模式，并从数据中自动学习不同驾驶行为基元的分布情况，使得驾驶行为分类更加精准，同时避免了手动设定固定驾驶风格类别的局限性。

2. 基于多模态隐狄利克雷分配模型的驾驶行为分段模型

多模态隐狄利克雷分配（MLDA）是一种改进的主题建模方法，适用于多模态数据的融合分析。在驾驶行为建模任务中，单一数据模态往往无法完整刻画驾驶员的驾驶风格。MLDA 允许多个数据模态（如速度、加速度、换道行为、驾驶轨迹等）共享主题分布，同时在不同模态下建模主题的特征分布，从而提供更精确的驾驶行为基元识别。

在 MLDA 框架下，每个驾驶行为数据样本都可以视为一个由多个模态（多种驾驶行为特征）组成的观察数据集，每个模态的数据在不同驾驶行为主题（即驾驶基元）上的分布由一个独立的狄利克雷分布建模。在训练过程中，MLDA 通过 Gibbs 采样或者变分推断方法，对驾驶行为主题的多模态分布进行优化，以便更好地刻画驾驶员的驾驶风格及行为变化特征。

在 MLDA 模型中，对关键模型参数进行如下定义：

$X = \{X_1, X_2, \dots, X_M\}$ 为驾驶行为数据集，其中 X_M 表示第 m 个模态的数据，如速度、加速度、换道行为等； Z 为隐含主题变量，即驾驶行为基元； w_m 表示在模态 m 下的驾驶行为数据单词，即数据离散化后形成的“单词”；主题分布 $p(Z | X)$ 服从狄利克雷先验。

MLDA 通过联合概率建模多个模态的数据，在每个驾驶行为基元的主题分布基础上，使用不同的狄利克雷分布来建模数据的多模态信息：

$$p(z_{d,n}^m | z_{-d,-n}^m, W) = \frac{n_{z,-d,-n}^m + \alpha_k}{\sum_k (n_{z,-d,-n}^m + \alpha_k)} \times \frac{n_{w,-d,-n}^m + \beta_t}{\sum_t (n_{w,-d,-n}^m + \beta_t)} \quad (3.4)$$

其中：

$z_{d,n}^m$ 表示文档 d （驾驶行为序列）中的第 n 个驾驶行为词在模态 m 下的主题分配。

$n_{z,-d,-n}^m$ 表示在去除当前采样点后，主题 z 在模态 m 下被分配到的数据数目。

$n_{w,-d,-n}^m$ 表示去除当前采样点后，模态 m 下单词 w 在主题 z 下被观察到的次数。

α_k 和 β_t 是超参数，用于控制主题分布的稀疏性。

每个驾驶行为基元（主题）在不同模态的数据分布受制于模态自身的词汇频率，同时受到该主题在整个数据集上的分布影响。因此，MLDA 能够在多个模态下联合学习驾驶行为特征的主题表示，从而提高换道行为建模的准确性。

3.2.3 换道行为基元提取模型评价

在驾驶员换道行为的研究中，驾驶决策过程通常可划分为换道决策阶段、换道执行阶段、换道调整阶段，而从车辆轨迹特征的角度分析，换道行为则可表现为两段车道保持阶段与一段车道切换阶段。基于此，本研究在完成驾驶行为轨迹分割后，进一步采用无监督学习方法进行驾驶行为基元提取，以挖掘不同驾驶风格在换道过程中的演化特征。在驾驶行为基元建模过程中，合理的主题数量 K 的设定是确保驾驶行为模式可解释性的关键。若 K 设定过小，模型可能会因过度泛化导致驾驶行为特征表达不足；反之，若 K 设定过大，则可能出现过拟合现象，使得行为基元的物理意义难以解释，从而降低分类结果的可读性。为此，本文在参考相关研究工作的基础上，结合实验结果，将换道行为基元的主题数量设定为 $K = 5$ ，以确保模型在保持行为类别区分度的同时，避免信息冗余或模式碎片化^[95]。

为进一步量化评估各模型在驾驶行为基元提取中的建模质量，引入困惑度（Perplexity）和信息熵（Entropy）作为性能评价指标，以衡量模型的生成能力及行为基元的分布均匀性。

困惑度作为衡量模型生成能力的重要指标，困惑度反映了模型对驾驶行为模式的拟合优度。困惑度的定义如下：

$$\text{Perplexity} = \exp\left(-\frac{1}{N} \sum_{d=1}^N \log p(X_d)\right) \quad (3.5)$$

其中， N 表示测试数据集中驾驶行为序列的总数， $p(X_d)$ 为模型对样本 X_d 的对数似然概率。较低的困惑度表明模型对驾驶行为的生成能力更强，即其分类效果更优；反之，较高的困惑度则表明模型对数据的解释能力较弱，可能存在过拟合或欠拟合问题。

信息熵（Entropy）：信息熵用于衡量驾驶行为类别的分布均匀性，以刻画驾驶行为模式的多样性和分类结构合理性。其计算公式如下：

$$\text{Entropy} = - \sum_{k=1}^K p_k \log p_k \quad (3.6)$$

其中， K 表示驾驶行为类别（基元）数量， p_k 为类别 k 在数据集中出现的概率。信息熵较低表明驾驶行为模式具有较好的可区分性，而较高的信息熵则表明驾驶行为类别较为均匀分布，可能导致部分类别难以解析。

表 3-2 使用上述评价指标对比了不同分割和聚类算法的组合后的模型效果。综合表格分析与上文模型分析进行对比，可知 MLDA 算法有着更优的计算结果。

表 3-2 不同方法下的模型评价指标

	困惑度	信息熵
GMM-LDA	3.9611	1.9859,
MLDA	3.1480	1.6544,

因此在后续的数据分析方面选择使用 MLDA 方法来进行,以深入挖掘驾驶人换道行为的驾驶特征。

3.2.4 换道行为基元物理意义分析

MLDA 算法将车辆的换道过程划分为了五个行为基元,初始稳定行驶阶段为换道做准备,驾驶员观察环境并调整策略;换道起始阶段是换道意图的初步体现,车辆开始进行姿态调整;换道加速期是换道动作的正式执行,车辆向目标车道加速偏移;换道调整阶段则是在车辆大部分进入目标车道后,对行驶轨迹和速度等进行优化;换道完成并进入稳定行驶阶段标志着换道行为的结束,车辆重新回归稳定行驶状态。不同行为基元的统计分析如表 3-3 所示。

表 3-3 换道行为基元统计学规律分析

	基元	基元 1	基元 2	基元 3	基元 4	基元 5
Vel_x	均值	5.633	2.237	8.139	5.208	11.809
	标准差	1.403	1.040	0.937	0.863	1.507
	上四分位数	6.789	3.110	8.850	5.941	12.805
	中位数	5.658	2.404	8.065	5.233	11.454
	下四分位数	4.457	1.625	7.354	4.456	10.608
Vel_y	均值	-0.020	-0.021	-0.009	-0.020	-0.013
	标准差	0.109	0.092	0.111	0.114	0.127
	上四分位数	0.050	0.026	0.060	0.053	0.061
	中位数	-0.015	-0.008	-0.005	-0.014	-0.005
	下四分位数	-0.084	-0.072	-0.071	-0.085	-0.076
Acc_x	均值	-2.315	0.034	0.178	0.520	-0.519
	标准差	1.007	1.248	1.096	0.955	1.442
	上四分位数	-2.090	0.024	0.052	0.098	0.011
	中位数	-2.116	0.000	0.000	0.005	-0.029
	下四分位数	-2.125	-0.021	-0.022	-0.005	-2.058
Acc_y	均值	-0.002	0.000	0.002	-0.002	-0.003
	标准差	0.891	0.888	0.887	0.885	0.878
	上四分位数	0.036	0.012	0.018	0.012	0.038
	中位数	0.000	0.000	0.000	0.000	0.000
	下四分位数	-0.039	-0.013	-0.039	-0.022	-0.068

不同的换道行为基元在各特征维度上表现出显著差异。基元 1 的纵向速度均值为 5.633,为五个基元中偏低值,但其纵向速度与加速度的波动较大,可能处于受到外界环境干扰较强的状态,例如在准备换道前,驾驶员正在观察周围交通环境并频繁调整速度以维持安全车距。基元 2 的横向速度均值为-0.021,是所有基元中最低的,纵向速

度标准差也相对较小 (1.040), 说明该阶段车辆以较为稳定的速度沿纵向方向行驶, 缺乏横向操作意图, 驾驶行为表现为平稳直行。基元 3 在纵向速度均值 (8.139) 较高的同时, 其横向速度和横向加速度的标准差分别为 0.111 和 0.887, 均为较高水平, 表明车辆可能正处于换道过程中横向位移快速变化的阶段, 驾驶行为较为激进。基元 4 虽然纵向速度均值略低于基元 3, 但也达到 5.208, 且横向速度与加速度变化不大, 反映出车辆状态较为稳定, 受外界干扰较小, 可能对应于换道行为的前期准备或后期稳定阶段。基元 5 的纵向速度均值最高 (11.809), 横向速度均值为-0.013, 仅次于基元 3, 同时其纵向加速度标准差为 1.442, 为所有基元中最大值, 车辆在纵向和横向方向上均有一定幅度的动态变化, 属于换道过程中的另一种较强意图表现, 但整体侵略性略低于基元 3。

在对换道行为进行深入建模之前, 首先需要将原始连续轨迹序列划分为具有一致驾驶行为语义的轨迹段落。通过分析车辆在位置、速度、加速度等维度的变化模式, 提取出相对稳定的行为片段。图 3-4 所示为三个典型车辆换道轨迹的分段结果示意图, 其中:




图 3-4 右侧封闭施工区典型车辆换道轨迹基元分段结果示意图

左列为纵向位置随时间变化的曲线，标星点为 MLDA 模型自动识别出的分段位置；中列为速度曲线，背景色代表划分出的不同基元阶段；右列为横向与纵向加速度曲线，同样按阶段上色，展现各阶段的驾驶行为差异。

通过对结果的分析可知，换道行为并非瞬时发生，而是在准备、执行与完成阶段中动态演化。例如，在换道准备阶段，车辆纵向速度波动性较大，驾驶员可能处于频繁调整状态；而换道加速阶段则表现出速度上升、横向扰动增强的特征；进入换道完成阶段后，车辆的加速度逐渐平稳，运动状态重新归于稳定。

3.3 驾驶人换道风格聚类模型构建

在高速公路施工区域，驾驶员的换道行为受到道路环境、周围交通流以及个体驾驶风格的综合影响。为了深入刻画换道过程中的驾驶行为特征，本文采用基元提取方法，将换道行为划分为五个不同的基元。每个基元均具有独特的运动学特性，能够反映驾驶员在换道过程中的不同驾驶策略和行为模式。相较于对换道行为的整体分析，基于行为基元的分解方式能够提供更细粒度的驾驶行为特征描述，有助于识别不同阶段的驾驶特性及潜在的行为规律。

1. 聚类特征选择

在换道行为基元提取的基础上，构建了驾驶风格特征矩阵，其中每个驾驶员的换道行为被分为五个基元，每个基元均包含横向速度 (V_x)、纵向速度 (V_y)、横向加速度 (A_x) 和纵向加速度 (A_y) 等关键运动学特征。因此，最终的特征矩阵形式如下：

$$F = \{V_{x1}, V_{y1}, A_{x1}, A_{y1}, V_{x2}, V_{y2}, A_{x2}, A_{y2}, \dots, V_{x5}, V_{y5}, A_{x5}, A_{y5}\} \quad (3.7)$$

该特征矩阵能够反映驾驶员在换道前、换道过程中及换道完成后的行为模式差异，为驾驶风格的分类提供了全面的数据支持。

2. K-Means 聚类建模

为了有效识别不同类型的驾驶风格，本文采用 K-Means 聚类算法进行驾驶风格分类，具体过程如下：

(1) 数据归一化：由于不同特征的数值范围存在较大差异，为避免影响聚类效果，首先对所有特征采用 Min-Max 归一化处理：

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (3.8)$$

(2) 聚类类别确定：使用轮廓系数和肘部法评估不同聚类数目的效果，最终选择三类驾驶风格作为最优分类数目 ($K = 3$)。

执行 K-Means 聚类，基于欧式距离计算相似性，将所有驾驶员分配到 3 个不同的聚类中心，并迭代优化聚类效果，随后对划分的三个类别进行各个特征的统计学分析，结果如图 3-5。




图 3-5 不同类别的运动学特征分布

在横向速度 v_x 方面，激进型驾驶员在基元 2 阶段横向速度迅速上升，并在基元 3 达到峰值，表明其换道动作启动更早、执行更迅速；而保守型驾驶员横向速度始终较低，换道过程更为缓慢平稳。进入基元 4 后，各风格均呈下降趋势，至基元 5 趋于归零，表明换道已基本完成。

在纵向速度 v_y 方面，激进型驾驶员在整个换道过程中维持较高速度，表现出在高速下完成换道操作的倾向；保守型驾驶员则自基元 2 起显著减速，体现出更强的安全顾虑与谨慎态度；稳健型风格的速度变化居于二者之间，保持较好的速度稳定性。

在纵向加速度 a_x 分布上，激进型驾驶员在换道初期（基元 1~2）即表现出较高的加速趋势，而稳健型与保守型则加速度较低，起步更为平缓。至基元 5 阶段，各类风格纵向加速度均回落至稳定区间，表明车辆已重新进入平稳行驶状态。

横向加速度 a_y 的分析进一步验证了换道执行强度的差异。在基元 2 与基元 3 阶段，激进型驾驶员展现出显著的横向加速度峰值，反映其换道过程中具有更大的操控幅度与动态响应。而保守型驾驶员横向加速度值整体较低，且换道过程更长，呈现出典型的渐进式换道特征。

激进型驾驶员在换道过程中具有启动早、速度高、动作强的特点，换道过程迅速果断；保守型则表现为延迟启动、速度缓慢、动作柔和，换道完成时间相对更长；稳健型则在换道速度与操作强度上维持中间水平，兼顾效率与稳定性。这些差异性特征为后续个性化换道模型构建提供了明确的物理参数支持，也验证了行为基元分段方法在刻画驾驶行为动态演化过程中的有效性。

3.4 本章小结

本章节聚焦于高速公路施工区的换道行为，基于轨迹数据对换道数据进行建模与分类，以探究不同驾驶风格对换道策略的影响。

为有效提取换道行为的时序结构特征，采用贝叶斯凝合分割算法对原始换道轨迹序列进行自动分割，精确识别换道过程中状态的变化节点，为后续行为基元提取打下基础。在此基础上，分别使用 GMM-LDA 与 MLDA 模型对换道行为基元进行建模与提取。实验比较表明，GMM-LDA 在面对施工区复杂多变的交通行为时难以适应数据的动态特性，其提取结果存在阶段划分模糊、语义信息不足等问题；而 MLDA 模型通过引入马尔可夫假设有效增强了阶段间的时间依赖建模能力，在困惑度与信息熵指标上表现更优，更加精准地刻画了换道行为的潜在结构与语义演化过程。

在提取出换道行为的关键基元之后，进一步计算了各阶段的核心运动学特征指标，包括纵向速度、横向速度、纵向加速度和横向加速度，量化了不同驾驶风格在换道各阶段的差异表现。最后，结合所提取的运动学特征，利用 K-Means 聚类算法对驾驶员换道风格进行分类，识别出激进型、稳健型与保守型三类典型风格。实验结果显示：激进型驾驶员具有更高的横向速度与更快的换道完成时间；稳健型驾驶员在速度与加速度方面表现出一致性与稳定性，换道过程流畅；保守型驾驶员则换道时间较长，横向调整频繁，纵向速度整体偏低。

本页空白

第四章 多场景识别与融合的高速公路施工区换道预测模型

4.1 模型总体架构

在高速公路施工区场景下，道路结构的临时调整与交通流状态的波动使得驾驶员的行为具有高度不确定性，尤其是换道行为的决策模式更为多样且不可预测。因此，如何在施工区等多变场景下实现对车辆换道意图的精准预测，已成为智能驾驶系统中一项极具挑战性且极具应用价值的关键问题。换道意图判断的准确性，直接影响到辅助驾驶系统的响应效率、交通安全保障能力以及自动驾驶车辆的全局路径规划质量。

当前主流的换道预测方法大多依赖于短时轨迹特征建模，在普通道路场景中可以取得一定的性能，但在施工区中面对车道封闭、通行受限、换道空间紧张等多种复杂环境干扰时，建模能力往往不足，难以捕捉驾驶行为背后的长期依赖特性，导致预测精度显著下降。施工区车辆的轨迹变化过程高度依赖于其所处的具体施工环境，具有显著的场景差异性。

为此，本章节提出了一种多场景识别与融合的高速公路施工区换道预测模型，通过场景识别模块动态感知车辆所处施工环境，构建并调用相应的子预测模型，并引入权重融合机制以实现多子模型的协同决策，从而有效提升模型对复杂施工环境的适应能力和泛化能力。为增强模型的现实适用性与感知协同特性，本研究首先基于无人机高精度航拍数据提取真实驾驶员在施工区环境中的换道轨迹及行为特征，并构建换道意图识别模型，反映人类驾驶中的策略偏好。该模型作为先验行为知识进一步嵌入车联网仿真环境中，结合感知状态、V2X 通信等协同信息构建智能车辆的换道决策框架，从而实现“人类行为建模 + 车联网感知增强”的融合式建模路径。在数据层面引入人类驾驶样本，在模型层面体现车联网环境下感知增强决策机制，建立起无人机轨迹数据与车联网场景之间的有效联系。

在模型构建方面，本章节设计了两种集成架构：串行架构与并行架构。其中，串行架构通过先由 LSTM 提取短时行为特征，再由 Transformer 捕捉长时依赖信息，从层次上增强特征的时间感知能力；并行架构则利用双分支结构同时建模短时与长时特征，后续通过自注意力机制进行特征融合，以提升模型对多尺度信息的感知能力。在此基础上，引入动态权重计算模块，通过学习施工区环境特征与子模型性能之间的关系，完成子模型决策结果的权重优化融合，从而实现跨场景换道预测。

本章节以前文采集的高速公路施工区轨迹数据为基础，构建多场景换道数据集，通过对模型进行多工况训练与验证，系统评估所提方法在不同施工封闭区域、不同交通压力状态下的换道预测性能。

施工区换道行为的本质差异不仅源于驾驶员的个体风格，还与其所处的道路环境

密切相关。不同类型的施工场景对驾驶行为的影响具有明显的结构性差异，例如左侧封闭区域中普遍发生向右并道、右侧封闭区域中需避让超车道快速车流，而上游警告区则存在大量换道时机和时点上的不确定性。在场景驱动的换道行为背景下，传统单一预测模型难以兼顾多种工况下的行为特征差异，容易导致模型性能在非适用场景中急剧下降。

为解决这一问题，本文构建了基于分场景建模与动态融合机制的两层结构预测模型，如图 4-1 所示。具体而言，针对左侧封闭过渡区、右侧封闭过渡区和上游警告区典型施工场景类型分别构建三个换道意图预测子模型，每个子模型聚焦于建模本场景下的换道特征分布与行为模式，形成具有专属性的预测子网络结构。针对常见的施工场景类型分别构建对应的换道意图预测子模型，以充分挖掘各场景下驾驶行为的差异性特征。随后，设计场景识别模块，根据实时采集的道路结构与交通状态信息判断当前所处的施工环境，并将环境特征输入动态融合模块，动态分配各子模型的融合权重，实现针对不同施工情境的自适应预测。




图 4-1 多场景识别与融合的换道预测模型结构示意图

在推理阶段，系统首先通过环境识别模块提取当前场景的施工类型、封闭方向、车道数变化、车流速度与密度等特征，输入至融合机制中，根据动态计算出的子模型权重，对各子模型输出的换道预测结果进行加权融合，最终生成车辆当前的换道意图判定结果。该自适应融合策略不仅能够充分利用各子模型在其特定场景下的建模优势，还有效克服了单一模型在跨场景泛化能力弱的问题，提升了系统在动态交通环境中的稳定性与适应性。

在子模型结构方面，探索了两种基于深度时序建模的融合架构：串行 LSTM-Transformer 架构与并行 LSTM-Transformer 架构。这两种结构分别从层次建模与特征互补的角度出发，集成了 LSTM 对短期动态的高效建模能力与 Transformer 在捕捉长时依赖关系方面的优势，为不同施工场景下的子模型提供了灵活且强大的建模支撑。

4.2 双层 LSTM-Transformer 换道预测模型

4.2.1 双层 LSTM-Transformer 模型

本文构建了一种融合双层长短期记忆网络（LSTM）与 Transformer 架构的混合模型，旨在实现对车辆换道意图的高精度预测。借助该模型，能够同步完成对短时特征与长时特征的建模，进而显著提升模型的分类性能。具体而言，本文对两种架构展开深入探究：串行架构与并行架构。

在串行架构中，首先利用 Transformer 架构对车辆的全局轨迹变化趋势进行深度建模，通过自注意力机制学习车辆在较长时间尺度下的行驶状态，包括与周边车辆的长时交互关系等长时依赖信息。随后，借助双层长短期记忆网络（LSTM）对经 Transformer 初步处理后的信息进行进一步挖掘，重点提取车辆速度的实时变化、短期内轨迹的细微调整以及与周边车辆的即时交互等短时依赖信息。将经过不同层次处理的特征信息输入全连接层，完成对车辆换道意图的分类任务，串行结构如图 4-2 所示。这种架构充分发挥了 Transformer 在处理长时依赖关系方面的优势，同时结合 LSTM 对短时特征的有效捕捉能力，使得整体模型既能够把握全局态势，又能关注到瞬间变化。由于其计算流程相对简洁，计算复杂度较低，能够满足实时性要求较高的换道意图预测场景。




图 4-2 串行结构下的双层 LSTM-Transformer 换道决策模型框架

在并行架构中，交通数据采集后，同时输入双层 LSTM 与 Transformer 模型，模型

结构如图 4-3 所示。双层 LSTM 主要用于捕捉车辆行驶状态与交通环境的短期动态变化，如车辆速度、间距的短时间波动；Transformer 则专注于挖掘数据中的全局信息和长时依赖关系。随后采用自注意力机制对两个分支的计算结果进行融合。自注意力机制能够使模型在融合过程中，关注到两个分支不同位置信息间的关联，从而更有效地融合短时和长时特征。融合后的特征经全连接层完成最终分类。该架构能够充分保留 LSTM 与 Transformer 各自提取的特征信息，显著提升换道意图预测的准确率，并且能较好地适配不同驾驶风格下的换道行为，如短时急躁换道和长时渐进式换道。不过，此架构存在计算量高于串行架构、训练数据需求量大以及需额外进行参数调优等问题。




图 4-3 并行结构下的双层 LSTM-Transformer 换道决策模型框架

考虑到高速公路施工区内不同施工环境对车辆换道行为产生显著且多样化的影响，模型若以单一场景建模将难以适应实际复杂工况。例如，在左侧车道封闭的过渡区域，车辆普遍向右并入，导致右侧车道压力骤增、换道空间收紧；在右侧车道封闭情形下，车辆需向左并线，但左侧多为超车车道，换道行为不仅需更加谨慎，还易干扰高速通行车辆；而在上游警告区，部分驾驶员提前换道，部分则延迟换道，造成行为分布高度不确定。因此，构建统一预测模型难以兼顾多种换道场景的行为差异。

为提升模型在多种施工环境下的适应性与泛化能力，本文进一步提出了动态权重计算模块，作为多场景子模型融合的核心机制。该模块通过实时获取施工区环境信息，学习不同场景下各子模型的最优权重分布，实现对各场景子模型的动态加权融合，以

增强换道决策的鲁棒性与精度。

具体而言,该模块以封闭车道信息、交通流状态以及道路拓扑特征等作为输入变量,构成环境特征向量。通过全连接神经网络对这些多维特征进行建模,学习环境与孩子模型性能之间的非线性关系,并输出三个子模型(左侧封闭场景模型、右侧封闭场景模型、上游警告区模型)对应的权重。为保证权重具备可解释性与可融合性,模块采用 Softmax 函数对权重结果进行归一化处理,确保权重总和为 1。

在推理阶段,根据动态权重计算模块的输出结果,对各子模型的换道预测结果进行融合,融合策略包括加权求和或概率加权融合,从而实现对车辆当前换道意图的全局最优判定。该模块的引入,进一步强化了模型在不同施工情境下的预测精度,克服了单子模型在非目标场景中预测性能下降的缺陷,确保在动态复杂环境下,系统依旧能够作出可靠、稳定的换道辅助决策。

1. 双层 LSTM 模块设计

LSTM 是一种能够有效捕捉长序列依赖关系的循环神经网络(RNN),专门用于处理时间序列数据。相比于传统 RNN, LSTM 通过输入门、遗忘门和输出门的门控机制,有效解决了长时间依赖问题中的梯度消失和梯度爆炸问题,使得模型在较长时间跨度内仍能保持有效的信息传播。在进行高速公路施工区换道预测时,车辆的轨迹数据呈现出明显的时间依赖性,换道的决策往往取决于过去若干个时间步内的动态信息。

LSTM 主要由三个门控单元(Gate)和一个记忆单元(Cell State)组成,每个时间步的输入会经过图 4-4 所示的计算:




图 4-4 LSTM 神经网络节点计算示意图

遗忘门(Forget Gate): 用于决定当前时刻应该舍弃哪些过去的信息。其计算方式如下:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (4.1)$$

其中, f_t 是遗忘门的输出, W_f 和 b_f 为训练参数, h_{t-1} 是上一时间步的隐藏状态, x_t 是当前输入, σ 代表 sigmoid 激活函数。

输入门(Input Gate): 用于决定当前时刻应添加哪些新信息到记忆单元:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (4.2)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (4.3)$$

其中, i_t 控制新信息的权重, $\tilde{C}_t$ 代表新的候选记忆单元状态。

更新记忆单元 (Cell State):

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (4.4)$$

这里 C_t 代表当前时刻的记忆状态，它结合了部分旧的记忆信息和新的输入信息。

输出门 (Output Gate): 用于决定当前时刻的隐藏状态:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (4.5)$$

其中， o_t 控制隐藏状态的输出部分，而 h_t 作为当前时间步的最终隐藏状态被传递至下一时间步。

而双层 LSTM 在传统 LSTM 的基础上增加了一层 LSTM 结构，使其能够以层次化的方式处理时间序列数据。每一层 LSTM 都包含输入门、遗忘门、输出门以及记忆单元，这些组件协同工作，有效解决了传统 RNN 存在的梯度消失和梯度爆炸问题，从而能够更好地捕捉数据中的长期依赖关系。

在车联网环境下的高速公路施工区换道意图识别任务中，双层 LSTM 的第一层主要负责对原始输入数据，如车辆速度、轨迹变化以及与周边车辆的即时交互信息等等进行初步处理，提取出较为基础的短时特征。这些特征包含了车辆在短时间内的动态变化情况。接着，第二层 LSTM 基于第一层提取的特征，进一步挖掘更深层次的短时依赖关系，能够从更宏观的角度对车辆在短时间内的行为模式进行理解和归纳，结构如图 4-5 所示:




图 4-5 双层 LSTM 网络结构

相较于单层 LSTM，双层 LSTM 具有更强的特征学习能力，能够对复杂的时间序列数据进行更深入的特征提取，从而为后续的模型任务提供更丰富、更具代表性的特征信息。在高速公路施工区这种环境复杂、干扰因素众多的场景下，双层 LSTM 能够更有效地捕捉车辆行为的细微变化，为准确识别车辆换道意图奠定坚实基础。

2. Transformer 模块设计

尽管 LSTM 能够捕捉时间序列关系，但仍然存在信息传递的依赖性问题。为了进一步优化时序建模能力，本文结合 Transformer 结构，利用自注意力机制建模车辆行为

的全局关系。与 LSTM 不同，Transformer 通过多头注意力并行关注多个时间步的信息，从而提高换道预测的稳定性和鲁棒性。相比于传统的循环神经网络（RNN）和长短时记忆网络（LSTM），Transformer 通过自注意力（Self-Attention）机制捕捉序列中的全局依赖关系，避免了序列化计算带来的效率瓶颈。本文在换道预测任务中引入 Transformer 结构，以提高模型对长时间依赖关系的建模能力。

（1）多头注意力机制

多头自注意力机制是 Transformer 结构的核心组件，其主要作用是通过多个注意力头同时关注输入序列的不同部分，从而增强模型对复杂关系的表达能力。在换道预测任务中，不同时间步的车辆运动特征可能对最终的换道决策产生不同影响，因此使用多头自注意力可以确保模型能够同时捕捉多个时间步的关键信息，提高对换道模式的建模能力。多头自注意力的计算包括输入投影、计算注意力分数和多头计算三个关键过程

投影输入主要将输入时间序列 X 通过线性变换映射到查询、键、值矩阵：

$$Q = XW_Q, K = XW_K, V = XW_V \quad (4.6)$$

其中， W_Q, W_K, W_V 是可训练参数矩阵。在模型训练过程中，它们会不断调整自身参数，使得生成的 Q 、 K 、 V 矩阵能够最大程度地包含对后续注意力计算和换道意图预测有价值的信息。 Q 矩阵可以看作是模型对当前时刻车辆状态信息的一种“询问”表示； K 矩阵是用来匹配和查找相关信息的“索引”； V 矩阵包含了实际用于后续计算和决策的关键信息。

计算注意力分数需要计算查询向量 Q 与键向量 K 的点积，为了防止在计算点积时，由于维度较高导致梯度过大或过小，影响模型的训练和收敛，需要对其进行缩放：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (4.7)$$

其中， d_k 为键向量的维度，使用 $\sqrt{d_k}$ 进行缩放可以防止梯度过大或过小。通过 softmax 函数对计算结果进行归一化处理，得到每个位置的注意力权重，这些权重表示了当前位置与其他位置之间的关联程度。

多头计算则是采用多个独立的注意力头，每个注意力头计算不同的权重分布，并拼接最终的输出：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h)W_O \quad (4.8)$$

其中， W_O 是输出变换矩阵。用于将多个注意力头的输出进行整合。不同的注意力头可以关注输入序列的不同方面，从而从多个角度对时间序列数据的依赖关系进行建模，提高换道预测的准确性。

(2) 位置编码

由于 Transformer 结构本身不具有序列信息，而换道预测任务依赖于时间步之间的时序关系，因此需要额外引入位置信息。本文采用 正弦-余弦位置编码，其计算公式如下：

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{\frac{2i}{d}}}\right) \quad (4.9)$$

$$PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{\frac{2i}{d}}}\right) \quad (4.10)$$

其中， pos 为时间步索引，表示当前数据点在序列中的位置； d 为隐藏层维度，确保不同维度的编码具有不同的周期性。

位置编码在 Transformer 结构中的主要优点体现在多个方面。首先，它能够有效引入时间序列信息，弥补 Transformer 结构本身缺少顺序信息的缺陷，使得模型能够感知数据的时间特性，从而更准确地处理时序依赖关系。其次，位置编码采用正弦和余弦函数进行计算，其周期性确保了不同时间步的编码不会相互冲突，从而使时间步的表示更加平滑，增强了模型对长时间序列数据的适应能力。此外，位置编码的计算方式是基于固定公式实现的，无需额外的学习参数，相较于可训练的位置编码方法，其计算过程更加稳定，并且不会引入额外的参数冗余。在换道预测任务中，车辆的历史轨迹对于当前时刻的决策具有重要影响，而 Transformer 通过位置编码可以正确地捕捉时间步之间的顺序关系，使得注意力机制能够更加精准地建模轨迹数据的时间依赖特性，从而提升换道行为预测的准确性。

4.2.2 场景识别驱动的子模型加权融合策略

在高速公路施工区这一复杂动态场景下，道路结构、封闭方向及交通流状态的多样性对车辆换道行为产生显著影响。在左侧两车道封闭的过渡区域中，车辆需向右并入，右侧车道拥挤度骤升，换道窗口受限；在右侧车道封闭的情况下，车辆需向左变道进入快车道，需避免与高速车辆发生冲突，换道行为更为谨慎；而在上游警告区，部分驾驶员提前变道，部分则选择延迟变道，导致行为时点高度离散。面对这种工况差异性强、行为异质性高的换道决策背景，本文构建了基于场景识别的子模型融合机制，实现对多种典型施工区环境下换道意图的预测。

1. 场景权重计算模块设计

为了实现不同施工环境下模型输出的自适应融合，本文提出了基于场景识别的权重计算模块。该模块以当前施工环境状态为输入，通过神经网络自动学习环境特征与

子模型性能之间的非线性关系，输出三个子模型的权重系数，进而在推理阶段指导预测结果的加权融合。模块输入涵盖多维度变量，在封闭车道信息方面，通过施工区封闭位置 Type 确定封闭方位；交通流量信息中，当前车道车辆密度（车辆数量与道路长度比值）和平均速度直观反映交通状况；道路拓扑特征包含车道类型（警告区 / 过渡区）与施工区域长度，直接影响换道规则和换道窗口；引入输出置信度，其通过子模型对输入样本的 softmax 分布熵量化模型判断的稳定性与确定性，作为基于模型置信度进行权重调节的核心依据。这些环境信息可借助高速公路传感器网络、自动驾驶汽车传感器实时采集并传输至模块。模块输入包括多个影响换道行为的关键变量，具体维度如表 4-1 所示：

表 4-1 动态权重计算模块输入特征维度

变量类别	变量名称	变量描述
封闭车道信息	施工区封闭位置 Type	指明施工区封闭的具体位置（左侧/右侧）。
交通流量信息	当前车道车辆密度	当前车道上的车辆数量与道路长度的比值，反映交通流量状况。
	当前车道平均速度	计算当前车道车辆的平均速度，衡量交通流畅性。
道路拓扑特征	车道类型	当前车道的类型（警告区/过渡区），影响换道规则。
	施工区域长度	施工区的总长度，决定换道窗口大小。
子模型响应特征	输出置信度	子模型对当前输入样本的 softmax 分布熵，衡量模型判断的稳定性与确定性

环境信息可借助高速公路的传感器网络、自动驾驶汽车传感器等方式进行实时采集，并及时输入至场景权重计算模块。

为精准确定不同子模型在当前施工环境中的适用性，权重计算模块采用神经网络建模，其核心是全连接网络，旨在深度学习施工环境与子模型权重之间的复杂关系。具体而言，该模块包含输入层、隐藏层和输出层三个关键组件。输入层负责接收施工环境特征向量 x_{scene} ，将采集到的环境信息转化为神经网络可处理的形式。隐藏层负责运用全连接网络对施工环境信息进行深度提取，并巧妙映射到子模型权重空间，挖掘环境特征与权重之间的潜在联系。输出层需要生成 3 个子模型的权重 w_1, w_2, w_3 ，分别对应左侧封闭、右侧封闭和上游警告区的子模型，为后续的加权融合提供依据。

接着使用Softmax归一化来确保权重总和为1，即 $w_i = \frac{e^{z_i}}{\sum_{j=1}^3 e^{z_j}}, i = 1,2,3$ 。其中 z_i 是全连接网络的输出值，通过 Softmax 归一化，可使权重符合概率分布，保证所有子模型权重总和始终为 1，使加权融合更加合理。

该模块的网络结构可表示为：

$$w = \text{Softmax}(\text{ReLU}(W_2 \cdot \text{ReLU}(W_1 \cdot x_{scene} + b_1) + b_2)) \tag{4.11}$$

其中：

W_1, W_2 是网络的可训练参数，通过不断学习调整，以优化权重计算。

b_1, b_2 是偏置项，用于增加模型的灵活性和适应性。

ReLU (Rectified Linear Unit) 激活函数用于引入非线性，有效提高模型的表达能力，使其能够更好地拟合复杂的环境与权重关系。

Softmax 归一化确保权重可用于场景加权融合，为最终的决策提供准确的权重分配。

场景权重计算模块采用监督学习方式训练，训练数据主要来源于不同施工场景的真实换道数据。训练目标是使动态权重计算模块的输出权重尽可能匹配真实环境下不同子模型的最优权重分布，即最小化损失函数：

$$\mathcal{L} = \sum_{i=1}^N ||w_i^{\text{pred}} - w_i^{\text{true}}||^2 \quad (4.12)$$

其中：

w_i^{pred} 是模型预测的权重，代表模型当前的输出结果。

w_i^{true} 是基于真实数据计算出的最优权重，作为模型训练的参考标准。

通过梯度下降法优化该损失函数，使权重计算模块能够在实际环境中生成合理的动态权重，不断提升模型的准确性和适应性。

在推理阶段，根据动态权重计算模块的输出，对不同子模型的换道决策进行加权融合，从而获得最终的换道预测结果。

2. 子模型输出融合策略

假设左侧封闭、右侧封闭和上游警告区的子模型分别输出换道决策：

$f_{\text{left}}(x)$ —— 左侧封闭过渡区子模型输出的换道决策概率。

$f_{\text{right}}(x)$ —— 右侧封闭过渡区子模型输出的换道决策概率。

$f_{\text{warning}}(x)$ —— 上游警告区子模型输出的换道决策概率。

则最终的加权融合输出为：

$$\text{haty} = w_1 \cdot f_{\text{left}}(x) + w_2 \cdot f_{\text{right}}(x) + w_3 \cdot f_{\text{warning}}(x) \quad (4.13)$$

其中：

w_1, w_2, w_3 为动态计算出的场景权重，根据实时环境信息动态调整。

$f(x)$ 代表相应子模型的预测结果，通过加权融合，综合考虑不同场景下子模型的优势。场景加权融合层选择使用加权求和用于换道决策分类任务：

$$y = w_1 \cdot y_1 + w_2 \cdot y_2 + w_3 \cdot y_3 \quad (4.14)$$

其中 y_i 为第 i 个子模型的换道预测类别（换道 / 不换道）。

4.2.3 模型训练与优化

在完成双层 LSTM - Transformer 架构（包括串行架构和并行架构）的搭建后，模型

训练与优化成为确保模型性能的关键环节。本研究使用反向传播算法对模型进行训练，该算法能够高效地计算模型的梯度，从而实现对模型参数的更新，使模型不断学习输入数据与换道决策之间的映射关系。

训练过程中，采用了 Adam 优化器对模型参数进行更新。该优化器综合了 Adagrad 和 RMSProp 的优点，具有自适应调整每个参数学习率的能力，能够有效应对梯度稀疏和非平稳目标函数的问题。本研究在高速公路施工区换道辅助决策的场景下，针对不同模型训练阶段的需求，设置初始学习率为 $1e-3$ ，并在训练过程中采用学习率调度策略，当验证集性能趋于稳定时，自动将学习率以 0.5 的比例递减，直至最低 $1e-5$ ，以平衡收敛速度与稳定性。

为避免过拟合，训练中引入了早停策略。当模型在验证集上连续 8 轮训练 (epoch) 未出现损失下降时，自动终止训练。本研究在每次训练中均划分 20% 的样本作为验证集，确保模型不仅在训练集上表现良好，更具备在未见数据上的推广能力。

针对模型架构中的关键超参数，包括 LSTM 层隐藏单元数量（尝试范围：64、128、256、512）、Transformer 多头注意力的头数（尝试范围：4、8、12）、学习率（尝试范围： $1e-2$ 至 $1e-5$ ）及批次大小（尝试范围：32、64、128），本研究采用“随机搜索 + 网格搜索”的混合策略进行调参。通过在 50 组超参数组合中进行并行训练与评估，并结合交叉验证方式，最终确定串行结构中 LSTM 隐藏单元为 256，Transformer 头数为 8；并行结构中 LSTM 隐藏单元为 128，Transformer 头数为 12，在准确率、召回率和 F1 分数上均取得最优表现。

本章节所使用的数据依托于第二章所获取的换道轨迹数据以及第三章分析得到的驾驶人驾驶行为分类结果。参考现有研究中对换道过程的划分方式与本研究的分析结果，将换道决策点的瞬时数据，作为构建换道车辆决策模型的关键数据来源。

4.3 实验设计与实验结果分析

4.3.1 实验方案设计

为全面评估基于双层 LSTM-Transformer 架构的换道辅助决策模型在不同施工区环境下的适用性与优越性，本研究构建了分场景训练与动态权重赋值相结合的策略，并与传统换道决策模型进行对比分析，旨在探究该模型在左侧封闭、右侧封闭等不同施工封闭条件下的泛化能力与决策效果。

在高速公路施工区换道场景中，不同施工区域的交通流特征和换道行为模式存在显著差异。为增强模型在不同施工环境下的适应性与泛化能力，本研究针对封闭左侧两车道的过渡区、封闭右侧两车道的过渡区以及其在警告区、过渡区上游、过渡区中游、过渡区下游场景分别训练换道决策模型，并在推理阶段采用动态权重赋值策略以

适应实际道路环境变化。

在不同场景的数据集上训练基于双层 LSTM-Transformer 的换道预测模型，使其适应各自环境约束和换道模式；并在模型结构中加入场景特征编码，使模型能够识别当前环境的施工状态并据此调整策略。

1. 换道预测模块

将本文模型与支持向量机 (SVM)、决策树 (Decision Tree)、单一 LSTM 模型进行对比分析。SVM 基于最优分类超平面通过换道特征数据预测换道可行性；决策树利用递归分割方式根据车辆状态和施工环境建立层级决策规则；单一 LSTM 模型用于学习时间序列数据的动态特征以建模车辆换道意图。实验将高速公路施工区换道数据集按照 70%、15%、15% 的比例划分为训练集、验证集和测试集，确保数据代表性和泛化性。所有模型采用相同训练超参数，如学习率、批次大小、训练轮数等，以保证实验结果公平性。

2. 动态权重计算模块

在推理阶段，通过车辆位置信息、道路拓扑以及施工区标志数据确定当前车辆所处施工场景，根据环境识别结果对不同场景的换道决策模型赋予不同权重，如车辆处于封闭左侧两车道的过渡区时该场景模型权重较高，处于上游警告区时结合警告区模型和相邻过渡区模型决策结果动态调整权重，最后通过加权融合各场景模型的预测结果输出换道决策。本研究采用全连接神经网络训练该模块，输入层以施工环境特征 x_{scene} 作为输入，隐藏层运用 ReLU 激活函数的全连接网络结构，输出层输出 3 维向量 $[w_1, w_2, w_3]$ ，通过 Softmax 归一化确保权重之和为 1，即：

$$w_i = \frac{e^{z_i}}{\sum_{j=1}^3 e^{z_j}}, i = 1, 2, 3 \quad (4.15)$$

训练设置方面，选用均方误差 (MSE) 作为损失函数，采用 Adam 优化算法，学习率设为 0.001，运用监督学习结合梯度下降法，设定 batch size 为 32，训练轮数为 100。

对比实验包含静态权重模型，即设定固定权重 $w_1 = w_2 = w_3 = 1/3$ ，对所有子模型等权加权，动态权重模型则运用训练得到的预测权重 w_{pred} 进行加权融合，还有单子模型实验，分别利用 $f_{\text{left}}(x)$ 、 $f_{\text{right}}(x)$ 、 $f_{\text{warning}}(x)$ 独立决策并计算准确率。

4.3.2 数据预处理

1. 基于 cKDTree 的车辆环境信息匹配

在交通系统中，车辆的换道行为是一个复杂的过程，其决策不仅取决于自身的运动状态，还受到周围车辆的显著影响。准确提取换道前后的环境信息对于深入理解换

道行为至关重要。为此,本文引入了基于 cKDTree 的空间索引方法,以高效地匹配换道车辆的周围环境信息。cKDTree 是一种高效的 k 维树方法,专门用于多维空间中的最近邻搜索。它通过将 k 维空间划分成多个超矩形区域,实现快速排除大量不相关的点,从而在搜索邻近点时大幅提高效率。具体的构建过程如下:

(1) 选择划分轴:从当前数据集中选择方差最大的维度作为划分轴。这一步骤的目的在于找到数据变化最大的方向,以便更好地进行空间划分。

(2) 数据排序与确定根节点:按照选定的维度对数据进行排序,并选择中位数点作为根节点。这样可以确保根节点将数据大致分为两个相等的部分,为后续的递归划分奠定基础。

(3) 递归划分:递归地对左右子集分别重复上述过程,直到所有点被划分完成。在每一次递归中,都选择当前子集中方差最大的维度进行划分,并确定新的子节点。通过不断地重复这个过程,最终将整个数据集构建成一个层次化的树结构。

在进行最近邻搜索时,cKDTree 采用了以下步骤:

(1) 确定查询点所在区域:从根节点开始,确定查询点所在的超矩形区域。这一步骤通过比较查询点与各个节点的划分维度值,逐步缩小查询范围,确定查询点所在的具体区域。

(2) 计算距离与存储临近点:分别计算查询点与当前节点的距离。使用优先级队列存储最近的 k 个临近点。优先级队列按照距离从小到大的顺序存储点,确保始终能够快速获取最近的 k 个点。

(3) 回溯检查:通过回溯过程检查是否有可能存在更近的点,确保返回最优解。在回溯过程中,检查已经访问过的节点的相邻区域,看是否存在比当前最近的 k 个点更近的点。如果存在,则更新优先级队列,继续回溯检查,直到确定没有更近的点为止。

通过 cKDTree 进行最近邻搜索,相较于直接遍历所有车辆,查询速度大幅提升。尤其在大规模轨迹数据集中,能够有效降低计算复杂度,为换道行为分析提供高效的计算支持。

使用提取出的换道车辆的完整轨迹数据构建车辆集合,并利用 cKDTree 进行最近邻搜索。对于每一个时间步,从轨迹数据中提取该时刻的所有其他车辆,并分别构建当前车道和目标车道的车辆集合。这样可以将换道车辆周围的车辆按照所在车道进行分类,便于后续分析换道车辆与不同车道上车辆的相互关系。在当前车道中构建 cKDTree 结构,并查询换道车辆在该车道上最接近的前后车辆。同样地,在目标车道中构建 cKDTree 结构,以找到换道车辆在目标车道上的前后车辆。通过这种方式,可以快速准确地确定换道车辆在不同车道上的相邻车辆,为分析换道行为提供重要的环境信息。在匹配过程中,分别记录了换道车辆与其前后车辆之间的距离和速度信息,

包括当前车道与目标车道前后车辆信息。

最终，所有换道车辆在换道过程中每个时间步的环境信息被存储至数据集中。这些环境信息将作为后续深度学习模型的输入特征，用于进一步分析和预测换道行为。

2. 基于递归特征消除的特征筛选策略

为剖析不同特征之间的内在关联，选取对换道决策预测最具价值的特征，本研究采用基于递归特征消除的特征筛选策略。在进行特征消除前首先进行特征相关性分析，以识别数据中潜在的多重共线性问题，进而筛选出信息冗余度较低的特征用于模型训练。为全面洞悉换道决策数据集中各变量间的交互作用以及单独分布特性，开展了详尽的散点图矩阵分析。数据集中所有关键变量的分布图如图 4-5 所示。




图 4-5 特征间关系的散点图矩阵

对角线上的直方图展示了各变量的频率分布状况。以变量 **Speed** 为例，其呈现出单峰且略微偏态的分布特征，这意味着大部分观测值围绕某一中心值集中分布，同时存在少量极端值。部分散点图，如 **current_front_distance** 与 **current_back_distance**，呈现出分组现象，数据点围绕几个不同中心聚集。这种分布模式可能对应不同的驾驶行为类型或道路条件。而除了通过散点图矩阵直观地分析特征关系外，还可以从量化的角度来评估特征间的相关性。图 4-6 展示了从数据集中计算得出的特征相关性矩阵。矩阵中每个元素代表两个特征之间的相关性系数，系数值范围从 -1 到 +1。




图 4-6 特征相关性矩阵

如图所示，速度与车辆的水平速度和垂直速度具有较高的相关性，这表明速度变量可能已包含 vx 和 vy 的相关信息。

为进一步提升模型性能，确保输入特征具备有效性与准确性是关键所在。本文选用递归特征消除方法开展特征筛选工作。RFE 作为一种依托机器学习模型的特征选择技术，其核心优势在于能够以迭代的方式逐步剔除对预测任务而言不重要的特征，进而精准保留对换道意图预测最为关键的特征集合，为后续模型训练奠定坚实基础。

RFE 的运行流程包含以下几个关键步骤：

(1) 初始化基模型：本研究选用随机森林分类器作为特征评估器。随机森林分类器具有诸多显著优势，一方面，它能够精确衡量各个特征的重要性程度；另一方面，在面对高维数据时，依然能够保持良好的处理能力，同时展现出出色的泛化能力，有效避免模型过拟合现象，确保模型在不同数据集上均能维持稳定的性能表现。

(2) 训练初始模型：运用全部输入特征对随机森林分类器展开训练。在训练过程中，通过特定的算法和指标，计算得到各个特征在模型中的重要性数值。这些数值将作为后续特征筛选的重要依据，反映出每个特征对换道意图预测的贡献程度。

(3) 迭代特征消除：在每一轮迭代操作中，依据上一轮训练得到的特征重要性数值，将当前模型中重要性最低的特征予以移除。随后，基于剩余的特征重新对随机森林分类器进行训练，再次计算新特征集合中各个特征的重要性，为下一轮迭代提供数据支持。

(4) 确定最终特征集：持续重复上述步骤，直至剩余特征数量达到设定的目标数量。此时所保留的特征，即为对换道意图预测贡献最大、最具区分性的特征，这些特征将被用于后续换道意图识别模型的训练，能够有效提升模型的预测精度和运行效率。

经过 RFE 方法的筛选，结合特征实际含义，最终从初始特征中确定几个最具区分

性的特征，特征如表 4-2 所示。

表 4-2 高速公路施工区换道预测建模特征

特征名称	说明
Type	车辆类型
t	时间步(s)
x	车辆在道路坐标系中的横向位置(m)
y	车辆在道路坐标系中的纵向位置(m)
lane_change	是否为换道决策点（0：否，1：是）
vx	车辆在 x 方向的速度(m/s)
vy	车辆在 y 方向的速度(m/s)
ax	车辆在 x 方向的加速度(m/s ²)
ay	车辆在 y 方向的加速度(m/s ²)
current_front_distance	车辆与当前车道前车的距离(m)
current_back_distance	车辆与当前车道后车的距离(m)
current_front_speed	当前车道前车的速度(m/s)
current_back_speed	当前车道后车的速度(m/s)
target_front_distance	车辆与目标车道前车的距离(m)
target_back_distance	车辆与目标车道后车的距离(m)
target_front_speed	目标车道前车的速度(m/s)
target_back_speed	目标车道后车的速度(m/s)
Cluster	驾驶员驾驶风格

4.3.3 模型性能指标评估

1. 换道预测模块评价指标

本研究从多个维度剖析模型在换道预测任务中的表现。这些指标不仅能够反映模型的分类准确性，还能体现模型在不同应用场景下的可靠性与稳定性，为模型的优化与实际应用提供坚实的数据支撑，本文选择的指标如表 4-3 所示：

表 4-3 分类指标说明

指标名称	定义	作用
准确率	衡量模型整体分类的正确性，即所有正确分类样本占总样本的比例。	反映模型在测试集上的总体预测能力。
精确率	在所有被预测为换道的样本中，真正属于换道类别的比例。	衡量模型预测换道类别的可靠性，降低误报（False Positive）。
召回率	在所有真实换道样本中，被正确预测的比例。	衡量模型对换道行为的检测能力，关注换道事件的识别敏感性。
F1-score	精确率和召回率的调和平均值，综合衡量分类性能。	兼顾精确率与召回率，用于全面评估模型的分类能力。
ROC-AUC 曲线	通过绘制受试者工作特征曲线（ROC），计算曲线下面积（AUC）。	衡量模型在不同阈值下的分类能力，AUC 值越接近 1，表示模型区分换道与非换道类别的能力越强。

(1) 准确率

准确率是衡量模型整体分类正确性的关键指标，它表示所有正确分类样本在总样本中所占的比例，计算公式为：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (4.16)$$

其中，TP代表真正例，即被正确预测为换道的样本数量；TN代表真反例，即被正确预测为非换道的样本数量；FP代表假正例，即被错误预测为换道的非换道样本数量；FN代表假反例，即被错误预测为非换道的换道样本数量。

在高速公路施工区换道预测任务中，准确率直观地反映了模型在大规模数据上的总体预测能力。较高的准确率意味着模型能够准确区分换道和非换道情况，对整体交通状况的判断较为准确。然而，当数据类别不平衡时，准确率可能会掩盖模型对少数类（如换道行为相对较少的情况）的分类能力不足，因此需要结合其他指标进行综合评估。

（2）精确率

精确率衡量的是在所有被预测为换道的样本中，真正属于换道类别的比例，其计算公式为：

$$Precision = \frac{TP}{TP + FP} \quad (4.17)$$

精确率着重体现了模型预测换道类别的可靠性。在高速公路施工区，误报换道信息可能会导致不必要的交通管制或驾驶员的误判，从而影响交通流畅性和安全性。因此，精确率对于减少误报、提高预测的可靠性具有重要意义。较高的精确率表明模型在预测换道时能够较为准确地识别真正的换道样本，降低错误预警的概率。

（3）召回率

召回率，也称为查全率，是指在所有真实换道样本中，被正确预测的比例，计算公式为：

$$Recall = \frac{TP}{TP + FN} \quad (4.18)$$

召回率主要关注模型对换道行为的检测能力，反映了模型对换道事件的识别敏感性。在高速公路施工区，及时准确地检测到换道行为对于保障交通安全至关重要。如果召回率较低，可能会导致部分换道行为未被检测到，从而增加交通事故的风险。因此，高召回率能够确保模型尽可能捕捉到所有实际发生的换道事件，为交通管理和安全保障提供有力支持。

（4）F1 值

F1 值是精确率和召回率的调和平均值，它综合了精确率和召回率的优点，能够更全面地评估模型的分类性能，计算公式为：

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (4.19)$$

在实际应用中，精确率和召回率往往存在相互制约的关系，单纯追求高精确率可能会导致召回率降低，反之亦然。F1 值通过对两者的调和，为模型性能评估提供了一个更为平衡和综合的指标。较高的 F1 值意味着模型在可靠性和检测能力方面都表现出色，能够在不同应用场景下保持较好的性能。

(5) ROC - AUC 曲线

ROC 曲线是一种以假阳性率（FPR, False Positive Rate）为横坐标，真阳性率（TPR, True Positive Rate）为纵坐标绘制的曲线。假阳性率表示在所有实际为非换道的样本中，被错误预测为换道的比例，即：

$$FPR = \frac{FP}{FP + TN} \quad (4.20)$$

真阳性率表示在所有实际为换道的样本中，被正确预测为换道的比例，即：

$$TPR = \frac{TP}{TP + FN} \quad (4.21)$$

AUC 则是 ROC 曲线下的面积，其取值范围在 0 到 1 之间。

ROC - AUC 曲线能够全面衡量模型在不同阈值下的分类能力。AUC 值越接近 1，表明模型区分换道与非换道类别的能力越强，即模型在不同决策阈值下都能保持较好的分类性能。在实际应用中，模型输出的往往是一个概率值，通过设置不同的阈值来判定样本是否为换道。ROC - AUC 曲线可以帮助我们直观地了解模型在不同阈值设置下的性能变化，从而选择最优的决策阈值，提高模型的实际应用效果。

2. 动态权重计算模块评价指标

针对动态权重计算模块，选择使用 MSE 用于衡量预测权重 w_{pred} 与真实权重 w_{true} 之间的误差，误差值越小模型性能越优；并使用换道预测准确率来评估动态加权融合后的换道预测准确性。

4.3.4 实验结果分析

1. 换道预测模块实验结果

本研究对五种模型（SVM、决策树、单层 LSTM、串联 LSTM - Transformer、并联 LSTM - Transformer）在三个施工场景（左侧封闭过渡区、右侧封闭过渡区、上游警告区）下的性能进行了全面评估，实验结果呈现了各模型在不同施工场景下各项指标的具体数值，见表 4-4。

表 4-4 换道预测模型实验结果

模型	场景	Accuracy (%)	Recall (%)	F1-score (%)	RMSE	AUC	训练时间(s)
SVM	左侧封闭过渡区	79.6	76.8	78.2	0.264	0.821	1.3
决策树		81.2	78.5	79.8	0.251	0.835	1.1
单层 LSTM		86.4	84.7	85.5	0.195	0.892	5.8
串联 LSTM-Transformer		89.5	91.2	90.3	0.142	0.917	12.5
并联 LSTM-Transformer		91.8	93.5	92.6	0.119	0.935	9.7
SVM	右侧封闭过渡区	78.2	74.5	76.3	0.279	0.812	1.4
决策树		80.5	77.2	78.8	0.265	0.829	1.2
单层 LSTM		85.1	82.9	84	0.21	0.881	5.9
串联 LSTM-Transformer		87.9	89.4	88.6	0.158	0.908	12.8
并联 LSTM-Transformer		90.2	91.7	90.9	0.134	0.926	9.4
SVM	上游警告区	76.5	72.1	74.2	0.301	0.803	1.5
决策树		78.9	74.8	76.8	0.287	0.819	1.3
单层 LSTM		83.2	81.5	82.3	0.228	0.872	6.1
串联 LSTM-Transformer		85.7	88.2	86.9	0.175	0.897	13.1
并联 LSTM-Transformer		88.5	90.1	89.2	0.151	0.915	9.2

在高速公路施工区换道预测研究中，不同模型性能差异显著。从整体表现看，并联 LSTM - Transformer 模型展现出卓越的综合性能。在各施工场景下，其预测精度始终名列前茅，无论是在捕捉真实换道情况的能力，还是平衡准确率与召回率方面，均表现突出。它的预测误差极小，稳定性高，在换道决策分类能力上也远超其他模型。

串联 LSTM - Transformer 模型性能同样较为突出，虽然整体稍逊于并联结构，但在多个关键指标上仍显著优于部分模型，在换道预测中展现出较强实力。

单层 LSTM 模型借助时间序列建模优势，在性能上超越了传统的 SVM 和决策树模型，尤其在处理与时间相关的换道行为数据时，效果显著。

反观 SVM 和决策树模型，面对高速公路施工区复杂的换道行为，在各项关键指标上均处于劣势，充分暴露了传统机器学习方法在处理此类复杂动态问题时的局限性。

从训练时间角度分析，SVM 和决策树虽训练速度快，但性能过低，难以满足实际需求。单层 LSTM 训练时间较长，不过性能提升明显。串联 LSTM - Transformer 训练时间最长，但其高精度性能使其适用于对预测精度要求极高的场景。并联 LSTM - Transformer 则在训练效率和性能之间达到了良好平衡，训练时间相对合理且性能最优。

施工场景的不同对模型性能影响较大。左侧封闭过渡区因换道行为规律性强，各模型表现相对较好，其中并联 LSTM - Transformer 优势显著。右侧封闭过渡区，受车速等因素影响，预测难度增加，模型性能普遍下降，而并联 LSTM - Transformer 依旧领先。上游警告区，换道意图受多种因素干扰，不确定性大，所有模型性能下滑，SVM 和决

策树表现尤为不佳，并联 LSTM - Transformer 则展现出强大的适应性。

综上所述，并联 LSTM - Transformer 在不同施工场景下均展现出全面且卓越的性能，是构建高速公路施工区换道辅助决策方法的理想决策子模型结构。

2. 动态权重计算模块实验结果

换道预测模块选择实验效果较好的的并联 LSTM -Transformer 架构，对单个子模型、静态平均加权、动态权重在换道预测任务上的表现进行分析，来证明采用动态权重计算的必要性，实验结果如表 4-5 所示。单子模型在非适用场景下表现较差，而动态权重计算模型则通过自适应权重调整，实现更高的预测准确率。

表 4-5 不同场景下不同模型架构的准确率结果

模型	左封闭场景准确率 (%)	右封闭场景准确率 (%)	上游警告区准确率 (%)	总体准确率 (%)
单子模型 (左封闭)	91.8	66.8	59.4	66.2
单子模型 (右封闭)	68.1	90.2	57.6	65.6
单子模型 (警告区)	63.5	60.7	88.5	65.4
平均权重加权	79.2	76.8	73.5	76.4
动态权重计算模型	90.8	90.3	89.3	90.1

这些结果表明，单子模型在其目标施工环境下的表现较优，但在非目标施工环境下缺乏泛化能力，导致预测性能大幅下降，说明单子模型难以应对施工区的复杂换道行为变化。采用简单的固定权重融合，模型在整体上也能取得更稳定的预测效果，减少单子模型在非目标施工环境下的预测偏差。而相比于平均加权模型，动态权重计算模型引入了神经网络计算的权重调整策略，根据实时施工环境动态调整不同子模型的贡献度，从而在不同场景下实现更优的换道预测表现。实验结果显示，动态权重计算模型在 所有施工场景下均取得了高准确率，并且总体准确率提升至 90.1%，相比静态权重加权模型提升 13.7%，相比最佳单子模型提升 23.9%。动态权重计算模型能够充分利用施工环境特征进行自适应优化，使得换道预测在所有场景下均保持高准确率，避免了单子模型在非适用场景下的准确率大幅下降问题。

4.4 本章小节

本章围绕高速公路施工区场景下的换道预测问题，提出并实现了一种多场景识别与融合的深度学习预测模型架构，旨在解决施工区域内换道行为模式复杂多变、预测难度显著提升的问题。

在方法构建方面，本章设计了融合双层 LSTM 与 Transformer 的深度预测网络，并结合施工环境特征构建了三类典型场景下的专属子模型，以增强对不同工况下驾驶行为特征的刻画能力。为实现子模型输出的最优融合，进一步提出动态权重计算模块，基于施工区域类型、车道结构、交通状态等特征实现子模型权重的自适应分配，有效提升了模型对多变环境的泛化能力。

在数据处理方面，依托第三章获取的换道轨迹子集与驾驶风格标签，利用 cKDTree 方法实现换道车辆与周边交通环境信息的高效匹配，并结合递归特征消除策略（RFE）完成对换道决策相关变量的筛选，确保输入特征的代表性与建模效率。

在实验评估方面，通过与传统机器学习方法（SVM、决策树）、单一模型结构（单层 LSTM）及不同融合策略（静态权重）进行对比，结果表明本章提出的多场景识别与加权融合机制在各类施工环境下均取得了更优的预测表现，最高准确率达 90.1%，整体性能提升 23.9%，验证了模型在实际复杂施工场景中的实用性与稳定性。

尽管融合模型在多数场景下实现了稳健的预测效果，但由于施工区场景间存在结构与行为模式的显著差异，模型在不同子场景下仍表现出一定性能差异。这一现象也反映出当前阶段构建通用预测模型面临的挑战。为进一步提升模型适应能力，可以以施工环境特征驱动的动态权重调节机制作为改进方向，以期在保持通用框架结构的前提下，增强其对多种典型施工区环境的自适应能力。

本章在第三章驾驶行为分析的基础上，进一步完成了面向复杂施工环境的换道预测建模工作，为后续构建可部署的辅助驾驶系统提供关键的换道判定模块。在接下来的第五章中，将在本章模型输出的换道意图基础上，深入探讨换道行为的风险评估与路径优化策略，实现从意图预测到行为决策的系统闭环。

本页空白

第五章 车联网环境下的高速公路施工区换道决策模型

5.1 基于分层强化学习的换道决策模型构建

施工区换道行为所面临的安全风险远高于普通道路场景，其风险不仅与驾驶员自身风格相关，更受到邻近车辆行为、交通流密度以及换道空间可达性的显著影响。特别是在车道封闭、交通瓶颈与突发作业活动交织的环境下，驾驶员的换道行为可能引发交通冲突、急刹甚至追尾事故^[103,104]。在第四章中，本文提出了一种多场景识别与融合的高速公路施工区换道预测模型，实现了对复杂施工环境中驾驶员换道意图的感知，提升了模型在多变工况下的适应能力与预测性能。这一换道意图的准确判断为自动驾驶系统提供了关键的先验认知，但在此基础上，如何进一步实现智能体对换道行为的策略优化与风险规避，构建系统化的决策能力，是整个系统的关键环节。本章从预测换道意图进一步延伸至决策换道行为，在此基础上，提出了一种面向车联网环境的高速公路施工区换道决策方法。该方法以分层强化学习思想为基础，构建策略决策模块与动作执行模块：前者负责依据环境状态输出换道策略；后者则依据策略结果生成具体的加速度控制动作，确保换道过程的平稳性与安全性。本章所提出的强化学习决策模型在设计状态空间时引入了换道预测概率这一变量，作为对潜在换道需求的前置引导，从而提高智能体在换道行为学习过程中的效率与稳定性。意图实现预测与决策之间的协同融合，使模型不仅能基于当前状态做出最优行为判断，也能兼顾历史行为规律与未来换道趋势。

本章在前述换道意图识别建模基础上，将其集成至车联网协同感知的仿真平台中，构建具备行为先验与信息增强能力的自动驾驶车辆决策模型。具体而言，通过将无人车轨迹数据中训练得到的换道意图预测结果作为强化学习模型的状态输入，模拟车联网环境中车辆通过 V2X 感知得到的“前车意图”信息，从而实现更具前瞻性的智能决策控制机制。该仿真框架结合了数据驱动的人类驾驶特征，并展现了车联网环境下感知增强对提升换道决策效率与安全性的作用。

实验部分将通过 SUMO 仿真平台，分别在不同交通负载条件下评估模型性能，并与 DQN、DDQN、Dueling DQN 等方法进行对比，验证本文方法的优势。

5.1.1 模型架构

在高速公路施工区，由于存在车道收窄、临时障碍、限速区域及邻车行为突变等复杂因素，车辆换道面临更加严峻的安全与效率挑战。传统的基于规则或静态规划的换道方法，难以适应这种动态多变且高风险的环境。为此，本文构建了一种分层强化

学习换道决策模型，将换道任务划分为行为选择与动作执行两个协同子模块，并通过施工区敏感特征建模与奖励机制设计，有效提升模型在复杂环境下的响应能力。

行为选择模块以全局驾驶目标为导向，结合当前环境状态进行宏观动作规划。该模块采用 Dueling DQN 架构，其优势在于能够分别建模状态价值与动作优势函数，从而提升在高不确定性施工环境中的策略评估稳定性。模块输入涵盖车辆速度、车道编号、与前后车辆的距离、是否处于施工区域、施工障碍物距离、剩余可用车道数等状态变量，使智能体具备辨识施工区特征的能力。网络结构首先通过共享层提取状态特征，随后分支计算 $V(s)$ 与 $A(s, a)$ ，最终合成 Q 值，用于指导保持车道、向左或向右换道的策略选择。

动作执行模块则针对策略模块输出的换道意图，执行具体的加速度控制以完成平稳安全的换道过程。考虑到施工区内加速度波动对乘客舒适性和行车安全的更高要求，该模块采用 Policy Gradient 策略梯度方法构建概率控制策略网络。输入包括目标车道编号、车速、目标车道前方车辆距离、当前加速度及是否处于施工区域等，输出为三类控制动作（加速、减速、保持速度）的概率分布。通过采样生成控制动作，并在训练中引入施工区特有的奖励惩罚机制，引导智能体学习在狭窄、限速、易拥堵的施工环境中保持更平滑、稳健的速度调整策略。

总体而言，该模型不仅实现了换道意图与动态控制的分层解耦，还通过在状态建模与奖励设计中嵌入施工场景特征，使模型具备较强的环境自适应能力。在施工区这类高风险道路场景中，策略模块提供全局视角的路径规划，控制模块实现细粒度的加速度响应，两者协同工作，显著提升了换道决策的安全性、通行效率与舒适性。

5.1.2 行为选择模块

1. 网络结构与原理

行为选择模块基于 Dueling DQN 强化学习算法构建，其核心网络结构包括共享特征提取层、状态价值分支与动作优势分支。

共享特征提取层负责对输入的车辆环境状态信息进行初步处理，提取其中的关键特征。这一层通常由多个卷积层或全连接层组成，能够有效地从原始状态数据中提取出有用的信息，为后续的价值和优势计算提供基础。在处理车辆速度、位置等信息时，共享特征提取层可以通过特定的权重和激活函数，将这些信息转化为更抽象、更具代表性的特征向量，以便后续的网络层进行处理。

价值流分支基于共享特征提取层的输出，专门计算状态价值函数 $V(s)$ 。它反映了在当前状态 s 下，智能体所能获得的长期累积奖励的期望，与具体的动作无关，仅依赖于环境状态本身。在高速公路施工区，当车辆处于交通拥堵但暂无明显换道机会的状

态时，价值流分支会根据当前的交通流量、道路状况等信息，评估该状态下的固有价值，为后续的决策提供参考。

优势流分支同样基于共享特征提取层的输出，计算每个动作的优势函数 $A(s, a)$ 。优势函数衡量了在状态 s 下，采取动作 a 相较于平均动作的价值增益，即该动作相对于其他动作的优势程度。在面对前方车辆缓慢行驶的情况时，优势流分支会分别计算向左换道、向右换道和保持车道这三个动作的优势函数，评估每个动作在当前状态下的相对价值。

最终，通过将状态价值函数 $V(s)$ 和优势函数 $A(s, a)$ 进行组合，得到每个动作的 Q 值，即：

$$Q(s, a) = V(s) + A(s, a) - \frac{1}{|A|} \sum_{a_i} A(s, a_i) \quad (5.1)$$

这种分解方式使得 Dueling DQN 能够更精准地捕捉到状态价值和动作优势之间的差异，为智能体的决策提供更丰富、准确的信息。在实际应用中，当 Dueling DQN 计算出向左换道的 Q 值最高时，说明在当前状态下，向左换道相对于其他动作具有更大的价值增益，智能体应选择向左换道。

2. 输入与输出

行为选择模块的输入为车辆当前的驾驶环境状态，这些状态信息是智能体做出换道决策的重要依据。具体包括当前车速、车道位置、车道编号、前方车辆距离和后方车辆距离等。当前车速反映了车辆的行驶速度，它直接影响着换道的安全性和效率。在高速公路施工区，车速过快或过慢都可能增加换道的风险，因此准确获取当前车速对于换道决策至关重要。车道位置和车道编号则明确了车辆在道路上的具体位置，这有助于智能体判断自身所处的交通环境，以及换道的可行性。前方车辆距离和后方车辆距离是衡量换道安全性的关键因素，它们能够让智能体了解周围车辆的分布情况，避免在换道过程中与其他车辆发生碰撞。

根据这些输入信息，Dueling DQN 计算每个动作的 Q 值，并选择最优动作，输出三种换道策略之一：向左换道、向右换道或保持车道。在决策过程中，Dueling DQN 会根据当前的环境状态，综合考虑各种因素，如交通流量、道路状况、车辆之间的距离等，计算每个动作的 Q 值。如果向左换道的 Q 值最高，说明在当前状态下，向左换道是最优的选择，可能是因为左侧车道的交通流量较小，换道后可以提高行驶效率；如果向右换道的 Q 值最高，则说明向右换道更具优势，可能是右侧车道前方的车辆距离较远，换道风险较小；如果保持车道的 Q 值最高，则表明在当前状态下，保持当前车道是最合理的决策，可能是因为周围车辆的分布较为密集，换道可能会增加碰撞风险。

3. 训练机制

为了提高训练的稳定性，行为选择模块采用了多种训练机制，包括经验回放、目标网络机制及 ϵ -greedy 策略。

经验回放机制用于存储历史决策样本，并进行小批量更新，以减少时间相关性对训练的影响。在训练过程中，智能体每执行一个动作，都会将当前的状态、动作、奖励和下一个状态存储在经验回放池中。当需要更新网络参数时，从经验回放池中随机抽取一批样本进行训练。这种方式可以打破样本之间的时间相关性，避免由于连续的相似样本导致的过拟合问题，使得网络能够更好地学习到不同状态下的最优策略。在高速公路施工区的换道决策中，经验回放池可以存储不同交通状况下的换道决策样本，如交通拥堵时的换道决策、道路狭窄时的换道决策等，通过随机抽取这些样本进行训练，智能体可以学习到在各种复杂情况下的最优换道策略。

目标网络机制用于计算稳定的 Q 值目标，避免策略剧烈波动。目标网络是一个与主网络结构相同但参数更新较慢的网络，它用于计算目标 Q 值。在计算目标 Q 值时，使用目标网络的参数来估计下一状态的最大 Q 值，然后结合当前的奖励值，得到目标 Q 值。通过使用目标网络，使得 Q 值的更新更加稳定，减少了由于网络参数频繁更新导致的策略波动，提高了训练的稳定性。在训练初期，主网络的参数变化较大，如果直接使用主网络来计算目标 Q 值，可能会导致目标 Q 值的波动较大，从而影响训练的稳定性。而目标网络的参数更新较慢，能够提供相对稳定的目标 Q 值，帮助主网络更好地收敛。

ϵ -greedy 策略用于在训练过程中兼顾探索和利用，从而提高换道决策的鲁棒性。在选择动作时，智能体以 $1 - \epsilon$ 的概率选择当前 Q 值最大的动作，即利用当前已经学习到的最优策略；以 ϵ 的概率随机选择一个动作，即进行探索，尝试新的策略。在训练初期， ϵ 的值较大，智能体更倾向于探索，这样可以快速地探索不同的换道策略，发现更多的潜在最优解。随着训练的进行， ϵ 的值逐渐减小，智能体逐渐倾向于利用已经学习到的最优策略，提高决策的准确性和稳定性。在高速公路施工区的复杂环境中，通过 ϵ -greedy 策略，智能体可以在探索新的换道策略和利用已有的经验之间取得平衡，提高在不同场景下的换道决策能力。

5.1.3 动作执行模块

1. 网络结构与原理

动作执行模块采用策略梯度网络，其结构为两层全连接神经网络。这种网络结构能够有效地处理输入的车辆状态信息，并输出合理的加速度调整策略。

策略梯度网络的原理基于策略梯度算法，该算法直接对策略进行优化，通过调整策略网络的参数，使得智能体在环境中采取的行动能够最大化长期累积奖励的期望。

在高速公路施工区换道决策的场景中，策略网络以目标车道编号、当前车速、目标车道前方车辆距离和当前加速度等作为输入，这些信息全面地描述了车辆在换道过程中的实时状态。通过第一层全连接层，对输入信息进行初步的特征提取和变换，将原始的状态信息转化为更抽象、更具代表性的特征向量。然后，这些特征向量被输入到第二层全连接层，该层进一步对特征进行处理和融合，最终输出每种控制动作（加速、减速、保持当前速度）的概率分布。

智能体根据这个概率分布选择具体的加速度调整动作，以实现换道过程的平滑和安全。在面对前方车辆距离较近且车速较慢的情况时，策略网络可能会输出较高的减速动作概率，智能体则根据这个概率分布选择减速动作，以避免与前方车辆发生碰撞，同时确保换道过程的平稳性。通过不断地调整策略网络的参数，使得智能体能够根据不同的换道情况，动态地调整加速度，从而提高换道的安全性和舒适性。

2. 输入与输出

动作执行模块的输入涵盖了车辆在换道过程中的关键状态信息和目标信息，这些信息是模块进行决策的重要依据。具体包括目标车道编号、当前车速、目标车道前方车辆距离和当前加速度。目标车道编号明确了车辆换道的目标方向，它决定了智能体后续的决策方向和策略。当前车速反映了车辆当前的行驶速度，这对于判断换道时的速度调整需求至关重要。在高速行驶时，换道所需的加速度调整可能与低速行驶时不同，需要更加谨慎地控制加速度，以避免因速度变化过大而导致的不稳定。目标车道前方车辆距离则提供了换道时的安全距离信息，智能体可以根据这个距离来判断换道的可行性和安全性。如果目标车道前方车辆距离过近，智能体可能需要采取减速或等待的策略，以确保换道过程中不会与前方车辆发生碰撞。当前加速度则描述了车辆当前的加速度状态，它为智能体提供了当前车辆的动力学信息，帮助智能体更好地调整加速度，实现平稳的换道过程。

根据这些输入信息，策略梯度网络计算适合的加速度调整策略，输出的动作包括加速、减速和保持当前速度。具体加速度调整值由策略网络决定，它会根据输入信息和当前的策略参数，计算出每个动作的概率分布，然后智能体根据这个概率分布选择具体的动作。在某些情况下，策略网络可能计算出加速的概率较高，智能体则会执行加速动作，以快速完成换道或调整到合适的速度。在换道过程中，当检测到目标车道前方车辆距离较远且当前车速较低时，策略网络可能会输出较高的加速动作概率，智能体则会选择加速，以提高行驶效率，同时确保换道过程的平稳性。

3. 训练机制

动作执行模块的训练采用策略梯度方法，通过一系列严谨的步骤来优化换道执行策略，使智能体能够学习到最优的加速度调整方案。

训练步骤如下：首先，采样状态 s_t 并计算动作概率；

$$\pi(a_t|s_t) = \frac{e^{f_\theta(s_t, a_t)}}{\sum_{a' \in A} e^{f_\theta(s_t, a')}} \quad (5.2)$$

其中, $f_\theta(s_t, a_t)$ 表示策略网络输出的评分函数, 它根据当前状态 s_t 和动作 a_t 计算出一个评分, 用于衡量该动作在当前状态下的优劣。智能体根据这个概率分布选择动作并执行, 然后获取奖励 R_t :

$$R_t = \sum_{k=0}^{T-t} \gamma^k r_{t+k} \quad (5.3)$$

其中 γ 是折扣因子, 用于衡量未来奖励的重要性, r_{t+k} 是在时间步 $t+k$ 获得的奖励, T 是整个轨迹的长度。这个奖励值综合考虑了换道过程中的安全性、效率性和舒适性等因素, 例如, 如果换道过程中加速度平稳, 没有出现急刹车或急加速的情况, 且成功完成换道, 智能体将获得较高的奖励; 反之, 如果换道过程中出现了危险情况, 如与其他车辆距离过近或加速度变化过大, 智能体将获得较低的奖励。

接着, 计算策略梯度并更新网络:

$$\nabla_\theta J(\theta) = E \left[\sum_{t=0}^T \nabla_\theta \log \pi_\theta(a_t|s_t) R_t \right] \quad (5.4)$$

其中, $\nabla_\theta J(\theta)$ 表示策略梯度, 它反映了参数 θ 的微小变化对累积奖励期望的影响。通过计算策略梯度, 我们可以知道如何调整策略网络的参数 θ , 使得累积奖励期望增加。最后, 更新策略网络参数 $\theta \leftarrow \theta + \alpha \nabla_\theta J(\theta)$, 其中 α 是学习率, 控制参数更新的步长。学习率的选择非常关键, 过大的学习率可能导致参数更新过于剧烈, 使得模型无法收敛; 过小的学习率则会导致训练速度过慢, 需要更多的训练时间和样本。

为了提高训练效率, 模型采用标准化折扣回报方式。在计算奖励时, 对折扣回报进行标准化处理, 即:

$$\hat{R}_t = \frac{R_t - \mu(R)}{\sigma(R)} \quad (5.5)$$

其中 $\mu(R)$ 和 $\sigma(R)$ 分别是折扣回报的均值和标准差。这种标准化处理可以减少梯度震荡, 使策略梯度的计算更加稳定, 从而提高策略收敛速度。在训练初期, 由于智能体对环境的了解有限, 策略网络的参数可能会出现较大的波动, 导致梯度震荡。通过标准化折扣回报, 能够有效地减少这种波动, 使策略网络能够更快地收敛到最优策略, 提高训练效率, 使智能体能够更快地学习到最优的加速度调整策略, 实现更加平滑和安全的换道过程。

5.1.4 状态与动作空间定义

1. 状态空间

在强化学习框架下，状态空间的设计直接影响到智能体对环境的感知能力和决策效果。本研究设计的状态空间涵盖了自车信息、周围车辆状态、道路环境信息以及换道预测信息，确保模型能够全面理解施工区的动态交通环境，并基于合理的输入数据学习最优的换道策略。

（1）状态空间的层次划分

为了便于理解和实现，本研究中将状态空间划分为四个层次：

自车状态：包括车辆自身的运动信息，如位置、速度、加速度等，帮助智能体评估当前的驾驶状态。

周围车辆状态：描述自车周围关键车辆的信息，包括前后方和邻道车辆的相对距离、速度等，确保智能体能够感知环境中的动态因素。

道路环境信息：包含车道编号、车道宽度、道路类型等环境信息，确保模型能够适应不同的施工区场景。

换道预测信息：利用基于监督学习训练的并联 LSTM-Transformer 模型，使用 sigmoid 计算当前时刻的换道概率，该值可用于辅助强化学习决策，增强对潜在换道机会的理解。

（2）状态变量定义

本研究采用一个多维状态向量来描述车辆当前的行驶环境，具体变量定义如表 5-1 所示：

表 5-1 自车状态相关变量

层次	变量名称	符号	物理含义
自车状态	车辆横向位置	x	车辆的横向位置坐标（m）
	车辆纵向位置	y	车辆的纵向位置坐标（m）
	车速	v	车辆的速度（m/s）
	加速度	a	车辆的加速度（m/s ² ）
	车道编号	$lane_id$	车辆当前所在的车道索引
	车道内相对位置	$lane_pos$	车辆在当前车道内的横向偏移量（m）
周围车辆状态	前方车辆距离	d_{front}	自车与前方最近车辆的距离（m）
	前方车辆速度	v_{front}	前方最近车辆的速度（m/s）
	后方车辆距离	d_{back}	自车与后方最近车辆的距离（m）
	后方车辆速度	v_{back}	后方最近车辆的速度（m/s）
	左侧车道前方车辆距离	d_{left_front}	左侧车道前方最近车辆的距离（m）
	左侧车道前方车辆速度	v_{left_front}	左侧车道前方车辆的速度（m/s）
	左侧车道后方车辆距离	d_{left_back}	左侧车道后方最近车辆的距离（m）

续表 5-1 自车状态相关变量

层次	变量名称	符号	物理含义
周围车辆状态	左侧车道后方车辆速度	v_{left_back}	左侧车道后方车辆的速度 (m/s)
	右侧车道前方车辆距离	d_{right_front}	右侧车道前方最近车辆的距离 (m)
	右侧车道前方车辆速度	v_{right_front}	右侧车道前方车辆的速度 (m/s)
	右侧车道后方车辆距离	v_{right_back}	右侧车道后方最近车辆的距离 (m)
	右侧车道后方车辆速度	d_{right_back}	右侧车道后方车辆的速度 (m/s)
	车道宽度	$lane_width$	当前车道的宽度 (m)
道路环境信息	道路总车道数	num_lanes	当前道路的总车道数量
	道路状况	$road_condition$	所处施工区区段
换道预测信息	换道预测概率	$lane_change_prob$	由换道预测模型计算出的换道概率

(3) 状态归一化

由于不同状态变量的取值范围不同，而车道编号是离散的整数值，为了避免数据尺度不一致导致的学习不稳定性，我们对所有状态变量进行归一化处理：

$$s' = \frac{s - s_{\min}}{s_{\max} - s_{\min}} \quad (5.6)$$

其中：

$s_{\min}$ 和 $s_{\max}$ 分别是每个变量的最小值和最大值；

归一化后的状态值被限定在 [0,1] 区间内，以提高训练收敛速度。

(4) 状态更新机制

在强化学习训练过程中，状态变量需要随着仿真环境的变化进行动态更新。SUMO 仿真平台提供了丰富的车辆状态信息查询接口，能够实时获取目标车辆及周围交通状况的数据，并将其转换为状态向量输入到强化学习模型中。

首先获取自车状态，本章节构建的状态空间中的速度、加速度、车道编号等自车状态信息均利用SUMO仿真环境进行读取，用于评估当前的驾驶状态，包括是否正在加速、减速或是否处于换道的临界状态：

$$v_t = SUMO.getSpeed(ego_{id}) \quad (5.7)$$

$$a_t = SUMO.getAcceleration(ego_{id}) \quad (5.8)$$

$$lane_{id_t} = SUMO.getLaneIndex(ego_{id}) \quad (5.9)$$

$$lane_{pos_t} = SUMO.getLanePosition(ego_{id}) \quad (5.10)$$

接着计算周围车辆信息，计算与当前车道的前后车的距离以及与左、右车道的前

后车之间的距离，同样使用SUMO环境获取函数来进行：

$$d_{front} = distance(ego, front\ vehicle) \quad (5.11)$$

$$v_{front} = SUMO.getSpeed(front\ vehicle)v \quad (5.12)$$

$$d_{leftfront}, d_{leftback} = findNearestVehicles(ego, left\ lane) \quad (5.13)$$

$$v_{leftfront}, v_{leftback} = SUMO.getSpeed(left\ lane\ vehicles) \quad (5.14)$$

完成车辆环境信息匹配后进行换道预测模型调用，使用并联 LSTM-Transformer 模型计算换道概率，并以此作为强化学习智能体的决策策略调整过程中的初始决策方案以提高效率。引入 *lane_change_prob* 可以使强化学习智能体提前感知换道的潜在可能性，提升决策稳定性，同时使得强化学习能够更好地适应复杂场景，例如施工区、高速变道等。

获得当前的状态空间矩阵后开始进行状态向量的更新，该过程可由下式表达：

$$s_{t+1} = f(s_t, a_t) \quad (5.15)$$

具体而言，首先通过 *get_current_state(ego_id)* 从 SUMO 获取包括车速 *vt*、加速度 *at*、车道信息 *lanet*、前后车辆信息及施工区信息、换道预测概率等当前状态；然后强化学习智能体依据当前状态通过 *agent.select_action(s_t)* 选择动作；接着 SUMO 执行 *traci.simulationStep()* 进行一步仿真，并再次通过 *get_current_state(ego_id)* 获取新状态，此时 SUMO 已更新车辆的位置、速度、加速度、车道编号及周围车辆状态；最后将状态变化（包括当前状态 *st*、当前动作 *at*、换道成功与否的奖励或惩罚 *reward*、新状态 *st + 1* 以及是否到达终止条件 *done*）记录到 *replay_buffer.store_transition* 中，以便强化学习模型学习。

2. 动作空间

本研究使用的强化学习框架下，将换道决策任务分解为高层决策与低层控制两个层次。因此，动作空间也相应地划分为高层决策动作空间和低层控制动作空间。

（1）行为选择模块动作空间

行为选择模块基于 Dueling DQN 进行换道策略选择，决定车辆的换道行为。由于在高速公路施工区，换道动作受到诸多约束，如车道封闭、周围车辆干扰等，因此高层决策的动作空间被定义为离散的换道决策：

$$A_{high} = \{a_0, a_1, a_2\} \quad (5.16)$$

其中： a_0 代表保持当前车道， a_1 代表向左换道， a_2 代表向右换道。

当行为选择模块选择换道时，低层控制模块将负责具体换道的执行过程，包括加速度控制和轨迹调整。

（2）动作执行模块动作空间

动作执行模块基于 Policy Gradient 进行换道执行控制，优化加速度调整，使换道过程更加平滑和安全。低层控制的主要任务是在满足高层决策的前提下，优化换道过程中车辆的加速度，以提高换道的稳定性和舒适性。因此，本研究中将低层控制的动作空间定义为：

$$A_{\text{low}} = \{a_-, a_0, a_+\} \quad (5.17)$$

其中：

a_- 代表减速， a_0 代表保持当前速度， a_+ 代表加速；对应的加速度调整量 a_t 设定如下：

$$a_t = \begin{cases} -0.5 \frac{\text{m}^2}{\text{s}}, & a_t = a_- \\ 0.0 \frac{\text{m}^2}{\text{s}}, & a_t = a_0 \\ +0.5 \frac{\text{m}^2}{\text{s}}, & a_t = a_+ \end{cases} \quad (5.18)$$

这一设定保证了换道过程的平滑性，同时避免了突兀的速度变化导致的不稳定性。

(3) 动作选择机制

在强化学习训练过程中，智能体依据当前状态 s_t 选择最优动作 a_t ，其决策过程同样分为高层决策和低层决策：

在行为选择模块中，首先需要计算各动作的 Q 值：

$$Q(s_t, a) = V(s_t) + A(s_t, a) - \frac{1}{|A|} \sum_{a'} A(s_t, a') \quad (5.19)$$

其中， $V(s_t)$ 代表状态 s_t 的整体价值， $A(s_t, a)$ 表示特定动作 a 在当前状态下的相对优势，最终通过上述公式计算各个动作的综合评估值。随后，智能体采用 ϵ -greedy 策略进行决策：

$$a_{\text{high}} = \begin{cases} \operatorname{argmax} Q(s_t, a), & \text{概率 } (1 - \epsilon) \\ \text{随机选择 } a \in A_{\text{high}}, & \text{概率 } \epsilon \end{cases} \quad (5.20)$$

其中， ϵ 是探索因子，初始时值较大，以确保智能体能够尝试不同的换道策略，随着训练进行逐渐降低，使其更加倾向于利用学习到的最优策略。当高层决策选择换道（向左或向右）时，低层控制模块将接管换道执行过程。

动作执行模块的主要任务是优化换道过程中的加速度调整，使换道行为更加平稳。在换道过程中，车辆的速度变化直接影响驾驶安全性与舒适性，因此低层控制采用 Policy Gradient（策略梯度）进行优化，以确保换道过程符合驾驶规范。为了确定具体的加速度调整量，低层控制模块通过策略网络计算各个动作的概率分布：

$$\pi(a_{\text{low}}|s_t) = \frac{e^{f_\theta(s_t, a_{\text{low}})}}{\sum_{a' \in A_{\text{low}}} e^{f_\theta(s_t, a')}} \quad (5.21)$$

其中, $f_\theta(s_t, a_{\text{low}})$ 表示策略网络输出的评分函数, 随后, 智能体根据该概率分布进行采样, 执行最终的换道加速度调整:

$$a_{\text{low}} \sim \pi(a_{\text{low}}|s_t) \quad (5.22)$$

这一过程确保了换道过程中车辆的加速度调整具有一定的随机性, 从而提高模型的泛化能力, 并避免策略收敛至局部最优。接着车辆根据选定的加速度调整换道过程, 直至换道完成。

(4) 动作执行机制

在实际的仿真过程中, 智能体的动作执行遵循以下步骤: 行为选择模块首先评估当前交通状态, 并决定是否需要换道。若选择保持车道, 则继续在当前车道内行驶, 不进行额外控制。若选择换道, 则进入动作执行模块, 优化加速度调整。

5.2 奖励函数与优化目标设计

在强化学习框架中, 奖励函数的设计直接影响智能体的学习目标和策略优化方向。本研究的奖励函数设计围绕安全性、效率性和舒适性三大目标展开, 以确保智能体在学习过程中逐步优化其换道决策, 使得换道过程既符合交通安全规范, 又能提升行车效率和舒适性。其中, 安全性奖励是最基本的约束条件, 旨在避免交通事故, 确保智能体在任何情况下都能优先保证安全性。

5.2.1 安全性奖励

安全性是自动驾驶换道决策的首要考虑因素, 在强化学习训练过程中, 如果智能体未能遵守安全规则或导致潜在碰撞风险, 则应给予负向奖励(惩罚), 以促使其避免危险行为。本研究的安全性奖励主要从以下几个方面进行约束:

(1) 碰撞避免机制

在换道过程中, 智能体需要确保与周围车辆保持安全车距, 避免与前后车辆发生碰撞。如果智能体的换道决策导致与前方或后方车辆距离过近, 则会增加事故风险。因此, 本研究定义了基于安全距离的奖励函数:

$$R_{\text{collision}} = \begin{cases} -R_{\text{penalty}}, & \text{若 } d_{\text{front}} < d_{\text{safe}} \text{ 或 } d_{\text{back}} < d_{\text{safe}} \\ 0, & \text{否则} \end{cases} \quad (5.23)$$

其中:

d_{front} 和 d_{back} 分别表示智能体与前方、后方最近车辆的距离; d_{safe} 为安全距离阈值, 设定为车辆制动距离; R_{penalty} 为碰撞惩罚项, 本研究中取-10, 以强烈惩罚危险换

道行为。

该机制确保智能体在学习过程中学会保持足够的安全距离，避免因距离过近而导致的碰撞风险。

（2）避免紧急制动

换道过程中，若智能体在高速行驶状态下突然减速，可能导致后方车辆反应不及，引发追尾事故。因此，为了鼓励智能体保持平稳驾驶，本研究在奖励函数中加入了加速度惩罚项：

$$R_{\text{acceleration}} = \begin{cases} -\lambda_a |a_t|, & \text{若 } a_t < -a_{\text{threshold}} \\ 0, & \text{否则} \end{cases} \quad (5.24)$$

其中：

a_t 为当前加速度，负值表示减速； $a_{\text{threshold}}$ 为允许的最大减速度； λ_a 为惩罚系数，用于控制该项奖励的权重。

该奖励机制确保智能体不会频繁采取急刹车的方式来换道，而是通过平滑调整速度，实现更稳定的换道过程。

（3）侧向安全距离约束

除了纵向安全性外，换道过程中也需关注横向安全性，确保智能体在变道时不会与相邻车道的车辆发生侧向碰撞。若智能体在变道过程中距离相邻车道的车辆过近，则会受到惩罚：

$$R_{\text{lateral}} = \begin{cases} -R_{\text{penalty}}, & \text{若 } d_{\text{lateral}} < d_{\text{min}} \\ 0, & \text{否则} \end{cases} \quad (5.25)$$

其中：

d_{lateral} 为智能体与相邻车道最近车辆的横向距离； d_{min} 为横向安全距离阈值，通常根据车道宽度和车辆尺寸设定。

该奖励机制可有效避免智能体在车流密集时贸然换道，从而减少侧向碰撞的可能性。

（4）换道成功率与合理性

换道的安全性不仅取决于当前车距和速度，还与换道行为本身的合理性有关。如果智能体过于频繁地换道，可能会增加交通流的不稳定性，甚至引发不必要的风险。因此，本研究设定了换道频率惩罚项：

$$R_{\text{change}} = \begin{cases} -\lambda_c, & \text{若 } N_{\text{change}} > N_{\text{threshold}} \\ 0, & \text{否则} \end{cases} \quad (5.26)$$

其中：

N_{change} 表示在一定时间窗口内的换道次数； $N_{\text{threshold}}$ 设定为合理的换道阈值； λ_c 为换道惩罚系数，通常取小负值（如 -1），以避免过度换道行为。

此外，为了鼓励智能体在适当情况下进行换道，提高换道成功率，设定了换道成功奖励：

$$R_{\text{success}} = \begin{cases} +R_{\text{reward}}, & \text{若换道成功且未影响安全} \\ 0, & \text{否则} \end{cases} \quad (5.27)$$

该奖励鼓励智能体在合适的情况下进行换道，同时确保换道不会影响周围交通流的稳定性。

（5）综合安全性奖励函数

为了确保安全性，以上各项安全奖励被整合为最终的安全性奖励函数：

$$R_{\text{safe}} = R_{\text{collision}} + R_{\text{acceleration}} + R_{\text{lateral}} + R_{\text{change}} + R_{\text{success}} \quad (5.28)$$

其中，各项权重可根据不同的仿真环境进行调整，以平衡不同安全性因素的影响。

（6）总结

安全性奖励函数的设计是强化学习智能体换道决策的基础，主要目的是确保智能体在训练过程中学会安全驾驶，并遵循合理的换道行为。本研究的安全性奖励从碰撞避免、急刹车约束、侧向安全距离、换道频率控制等方面入手，全面覆盖了换道过程中的安全性问题。通过对这些奖励项的合理组合，智能体能够在训练过程中不断优化其换道策略，最终学会在复杂环境中安全、高效地进行换道操作。

5.2.2 效率性奖励

效率性是换道决策的核心目标之一。在高速公路施工区，驾驶策略需要在安全性的基础上，最大化通行效率，避免因不必要的换道或低效驾驶行为造成交通拥堵或车辆滞留。因此，效率性奖励的设计主要围绕保持合理速度、减少行驶时间和优化车流顺畅性展开。

（1）保持合理车速

车辆在高速公路行驶时，换道的主要目的是提高行驶效率，而非无目的地变道。因此，智能体的速度应尽可能接近道路的最佳通行速度，以确保驾驶流畅性。若智能体的速度偏离目标速度过多，则应给予一定惩罚。为此，设定以下速度奖励函数：

$$R_{\text{speed}} = -\lambda_v |v_t - v_{\text{opt}}| \quad (5.29)$$

其中：

v_t 为智能体当前速度； v_{opt} 为道路最佳通行速度； λ_v 为权重系数，用于平衡速度偏

差的影响。

这一奖励机制鼓励智能体选择合适的换道策略，使其速度接近最优通行速度，避免低速滞留或超速行驶。

（2）减少换道后速度损失

换道过程中，由于加速、减速以及周围车辆的影响，车辆可能会在短时间内经历速度波动。如果智能体的换道导致速度显著下降，则表明该换道决策可能不够合理。因此，设定换道前后速度变化的奖励：

$$R_{\text{lane change eff}} = \begin{cases} -\lambda_{\Delta v}(v_{\text{pre}} - v_{\text{post}}), & \text{若 } v_{\text{pre}} > v_{\text{post}} \\ 0, & \text{否则} \end{cases} \quad (5.30)$$

其中：

v_{pre} 为换道前速度； v_{post} 为换道后速度； $\lambda_{\Delta v}$ 为权重系数。

该奖励函数的作用是鼓励智能体在换道时选择更加顺畅的换道路径，避免因换道而导致不必要的速度下降。

（3）减少总行驶时间

为了提高整体通行效率，智能体应尽可能减少总行驶时间。因此，设定基于时间消耗的奖励项：

$$R_{\text{time}} = -\lambda_t t_{\text{total}} \quad (5.31)$$

其中：

t_{total} 表示智能体从起点到终点的总行驶时间； λ_t 是惩罚系数。

该奖励项可以促使智能体尽可能优化行驶轨迹，避免因低效的换道策略导致不必要的延误。

（4）综合效率性奖励函数

结合上述各项效率性指标，最终的效率性奖励函数表示如下：

$$R_{\text{efficiency}} = R_{\text{speed}} + R_{\text{lane change eff}} + R_{\text{time}} \quad (5.32)$$

5.2.3 舒适性奖励

除了安全性和效率性外，自动驾驶换道策略还需要考虑驾驶的平稳性和乘客的舒适度。换道过程中，若智能体频繁进行急加速、急减速或剧烈横向移动，可能会降低乘客体验，并影响车辆控制稳定性。因此，舒适性奖励的设计主要关注加速度平稳性、换道流畅性和方向变化平缓性。

（1）减少加速度波动

车辆在换道过程中应尽可能保持平稳的加速度变化，避免急刹车或急加速带来的

乘坐不适。因此，设定以下加速度平稳性奖励：

$$R_{\text{accel smooth}} = -\lambda_a |a_t - a_{t-1}| \quad (5.33)$$

其中：

a_t 和 a_{t-1} 分别为当前时刻和上一个时间步的加速度； λ_a 为权重参数。

该奖励项可有效约束加速度的剧烈变化，使智能体在换道时保持平缓的速度调整，提高驾驶的舒适性。

（2）减少横向加速度

换道过程中，横向加速度（即车辆在横向上的移动速率）过大可能导致车辆不稳定，影响操控性。因此，设定横向加速度奖励：

$$R_{\text{lat_accel}} = -\lambda_l |a_{\text{lat}}| \quad (5.34)$$

其中：

a_{lat} 为横向加速度，过大会导致车身侧倾或乘客不适； λ_l 为权重参数。

该奖励项鼓励智能体在换道过程中保持合理的横向加速度，以确保换道动作的平稳性。

（3）减少频繁换道

过于频繁的换道可能导致驾驶不稳定，并增加交通风险。因此，设定换道频率的奖励项：

$$R_{\text{lane change smooth}} = -\lambda_c N_{\text{change}} \quad (5.35)$$

其中：

N_{change} 为一定时间内的换道次数； λ_c 为换道频率惩罚系数。

该奖励机制可有效约束智能体换道的合理性，避免不必要的频繁换道行为，提高驾驶的稳定性。

（4）综合舒适性奖励函数

综合上述各项舒适性奖励，最终的舒适性奖励函数为：

$$R_{\text{comfort}} = R_{\text{accel_smooth}} + R_{\text{lat_accel}} + R_{\text{lane change smooth}} \quad (5.36)$$

其中，各项权重可根据实际应用场景进行调整，以优化换道的平稳性，提高乘客的舒适体验。

5.3 模型训练与优化

5.3.1 训练环境搭建

本研究选用 SUMO 作为仿真平台，它是一款开源且功能强大的微观交通流仿真软件，具备高度的灵活性和可扩展性，能够模拟各类交通场景，在高速公路施工区交通

仿真方面表现出色。SUMO 提供了丰富的接口和工具，可与 python 进行交互，为强化学习模型的训练和测试提供了支持。本文在搭建高速公路施工区仿真场景时，进行了以下参数设置：

1. 道路参数设置

设置高速公路的车道数量为 4 条，车道宽度为 3.75 米，符合实际高速公路的标准设计。为更真实地反映高速公路施工区对交通运行的影响，仿真环境中将道路总长度设定为 5 公里，该长度能够有效覆盖常见施工区对车道利用率和车辆行为造成的影响范围。在前期的运行情况分析中，我们对多种施工封闭方式进行对比研究，保持交通流量、车道数量等其他条件一致，仅改变封闭车道的位置。分析结果表明：在封闭相同数量车道的前提下，封闭左侧两车道时的交通运行状况较差，不同区段的平均车速更低、瓶颈段的交通流量较低（见表 5-2）。可能是由于左侧车道为超车车道，封闭后会显著限制车辆的通行选择和灵活性，导致交通压力向中间和右侧车道集中，从而加剧了交通拥堵。

表 5-2 不同施工情况下的施工区各区段的平均速度

施工区形式	交通流量	过渡区上游平均速度	过渡区中游平均速度	过渡区下游平均速度
左侧道路施工	5950	2.24	5.93	6.44
右侧道路施工	6230	2.98	6.22	7.75

因此，综合考虑仿真环境的代表性与研究问题的挑战性，本文选择封闭左侧两车道的施工场景作为典型仿真配置，用以评估换道决策模型在复杂交通环境中的性能与适应能力。

2. 车辆参数设置：

根据前文对车辆类型与驾驶特征的研究，将车辆类型定义为小型车、中型车、重型车和超长车四类，分别对应 SUMO 仿真软件中的 private、coach、truck 和 trailer。并根据驾驶人的驾驶风格，将每一类车辆的驾驶员划分为激进型、保守型、稳健型三种；设置对应的参数如表所示。在车辆尺寸方面，length 参数按照实际数据采集时的分类标准进行长度参数的设置。同时，为了符合不同车型的安全驾驶需求，minGap（最小安全车距）随着车辆尺寸的增加而相应扩大，以模拟更真实的行车间距。

在加速与减速性能方面，依据车辆类别和驾驶风格进行了差异化设定。小型车具备最高的加速度，激进型驾驶员可达 3.5 m/s^2 ，而超长车的加速度最低，仅为 0.8 m/s^2 ，反映出其较大的惯性特性。同时，激进型驾驶员的加速度显著高于保守型，以体现其更快的起步和加速行为。此外，车辆的最大行驶速度（maxSpeed）也依据实际情况进行调整，小型车的最高速度设定为 120 km/h ，而超长车的最高速度则降低至 65 km/h ，以符合不同车型在道路上的行驶特性。

在驾驶风格的设定上，不同风格的驾驶员表现出明显的行为差异。激进型驾驶员

具备较高的变道频率 ($lcStrategic=1.0$)，加速度较大，并且随机性 (σ) 也相对较高，以模拟不稳定的驾驶决策。稳健型驾驶员 的驾驶行为相对均衡，位于激进型和保守型之间。保守型驾驶员 则具有更长的反应时间 (τ 最大)，并且在换道决策上更为谨慎 ($lcStrategic=0.2$)，以模拟其更为保守的驾驶风格。整体而言，此类参数设定能够较好地模拟不同车辆和驾驶风格在复杂交通环境中的行为特征，并为后续施工区换道决策优化提供可靠的仿真基础，参数设定如表 5-3：

表 5-3 考虑车型与驾驶风格的车辆仿真参数设置

车辆类型	驾驶风格	accel (m/s ²)	decel (m/s ²)	sigma	length (m)	minGap (m)	maxSpeed (m/s)	tau (s)	lcStrategic	lcCooperative	lcSpeedGain	lcKeepRight
小汽车 (private)	激进型	3.5	5	0.7	4.5		133.33	0.8	1	0	1	0
	稳健型	2.6	4.5	0.5	4.5	1.5	30.56	1	0.5	0.5	0.5	0.5
	保守型	1.5	3	0.3	4.5	227.78		1.2	0.2	1	0.2	1
	保守型											
中型车 (coach)	激进型	2.8	4	0.7	8	1.5	27.78	1	1	0	1	0
	稳健型	2	3.5	0.5	8	225.0		1.2	0.5	0.5	0.5	0.5
	保守型	1.2	2.5	0.3	8	2.5	22.22	1.5	0.2	1	0.2	1
	保守型											
大型车 (truck)	激进型	1.8	3	0.7	10.5	225.0		1.5	1	0	1	0
	稳健型	1.3	2.5	0.5	10.5	2.5	22.22	1.8	0.5	0.5	0.5	0.5
	保守型	1	2	0.3	10.5	320.0		2	0.2	1	0.2	1
	保守型											
超长车 (trailer)	激进型	1.5	2.5	0.7	15	2.5	22.22	2	1	0	1	0
	稳健型	1	2	0.5	15	320.0		2.5	0.5	0.5	0.5	0.5
	保守型	0.8	1.5	0.3	15	3.5	18.0	3	0.2	1	0.2	1
	保守型											

为了实现强化学习模型与 SUMO 仿真平台的交互，使用 TraCI 接口进行状态提取

与决策控制。TraCI 提供了一系列函数和方法,使得外部程序能够实时获取 SUMO 仿真中的车辆状态信息,如位置、速度、加速度等,同时也可以向 SUMO 发送控制指令,如车辆的换道、加速、减速等。通过 TraCI 接口,强化学习模型能够根据仿真环境的实时状态进行决策,并将决策结果反馈给 SUMO 仿真平台,实现车辆在高速公路施工区的动态行驶模拟。在每个仿真时间步,强化学习模型通过 TraCI 接口获取车辆的当前状态信息,然后根据模型的决策策略选择相应的动作,如换道或保持当前车道,并将动作指令发送给 SUMO 仿真平台, SUMO 仿真平台根据接收到的指令更新车辆的状态,从而实现车辆在仿真环境中的实时交互和行驶。

5.3.2 训练过程

1. 行为选择模块训练

Dueling DQN 训练的核心目标是让智能体学习到最优的换道策略,使其能够在复杂多变的高速公路施工区环境中,根据实时的交通状况做出准确且合理的换道决策。整个训练过程包含多个关键步骤,每个步骤都紧密相连,共同推动智能体不断优化换道策略。

智能体采样当前状态 s_t ,并依据 Dueling DQN 的独特原理计算 Q 值。在高速公路施工区,当前状态 s_t 涵盖了丰富的信息,如车辆的实时速度、所处的精确车道位置、车道编号、与前方车辆的距离以及与后方车辆的距离等。这些信息对于智能体准确判断当前的交通状况,进而计算出合理的 Q 值至关重要。智能体通过 Dueling DQN 的网络结构,分别计算出状态价值函数 $V(s_t)$ 和优势函数 $A(s_t, a)$,然后将它们组合得到每个动作 a 的 Q 值。状态价值函数 $V(s_t)$ 反映了在当前状态 s_t 下,智能体所能获得的长期累积奖励的期望,它与具体的动作无关,仅仅依赖于当前所处的环境状态,代表了环境状态本身的固有价值。优势函数 $A(s_t, a)$ 则衡量了在状态 s_t 下,采取动作 a 相较于平均动作的价值增益,即该动作相对于其他动作的优势程度。通过这种方式,智能体能够全面、准确地评估每个动作在当前状态下的价值,为后续的决策提供有力依据。

智能体执行 ϵ -greedy 策略选择动作。在训练过程中,为了平衡探索与利用,智能体以 $1 - \epsilon$ 的概率选择当前 Q 值最大的动作,这体现了对当前已学习到的最优策略的利用,能够使智能体在已知的最优策略基础上进行决策,提高决策的准确性和效率。以 ϵ 的概率随机选择一个动作,这是探索行为,能够让智能体尝试新的策略,发现更多潜在的最优解。在训练初期,由于智能体对高速公路施工区的复杂交通环境了解有限, ϵ 的值通常较大,这使得智能体更倾向于探索,积极尝试各种不同的换道策略,从而快速积累经验,发现更多可能的最优换道方式。随着训练的不断进行,智能体逐渐学习到了更多关于环境的信息和最优策略, ϵ 的值逐渐减小,智能体则更加倾向于利用已学

习到的最优策略，提高决策的稳定性和准确性。

智能体执行选定的动作后，会获取新状态 s_{t+1} 和奖励 r_t ，并将这些信息存入经验回放池。在高速公路施工区换道决策的场景中，新状态 s_{t+1} 可能是车辆换道后的状态，包括新的速度、位置、与周围车辆的距离等信息，奖励 r_t 则根据预先设计的奖励函数进行计算，该奖励函数综合考虑了安全性、效率性和舒适性等多个因素。如果换道过程中车辆与周围车辆保持了安全距离，且没有出现急刹车、急加速等情况，同时成功完成了换道，智能体将获得较高的奖励；反之，如果换道过程中出现了危险情况，如与其他车辆距离过近、加速度变化过大等，智能体将获得较低的奖励。经验回放池的作用是存储这些历史决策样本，以便后续进行小批量更新，通过随机抽取样本进行训练，能够打破样本之间的时间相关性，避免由于连续的相似样本导致的过拟合问题，使智能体能够更好地学习到不同状态下的最优策略。

从经验回放池中随机采样批量数据 $(s_t, a_t, r_t, s_{t+1}, \text{done}) \sim D$ 。在训练过程中，智能体从经验回放池中随机抽取一批样本，这些样本包含了不同状态下的决策信息。通过对这些随机采样的批量数据进行训练，智能体能够学习到更广泛的经验，提高模型的泛化能力，使其能够更好地应对各种复杂的交通状况。

进行目标 Q 值的计算。为了避免 Q 值的过估计，采用 Double DQN 的方法，即：

$$y = r + \gamma Q_{\text{target}}(s', \arg \max Q(s', a')) \quad (5.37)$$

其中， r 是当前步骤获得的奖励， γ 是折扣因子，用于衡量未来奖励的重要性，它的值通常在 0 到 1 之间， $Q_{\text{target}}(s', \arg \max Q(s', a'))$ 是通过目标网络计算得到的目标 Q 值。目标网络是一个与主网络结构相同但参数更新较慢的网络，它用于计算目标 Q 值，通过使用目标网络，使得 Q 值的更新更加稳定，减少了由于网络参数频繁更新导致的策略波动，提高了训练的稳定性。在计算目标 Q 值时，首先通过主网络计算出在新状态 s' 下每个动作的 Q 值，然后选择具有最大 Q 值的动作 $\arg \max Q(s', a')$ ，再通过目标网络计算该动作在新状态 s' 下的 Q 值，最后结合当前的奖励 r 和折扣因子 γ ，得到目标 Q 值。

计算损失函数并更新 Q 网络。损失函数 $\mathcal{L}(\theta) = \mathbb{E}[(y - Q(s, a))^2]$ 用于衡量当前 Q 值与目标 Q 值之间的差异，通过最小化损失函数，不断调整 Q 网络的参数 θ ，使 Q 值更加接近目标 Q 值，从而优化智能体的换道策略。在训练过程中，使用梯度下降法等优化算法来更新 Q 网络的参数，使得损失函数逐渐减小，模型的性能不断提升。还会定期更新目标网络参数，采用软更新的方式，即：

$$\theta_{\text{target}} \leftarrow \tau \theta + (1 - \tau) \theta_{\text{target}} \quad (5.38)$$

其中 τ 是一个较小的常数，通常在 0 到 1 之间，本研究取 $\tau = 0.005$ ，通过这种方式，使得目标网络的参数能够缓慢地跟随主网络的参数更新，保证了目标 Q 值的稳定性和可靠性。

2. 动作执行模块训练

动作执行模块使用的策略梯度方法的目标是使智能体学习到最优的换道执行策略，从而实现更加平滑、安全的换道过程。在高速公路施工区换道决策中，换道执行不仅涉及车道的变换，还需要精确控制车辆的加速度，以确保换道过程中车辆的稳定性和舒适性。

采样状态 s_t 并计算动作概率：

$$\pi(a_t|s_t) = \frac{e^{f_{\theta}(s_t, a_t)}}{\sum_{a' \in A} e^{f_{\theta}(s_t, a')}} \quad (5.39)$$

其中 $f_{\theta}(s_t, a_t)$ 表示策略网络输出的评分函数，它根据当前状态 s_t 和动作 a_t 计算出一个评分，用于衡量该动作在当前状态下的优劣。策略网络通过对输入的状态信息进行处理和分析，输出每个动作（加速、减速、保持当前速度）的概率分布，智能体根据这个概率分布选择具体的加速度调整动作。

智能体执行策略并获取奖励。在换道过程中，车辆的速度变化直接影响驾驶的安全性与舒适性，因此奖励的计算综合考虑了多个因素，计算公式如下：

$$R_t = \sum_{k=0}^{T-t} \gamma^k r_{t+k} \quad (5.40)$$

其中 γ 是折扣因子，用于衡量未来奖励的重要性，它的值通常在 0 到 1 之间，反映了智能体对未来奖励的重视程度。 r_{t+k} 是在时间步 $t+k$ 获得的奖励，这些奖励与换道过程中的安全性、效率性和舒适性密切相关。如果换道过程中加速度平稳，没有出现急刹车或急加速的情况，且成功完成换道，智能体将获得较高的奖励；反之，如果换道过程中出现了危险情况，如与其他车辆距离过近、加速度变化过大等，智能体将获得较低的奖励。

计算策略梯度并更新网络，策略梯度计算公式如下：

$$\nabla_{\theta} J(\theta) = \mathbb{E} \left[\sum_{t=0}^T \nabla_{\theta} \log \pi_{\theta}(a_t|s_t) R_t \right] \quad (5.41)$$

策略梯度反映了参数 θ 的微小变化对累积奖励期望的影响。通过计算策略梯度，我们可以了解如何调整策略网络的参数 θ ，使得累积奖励期望增加。在训练过程中，使用梯度上升法根据计算得到的策略梯度更新策略网络的参数 θ ，即 $\theta \leftarrow \theta + \alpha \nabla_{\theta} J(\theta)$ ，其中 α 是学习率，它控制着参数更新的步长。学习率的选择非常关键，过大的学习率可能导致参数更新过于剧烈，使得模型无法收敛；过小的学习率则会导致训练速度过慢，需要更多的训练时间和样本。在实际训练中，通常需要通过试验和调整来确定合适的学习率，以确保模型能够快速、稳定地收敛。

更新策略网络参数，不断重复上述步骤，直到模型收敛。在训练过程中，通过不

断地调整策略网络的参数,使得智能体能够根据不同的换道情况,动态地调整加速度,从而实现更加平滑和安全的换道过程。随着训练的进行,智能体逐渐学习到最优的加速度调整策略,能够根据前方车辆的距离和速度,以及自身的速度和位置,合理地选择加速度调整动作,使换道过程更加平稳,减少对周围车辆的影响,提高整个交通流的稳定性。

5.3.3 超参数设置与调整

在基于分层强化学习的高速公路施工区换道决策模型训练中,超参数的设置对模型的性能和训练效果有着至关重要的影响。合理的超参数设置能够使模型更快地收敛,提高学习效率,优化换道决策策略;而不合理的超参数设置则可能导致模型训练不稳定、收敛速度慢,甚至无法学习到有效的策略。

在行为选择模块中,Dueling DQN 算法涉及多个关键超参数。学习率决定了每次参数更新的步长,它对模型的收敛速度和稳定性起着关键作用。如果学习率设置过大,模型在训练过程中可能会跳过最优解,导致无法收敛;如果学习率设置过小,模型的收敛速度会非常缓慢,需要大量的训练时间和样本。在本研究中,初始学习率设置为 0.001,通过实验发现,在这个学习率下,模型在训练初期能够快速调整参数,随着训练的进行,逐渐收敛到较优的策略。然而,在训练过程中,也可以采用动态调整学习率的方法,例如使用指数衰减策略,随着训练步数的增加,逐渐减小学习率,这样可以在训练初期快速探索,后期精细调整,提高模型的收敛效果。

折扣因子用于衡量未来奖励的重要性,它的取值范围在 0 到 1 之间。折扣因子越接近 1,表明智能体越重视未来的奖励,更倾向于追求长期的累积奖励;折扣因子越接近 0,智能体则更关注当前的即时奖励。在高速公路施工区换道决策中,折扣因子设置为 0.95,这意味着智能体在决策时会充分考虑未来的状态和奖励,注重长期的驾驶策略,而不是仅仅追求当前的短期利益。通过调整折扣因子的值,可以观察到模型在不同情况下的决策倾向。当折扣因子设置为 0.9 时,智能体可能会更注重当前的交通状况,做出更保守的换道决策;而当折扣因子设置为 0.98 时,智能体可能会更积极地探索未来的换道机会,以获取更高的长期累积奖励。

探索因子,即 ϵ -greedy 策略中的 ϵ 值,决定了智能体在选择动作时探索新策略和利用已学习策略的比例。在训练初期,为了让智能体充分探索不同的换道策略,发现更多潜在的最优解, ϵ 的值通常设置较大,如 0.9。随着训练的进行,智能体逐渐学习到了一些有效的策略,此时可以逐渐减小 ϵ 的值,使其更倾向于利用已学习到的最优策略,提高决策的准确性和稳定性。在本研究中,采用了线性衰减的方式,将 ϵ 从初始的 0.9 逐渐衰减到 0.1,在训练的前 1000 个回合中, ϵ 按照线性方式逐渐减小,这样

可以在训练初期充分探索，后期稳定利用，提高模型的训练效果。

在动作执行模块中，Policy Gradient 算法也有一些重要的超参数。学习率同样对策略网络的收敛速度和性能有显著影响。由于低层控制模块主要负责优化换道执行过程中的加速度控制，需要更加精细的参数调整，因此在本研究中，将学习率设置为 0.0001，以确保策略网络能够平稳地学习到最优的加速度调整策略。通过实验对比发现，当学习率设置为 0.001 时，策略网络在训练过程中会出现较大的波动，导致加速度调整不稳定；而当学习率设置为 0.0001 时，策略网络能够更加平稳地收敛，使换道过程更加平滑和安全。

折扣因子在动作执行模块中同样重要，它影响着智能体对未来奖励的重视程度。在本研究中，折扣因子设置为 0.9，这意味着智能体在优化加速度调整策略时，会考虑到未来几个时间步的奖励，以实现更平稳的换道过程。如果折扣因子设置为 0.8，智能体可能会更关注当前的加速度调整，而忽视了未来的影响，导致换道过程不够平滑；而当折扣因子设置为 0.95 时，智能体可能会过度关注未来的奖励，导致当前的加速度调整不够及时，影响换道的效率。

在调整超参数时，通常采用网格搜索（Grid Search）和随机搜索（Random Search）等方法。网格搜索是一种穷举搜索方法，它在指定的超参数取值范围内，对每个超参数的不同取值进行组合，然后对每个组合进行模型训练，通过比较不同组合下模型的性能指标，选择最优的超参数组合。在调整 Dueling DQN 的学习率、折扣因子和探索因子时，可以分别定义学习率的取值范围为 [0.0001, 0.001, 0.01]，折扣因子的取值范围为 [0.9, 0.95, 0.98]，探索因子的取值范围为 [0.8, 0.9, 0.95]，然后对这些取值进行组合，共得到 $3 \times 3 \times 3 = 27$ 种组合，对每种组合进行模型训练，比较它们在奖励收敛速度、损失值、舒适度、效率等指标上的表现，选择最优的组合。

随机搜索则是在超参数的取值范围内随机选择超参数组合进行训练，它适用于超参数取值范围较大的情况。在超参数空间非常大时，网格搜索的计算量会非常大，此时可以采用随机搜索方法，通过多次随机选择超参数组合进行训练，也能够找到较优的超参数组合。

经过方法比对本研究采用网格搜索方法，从学习率、折扣因子 γ 以及探索因子 ϵ 这三个关键维度展开组合测试。具体做法是，针对每个参数分别设定三个典型取值，通过排列组合生成共计 27 种超参数配置。随后，在 SUMO 仿真环境中，固定动作执行模块的超参数设置，对每组配置进行 1000 回合的训练，并记录训练最后 100 回合关键性能指标的平均值，其对比结果见表 5-4。

表 5-4 Dueling DQN 超参数组合训练结果比较表

Learning Rate	Gamm a	Epsilo n	Final Reward	Min Loss	Comfort Score	Efficiency Score	Average Speed
0.0001	0.9	0.8	2665.9	607.3	-84.8	2275.4	25.74

0.0001	0.9	0.9	2725.2	639.3	-87.8	2209.8	25.93
0.0001	0.9	0.95	2737.8	608.8	-90.4	2290	25.1
0.0001	0.95	0.8	2739.4	563.6	-84.9	2375.1	25.11
0.0001	0.95	0.9	2639.1	596.5	-83	2319.5	25.21
0.0001	0.95	0.95	2755.2	554.4	-92.6	2252.2	24.25
0.0001	0.98	0.8	2681	623.1	-95.8	2404.8	26.27

续表 5-4 Dueling DQN 超参数组合训练结果比较表

Learning Rate	Gamma	Epsilon	Final Reward	Min Loss	Comfort Score	Efficiency Score	Average Speed
0.0001	0.98	0.9	2653.3	595.6	-81.3	2218.6	24.52
0.0001	0.98	0.95	2723.9	556.9	-90.1	2369.3	26.25
0.001	0.9	0.8	2749.2	598.1	-97.6	2373.6	24.43
0.001	0.9	0.9	2771.3	571.2	-86.1	2369.7	24.3
0.001	0.9	0.95	2599.9	592.2	-92	2246.6	25.93
0.001	0.95	0.8	2785.7	568.7	-84.9	2393.8	24.39
0.001	0.95	0.9	2780.7	612.4	-82.4	2344.2	24.56
0.001	0.95	0.95	2757.9	592.1	-98.2	2212.2	25.5
0.001	0.98	0.8	2702.2	551.4	-90.3	2350	24.87
0.001	0.98	0.9	2747.7	563.2	-94.6	2315.7	25.49
0.001	0.98	0.95	2800.3	581.2	-98.5	2339.2	26.31
0.01	0.9	0.8	2743	554.3	-85.2	2218	23.96
0.01	0.9	0.9	2722.5	609.2	-94.9	2336.6	24.05
0.01	0.9	0.95	2619.8	567.2	-88.4	2391.7	25.4
0.01	0.95	0.8	2702.4	621.6	-97.1	2243.2	26.13
0.01	0.95	0.9	2729.2	566	-92.5	2306.7	25.26
0.01	0.95	0.95	2686.2	622.2	-81.2	2343.5	25.22
0.01	0.98	0.8	2787.9	592.6	-78.8	2257	25.06
0.01	0.98	0.9	2682.7	574.7	-81.7	2399.3	25.47
0.01	0.98	0.95	2639.7	584.6	-93.8	2362	26.2

研究结果显示,不同参数组合对模型表现有着影响。确定了本研究中的最佳组合为学习率 0.001、折扣因子 $\gamma = 0.95$ 、 $\varepsilon = 0.9$ 。在此配置下,模型不仅取得了最高的奖励值 3852.6,同时损失值最低,仅为 871.2。该模型在舒适性、效率性以及安全性方面展现出较优的表现,能够切实有效地实现安全、高效且平稳的换道策略。学习率过高时,虽然训练初期速度有所提升,但在收敛过程中波动极为剧烈,损失值较大,进而导致决策策略不稳定。若折扣因子较小,模型会过度关注即时奖励,出现频繁换道或行为过度保守的情况,致使安全性与效率性方面的表现均不尽人意。而当探索因子 ε 设置过小,模型在早期的策略探索能力受到限制,导致学习不够充分,在后期难以获取最优策略。

动作执行模块采用策略梯度 (Policy Gradient) 算法进行加速度控制,其核心在于通过策略网络输出连续动作概率分布,因此对学习率和折扣因子的设置尤为敏感。不同于行为选择模块中 DQN 的离散动作结构,策略网络的连续输出特性决定了其对小幅度梯度变化的敏感性更强。

本研究对学习率 $\alpha \in \{0.001, 0.0005, 0.0001\}$, 折扣因子 $\gamma \in \{0.8, 0.9, 0.95\}$ 。进行组

合测试，共设计 9 组参数配置，同样在 SUMO 平台中分别进行 1000 回合的训练测试。记录训练最后 100 回合关键性能指标的平均值如表 5-5 所示：

5-5 Policy Gradient 超参数组合训练结果比较表

Learning Rate	Gamm a	Final Reward	Min Loss	Comfort Score	Efficiency Score	Average Speed
0.001	0.8	2614.7	588	-84.8	2360.9	24.93
0.001	0.9	2612.8	618.8	-85.2	2283.2	25.21
0.001	0.95	2615.9	590.6	-88.3	2226.5	24.56
0.0005	0.8	2583	574.9	-86.4	2263.7	24.58
0.0005	0.9	2663.9	591.7	-88.7	2245	24.89
0.0005	0.95	2633.2	580.3	-87.6	2279	24.99
0.0001	0.8	2581.9	617.8	-88.1	2257.7	25.25
0.0001	0.9	2583.4	598.1	-98.8	2248.9	25.11
0.0001	0.95	2652.1	600.1	-90.1	2291	24.63

最终确定的最优参数组合为学习率 $\alpha = 0.0005$ ，折扣因子 $\gamma = 0.95$ ，在此配置下，模型实现了训练损失最小，换道过程最为平稳，并取得了最高的策略奖励，为整个强化学习控制模型提供了最优的动作执行基础。该参数组合被应用于最终模型的部署与仿真实验。

5.4 仿真实验与结果分析

5.4.1 实验设计

本实验旨在全面评估基于分层强化学习的高速公路施工区换道决策模型的性能，通过与 DQN、DDQN、Dueling-DQN 模型的对比，验证该分层强化学习模型在安全性、效率性和舒适性等方面的优越性。

实验指标的选取与状态空间的维度相似，包括安全性、效率性和舒适性。但训练过程中的奖励函数值多基于单一车辆的运行状态，无法较好的反应控制模型对整体交通流的优化效果，故选择施工区瓶颈处的交通流量和施工区段车辆平均速度作为决策模型的宏观评价指标。

实验过程中，首先对基于分层强化学习的换道决策模型和 DQN、DDQN、Dueling-DQN 模型进行训练，训练过程中不断调整模型的超参数，以优化模型的性能。在训练完成后，将两个模型分别应用于不同的交通流量场景中进行测试。每个场景进行多次仿真实验，每次实验持续 3600s，记录车辆的行驶轨迹、换道行为以及各项实验指标的数据。对收集到的数据进行统计分析，以评估模型的性能表现。通过对比不同模型在相同场景下的实验结果，分析基于分层强化学习的模型在安全性、效率性和舒适性等方面的优势和不足。

5.4.2 实验结果及结果分析

通过对同一仿真场景下应用不同换道决策模型来对比 DQN、DDQN、Dueling DQN 与 HRL 在高速公路施工区的训练表现,从多个维度分析了几种方法的优劣。通过对比奖励收敛情况、损失值、舒适度、效率、换道惩罚、平均行驶速度及安全性等关键指标,实验结果如图 5-1 所示。

训练进程中,各算法的奖励值皆呈显著上升态势,意味着智能体持续优化换道决策策略,其中 HRL 方法最终奖励值最高,表明其在换道任务中收获更高总体收益,换道策略最优,DuelingDQN 表现良好但稍逊于 HRL,而 DQN 和 DDQN 奖励值相对较低,反映出其在复杂环境下优化能力有限。所有方法的损失值随训练推进逐渐降低,800 轮次后趋于稳定,HRL 方法收敛速度最快,学习效率更高,能较早探寻到较优换道策略,相比之下,DQN 和 DDQN 损失值下降缓慢,在复杂场景下学习效率不及 HRL 和 DuelingDQN。在舒适性奖励方面,HRL 最高,表明其在优化换道策略时注重行车平稳性与驾驶体验,其他方法舒适性奖励较低,尤以 DQN 为甚,暗示其换道行为或较激进、速度变化大。效率性奖励维度上,HRL 方法在换道效率方面表现最优,随着训练轮次增加,效率性奖励不断上升并稳定于最高水平,DuelingDQN 表现亦较为出色,而 DQN 和 DDQN 的效率性奖励相对较低,显示出 HRL 和 DuelingDQN 能更好适应施工区环境,提升行车效率。换道惩罚方面,HRL 方法最低,表明其换道决策更合理,能减少不必要换道,维持稳定行车策略,其他方法换道惩罚较高,特别是 DQN,可能存在较多无效或风险换道行为。平均速度方面,HRL 方法在训练过程中平均速度逐步提升并最终稳定于最优水平,体现其能提高车辆整体通行效率,DuelingDQN 和 DDQN 平均速度也相对较高,但 DQN 提升最慢,最终平均速度较低,且调整后的速度曲线呈现合理收敛趋势,各方法速度变化存在差异并伴有一定抖动,反映实际交通流的复杂性。综合而言,HRL 方法在所有关键指标上表现最佳,在奖励值、舒适性、效率性以及换道惩罚等方面显著优于其他强化学习方法,这表明分层强化学习(HRL)在换道决策任务中能够更有效地学习到合理换道策略,平衡行车舒适性与通行效率,适用于复杂的施工区环境,DuelingDQN 作为次优方法具备较好换道能力,而 DQN 和 DDQN 在该任务中表现相对较弱,使用分层强化学习可以较好的提升强化学习的效率。

接着将训练好的模型应用于实际仿真场景中进行,研究设定的流量水平根据道路实际流量划分为低流量 1750pcu/h、中等流量 3500pcu/h 以及高流量 4400pcu/h。控制状态则包括无控制、DQN、DDQN、Dueling DQN 和 HRL 五种情形,控制效果如表 5-5 所示。

无控制状态下,低流量时平均速度为 29 m/s,瓶颈流量达 1353 pcu/h,此时交通状况良好,车辆通行较为顺畅。当流量攀升至中等水平,平均速度降至 20 m/s,瓶颈流

量增长至 2703 pcu/h，表明道路开始出现拥堵趋势。高流量时，平均速度大幅下滑至 13 m/s，瓶颈流量进一步增加到 3204 pcu/h，严重拥堵状况凸显。

在引入强化学习控制方法后，各方法在不同流量下呈现出不同表现。低流量 1750 pcu/h 时，DQN 的平均速度为 27 m/s，瓶颈流量为 1400 pcu/h；DDQN 平均速度略高，达 28 m/s，瓶颈流量为 1450 pcu/h；DuelingDQN 的平均速度为 28.5 m/s，瓶颈流量为 1470 pcu/h；而 HRL 表现最为突出，平均速度达到最高的 30 m/s，瓶颈流量也最大，为 1505 pcu/h，这表明 HRL 的换道策略在低流量时能最大程度提升车辆通行效率。




图 5-1 DQN 模型与分层强化学习的训练效果对比

中等流量 3500 pcu/h 时，DQN 平均速度为 22 m/s，瓶颈流量 2750 pcu/h；DDQN 平均速度提升至 23.5 m/s，瓶颈流量为 2800 pcu/h；DuelingDQN 平均速度为 24 m/s，瓶颈流量为 2856 pcu/h；HRL 平均速度为 26 m/s，瓶颈流量为 2891 pcu/h。在此流量下，HRL 依旧保持领先，通过高效优化交通流，维持较高平均速度和最大瓶颈流量。

高流量 4400 pcu/h 时，DQN 平均速度为 14.3 m/s，瓶颈流量为 3288 pcu/h；DDQN 平均速度为 15.4 m/s，瓶颈流量为 3254 pcu/h；DuelingDQN 平均速度为 15.9 m/s，瓶颈流量为 3301 pcu/h；HRL 平均速度为 16.2 m/s，瓶颈流量为 3309 pcu/h。HRL 在复杂的高流量场景下，其平均速度和瓶颈流量均高于其他强化学习方法，彰显出强大的缓解拥堵能力。

表 5-5 强化学习换道决策模型控制效果

输入流量	1750pcu/h		3500pcu/h		4400pcu/h	
控制状态	平均速度 (m/s)	瓶颈流量 (pcu/h)	平均速度 (m/s)	瓶颈流量 (pcu/h)	平均速度 (m/s)	瓶颈流量 (pcu/h)
无控制	29	1353	20	2703	13	3204
DQN	27	1400	22	2750	14.3	3288
DDQN	28	1450	23.5	2800	15.4	3254
DuelingD QN	28.5	1470	24	2856	15.9	3301
HRL	30	1505	26	2891	16.2	3309

为验证仿真结果的合理性，本文基于无人机视频中对应时段的交通流片段进行抽样估算，计算施工区瓶颈处的最大通行能力。在典型的右侧封闭过渡区场景中，选择最为拥堵的交通状态进行瓶颈流量统计，瓶颈车道单位时间内的最大流量约为 3100 pcu/h。两者对比发现，HRL 模型在该场景下的输出瓶颈流量略有高估，存在一定偏差。产生差异的主要原因可能包括以下几点：

- 1. 模型简化假设影响：HRL 模型在控制过程中对车间距、安全空间等参数设定偏向理想化，导致车辆在接近瓶颈处表现出更高的间隙利用率，流量因此被抬高。
- 2. 行为规则优化导致激进策略：强化学习过程中模型逐渐学习出趋于效率最优的换道行为，在权衡瓶颈通行效率时易产生“激进融合”的策略偏向。
- 3. 感知-反应滞后未完全建模：现实驾驶行为中受限于人类感知-决策-执行链条，响应速度与稳定性远低于仿真中控制器，因此造成一定的实际流量折损。

尽管存在一定偏差，但模型预测结果与实际估算值相差不超过 7%，说明所构建的 HRL 控制模型在整体表现上具有较强的现实吻合性，可作为施工区瓶颈流量评估与优化决策的有效工具。在后续研究中，可进一步引入行为不确定性建模与异质性驾驶特征，以提升仿真系统对真实交通流的拟合能力与泛化效果。

综合对比，HRL 在所有流量场景下性能最优。无论是低流量时的高效通行，中等流量时对交通流的有效优化，还是高流量下强大的拥堵缓解能力，均表现卓越。DuelingDQN 表现次之，在各流量水平下性能优于 DQN 和 DDQN，尤其在高流量场景

中,通过增强状态值估计改进了换道策略,但与 HRL 相比仍存在差距。DQN 表现最差,在各流量水平下平均速度和瓶颈流量均为最低。DDQN 虽对 DQN 的 Q 值过估问题有所优化,平均速度和瓶颈流量较 DQN 有所提高,但与 DuelingDQN 和 HRL 相比,仍无法有效缓解拥堵。总体而言,HRL 凭借分层策略,能合理优化换道行为,显著提升整体交通流的通行能力,最大程度降低拥堵对平均速度的影响,是高速公路施工区交通控制的最优强化学习方法。

5.5 本章小结

本章在高速公路施工区换道预测模型的基础上进行了进一步研究,构建了一种基于分层强化学习的高速公路施工区换道决策模型。第四章中已通过并联结构的 LSTM-Transformer 网络对换道意图进行了有效建模与预测,为强化学习智能体提供了先验行为参考;在此基础上,本章进一步通过分层建模、策略训练和仿真实验验证,实现了换道行为从预测向决策控制的闭环闭合。通过将换道任务分解为行为选择和动作执行,采用 Dueling DQN 和 Policy Gradient 算法分别实现换道策略选择和加速度控制,有效提升了高速公路施工区换道决策的稳定性和适应性。

在状态与动作空间定义方面,设计了涵盖自车状态、周围车辆状态和道路环境信息的状态空间,并对状态变量进行归一化处理,提高了训练收敛速度。同时,将动作空间划分为高层决策动作空间和低层控制动作空间,使智能体能够在不同层次上进行精确决策。奖励函数设计围绕安全性、效率性和舒适性三大目标展开,通过合理的奖励机制引导智能体学习到安全、高效且舒适的换道策略。

通过在 SUMO 仿真平台上进行模型训练与优化,验证了基于分层强化学习的换道决策模型的有效性和优越性。实验结果表明,该模型在安全性、效率和舒适性方面均表现出色。引入强化学习控制方法后,各方法表现各异。低流量时,HRL 平均速度达 30m/s,瓶颈流量 1505pcu/h,表现最佳;中等流量下,HRL 以 26m/s 平均速度和 2891pcu/h 瓶颈流量领先;高流量场景中,HRL 平均速度 16.2m/s,瓶颈流量 3309pcu/h,均高于其他方法。

综合来看,HRL 在所有流量场景下性能最优,能有效优化交通流、缓解拥堵。DuelingDQN 次之,优于 DQN 和 DDQN。DQN 表现最差,DDQN 对其有一定改进但仍不足。因此,HRL 凭借分层策略,在本研究的高速公路施工区换道决策中有着最优的决策效果。

第六章 结果与展望

6.1 主要研究结论

本文聚焦于车联网环境下高速公路施工区的换道行为建模与自动驾驶决策优化问题，围绕轨迹数据获取与分析、行为建模、意图预测及智能决策等核心环节，构建了一套集数据驱动与策略学习于一体的智能换道决策方法体系。研究主要研究结论如下：

1. 施工区交通流特征分析方法

本文基于无人机视频采集技术与轨迹重建方法，建立了覆盖多种施工封闭形态的高速公路施工区轨迹数据库。通过数据清洗、标准化与行为识别，形成可用于驾驶行为建模的高质量数据集，为后续驾驶风格识别与换道行为建模提供了坚实的数据支撑并对施工区交通流的关键特征进行分析。揭示了不同施工环境对换道行为的影响，为施工区交通管理与车辆换道控制提供了理论依据。

2. 基于 MLDA 的换道行为基元提取方法

利用贝叶斯凝合分割算法对轨迹序列进行时序划分，结合混合潜在狄利克雷分配模型（MLDA）提取换道行为基元，将换道行为分为五个关键阶段。在此基础上，采用 K-Means 聚类识别驾驶风格，归纳出激进型、稳健型与保守型三类行为特征，实现了对个体换道风格的建模与量化，为后续个性化预测与决策提供了先验依据。

3. 多场景融合的换道预测模型

提出并实现了融合双层 LSTM 与 Transformer 的深度换道预测网络结构，引入动态权重机制实现对多施工场景的自适应建模。通过环境感知特征驱动子模型融合，提高了预测模型在动态交通环境中的鲁棒性。实验结果表明，该模型在多种施工场景下均保持较高的预测精度，最高准确率达 90.1%，优于传统方法。

4. 基于分层强化学习的换道决策模型

构建分层强化学习框架，将换道任务拆解为策略选择与动作控制两个模块：策略选择模块采用 Dueling DQN 算法，实现对换道意图的优化规划；动作控制模块采用 Policy Gradient 算法，输出加速度控制策略，实现连续、平稳的换道行为生成。模型状态空间融合了自车状态、环境感知信息及换道预测先验，通过多目标奖励函数从安全性、效率性与舒适性三个维度优化模型训练。

5. 基于 SUMO 平台进行仿真研究，验证其实用性与性能优势

基于真实场景构建的仿真环境，开展多流量工况下的模型性能测试。结果显示，所提分层强化学习模型在平均速度、瓶颈流量、换道成功率等核心指标上均优于传统 DQN、DDQN 及 Dueling DQN 方法。特别是在高流量复杂工况下，该模型表现出更好的通行效率与决策稳定性。

6.2 论文创新点

针对高速公路施工区内自动驾驶车辆的换道决策问题，本文从实地数据采集、行为建模、预测融合到智能体训练全过程展开系统性研究，主要创新点体现在以下几个方面：

1. 驾驶行为基元提取与风格识别相结合的换道行为建模方法

针对施工区交通环境复杂、驾驶行为不确定性强的特点，本文构建了系统的驾驶行为建模流程。利用无人机视频获取高精度轨迹数据，结合贝叶斯凝聚分割算法对换道序列进行自动分段，引入混合潜在狄利克雷分配（MLDA）模型提取具有语义清晰度的换道行为基元，进一步划分为五个换道阶段。通过 K-Means 聚类识别激进型、稳健型、保守型三类驾驶风格，为个性化换道建模提供行为先验。这一流程提升了对换道行为的结构化解析能力，并建立了统一的数据基础与风格标签体系，为后续决策模型提供有效支持。

2. 多场景融合的换道预测模型及其在强化学习中的嵌入应用

面向施工区场景中频繁变化的道路结构与交通条件，本文设计了基于 LSTM 与 Transformer 并联架构的多场景换道预测模型，充分结合 LSTM 的时序建模能力与 Transformer 的全局注意力机制，实现对复杂行为模式的精准建模。构建了三类典型施工子模型，并引入动态权重融合策略，根据交通状态与道路封闭信息实现自适应预测输出。此外，模型输出的换道概率作为先验特征嵌入到强化学习的状态空间中，有效增强了智能体的策略收敛速度与行为合理性。这一机制实现了深度学习与强化学习的深度耦合，为后续的行为决策模块奠定基础。

3. 融合先验信息的分层强化学习换道策略生成机制

针对自动驾驶车辆在施工区中换道需求受限、安全约束严苛的问题，本文构建了融合换道预测先验与驾驶风格标签的分层强化学习框架。在策略层采用 Dueling DQN 强化算法进行动作意图选择，评估各类策略在当前交通状态下的长期价值；在控制层采用 Policy Gradient 方法实现对加速度的连续控制，保障换道过程的平稳性与可执行性。状态空间融合自车状态、周围环境信息与预测先验，奖励函数综合考虑安全性、效率性与舒适性指标，并通过多组超参数组合实验优化模型性能。最终在 SUMO 仿真环境中验证其优越性，优于 DQN、DDQN、Dueling DQN 等传统方法。

6.3 研究展望

本文围绕高速公路施工区场景下的自动驾驶换道行为建模与决策方法开展系统性研究，构建了融合轨迹数据驱动、深度意图预测与强化学习策略优化的换道决策框架。然而，受限于实验条件与研究范围，仍存在部分尚未解决的问题：

1. 施工区的车联网环境建模简化

对车联网通信环境的建模主要集中于功能层面，假设车辆间信息可稳定获取，忽略了实际车联网通信中的传输延迟、丢包率、设备异构性等对感知决策链条的干扰，未能充分模拟真实部署条件下的通信不确定性。

2. 驾驶行为基元表达精度有限

尽管引入贝叶斯凝合分割算法与 MLDA 实现了换道行为的阶段性建模，但对行为基元之间的时序依赖、阶段过渡动态特征挖掘仍显粗糙，尚未实现对行为演化过程的连续建模，限制了后续预测模型的动态表达能力。

3. 意图预测与行为风格融合仍有改进空间

构建的双层 LSTM-Transformer 融合架构，虽然可以实现多场景下的换道意图预测，但前一章节中提取的驾驶风格特征仅作为静态标签参与监督建模，未能动态引导模型输出，导致个性化预测能力受限；后续研究可以考虑对注意力机制的权重进行动态调整。

4. 决策模型缺乏车辆之间的交互机制

分层强化学习决策模型主要基于单车视角展开，对周边车辆行为仅作静态建模，尚未考虑在高渗透率条件下多车间策略博弈与协同调节问题。现实中，施工区易形成车道争用和资源冲突，未来应引入多智能体建模方法，提升系统级决策协调能力。

参考文献

- [1] 李小鹏.深入学习贯彻习近平总书记关于交通强国的重要论述奋力加快建设交通强国[EB/OL]. https://www.mot.gov.cn/jiaotongyaowen/202409/t20240912_4152119.html.
- [2] 中共中央国务院.中共中央国务院印发《国家综合立体交通网规划纲要》[EB/OL]. https://www.gov.cn/gongbao/content/2021/content_5593440.htm.
- [3] 程国柱,孟凤威,陈永胜,等.考虑换道风险动态评估的快速路合流区CAV换道决策模型研究[J]. 中国公路学报: 1-23.
- [4] 何小洲,过秀成,吴平,等.高速公路施工区交通特性分析[J].公路,2005(12): 6.
- [5] 段克.高速公路施工区换道汇合风险分析与管控策略研究[D]:[博士]北京交通大学,2022.
- [6] 刘潇.面向高速环境的自动驾驶车辆行为决策、规划与控制研究[D]: [博士]. 浙江大学,2023.
- [7] 宋昊辰,杨林,徐华伟,等.智能网联汽车信息安全综述[J]. 信息安全与通信保密,2020(7): 9.
- [8] 常浩.车路协同下的车辆换道驾驶辅助方法研究[D]: [硕士]. 北京交通大学,2015.
- [9] Chang X, Li H, Rong J, et al. Analysis of Capacity for Mixed Traffic Flow with Connected Vehicle Platoon on Freeway [J]. Huanan Ligong Daxue Xuebao/Journal of South China University of Technology (Natural Science), 2020, 48(4).
- [10] 王强,邓建华.不同驾驶风格车辆自由换道演化博弈机制[J]. 内燃机与配件,2024(18): 7-11.
- [11] Xu D, Xue C, Zhou H. Analysis of headway and speed based on driver characteristics and work zone configurations using naturalistic driving study data [J]. Transportation research h record, 2021, 2675(10): 1196-1210.
- [12] Racha S, Chowdhury M, Sarasua W, et al. Analysis of work zone traffic behavior for planning applications [J]. Transportation Planning and Technology, 2008, 31(2): 183-199.
- [13] 张犇,李永,刘涛,等.车道缩减路段自动车辆协同换道控制[J/OL].控制与决策,1-11[2025-05-06].<https://doi.org/10.13195/j.kzyjc.2024.0845>.
- [14] 李耘.高速公路施工区交通流特性与安全风险分析[D]: [博士]. 长安大学,2014.
- [15] Weng J, Meng Q, Fwa T F. Vehicle headway distribution in work zones [J]. Transportmetrica A: Transport Science, 2014, 10(4): 285-303.
- [16] 朱慧芳.高速公路施工区交通组织方案优化及仿真评价[D]: [博士]. 长安大学,2011.
- [17] Genders W, Razavi S N. Impact of connected vehicle on work zone network safety through dynamic route guidance [J]. Journal of Computing in Civil Engineering, 2016, 30(2): 04015020.
- [18] 杨正艳.高速公路多交通车场景下智能车辆换道决策及轨迹规划研究 [D]: [Master's Thesis]. 长安大学,2024.
- [19] 马瑞兰.多车协同换道决策控制策略研究[J]. 内燃机与配件,2024(20): 5-8.
- [20] 方华珍,刘立,顾青,等.基于换道意图和强化学习的车辆匝道汇入决策[J]. 无人系统技术,2024,7(05): 111-119.
- [21] 姜文鑫,吴志周,许宏鑫,等.基于强化学习的自动驾驶汽车换道决策研究[J]. 计算机工程与应用: 1-13.
- [22] 冯超铭.高速公路施工作业区的安全管理[J]. 广东交通职业技术学院学报,2004,3

- (1): 3.
- [23] 吴彪,许洪国,戴彤焱,等. 考虑驾驶员认知过程的高速公路施工区 MVMS 前置距离计算模型[J]. 交通信息与安全,2013 (2): 5.
- [24] Ma C, Li D. A review of vehicle lane change research [J]. Physica A: Statistical Mechanics and its Applications, 2023, 626: 129060.
- [25] Chen Y, Dong C, Palanisamy P, et al. Attention-based hierarchical deep reinforcement learning for lane change behaviors in autonomous driving [C]. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops. 2019: 0-0.
- [26] 张磊,彭金栓,宋臻,等. 车道变换行为研究进展[J]. 重庆理工大学学报(自然科学),2022,36 (11): 40-50.
- [27] 侯海晶,金立生,关志伟,等. 驾驶风格对驾驶行为的影响[J]. 中国公路学报,2018,31 (04): 18-27.
- [28] 李阳钊,陈海华,黄申春,等. 基于自然驾驶轨迹数据的城市快速路小型车辆换道特性分析[J]. 交通信息与安全,2024,42 (05): 33-41.
- [29] 王畅,付锐,张琼. 换道决策中的车辆速度估计模型[J]. 交通运输工程学报,2015,15 (06): 83-91.
- [30] 朱乃宣. 仿驾驶员行为的智能汽车横向决策方法研究[D]: [博士]. 吉林大学,2024.
- [31] 车松珊,钱勇生,曾俊伟,等. 基于驾驶人有限理性的交织区换道行为决策[J]. 公路交通科技,2023,40 (09): 166-174.
- [32] 朱凯家,邓天民. 客运驾驶员驾驶行为分析及车速预测方法研究[D]: [硕士]. 重庆交通大学,2022.
- [33] 王琦,胡宏宇. 基于可解释深度学习的自动驾驶汽车预测任务研究[D]: [博士]. 吉林大学,2023.
- [34] 张俊杰,马永锋,陈淑燕,等. 高速公路施工区车队被动换道行为建模与仿真[J]. 浙江大学学报(工学版),2024,58 (2): 381-387.
- [35] Duan K, Yan X, Li X, et al. Improving drivers' merging performance in work zone using an in-vehicle audio warning [J]. Transportation research part F: traffic psychology and behaviour, 2023, 95: 297-321.
- [36] 朱伯青. 高速公路入口匝道智能网联汽车换道模型研究[D]: [博士]. 天津职业技术师范大学,2023.
- [37] 肖哲. 车联网条件下八车道高速公路施工区可变限速控制方法[D]: [硕士]. 东南大学,2022.
- [38] Domenichini L, La Torre F, Branzi V, et al. Speed behaviour in work zone crossovers. A driving simulator study [J]. Accident Analysis & Prevention, 2017, 98: 10-24.
- [39] 季文韬. 基于强化学习的高速公路施工区可变限速控制方法[D]: [硕士]. 东南大学,2022.
- [40] 段克. 高速公路施工区换道汇合风险分析与管控策略研究[D]: [博士]. 北京交通大学,2023.
- [41] Adeel M, Khattak A J, Mishra S, et al. Enhancing work zone crash severity analysis: The role of synthetic minority oversampling technique in balancing minority categories [Z]. In: Accident Analysis and Prevention: Vol. 208. Elsevier Ltd, 2024.
- [42] Zhu Y, Yue L, Sun J. Modeling the Driver's Lane-Changing Decision Under the Influence of the Blind Zone Image of an Intelligent Vehicle: A Practice Based on Cognitive-Driven Large Language Model [Z]. In: Proceedings of the 2024 8th CAA International Conference

- e on Vehicular Control and Intelligence, CVCi 2024. Institute of Electrical and Electronics Engineers Inc., 2024.
- [43] 张龙钊. 高速公路施工区车辆换道行为研究[D]: [硕士]. 哈尔滨工业大学, 2022.
- [44] Li Q L, Liu J, Jiang R, et al. Research on a work zone model with metering zone under mixed traffic flow environment [Z]. In: International Journal of Modern Physics C: Vol. 35. World Scientific, 2024.
- [45] Jiao Y, Zhu X, Ji X, et al. Empirical Studies on Merging Characteristics in Temporary Highway Work Zones with Different Traffic States and Layouts [Z]. In: Algorithms: Vol. 17. Multidisciplinary Digital Publishing Institute (MDPI), 2024.
- [46] 梁志康. 高速公路施工区智能网联车辆控制策略仿真研究[D]: [硕士]. 吉林大学, 2019.
- [47] 黄群龙. 高速公路改扩建施工区通行能力研究[D]: [硕士]. 北京工业大学, 2021.
- [48] 梁晨曦, 郝孜奇, 王川, 等. 高速公路事故路段智能网联车辆博弈换道模型[J]. 公路, 2024, 69 (06): 197-203.
- [49] Maddineni V K, Ansarinejad M, Ahmed M M. Safety and operational impacts of different Autonomous Vehicle operations on freeway work zones [Z]. In: Advances in Transportation Studies: Vol. 4. Aracne Editrice, 2024: 117-126.
- [50] 刘志强, 王俊彦, 汪澎, 等. 基于 BP 神经网络的高速公路入口合流区域换道行为研究[J]. 公路交通科技, 2014, 31 (9): 5.
- [51] 陆键, 王可, 蒋愚明. 基于车辆行驶轨迹的道路不良驾驶行为实时辨识方法[J]. 交通运输工程学报, 2020, 20 (6): 227-235.
- [52] Gipps P G. A model for the structure of lane-changing decisions [J]. Transportation Research Part B: Methodological, 1986, 20(5): 403-414.
- [53] Kosonen I. HUTSIM-Urban traffic simulation and control model: principles and applications [J]. 1999.
- [54] Chen C, Li L, Hu J, et al. Calibration of MITSIM and IDM car-following model based on NGSIM trajectory datasets [C]. In: Proceedings of 2010 IEEE International Conference on Vehicular Electronics and Safety. IEEE, 2010: 48-53.
- [55] Casas J, Ferrer J L, Garcia D, et al. Traffic simulation with aimsun [J]. Fundamentals of traffic simulation, 2010: 173-232.
- [56] Pan W, Xue Y, He H D, et al. Impacts of traffic congestion on fuel rate, dissipation and particle emission in a single lane based on Nasch Model [J]. Physica A: Statistical Mechanics and its Applications, 2018, 503: 154-162.
- [57] Kesting A, Treiber M, Helbing D. General lane-changing model MOBIL for car-following models [J]. Transportation Research Record, 2007, 1999(1): 86-94.
- [58] Ali Y, Zheng Z, Haque M M, et al. A game theory-based approach for modelling mandatory lane-changing behaviour in a connected environment [J]. Transportation research part C: emerging technologies, 2019, 106: 220-242.
- [59] 陆春意, 何赏璐, 高彬彬, 等. 基于博弈论的自动驾驶驶离专用车道换道决策模型[J]. 交通信息与安全, 2024, 42 (04): 144-153+174.
- [60] 黄平. 面向交通冲突场景的自动驾驶车辆换道博弈决策方法研究[D]: [博士]. 吉林大学, 2024.
- [61] 黄开启, 瞿桃欢, 黄明禹, 等. 基于演化博弈的车辆换道研究[J]. 公路交通科技, 2024, 41 (08): 31-39.

- [62] 孟少寅,徐良杰. 基于演化博弈论的高承载车道共享决策方法[J]. 武汉理工大学学报(交通科学与工程版),2024,48 (06): 1057-1062.
- [63] Chen W, Ren G, Cao Q, et al. A game-theory-based approach to modeling lane-changing interactions on highway on-ramps: Considering the bounded rationality of drivers [J]. Mathematics, 2023, 11(2): 402.
- [64] 王嵩. 基于博弈论的混合车辆交互变道决策模型研究[D]: [硕士]. 长春工业大学,2024.
- [65] 徐兵,刘潇,汪子扬,等. 采用梯度提升决策树的车辆换道融合决策模型[J]. 浙江大学学报(工学版),2019,53 (06): 1171-1181.
- [66] Dogan Ü, Edelbrunner J, Iossifidis I. Autonomous driving: A comparison of machine learning techniques by means of the prediction of lane change behavior [C]. In: 2011 IEEE International conference on robotics and biomimetics. IEEE, 2011: 1837-1843.
- [67] Khelfa B, Ba I, Tordeux A. Predicting highway lane-changing maneuvers: A benchmark analysis of machine and ensemble learning algorithms [J]. Physica A: Statistical Mechanics and its Applications, 2023, 612: 128471.
- [68] 房哲哲. 基于深度学习的换道行为建模与分析[D]: [硕士]. 北京交通大学,2018.
- [69] 罗归权,张兆磊,易可夫,等. 基于深度强化学习的匝道合流区车辆自主换道方法[J]. 交通科学与工程: 1-12.
- [70] Vallon C, Ercan Z, Carvalho A, et al. A machine learning approach for personalized autonomous lane change initiation and control [C]. In: 2017 IEEE Intelligent vehicles symposium (IV). IEEE, 2017: 1590-1595.
- [71] 刘普俊. 基于时变协方差隐马尔可夫模型的周车换道意图识别方法研究[D]: [硕士]. 吉林大学,2024.
- [72] 鲁爽. 基于双向 LSTM 的自动驾驶汽车周车轨迹预测研究[D]: [硕士]. 吉林农业大学,2024.
- [73] 刘晗,丁康展. 基于 LSTM 的车辆换道意图识别研究[J]. 时代汽车,2024 (21): 157-159.
- [74] Benterki A, Boukhni M, Judalet V, et al. Prediction of surrounding vehicles lane change intention using machine learning [C]. In: 2019 10th IEEE International Conference on Intelligent Data Acquisition and Advanced Computing Systems: Technology and Applications (IDAACS): Vol. 2. IEEE, 2019: 839-843.
- [75] 贾寒冰,刘鹏,张雷,等. 基于规则与机器学习融合的换道决策建模方法研究[J]. 机械工程学报,2022,58 (04): 212-221.
- [76] 李柏. 复杂约束下自动驾驶车辆运动规划的计算最优控制方法研究[D]: [博士]. 浙江大学,2018.
- [77] 胡林,杨冬兆,张新,等. 基于 DQP-LMPC 的智能车超车换道动态路径规划[J]. 机械工程学报,2024,60 (10): 171-181.
- [78] Dong C, Wang H, Li Y, et al. Application of machine learning algorithms in lane-changing model for intelligent vehicles exiting to off-ramp [J]. Transportmetrica A: transport science, 2021, 17(1): 124-150.
- [79] 陆文琦. 车路协同环境下高速公路车道级管理与控制方法研究[D]: [博士]. 东南大学,2023.
- [80] 胡锦涛超. 面向合流区安全和效率提升的车路协同路端智能辅助决策方法研究[D]: [博士]. 东南大学,2023.

- [81] Das A, Khan M N, Ahmed M M. Detecting lane change maneuvers using SHRP2 naturalistic driving data: A comparative study machine learning techniques [J]. Accident Analysis & Prevention, 2020, 142: 105578.
- [82] 上海市公路管理处. 公路养护安全作业规程[M]. 公路养护安全作业规程, 2004.
- [83] Oh M, Shaw J, Dong-O'Brien J. Enhancing work zone safety: a psychological and behavioral analysis of anti-tailgating strategies using dynamic message signs and fixed warning signs [J]. Transportation Research Part F: Traffic Psychology and Behaviour, 2024, 106: 150-168.
- [84] 戢杨杰, 张馨雨, 杨紫茹, 等. 多智能网联汽车轨迹规划: 现状与展望[J]. 机械工程学报, 2024, 60 (10): 129-146.
- [85] 谭征宇, 张瑞佛, 刘芝孜, 等. 智能网联汽车人机交互信任研究现状与展望[J]. 机械工程学报, 2024, 60 (10): 366-383.
- [86] Chen Y, Dong C, Lyu K, et al. A review of car-following and lane-changing models under heterogeneous environments [J]. Physica A: Statistical Mechanics and its Applications, 2024, 654: 130127.
- [87] 杨智勇, 杨俊, 欧明辉, 等. 智能网联汽车轨迹预测研究现状与趋势[J]. 重庆理工大学学报(自然科学), 2024, 38 (09): 1-13.
- [88] 李春, 吴志周, 曾广, 等. 合流区智能网联汽车协同控制方法综述[J]. 计算机工程与应用, 2024, 60 (12): 1-17.
- [89] 郭雅楠, 范旭东. 基于文献计量学的智能网联汽车交互设计研究进展及趋势[J]. 包装工程, 2024, 45 (24): 86-98.
- [90] GB/T 40429-2021 汽车驾驶自动化分级[S].
- [91] 柴锐. 车联网环境下的驾驶行为特性研究[D]: [博士]. 北京理工大学, 2016.
- [92] Bouchouia M L, Labiod H, Jelassi O, et al. A survey on misbehavior detection for connected and autonomous vehicles [J]. Vehicular Communications, 2023, 41: 100586.
- [93] Sumalee A, Ho H W. Smarter and more connected: Future intelligent transportation system [J]. IATSS Research, 2018, 42(2): 67-71.
- [94] Cen B ling, Xue Y, Zhang K, et al. Study on traffic flows with connected vehicles and human-driven vehicles [J]. Applied Mathematics and Computation, 2025, 490: 129182.
- [95] 刘宇翔. 基于驾驶行为基元的换道风格分类方法研究[D]: [博士学位论文]. 2023.
- [96] 郑奇. 智能驾驶中驾驶员风格识别及车辆行为预测研究[D]: [硕士]. 浙江大学, 2022.
- [97] 陈嘉昊. 基于驾驶风格的智能网联车辆博弈换道行为研究[D]: [硕士]. 石家庄铁道大学, 2023.
- [98] 周平尹. 基于贝叶斯序列分割的高维时间序列在线分类算法[J]. 计算机应用与软件, 2021, 38 (8).
- [99] Bouhissin S, Sael N, Benabbou F. Driver behavior classification: a systematic literature review [J]. IEEE Access, 2023, 11: 14128-14153.
- [100] 赵文静. 车联网环境下实时交通信息对驾驶行为的影响研究[D]: [博士]. 中南大学, 2023.
- [101] 牛军. 高速公路主线瓶颈路段交通流预测与控制方法研究[D]: [博士]. 长安大学, 2023.
- [102] Ao Y, Zhu H, Wang Y, et al. Identifying the driving factors of rural residents' household waste classification behavior: Evidence from Sichuan, China [J]. Resources, Conservation and Recycling, 2022, 180: 106159.

-
- [103] Liu Y, Wang X, Li L, et al. A Novel Lane Change Decision-Making Model of Autonomous Vehicle Based on Support Vector Machine [J]. IEEE Access, 2019, 7: 26543-26550.
- [104] Wang Z, Huang H, Tang J, et al. A deep reinforcement learning-based approach for autonomous lane-changing velocity control in mixed flow of vehicle group level [J]. Expert Systems with Applications, 2024, 238: 122158.

毕业/学位论文答辩委员会名单

毕业/学位论文题目		车联网条件下高速公路施工区换道行为与决策方法研究		
作 者		马宇恒		
专 业		交通运输		
研究方向		交通运输规划与管理		
导 师		过秀成		
答辩委员会组成	姓 名	职 称	学科专业	工作单位
	任刚 (主席)	教授	交通运输工程	东南大学
	邓一凌	教授	交通运输工程	浙江工业大学
	何赏璐	副教授	交通运输工程	南京理工大学
	朱震军	副教授	交通工程	南京林业大学
	罗丽梅	高级工程师	交通运输工程	南京市城市与交通规划设计研究院
	刘培 (秘书)	研究实习员	交通运输工程	东南大学

备注：

- 1、本表格适用于所有研究生。
- 2、本表格排版在终版毕业/学位论文中，附在毕业/学位论文的最后。