

分类号：TP23

单位代码：11510

学号：19021005

密级：



山东交通学院

专业学位硕士学位论文

(2022 届)

面向高速公路预警跟随车视觉导航的锥桶检测算法研究

Research on Traffic Cone Detection Algorithm for Visual
Navigation of Expressway Warning Following Vehicle

论文作者：刘志远

学科专业：船舶与海洋工程

指导教师：潘为刚 王书新

所在学院：信息科学与电气工程学院
(人工智能学院)

2022 年 5 月 27 日

分类号： TP23
学号： 19021005

单位代码： 11510
密级：

山东交通学院

专业学位硕士学位论文

面向高速公路预警跟随车视觉导航的锥桶检测算法研究

Research on Traffic Cone Detection Algorithm for Visual Navigation
of Expressway Warning Following Vehicle

论文作者：	刘志远
学科专业：	船舶与海洋工程
研究方向：	船舶电子电气与轮机工程
指导教师：	潘为刚 王书新
所在学院：	信息科学与电气工程学院 (人工智能学院)

2022 年 5 月 27 日

目 录

摘 要	I
ABSTRACT	II
1 绪论	1
1.1 研究背景及意义	1
1.2 国内外相关技术研究现状	2
1.2.1 高速公路视觉导航技术	2
1.2.2 交通锥桶目标检测技术	3
1.2.3 深度学习与云边端架构融合技术	4
1.3 研究内容与章节安排	5
2 基于云边端架构的高速公路预警跟随车系统设计	7
2.1 系统需求分析	7
2.1.1 高速公路预警跟随车系统需求分析	7
2.1.2 智慧高速公路云边端架构需求分析	8
2.2 高速公路云边端架构设计	9
2.2.1 硬件平台搭建	9
2.2.2 云边端架构数据分配体系	12
2.3 基于高速公路预警跟随车系统的终端实现	13
2.4 本章小结	14
3 基于纹理特征的交通锥桶检测算法研究	15
3.1 基于纹理特征的锥桶检测算法	15
3.1.1 锥桶特征分析	15
3.1.2 图像预处理	16
3.1.3 基于纹理特征的约束条件	22
3.2 基于 Retinex 的图像增强算法	24
3.3 基于亮度的阈值分类选取算法	28
3.4 实验验证	29
3.4.1 实验平台环境	29

3.4.2 实验结果分析	29
3.5 本章小结	34
4 基于深度学习的复杂环境下交通锥桶检测算法研究	35
4.1 复杂环境下的交通锥桶数据集构建	35
4.2 YoloV4 网络模型	37
4.3 MobileNetV3_YoloV4 网络模型	38
4.3.1 轻量化网络 MobileNet	38
4.3.2 MobileNetV3 与 YoloV4 算法融合	42
4.4 实验验证	42
4.4.1 实验平台环境	42
4.4.2 性能评估指标	43
4.4.3 实验结果分析	44
4.5 本章小结	45
5 基于 MobileNetV3_YoloV4 的锥桶检测算法改进	46
5.1 基于浅层特征的改进	46
5.1.1 检测层尺度改进	46
5.1.2 MobileNetV3 网络结构改进	47
5.1.3 图片尺寸优化	49
5.2 基于先验框的 MobileNetV3_YoloV4 改进	50
5.2.1 K-means 聚类算法介绍	50
5.2.2 基于先验框的算法优化	50
5.3 基于轻量化注意力机制的改进	53
5.4 基于改进方法的算法融合	55
5.5 实验验证	57
5.6 本章小结	60
6 总结与展望	62
6.1 总结	62
6.2 创新点	62
6.3 展望	63

参考文献	64
致 谢	69
在校期间主要科研成果	70
一、发表学术论文	70
二、其它科研成果	70

摘 要

随着我国交通路网逐渐完善,智慧高速公路建设的不断推进,自动驾驶技术发展迎来了新的机遇。视觉导航作为自动驾驶领域中的关键技术,成为重点研究对象,其与深度学习、5G 通信技术相融合,在交通运输领域中形成了新的发展趋势。在高速公路移动养护作业中,快速行驶的车辆很容易对人员和设备造成威胁,利用视觉导航技术研发一种具备自动跟随功能的高速公路预警跟随车是亟需的。预警跟随车的关键技术在于视觉导航,可通过高速公路上的交通锥桶实现定位。本文以云边端架构的高速公路预警跟随车系统为平台,在道路养护工作背景下,对视觉导航关键技术中的交通锥桶检测算法进行了深入研究。主要工作内容如下:

第一,依据云边端技术体系,搭建了云边端系统。首先,根据实验室现有环境搭建了由云服务器、边缘控制器和终端组成的网络平台;其次,设计了云边端架构通信方案,并根据云、边、端各自的特点对数据资源的分配进行了分析;最后,组装了高速公路预警跟随车的终端系统。

第二,基于图像处理技术,实现了基于纹理特征的交通锥桶检测。首先,对锥桶图像进行特征分析,确定了锥桶的颜色和形状两种明显的纹理特征;其次,对锥桶图像进行预处理,分析了基于纹理特征的约束条件,最终提出了基于 HSV 颜色空间的 V 通道直方图均衡化图像增强算法;然后,针对夜晚环境锥桶检测率低的问题,采用改进的 Retinex 图像增强算法,改善了锥桶检测效果;最后,将 V 通道直方图均衡化与 Retinex 增强算法相结合,提出了基于亮度的阈值分类选取算法,提高了复杂环境下的锥桶检测性能。

第三,基于深度学习理论,实现了复杂环境下交通锥桶检测。首先,针对高速公路环境复杂、锥桶种类多而导致识别率低的问题,自建复杂环境下的交通锥桶数据集;其次,为了提高锥桶检测速度,采用 MobileNetV3 轻量化网络,保证了算法的实时性;再次,针对 MobileNetV3_YoloV4 对小目标检测性能不足的问题,分别从网络浅层特征、先验框和注意力机制三个方面对原算法改进,并研究了改进方式融合的方法;最后,在搭建的云边端架构下进行实验验证,实验结果表明,改进后的算法整体性能大幅提高,符合预警跟随车对实时性和安全性的要求。

关键词: 智慧高速公路;云边端架构;交通锥桶检测;MobileNetV3_YoloV4

ABSTRACT

With the gradual improvement of my country's transportation network and the continuous advancement of the construction of smart highway, the development of autonomous driving technology has ushered in new opportunities. As a key technology in the field of autonomous driving, visual navigation has become a key research object. Its integration with deep learning and 5G communication technology has formed a new development trend in the field of transportation. In highway mobile maintenance operations, fast-moving vehicles can easily threaten personnel and equipment. It is urgent to develop a highway warning follower vehicle with automatic follow-up function using visual navigation technology. The key technology of early warning following cars lies in visual navigation, which can be positioned through the traffic cone on the highway. In this paper, based on the cloud edge framework highway warning and following car system, under the background of road maintenance work, the traffic cone detection algorithm in the key technology of visual navigation is deeply studied. The main work contents are as follows:

First, based on the cloud edge framework technology system, a cloud edge framework is built. Firstly, a network platform consisting of cloud servers, edge controllers and terminals is built according to the existing environment of the laboratory; secondly, a cloud edge framework communication scheme is designed, and data resources are allocated according to the characteristics of cloud, edge and terminal. The analysis is carried out; finally, the terminal system of the highway warning following car is assembled.

Second, based on image processing technology, the detection of traffic cone buckets based on texture features is realized. Firstly, the feature analysis of the traffic cone image is carried out, and two obvious texture features of the color and shape of the traffic cone are determined; secondly, the traffic cone image is preprocessed, and the constraints based on texture features are analyzed, and finally the proposed V-channel histogram equalization image enhancement algorithm based on HSV color space; then, for the problem of low detection rate of traffic cone in the night environment, an improved Retinex image enhancement algorithm is used to improve the detection effect of traffic cone; finally, the V-channel Combined with histogram equalization and Retinex enhancement algorithm, a brightness-based threshold classification and

selection algorithm is proposed, which improves the detection performance of traffic cone in complex environments.

Third, based on deep learning theory, the detection of traffic cone in complex environments is realized. Firstly, in view of the problem of low recognition rate due to complex highway environment and many types of traffic cone, a self-built traffic cone dataset under complex environment; The real-time performance of the algorithm is improved; thirdly, in view of the insufficient performance of MobileNetV3_YoloV4 for small target detection, the original algorithm is improved from the three aspects of network low-level features, anchor and attention mechanism, and the method of fusion of improved methods is studied; Finally, the experimental verification is carried out under the built cloud edge framework. The experimental results show that the overall performance of the improved algorithm is greatly improved, which meets the real-time and safety requirements of the early warning follower vehicle.

Key words: Smart highway; Cloud edge framework; Traffic cone detection; MobileNetV3_YoloV4

1 绪论

1.1 研究背景及意义

目前,全国公路通车总里程已超过 519.8 万公里^[1],随着物联网和云计算技术从实验室走向实际应用,智慧高速公路逐渐成为新的发展趋势,正朝着车路智能协同和自动驾驶方向迈进。智慧高速公路作为公路行业信息化和智能化发展程度最高的领域之一,对加快交通强国建设、推进智慧交通建设具有重要意义。

随着自动驾驶技术的不断发展,具有自动驾驶特征的服务型机器人^[2-3]、物流配送车辆^[4-5]、智能公共交通工具^[6-7]等相继出现。近年来,基于视觉导航的技术在自动驾驶、人工智能等方面逐渐完善,并逐渐成为智慧高速公路信息感知的重要方式。视觉导航的关键技术在于对目标物体的检测与定位,受外部环境的影响较大,如在采集的图像的过程中自然环境下的光照变化、外界天气环境的变化等^[8];且视觉导航算法的计算复杂度较高,目标检测效率较低,而采用深度学习算法,虽然可以提高检测精度,但对硬件配置有着较高的要求,实时性难以得到保障,由此会直接影响到系统的稳定性和安全性。

针对高速公路自动驾驶、视觉导航等对响应时间要求高、计算量复杂的场景,云边端架构应运而生。采用“云边端”协同控制的方式,可以有效结合云计算强大的资源服务与边缘计算低时延特性,推动自动驾驶、智慧交通的基础设施建设,支撑智慧高速公路项目的实际落地^[9]。

随着我国公路的建设以及交通需求的快速发展,高速公路养护正成为我国公路发展的新主题。在高速公路养护作业中,根据养护工作施工标准,需要设置警示装置以提醒后方驾驶人员注意安全^[10],但传统的警示装置需要人工搬运,不适用于移动养护作业,且警示效果单一,容易造成交通事故。本文设计的高速公路预警跟随车系统,可以自动跟随施工车辆移动,实施智能预警,有效提醒后方来车注意安全。实现高速公路预警自动跟随功能的关键在于导航技术。本文设计的系统,采用视觉导航技术,根据道路中车道线、交通锥桶等标志物的位置信息进行定位与路径拟合。由于施工路面的车道线存在残损、长距离间断、遮挡的情况,作为检测目标会导致定位不准等情形。交通锥桶作为道路养护作业中的必备警示装备之一,可作为临时隔离带,用于分割或合并车道,提醒驾驶人员注意安全,

故交通锥桶定位技术可以作为首选定位目标。因此，交通锥桶目标检测技术具有重要的研究意义。

1.2 国内外相关技术研究现状

1.2.1 高速公路视觉导航技术

视觉导航技术即通过计算机视觉来完成目标定位与路径规划，是自动驾驶技术的重要组成部分，也是推进智慧高速公路建设的关键技术；视觉导航技术的关键在于目标识别与定位，识别的目标主要包括车辆、车道线、交通指示牌等。

(1) 车辆检测

在高速公视觉导航中，国内外以车辆作为导航目标的研究较多，检测方法大体分为两类。

一类是传统目标检测算法，包括基于激光雷达的车辆检测、分类器特征提取等方法，如陆德彪等人^[11]提出了基于激光雷达的车辆目标检测与跟踪方法，通过激光雷达的深度数据获取目标特征。刘金清等人^[12]采用 Hog 和 Gentle-AdaBoost 多个分类算法融合的方法检测车辆，能准确地识别车辆，但实时性较差。于莉媛等人^[13]根据车辆尾灯的光晕和亮度进行特征提取，提出了基于尾灯的夜间车辆检测与跟踪方法，提高了夜晚环境下车辆检测的准确率。谭力凡等人^[14]利用 Haar-like 特征与 AdaBoost 算法训练车辆样本分类器，提高了车辆检测的准确率。

另一类是基于深度学习的目标检测方法，如罗梅^[15]设计了基于深度学习的高速公路车辆检测与跟踪系统，通过对驾驶行为判定、车流量统计等辅助交通管理。刘军等人^[16]针对小目标车辆和车辆检测实时性问题，提出了改进的 Tiny_YoloV3 模型，检测速度和精度均有所提升。周苏等人^[17]提出了基于车载视频图像的车辆检测与跟踪算法，通过改进 YoloV3 算法，提高了整体检测精度。

(2) 车道线检测

车道线作为道路的主要标记线，国内外学者对此目标识别研究较为深入。检测方法同样分为传统目标检测算法和深度学习目标检测算法两类。王志、杨妍、黄晓青、李军等人^[18-21]，采用传统的 Hough 直线变换算法检测车道线，检测速度快，但容易受外界环境的影响，鲁棒性不高。赵岩等人^[22]提出了一种基于轮廓筛选的车道线检测方法，在保证实时性的前提下，提高了算法的抗遮挡能力。邓元望等人^[23]设计了基于 RC-DBSCAN 的车道线检测算法，融合边缘检测与颜色空间

阈值分割算法,提出了基于 DBSCAN 二次聚类的特征点聚类算法,提高了车道线检测的可靠性。Abualsaud 等人^[24]结合 Affinity Field 聚类 and 二分类的方法对车道线进行检测和分割,提出了 LaneAF 算法,不仅可以提高车道线检测精度,还可以实现任意数量的车道线实例分割。高扬等人^[25]对 VGG 神经网络进行改进,并融合空洞卷积,提出了一种基于深度学习的车道线检测方法,该算法在复杂环境下依然有较好的表现。刘莉^[26]提出了一种基于多层级、多尺度卷积神经网络的车道线检测方法,检测精度大幅提升。Tabelini 等人^[27]结合卷积神经网络和注意力机制,提出了一种车道线检测模型,提高了车道线检测性能。

(3) 交通指示牌识别

Lee 等人^[28]利用卷积神经网络,有效检测出交通指示牌标志的位置和边界信息。刘顺民等人^[29]提出了一种基于 SSD 算法的交通指示牌目标检测方法,在 SSD 算法的基础上使用特征金字塔,融合浅层和深层特征,提高了对交通指示牌的检测性能。陈柏立等人^[30]利用卷积神经网络实现了对交通路标的识别。首先利用直方图均衡化进行图像增强,然后构建 LeNet5 结构的卷积神经网络。相比于传统的识别方法,检测率大幅提高。霍爱清等人^[31]提出结合深度残差网络和 GRU 网络的 SqueezeNet 模型,同时提高了算法对交通指示牌的检测精度和速度。

1.2.2 交通锥桶目标检测技术

道路养护作业中,交通锥桶是必备的警示装置,常摆放在施工队伍后方和施工区域一侧;在特殊工作环境中实现自动驾驶,锥桶的检测定位是必不可少的。通过查阅大量文献,发现国内外对交通锥桶检测的研究较少,方法大致可分为两类。

第一类通过颜色和结构特征检测锥桶。其中,Wang 等人^[32]采用两个单色相机获取目标位置信息,采用两个彩色相机获取颜色信息,联合深度、颜色和结构信息检测锥桶,但此方法受光照影响较大。Yong 等人^[33]提出了一种基于视觉和雷达信息融合的锥桶检测方法。首先利用标定的方法将雷达数据映射到图像上,再结合倒角匹配和颜色信息寻找图像中的红色圆锥体,最终得到交通锥桶的位置信息。此方法有较高的实时性,但受周围环境和光照的影响较大,且仅能检测单一类型的锥桶,检测的准确率不高。

第二类运用分类器和神经网络算法识别交通锥桶。其中,Zhou 等人^[36]融合颜

色、形状、几何和分类器信息对交通锥桶进行识别。首先根据颜色信息找出感兴趣区域，再利用深度相机计算出每个像素点的深度值，通过匹配图像中交通锥桶距离与面积的比例关系可去除大部分异常数据。然后采用 AdaBoost 算法训练分类器再次进行数据筛选，最终完成对交通锥桶的检测。但此方法在颜色阈值筛选部分容易受到光照、阴影的影响，若交通锥桶有部分遮挡或污渍，检测的准确率会有所下降。Jun 等人^[37]同样提出了一种视觉与雷达信息融合的方法。激光雷达获取点云信息，通过欧式聚类的方法，过滤出尺寸大小与锥桶相近的物体，结合 HOG 特征和 SVM 分类器精准识别锥桶，但激光雷达在遮挡条件下无法获得足够的特征点，受周围大型运动物体的影响较大，且其控制器有较大的时延和误差。Dhall 等人^[38]结合深度学习算法和交通锥桶结构特征，利用单目相机准确识别出了交通锥桶及其三维位置信息。首先利用 YoloV2 目标检测算法识别锥桶及其 2D 位置信息，然后根据改进的卷积神经网络确定锥桶的七个特征点位置信息，最后利用 PnP (Perspective-n-Point) 算法将锥桶从二维位置转换到三维位置，从而得到交通锥桶的三维位置信息。此方法降低了光照和周围环境对交通锥桶检测影响，检测的准确率高，但检测类型单一，只针对特定类型的交通锥桶。

1.2.3 深度学习与云边端架构融合技术

云边端架构是一种新型计算范式，将云计算强大的计算能力与边缘计算的高响应速度特性相结合^[39]，并且边缘计算的快速发展使得人工智能算法可以部署在边缘侧，减轻了云端的海量计算压力。

尽管借助多信息融合以及深度学习方法准确识别率好，但其固有计算复杂度和高样本要求，与高速公路养护作业现场的强实时性需求不匹配，实际应用的可能性较低。而强大的云边端架构协同控制是解决上述的问题的有效途径。Wang 等人^[40]提出了用于实时查询大规模监控视频流的云边缘系统，提高了视频实时查询的响应时间和准确率。Wu 等人^[41]提出一种云边端协同控制下的情感识别框架，减少了模型训练时间，提高了情感识别准确率。Ghosh 等人^[42]将边缘和云计算与物联网数据相结合，利用边缘节点减少机器学习任务中的网络延迟问题，且不会对机器学习的准确率产生影响。Li 等人^[43]提出了神经网络与云边端架构相结合方法，将云功能从网络中心推送到网络边缘，通过边缘计算实现了低延迟和高能效的神经网络推理。唐博恒等人^[44]以计算机视觉深度学习网络为切入点，分析了云侧和边缘侧的优缺点，云边端协同控制可以有效减轻云端的带宽压力，提高神经网络

处理的实效性。马富齐等人^[45]构建了云边端协同的电力视觉边缘智能结构框架，提高了电力系统智能终端处理海量影像信息的能力。

综上所述，智慧高速公路的视觉导航技术发展相对完善，尤其是对车辆、车道线和交通指示牌的目标识别技术。然而，道路养护作业中的锥桶检测技术在国内外研究相对较少，本节分析了国内外锥桶检测算法的优劣性，并分析了深度学习算法在云边端架构中的应用。

1.3 研究内容与章节安排

交通锥桶作为道路养护作业中的重要警示装置，将成为视觉导航技术中的关键识别目标。本文在分析了国内外高速公路视觉导航、锥桶检测、深度学习与云边端架构相融合的研究成果的基础上，以高速公路预警跟随车系统作为终端，着重对以下几个方面进行研究：（1）针对云计算强运算、边缘计算低延迟的特点，搭建了云边端架构，并以深度学习算法为例，将算法合理分配到云边端结构体系中。（2）根据交通锥桶的纹理特征，对传统锥桶检测算法流程进行研究，并研究了夜晚环境下检测率低的解决方案。（3）分析了基于深度学习目标检测的交通锥桶检测方法，建立了复杂环境下的交通锥桶数据集，并通过深度学习目标检测模型测试了数据集的有效性。（4）针对算法对锥桶小目标检测精度低的问题，研究了 MobileNetV3_YoloV4 模型的改进方法。

本文章节安排如下：

（1）第一章为绪论。说明了本课题的研究背景及意义，介绍了当前国内外对高速公路视觉导航技术、交通锥桶目标检测技术以及深度学习与云边端架构融合技术的研究现状，并阐述了本文的主要研究内容。

（2）第二章为基于云边端架构的高速公路预警跟随车系统方案设计。介绍了高速公路预警跟随车系统和云边端架构的需求。搭建了高速公路云边端架构和预警跟随车系统，解决了多种系统之间的环境异构问题，阐明了深度学习模型在边端架构中的数据分配体系。

（3）第三章为基于纹理特征的交通锥桶检测算法研究。首先，对交通锥桶进行特征分析；其次，根据锥桶特征进行图像处理，包括滤波去噪、基于直方图均衡化的图像增强、基于 HSV 颜色空间的图像分割和图像形态学处理；紧接着，描述了基于连通域形状特征的条件函数，确定了基于纹理特征的交通锥桶检测方法

和步骤。再次，针对夜晚等低照度环境下的图片，分析了阈值分割效果不明显的原因，提出一种基于 Retinex 算法的图像增强方法；最后，将直方图均衡化和 Retinex 两种图像增强算法相结合，提出一种基于亮度的阈值分类选取算法，并进行实验数据分析，证明了基于亮度的阈值分类选取算法检测锥桶的性能更高。

（4）第四章为基于深度学习的复杂环境下交通锥桶检测算法研究。考虑到晴天、阴天、雨天、夜晚等不同环境给图像采集带来的影响，自建了复杂环境下的交通锥桶数据集。介绍了轻量化网络 MobileNetV3 与 YoloV4 模型融合后的 MobileNetV3_YoloV4，并在自建数据集上测试了 YoloV4 与 MobileNetV3_YoloV4 的检测性能，验证了自建数据集的有效性。

（5）第五章为基于 MobileNetV3_YoloV4 的锥桶检测算法改进。首先，针对 MobileNetV3_YoloV4 对锥桶小目标检测精度低的问题，从网络浅层特征、先验框和注意力机制三个角度提出了改进方法；其次，将改进方法有效融合；最后，在自建数据集上测试算法性能，实验证明了改进后的算法在小目标以及整体性能上都有较大提升。

（6）第六章为总结与展望。对全文研究内容总结概括，指出了本文的创新点，并对本文后续研究工作进行展望。

2 基于云边端架构的高速公路预警跟随车系统设计

本章从高速公路预警跟随车的应用环境和系统功能考虑，基于实验室现有环境，搭建了云边端架构系统，提出了多系统之间环境异构问题的解决方案，介绍了预警跟随车系统的硬件平台，并将深度学习算法合理分配到云边端架构中，有利于智慧高速公路养护背景下，预警跟随车视觉导航关键技术的研究。

2.1 系统需求分析

2.1.1 高速公路预警跟随车系统需求分析

根据《道路施工安全标志的设置规范》，“安全标志应设置在与安全有关的明显地方，并保证人们有足够的时间注意其所表示的内容”。在道路养护作业中，应在施工队伍后方设立安全警示标志，以达到提醒后方车辆驾驶人员注意路况的目的^[46]。

如图 2.1 所示，目前施工现场设立警示标志的方式有摆放警示锥桶、施工人员挥舞警示旗帜和摇臂机器人三种方式：

（1）在施工队后方摆放警示锥桶是最原始的方式，此方式存在较高的危险性，如有意外发生，既不能阻止车辆闯入，也不能及时给施工人员发出避险警报；

（2）施工人员挥舞警示旗帜的方式，一般需要一名到几名施工人员在施工队后方不停的挥舞警示旗帜，这种方式不仅要消耗数名劳动力，而且使施工人员处于十分危险的场景中；

（3）摇臂机器人是近几年刚出现的一种方式，通过一台电机带动仿人机器人的手臂挥舞警示旗，从而达到了代替施工人员挥舞警示旗帜。但是这种方式的弊端在于在施工队前进时，需要专门的机械去搬运机器人，不适用于高速公路移动养护作业，且在后方出现危险时，无法及时给前方施工人员发出避险警报。



图 2.1 传统警示装备



图 2.2 国内已研发的预警设备

如图 2.2 所示，由江苏博崴特电子科技有限公司生产的道路交通安全智能预警装置，开创了国内外道路养护作业、事故处置、变被动防护为主动预警的新时代。当有危险车辆进入时，系统发出增强定向声波预警，实时向作业人员发出报警，以提醒作业人员提前避让，当危险解除时系统自动关闭，有效的减小了交通事故发生率。但此设备只能人工摆放和回收，若针对高速公路上养护作业区改变或移动的情况，预警设备无法自主移动，需要人工搬运，此时一旦车辆进入，会对施工人员产生重大安全威胁。

针对此安全问题，需要设计一款高速公路预警跟随车，可以在危险车辆靠近时发出报警，还可以自动跟随前方施工车辆移动，不再需要人为的搬运，实现自动化与智能化，提高工作效率，减小交通安全隐患，为道路养护施工人员和驾驶人员提供安全保障。

为了使预警跟随车在安全区域内行进，实现自主移动跟随功能，视觉导航技术是关键性问题，尤其是针对高速公路中的目标识别技术，一般需要准确的识别出道路上的车道线和施工摆放的交通锥桶，以便路径的规划与导航。目前，车道线检测与路径规划技术发展相对完善，而对于高速公路上临时摆放的交通锥桶检测技术研究较少，若不能及时有效的对其判别与定位，很可能造成严重的交通事故。在高速公路环境下，需要对道路养护作业中的锥桶检测具备高准确率、低延迟的要求，本文以高速公路预警跟随车系统为载体，主要研究了高速公路道路养护中的交通锥桶检测算法。

2.1.2 智慧高速公路云边端架构需求分析

目前，我国高速公路网已经基本构建完成，随着高速公路云边端架的不断完善和人民生活质量的提高，人们交通出行时对道路的要求越来越高，在安全、稳

定的前提下，不断向着便捷、智能化发展。智慧高速公路中的车辆提前预警、车流量统计、自动驾驶、车辆跟踪、数据实时采集等功能都需要在云边端架构中实现，云边端架构推动着我国智慧高速公路的建设，是未来高速公路重要发展方向之一。

高速公路预警跟随车能在安全区域内行驶，离不开延迟低、准确率高的视觉导航技术。目前，深度学习模型在视觉处理方面应用越来越广泛，尤其是目标检测技术，已经具备较高的识别精度。但深度学习模型的网络训练和推理过程往往需要耗费较大的算力，以及价格昂贵的高性能 GPU 和处理器硬件支持。若每个预警跟随车都配备高性能 GPU 和处理器，随着预警跟随车数量的增加，成本也会大大增加。故本文将深度学习模型融入到云边端架构，合理利用高速公路搭建的云边端架构资源，利用云边端协同控制的方式，合理分配计算资源，提高终端在视觉处理方面的实时性，降低单个预警跟随车的成本，这对构建智慧交通、保证人民群众安全出行具有重要意义。

2.2 高速公路云边端架构设计

2.2.1 硬件平台搭建

高速公路的云边端架构系统一般是由云服务器、边缘控制器和终端组成，它们之间可以进行数据交互、指令传输等功能。云服务器是指性能强大、稳定性高的云虚拟机，用户可以通过网络连接的方式与云服务器进行数据交互，具有超强的运算能力。边缘控制器是指靠近数据源头的一侧安装具有一定计算能力的计算机系统，具有较高的响应速度。终端是指高速公路上具备网络连接能力，且能与云服务器、边缘控制器进行数据交互的智能设备，主要包括车道两侧的摄像头、智能测速仪等。本章基于实验室现有的环境，搭建了一套云边端架构系统，并应用在高速公路预警跟随车系统中。

(1) 硬件组成

本文搭建的云边端架构由云服务器、边缘控制器和终端三部分组成。硬件上，戴尔机架式服务器 R740 作为云服务器，MIPS 系统、ARM 系统、X86 系统作为边缘控制器，高速公路预警跟随车作为终端，终端的主控单元选用 STM32 单片机。云服务器和边缘控制器的 CPU 型号、内存大小、CPU 主频和 GPU 型号如表 2.1 所示：

表 2.1 实验平台硬件组成信息

分类	CPU 型号	CPU 主频 (GHz)	内存大小 (GB)	GPU 型号
云服务器	Intel(R) Xeon(R) Gold 5218R	2.1	96	GeForce RTX 2080 SUPER
边缘控制器 (X86)	Intel(R) Core(TM) i5-4590	3.3	8	GeForce GTX 1050

云服务器如图 2.3(a)所示, 具有较高的硬件环境配置, 存储和计算能力较强, 能够充分发挥算法的性能。在高速公路视觉导航的关键技术中, 图像处理技术尤为重要, 云服务器具备高配置的显卡, 能大幅提高图像处理能力。

边缘控制器由三台系统分别为 MIPS、ARM、X86 的主机构成, 边缘控制器之间通过交换机相连, 高速公路上的边缘控制器分布在道路一侧, 当预警跟随车出现在两台边缘控制器中间位置时, 会启动云服务器来判断两台边缘控制器的当前负荷, 优先选择当前负荷量小的边缘控制器与预警跟随车进行数据交互。由于边缘控制器的数量多、种类不一, 存在环境异构问题, 本文使用 docker 镜像的方法, 仅需在一台边缘控制器上配置基本环境, 并打包成 docker 镜像, 其他的边缘控制器直接载入打包好的 docker 镜像即可, 解决了环境异构问题。由于图像处理需要使用到 GPU 资源, 故边缘控制器载入 docker 镜像后需要根据不同硬件资源调整相应的 GPU 环境。虽然边缘控制器没有云服务器一样强大的计算能力, 但却有着很高的响应速度, 能够将道路上的信息及时反馈给云服务器或终端, 以便及时做出决策或动作, 满足高速公路中对实时性要求较高的任务。边缘控制器如图 2.3(b)所示。

终端可以是各类传感器设备, 比如日常用的手机、智能家居、摄像头等, 本文将带有摄像头的高速公路预警跟随车系统作为终端, 主控系统通过摄像头将采集的画面上传至云服务器或边缘控制器, 以便于对视觉导航关键技术的研究。终端的主控系统为 STM32 单片机, 采集图像装置为摄像头, 如图 2.3(c)、(d)所示。



图 2.3 云边端架构实物图

(2) 云边端架构通信设计

在实际的通信测试过程中，网络的信号的质量和强度尤为重要，对数据的传输速度起到关键性的作用。由于 5G 网络的抗干扰能力好，传输速度快，本实验选用华为 5G 路由器来负责组网工作。针对 5G 频段的信号覆盖范围较弱的问题，采用 LAFALINK LF-OAP50 大功率无线基站，无线网可实现 450 米远距离覆盖，最高传输速率可达 300Mbps，实现高速上网，具有较高的抗干扰能力，有利于提高云边端架构之间数据传输的快速性和稳定性。大功率无线基站如图 2.4 所示。



图 2.4 大功率无线基站

云服务器、边缘控制器和终端的网络通信关系为：首先，将 5G 路由器与交换机用网线连接，再将云服务器与三个边缘控制器用网线直连方式接入同一交换机，使它们在同一局域网下。大功率无线基站改用网关模式，将其 WAN 口与交换机的 LAN 口用网线直连，并且在交换机中设置静态路由表，实现大功率无线基站与交换机之间的相互访问。高速公路预警跟随车通过无线网络连接到大功率无线基站上，通过访问对应的 IP 地址，来实现对云服务器和边缘控制器的访问和数据交互。云边端架构如图 2.5 所示。




图 2.5 云边端架构

2.2.2 云边端架构数据分配体系

云、边、端设备都有各自的优缺点，云边端架构融合各自的特点，充分提升设备的性能。因此，如何构建云边端架构下合理的数据分配体系是至关重要的。

在传统的物联网计算模型中，由于的硬件资源限制，终端设备不具备较强的计算和存储能力，因此将计算任务放在云服务器是一种高效的数据处理手段^[47]。对计算和存储资源要求较高的任务，例如深度学习目标检测的训练过程，仍需要云服务器来完成。

随着物联网技术的发展，网络互联式传感器数量与日俱增，云服务器需要处理的数据海量增加，对网络的数据传输造成了很大的压力^[48]；云服务器较高的网络延迟不能满足对实时性要求较高的设备。相比于云服务器，边缘控制器可以大幅度提升网络的响应速度、减轻云服务器的压力、提高系统的稳定性。

本文在对视觉导航关键技术的研究中，主要研究了高速公路预警跟随车系统的目标检测部分。针对深度学习目标检测模型的训练过程需要消耗大量计算资源的问题，如何有效的将深度学习模型分配到云边端架构是至关重要的。深度学习模型在云边端架构中的数据处理分布如下：

（1）云服务器用做深度学习中的模型训练和数据存储。模型的训练过程需要耗费大量的时间和计算资源，而云服务器本身具有丰富的计算存储资源，因此，可以将模型的训练和数据存储过程放至云服务器。将数据集等大型文件上传至云服务器，把深度学习模型的训练任务卸载到云端，将训练好权值文件直接分发至边缘控制器即可。有效利用云服务器强大的计算资源，节省训练的时间。

（2）模型的推理过程不需要庞大的计算资源，因此，可以将模型推理过程放在边缘控制器进行。将终端采集的实时画面上传至边缘控制器，在边缘控制器中

进行深度学习网络的推理过程，将得到的交通锥桶位置信息下传至终端，在终端进行运动控制。有效利用边缘控制器的高实时性，进一步提高锥桶检测速度。

(3) 终端（高速公路预警跟随车系统）主要负责数据的采集、上传、请求访问等信息交互功能；同时，对实时性要求较高的运动控制系统也部署在终端，可以立即响应动作，提高系统的安全性和稳定性。

2.3 基于高速公路预警跟随车系统的终端实现

终端系统采用高速公路预警跟随车系统，该系统是针对公路养护作业时人员、设备及过往车辆的安全问题而研发的，综合利用视觉感知技术、激光雷达技术、卫星和惯性导航技术实现跟随车主体在安全区域自主运动与预警。该系统集定位跟随、车道保持、自动避障、主动预警、人机交互功能于一体。本文主要研究了该系统的视觉导航关键技术，根据目标识别技术，成功定位待检测物体。

(1) 终端系统硬件组成

预警跟随车的主控系统选用 STM32 单片机。结构上由摄像头、激光雷达、超声波模块、433M 无线模块、GPS 模块、警示灯、LED 显示屏、摇杆机构、太阳能电池板、把手、两个驱动轮、一个万向轮组成。摄像头采集周围环境，用来检测车道线与锥桶，超声波用来检测前方障碍物，激光雷达用来检测后方来车，警示灯和 LED 显示屏用来警示后方来车，摇杆机构可以安放警示红旗，两个驱动轮完成预警跟随车的前进与后退功能，万向轮辅助预警跟随车方向的改变，太阳能电池板给蓄电池供电。预警跟随车结构示意图如图 2.6 所示。




图 2.6 预警跟随车结构示意图

(2) 终端系统通信方式

在预警跟随车系统中,通过 433M 无线通信模块将摄像头采集到的图像上传至云边端架构,按照数据分配体系合理分配资源。主控系统 STM32 单片机通过串口转 USB 的通信方式获取摄像头和激光雷达的数据,通过串口通信方式与 GPS 模块、超声波模块、LED 显示屏和 433M 无线通信模块通讯,通过单片机的 I/O 控制警示灯、摇杆机构和驱动轮。预警跟随车系统通信方式如图 2.7 所示。




图 2.7 预警跟随车系统通信方式

2.4 本章小结

本章首先介绍了高速公路预警跟随车系统和云边端架构的背景需求和研发意义,并根据实验室现有的环境,搭建了一套云边端架构系统,介绍了云边端结构的结构组成和数据分配体系,通过 docker 镜像解决了环境异构问题,并将预警跟随车系统融入到云边端架构中;又单独介绍了预警跟随车系统的硬件组成和通信方案设计;本章最后,提出了本文研究的关键技术,即在高速公路预警跟随车系统环境下,研究基于云边端架构的交通锥桶检测算法。

3 基于纹理特征的交通锥桶检测算法研究

在高速公路预警跟随车系统中，视觉感知技术是尤为重要的，尤其是对道路养护作业途中的交通锥桶检测。本章根据高速公路上锥桶的颜色和形状特征，设计了基于纹理特征的锥桶检测算法，在此基础上针对低照度环境下识别效果低的问题进行了改进，提高了在夜晚环境下的锥桶检测率。

3.1 基于纹理特征的锥桶检测算法

纹理特征是一种反映图像中同质现象的视觉特征，它体现了物体表面的具有缓慢变化或者周期性变化的表面结构组织排列属性。由于锥桶颜色和形状特征明显，故本章选用颜色和形状信息作为锥桶的纹理特征。

锥桶检测算法流程分为两大部分，第一部分是图像预处理，包括对感兴趣区域提取、图像滤波，并利用 HSV 颜色空间下直方图均衡化算法进行图像增强，根据锥桶颜色选取阈值，进行图像分割，再通过图像形态学处理进一步减少噪点等无关信息的干扰；第二部分是基于纹理的锥桶检测，根据锥桶的形状和位置约束关系，筛选出符合条件的目标作为最终识别结果。基于纹理特征的交通锥桶检测算法流程如图 3.1 所示。




图 3.1 基于纹理特征的交通识别算法流程图

3.1.1 锥桶特征分析

高速公路道路养护作业中的锥桶大都由底座和锥体两部分构成，底座颜色与锥桶颜色相同，锥体呈圆锥形，锥体中间存在白色反光条。可将锥桶上下分为三个区域，设顶部红色区域为 A，底部色区域为 C，中间白色反光条区域为 B，可以通过 A、B、C 三者的位置关系来识别锥桶。由于白色反光条与高速公路的车道

线、路面标志颜色接近，很容易造成干扰，白色区域 B 不利于锥桶的检测，故本章只分析了锥桶的 A、C 两部分，最终依据锥桶红色区域的特点和位置关系来识别锥桶。实物图与形状位置关系图如图 3.2 所示。




图 3.2 交通锥桶实物图与位置关系图

3.1.2 图像预处理

(1) 感兴趣区域提取

《公路工程技术标准》规定：时速为 120km/h 的高速公路车道宽度应为 3.75m。为了获取高速公路较宽范围的视角信息，本文选用视场角为 150° 的 CMOS 无畸变摄像头，分辨率选用 640×480 。由于光照对相机采集图像的质量影响较大，且获取的图像中包含天空、建筑物、交通路标等大量无用信息，加大了图像处理的难度。因此，在相机安装高度为 1.2m 的前提下，将相机安装的俯仰角调整为 62° ，避免了阳光的直射，同时减少了图像中的无用信息。调整俯仰角后，锥桶主要出现在相机视野的上半部分，而底部的四分之一区域基本采集不到有用信息。去除底部四分之一的平面信息后，降低了图像处理的复杂度，提升了算法检测速度。

相机采集的原图像与感兴趣区域图像如图 3.3 所示。



图 3.3 原图像与感兴趣区域图像

(2) 图像滤波算法

为了防止噪声的干扰，需要对图像进行滤波操作。在高速公路上，环境复杂

多样，采集的图像中可能会受到车辆阴影、路面反光、遮挡等环境因素的影响，影响后续目标的检测。图像滤波可以过滤干扰信息，保留识别目标物的有用信息^[49]。

均值滤波的基本思想是将目标像素及周围像素取平均值后再替代目标像素。但均值滤波图像去噪时很容易破坏图像细节，使图像模糊^[50]。

中值滤波器的基本原理是选择待处理像素邻域中每个像素值的中值来替换待处理像素，有效消除孤立点^[51]。但中值滤波的效果与滤波窗口大小有关，随着滤波效果的提升，图像会变得愈加模糊。

双边滤波是一种非线性高斯滤波^[52]，是结合图像的空间邻近度和像素值相似度的一种折中处理方法，结合图像的空间域信息和灰度相似性，很好的去除图像噪点，有效保留了像素的边缘信息，但处理速度较慢。

高斯滤波是一种线性滤波^[53]，基本思想是对图像的像素值进行加权，每个像素点的值等于本身及其邻域内像素点的加权值，用于去除图像中的细节和噪声，有效保留了图像的特征点和边缘的特性。

综上所述，双边滤波和高斯滤波的效果更适合高速公路图像处理，能有效的保留特征点和边缘信息。但考虑到高速公路处理数据对实时性的要求较高，故本文采用效率更高的高斯滤波作为图像预处理过程中的图像滤波算法，各种滤波算法的滤波效果如图 3.4 所示。




图 3.4 各种滤波算法效果图

(3) 基于直方图均衡化的 HSV 颜色空间图像增强

RGB 颜色空间是通过叠加红、绿、蓝三原色之间的权重关系来描述颜色信息的颜色空间^[54]，具有显示直观、处理简单等优点。一幅图像的色调、亮度和饱和度可由 RGB 三通道叠加计算得到，亮度发生改变时，RGB 三通道的值都会发生改变，故 RGB 颜色空间在图像处理中不够稳定，不能通过阈值选取的方法提取出图像中的目标。

HSV 颜色模型是一种更加直观的颜色模型，可以分开描述图像中的颜色信息和亮度信息。HSV 颜色模型将图像分为三个通道：H（色调）、S（饱和度）和 V（亮度）。H 通道由颜色的光谱波长决定，不同的波长有着不同的色调。S 通道是对饱和度的描述，是指颜色的纯度，它受光线中混入多少白光的影响。V 通道代表颜色的亮度，它只与光线的能量大小有关，与色度无关。其中，H 与 S 一般不受光照的影响，适合图像阈值分割^[55]。

直方图均衡化是一种增强图像对比度的方法^[56]。一幅图像的某个阈值内，像素的分布可能非常密集或稀疏，直方图均衡化可以使像素分布更加均匀，平均分布同一阈值间隔内的像素数。

由于 HSV 颜色空间可以更直观地表达颜色的色调、饱和度和亮度，有利于颜色的对比，故本文选用 HSV 颜色空间对图像进行处理，并对对 V（亮度）通道进行直方图均衡化处理，使得 V 通道的值分布更加均匀，减小光照给图片带来的影响，同时不会影响 H 和 S 的值。原图与 HSV 直方图均衡化后的效果如图 3.5 所示。



图 3.5 原图与 HSV 直方图均衡化后的图像效果图

(4) 基于 HSV 颜色空间的图像分割

图像分割可以将目标物体从图像中分离出来，实现最终的位置定位功能。由于锥桶的颜色特征明显，可以通过提取锥桶中上下两部分的红色区域来实现图像分割。在 HSV 颜色空间，图像的色调不受亮度的影响，可以有效减小光照对颜色的影响，故采用 HSV 颜色空间提取锥桶的红色区域，最终实现图像分割的目的。

为了确定 HSV 三通道的阈值大小，本文采集了 20 张在反光、阴影、夜晚环境下的锥桶图片，并截取图中锥桶的红色区域，用来计算 H、S、V 的大小。图 3.6 为截取红色区域的锥桶图片。



图 3.6 截取红色区域的锥桶图片

分别求出图 3.6 中每张图片 H、S、V 三个通道的期望值，并作为单张图片的最终阈值，20 张锥桶图片的 HSV 三通道阈值变化如图 3.7 所示。由图 3.7 可知，光照的变化使 V 通道浮动较大，尤其是在夜晚环境下的图片（图片序号为 4 号和 18 号），无法较好的反映整体的阈值范围。阈值范围的筛选过程十分重要，若选择的浮动范围太大，图像会产生更多的噪点，出现误检测的现象，若选择的浮动范围太小，则会出现漏检的现象。




图 3.7 HSV 三通道的阈值变化




图 3.8 直方图均衡化后的 HSV 三通道的阈值变化

经过 HSV 直方图均衡化后的 HSV 三通道阈值变化如图 3.8 所示。V 通道的值分布均匀, 浮动范围变小。最终确定了锥桶的红色区域的 H 通道取值范围为 $[0, 42]$, S 通道取值范围为 $[53, 170]$, V 通道的取值范围为 $[125, 255]$ 。

直方图均衡化后的图像与经 HSV 图像阈值分割后的图像如图 3.9 所示。采用直方图均衡化的方法在白天环境下的图像分割效果较好。但在夜晚路灯下, 由于锥桶表面光照不均匀, 有阴影遮挡的部分没有识别出来, 图像分割效果并不理想, 很可能会影响后续的锥桶检测。




图 3.9 直方图均衡化后的图像与经 HSV 图像阈值分割后的图像效果图

(5) 图像形态学处理

首先，对图像进行二值化，方便图像的处理。图像二值化可以将图像中的像素划分为 0 或 255 两种状态，分别代表黑色和白色^[57]。二值化首先需要确定分割阈值，然后依次读取图像每个像素的灰度值，并将其与阈值进行比较；将大于或等于阈值的像素替换为 255，小于阈值的像素替换为 0，这样便得到了一幅黑白图像。目前，二值化可分为全局阈值法和局部阈值法。全局阈值法在目标与背景灰度差异明显时效果更好，计算速度更快；局部阈值法将图像分为多个区域，每个区域分别计算阈值。可用于背景较复杂的环境下，但处理速度较慢。由于高速公路环境下的交通锥桶与沥青路面的灰度差别明显，且对实时性要求较高，故采用全局阈值法计算阈值。对已提取出红色区域图像的 H（色调）通道进行二值化，效果如图 3.10 所示。




图 3.10 图像分割后的图像与二值化后图像效果图

其次，对二值化后的图像进行闭运算和开运算，减小噪点等无用信息。闭运算为先膨胀后腐蚀，可以消除二值化图像内部的小黑洞；开运算为先腐蚀后膨胀，作用是将二值化图像中连接在一起的部分离开，去除孤立的点或毛刺。

先后经过闭运算、开运算，图像中的噪点明显减少，黑色小孔洞也被填充，有利于后续的锥桶筛选工作。对二值化后的图像进行闭运算、开运算，效果如图 3.11 所示。




图 3.11 二值化后的图像与闭、开运算后的图像效果图

3.1.3 基于纹理特征的约束条件

(1) 图像连通域选取

一幅图像中的最小单位是像素，图像连通域是指在二值化图像中具有相同像素值且具有邻接关系的像素组成的区域。邻接关系可分为 4 邻接和 8 邻接两种，4 邻接是指该像素的上、下、左、右四个方向有紧邻的像素点，8 邻接是指该像素的上、下、左、右并外加四个对角线位置，共八个方向有紧邻的像素点^[58]。4 邻接和 8 邻接像素位置关系如图 3.12 所示。




图 3.12 4 邻接和 8 邻接像素位置关系

为了更准确筛选出锥桶，本文选用 8 邻接的方法，并将检测出的所有连通域用边界框框出来，图像中所有边界框的像素点面积、角点坐标、质心坐标都可以在寻找连通区域时求出。连通域如图 3.13 所示。




图 3.13 连通域图像

(2) 交通锥桶形状筛选

由于锥桶红色区域的形状是固定的，可以根据标记出的连通域方框的大小和位置关系筛选出符合锥桶形状的目标。

真实锥桶的连通域方框位置关系如图 3.14 所示。假设红色区域 A 的面积为 S_A ，红色区域 C 的面积为 S_C ， W_A 、 W_C 分别代表区域 A 和区域 C 的宽度， H_A 、 H_C 分别代表区域 A 和区域 C 的高度， $C_A(X_A, Y_A)$ 代表区域 A 的质心点像素坐标， $C_C(X_C, Y_C)$ 代表区域 C 的质心点像素坐标， Y_{LA} 、 Y_{LC} 分别代表区域 A 的左下角纵坐标和区域 C 的右上角纵坐标。




图 3.14 真实锥桶的连通域方框位置关系

首先，利用连通域求出的面积和宽高进行条件筛选，去除异常的连通域。在本实验环境下，采集的图像像素大小为 640×480 ，锥桶的宽高至少大于等于 5 个像素点，面积应大于等于 25 个像素点，小于等于 6000 个像素点，且连通域的高度是宽度的 0.5~3 倍，否则视为异常点，并将不符合条件的剔除。筛选条件可由公式

3.1 表示。

$$\begin{cases} W_A \geq 5, H_A \geq 5, W_C \geq 5, H_C \geq 5 \\ 25 \leq S_A \leq 6000, 25 \leq S_C \leq 6000 \\ 0.5 \leq H_A / W_A \leq 3, 0.5 \leq H_C / W_C \leq 3 \end{cases} \quad (3.1)$$

其次，按照从左至右，自上而下的顺序扫描每一个经过首次筛选后的连通域，每两个相邻的两个连通域作比较。锥桶红色区域形状应满足以下条件：区域 A 在在区域 C 的上方；C 区域面积是 A 区域面积的 1.5~4.5 倍；A、C 区域的质心点左右偏差小于等于 25 个像素点，上下偏差大于等于 10 个像素点且小于等于 150 个像素点；A、C 两个矩形框之间的间隔可由 $Y_{LC} - Y_{LA}$ 来表示，间隔应大于等于 2 个像素点，小于等于 50 个像素点。将符合以上条件的筛选出来，筛选条件可由公式 3.2 表示。

$$\begin{cases} 1.5 \leq S_C / S_A \leq 4.5 \\ 0 \leq |X_A - X_C| \leq 25 \\ 10 \leq (Y_C - Y_A) \leq 150 \\ 2 \leq (Y_{LC} - Y_{LA}) \leq 50 \end{cases} \quad (3.2)$$

最后，将经过条件筛选后的结果用矩形框框出，并将 A、C 上下两部分合在一起显示，显示的结果即为交通锥桶所在的位置信息。筛选后的锥桶图像如图 3.15 所示。




图 3.15 筛选后的锥桶图像

3.2 基于 Retinex 的图像增强算法

图像处理采集的过程中，光照不均匀、光线强弱变换会严重影响图像处理的效果。上一小节中，直方图均衡化的图像增强方法在光照较暗、光照不均的环境下并不适用，在有夜晚路灯的环境下，阴影遮挡部分的红色区域并没有被检测到，严重影响了锥桶的识别效果。而 Retinex 算法^[59]可以有效减小光照不均、阴影遮挡

对图像识别的影响。

Retinex 算法的基本思想是：物体的颜色取决于物体对光的反射能力，而不是光照，物体的颜色是恒定的。眼睛观测到的图像 S 可以分解为反射图像 R 和入射图像 L 。反射图像 R 具有恒常性，Retinex 算法通过 S 估算出 L 值，最终求出 R 值。图像分解关系可以用公式 3.3 表示。

$$S = R \times L \quad (3.3)$$

但 Retinex 算法也存在一定的缺陷，在强光和阴影的过渡区容易出现光晕现象，导致红色阈值出现偏差，容易出现噪点。Ahn 等人结合传统的 Retinex 算法，提出了全局自适应和局部自适应两种图像增强方法，在全局自适应方法中，能有效处理低照度的图片，有利于解决夜晚光照不足以及路灯下出现的阴影遮挡问题，本文简称此算法为 ALTM_Retinex 算法^[60]。

ALTM_Retinex 算法的计算公式如式 3.4 所示。其中 $L_g(x, y)$ 代表 ALTM_Retinex 算法全局自适应输出结果， $L_w(x, y)$ 代表输入图像的亮度值，可由彩色图像的 RGB 三个通道计算得到， $L_{w\max}$ 代表图像中亮度的最大值， $\bar{L}_w$ 代表图像亮度取对数后的平均值， N 为图像中像素的总个数， δ 为极小的数值，为了避免图中出现黑色像素点时 $\log$ 计算出错^[60]。

$$\begin{cases} L_g(x, y) = \frac{\log(L_w(x, y) / \bar{L}_w + 1)}{\log(L_{w\max} / \bar{L}_w + 1)} \\ L_w(x, y) = 0.229 \times R + 0.587 \times G + 0.114 \times B \\ \bar{L}_w = \exp\left(\frac{1}{N} \sum_{x, y} \log(\delta + L_w(x, y))\right) \end{cases} \quad (3.4)$$

计算得到的 $L_g(x, y)$ 与图像亮度 $L_w(x, y)$ 相除得到一个增益系数 $gain$ ，将增益系数 $gain$ 扩展到彩色图像 RGB 的每个通道上，使得图像的亮度有整体的提升，尤其是对低照度的图像，提升效果更明显。计算过程可由公式 3.5 表示。

$$\begin{cases} gain = L_g(x, y) / L_w(x, y) \\ result = (gain \times R, gain \times G, gain \times B) \end{cases} \quad (3.5)$$

对图片的 RGB 三通道进行 ALTM_Retinex 算法图像增强，图 3.16 为原图与使用 ALTM_Retinex 算法后的效果图。



图 3.16 原图与使用 ALTM_Retinex 算法后的效果图

经过 ALTM_Retinex 算法后图像的 HSV 三通道阈值变化如图 3.17 所示。




图 3.17 经过 ALTM_Retinex 算法后的 HSV 三通道阈值变化




图 3.18 对比原始图像 V 通道与经过 ALTM_Retinex 算法后的 V 通道阈值变化

对比了原始图像的 V 通道和经过 ALTM_Retinex 算法后的 V 通道阈值变化，如图 3.18 所示，由图可知，图像经过 ALTM_Retinex 算法后的 V 通道阈值比原始图像的 V 通道阈值有了整体提高，尤其对夜晚环境下的图片（对应图片序号 4 号和 18 号），V 通道阈值有了显著的提升。

经过 ALTM_Retinex 算法后，重新选择了分割锥桶的阈值，根据图 3.18，确定了锥桶的红色区域的 H 通道取值范围为 $[0,40]$ ，S 通道取值范围为 $[47,167]$ ，V 通道的取值范围为 $[78,255]$ 。

基于 Retinex 算法的交通锥桶检测算法流程图如图 3.19 所示。将滤波后的图像使用 ALTM_Retinex 低照度图像增强算法，代替了之前的 V 通道直方图均衡化图像增强算法，其它步骤保持不变。




图 3.19 基于 Retinex 算法的交通识别算法流程图

3.3 基于亮度的阈值分类选取算法

白天、夜晚环境下的锥桶图像经过 V 通道直方图均衡化后的图像阈值分割效果与经过 ALTM_Retinex 算法后的图像阈值分割效果如图 3.20 所示。




图 3.20 经过两种图像增强算法后的图像阈值分割效果对比

由图 3.20 可知，V 通道直方图均衡化后的图像在白天环境下的图像分割效果更好，而经过 ALTM_Retinex 算法后的图像对针对低照度、有阴影遮挡的图像提升效果显著，能够检测出更多的有效区域，有利于锥桶检测算法性能的提升。

故本文提出了基于亮度的阈值分类选取算法，结合 HSV 颜色空间的 V 通道直方图均衡化和 ALTM_Retinex 两种图像增强算法，根据图像亮度值选取合适的颜色阈值。在白天等亮度较大的环境下，采用 V 通道直方图均衡化的方法进行图像增强，在夜晚等低照度的环境下，采用 ALTM_Retinex 算法进行图像增强。

本文通过判断图片在 HSV 颜色空间下 V 通道的期望值大小来区分白天还是夜晚，用 V_{mean} 在表示。算法中亮度的临界值设置为 128，若 V_{mean} 大于 128，则判定该图片属于白天，采用 V 通道直方图均衡化的方法，H 通道取值范围为[0,42]，S 通道取值范围为[53,170]，V 通道的取值范围为[125, 255]。若 V_{mean} 小于等于 128，则判定该图片属于夜晚，采用 ALTM_Retinex 图像增强的方法，H 通道取值范围为[0,40]，S 通道取值范围为[47,167]，V 通道的取值范围为[78,182]。此方法有效解决了光照不均、低照度给目标检测带来的影响。基于亮度的阈值分类选取算法流程图如图 3.21 所示。




图 3.21 基于亮度的阈值分类选取算法流程图

如图 3.21 所示，经过图像滤波后，首先将 RGB 图像转到 HSV 颜色空间，再通过计算图片 V 通道的期望值 V_{mean} 大小来决定走哪一条支路，两种算法对应两种不同的 HSV 阈值。其它流程步骤保持一致。

3.4 实验验证

3.4.1 实验平台环境

为了验证本章所研究交通锥桶检测方法，本文基于预警跟随车系统，用选用的 CMOS 相机采集了 220 张分辨率为 640*480 的带有交通锥桶的图片，共包含 548 个锥桶。其中，白天环境下的图片有 125 张，共包含 248 个锥桶，夜晚环境的图片有 95 张，共包含 300 个锥桶。在锥桶检测算法中，分别添加 V 通道直方图均衡化算法、ALTM_Retinex 算法和基于亮度的阈值分类选取算法，并对三种算法进行测试，测试平台选用自己搭建的边缘控制器（X86 系统）。

3.4.2 实验结果分析

（1）阈值分割后的效果图可以直观的展示检测效果的好坏。首先，针对白天和夜晚的环境下采集的锥桶图片，经过 V 通道直方图均衡化算法后再进行图像阈值分割，来检测算法的效果。

在白天环境下，V 通道直方图均衡化算法较完整的检测到了锥桶的有用信息，有利于后期锥桶的筛选。效果如图 3.22 所示。




图 3.22 白天环境下经过 V 通道直方图均衡化算法后的图像阈值分割效果图

在夜晚环境下，V 通道直方图均衡化算法对锥桶的阈值分割效果明显下降，效果如图 3.23 所示，其中，(b)图几乎没有分割出锥桶的颜色，而(d)图检测到了大量的噪点，不利于后期锥桶的筛选。




图 3.23 夜晚环境下经过 V 通道直方图均衡化算法后的图像阈值分割效果图

测试了 V 通道直方图均衡化算法在白天和夜晚环境下检测锥桶的准确率，如表 3.1 所示。在白天环境下，锥桶检测的准确率可达到 83.20%，而在夜晚的环境下，锥桶检测的准确率仅有 54.67%。

表 3.1 V 通道直方图均衡化算法在白天和夜晚环境下的锥桶检测结果

环境	训练集（张）
白天	83.20%
夜晚	54.67%

（2）其次，针对白天和夜晚的环境下采集的锥桶图片，经过 ALTM_Retinex 算法后对图像进行阈值分割，来检测该算法对锥桶检测的效果。

在白天环境下，经过 ALTM_Retinex 算法后阈值分割的效果如图 3.24 所示，其中，(b)、(d)两图丢失了大量的锥桶红色信息，阈值分割效果不理想，不利于后期锥桶的筛选。





图 3.24 白天环境下经过 ALTM_Retinex 算法后的图像阈值分割效果图

在夜晚环境下，经过 ALTM_Retinex 算法后阈值分割的效果如图 3.25 所示，较完整的分割出了锥桶的红色区域，且仅有少量的噪点，有利于后期锥桶的筛选。






图 3.25 夜晚环境下经过 ALTM_Retinex 算法后的图像阈值分割效果图

测试了 ALTM_Retinex 算法在白天和夜晚环境下检测锥桶的准确率，如表 3.2 所示。在白天环境下，锥桶检测的准确率仅有 60.80%，而在夜晚的环境下，锥桶检测的准确率可以达到 80.00%。

表 3.2 ALTM_Retinex 算法在白天和夜晚环境下的锥桶检测结果

环境	准确率
白天	60.80%
夜晚	80.00%

(3) 最后，将两种算法相融合，用基于亮度的阈值分类选取算法，对包含白天和夜晚两种环境下的全部 548 个锥桶进行测试，并与单独的 V 通道直方图均衡化算法和 ALTM_Retinex 算法做对比。对比结果如表 3.3 所示。由表 3.3 可知，基于亮度的阈值分类选取算法的准确率相比加入 V 通道直方图均衡化和加入 ALTM_Retinex 算法分别提高了 18.98%和 4.93%。

表 3.3 交通锥桶检测结果对比

环境	直方图均衡化	ALTM_Retinex 算法	基于亮度的阈值分类选取算法
白天+夜晚	66.42%	80.47%	85.40%

在边缘控制器端，测试了三种算法对锥桶图像的处理速度，一帧图片的检测时间为 20ms，即检测帧率为 50FPS，满足高速公路下目标检测的实时性要求。

测试了基于亮度的阈值分类选取算法在各种环境下的交通锥桶检测效果，效果如图 3.26 所示。



图 3.26 交通锥桶检测效果

图 3.26 中, (a)、(b)为白天光照均匀环境下的图片, 锥桶的检测效果较好。(c)、(d)、(e)、(f)为夜晚光照不均、低照度环境下的图片, 使用 ALTM_Retinex 算法后, 检测效果明显提升。(g)、(h)分别为白天有树荫等阴影遮挡、雨天环境下的图片, 检测效果较好。在图(i)、(j)中, 均出现了误检测的现象, 两幅图中有大量红色的楼房、墙壁, 对锥桶的检测造成了一定的影响。

此算法本身具有一定的局限性, 只针对于上下是红色、中间是白色的锥形桶, 对其他类型的交通锥桶并不适用, 且基于形状特征的锥桶筛选条件是根据自己搭建的终端测得的, 与相机的焦距、视场角、安装高度、安装角度有关。

3.5 本章小结

本章根据锥桶的颜色和形状的纹理特征, 提出了基于纹理特征的交通锥桶检测方法。首先, 对感兴趣区域提取并进行图像滤波; 其次, 通过 V 通道直方图均衡化的方法增强图像中的有用信息, 并根据颜色信息进行图像分割; 然后, 通过图像形态学处理, 得到一幅信息丰富的二值化图像; 最后, 通过二值化连通域的方式找到所有连通区域的大小和位置信息, 并根据锥桶固有的形状和位置信息进行筛选, 得到最终的检测结果。

针对夜晚环境锥桶检测效果不理想的问题, 提出了用 ALTM_Retinex 算法替换 V 通道直方图均衡化的方法, 提高了图像的整体亮度, 尤其是夜晚的图像亮度提升最明显。图像经过 ALTM_Retinex 算法处理后, 重新修正了 HSV 三通道的阈值, ALTM_Retinex 算法在夜晚等低照度环境下的图像分割效果要优于 V 通道直方图均衡化的图像增强算法。

针对白天环境下 V 通道直方图均衡化算法的图像分割效果更明显, 而在夜晚环境下 ALTM_Retinex 算法的图像分割效果更明显的情况, 提出了基于亮度的阈值分类选取算法。通过判断图像 HSV 颜色空间下 V 通道的期望值大小, 来选择图像增强的方法。融合后的算法在白天和夜晚两种环境下均有较好的表现, 实验结果表明, 基于亮度的阈值分类选取算法准确率达到了 85.40%, 相比加入 V 通道直方图均衡化和 ALTM_Retinex 算法分别提高了 18.98%和 4.93%。

4 基于深度学习的复杂环境下交通锥桶检测算法研究

基于纹理特征的交通锥桶检测方法受外界环境因素影响较大，稳定性和准确性不高，而且只针对特定颜色和形状的方法不适用于多类型的交通锥桶检测。随着深度学习目标识别技术的完善，目标识别算法的检测精度和速度都在不断上升。本章基于深度学习目标识别的方法，自建复杂环境下的交通锥桶数据集；考虑到实时性问题，采用轻量化 MobileNet^[61]网络的思想，将 MobileNet 网络与 YoloV4^[62]网络相融合，得到网络结构复杂度更低的 MobileNetV3_YoloV4 目标识别算法，并测试了算法在自建交通锥桶数据集中的检测性能，验证了自建数据集的有效性。

4.1 复杂环境下的交通锥桶数据集构建

我国在高速公路养护作业中使用的交通锥桶种类包含圆锥和方锥两类，且颜色多样、大小不一，故本文自建了用于深度学习的交通锥桶数据集。该数据集包含了晴天、阴天、雨天、夜晚四种环境下的交通锥桶图像，图像中大都涵盖了近距离和远距离的锥桶图像，而且将四种环境下的锥桶图像分为圆锥和方锥两类。由于检测目标单一，且锥桶大都摆放在沥青路面，检测背景也相对单一，本文通过建立复杂环境下的锥桶数据集，提高了样本的质量，有效减少了深度学习算法中的过拟合问题，提高了算法的准确性和鲁棒性。

本文共采集 1778 张含多个锥桶的图像，共包含 5141 个交通锥桶。其中，在四种环境下共计训练集 1278 张，包含 3678 个锥桶，测试集 500 张，包含 1463 个锥桶；交通锥桶数据集如表 4.1 所示。

表 4.1 四种环境下的交通锥桶数据集

环境	训练集（张）	测试集（张）	总计（张）
晴天	331	125	456
阴天	361	125	486
雨天	212	125	337
夜晚	374	125	499

图 4.1 为四种环境下采集的交通锥桶图片。



图 4.1 四种环境下的交通锥桶图片

为了方便测试算法对小目标的检测性能，本文从测试集中挑选了 100 张含有较多小目标锥桶的图像作为小目标测试集。由于数据集均由分辨率为 640*480 的相机采集，本文界定目标像素面积小于 200 则认定为小目标。小目标锥桶如图 4.2 所示。



图 4.2 小目标锥桶

如图 4.3 所示，使用 Labelimg 目标检测标注工具对数据集进行标注，标注格式设置为 Pascal VOC2007，数据集中圆锥和方锥的种类名称统一设置为 cone，最终会生成 xml 标签文件，包含目标的位置坐标和类别信息。



图 4.3 Labelimg 标注工具

如图 4.4 所示，xml 标签中包含文件名称、路径信息、图片尺寸、类别信息以及所标矩形框的左上角和右下角坐标。


```
<annotation>
  <folder>JPEGImages</folder>
  <filename>1056.jpg</filename>
  <path>D:\cone\JPEGImages\1056.jpg</path>
  <source>
    <database>Unknown</database>
  </source>
  <size>
    <width>640</width>
    <height>480</height>
    <depth>3</depth>
  </size>
  <segmented>0</segmented>
  <object>
    <name>cone</name>
    <pose>Unspecified</pose>
    <truncated>0</truncated>
    <difficult>0</difficult>
    <bndbox>
      <xmin>114</xmin>
      <ymin>130</ymin>
      <xmax>160</xmax>
      <ymax>228</ymax>
    </bndbox>
  </object>
</annotation>
```

图 4.4 xml 标签文件

4.2 YoloV4 网络模型

本文测试了 YoloV4 模型用于锥桶目标检测。YoloV4 网络模型如图 4.5 所示，输入图像大小为 416×416 ，CSPDarknet53 作为主干特征提取网络，SPP-Net^[63]、PANet^[64]作为加强特征提取网络。




图 4.5 YoloV4 网络模型

YoloV4 模型为典型的端到端的网络，其结构比 Faster R-CNN^[65] 算法更加简洁直观，继承了 YoloV3^[66] 的主干结构，在特征提取结构上融合了 CSPNet^[67] 结构，提出了 CSPDarkNet53，使用 SPP-Net 来增加感受野；YoloV4 模型分别用 4 个不同尺寸的池化核进行最大池化处理，最大池化的池化核大小分别为 13×13 ， 9×9 ， 5×5 和 1×1 ，能够更好地进行特征融合。

在 YoloV4 网络中，锥桶检测的具体流程如下：首先在主干特征提取网络 CSPdarknet53 中输入大小为 $(416, 416, 3)$ 的锥桶图片，经过多次下采样，图像的高和宽会被不断地压缩，图像的通道数也在不断扩张，从而获得不同尺寸大小的特征层。紧接着对大小为 $(13, 13, 1024)$ 的特征层进行三次卷积，并在 SPP 加强特征提取网络内进行最大池化操作，然后对特征层进行堆叠和三次卷积；进入 PANet 后，对特征层进行上采样操作，将特征层的高和宽变为原来的两倍，此时得到的特征层大小为 $(26, 26, 512)$ ，并与主干网络中大小为 $(26, 26, 512)$ 的特征层进行堆叠和五次卷积操作，实现二者的特征融合。融合后的特征层继续执行上采样操作，得到大小为 $(52, 52, 256)$ 的特征层，并与主干网络中大小为 $(52, 52, 256)$ 的特征层进行堆叠和五次卷积操作，再次实现特征融合。将 PANet 融合后大小为 $(52, 52, 256)$ 的特征层进行下采样，得到大小为 $(26, 26, 512)$ 的特征层，与 PANet 中另一个大小为 $(26, 26, 512)$ 的特征层进行堆叠和五次卷积操作，实现二者的特征融合，从而提取到非常多的有效特征。最终，根据提取到的特征进行锥桶预测。

4.3 MobileNetV3_YoloV4 网络模型

鉴于大型网络模型参数比较大，对设备的算力要求较高，导致算法无法在高速公路预警跟随车以及嵌入式设备上运行的问题，本章采用轻量级深层神经网络 MobileNetV3^[68] 模型与 YoloV4 模型相结合的 MobileNetV3_YoloV4 模型，大幅减少了网络参数量和运算量。

4.3.1 轻量化网络 MobileNet

MobileNet 网络是谷歌公司提出的一种针对移动终端或嵌入式设备的轻量级深度神经网络，目前有 V1、V2、V3 三个版本。MobileNet 网络的核心思想是使用深度可分离卷积（Depthwise Separable Conv）^[68]，与传统卷积相比，其计算量大幅降低。

在传统卷积中，假设输入特征矩阵的通道数（channel）为 3，且使用 4 个卷积

核进行卷积，则每个卷积核的通道数与输入特征矩阵的通道数相同，而输出特征矩阵的通道数是由卷积核的个数决定的，即卷积核的通道数等于输入特征矩阵通道数，输出特征矩阵的通道数等于卷积核的个数。传统卷积如图 4.6 所示。




图 4.6 传统卷积

深度可分离卷积是由 DW 卷积 (Depthwise Conv) 和 PW 卷积 (Pointwise Conv) 组成的。

DW 卷积 (Depthwise Conv) 中每个卷积核的通道数为 1，每个卷积核只负责与输入特征矩阵的 1 个通道数进行卷积运算，然后得到 1 个输出特征矩阵，即每个卷积核负责一个通道数，故 DW 卷积的卷积核通道数等于 1，输入特征矩阵的通道数等于卷积核个数，也等于输出特征矩阵的通道数。

PW 卷积 (Pointwise Conv) 实质上是一个卷积核的大小固定为 1 传统卷积。深度可分离卷积如图 4.7 所示。




图 4.7 深度可分离卷积

为了对比传统卷积与深度可分离卷积的计算量，假设输入特征矩阵的大小为 $D_F \times D_F \times M$ ，输出特征层大小为 $D_F \times D_F \times N$ 。以下对两种卷积的计算量进行分析：

(1) 在传统卷积中，假设卷积核大小为 $D_K \times D_K \times M$ ，则卷积计算量可以用

公式 4.1 表示。

$$D_K \times D_K \times M \times N \times D_F \times D_F \quad (4.1)$$

(2) 深度可分离卷积是 DW 卷积和 PW 卷积相加的结果，首先使用大小为 $D_K \times D_K \times 1$ 的卷积核进行卷积，再使用 N 个 $1 \times 1 \times M$ 大小的卷积核进行卷积，卷积计算量可以用公式 4.2 表示。

$$D_K \times D_K \times M \times D_F \times D_F + M \times N \times D_F \times D_F \quad (4.2)$$

深度可分离卷积与传统卷积的计算量之比如公式 4.3 所示。

$$\frac{D_K \times D_K \times M \times D_F \times D_F + M \times N \times D_F \times D_F}{D_K \times D_K \times M \times N \times D_F \times D_F} = \frac{1}{N} + \frac{1}{D_K^2} \quad (4.3)$$

其中， $N > 0$ ，且网络中卷积核的大小 D_K 一般取 3，在理论上传统卷积的计算量是深度可分离卷积的 8~9 倍。

MobilenetV3 提出了 bneck 结构，有效结合了 MobileNetV1^[61] 的深度可分离卷积结构、MobileNetV2^[69] 的具有线性瓶颈特征的倒残差结构、注意力机制 SE 模块和 Hard_swish 激活函数。在 bneck 结构中，首先将输入的特征层利用卷积核大小为 1×1 的卷积对特征层进行升维操作，然后利用卷积核大小为 3×3 的深度可分离卷积进行特征提取，对获取到的特征层施加注意力机制，再进行两次全连接，第一次全连接后面跟的是 ReLU 激活函数，第二次全连接后面跟的是 Hard_Sigmoid 激活函数；再将得到的结果与施加注意力机制之前的特征层相乘，从而得到一个新的特征层，然后利用卷积核大小为 1×1 的卷积对特征层降维，最后将原始输入的特征层与降维后的特征层相加并输出结果。




图 4.8 bneck 网络结构

bneck 网络结构如图 4.8 所示，图中最左侧的短接边只有在步距等于 1，且输

入与输出特征矩阵大小相同时才生效，图中的 NL 代表非线性激活函数，由于在 MobilenetV3 网络中不同的层所使用的激活函数是不一样的，故在此用 NL 来表示。

MobileNetV3 的网络结构有 MobileNetV3-Large 和 MobileNetV3-Small 两种，本文均采用 MobileNetV3-Large 来进行实验测试。MobileNetV3 的网络结构如表 4.2 所示^[68]，第一列代表当前输入特征层的尺寸；第二列代表具体操作内容；第三列代表在 bneck 结构中第一次升维操作后的通道数大小；第四列代表输出特征矩阵的通道数大小；第五列代表是否使用 SENet 注意力机制；第六列代表使用的激活函数种类，HS 代表 Hard_swish 激活函数，RE 代表 ReLU 激活函数；第七列代表步距大小。

表 4.2 MobileNetV3 网络结构

Input	Operator	exp size	#out	SE	NL	s
$416^2 \times 3$	conv2d	-	16	-	HS	2
$208^2 \times 16$	bneck, 3×3	16	16	-	RE	1
$208^2 \times 16$	bneck, 3×3	64	24	-	RE	2
$104^2 \times 24$	bneck, 3×3	72	24	-	RE	1
$104^2 \times 24$	bneck, 5×5	72	40	√	RE	2
$52^2 \times 40$	bneck, 5×5	120	40	√	RE	1
$52^2 \times 40$	bneck, 5×5	120	40	√	RE	1
$52^2 \times 40$	bneck, 3×3	240	80	-	HS	2
$26^2 \times 80$	bneck, 3×3	200	80	-	HS	1
$26^2 \times 80$	bneck, 3×3	184	80	-	HS	1
$26^2 \times 80$	bneck, 3×3	184	80	-	HS	1
$26^2 \times 80$	bneck, 3×3	480	112	√	HS	1
$26^2 \times 112$	bneck, 3×3	672	112	√	HS	1
$26^2 \times 112$	bneck, 5×5	672	160	√	HS	2
$13^2 \times 160$	bneck, 5×5	960	160	√	HS	1
$13^2 \times 160$	bneck, 5×5	960	160	√	HS	1
$13^2 \times 160$	conv2d, 1×1	-	960	-	HS	1
$13^2 \times 960$	Pool, 13×13	-	-	-	HS	-
$1^2 \times 960$	conv2d 1×1 , NBN	-	1280	-	HS	1
$1^2 \times 1280$	conv2d 1×1 , NBN	-	k	-	HS	-

4.3.2 MobileNetV3 与 YoloV4 算法融合

MobileNetV3_YoloV4 网络将 YoloV4 与 MobileNetV3 相结合。将原始 YoloV4 模型中的主干特征提取网络 CSPDarknet53 替换为 MobileNetV3 网络结构。将 MobileNetV3 网络结构中第一层输入特征矩阵修改为图像尺寸大小, 本小节选用了宽高为 416×416 的默认图像大小, 分别取出 MobileNetV3 网络中特征层大小为(52, 52, 40)、(26, 26, 112)和(13, 13, 160)的最后一层进行加强网络特征提取。在加强特征提取网络 PANet 中, 将传统的 3×3 卷积替换为深度可分离卷积, 大幅减少网络参数量。MobileNetV3_YoloV4 网络模型如图 4.9 所示。




图 4.9 MobileNetV3_YoloV4 网络模型

4.4 实验验证

4.4.1 实验平台环境

算法的测试过程在云边端架构中进行, 将网络的训练过程分配到云服务器中, 网络的预测过程分配到边缘控制器中, 终端负责实时采集上传图片。其中, 云服务器和边缘控制器均基于 Linux 平台, Centos7, 均采用 PyTorch 深度学习框架, PyTorch 版本为 V1.7.1, python 版本为 3.7.11, CUDA 版本为 V11.0.2, 对应的 CUDNN 版本为 V8.0.5。

实验过程中, YoloV4 和 MobileNetV3_YoloV4 的网络模型参数如下:

- (1) 输入图片尺寸默认缩放为 416*416;
- (2) 学习率采用 pytorch 自带的余弦退火衰减法;
- (3) Batch_size 大小设置为 16, Epoch 设为 1200;
- (4) 为了防止过拟合, 将 Label Smoothing 平滑设为 0.005;

(5) 在实际测试的过程中, 由于本数据集种类单一, 使用 Mosaic 数据增强的方式没有起到很好的效果, 容易导致不稳定的现象, 故在算法中关闭了此功能。

4.4.2 性能评估指标

目标检测实验可以使用 mAP(mean Average Precision)做为评价指标。在介绍 mAP 之前, 首先介绍一下 TP、TN、FP、FN、Recall 和 Precision 的概念。

T、F 分别代表该样本被正确分类和错误分类, P、N 分别代表该样本被预测成了正样本和负样本。TP (True Positives) 表示被正确的预测为正样本; TN (True Negatives) 表示被正确的预测为负样本; FP (False Positives) 表示被错误的预测为正样本, 实际是负样本; FN (False Negatives) 表示被错误的预测为负样本, 实际是正样本。

Recall (召回率): 表示测试集中所有正样本被正确识别的比例, 其计算公式如式 4.4 所示。

$$Recall = \frac{TP}{TP + FN} \quad (4.4)$$

Precision (精确度): 表示被分为正确的样本中, 其真实值也为正样本的比重, 其计算公式如式 4.5 所示。

$$Precision = \frac{TP}{TP + FP} \quad (4.5)$$

在目标检测中, 每一类都可以根据 Precision 和 Recall 绘制一条 PR 曲线, AP 就是该曲线下的面积, mAP 表示所有类别的 AP 值求平均。由于本数据集的标签只有锥桶一种, 故本实验的 AP 值与 mAP 值相等。

交并比 IOU (Intersection Over Union) 用来衡量真实框和预测框的重合程度。如图 4.10 所示, 假设 A 代表真实框, B 代表预测框, $S_{A \cap B}$ 代表真实框与预测框重叠区域的面积, 即 A 与 B 的面积求交集; $S_{A \cup B}$ 代表真实框与预测框所占有的总面积, 即 A 与 B 的面积求并集。




图 4.10 真实框与预测框交集、并集示意图

则 IOU 的计算过程可以用公式 4.6 表示：

$$IOU = \frac{S_{A \cap B}}{S_{A \cup B}} \quad (4.6)$$

通过计算不同 IOU 下的 mAP 值来评价检测精度的高低，mAP 值越高，代表算法的检测精度越高。本章测试了 YoloV4 与 MobileNetV3_YoloV4 模型 mAP@0.5、mAP@0.75 和 mAP@[0.5:0.95] 的值。mAP@0.5 表示 IOU 大于 0.5 的 mAP 值，mAP@0.75 表示 IOU 大于 0.75 的 mAP 值，mAP@[0.5:0.95] 表示 IOU 的阈值从 [0.5:0.95] 的区间上每隔 0.5 计算一次 mAP 值，取这 10 个 mAP 值的平均值作为最终结果。

FPS(Frames Per Second)为终端每秒钟处理图像的帧数，用来评价目标检测算法检测速度，FPS 值越高代表模型的检测速度越快。其计算公式如式 4.7 所示，其中，T 代表一次前向运算需要的时间。

$$FPS = \frac{1}{T} \quad (4.7)$$

4.4.3 实验结果分析

本节测试了 YoloV4 与 MobileNetV3_YoloV4 模型，算法中默认输入的图像尺寸为 416*416，由于数据集只包含交通锥桶，故目标检测种类个数设为 1，此处先验框的大小和个数均选用默认参数。表 4.3 为 YoloV4 与 MobileNetV3_YoloV4 在本数据集下的网络参数量对比，可以看出，MobileNetV3 网络与 YoloV4 网络结合后，网络参数量相比 YoloV4 降低了将近 6 倍，降低了网络的复杂度，有利于网络检测速度的提升。

表 4.3 YoloV4 与 MobileNetV3_YoloV4 网络参数量对比

目标检测算法	网络参数量
YoloV4	63,937,686
MobileNetV3_YoloV4	11,303,654

表 4.4 YoloV4 和 MobileNetV3_YoloV4 mAP 值及检测速度对比

目标检测算法	mAP@0.5	mAP@0.75	mAP@[0.5:0.95]	帧率 (FPS)
YoloV4	98.86%	92.60%	80.09%	9~10
MobileNetV3_YoloV4	94.47%	79.96%	69.11%	32~33

对 500 张锥桶测试集进行了测试,分别对比了 YoloV4 和 MobileNetV3_YoloV4 在边缘控制器下的 mAP 值和检测速度。测试结果如表 4.4 所示, MobileNet 网络与 YoloV4 融合后,检测精度有一定的下降,但检测速度大幅提升,在边缘控制器上,检测速率提升了 3 倍。

4.5 本章小结

本章介绍了自建的复杂环境下的交通锥桶数据集,验证了数据集的有效性,适用于高速公路环境下的锥桶检测。为了提高检测的速度,满足智慧高速公路对高实时性的要求,本章分析了轻量化神经网络 MobileNet,并阐述了与 YoloV4 融合的过程。最后,根据自己搭建的实验平台环境,对比了 YoloV4 与 MobileNetV3_YoloV4 的 mAP 值和检测帧率。结果表明, MobileNetV3_YoloV4 的精测速度相比于 YoloV4 有了大幅提升,训练速度也大幅上升,但检测精度还有一定的提升空间。

5 基于 MobileNetV3_YoloV4 的锥桶检测算法改进

MobileNetV3_YoloV4 在牺牲算法检测精度的前提下，提高了算法的实时性。为了进一步提高对锥桶的检测精度，本章基于 MobileNetV3_YoloV4 网络，提出一种适用于检测高速公路交通锥桶的 MobileNetV3_YoloV4 改进算法，使之能兼顾检测精度和检测速度。

5.1 基于浅层特征的改进

在模型中融合图像浅层特征可以有效提高小目标的检测性能，融合方式有两种：一种是融合新的特征提取结构，另一种是在网络特征提取结构内部增加浅层特征。

5.1.1 检测层尺度改进

在网络模型中，浅层网络学习到的是边缘、转角、形状、斑块、颜色等底层细粒度的信息，感受野小，适合检测小目标；而深层网络学习到的是各种纹理等抽象特化的语义信息，感受野大，适合检测较大物体。MobileNetV3_YoloV4 网络的特征提取过程中存在多次下采样操作，浅层信息较少，不利于对小目标的检测。因此，可以将浅层特征层信息融入到 MobileNetV3_YoloV4 网络中，增加特征层分辨率，提高模型对小目标的检测性能。




图 5.1 修改检测层尺度后的 MobileNetV3_YoloV4 网络结构图

为了提高检测小目标的精度，本文尝试了修改检测层尺度，将主干网络尾部大小为 13×13 的特征层去掉，改用 26×26 、 52×52 和 104×104 的特征层进行特征提取，修改检测层尺度后的 MobileNetV3_YoloV4 网络结构图如图 5.1 所示。

由于去掉了主干网络中最后 13×13 的特征层，在网络的训练和预测过程中减少了 2 次 bneck 运算，故 MobileNetV3_YoloV4 的网络参数量有一定的降低。表 5.1 为修改检测层尺度后网络参数量对比。

表 5.1 网络参数量对比

目标检测算法	网络参数量
原 MobileNetV3_YoloV4	11,303,654
修改检测层尺度	9,234,654

本章在边缘控制器的实验环境下，对采集的 500 张交通锥桶测试集进行实验对比，修改检测层尺度后的 mAP 值及检测速度如表 5.2 所示。

表 5.2 mAP 值及检测速度对比

目标检测算法	mAP@0.5	mAP@0.75	mAP@[0.5:0.95]	帧率 (FPS)
MobileNetV3_YoloV4	94.47%	79.96%	69.11%	32~33
修改检测层尺度	97.34%	87.20%	74.84%	19~20

由表 5.2 可知，修改检测层尺度后，网络的检测精度大幅提升，小目标的检测效果有了明显的改善，但检测速度下降幅度较大，故增加检测层尺度的方法并不理想。

5.1.2 MobileNetV3 网络结构改进

在 MobileNetV3 网络中，可通过增加浅层的卷积次数来丰富图像的细粒度特征，使网络捕获更多的细节特征。改进的 MobileNetV3 网络结构如图 5.2 所示，以输入图像尺寸为 416×416 为例，分别在特征层大小为 $(208, 208, 16)$ 和 $(104, 104, 24)$ 处增加一层 bneck 网络。




图 5.2 MobileNetV3 网络改进

改进 MobileNetV3 网络结构后，在 500 张测试集上进行测试，相比于原始 MobileNetV3_YoloV4, mAP@0.5、mAP@0.75 和 mAP@[0.5:0.95]分别提高了 3.69%、7.85%和 5.61%，检测速度一致，检测性能大幅提高。测试结果如表 5.3 所示。

表 5.3 mAP 值及检测速度

目标检测算法	mAP@0.5	mAP@0.75	mAP@[0.5:0.95]	帧率 (FPS)
MobileNetV3_YoloV4	94.47%	79.96%	69.11%	32~33
改进 MobileNetV3 网络结构	98.16%	87.81%	74.72%	32~33

图 5.3 为小目标锥桶图像在原始 MobileNetV3_YoloV4 和改进 MobileNetV3 网络结构后的检测效果图。




图 5.3 原始 MobileNetV3_YoloV4 与改进 MobileNetV3 网络结构后的检测效果图

5.1.3 图片尺寸优化

为了进一步提高算法的检测速度，本章又对网络训练和预测时输入的图片尺寸进行了调整。由 MobileNetV3_YoloV4 网络结构可知，网络可以处理图片尺寸满足 32 的倍数的不同尺度的图像，实现了图像的多尺度融合。算法默认输入的图片尺寸为 416×416 ，而相机采集的图像大小为 640×480 ，故算法中首先要调整采集图像的大小，将 640×480 的图像不失真的调整为 416×416 的图像。在 YoloV4 模型中，作者使用的是 `letterbox_image` 函数，其原理是将输入的图像进行等比例缩放，然后将一张 416×416 的灰色图片贴在缩放后的图片上，最终返回一张不失真的 416×416 的图像。由于原图像大小为 640×480 ，而经过 `letterbox_image` 函数缩放后的图像大小为 416×416 ，两边会有一部分无效像素点，即灰色条，为了进一步减少无效像素点，本文将缩放后的图像尺寸改为 480×320 。图 5.4 为相机采集的图像经过 `letterbox_image` 函数缩放为 416×416 和 480×320 后的图像对比。




图 5.4 图像尺寸对比

由图 5.4 可知，缩放为 416×416 的图片改为缩放为 480×320 的图片后，图像的无效像素点明显减少，且网络最终输出的三个有效特征层的宽高大小由 26×26 、 52×52 、 104×104 转变为 30×20 、 60×40 、 120×80 。 416×416 大小的图片被划分为 $26 \times 26 + 52 \times 52 + 104 \times 104$ 个网格，即 14196 个网格；而 480×320 大小的图片被划分为 $30 \times 20 + 60 \times 40 + 120 \times 80$ 个网格，即 12600 个网格；因此，网络中先验框的总个数大幅减少，降低了网络的计算复杂度。

本节对此改进方法进行了验证，在修改检测层尺度后的 MobileNetV3_YoloV4 基础上，分别对比了默认训练尺寸 416×416 和修改训练尺寸为 480×320 后的 mAP 值及检测速度，本实验在云边端架构下对 500 张测试集进行了测试。表 5.4 是修改训练图片输入尺寸后的 mAP 值及检测速度对比。

表 5.4 mAP 值及检测速度对比

输入图像尺寸	mAP@0.5	mAP@0.75	mAP@[0.5:0.95]	帧率 (FPS)
416*416	97.29%	86.67%	72.61%	19~20
480*320	97.34%	87.20%	74.84%	21~22

由表 5.6 可知，在修改完训练图片尺寸后，算法在检测精度和检测速度上均有了一定的提升，尤其是检测速度提升了 2FPS 左右。

5.2 基于先验框的 MobileNetV3_YoloV4 改进

先验框（anchors）是预先在图像上预设好不同大小和不同宽高比的框，有利于网络的训练和预测。在 MobileNetV3_YoloV4 网络中，依旧选用 YoloV4 中 K-means 聚类算法获得先验框。提前选择合适的先验框，网络会更容易训练和学习，从而得到更好地检测效果。获取先验框常用的方法有：（1）手动获取（2）K-means 聚类算法（3）作为超参数学习。K-means 聚类算法是目前使用最广泛的，在网络中有较好的效果。

5.2.1 K-means 聚类算法介绍

K-means 聚类通过计算样本之间的距离（相似性）将更接近的样本聚集到同一类别（簇）中。K-means 聚类算法的计算过程如下：（1）从样本中随机选取 k 个样本作为簇的质心；（2）根据欧氏距离公式求解剩余的每个样本与质心之间的距离，并将剩余样本归到与它最近的质心的簇中；（3）重新计算每个簇中样本的平均值，并更新簇的质心；（4）重复第 2~3 步骤，直到簇的质心不再变化或变化范围小于一定阈值。

以上便是 K-means 聚类算法的介绍，本章节对先验框的优化设计也是通过 K-means 聚类算法实现的，自建数据集的真实框的宽高作为 K-means 聚类的样本，簇的个数 k 即为先验框的个数。

5.2.2 基于先验框的算法优化

MobileNetV3_YoloV4 中先验框的尺寸是利用 K-means 聚类得到的。通过数据集聚类得到的先验框，相比手工选择的可以有效的避免主观性。原始 MobileNetV3_YoloV4 中的 9 个先验框的大小是利用 COCO 数据集聚类得到的。

通用的先验框大小都是在大型数据集上经过聚类得到的，对于特定的检测目标，若使用默认的先验框大小，不仅会影响检测精度，而且在训练过程中容易出

现模型难以收敛的情况。故本文通过 K-means 聚类的方式，在自建交通锥桶数据集上聚类出 3 个、6 个、9 个、12 个、15 个、18 个先验框，并分析了先验框数量给 MobileNetV3_YoloV4 带来的影响。图 5.5 为先验框数量与数据集平均 IOU 绘制的曲线图，平均 IOU 越大代表得到的先验框质量越好。




图 5.5 先验框数量与数据集平均 IOU 的曲线图

由图 5.5 可知，先验框数量越多，平均 IOU 的值越大。在先验框数量大于 15 以后，增长速度越来越慢。

经过 K-means 聚类的方法对锥桶数据集进行聚类，得到了更符合本文要求的先验框尺寸大小，若选用 15 个先验框，则聚类的中心点分别为(6,17), (8,22), (10,29), (13,38), (16,46), (19,26), (20,58), (27,71), (29,38), (33,91), (43,115), (52,69), (58,149), (74,207), (128,140)，先验框宽高比例均在 1:3 左右，符合真实交通锥桶的宽高比。

原始 MobileNetV3_YoloV4 的先验框与优化后的先验框如图 5.6 所示，图中的图片大小为 416*416，其为了方便展示，将所有的先验框均放在了 13*13 的中间网格中显示。实际上，在原始 MobileNetV3_YoloV4 中是将三个较大的先验框分配给 13*13 的网格，将三个中等的先验框分配给 26*26 的网格，将较小的三个先验框分配给 52*52 的网格。经过优化后，经将五个较大的先验框分配给 13*13 的网格，五个中等的先验框分配给 26*26 的网格，五个较小的先验框分配给 52*52 的网格。




图 5.6 原始先验框与优化后的先验框

由于 MobileNetV3_YoloV4 最终输出三个有效特征层，为了方便计算，对网络进行训练时分别选用了 3 个、6 个、9 个、12 个、15 个先验框，按照大、中、小平均分配到对应的有效特征层上，并用采集的 500 张交通锥桶测试集进行算法优化前后测试，实验均在云边端架构下进行。表 5.5 为 MobileNetV3_YoloV4 模型改变先验框数量后的 mAP 值及检测速度对比。

表 5.5 mAP 值及检测速度对比

先验框数量（个）	mAP@0.5	mAP@0.75	mAP@[0.5:0.95]	帧率（FPS）
3	95.23%	80.00%	69.36%	32~33
6	95.36%	80.76%	69.50%	32~33
9	95.37%	80.87%	69.72%	32~33
12	95.47%	80.93%	69.77%	31~32
15	95.66%	82.77%	71.62%	31~32

表 5.6 为 MobileNetV3_YoloV4 模型改变先验框数量后的参数量对比。

表 5.6 参数量对比

先验框数量	网络参数量
3	11,282,114
6	11,292,884
9	11,303,654
12	11,314,424
15	11,325,194

在 MobileNetV3_YoloV4 中，网络最终输出的三个有效特征层大小分别为：
(num_anchors*(1+4+num_classes),13,13), (num_anchors*(1+4+ num_classes),26,26),
(num_anchors*(1+4+num_classes),52,52)。其中，num_anchors 代表该特征层上的先

验框数量,数字 1 为预测边框的置信度,数字 4 为预测边框的坐标信息,num_classes 代表预测目标的种类个数,后面的 13、26、52 分别代表特征层被划分为网格的大小。由于本文最终检测的目标种类只有交通锥桶一种,即 num_classes 等于 1,这大大减小了 num_anchors 对网络参数的影响,而且由表 5.6 可知,先验框数量的改变对网络参数大小的影响不大。在表 5.5 中,选用 15 个先验框后,相对于原始的 9 个先验框检测帧率只下降了 1FPS,但 mAP 值却有一定的提升,随着先验框数量的增加,检测小目标的检测性能会越来越好,但算法的复杂度也会随着增加。综合考虑,本文选用 15 个先验框对 MobileNetV3_YoloV4 进行优化,在检测帧率几乎不变的前提下,检测精度有了一定的提升,更适合对交通锥桶的识别。

5.3 基于轻量化注意力机制的改进

网络到达一定深度时,其语义信息也会变得更加丰富,但也会出现特征冗余现象,影响对正确特征的学习。因此,如何选出正确特征是有必要的。注意力机制是一种有效选取正确特征的方式,在深度神经网络中,可以根据目标信息的重要程度分配不同大小的权重。注意力机制可分为空间注意力机制、通道注意力机制以及二者的结合,常见的注意力机制有 SENet^[70],CBAM^[71],ECANet^[72]等。

(1) SENet

SENet 属于通道注意力机制,具体实现方法如下:首先,对输入特征层进行全局平均池化;紧接着进行两次全连接,第一次全连接神经元数量较少,第二次全连接神经元数量与输入特征层数量相同;其次,利用 Sigmoid 函数进行归一化处理,获得输入特征层每一个通道的权重大小;最后,将权重大小乘以原始输入特征层,完成 SENet 注意力机制的施加。

(2) CBAM

CBAM 整合了通道注意力机制与空间注意力机制。对于通道注意力机制,首先在输入的特征层上进行池化操作,然后对结果进行全连接操作,并将处理后的两个结果相加;通过 Sigmoid 函数进行归一化处理,获得输入特征层每个通道的权重大小;最后,将权重大小乘以原输入特征层。对于空间注意力机制,首先,计算输入特征层每个通道的最大值和平均值;然后将两个结果进行堆叠处理,利用通道数为 1 的卷积调整特征层的通道数;再通过 Sigmoid 函数进行归一化处理,获得输入特征层上每个特征点的权重大小;最后,将权重大小乘以原始输入特征层

即可完成注意力机制的施加。

(3) ECANet

ECANet 是通道注意力机制的一种，可以看作是改进后的 SENet，去除了原有 SENet 中的全连接层，在全局平均池化之后的特征上直接通过一维卷积进行学习。

本文将注意力机制添加到 MobileNetV3_YoloV4 加强特征提取网络中。如图 5.7 所示，对主干网络提取出来的三个特征层上施加注意力机制，同时对 PANet 网络中上采样和下采样后的结果施加注意力机制。




图 5.7 MobileNetV3_YoloV4 网络添加注意力机制后的网络结构图

MobileNetV3_YoloV4 分别加入三种注意力机制后的网络参数量如表 5.7 所示。

表 5.7 网络参数量对比

注意力机制模型	网络参数量
原 MobileNetV3_YoloV4	11,303,654
加入 SENet	11,359,782
加入 CBAMNet	11,529,012
加入 ECANet	11,303,685

由表 5.7 可知，加入 ECANet 后，MobileNetV3_YoloV4 网络的参数量几乎没有变化。为了满足高速公路实时性要求，本文采取了更轻量化的注意力机制 ECANet，ECANet 网络结构如图 5.8 所示。实现流程如下：首先，将输入特征进行全局平均池化；其次，利用 Conv1d 进行特征提取；然后，对提取的特征进行归一化；最后，将输入特征与归一化后的结果相乘。




图 5.8 ECANet 网络结构

表 5.8 为 MobileNetV3_YoloV4 加入 ECANet 注意力机制后的 mAP 值及检测速度。

表 5.8 mAP 值及检测速度对比

目标检测算法	mAP@0.5	mAP@0.75	mAP@[0.5:0.95]	帧率 (FPS)
原 MobileNetV3_YoloV4	94.47%	79.96%	69.11%	32~33
加入 ECANet	95.27%	80.27%	69.77%	32~33

由表 5.8 可知，加入 ECANet 后，网络的检测精度有一定提升，mAP 值提高了约 1%，网络参数量没有明显的增加，故检测帧率也没有明显变化。

5.4 基于改进方法的算法融合

将前文描述的改进方法融合在一起，首先根据自建交通锥桶数据集聚类出 15 个先验框，并在网络中融入 ECANet 轻量化注意力机制，然后将训练和预测时输入的图像尺寸修改为 480*320，最后，修改 MobileNetV3 网络结构。考虑到增加检测层尺度会大幅增加网络模型的计算复杂度，严重降低算法的检测速度，且修改 MobileNetV3 网络结构后已经融入了浅层特征信息，可以有效代替增加的浅层检测层。综合考虑，我们尝试去除改进检测层尺度的方法，以期获得更好的结果。

MobileNetV3_YoloV4 最终输出的三个有效特征层大小由原来的 13*13、26*26、52*52 转变为 15*10、30*20、60*40，网络最终输出的三个有效特征层大小由 $(5*(1+4+1),13,13)$ 、 $(5*(1+4+1),26,26)$ 、 $(5*(1+4+1),52,52)$ 变为 $(5*(1+4+1),15,10)$ 、 $(5*(1+4+1),30,20)$ 、 $(5*(1+4+1),60,40)$ 。并将 15 个先验框中最大的五个分配给尺寸为 15*10 的有效特征层，将中等大小的五个分配给 30*20 的有效特征层，将最小的五个分配给 60*40 的有效特征层。改进方法有效融合后的 MobileNetV3_YoloV4 网络结构图如图 5.9 所示。




图 5.9 改进方法有效融合后的 MobileNetV3_YoloV4 网络结构图

本小节对原始 YoloV4、原始 MobileNetV3_YoloV4 以及改进后的 MobileNetV3_YoloV4 进行测试。在云边端架构下进行实验，对 500 张测试集进行测试，表 5.9 为三种算法的 mAP 值及检测速度实验对比。

表 5.9 mAP 值及检测速度对比

目标检测算法	mAP@0.5	mAP@0.75	mAP@[0.5:0.95]	帧率 (FPS)
YoloV4	98.86%	92.60%	80.09%	9~10
MobileNetV3_YoloV4	94.47%	79.96%	69.11%	32~33
改进 MobileNetV3_YoloV4	98.02%	86.81%	74.33%	32~33

实验结果表明，改进后的 MobileNetV3_YoloV4 相比于原始 MobileNetV3_YoloV4 在 mAP@0.5、mAP@0.75 和 mAP@[0.5:0.95]上分别提高了 3.55%、6.85% 和 5.22%，检测速度不变；相比于 YoloV4 分别还有 0.84%、5.79%和 5.76%的差距，但检测速度比 YoloV4 高 23FPS 左右。

改进后的 MobileNetV3_YoloV4 在检测速度不变的前提下，大幅提升了算法的检测精度，特别是对小目标锥桶，检测精度提升最明显。图 5.10 为原 MobileNetV3_YoloV4 与改进后的 MobileNetV3_YoloV4 对小目标锥桶的检测效果图。




图 5.10 MobileNetV3_YoloV4 与改进后的 MobileNetV3_YoloV4 检测效果图

5.5 实验验证

由于目标检测算法容易受到外界环境因素的影响，为了验证算法的稳定性，本小节比较了原始 MobileNetV3_YoloV4 与改进后的 MobileNetV3_YoloV4 在晴天、雨天、阴天、夜晚和小目标五种场景下的检测效果。

(1) 晴天环境：




图 5.11 MobileNetV3_YoloV4 与改进后的 MobileNetV3_YoloV4 检测效果图

如图 5.11 所示, 在晴天环境下, 锥桶形状轮廓清晰, 原始 MobileNetV3_YoloV4 和改进后的 MobileNetV3_YoloV4 都可以很好的检测出锥桶。

(2) 阴天环境:




图 5.12 MobileNetV3_YoloV4 与改进后的 MobileNetV3_YoloV4 检测效果图

如图 5.12 所示, 在阴天环境下, 锥桶的轮廓形状清晰可见, 受光照的影响较小, 改进前后的两种算法都可以检测出锥桶, 但改进算法的预测框明显与真实框更接近, 检测精度更高。

(3) 雨天环境:




图 5.13 MobileNetV3_YoloV4 与改进后的 MobileNetV3_YoloV4 检测效果图

如图 5.13 所示, 在雨天环境下, 光照效果与阴天类似, 受光照的影响较小。图 5.13 中(c)、(d)可以看出, 原始 MobileNetV3_YoloV4 有一处误检测, 改进后的 MobileNetV3_YoloV4 没有误检测现象, 证明算法改进后的抗干扰能力更强。

(4) 夜晚环境:




图 5.14 MobileNetV3_YoloV4 与改进后的 MobileNetV3_YoloV4 检测效果图

如图 5.14 所示, 在夜晚环境下, 光线较暗, 锥桶的颜色和形状信息容易受到外界环境的影响, 原始 MobileNetV3_YoloV4 出现了漏检现象。而改进后的 MobileNetV3_YoloV4 全部检测成功, 证明在夜晚这种光线较暗的环境下, 改进的 MobileNetV3_YoloV4 抗干扰能力更强, 增加了算法在夜晚环境下检测锥桶的能力。

(5) 小目标场景:




图 5.15 MobileNetV3_YoloV4 与改进后的 MobileNetV3_YoloV4 检测效果图

如图 5.15 所示, 在小目标场景下, 远处锥桶的像素点较少, 不利于特征的提取, 而改进后的 MobileNetV3_YoloV4 相比于原始 MobileNetV3_YoloV4 能检测出更多的锥桶, 提高了算法对小目标的检测性能。

基于自建数据集, 本文对比了原始 MobileNetV3_YoloV4 与改进后的 MobileNetV3_YoloV4 在晴天、雨天、阴天、夜晚和小目标五种场景下的 mAP 值, 对比结果如表 5.10 所示。

表 5.10 两种算法各场景下的 mAP 值对比

场景	目标检测算法	mAP@0.5	mAP@0.75	mAP@[0.5:0.95]
晴天	MobileNetV3_YoloV4	98.96%	94.78%	78.05%
	改进的 MobileNetV3_YoloV4	99.40%	95.59%	80.38%
阴天	MobileNetV3_YoloV4	99.47%	98.02%	81.27%
	改进的 MobileNetV3_YoloV4	100%	98.32%	84.90%
雨天	MobileNetV3_YoloV4	100%	100%	82.72%
	改进的 MobileNetV3_YoloV4	100%	100%	85.20%
夜晚	MobileNetV3_YoloV4	99.47%	92.87%	77.28%
	改进的 MobileNetV3_YoloV4	99.92%	93.09%	77.66%
小目标	MobileNetV3_YoloV4	88.34%	58.54%	56.04%
	改进的 MobileNetV3_YoloV4	97.48%	83.27%	71.69%

由表 5.8 可知, 改进后的 MobileNetV3_YoloV4 在整体检测精度上大幅提升, 尤其是在夜晚环境和远距离小目标的场景下, 检测性能有了较大的提升。改进后的 MobileNetV3_YoloV4 满足了高速公路环境下对目标检测准确性和实时性的要求, 适用于高速公路复杂环境下的交通锥桶检测。

5.6 本章小结

本章从先验框、注意力机制和检测层尺度三个方面研究了 MobileNetV3_YoloV4 对锥桶检测的影响, 根据对三者的优化改进, 提出了基于 MobileNetV3_YoloV4 的综合改进算法, 提高了高速公路环境下基于云边端架构的锥桶检测性能。

根据先验框对算法的影响, 提出了优化先验框个数的 MobileNetV3_YoloV4 改进方法。根据自建的数据集聚类出了 15 个最优的先验框, 在检测速度损耗不大的前提下, 提高了锥桶的检测性能。

基于注意力机制的对算法的影响, 提出了融合轻量化注意力机制 ECANet 的

改进方法，将 ECANet 融入 MobileNetV3_YoloV4 网络，加大了锥桶有效信息所分配的权重，在检测速度不变的前提下，提高了检测精度。

针对 MobileNetV3_YoloV4 对小目标检测能力弱的问题，提出了基于网络浅层特征的改进方法。分析了 MobileNetV3_YoloV4 网络结构中浅层特征对算法所带来的影响，并通过增加检测层尺度、改进 MobileNetV3_YoloV4 网络结构和优化训练图片的尺寸大小，大幅提升了对小目标的检测性能。

最后，将改进方法有效融合在一起，得到了改进后的 MobileNetV3_YoloV4，并针对复杂环境在云边端架构下进行了实验分析。实验证明，改进后的网络相比原始 MobileNetV3_YoloV4 在检测速度不变的情况下，检测精度大幅提升；与 YoloV4 相比，检测精度相差不大，且检测速度远高于 YoloV4。在云边端架构下，该算法同时兼顾了检测速度和检测精度，适用于高速公路复杂环境下的交通锥桶检测。

6 总结与展望

6.1 总结

本文研究内容主要是基于云边端架构的高速公路预警跟随车视觉导航关键技术研究，在智慧高速公路、预警跟随车、云边端架构和视觉导航的关键技术全面综述基础上，针对预警跟随车的交通锥桶检测技术进行了深入研究。研究的主要内容包括高速公路云边端架构的搭建与数据分配体系、基于纹理特征的交通锥桶检测算法、基于深度学习的交通锥桶检测算法。为了使高速公路预警跟随车系统安全、稳定运行，将深度学习算法合理分配到云边端架构，有利于提高目标识别算法的性能，构建安全有保障的交通道路环境。完成的具体内容有：

(1) 本文根据道路移动养护作业中警示装置类型单一、不可移动的问题，搭建高速公路预警跟随车系统，分析视觉导航关键技术，并阐述了交通锥桶检测的重要性；结合当前智慧高速公路的发展，搭建了云边端架构系统，使用 docker 镜像解决了环境异构问题，并将深度学习目标检测模型与云边端架构有效结合。

(2) 设计了基于纹理特征的交通锥桶检测算法流程。分析交通锥桶颜色和形状特点，并提取感兴趣区域，通过图像滤波、图像增强和图像分割进行图像预处理，再利用图像二值化、闭运算、开运算的形态学处理技术再次优化图像，然后根据二值化图像连通域和锥桶形状特征进行最后的筛选；分析了夜晚等低照度环境对锥桶检测带来的影响，通过 Retinex 算法进行图像优化，最后结合直方图均衡化和 Retinex 算法，改善了光照对锥桶检测的影响。

(3) 分析了基于深度学习的交通锥桶检测算法。自建多种环境下的交通锥桶数据集，融合 MobileNetV3 与 YoloV4，针对锥桶特征对融合后的 MobileNetV3_YoloV4 进行改进，将改进后的算法合理分配到云边端架构，并在自建数据集上进行测试，提高了锥桶的识别精度和速度。

6.2 创新点

本文将云边端架构与深度学习算法相融合，围绕高速公路交通锥桶检测算法进行深入研究，针对高速公路特殊环境以及小目标难以检测的问题，提出锥桶检测改进措施，提高了锥桶检测算法的性能，使高速公路预警跟随车安全、稳定运

行,对公路养护作业中的安全问题提供了有效保障。本文创新点主要体现在如下:

(1) 创新性的提出了基于纹理特征的锥桶检测算法。通过 HSV 颜色空间 V 通道直方图均衡化提高了白天环境锥桶的识别精度;针对夜晚环境,利用改进的 Retinex 算法提高了锥桶的识别精度;最后提出了基于亮度的阈值分类选取算法,根据图像亮度值来选择合适的图像增强算法,实验结果表明,在不影响检测速度的前提下,采用基于亮度的阈值分类选取算法的检测精度相比于单纯加入 V 通道直方图均衡化和加入改进的 Retinex 算法分别提高了 18.98%和 4.93%,有效提高了算法的精度。

(2) 针对高速公路锥桶类型多样、环境复杂而导致检测率低的问题,分别采集了晴天、阴天、夜晚、雨天和小目标场景下的交通锥桶图片,自建复杂环境下的交通锥桶数据集,并将 YoloV4 和 MobileNetV3_YoloV4 分布在云边端架构平台,测试了数据集的有效性,提高了算法的抗干扰能力。

(3) 针对小目标锥桶检测率低的问题,提出了基于 MobileNetV3_YoloV4 的交通锥桶改进方法,增加了网络中的浅层特征信息,改进了先验框尺寸和形状,融合了轻量化注意力机制;改进后的 MobileNetV3_YoloV4 相比原始 MobileNetV3_YoloV4,在检测速度一致的前提下, $mAP@0.5$ 、 $mAP@0.75$ 和 $mAP@[0.5:0.95]$ 值分别提升了 3.22%、9.7%和 6.83%,检测精度大幅提升;相比于原始 YoloV4,在检测精度接近的情况下,检测速度提高了 23FPS。

6.3 展望

本文按照既定计划基本完成了课题研究内容,但由于时间紧张及个人水平所限,还有些方面需要进一步研究并加以改善:

(1) 自建交通锥桶数据集大部分是在学校道路上采集完成的,且只包含两种类型锥桶。由于高速公路交通锥桶种类繁多,且公路背景环境可能与校内有所差异。在之后的工作中,需要进一步扩充高速公路锥桶数据,提高系统鲁棒性。

(2) 进行高速公路预警跟随车路径规划方法的研究。本文分别利用改进的传统算法和深度学习算法完成了对锥桶的定位识别工作,而定位到目标物之后,还需要根据目标位置进行路径规划导航,使预警跟随车能够沿着正确的、最优的路径行进。此后,可以继续把路径规划部分作为研究重点,实现预警跟随车整个系统的视觉导航功能。

参考文献

- [1] 杨承进. 公路养护高质量发展思路[J]. 中国公路, 2021(15): 40-42.
- [2] Belanche D, Casaló L V, Flavián C, et al. Service robot implementation: a theoretical framework and research agenda[J]. The Service Industries Journal, 2020, 40(3-4): 203-225.
- [3] Portugal D, Alvito P, Christodoulou E, et al. A study on the deployment of a service robot in an elderly care center[J]. International Journal of Social Robotics, 2019, 11(2): 317-341.
- [4] Chen C, Demir E, Huang Y, et al. The adoption of self-driving delivery robots in last mile logistics[J]. Transportation research part E: logistics and transportation review, 2021, 146: 102214.
- [5] Hjalmarsson-Jordanius A, Edvardsson M, Romell M, et al. Autonomous Transport: Transforming Logistics through Driverless Intelligent Transportation[J]. Transportation Research Record, 2018, 2672(7): 24-33.
- [6] Iclodean C, Cordos N, Varga B O. Autonomous shuttle bus for public transportation: A review[J]. Energies, 2020, 13(11): 2917.
- [7] Boersma R, Van Arem B, Rieck F. Application of driverless electric automated shuttles for public transport in villages: The case of Appelscha[J]. World Electric vehicle journal, 2018, 9(1): 15.
- [8] 王家辉. 基于 YOLOv3 的水田除草机器人视觉导航技术研究[D]. 广州: 华南理工大学, 2020.
- [9] 岑晏青, 宋向辉, 王东柱, 等. 智慧高速公路技术体系构建[J]. 公路交通科技, 2020, 37(07): 111-121.
- [10] 孙晶超. 高速公路交通事故预警管理研究[D]. 济南: 山东财经大学, 2017.
- [11] 陆德彪, 郭子明, 蔡伯根, 等. 基于深度数据的车辆目标检测与跟踪方法[J]. 交通运输系统工程与信息, 2018, 18(03): 55-62.
- [12] 刘金清, 陈存弟. 高速路的车道检测与车辆跟踪[J]. 计算机系统应用, 2020, 29(02): 187-197.
- [13] 于莉媛, 郭云雷, 牛萍娟, 等. 基于尾灯的夜间前方车辆检测与跟踪方法[J]. 天津工业大学学报, 2019, 38(01): 61-68.
- [14] 谭力凡, 吴俊, 曹立波, 等. 基于 AdaBoost 和压缩跟踪的前方车辆检测方法[J]. 汽车技术, 2019(02): 21-25.
- [15] 罗梅. 基于深度学习的高速公路车辆检测与跟踪系统研究与实现[D]. 成都: 西南交通大学, 2019.

- [16] 刘军, 后士浩, 张凯, 等. 基于增强 Tiny YOLOV3 算法的车辆实时检测与跟踪[J]. 农业工程学报, 2019 ,35(08): 118-125.
- [17] 周苏, 支雪磊, 林飞滨, 等. 基于车载视频图像的车辆检测与跟踪算法[J]. 同济大学学报(自然科学版), 2019 ,47(S1): 191-198.
- [18] 王志, 汪步云, 胡汉春, 等. 移动机器人导航系统中的车道线检测方法及其实现[J]. 计算机测量与控制, 2019, 27(09): 42-46.
- [19] 杨妍. 基于车道线的高速公路视频监控中车辆检测与跟踪研究[D]. 西安: 西安理工大学, 2019.
- [20] 黄晓青. 基于 Hough 变换的高速公路车道线检测算法设计[J]. 宁夏师范学院学报, 2018, 39(04): 57-61+72.
- [21] 李军, 钟鹏. OpenCV 的车道线检测方法[J]. 华侨大学学报(自然科学版), 2021, 42(04): 421-424.
- [22] 赵岩, 赵建国. 一种移动车辆遮挡下的车道线检测方法[J]. 科学技术与工程, 2021, 21(07): 2782-2787.
- [23] 邓元望, 蒲宏韬, 华鑫斌, 等. 基于 RC-DBSCAN 的车道线检测研究[J]. 湖南大学学报(自然科学版), 2021, 48(10): 85-92.
- [24] Abualsaud H, Liu S, Lu D B, et al. Laneaf: Robust multi-lane detection with affinity fields[J]. IEEE Robotics and Automation Letters, 2021, 6(4): 7477-7484.
- [25] 高扬, 王晨, 李昭健. 基于深度学习的无人驾驶汽车车道线检测方法[J]. 科学技术与工程, 2021, 21(24): 10401-10406.
- [26] 刘莉. 智能交通场景的车道线检测方法研究[D]. 南京: 南京航空航天大学, 2020.
- [27] Tabelini L, Berriel R, Paixao T M, et al. Keep your eyes on the lane: Real-time attention-guided lane detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 294-302.
- [28] Lee H S, Kim K. Simultaneous traffic sign detection and boundary estimation using convolutional neural network[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 19(5): 1652-1663.
- [29] 刘顺民, 马致明, 陈炳才. 基于 SSD 算法的交通指示牌目标检测[J]. 现代电子技术, 2021, 44(13): 144-147.
- [30] 陈柏立, 林楠. 基于卷积神经网络的交通路标识别[J]. 计算机与现代化, 2018(07): 103-107+113.
- [31] 霍爱清, 张文乐, 李浩平. 基于深度残差网络和 GRU 的 SqueezeNet 模型的交通路标识别[J]. 计算机工程与科学, 2020, 42(11): 2030-2036.
- [32] Wang L, Sun P, Xie M, et al. Advanced driver-assistance system (ADAS) for intelligent

- transportation based on the recognition of traffic cone[J]. Advances in Civil Engineering, 2020, 2020.
- [33] Yong H, Jianru X. Real-time traffic cone detection for autonomous vehicle[C]//2015 34th Chinese Control Conference (CCC). IEEE, 2015: 3718-3722.
- [34] SHI J, WANG G, WANG J. Recognition of traffic cone in micro-traffic environment [J]. Journal of Hefei University of Technology (Natural Science), 2012, 12: 014.
- [35] Qie L, Gong J, Zhou H, et al. Cone Detection and Location for Formula Student Driverless Race[C]//2019 6th International Conference on Dependable Systems and Their Applications (DSA). IEEE, 2020: 440-444.
- [36] Zhou L, Wang H, Wang D, et al. Traffic cone detection and localization in TechX Challenge 2013[C]//2014 13th International Conference on Control Automation Robotics & Vision (ICARCV). IEEE, 2014: 54-58.
- [37] Jun NI, Jibin HU. Autonomous driving system design for formula student driverless racecar[C]//2018 IEEE Intelligent Vehicles Symposium (IV). IEEE, 2018: 1-6.
- [38] Dhall A, Dai D, Van Gool L. Real-time 3D traffic cone detection for autonomous driving[C]//2019 IEEE Intelligent Vehicles Symposium (IV). IEEE, 2019: 494-501.
- [39] 陈玉平, 刘波, 林伟伟, 等. 云边协同综述[J]. 计算机科学, 2021,48(03):259-268.
- [40] Wang S, Yang S, Zhao C. SurveilEdge: Real-time Video Query based on Collaborative Cloud-Edge Deep Learning[C]//IEEE INFOCOM 2020-IEEE Conference on Computer Communications. IEEE, 2020: 2519-2528.
- [41] Wu D, Han X, Yang Z, et al. Exploiting transfer learning for emotion recognition under cloud-edge-client collaborations[J]. IEEE Journal on Selected Areas in Communications, 2020, 39(2): 479-490.
- [42] Ghosh A M, Grolinger K. Deep learning: Edge-cloud data analytics for iot[C]//2019 IEEE Canadian Conference of Electrical and Computer Engineering (CCECE). IEEE, 2019: 1-7.
- [43] Li E, Zhou Z, Chen X. Edge intelligence: On-demand deep learning model co-inference with device-edge synergy[C]//Proceedings of the 2018 Workshop on Mobile Edge Communications. 2018: 31-36.
- [44] 唐博恒, 柴鑫刚. 基于云边协同的计算机视觉推理机制[J]. 电信科学, 2021, 37(05): 72-81.
- [45] 马富齐, 王波, 董旭柱, 等. 电力视觉边缘智能: 边缘计算驱动下的电力深度视觉加速技术[J]. 电网技术, 2020, 44(06): 2020-2029.
- [46] 康刚. 货车后置防撞垫碰撞仿真研究[D]. 北京: 华北电力大学, 2017.
- [47] 佟兴, 张召, 金澈清, 等. 面向端边云协同架构的区块链技术综述[J]. 计算机学报, 2021, 44(12): 2345-2366.
- [48] Yu W, Liang F, He X, et al. A survey on the edge computing for the Internet of Things[J].

IEEE access, 2017, 6: 6900-6919.

- [49] 史林波. 自动驾驶中路锥车道的识别方法及其路径规划研究[D]. 成都: 电子科技大学, 2020.
- [50] 赵晓雷. 基于小波变换和均值滤波的图像去噪研究[J]. 信息技术, 2017(02): 69-71+7- 5.
- [51] 安春莲, 杨古月, 杨延菊. 基于中值滤波预处理的强冲击噪声背景测向方法[J]. 电子学报, 2021,49(06):1159-1166.
- [52] 廖建尚, 王立国, 郝思媛. 基于双边滤波和空间邻域信息的高光谱图像分类方法[J]. 农业机械学报, 2017, 48(08): 140-146+211.
- [53] 宋琴琴, 杨国平. 基于 HSV 颜色阈值分割的车道线检测[J]. 计算机与数字工程, 2021, 49(09): 1895-1898.
- [54] 刘寿鑫, 龙伟, 李炎炎, 等. 融合彩色模型空间的非线性低照度图像增强[J]. 四川大学学报(自然科学版), 2021, 58(01): 57-64.
- [55] 白金柯, 孙彩云. 基于 HSV 颜色模型和形状特征的交通标志检测算法研究[J]. 河南科技, 2019(23): 91-92.
- [56] 毕秀丽, 邱雨檬, 肖斌, 等. 基于统计特征的图像直方图均衡化检测方法[J]. 计算机学报, 2021, 44(02): 292-303.
- [57] 林明哲. 基于图像分割及逆透视变换的车道线检测算法研究[D]. 长沙: 湖南大学, 2020.
- [58] 杜晨健. 基于图像处理的交通锥识别与定位算法研究[D]. 郑州: 郑州大学, 2017.
- [59] Land E H, McCann J J. Lightness and retinex theory[J]. Josa, 1971, 61(1): 1-11.
- [60] Ahn H, Keum B, Kim D, et al. Adaptive local tone mapping based on retinex for high dynamic range images[C]//2013 IEEE International Conference on Consumer Electronics (ICCE). IEEE, 2013: 153-156.
- [61] Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint arXiv: 1704.04861, 2017.
- [62] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv: 2004.10934, 2020.
- [63] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 37(9): 1904-1916.
- [64] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segmentation[C]// Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 8759-8768.
- [65] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28.
- [66] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint arXiv:

1804.02767, 2018.

- [67] Wang C Y, Liao H Y M, Wu Y H, et al. CSPNet: A new backbone that can enhance learning capability of CNN[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops. 2020: 390-391.
- [68] Howard A, Sandler M, Chu G, et al. Searching for mobilenetv3[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 1314-1324.
- [69] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 4510-4520.
- [70] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [71] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [72] Qilong Wang, Banggu Wu, Pengfei Zhu, et al. ECA-Net: Efficient Channel Attention for Deep Convolutional Neural Networks[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 11534–11542.

致 谢

时光荏苒，转眼间，三年的研究生求学生活已接近尾声。回首三年的点点滴滴，充满了酸甜苦辣，更有收获和成长。在这里借此机会，感谢身边的各位师长、同学、亲人、朋友，感谢他们给予我无微不至的关照与呵护，感谢他们给予我人生道路的指导和鼓励。

首先，非常感谢我的导师潘为刚教授。潘老师严谨的治学态度、深刻的思想见解和严格的学术要求深深影响着我。从论文的选题、提纲，到文稿的修改、润色，都倾注了潘老师的心血和精力。在潘老师的教导和帮助下，我学到的不仅是专业知识，更学到了研究问题的方法以及如何做人做事。

感谢王书新老师对论文的指导和帮助，您诲人不倦的教学精神，给了我无限的学习动力。感谢王目树老师、高嵩老师、康超老师、秦石铭老师、张允刚老师、杨光老师，感谢实验室各位老师对我的指导和帮助。

感谢实验室的兄弟姐妹们，感谢你们的支持和帮助。感谢杜连旗、王康、李清洲、赵天怀、高琬琦、董兴学、徐飞、胡浩、李正磊，感谢 301 实验室的全体同学，感谢你们平时在学习和生活上的关心帮助。

最后，要感谢我的父母和家人，是你们用无私的爱浇灌我茁壮成长，感谢你们一如既往的鼓励和支持，你们的付出让我在求学的道路上没有了顾虑，激励我不断前行。三年的学业即将结束，不久后我将踏入工作岗位，我一定会踏实工作，好好报答你们，今后让你们度过幸福的时光。未来的人生道路，我将携手我的另一半一起度过。

请允许我向百忙中参予本论文评阅以及答辩的专家、老师致以衷心的感谢！

在校期间主要科研成果

一、发表学术论文

- [1] 刘志远, 胡冠山. 多电机并行控制系统方案设计[J]. 电子世界, 2021(13): 158-159. 第一位
- [2] 杜连旗, 刘志远, 潘为刚. 手术刀遥控的智能无影灯随动系统设计[J]. 单片机与嵌入式系统应用, 2020, 20(09): 39-42. 第二位
- [3] Wang Shuxin, Liu Zhiyuan, Pan Weigang, et al. Research on Small Target Traffic Cone Recognition Algorithm Based on Improved MobileNetV3_YoloV4[J]. Journal of the Optical Society of America A-optics Image Science and Vision. (SCI, Peer Review) 第二位

二、其它科研成果

- [1] 潘为刚, 刘志远, 杜连旗, 等. 能自动跟踪手术刀的智能无影灯控制系统及方法[P]. 山东省: ZL202010224828.0[P]. 发明专利, 第二位(导师第一位)
- [2] 刘志远, 张允刚, 潘为刚, 等. 一种攀岩计时器控制系统[P]. 山东省: ZL202122538554.5[P]. 实用新型专利, 第一位
- [3] 胡浩, 王书新, 刘志远, 等. 一种室内闪送机器人[P]. 山东省: ZL202122862980.4[P]. 实用新型专利, 第三位
- [4] 刘志远, 赵天怀, 徐飞. 车道级智能防闯入主动预警跟随车系统 第十六届中国研究生电子设计竞赛华北分赛区团队三等奖。第一位
- [5] 刘志远, 胡浩, 范伟旭, 等. 车道级智能防闯入主动预警跟随车 第八届山东省大学生科技创新大赛三等奖。第一位